ĐẠI HỌC QUỐC GIA HÀ NỘI
TRƯỜNG ĐẠI HỌC CÔNG NGHỆ

LÊ HOÀNG

HỌC SÂU PHÂN LỚP CÁC KIỂU PHỤ CỦA MỘT LOẠI UNG THƯ VÀ ỨNG DỤNG

LUẬN VĂN THẠC SĨ KHOA HỌC MÁY TÍNH

HÀ NỘI - 2024

ĐẠI HỌC QUỐC GIA HÀ NỘI
TRƯỜNG ĐẠI HỌC CÔNG NGHỆ

LÊ HOÀNG

HỌC SÂU PHÂN LỚP CÁC KIỂU PHỤ CỦA MỘT LOẠI UNG THƯ VÀ ỨNG DỤNG

Ngành: Khoa học máy tính
Chuyên ngành: Khoa học máy tính
Mã số: 8480101.01

LUẬN VĂN THẠC SĨ KHOA HỌC MÁY TÍNH

NGƯỜI HƯỚNG DẪN KHOA HỌC: TS. Hoàng Thị Điệp

HÀ NỘI - 2024

VIETNAM NATIONAL UNIVERSITY, HANOI
UNIVERSITY OF ENGINEERING AND TECHNOLOGY

LE HOANG

DEEP LEARNING FOR CLASSIFICATION OF SUBTYPES OF CANCER AND ITS APPLICATION

Major: Computer Science
Specialization: Computer Science
Code: 8480101.01

MASTER THESIS IN COMPUTER SCIENCE

SUPERVISORS: Dr. Hoang Thi Diep

Hanoi - 2024

LỜI CAM ĐOAN

Luận văn thạc sĩ "Học sâu phân lớp các kiểu phụ của một loại ung thư và ứng dụng" là công trình nghiên cứu của bản thân tôi. Mọi nội dung, kết quả nghiên cứu được thực hiện trung thực, các nguồn tham khảo đều được trích dẫn đầy đủ và chính xác theo quy định, dưới sự hướng dẫn khoa học của TS. Hoàng Thị Điệp.

Nếu vi phạm những điều trên, tôi xin chịu hoàn toàn trách nhiệm và chấp nhận mọi hình thức xử lý theo quy định hiện hành của Trường Đại học Công nghệ - Đại học Quốc gia Hà Nội.

Hà Nội, ngày 18 tháng 11 năm 2024

Học viên

Lê Hoàng

LỜI CẢM ƠN

Để có thể hoàn thành luận văn thạc sĩ này, tôi xin gửi lời tri ân sâu sắc tới Khoa Công nghệ Thông tin, Trường Đại học Công nghệ - Đại học Quốc gia Hà Nội, nơi đã tạo điều kiện tốt nhất cho việc học tập và nghiên cứu của tôi.

Với lòng biết ơn chân thành, tôi xin gửi lời cảm ơn đặc biệt đến TS. Hoàng Thị Điệp. Sự tận tâm hướng dẫn và những đóng góp chuyên môn quý báu của cô là nền tảng giúp tôi vững bước hoàn thành nghiên cứu này.

Xin trân trọng cảm ơn đề tài QG.23.34 đã hỗ trợ để thực hiện luận văn này.

Tôi xin bày tỏ lòng biết ơn sâu sắc đến các thầy cô giáo đã dìu dắt, truyền đạt kiến thức và tạo nền tảng vững chắc cho con đường nghiên cứu của tôi.

Xin gửi lời cảm ơn đến gia đình đã luôn ủng hộ và là chỗ dựa vững chắc cho tôi. Cảm ơn các em trong nhóm nghiên cứu Tin sinh học của TS. Hoàng Thị Điệp - Tăng Thanh Hà và Nguyễn Minh Hiển - đã luôn đồng hành và hỗ trợ tôi trong suốt quá trình nghiên cứu.

Hà Nội, ngày 18 tháng 11 năm 2024

Học viên

Lê Hoàng

TÓM TẮT

Tóm tắt: Sự phát triển của công nghệ giải trình tự thế hệ mới đã tạo ra khối lượng lớn dữ liệu omics, mở ra những thách thức mới trong nghiên cứu ung thư. Luận văn này đề xuất một khung chương trình cho việc phân loại kiểu phụ ung thư vú và khai phá dấu ấn sinh học từ dữ liệu đa omics, tập trung vào hệ thống phân loại PAM50 với năm kiểu phụ: Basal-like, Normal-like, LumA, LumB và Her2. Nghiên cứu phát triển một cách tiếp cận tích hợp, kết hợp các yếu tố từ kiến trúc MOGONET và DeepSSC để xử lý dữ liệu không cân bằng hiệu quả hơn. Nghiên cứu tập trung vào việc thiết kế và đánh giá các baseline khác nhau cho giải thuật Integrated Gradient trong bối cảnh khai phá dấu ấn sinh học từ dữ liệu đa omics. Kết quả nghiên cứu cho thấy hiệu quả của cách tiếp cận đề xuất trong việc phân loại kiểu phụ ung thư vú và khai phá dấu ấn sinh học. Các baseline được thiết kế cho Integrated Gradient giúp xác định được nhiều gen có ý nghĩa sinh học, được xác nhận qua đối chiếu với cơ sở dữ liệu CTD. Bên cạnh các gen đã biết, nghiên cứu cũng phát hiện một số gen tiềm năng mới như ATG10, UBLCP1 và MRPL13.Khung chương trình được đề xuất có thể được ứng dụng trong nghiên cứu ung thư và y học chính xác, hỗ trợ việc phân loại kiểu phụ bệnh và phát triển các phương pháp điều trị phù hợp.

Từ khóa: *Học sâu, Dữ liệu đa omics, Ung thư vú, PAM50, Dấu ấn sinh học, Integrated Gradient, Trí tuệ nhân tạo có khả năng giải thích*

ABSTRACT

Abstract: The advancement of next-generation sequencing technologies has generated vast amounts of omics data, presenting new challenges in cancer research. This thesis proposes a framework for breast cancer subtype classification and biomarker discovery from multi-omics data, focusing on the PAM50 classification system with five subtypes: Basal-like, Normal-like, LumA, LumB, and Her2. The research develops an integrated approach, combining elements from MOGONET and DeepSSC architectures for more effective handling of imbalanced data. The study focuses on designing and evaluating various baselines for the Integrated Gradient algorithm in the context of biomarker discovery from multi-omics data. The results demonstrate the effectiveness of the proposed approach in breast cancer subtype classification and biomarker discovery. The designed baselines for Integrated Gradient help identify biologically significant genes, validated through comparison with the CTD database. Besides known genes, the study also identifies several potential novel genes such as ATG10, UBLCP1, and MRPL13. The proposed framework can be applied in cancer research and precision medicine, supporting disease subtype classification and the development of appropriate treatment approaches .

Keywords: *Deep Learning, Multi-omics Data, Breast Cancer, PAM50, Biomarkers, Integrated Gradient, Explainable AI*

Mục lục

Lời cam đoan **i**

Lời cảm ơn **ii**

Tóm tắt **iii**

Abstract **iv**

Danh sách hình vẽ **vii**

Danh sách bảng **x**

Danh sách thuật toán **xi**

Danh mục các thuật ngữ, ký hiệu và chữ viết tắt **xii**

Đặt vấn đề **1**

Chương 1 Kiến thức nền tảng **6**

1.1. Y học chính xác và các loại dữ liệu -omics 6

1.1.1. Y học chính xác là gì 6

1.1.2. Dữ liệu omics và các bộ dữ liệu liên quan 9

1.1.3. Dấu ấn sinh học là gì? Tại sao phát triển các giải pháp giúp khai phá bộ dấu ấn sinh học lại mang nhiều ý nghĩa? 12

1.1.4. Comparative Toxicogenomics Database (CTD) 14

1.2. Học máy và học sâu 15

1.2.1. Giới thiệu về các mô hình hình học máy và học sâu 15

1.2.2. Giới thiệu một số chỉ số quan trọng để đánh giá hiệu năng mô hình 19
1.3. Giải thuật hỗ trợ giải thích các mô hình học sâu 20
1.3.1. Feature Ablation 21
1.3.2. Integrated Gradient 23
1.4. Các nghiên cứu liên quan 26
1.4.1. MOGONET 26
1.4.2. DeepSSC 28
1.4.3. So sánh MOGONET và DeepSSC 29
Chương 2 Phương pháp 32
2.1. Tổng quan phương pháp tiếp cận 32
2.2. Kiến trúc chung của khung chương trình 34
2.3. Thiết kế thí nghiệm 36
2.4. Các baseline và giải thuật tổng hợp điểm trong khai phá dấu ấn sinh học . 39
2.4.1. Phân loại và thiết kế baseline cho Integrated Gradient 39
2.4.2. Giải thuật tổng hợp điểm quan trọng của đặc trưng 47
Chương 3 Thực nghiệm và kết quả 49
3.1. Dữ liệu và môi trường thực thi 49
3.1.1. Chi tiết dữ liệu thực nghiệm và tiền xử lý 49
3.1.2. Chi tiết kiến trúc và môi trường tính toán 53
3.2. Kết quả và phân tích 55
3.2.1. Kết quả huấn luyện phân loại trong Pha 1 56
3.2.2. Chất lượng các dấu ấn sinh học được khai phá 57
3.2.3. Tổng kết 66
Chương 4 Kết luận và thảo luận 67
4.1. Kết luận 67

4.2. Thảo luận về kết quả chính 68
4.2.1. Mối quan hệ giữa kiến trúc mạng và phương pháp giải thích mô hình 68
4.2.2. Phân tích hiệu năng và ý nghĩa sinh học 69
4.2.3. Đóng góp của nghiên cứu 69
4.2.4. Hạn chế và hướng phát triển tương lai 70
4.2.5. Tiềm năng ứng dụng 71

Danh mục công trình khoa học của tác giả liên quan đến luận văn 72

Tài liệu tham khảo 73

Danh sách hình vẽ

1.1 Tổng quan về Y học chính xác 7

1.2 Thành phần và tác động của y học chính xác 8

1.3 Cấu trúc của một mạng nơ ron cơ bản. 16

1.4 Cấu trúc của một nơ ron tự mã hóa. 17

1.5 Cấu trúc của một mạng nơ ron tích chập (CNN). 18

1.6 Quy trình thực hiện cơ bản của Feature Ablation. 22

1.7 Nguyên lý cốt lõi của Integrated Gradient[1] 23

1.8 Một vài gợi ý cơ bản về lựa chọn baseline cho các dữ liệu khác nhau Integrated Gradient 25

1.9 Kiến trúc học tích hợp các loại dữ liệu -omics của MOGONET giúp phân loại các kiểu phụ của bệnh [54] 27

1.10 Kiến trúc học tích hợp các loại dữ liệu -omics của DeepSSC giúp phân loại các kiểu phụ của bệnh [57] 29

2.1 Khung chương trình khai phá và đánh giá các dấu ấn sinh học tiềm năng . 34

3.1 So sánh hiệu năng của ba mô hình - Logistic Regression, SVM và Random Forest - trên tập kiểm thử với các dấu ấn sinh học được khai phá từ DeepSSC và MOGONET thông qua giải thuật dựa trên Integrated Gradient 58

3.1 So sánh hiệu năng của ba mô hình - Logistic Regression, SVM và Random Forest - trên tập kiểm thử với các dấu ấn sinh học được khai phá từ DeepSSC và MOGONET thông qua giải thuật dựa trên Integrated Gradient (tiếp theo) 59

3.2 So sánh hiệu năng của các phương pháp khai phá dấu ấn sinh học trên kiến trúc MOGONET sử dụng thang đo F1-macro 61

3.3 So sánh hiệu năng của các phương pháp khai phá dấu ấn sinh học trên kiến trúc DeepSSC sử dụng thang đo F1-macro 62

3.4 Số lượng các dấu ấn sinh học trùng khớp với CTD theo các tốp 64

3.5 Liệt kê chi tiết các gen trùng lặp theo các tốp 65

Danh sách bảng

3.1 Phân bố mẫu theo kiểu phụ ung thư vú 50

3.2 Kết quả huấn luyện đánh giá trên tập kiểm định 56

4.1 Danh sách các công trình nghiên cứu 72

Danh sách thuật toán

2.1 Tính toán và tổng hợp điểm tiềm năng đặc trưng sử dụng IG 48

Danh mục các thuật ngữ, ký hiệu và chữ viết tắt

Sinh học phân tử và Dữ liệu omics		
Từ viết tắt	**Từ đầy đủ**	**Định nghĩa**
aCGH	Array Comparative Genomic Hybridization	Kỹ thuật lai so sánh bộ gen trên chip vi mảng
BRCA	Breast Cancer	Loại ung thư phát triển từ mô vú, thường được phân loại thành các kiểu phụ PAM50 gồm 5 kiểu phụ là Basal-like, Her2-enriched, LumA, LumB, và Normal-like
CNA	Copy Number Alteration	Sự thay đổi số lượng bản sao của một đoạn DNA trong bộ gen
–	Epigenomics	Nghiên cứu về biến đổi di truyền không làm thay đổi trình tự DNA
GE	Gene Expression	Sự biểu hiện gen
–	Genomics	Nghiên cứu về cấu trúc, chức năng và tiến hóa của bộ gen
–	Metabolomics	Nghiên cứu về các sản phẩm chuyển hóa trong tế bào
mRNA	messenger RNA	RNA thông tin, mang thông tin di truyền từ DNA để tổng hợp protein
–	Multi-omics	Phương pháp tích hợp và phân tích nhiều loại dữ liệu omics

Từ viết tắt	Từ đầy đủ	Định nghĩa
NGS	Next Generation Sequencing	Công nghệ giải trình tự thế hệ mới
–	omics	Công nghệ OMICS đại diện cho một lĩnh vực nghiên cứu tương đối mới, mô tả sự tích hợp của các phương pháp sinh học phân tử khác nhau kết thúc bằng "-omics"
–	Proteomics	Nghiên cứu về cấu trúc và chức năng của protein
TCGA	The Cancer Genome Atlas	Dự án nghiên cứu về bộ gen ung thư quy mô lớn
–	Transcriptomics	Nghiên cứu về toàn bộ RNA trong tế bào
Mô hình và Phương pháp học máy/học sâu		
AE	AutoEncoder	Mô hình mạng nơ ron tự động học cách nén và khôi phục dữ liệu
CNN	Convolutional Neural Networks	Mạng nơ ron tích chập cho xử lý dữ liệu có cấu trúc lưới
DAE	Denoising Autoencoder	Mô hình autoencoder có khả năng khử nhiễu
DeepSSC	Deep Semi-supervised multi-omics integration framework for Subtype Classification	Khung tích hợp đa omics bán giám sát cho phân loại kiểu phụ
GCN	Graph Convolutional Network	Mạng nơ ron đồ thị tích chập
LG	Logistic Regression	Mô hình thống kê cho bài toán phân loại
MOGONET	Multi-Omics Graph cOnvolutional NETworks	Mạng nơ ron đồ thị tích chập cho dữ liệu đa omics
RF	Random Forest	Tập hợp nhiều cây quyết định cho bài toán phân loại và hồi quy

Từ viết tắt	Từ đầy đủ	Định nghĩa
SVM	Support Vector Machines	Mô hình học máy dựa trên việc tìm siêu phẳng tối ưu
VCDN	View Correlation Discovery Network	Mạng khám phá tương quan giữa các góc nhìn
Phân tích và Giải thích mô hình		
FA	Feature Ablation	Phương pháp đánh giá tầm quan trọng của đặc trưng bằng cách loại bỏ
IG	Integrated Gradient	Phương pháp quy trách nhiệm trong XAI dựa trên tích phân gradient
XAI	Explainable Artificial Intelligence	Phương pháp giúp hiểu và giải thích quyết định của mô hình AI
Đánh giá hiệu năng		
–	Accuracy	Độ chính xác tổng thể: Tỷ lệ dự đoán đúng trên tổng số mẫu
–	F1-score	Điểm đánh giá hiệu năng trung bình điều hòa của precision và recall
–	F1-macro	Trung bình cộng của điểm F1 tính riêng cho từng lớp, mỗi lớp có trọng số như nhau
–	F1-weighted	Trung bình có trọng số của điểm F1 tính riêng cho từng lớp, trọng số dựa trên số lượng mẫu của mỗi lớp
–	Precision	Độ chính xác dương tính: Tỷ lệ dự đoán đúng trong các dự đoán dương tính
–	Recall	Độ phủ: Tỷ lệ phát hiện đúng các mẫu dương tính thực sự
Phương pháp lấy mẫu và Dấu ấn sinh học		
–	Stratified K-fold	Phương pháp chia dữ liệu có phân tầng thành k phần
–	Stratified Random Sampling	Phương pháp lấy mẫu ngẫu nhiên có phân tổ

Từ viết tắt	Từ đầy đủ	Định nghĩa
–	Biomarkers	Chỉ thị sinh học dùng để đánh giá tình trạng sinh học
CTD	Comparative Toxicogenomics Database	Cơ sở dữ liệu về mối quan hệ giữa gen, hóa chất và bệnh uy tín
–	Gold standard	"Tiêu chuẩn vàng" dùng tham chiếu được chấp nhận rộng rãi
–	Inference Score	Điểm số đánh giá mức độ tin cậy của suy luận một chỉ số mà CTD đưa ra

Đặt vấn đề

Sự phát triển vượt bậc của công nghệ giải trình tự thông lượng cao đã mở ra kỷ nguyên mới trong việc thu thập và phân tích dữ liệu sinh học [14]. Kết quả là sự gia tăng đáng kể các nguồn tài nguyên dữ liệu omics - dữ liệu sinh học phân tử quy mô lớn, bao gồm genomics (nghiên cứu về bộ gen), transcriptomics (nghiên cứu về biểu hiện gen), proteomics (nghiên cứu về protein), metabolomics (nghiên cứu về chất chuyển hóa) và epigenomics (nghiên cứu về biến đổi di truyền không làm thay đổi trình tự DNA). Những bộ dữ liệu này đóng vai trò then chốt trong việc giải mã các bí ẩn phức tạp của quá trình sinh học và bệnh lý, đặc biệt trong lĩnh vực nghiên cứu ung thư [24, 33, 34, 50].

Song song với sự phát triển này, khái niệm y học chính xác đã nổi lên như một hướng tiếp cận đầy hứa hẹn trong việc cải thiện chăm sóc sức khỏe. Y học chính xác hướng tới việc cung cấp phương pháp chẩn đoán, dự phòng và điều trị được cá nhân hóa dựa trên đặc điểm di truyền, môi trường và lối sống của từng cá nhân. Trong bối cảnh này, phân tích dữ liệu omics nói chung và tích hợp đa omics nói riêng đóng vai trò then chốt, cung cấp cái nhìn toàn diện và sâu sắc hơn về các cơ chế phân tử phức tạp đằng sau các bệnh lý, đặc biệt là ung thư [37].

Tuy nhiên, việc khai thác hiệu quả dữ liệu omics đặt ra nhiều thách thức đáng kể. Kích thước và độ phức tạp của dữ liệu, với số chiều lên đến hàng triệu đặc trưng nhưng số lượng mẫu tương đối nhỏ, không chỉ gây khó khăn trong việc xử lý và lưu trữ, mà còn đặt ra thách thức lớn trong việc phân tích và trích xuất thông tin có ý nghĩa [39]. Bên cạnh đó, dữ liệu omics thường chứa nhiều nhiễu và biến động do các yếu tố kỹ thuật và sinh học. Sự không đồng nhất trong dữ liệu, xuất phát từ việc thu thập từ nhiều nguồn khác nhau và sử dụng các nền tảng và phương pháp khác nhau, càng làm tăng thêm độ phức tạp trong quá trình phân tích [38]. Hơn nữa, các đặc trưng trong dữ liệu omics thường có mối quan hệ phức tạp và phi tuyến tính với nhau, gây khó khăn trong việc hiểu và mô

hình hóa các quá trình sinh học.

Trong những năm gần đây, lĩnh vực phân tích dữ liệu omics đã chứng kiến sự chuyển dịch đáng kể từ các phương pháp thống kê truyền thống và học máy cổ điển sang các kỹ thuật học sâu [23, 35]. Sự chuyển dịch này được thúc đẩy bởi khả năng vượt trội của học sâu trong việc xử lý dữ liệu phức tạp và đa chiều, đặc biệt là khả năng tích hợp và phân tích đồng thời nhiều loại dữ liệu omics. Các mô hình học sâu đã chứng minh hiệu quả trong việc nắm bắt các mối quan hệ phi tuyến tính và phức tạp giữa các đặc trưng [35, 45], một thách thức mà các phương pháp truyền thống thường gặp khó khăn. Tuy nhiên, cùng với những lợi ích to lớn, học sâu cũng đặt ra thách thức đáng kể về tính "hộp đen" của nó. Khả năng giải thích hạn chế này tạo ra một khoảng cách đáng kể giữa kết quả dự đoán và sự hiểu biết của các chuyên gia y tế về cơ chế bệnh lý. Đây là lúc trí tuệ nhân tạo có khả năng giải thích (Explainable AI hay viết tắt là XAI) trở nên quan trọng [53]. Các kỹ thuật XAI nhằm mục tiêu làm cho quá trình ra quyết định của các mô hình học sâu trở nên dễ hiểu hơn, từ đó thu hẹp khoảng cách giữa hiệu năng dự đoán cao và khả năng diễn giải kết quả. Trong bối cảnh phân tích dữ liệu omics và nghiên cứu ung thư, việc kết hợp học sâu với XAI mở ra triển vọng không chỉ cải thiện độ chính xác trong việc phân loại và dự đoán, mà còn cung cấp những hiểu biết có giá trị về cơ chế phân tử đằng sau các kiểu phụ bệnh. Đặc biệt, phương pháp này có tiềm năng lớn trong việc xác định các dấu ấn sinh học (Biomarkers) mới và đáng tin cậy, góp phần quan trọng vào sự phát triển của y học chính xác và điều trị cá nhân hóa.

Trong lĩnh vực nghiên cứu ung thư vú, hệ thống phân loại PAM50 xác định năm kiểu phụ chính là Basal-like, Normal-like, LumA, LumB, và Her2 đã trở thành một công cụ quan trọng trong nghiên cứu và thực hành lâm sàng [9]. Tuy nhiên, việc phân loại chính xác và hiểu rõ cơ chế phân tử đằng sau mỗi kiểu phụ vẫn còn nhiều thách thức. Đặc biệt, vấn đề mất cân bằng dữ liệu giữa các kiểu phụ có thể ảnh hưởng đáng kể đến hiệu năng của các mô hình học máy, đòi hỏi các chiến lược đặc biệt trong quá trình xây dựng, phân tích và đánh giá mô hình. Nhận thức được những thách thức này, nghiên cứu này đề xuất một khung làm việc mới nhằm khai phá các dấu ấn sinh học liên quan đến bệnh ung thư vú và các kiểu phụ của nó. Mục tiêu chính là phát triển các phương pháp để khai phá dấu ấu sinh học từ dữ liệu đa omics, với mục tiêu thu hẹp đáng kể số lượng gen cần xem xét, từ hàng chục nghìn xuống còn vài trăm hoặc thậm chí ít hơn.

Phương pháp tiếp cận của nghiên cứu được thiết kế theo một quy trình ba pha có

tính kế thừa và bổ sung cho nhau. Pha đầu tiên tập trung vào việc huấn luyện mô hình học sâu để phân loại hiệu quả năm kiểu phụ PAM50 của bệnh ung thư vú dựa trên dữ liệu tích hợp đa omics. Tiếp theo, pha thứ hai thực hiện phân tích chuyên sâu mô hình đã huấn luyện và xác định các dấu ấn sinh học thông qua một giải thuật cải tiến dựa trên nền tảng Integrated Gradient, trong đó đặc biệt chú trọng đến việc thiết kế và đánh giá các baseline phù hợp với bản chất của dữ liệu omics. Cuối cùng, pha thứ ba đánh giá toàn diện chất lượng của các dấu ấn sinh học được phát hiện bằng cách so sánh với danh sách "tiêu chuẩn vàng" từ các nguồn uy tín, đồng thời kiểm chứng giá trị của chúng thông qua việc đánh giá hiệu năng phân loại sử dụng các mô hình học máy truyền thống.

Để thực hiện thành công ba pha này, nghiên cứu tập trung vào ba hướng tiếp cận chính. Hướng tiếp cận thứ nhất bao gồm hai khía cạnh quan trọng: nghiên cứu và cải tiến kiến trúc mô hình học sâu, cũng như việc chuẩn bị dữ liệu chất lượng và thiết lập quy trình huấn luyện hiệu quả. Về khía cạnh dữ liệu, nghiên cứu tập trung vào việc xây dựng các quy trình tiền xử lý phù hợp cho từng loại dữ liệu omics, đồng thời phát triển các chiến lược tích hợp dữ liệu hiệu quả. Về mặt kiến trúc mô hình, nghiên cứu thực hiện đánh giá có hệ thống các kiến trúc hiện có trong phân tích tích hợp đa omics, đặc biệt chú trọng đến khả năng học các đặc trưng phức tạp từ dữ liệu biểu hiện gen và biến đổi số bản sao. Các cải tiến được đề xuất không chỉ tập trung vào việc nâng cao khả năng xử lý dữ liệu không cân bằng, mà còn hướng đến việc tối ưu hóa quá trình học các mối tương tác giữa các loại dữ liệu omics khác nhau. Thông qua quá trình nghiên cứu và thử nghiệm, nghiên cứu hướng tới việc xây dựng một phương pháp phù hợp cho việc phát triển mô hình học sâu trong bối cảnh phân tích tích hợp dữ liệu đa omics.

Hướng tiếp cận thứ hai tập trung vào việc phát triển baseline cho giải thuật dựa trên Integrated Gradient. Nghiên cứu tiến hành đánh giá các loại baseline phổ biến và đề xuất các baseline mới dựa trên đặc tính của dữ liệu omics. Quá trình so sánh hiệu năng giữa các baseline khác nhau giúp làm rõ tầm ảnh hưởng của việc lựa chọn và thiết kế baseline đối với chất lượng của dấu ấn sinh học được xác định, đặc biệt trong bối cảnh dữ liệu đa chiều và không cân bằng. Các baseline được đánh giá dựa trên nhiều tiêu chí khác nhau, bao gồm khả năng phát hiện các đặc trưng sinh học có ý nghĩa và tính ổn định của kết quả.

Hướng tiếp cận thứ ba kết hợp các kết quả từ hai hướng trước để đề xuất các chiến lược tối ưu trong việc thiết kế và triển khai mô hình học sâu cho bài toán khai phá dấu ấn

sinh học. Nghiên cứu phân tích mối quan hệ ba chiều giữa thiết kế baseline, kiến trúc mô hình học, và bản chất của dữ liệu omics để xây dựng một khung phương pháp toàn diện. Khung phương pháp này tập trung vào việc phân tích các yếu tố then chốt ảnh hưởng đến hiệu quả của quá trình khai phá dấu ấn sinh học, từ đó cung cấp một số gợi ý về cách tiếp cận phù hợp cho việc thiết kế mô hình học sâu và lựa chọn baseline. Điều này không chỉ cung cấp một cách tiếp cận có hệ thống cho việc khai phá dấu ấn sinh học, mà còn đề xuất các chiến lược để nâng cao độ tin cậy của kết quả thu được.

Thông qua việc thực hiện các thí nghiệm và đánh giá, nghiên cứu này hướng tới việc cải thiện phương pháp khai phá dấu ấn sinh học từ dữ liệu omics bằng cách kết hợp học sâu với các kỹ thuật XAI. Việc phát triển một phương pháp tích hợp giữa việc thiết kế mô hình học sâu phù hợp và áp dụng hiệu quả giải thuật Integrated Gradient có thể mang lại một cách tiếp cận mới trong việc khai phá thông tin từ dữ liệu omics. Kết quả của nghiên cứu có thể hỗ trợ cộng đồng nghiên cứu trong việc phân tích dữ liệu omics và xác định dấu ấn sinh học trong nghiên cứu ung thư vú. Đặc biệt, các gợi ý về thiết kế baseline và lựa chọn kiến trúc mô hình có thể giúp các nhà nghiên cứu tiếp cận bài toán một cách có hệ thống hơn.

Trong bối cảnh y học chính xác, nghiên cứu này tập trung vào việc kết hợp học sâu với kỹ thuật XAI để đánh giá mức độ đóng góp của các gen trong quá trình phân loại kiểu phụ của bệnh ung thư vú. Phương pháp này có thể hỗ trợ việc xác định các dấu ấn sinh học tiềm năng có ý nghĩa sinh học, từ đó góp phần vào quá trình chẩn đoán và dự đoán tiên lượng bệnh. Thông qua việc xác định có trọng số các gen quan trọng, nghiên cứu có thể giúp thu hẹp phạm vi tìm kiếm các mục tiêu nghiên cứu tiềm năng, góp phần tối ưu hóa nguồn lực và thời gian trong các nghiên cứu tiếp theo.

Hơn nữa, phương pháp được nghiên cứu có khả năng được điều chỉnh để áp dụng cho các loại ung thư khác, góp phần vào việc phát triển các phương pháp phân tích dữ liệu omics trong nghiên cứu và điều trị bệnh. Đặc biệt, các kinh nghiệm thu được trong quá trình thiết kế baseline cho dữ liệu omics có thể được tham khảo và điều chỉnh cho các bộ dữ liệu tương tự. Việc kết hợp học sâu với XAI trong nghiên cứu này cũng góp phần cải thiện khả năng diễn giải kết quả của các mô hình học máy trong lĩnh vực y sinh, từ đó có thể nâng cao khả năng ứng dụng của chúng trong thực hành lâm sàng. Điều này đặc biệt quan trọng trong lĩnh vực y học, nơi việc hiểu được cơ sở của các quyết định do mô hình đưa ra là một yêu cầu thiết yếu.

Phần còn lại của luận văn này được tổ chức thành các chương như sau: Chương 1 trình bày các kiến thức nền tảng cần thiết về tin sinh học, học máy và ung thư vú. Chương này nhằm cung cấp cho độc giả một nền tảng vững chắc để hiểu các khái niệm và phương pháp được sử dụng trong nghiên cứu. Chương 2 mô tả chi tiết phương pháp nghiên cứu, bao gồm việc thu thập và xử lý dữ liệu, thiết kế mô hình học sâu và áp dụng giải thuật dựa trên Integrated Gradient. Chương này cũng trình bày cách tiếp cận của nghiên cứu trong việc đối phó với các thách thức như dữ liệu không cân bằng và tính đa chiều của dữ liệu omics. Chương 3 trình bày kết quả nghiên cứu và thảo luận về ý nghĩa của các phát hiện. Chương này sẽ so sánh hiệu năng của các mô hình khác nhau, đánh giá chất lượng của các dấu ấn sinh học được xác định, và thảo luận về ý nghĩa sinh học của các kết quả. Cuối cùng, Chương 4 kết luận và đề xuất hướng nghiên cứu trong tương lai. Chương này sẽ tổng hợp các phát hiện chính của nghiên cứu, thảo luận về hạn chế của phương pháp hiện tại, và đề xuất các hướng nghiên cứu tiềm năng để phát triển thêm công việc này.

Chương 1

Kiến thức nền tảng

Trong chương này, chúng ta sẽ bắt đầu với một giới thiệu ngắn gọn về *Y học chính xác là gì? Dữ liệu omics* và ứng dụng của chúng. Sau đó, chúng ta sẽ cung cấp một cái nhìn tổng quan về *Học máy* và *Học sâu* với các định nghĩa cơ bản, các thuật toán học máy truyền thống, xuất phát điểm của mạng nơ ron nhân tạo và một số kiến trúc nền tảng quan trọng của học sâu.

1.1. Y học chính xác và các loại dữ liệu -omics

1.1.1. Y học chính xác là gì

Y học chính xác, hay còn gọi là y học cá thể hóa, là một phương pháp tiếp cận hiện đại trong chẩn đoán, phòng tránh và điều trị bệnh dựa trên thông tin di truyền phân tử của từng bệnh nhân (Hình 1.1). Đây là một hướng tiếp cận nhắm mục tiêu, nhằm đảm bảo đúng phương pháp, đúng bệnh, đúng thời điểm và đúng liều lượng cho từng cá nhân [20]. Khái niệm y học chính xác không phải là mới. Từ thời Hippocrates, các bác sĩ đã nhận ra rằng bệnh nhân phản ứng khác nhau với cùng một phương pháp điều trị [6]. Tuy nhiên, sự phát triển của y học chính xác như chúng ta biết ngày nay bắt đầu với Dự án Bộ gen Người (The Cancer Genome Atlas Program - TCGA) vào những năm 1990 và đạt được bước tiến lớn với sự ra đời của các công nghệ giải trình tự thế hệ mới vào đầu những năm 2000 [21].

Thông tin di truyền phân tử được sử dụng trong y học chính xác có thể bao gồm

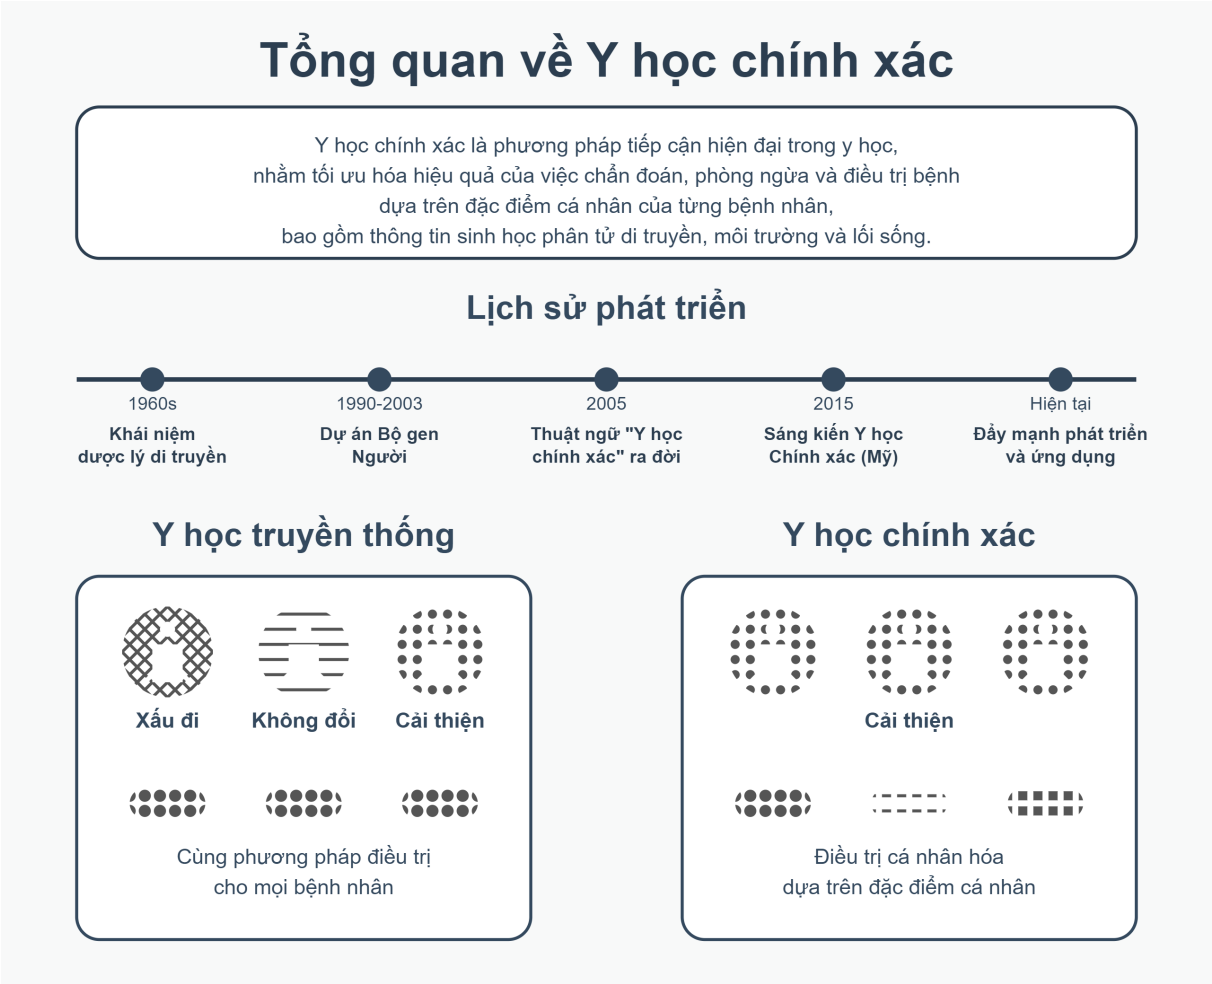

Hình 1.1: Tổng quan về Y học chính xác

các dữ liệu thuộc các ngành nghiên cứu như genomics, transcriptomics, proteomics, và các loại dữ liệu khác. Bằng cách kết hợp những thông tin này với các thông tin lâm sàng và hồ sơ bệnh án, y học chính xác mang lại những lợi ích lớn cho bệnh nhân, đặc biệt là trong việc sàng lọc, phát hiện sớm và điều trị các bệnh nguy hiểm [27]. Ví dụ, trong điều trị bệnh xơ nang, một bệnh di truyền ảnh hưởng đến hệ hô hấp và tiêu hóa, các nhà nghiên cứu đã phát hiện ra rằng đột biến cụ thể trong gen CFTR có thể ảnh hưởng đến hiệu quả của thuốc. Bệnh nhân có đột biến G551D trong gen CFTR đáp ứng tốt với ivacaftor, trong khi những bệnh nhân có đột biến khác có thể không được hưởng lợi từ thuốc này [15]. Đây là một ví dụ điển hình về cách y học chính xác có thể cá nhân hóa phương pháp điều trị, tăng hiệu quả và giảm tác dụng phụ không cần thiết.

Việc phát triển y học chính xác mang lại nhiều ý nghĩa quan trọng cho bệnh nhân và cộng đồng nghiên cứu khoa học (Hình 1.2). Đối với các bệnh nhân có nguy cơ cao

mắc bệnh, y học chính xác giúp xác định sớm và đưa ra biện pháp phòng ngừa hiệu quả. Ngoài ra, khả năng chẩn đoán chính xác và xây dựng phác đồ điều trị phù hợp với từng bệnh nhân giúp nâng cao hiệu quả điều trị và giảm thiểu chi phí [25]. Điều này đặc biệt quan trọng đối với những bệnh nhân mắc các bệnh khó chữa, nơi mà sự cá thể hóa trong điều trị có thể làm tăng cơ hội sống sót và cải thiện chất lượng cuộc sống. Về phía cộng đồng nghiên cứu, sự phát triển của y học chính xác mở ra những hướng đi mới, thu hút nguồn vốn đầu tư và xây dựng các nguồn dữ liệu sinh học quý giá. Điều này góp phần tạo ra một nền tảng vững chắc cho những nghiên cứu và ứng dụng mới, mang lại lợi ích lâu dài cho y học và khoa học [5].

Hình 1.2: Thành phần và tác động của y học chính xác

Tin sinh học đóng vai trò then chốt trong y học chính xác. Các công cụ và phương pháp tin sinh học được sử dụng để phân tích và diễn giải lượng lớn dữ liệu sinh học phức tạp, từ đó rút ra những hiểu biết có ý nghĩa lâm sàng [13]. Chẳng hạn như các thuật toán

học máy và trí tuệ nhân tạo đã được sử dụng để phân tích dữ liệu omics, nhận diện các dấu ấn sinh học mới, và dự đoán hiệu quả của các phương pháp điều trị [26]. Những tiến bộ trong lĩnh vực tin sinh học không chỉ giúp tăng tốc quá trình phân tích dữ liệu mà còn mở ra khả năng khám phá những mối liên hệ phức tạp giữa các yếu tố di truyền, môi trường và bệnh lý, từ đó đưa ra những hiểu biết mới về cơ chế bệnh và tiềm năng điều trị [18]. Tuy nhiên, việc nghiên cứu ứng dụng y học chính xác cũng đối mặt với nhiều thách thức. Một trong những thách thức lớn nhất là bảo mật và quyền riêng tư đối với dữ liệu di truyền của bệnh nhân [30]. Việc thu thập và lưu trữ thông tin di truyền cá nhân đặt ra những câu hỏi quan trọng về quyền sở hữu dữ liệu, quyền truy cập và sử dụng dữ liệu, cũng như các biện pháp bảo vệ chống lại việc sử dụng sai mục đích hoặc phân biệt đối xử dựa trên thông tin di truyền. Ngoài ra, chi phí cao trong các xét nghiệm di truyền và phân tích dữ liệu cũng là một rào cản đáng kể. Điều này có thể dẫn đến sự bất bình đẳng trong tiếp cận y tế [19]. Cuối cùng, việc đào tạo nhân lực có khả năng diễn giải và áp dụng kết quả từ các phân tích phức tạp này vào thực hành lâm sàng cũng là một thách thức không nhỏ, đòi hỏi sự đầu tư lớn vào giáo dục và đào tạo cho các chuyên gia y tế [7]. Các phần tiếp theo sẽ đi sâu vào khái niệm và đặc điểm của dữ liệu omics, một tập hợp các dữ liệu phân tử then chốt trong nghiên cứu hệ thống sinh học. Mỗi loại dữ liệu đều mang đến những thông tin độc đáo về hoạt động của tế bào sống. Bên cạnh đó, ta sẽ tìm hiểu về nguồn dữ liệu quan trọng cung cấp kho dữ liệu phong phú về các loại ung thư thông tin và về mối quan hệ giữa gen và bệnh. Việc nắm được bản chất của các dữ liệu này, cùng với khả năng khai thác hiệu quả các nguồn dữ liệu lớn, sẽ tạo nền tảng vững chắc cho việc phát triển các ứng dụng y học chính xác, đặc biệt trong việc chẩn đoán và điều trị ung thư.

1.1.2. Dữ liệu omics và các bộ dữ liệu liên quan

Dữ liệu omics là một tập hợp các dữ liệu phân tử được sử dụng để hiểu rõ hơn về cấu trúc, chức năng và động lực của các hệ thống sinh học. Trong bối cảnh y học chính xác, dữ liệu omics đóng vai trò then chốt trong việc cá nhân hóa chẩn đoán và điều trị dựa trên hồ sơ sinh học của từng bệnh nhân. Các loại dữ liệu omics chính bao gồm genomics, transcriptomics, proteomics, metabolomics, và epigenomics, mỗi loại cung cấp một góc nhìn độc đáo về các quá trình sinh học [44].

Genomics là ngành nghiên cứu toàn bộ bộ gen của một sinh vật. Ngành này tập

trung vào cấu trúc, chức năng và sự tiến hóa của gen, đồng thời là nền tảng của luận thuyết trung tâm trong sinh học phân tử. Dữ liệu genomics cung cấp thông tin về các biến đổi di truyền và cách chúng ảnh hưởng đến các tính trạng, bệnh lý của cá nhân. Trong đó, biến thể số lượng bản sao (Copy Number Alteration - CNA) là một loại biến đổi di truyền quan trọng, liên quan tới sự thay đổi số lượng bản sao của các đoạn DNA trong bộ gen. CNA có thể ảnh hưởng đáng kể đến sự biểu hiện gen và đóng vai trò quan trọng trong nhiều bệnh lý, đặc biệt trong ung thư. Để phát hiện CNA, các nhà khoa học thường sử dụng các công nghệ như aCGH (Microarray-based Comparative Genomic Hybridization) và giải trình tự thế hệ mới (Next Generation Sequencing).

Sau genomics, transcriptomics là bước tiếp theo trong luận thuyết trung tâm với việc nghiên cứu biểu hiện gen thông qua phân tích RNA. Dữ liệu transcriptomics, đặc biệt là mức biểu hiện của RNA thông tin (mRNA expression hay gene expression - GE), giúp ta hiểu rõ cách các gen được bật và tắt trong các tế bào, mô dưới các điều kiện khác nhau. Phân tích GE không chỉ cung cấp thông tin về mức độ hoạt động của các gen cụ thể, mà còn có thể tiết lộ các thay đổi trong biểu hiện gen liên quan đến bệnh lý hoặc đáp ứng với điều trị. Hiện nay, phân tích giải trình tự RNA thông lượng cao là phương pháp phổ biến để đo lường mức độ biểu hiện của các gen trong một mẫu sinh học, cho phép xác định chính xác mức độ biểu hiện của hàng nghìn gen cùng một lúc [11].

Proteomics nghiên cứu toàn bộ các protein được biểu hiện trong một tế bào, mô, hoặc sinh vật. Đây là giai đoạn cuối cùng trong luận thuyết trung tâm. Lĩnh vực này cung cấp thông tin về số lượng, cấu trúc, chức năng, và tương tác của các protein. Trong proteomics, các kỹ thuật được sử dụng phổ biến bao gồm phân tích khối phổ và phân tích protein bằng gel.

Metabolomics nghiên cứu các sản phẩm chuyển hóa nhỏ trong tế bào, mô, hoặc sinh vật. Lĩnh vực này cung cấp cái nhìn tổng quan về trạng thái sinh lý và các quá trình sinh hóa trong cơ thể. Metabolomics thường được xem như bước cuối trong chuỗi phân tử của luận thuyết trung tâm mở rộng, do nó phản ánh kết quả cuối cùng của các quá trình sinh học đã diễn ra.

Song song với các lĩnh vực trên là epigenomics. Nó nghiên cứu các thay đổi hóa học trên DNA và histone. Những thay đổi này ảnh hưởng đến biểu hiện gen nhưng không thay đổi trình tự DNA, qua đó giúp hiểu rõ hơn về cách các yếu tố môi trường và lối sống ảnh hưởng đến biểu hiện gen [4].

Sự phát triển của các công nghệ omics đã dẫn đến khái niệm “đa omics ”, đề cập đến việc tích hợp và phân tích đồng thời nhiều loại dữ liệu omics khác nhau. Phương pháp này mang lại cái nhìn toàn diện hơn về các quá trình sinh học phức tạp, cho phép các nhà nghiên cứu hiểu rõ hơn về mối quan hệ giữa gen, prôtêin, và các quá trình chuyển hóa. Ví dụ, việc kết hợp dữ liệu CNA với GE có thể giúp xác định các gen mà sự biểu hiện của chúng bị ảnh hưởng trực tiếp bởi các thay đổi số lượng bản sao, từ đó cung cấp cái nhìn sâu sắc hơn về cơ chế điều hòa gen trong bệnh lý. Tuy nhiên, việc tích hợp dữ liệu đa omics cũng đặt ra nhiều thách thức về mặt kỹ thuật và phân tích, đòi hỏi các phương pháp thống kê và tin sinh học tiên tiến [17].

Ngành nghiên cứu omics được ứng dụng rộng rãi trong nhiều lĩnh vực quan trọng. Trong y học chính xác, omics giúp cá nhân hóa chẩn đoán và điều trị dựa trên hồ sơ sinh học của từng bệnh nhân. Trong phát triển thuốc, nó hỗ trợ khám phá các mục tiêu điều trị và tối ưu hóa quy trình phát triển thuốc. Trong nông nghiệp, nghiên cứu omics cải thiện giống cây trồng và vật nuôi, cũng như tối ưu hóa chất lượng thực phẩm. Ngoài ra, omics còn góp phần vào việc nghiên cứu cơ chế sinh học, theo dõi sức khỏe hệ sinh thái, và đánh giá tác động của môi trường đối với sinh vật.

TCGA là một dự án quy mô lớn đã tạo ra một bộ dữ liệu vô giá cho các nhà nghiên cứu về mối quan hệ giữa hệ gen và các bệnh ung thư. TCGA đã thu thập dữ liệu từ hơn 11,000 bệnh nhân với 33 loại ung thư khác nhau. Dữ liệu TCGA được chia thành ba cấp độ: dữ liệu cấp 1 là dữ liệu thô và không được chuẩn hóa, dữ liệu cấp 2 thể hiện mức độ xử lý trung gian và chuẩn hóa dữ liệu, và dữ liệu cấp 3 là dữ liệu tổng hợp, chuẩn hóa và phân đoạn. Dữ liệu cấp độ 3 là dữ liệu phân tích phân tử đã được xử lý, bao gồm các dữ liệu omics về di truyền học, phiên mã, di truyền biểu sinh và ngay cả dữ liệu biểu hiện prôtêin [18].

Trong nghiên cứu này, bộ dữ liệu cấp độ 3 về ung thư vú (TCGA Breast Cancer - TCGA BRCA) đã được sử dụng. Cụ thể, ta tập trung vào hai loại dữ liệu omics là GE và CNA. Việc sử dụng dữ liệu đã qua xử lý và chuẩn hóa này giúp tối ưu hóa quá trình phân tích và đảm bảo tính nhất quán trong kết quả nghiên cứu. Sự kết hợp giữa dữ liệu CNA và GE cho phép ta khám phá mối quan hệ giữa các thay đổi cấu trúc trong bộ gen và sự biểu hiện gen, từ đó có thể xác định các gen quan trọng trong quá trình phát triển và tiến triển của ung thư vú [16].

Các xu hướng mới trong nghiên cứu omics đang phát triển mạnh mẽ. Đáng chú ý

nhất là kỹ thuật phân tích ở mức độ tế bào đơn (single-cell analysis), cho phép nghiên cứu chi tiết các quá trình sinh học diễn ra trong từng tế bào riêng lẻ. Song song với đó là việc ứng dụng trí tuệ nhân tạo và học máy để xử lý, phân tích khối lượng lớn dữ liệu omics phức tạp.

Bên cạnh đó, các nhà khoa học đang tập trung phát triển công cụ và phương pháp tích hợp dữ liệu đa omics, cũng như ứng dụng omics trong theo dõi sức khỏe thời gian thực và y học dự phòng. Mặc dù mang lại nhiều lợi ích, việc phân tích dữ liệu omics vẫn phải đối mặt với nhiều thách thức. Thách thức đầu tiên là việc quản lý và lưu trữ khối lượng dữ liệu khổng lồ từ các thí nghiệm omics. Tiếp đến là vấn đề tích hợp và phân tích đồng thời nhiều loại dữ liệu omics khác nhau, đòi hỏi những phương pháp tính toán phức tạp. Các nhà khoa học cũng gặp khó khăn trong việc giải thích các kết quả phân tích phức tạp dưới góc độ sinh học và đảm bảo tính tái lập cũng như độ tin cậy của các phát hiện. Ngoài ra, việc đào tạo nguồn nhân lực có kỹ năng phân tích dữ liệu omics cũng là một thách thức cần được giải quyết.

Tuy nhiên, với sự phát triển nhanh chóng của công nghệ omics và các phương pháp phân tích dữ liệu, việc nghiên cứu và ứng dụng dữ liệu omics trong y học chính xác và các lĩnh vực khác dự kiến sẽ tiếp tục mở rộng trong tương lai. Điều này sẽ mang lại những hiểu biết mới về cơ chế bệnh lý và góp phần cải thiện phương pháp chẩn đoán, điều trị [2]

1.1.3. Dấu ấn sinh học là gì? Tại sao phát triển các giải pháp giúp khai phá bộ dấu ấn sinh học lại mang nhiều ý nghĩa?

Dấu ấn sinh học là những chỉ số sinh học có thể đo lường được trong cơ thể. Các chỉ số này phản ánh các quá trình sinh lý hoặc bệnh lý đang diễn ra. Dấu ấn sinh học có thể là các phân tử như gen, protein, metabolite, hoặc có thể là các đặc điểm hình ảnh. Trong lĩnh vực y học chính xác, dấu ấn sinh học đóng vai trò then chốt. Chúng giúp các bác sĩ và nhà nghiên cứu xác định, dự đoán và theo dõi tình trạng bệnh. Không chỉ vậy, dấu ấn sinh học còn giúp đánh giá hiệu quả điều trị một cách cá thể hóa cho từng bệnh nhân.

Sự phát triển của các công nghệ omics đã mở ra nhiều cơ hội mới trong việc khai phá dấu ấn sinh học. Các công nghệ như genomics, transcriptomics, proteomics

và metabolomics cho phép thu thập dữ liệu ở quy mô lớn chưa từng có. Đặc biệt, khả năng tích hợp dữ liệu từ nhiều loại omics khác nhau mang lại cái nhìn toàn diện về các quá trình sinh học phức tạp. Từ đó, các nhà khoa học có thể phát hiện những dấu ấn sinh học mạnh mẽ và đáng tin cậy hơn. Điều này đặc biệt quan trọng trong nghiên cứu các bệnh phức tạp như ung thư, khi mà bệnh phát sinh từ sự tương tác của nhiều yếu tố di truyền và môi trường.

Trong y học hiện đại, việc khai phá và thu hẹp các bộ dấu ấn sinh học từ dữ liệu đa omics không chỉ là một nhu cầu mà còn là một thách thức lớn. Dù mục tiêu lý tưởng là có được bộ dấu ấn sinh học càng nhỏ càng tốt, việc giảm số lượng từ hàng chục nghìn gen xuống còn vài trăm gen đã mang lại nhiều lợi ích đáng kể cho nhiều đối tượng khác nhau. Đối với bệnh nhân, việc này giúp giảm đáng kể gánh nặng về thời gian và chi phí. Thay vì phải trải qua nhiều xét nghiệm phức tạp liên quan đến toàn bộ hệ gen, bệnh nhân chỉ cần thực hiện xét nghiệm tập trung vào vài trăm gen đặc hiệu. Điều này không những giảm stress cho người bệnh mà còn đẩy nhanh quá trình chẩn đoán và điều trị. Từ phía bác sĩ lâm sàng, một bộ dấu ấn sinh học gồm vài chục đến vài trăm gen tạo điều kiện thuận lợi cho việc ra quyết định điều trị. Thay vì phải phân tích toàn bộ hệ gen với hàng chục nghìn gen, việc tập trung vào một tập gen quan trọng giúp các bác sĩ đưa ra phác đồ điều trị phù hợp cho bệnh nhân ung thư vú một cách nhanh chóng và chính xác hơn. Đối với các nhà nghiên cứu, việc thu hẹp không gian tìm kiếm mang lại nhiều thuận lợi trong công việc. Họ có thể tập trung nguồn lực vào nghiên cứu sâu về một số gen tiềm năng thay vì phải thực hiện thí nghiệm trên toàn bộ hệ gen. Việc này không chỉ tiết kiệm thời gian, chi phí mà còn giúp tăng độ chính xác của kết quả nhờ giảm thiểu nhiễu. Quan trọng hơn, khi xác định được tập hợp gen quan trọng, các nhà nghiên cứu có thể tập trung tìm hiểu sâu hơn về cơ chế hoạt động và mối tương tác giữa chúng.

Trong thực tế lâm sàng, xét nghiệm Oncotype DX là một ví dụ điển hình về thành công của phương pháp này. Xét nghiệm này chỉ dựa trên biểu hiện của 21 gen nhưng đã giúp các bác sĩ dự đoán chính xác nguy cơ tái phát ung thư vú. Từ đó, họ có thể quyết định liệu bệnh nhân có cần hóa trị bổ trợ hay không, giúp nhiều người tránh được các tác dụng phụ không cần thiết [32]. Tuy nhiên, việc xác định được một bộ dấu ấn sinh học vừa nhỏ gọn vừa hiệu quả không phải là điều đơn giản. Quá trình này đòi hỏi sự kết hợp giữa nhiều yếu tố: kiến thức chuyên môn sâu về sinh học, phương pháp phân tích dữ liệu tiên tiến, và khả năng tích hợp thông tin từ nhiều nguồn khác nhau.

1.1.4. Comparative Toxicogenomics Database (CTD)

CTD là một nguồn dữ liệu công khai do Phòng thí nghiệm sinh học Mount Desert Island phát triển và duy trì [12, 40, 51, 60]. Cơ sở dữ liệu này đóng vai trò quan trọng trong việc tích hợp và cung cấp thông tin toàn diện về mối quan hệ giữa gen, hóa chất và bệnh tật.

Quy trình tích hợp dữ liệu của CTD được thực hiện một cách có hệ thống và chặt chẽ. Dữ liệu được thu thập từ nhiều nguồn đa dạng như các nghiên cứu thực nghiệm trực tiếp, tài liệu y văn được bình duyệt và các kết quả dự đoán từ mô hình máy tính. Để đảm bảo chất lượng thông tin, các chuyên gia thực hiện việc chú giải thủ công. Họ tiến hành đánh giá kỹ lưỡng, phân loại chi tiết và tổ chức dữ liệu theo hệ thống phân cấp tiêu chuẩn. Quy trình này tạo điều kiện thuận lợi cho việc truy cập và khai thác thông tin hiệu quả [40].

CTD chia mối quan hệ gen-bệnh thành nhiều loại khác nhau. Hai loại quan trọng nhất là Marker/Mechanism (M) và Therapeutic (T). Các gen thuộc nhóm M thường đóng vai trò như dấu ấn sinh học hoặc tham gia trực tiếp vào cơ chế phân tử gây bệnh. Trong khi đó, các gen thuộc nhóm T được xác định là những mục tiêu điều trị tiềm năng. CTD cũng ghi nhận các dạng tương tác khác như tăng cường hay gen làm tăng mức độ nghiêm trọng của bệnh, giảm thiểu hay gen làm giảm mức độ nghiêm trọng), và các tương tác chưa xác định rõ chiều hướng. Mỗi loại tương tác đều có bằng chứng khoa học cụ thể hỗ trợ. Tuy nhiên, các mối quan hệ M và T thường được coi là đáng tin cậy nhất nhờ có bằng chứng trực tiếp và mạnh mẽ về vai trò của gen trong bệnh lý hoặc điều trị [51].

Một đặc điểm nổi bật của CTD là hệ thống điểm số suy luận (Inference Score). Đây là thước đo định lượng đánh giá độ tin cậy và mức độ kết nối của các mối quan hệ gen-bệnh trong mạng lưới tương tác. Điểm số này được tính toán dựa trên nhiều yếu tố: tính chất topo của mạng lưới tương tác, số lượng và chất lượng của bằng chứng hỗ trợ, cùng mức độ tương đồng với mạng ngẫu nhiên tỷ lệ tự do. Điểm số càng cao thể hiện mối liên hệ càng mạnh mẽ và đáng tin cậy. Các mối quan hệ thuộc nhóm M hoặc T thường có điểm số cao hơn nhờ có bằng chứng trực tiếp và mạnh mẽ về vai trò của gen.

CTD là một cơ sở dữ liệu động, luôn được cập nhật để phản ánh những tiến bộ mới nhất trong lĩnh vực độc chất học và bệnh lý phân tử. Nhờ sự phát triển không ngừng này, CTD duy trì vai trò quan trọng trong việc hỗ trợ các nghiên cứu về cơ chế bệnh, phát

triển thuốc và đánh giá độc tính của các hợp chất hóa học.

1.2. Học máy và học sâu

1.2.1. Giới thiệu về các mô hình hình học máy và học sâu

Học máy và học sâu đóng vai trò quan trọng trong việc phân tích và giải thích dữ liệu omics, đặc biệt trong lĩnh vực y học chính xác và nghiên cứu ung thư. Học máy, một nhánh của trí tuệ nhân tạo, tập trung vào việc phát triển các kỹ thuật cho phép máy tính tự động học từ dữ liệu. Tom M. Mitchell đã định nghĩa rằng một chương trình máy tính được coi là học từ kinh nghiệm E cho một lớp nhiệm vụ T với một thước đo hiệu năng P nếu nó cải thiện hiệu năng thông qua kinh nghiệm E khi sử dụng P [1]. Mục tiêu chính của học máy là thiết kế các mô hình có khả năng tự học từ dữ liệu đầu vào mà không cần lập trình cụ thể. Trong quá trình phát triển mô hình học máy, dữ liệu thường được chia thành ba phần: tập huấn luyện, tập xác thực, và tập kiểm tra. Tập huấn luyện được sử dụng để đào tạo mô hình, tập xác thực giúp tinh chỉnh mô hình và lựa chọn siêu tham số, trong khi tập kiểm tra đánh giá hiệu năng cuối cùng của mô hình. Việc phân chia này đảm bảo tính khách quan trong đánh giá và giúp tránh hiện tượng quá khớp (overfitting).

Học máy có thể được chia thành nhiều nhóm bài toán khác nhau, trong đó học có giám sát và học không giám sát là hai loại phổ biến nhất. Học có giám sát sử dụng dữ liệu có nhãn để tìm hiểu mối quan hệ giữa dữ liệu đầu vào và nhãn tương ứng, trong khi học không giám sát tập trung vào việc phát hiện cấu trúc hoặc mẫu trong dữ liệu không có nhãn. Trong số các thuật toán học máy truyền thống, Logistic Regression, Support Vector Machines (SVM), và Random Forest đã chứng minh được hiệu quả trong nhiều ứng dụng, bao gồm cả phân tích dữ liệu sinh học. Logistic Regression là một thuật toán phân loại phổ biến, đặc biệt hữu ích cho các bài toán phân loại nhị phân. Nó sử dụng hàm sigmoid để dự đoán xác suất của một điểm dữ liệu thuộc về một trong hai lớp. SVM là một thuật toán mạnh mẽ được sử dụng cho cả bài toán phân loại và hồi quy, tìm kiếm một siêu phẳng tối ưu trong không gian nhiều chiều để phân chia các lớp dữ liệu. Random Forest là một thuật toán học tập kết hợp (ensemble learning), kết hợp nhiều cây quyết định để tạo ra một mô hình mạnh mẽ và ổn định, có khả năng xử lý dữ liệu có nhiều đặc trưng và ít bị ảnh hưởng bởi học quá khớp. Học sâu, một phân nhánh của học máy, dựa trên các mạng nơ ron nhân tạo có nhiều lớp ẩn. Mạng nơ ron nhân tạo được lấy

cảm hứng từ cấu trúc và chức năng của não người, bao gồm các nơ ron kết nối với nhau. Một nơ ron nhân tạo bao gồm đầu vào, hàm kích hoạt, và đầu ra, tương tự như cách thức hoạt động của nơ ron sinh học. Hình 1.3 mô tả cấu trúc của một mạng nơ ron nhân tạo cơ bản. Mạng nơ ron học sâu thường bao gồm lớp đầu vào, nhiều lớp ẩn, và lớp đầu ra. Mỗi lớp có vai trò riêng trong việc xử lý và truyền thông tin. Lớp đầu vào nhận dữ liệu thô, các lớp ẩn học các đặc trưng trừu tượng từ dữ liệu, và lớp đầu ra tạo ra kết quả cuối cùng.

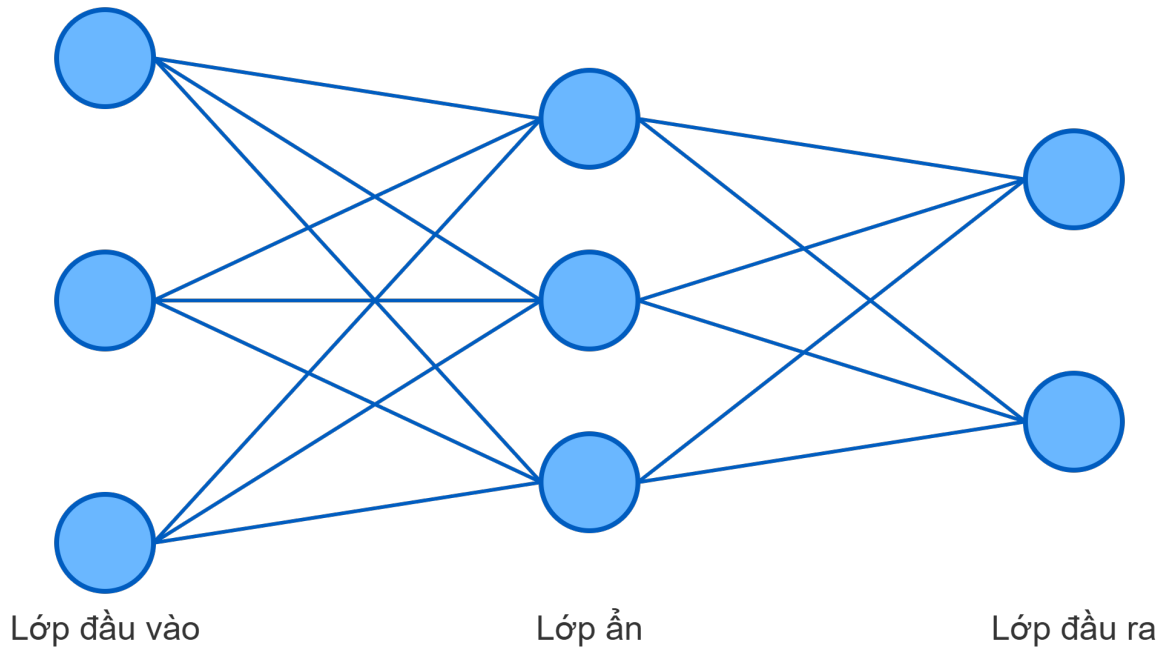

Hình 1.3: Cấu trúc của một mạng nơ ron cơ bản.

Hai kiến trúc học sâu đã thể hiện hiệu quả vượt trội trong phân tích dữ liệu sinh học là mạng nơ-ron tự mã hóa (AutoEncoder - AE) và mạng nơ-ron tích chập (Convolutional Neural Networks - CNN). Các kiến trúc này cũng là nền tảng để phát triển các mô hình phức tạp hơn, đáp ứng nhu cầu xử lý đa dạng dữ liệu sinh học.

Mạng nơ-ron tự mã hóa, như minh họa trong Hình 1.4, là một kiến trúc học không giám sát với hai thành phần chính: bộ mã hóa (encoder) và bộ giải mã (decoder). Trong đó, bộ mã hóa thực hiện nhiệm vụ nén dữ liệu đầu vào thành biểu diễn có chiều thấp hơn, trong khi bộ giải mã có nhiệm vụ tái tạo lại dữ liệu gốc từ biểu diễn này. Kiến trúc này đã chứng minh hiệu quả trong nhiều ứng dụng quan trọng như giảm chiều dữ liệu, phát hiện bất thường, và trích xuất đặc trưng quan trọng từ dữ liệu sinh học. Phát triển

từ AE cơ bản, mạng nơ-ron tự mã hóa lọc nhiễu (Denoising Autoencoder - DAE) được thiết kế với khả năng khôi phục dữ liệu gốc từ phiên bản nhiễu. Cơ chế học này giúp mô hình không chỉ nắm bắt được các đặc trưng mạnh mẽ mà còn cải thiện khả năng tổng quát hóa. Đặc tính này làm cho DAE trở nên đặc biệt phù hợp trong xử lý dữ liệu sinh học, nơi thường xuyên phải đối mặt với các thách thức về nhiễu và thiếu sót dữ liệu.

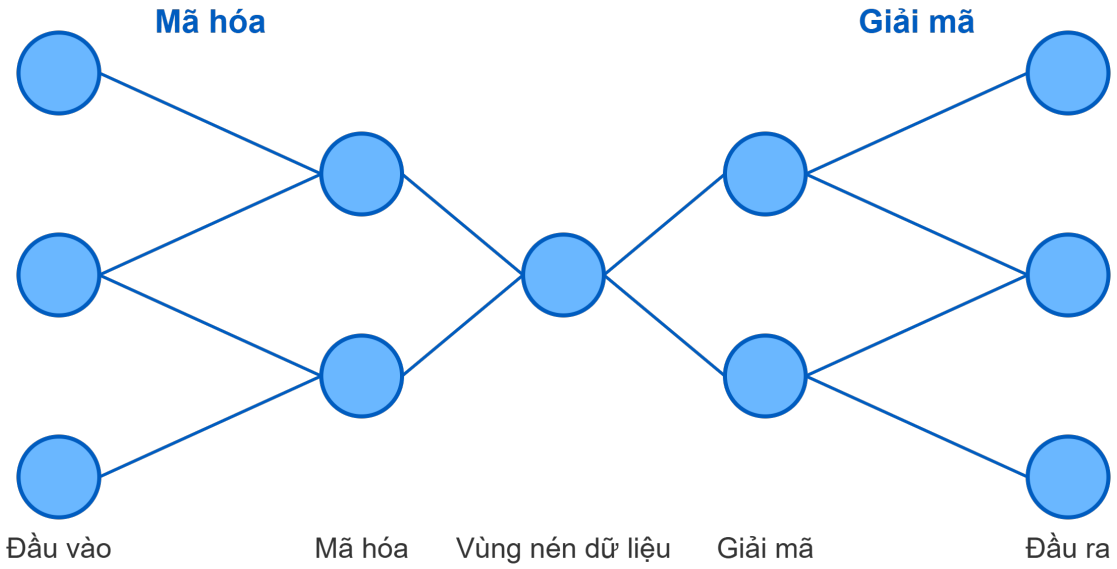

Hình 1.4: Cấu trúc của một nơ ron tự mã hóa.

Mạng nơ-ron tích chập (CNN) được phát triển ban đầu cho xử lý ảnh, nhưng đã chứng minh hiệu quả trong nhiều lĩnh vực khác, đặc biệt là phân tích dữ liệu sinh học. Như minh họa trong Hình 1.5, kiến trúc cơ bản của CNN bao gồm ba thành phần chính: các lớp tích chập để tự động học đặc trưng từ dữ liệu đầu vào, các lớp gộp (pooling layer) để giảm kích thước dữ liệu, và các lớp kết nối đầy đủ (fully connected layer) để tổng hợp thông tin. Với khả năng phát hiện hiệu quả các mẫu cục bộ trong dữ liệu, CNN đặc biệt phù hợp cho việc phân tích các chuỗi sinh học như DNA và prôtêin. Phát triển dựa trên nền tảng của CNN, mạng nơ-ron tích chập đồ thị (Graph Convolutional Network - GCN) được thiết kế để xử lý dữ liệu có cấu trúc đồ thị. GCN mở rộng khái niệm tích chập từ dữ liệu lưới đều sang dữ liệu đồ thị không đều, cho phép mô hình học được đặc trưng từ cả nút và cạnh trong đồ thị. Khả năng này mở ra nhiều ứng dụng quan trọng trong sinh học, như phân tích mạng lưới tương tác prôtêin và nghiên cứu các con đường trao đổi chất.

Trong lĩnh vực tin sinh học và y học chính xác, học máy và học sâu đóng vai trò quan trọng trong việc phân tích dữ liệu omics phức tạp. Các kiến trúc như DAE và GCN

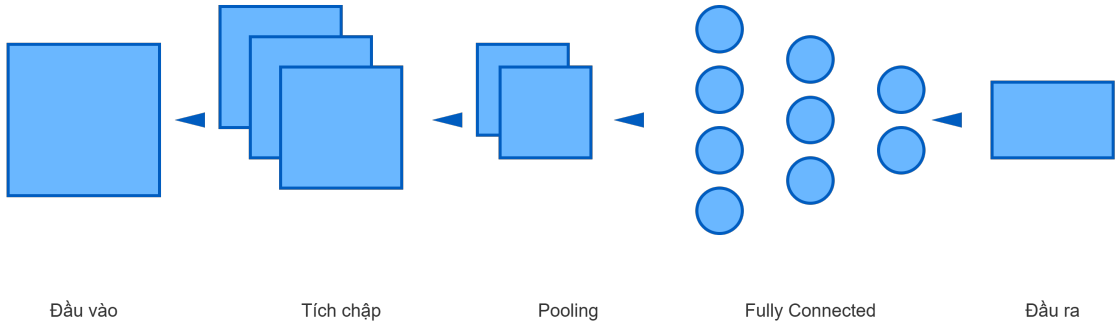

Hình 1.5: Cấu trúc của một mạng nơ ron tích chập (CNN).

có tiềm năng lớn trong việc tích hợp và phân tích dữ liệu đa omics, cho phép các nhà nghiên cứu khai thác thông tin từ nhiều nguồn dữ liệu sinh học khác nhau một cách đồng thời. Điều này có thể dẫn đến những hiểu biết sâu sắc hơn về các cơ chế sinh học phức tạp và cải thiện độ chính xác trong dự đoán và chẩn đoán bệnh. Tuy nhiên, việc áp dụng học máy và học sâu trong y học chính xác cũng đặt ra nhiều thách thức. Vấn đề về tính giải thích của mô hình, đặc biệt là với các mô hình học sâu phức tạp, là một trong những thách thức lớn. Các nhà nghiên cứu đang phát triển các phương pháp để "mở hộp đen" của các mô hình học sâu, nhằm hiểu rõ hơn cách thức mô hình đưa ra quyết định. Điều này đặc biệt quan trọng trong lĩnh vực y tế, nơi các quyết định có thể ảnh hưởng trực tiếp đến sức khỏe và cuộc sống của bệnh nhân.

Một thách thức quan trọng trong xử lý dữ liệu omics là vấn đề dữ liệu có số chiều cao (high-dimensional data) nhưng số lượng mẫu lại nhỏ. Điều này đòi hỏi các kỹ thuật đặc biệt trong thiết kế và huấn luyện mô hình, đồng thời cần áp dụng các phương pháp điều chuẩn (regularization) hiệu quả để tránh hiện tượng quá khớp. Học máy và học sâu đang mở ra nhiều hướng tiếp cận mới trong phân tích và nắm bắt bản chất của dữ liệu sinh học phức tạp. Các kiến trúc như mạng nơ ron tự mã hóa, mạng nơ ron tích chập, cùng với các biến thể như mạng nơ-ron tự mã hóa lọc nhiễu và mạng nơ ron tích chập đồ th đã và đang được phát triển nhằm giải quyết những thách thức đặc thù trong tin sinh học và y học chính xác. Những bước tiến này được kỳ vọng sẽ góp phần quan trọng vào sự phát triển của y học cá nhân hóa và nâng cao chất lượng chăm sóc sức khỏe trong tương lai.

1.2.2. Giới thiệu một số chỉ số quan trọng để đánh giá hiệu năng mô hình

Việc đánh giá hiệu năng của mô hình học máy và học sâu đóng vai trò quyết định trong quá trình phát triển và tinh chỉnh. Các chỉ số phổ biến như độ chính xác tổng thể (*Accuracy*), độ chính xác dương tính (*Precision*), độ phủ (*Recall*), và điểm $F1$ ($F1$-*score*) được sử dụng rộng rãi để đánh giá hiệu năng tổng thể của mô hình [3, 8]. Trong lĩnh vực y học chính xác, đặc biệt là bài toán phân loại kiểu phụ ung thư vú, việc lựa chọn phương pháp đánh giá phù hợp càng trở nên quan trọng do tính chất nhạy cảm của các quyết định y tế.

Độ chính xác tổng thể là chỉ số cơ bản nhất đo lường tỷ lệ dự đoán chính xác trên tổng số dự đoán:

$$Accuracy = \frac{TP + TN}{TP + TN + FP + FN} \tag{1.1}$$

Trong công thức trên, TP (True Positive) là số mẫu dương tính được dự đoán đúng, TN (True Negative) là số mẫu âm tính được dự đoán đúng, FP (False Positive) và FN (False Negative) lần lượt là số mẫu dự đoán sai thành dương tính và âm tính. Tuy nhiên, trong thực tế y khoa, độ chính xác tổng thể đơn thuần thường không đủ để đánh giá toàn diện hiệu năng của mô hình.

Để có cái nhìn chi tiết hơn, hai chỉ số quan trọng khác thường được sử dụng song song là độ chính xác dương tính (*Precision*) và độ phủ (*Recall*):

$$Precision = \frac{TP}{TP + FP} \tag{1.2}$$

$$Recall = \frac{TP}{TP + FN} \tag{1.3}$$

Điểm số $F1$ kết hợp cả hai chỉ số này thành một số đo duy nhất thông qua trung bình điều hòa:

$$F1 = \frac{2 \cdot (Precision \cdot Recall)}{Precision + Recall} \tag{1.4}$$

Trong các bài toán phân loại đa lớp mất cân bằng, việc sử dụng các biến thể của điểm $F1$ như $F1$-macro và $F1$-weighted trở nên đặc biệt quan trọng [10]. $F1$-macro tính trung bình số học của điểm $F1$ cho mỗi lớp:

$$F1\text{-}macro = \frac{1}{n}\sum_{i=1}^{n} F1_i, \quad \text{với } n \text{ là số lượng kiểu phụ} \tag{1.5}$$

$F1$-weighted tính trung bình có trọng số dựa trên tỷ lệ xuất hiện của mỗi kiểu phụ:

$$F1\text{-}weighted = \sum_{i=1}^{n} w_i \cdot F1_i, \quad \text{với } w_i \text{ thể hiện tỷ lệ của kiểu phụ } i \tag{1.6}$$

Qua các công thức trên, có thể nhận thấy rằng $F1$-*macro* và $F1$-*weighted* mỗi chỉ số đều có ưu và nhược điểm riêng khi đánh giá mô hình phân loại đa lớp mất cân bằng. Mặc dù $F1$-*macro* có ưu điểm là đảm bảo tính công bằng cho tất cả các lớp không phụ thuộc vào kích thước, chỉ số này lại khá nhạy cảm với sự suy giảm hiệu năng của các lớp có kích thước nhỏ hay thiểu số. Ngược lại, $F1$-*weighted* có ưu thế trong việc phản ánh chính xác hơn phân phối thực tế của dữ liệu, song lại có nhược điểm là có thể không phát hiện được những hạn chế của mô hình khi xử lý các lớp có kích thước nhỏ.

Trong lĩnh vực y học chính xác, đặc biệt là phân loại các kiểu phụ ung thư, $F1$-*macro* thường được ưu tiên sử dụng hơn. Điều này là do $F1$-*macro* đảm bảo không bỏ sót hiệu năng trên các lớp thiểu số - vốn thậm chí có thể đại diện cho những ca bệnh hiếm gặp nhưng quan trọng. Cách tiếp cận này phù hợp với mục tiêu của y học chính xác: cung cấp chẩn đoán và điều trị chính xác cho mọi bệnh nhân, không phân biệt tình trạng bệnh phổ biến hay hiếm gặp [22].

1.3. Giải thuật hỗ trợ giải thích các mô hình học sâu

Explainable Artificial Intelligence (XAI), hay trí tuệ nhân tạo có khả năng giải thích, ngày càng đóng vai trò quan trọng trong nghiên cứu và ứng dụng AI [31]. Vai trò này đặc biệt nổi bật trong lĩnh vực y sinh học và nghiên cứu ung thư [42]. Khi các mô hình AI ngày càng phức tạp và trở thành những "hộp đen" khó hiểu, XAI tập trung vào việc phát triển các công cụ và phương pháp nhằm làm sáng tỏ quá trình ra quyết định của AI. Trong bối cảnh y sinh học, XAI mang lại nhiều lợi ích quan trọng. Trước hết, nó

giúp các nhà nghiên cứu và bác sĩ hiểu rõ cơ sở của các dự đoán từ mô hình. Tiếp đến, XAI góp phần tăng cường sự tin tưởng vào các hệ thống AI trong y tế. Đặc biệt, XAI còn hỗ trợ việc phát hiện và khắc phục các sai lệch có thể xuất hiện trong quá trình học của mô hình.

1.3.1. Feature Ablation

Feature Ablation (FA) [43, 49] là một phương pháp cơ bản nhưng hiệu quả trong việc phân tích và giải thích các mô hình học máy lẫn học sâu. Phương pháp này dựa trên nguyên lý đơn giản: đánh giá tầm quan trọng của một đặc trưng bằng cách quan sát sự thay đổi trong kết quả dự đoán của mô hình khi loại bỏ đặc trưng đó. Khi một đặc trưng quan trọng bị loại bỏ, hiệu năng của mô hình thường sẽ suy giảm đáng kể. Ngược lại, việc loại bỏ các đặc trưng ít quan trọng sẽ ít ảnh hưởng đến kết quả dự đoán. Trong bối cảnh phân tích dữ liệu sinh học, Feature Ablation đặc biệt hữu ích khi xác định các gen hoặc protein có vai trò then chốt trong việc phân loại bệnh. Ví dụ, khi phân loại các kiểu phụ ung thư vú, việc loại bỏ biểu hiện của một gen quan trọng như ERBB2 có thể làm giảm đáng kể độ chính xác trong việc nhận diện kiểu phụ HER2-enriched. Điều này cho thấy gen đó có thể là một chỉ thị sinh học tiềm năng cho kiểu phụ này.

Quy trình thực hiện Feature Ablation bao gồm bốn bước chính (Hình 1.6). Thứ nhất, mô hình được huấn luyện và đánh giá trên tập dữ liệu đầy đủ để thiết lập điểm chuẩn về hiệu năng. Tiếp theo, các đặc trưng được loại bỏ một cách có hệ thống và thường thông qua thay thế giá trị của chúng bằng giá trị không. Tiếp đến, sự thay đổi trong hiệu năng của mô hình được đo lường và so sánh với điểm chuẩn ban đầu theo Công thức 1.7. Cuối cùng, các đặc trưng được xếp hạng về độ quan trọng dựa trên độ giảm dần của sự thay đổi về hiệu năng.

$$\Delta P = P_{\text{full}} - P_{\text{ablated}} \tag{1.7}$$

Trong đó:

- ΔP: Độ thay đổi hiệu năng
- P_{full}: Hiệu năng của mô hình với đầy đủ đặc trưng
- P_{ablated}: Hiệu năng của mô hình khi loại bỏ đặc trưng cần đánh giá

Hình 1.6: Quy trình thực hiện cơ bản của Feature Ablation.

Mặc dù đơn giản, dễ hiểu, dễ triển khai và đem lại hiệu quả nhất định, Feature Ablation vẫn tồn tại một số hạn chế cần lưu ý. Phương pháp này không tính đến các tương tác phức tạp giữa các đặc trưng, có thể bỏ qua những đặc trưng quan trọng trong ngữ cảnh kết hợp nhưng ít quan trọng khi xét riêng lẻ. Ngoài ra, việc loại bỏ đặc trưng có thể tạo ra các mẫu dữ liệu không thực tế, đặc biệt trong dữ liệu sinh học nơi các đặc trưng thường có mối tương quan chặt chẽ với nhau. Khi số lượng đặc trưng lớn, với mỗi một đặc trưng, việc ta phải thực hiện dự đoán lại với toàn bộ dữ liệu để đánh giá có thể gây tiêu tốn thời gian.

Trong bối cảnh của nghiên cứu này, Feature Ablation được sử dụng như một phương pháp cơ sở để đối chiếu với các phương pháp phân tích tiên tiến hơn như Integrated Gradients. Việc so sánh này giúp đánh giá hiệu quả của các phương pháp phức tạp và xác thực các dấu ấn sinh học được phát hiện.

1.3.2. Integrated Gradient

Integrated Gradients [36] là một phương pháp đo lường mức độ đóng góp tiên tiến được đề xuất bởi Sundararajan và cộng sự tại Google Research. Phương pháp này xác định mức độ ảnh hưởng của từng đặc trưng đầu vào đến dự đoán của mô hình học sâu. Integrated Gradients nổi bật với nền tảng lý thuyết vững chắc, được đảm bảo bởi các tiên đề toán học chặt chẽ trong việc đánh giá chất lượng giải thích mô hình. Tiên đề đầu tiên là tính nhạy cảm, trong đó phương pháp sẽ cho điểm đóng góp khác không với những đặc trưng có ảnh hưởng không đổi đến dự đoán của mô hình so với baseline. Tiên đề thứ hai về tính đầy đủ trong triển khai đảm bảo tổng điểm đóng góp của các đặc trưng bằng chính hiệu số giữa đầu ra của mô hình tại điểm dữ liệu và tại baseline. Tiếp theo, tính đối xứng của phương pháp thể hiện qua việc các đặc trưng có ảnh hưởng tương đương đến mô hình sẽ nhận được điểm đóng góp tương đương. Cuối cùng, tính bất biến với tuyến tính đảm bảo rằng với các mô hình tuyến tính, phương pháp cho kết quả tương đương với tích của đặc trưng và trọng số tương ứng.

Cần lưu ý rằng hương pháp này là một biến thể cải tiến của việc tính toán gradient của đầu ra dự đoán theo các đặc trưng đầu vào, không đòi hỏi bất kỳ sửa đổi nào đối với mạng gốc, dễ dàng triển khai và có thể áp dụng cho nhiều loại mô hình học sâu khác nhau (từ mô hình thưa đến dày đặc, từ xử lý văn bản đến thị giác máy tính).

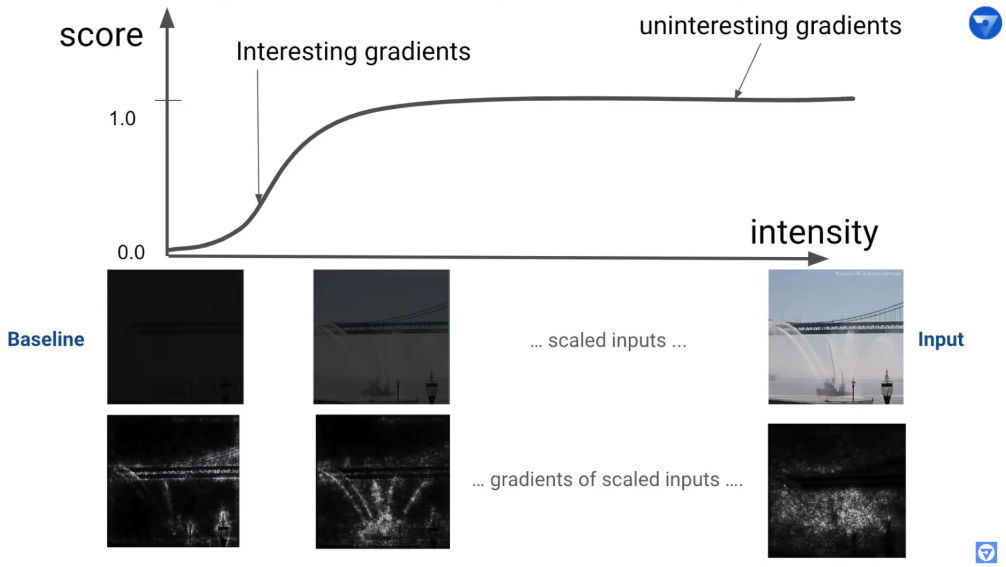

Hình 1.7: Nguyên lý cốt lõi của Integrated Gradient[1]

[1]Nguồn: `https://gist.github.com/devpramod/511c075ebbdf270beecf50cfa2097e12`

Nguyên lý cốt lõi của phương pháp này là tính toán tích phân của gradient dọc theo đường thẳng nối điểm giá trị nền (baseline) với điểm dữ liệu đầu vào (Hình 1.7). Integrated Gradients định nghĩa độ quan trọng của một đặc trưng thông qua công thức:

$$IG_i(x) = (x_i - x_i') \times \int_{\alpha=0}^{1} \frac{\partial F(x' + \alpha \times (x - x'))}{\partial x_i} d\alpha \tag{1.8}$$

Trong đó:

- x: Điểm dữ liệu đầu vào cần phân tích
- x': Baseline (thường là véc tơ 0)
- α: Tham số nội suy từ 0 đến 1
- F: Hàm biểu diễn mô hình học sâu
- $\frac{\partial F}{\partial x_i}$: Gradient của mô hình đối với đặc trưng thứ i

Trong thực tế, tích phân được xấp xỉ bằng phương pháp cộng Riemann rời rạc, giúp giảm đáng kể khối lượng tính toán mà vẫn có thể đảm bảo chất lượng kết quả:

$$IG_i(x) \approx (x_i - x_i') \times \sum_{k=1}^{m} \frac{\partial F(x' + \frac{k}{m} \times (x - x'))}{\partial x_i} \times \frac{1}{m} \tag{1.9}$$

Trong đó:

- x: Điểm dữ liệu đầu vào cần phân tích
- x': Baseline (thường là véc tơ 0)
- m: Số bước nội suy trên đường thẳng từ baseline đến điểm dữ liệu
- F: Hàm biểu diễn mô hình học sâu
- $\frac{\partial F}{\partial x_i}$: Gradient của mô hình đối với đặc trưng thứ i
- k: Chỉ số bước nội suy, từ 1 đến m

Việc lựa chọn baseline đóng vai trò đặc biệt quan trọng trong hiệu quả của phương pháp Integrated Gradients. Baseline không chỉ đơn thuần là điểm khởi đầu của tích phân, mà còn định nghĩa "điểm tham chiếu" để đánh giá sự đóng góp của các đặc trưng. Một baseline phù hợp có thể cải thiện đáng kể chất lượng của kết quả giải thích. Sundararajan và cộng sự đã đưa ra một số gợi ý có thể hữu ích trong việc xây dựng, lựa chọn baseline phù hợp với từng loại dữ liệu (Hình 1.8).

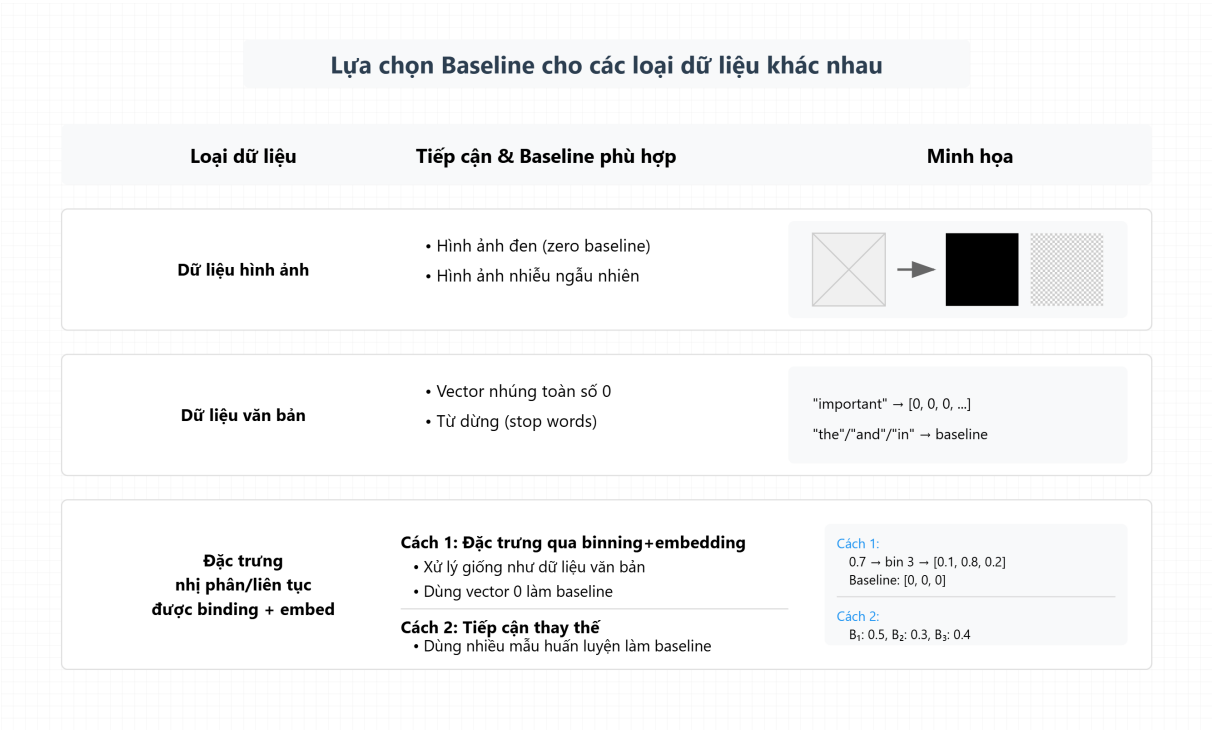

Hình 1.8: Một vài gợi ý cơ bản về lựa chọn baseline cho các dữ liệu khác nhau Integrated Gradient

Đối với dữ liệu omics, việc lựa chọn baseline đặc biệt quan trọng do tính chất phức tạp và đa chiều của dữ liệu. Có hai hướng tiếp cận cơ bản chính thường được sử dụng:

- Véc tơ không: Sử dụng véc tơ có tất cả các thành phần bằng 0 làm baseline. Cách tiếp cận này đơn giản và hiệu quả trong nhiều trường hợp, đặc biệt khi ta muốn đánh giá mức độ đóng góp tuyệt đối của từng đặc trưng.
- Trung bình quần thể: Sử dụng giá trị trung bình của từng đặc trưng trong tập dữ liệu làm baseline. Phương pháp này có ưu điểm là tính đến đặc điểm phân phối tự nhiên của dữ liệu sinh học.

Integrated Gradients thể hiện nhiều ưu điểm nổi bật trong việc giải thích mô hình

học sâu khi được áp dụng với baseline phù hợp. Về tính chính xác và đầy đủ, tổng các mức độ đóng góp phản ánh chính xác sự khác biệt giữa dự đoán tại điểm dữ liệu và tại baseline. Về tính nhất quán, các đặc trưng có ảnh hưởng tương đương sẽ nhận được điểm đóng góp tương đương, từ đó tăng độ tin cậy trong quá trình xác định dấu ấn sinh học. Mặc dù phương pháp yêu cầu tính toán tích phân phức tạp, việc áp dụng phương pháp xấp xỉ Riemann cùng với khả năng tận dụng tính toán song song trên GPU đã giúp tối ưu đáng kể quá trình thực hiện.

Tuy nhiên, phương pháp này vẫn còn một số thách thức cần được xem xét kỹ lưỡng. Số lượng điểm nội suy (m) ảnh hưởng trực tiếp đến chi phí tính toán và độ chính xác của xấp xỉ, đòi hỏi sự cân bằng hợp lý về tài nguyên tính toán. Bên cạnh đó, kết quả của phương pháp phụ thuộc nhiều vào việc lựa chọn baseline. Điều này yêu cầu người thực hiện phải hiểu sâu sắc về cả giải thuật lẫn bài toán cụ thể.

Integrated Gradients là một công cụ mạnh mẽ trong lĩnh vực XAI, đặc biệt hữu ích cho việc phân tích dữ liệu omics và nghiên cứu ung thư. Khi áp dụng cẩn thận với baseline phù hợp, phương pháp này cung cấp những giải thích chính xác và đáng tin cậy về quá trình ra quyết định của mô hình. Từ đó, nó góp phần nâng cao hiểu biết và sự tin tưởng vào các mô hình AI phức tạp trong y học [41]. Trong nghiên cứu này, việc lựa chọn baseline phù hợp là yếu tố then chốt để đảm bảo tính chính xác và độ tin cậy của các dấu ấn sinh học được phát hiện. Các thử nghiệm với nhiều loại baseline khác nhau sẽ được thực hiện nhằm xác định phương án tối ưu cho dữ liệu omics trong bài toán phân loại kiểu phụ ung thư vú.

1.4. Các nghiên cứu liên quan

Phần này giới thiệu hai nghiên cứu quan trọng trong lĩnh vực phân tích dữ liệu đa omics và phân loại kiểu phụ ung thư: MOGONET và DeepSSC. Hai nghiên cứu này đã phát triển các phương pháp tiên tiến để tích hợp dữ liệu đa omics và xác định dấu ấn sinh học, tạo nền tảng vững chắc cho nghiên cứu hiện tại.

1.4.1. MOGONET

MOGONET (Multi-Omics Graph cOnvolutional NETworks) là một khung phân tích dữ liệu đa omics do Wang và cộng sự đề xuất [54]. Phương pháp này tận dụng mạng

nơ ron tích chập đồ thị (GCN) để tối ưu hóa hiệu năng phân loại, đồng thời khai thác hiệu quả mối tương quan giữa các mẫu thông qua cấu trúc đồ thị.

Kiến trúc của MOGONET gồm hai thành phần chính. Thành phần thứ nhất là mô-đun học phân loại kiểu phụ của bệnh sử dụng các mạng nơ ron GCN. Thành phần thứ hai là mô-đun tích hợp thông tin đa omics với VCDN (View Correlation Discovery Network). Trong đó, mô-đun thứ nhất sử dụng GCN riêng biệt cho từng loại dữ liệu omics, còn mô-đun thứ hai tích hợp thông tin từ các dự đoán của các omics để đưa ra dự đoán phân loại cuối cùng.

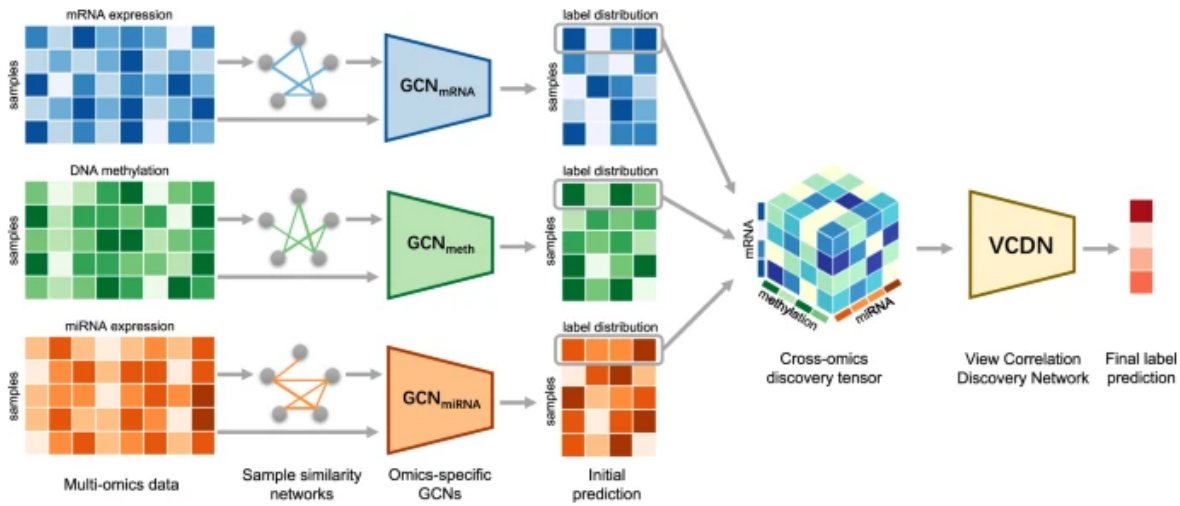

Hình 1.9: Kiến trúc học tích hợp các loại dữ liệu -omics của MOGONET giúp phân loại các kiểu phụ của bệnh [54]

MOGONET đã được thử nghiệm trên nhiều bộ dữ liệu đa dạng. Các bộ dữ liệu này bao gồm dữ liệu bệnh nhân Alzheimer, dữ liệu phân loại mức độ u trong glioma thấp cấp, dữ liệu phân loại loại ung thư thận, và dữ liệu phân loại kiểu phụ của ung thư vú xâm lấn từ TCGA [54]. Việc đánh giá được thực hiện thông qua các chỉ số khác nhau. Với các tác vụ phân loại nhị phân, các chỉ số bao gồm *Accuracy*, *AUC-ROC*, và $F1$-*score*. Với các tác vụ phân loại đa lớp, các chỉ số được sử dụng là *Accuracy*, $F1$-*weighted*, và $F1$-*macro*.

Để xác định dấu ấn sinh học, MOGONET sử dụng phương pháp cắt bỏ (*Feature Ablation*). Phương pháp này đánh giá mức độ sụt giảm hiệu năng của mô hình khi huấn luyện lại với tập dữ liệu có một đặc trưng cụ thể bị thay đổi. Đặc trưng nào gây sụt giảm hiệu năng nhiều nhất sẽ được xếp hạng cao nhất về độ quan trọng, từ đó giúp xác định các dấu ấn sinh học tiềm năng.

Một điểm đáng chú ý của MOGONET là việc sử dụng các phương pháp trích chọn đặc trưng đơn giản trước khi đưa vào mô hình. Cách làm này giúp giảm đáng kể khối lượng tính toán, điều đặc biệt quan trọng do GCN và phương pháp khai phá dấu ấn sinh học dựa trên *Feature Ablation* đòi hỏi nhiều tài nguyên tính toán.

1.4.2. DeepSSC

DeepSSC (Deep Semi-supervised multi-omics integration framework for Subtype Classification and biomarker discovery) là khung công cụ tích hợp đa omics bán giám sát do Le và cộng sự đề xuất [57]. Phương pháp này tập trung vào việc học hiệu quả từ dữ liệu có ít mẫu được gán nhãn - một thách thức thường gặp trong nghiên cứu y sinh.

Kiến trúc của DeepSSC được phát triển theo hai giai đoạn chính. Giai đoạn thứ nhất tập trung vào học biểu diễn và phân loại. Giai đoạn thứ hai thực hiện xác định dấu ấn sinh học. Trong giai đoạn đầu, mỗi loại dữ liệu omics được xử lý qua mạng nơ ron tự mã hóa khử nhiễu (*DAE*) để trích xuất biểu diễn ngữ nghĩa rút gọn. Sau đó, các biểu diễn này được kết hợp và đưa vào mạng nơ ron truyền thẳng để thực hiện phân loại.

DeepSSC đã được thử nghiệm trên nhiều bộ dữ liệu từ TCGA như ung thư vú, ung thư đại trực tràng và ung thư phổi. Tương tự MOGONET, việc đánh giá được thực hiện thông qua các chỉ số khác nhau. Với phân loại nhị phân, các chỉ số bao gồm *Accuracy*, *AUC-ROC* và $F1$-*score*. Với phân loại đa lớp, mô hình được đánh giá qua độ chính xác (*Accuracy*), $F1$-*weighted* và $F1$-*macro*. Để xác định dấu ấn sinh học, DeepSSC áp dụng thuật toán *Integrated Gradient* để tính toán mức độ đóng góp cho từng kiểu phụ. Phương pháp này sử dụng một baseline đơn giản là giá trị trung bình của đặc trưng, từ đó giúp nắm bắt được các tương tác phức tạp giữa các đặc trưng.

DeepSSC có thể hoạt động theo hai chế độ. Chế độ thứ nhất là học với dữ liệu đã có nhãn đầy đủ ở tất cả các dữ liệu omics. Chế độ thứ hai là học bán giám sát, tận dụng cả dữ liệu không nhãn hoặc chỉ có nhãn ở một phần các dữ liệu omics. Trong nghiên cứu này, ta tập trung vào chế độ thứ nhất để đảm bảo tính công bằng khi so sánh với MOGONET.

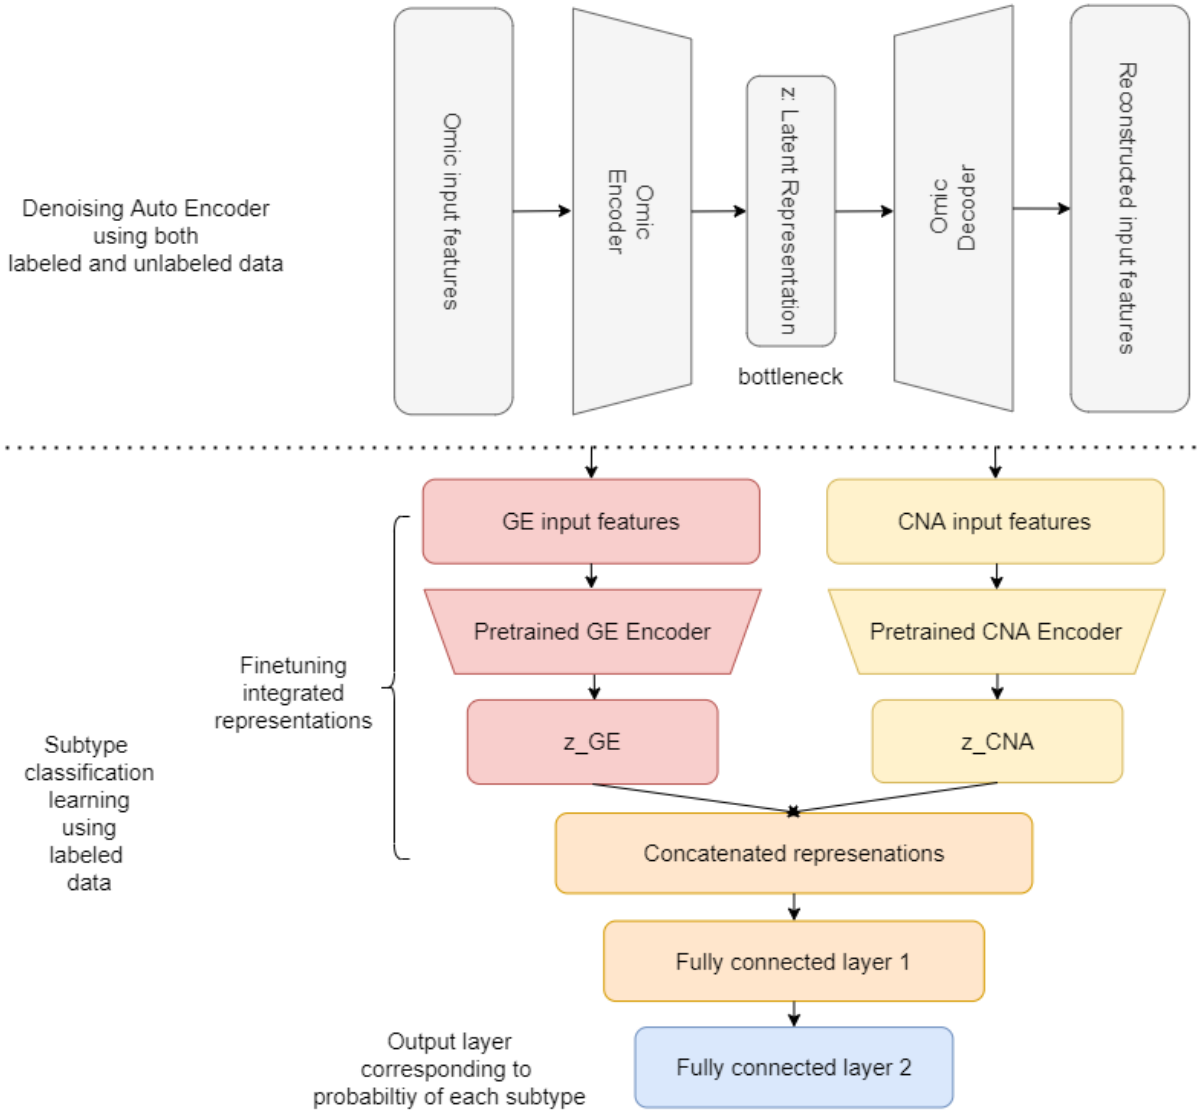

Hình 1.10: Kiến trúc học tích hợp các loại dữ liệu -omics của DeepSSC giúp phân loại các kiểu phụ của bệnh [57]

1.4.3. So sánh MOGONET và DeepSSC

MOGONET và DeepSSC đại diện cho hai hướng tiếp cận tiên tiến trong việc tích hợp dữ liệu đa omics và phân loại kiểu phụ ung thư. Đặc biệt, cả hai phương pháp đều cho thấy kết quả tốt trên dữ liệu omics mất cân bằng, một thách thức phổ biến trong nghiên cứu y sinh. Khi so sánh với các kiến trúc và phương pháp tích hợp khác, MOGONET và DeepSSC đã đạt được chỉ số $F1$-*macro* vượt trội trên các bộ dữ liệu chuẩn có tính mất cân bằng cao [54, 57, 58]. Kết quả ghi nhận này không chỉ chứng minh hiệu quả của hai phương pháp trong việc xử lý dữ liệu omics phức tạp mà còn khẳng định tiềm năng

ứng dụng rộng rãi của chúng trong các bài toán phân loại y sinh học thực tế. Mặc dù cùng hướng đến mục tiêu chung và đều áp dụng phương pháp tích hợp muộn cho dữ liệu omics, hai phương pháp này thể hiện những đặc điểm riêng biệt đáng chú ý trong cách thực hiện tích hợp và xử lý dữ liệu.

Trong những năm gần đây, lĩnh vực phân tích dữ liệu đa omics đã chứng kiến nhiều tiến bộ đáng kể nhờ sự phát triển của các phương pháp học sâu tiên tiến [48, 52, 56, 59]. MOGONET và DeepSSC nổi bật như hai phương pháp có cách tiếp cận độc đáo trong việc tích hợp và phân tích dữ liệu. Khi so sánh với các kiến trúc và phương pháp tích hợp khác, MOGONET và DeepSSC đã đạt được chỉ số $F1$-*macro* vượt trội trên các bộ dữ liệu chuẩn có tính mất cân bằng cao [54, 57, 58]. MOGONET xây dựng cấu trúc dựa trên mạng nơ-ron tích chập đồ thị. Với kiến trúc này, mô hình có khả năng khai thác hiệu quả mối tương quan giữa các mẫu sinh học thông qua biểu diễn cấu trúc đồ thị. Đặc biệt, MOGONET thực hiện việc tích hợp dữ liệu ở lớp cuối, nơi các dự đoán từ các mô hình dữ liệu omics độc lập được kết hợp thông qua cấu trúc mạng phát hiện tương quan đa chiều VCDN. Cách tiếp cận này phản ánh nguyên lý của học tập tổng hợp (ensemble learning) cho phép khai thác hiệu quả sức mạnh từ việc kết hợp nhiều mô hình chuyên biệt.

DeepSSC thể hiện tính linh hoạt đặc biệt trong phương pháp học. Mô hình được thiết kế để có thể hoạt động ở chế độ học bán giám sát và dễ dàng chuyển đổi sang chế độ học có giám sát khi cần thiết. Đặc điểm này giúp tối ưu hóa việc khai thác thông tin từ cả dữ liệu có nhãn và không nhãn - một ưu điểm quan trọng trong nghiên cứu sinh học, nơi việc thu thập và gán nhãn dữ liệu thường đòi hỏi nhiều thời gian và chi phí. Điểm nổi bật trong cấu trúc của DeepSSC là phương pháp tích hợp dữ liệu đa omics ở lớp biểu diễn thông tin. Mô hình sử dụng các bộ mã hóa khử nhiễu chuyên biệt cho từng loại dữ liệu omics. Mỗi bộ mã hóa có nhiệm vụ trích xuất đặc trưng quan trọng và loại bỏ nhiễu từ dữ liệu gốc. Lớp cuối của mỗi bộ mã hóa, gọi là lớp biểu diễn ẩn thông tin tinh gọn, chứa thông tin đã được tinh lọc. Các biểu diễn ẩn này sau đó được kết hợp thông qua phép ghép nối. Thông tin sau khi ghép nối được tiếp tục xử lý qua một mạng nơ-ron chuyên biệt để học cách kết hợp hiệu quả thông tin từ các nguồn dữ liệu omics khác nhau.

Hai mô hình cũng có sự khác biệt trong cách xác định dấu ấn sinh học. MOGONET sử dụng kỹ thuật loại bỏ có chọn lọc (Feature Ablation)để đánh giá mức độ quan trọng của đặc trưng. Phương pháp này đo lường sự suy giảm hiệu năng khi một đặc trưng bị

loại bỏ. DeepSSC thì áp dụng thuật toán (Integrated Gradient) trên mô hình đã huấn luyện. MOGONET tập trung vào việc tìm kiếm các dấu ấn sinh học có khả năng nâng cao hiệu năng phân loại chung cho tất cả các kiểu phụ. DeepSSC mặt khác hướng đến việc phát hiện các dấu ấn đặc trưng cho từng kiểu phụ, giúp hiểu rõ hơn về đặc điểm sinh học của mỗi kiểu phụ. Sự khác biệt trong cách tích hợp dữ liệu tạo nên những ưu điểm riêng cho mỗi mô hình. MOGONET, với việc tích hợp ở lớp dự đoán, thể hiện khả năng khai thác tốt thông tin từ từng loại dữ liệu omics riêng lẻ. DeepSSC, nhờ tích hợp ở lớp biểu diễn ẩn thông tin tinh gọn, có khả năng nắm bắt được các tương tác phức tạp giữa các loại dữ liệu omics ngay từ giai đoạn biểu diễn dữ liệu.

Chương 2

Phương pháp

Chương này trình bày chi tiết về phương pháp nghiên cứu được đề xuất để khai phá và đánh giá các dấu ấn sinh học tiềm năng trong bệnh ung thư vú. Khung chương trình nghiên cứu được thiết kế với ba pha chính: xây dựng các mô hình phân loại sử dụng học sâu, khai phá dấu ấn sinh học bằng thuật toán Integrated Gradient, và đánh giá tính hiệu quả của các dấu ấn sinh học được phát hiện. Đặc biệt, nghiên cứu tập trung vào việc đề xuất và thử nghiệm nhiều thiết kế baseline khác nhau cho thuật toán Integrated Gradient, nhằm tối ưu hóa quá trình khai phá dấu ấn sinh học trong bối cảnh dữ liệu đa omics phức tạp. Các thí nghiệm được thiết kế một cách có hệ thống để đánh giá hiệu quả của phương pháp đề xuất, từ việc xử lý dữ liệu ban đầu đến đánh giá cuối cùng dựa trên các tiêu chí về mặt sinh học và khả năng dự đoán.

2.1. Tổng quan phương pháp tiếp cận

Nghiên cứu này giới thiệu một khung chương trình tổng hợp dựa trên hai phương pháp tiên tiến trong lĩnh vực tích hợp dữ liệu đa omics và phân loại kiểu phụ ung thư: MOGONET và DeepSSC. Bằng cách kế thừa những ưu điểm của cả hai phương pháp, đồng thời phát triển thêm các cải tiến mới, khung chương trình này hướng đến việc nâng cao hiệu quả phân loại kiểu phụ ung thư vú và khả năng phát hiện các dấu ấn sinh học tiềm năng.

Khung chương trình nghiên cứu được thiết kế với ba giai đoạn chính hay ba pha chính nhằm tìm kiếm và đánh giá các dấu ấn sinh học tiềm năng liên quan đến bệnh ung

thư. Giai đoạn đầu tập trung vào việc lựa chọn và huấn luyện các mô hình học sâu để phân loại hiệu quả các kiểu phụ của bệnh ung thư vú. Tiếp theo, giai đoạn thứ hai thực hiện phân tích tổng hợp các mô hình và xác định dấu ấn sinh học bằng cách áp dụng thuật toán Integrated Gradient với các baseline phù hợp. Giai đoạn cuối cùng tập trung vào đánh giá chất lượng của các dấu ấn sinh học đã phát hiện thông qua việc so sánh với cơ sở dữ liệu chuẩn và đánh giá hiệu năng phân loại dựa trên các nhóm dấu ấn với các mô hình học máy truyền thống.

Nghiên cứu đặc biệt chú trọng việc cải tiến các bước xử lý dữ liệu và huấn luyện mô hình. Quy trình tiền xử lý dữ liệu được phát triển dựa trên nền tảng của phương pháp DeepSSC, nhằm đảm bảo chất lượng và tính nhất quán của dữ liệu đầu vào. Quá trình trích chọn đặc trưng kế thừa các kỹ thuật hiệu quả từ MOGONET, giúp giảm đáng kể kích thước dữ liệu và tập trung vào những đặc trưng quan trọng. Nghiên cứu áp dụng phương pháp đánh trọng số theo tỉ lệ các lớp để giải quyết thách thức của dữ liệu mất cân bằng. Vấn đề học quá cũng được phòng tránh thông qua việc kết hợp ưu điểm vốn từ cả hai kiến trúc, đồng thời sử dụng các kỹ thuật điều chuẩn và dừng sớm.

Để đảm bảo tính khách quan trong đánh giá và tăng độ ổn định của các dấu ấn sinh học, nghiên cứu áp dụng phương pháp chia dữ liệu thành nhiều tập ngẫu nhiên. Cụ thể, nghiên cứu sử dụng kỹ thuật lấy mẫu ngẫu nhiên phân tổ (Stratified Random Sampling) và kỹ thuật phân chia K-phần dựa trên lấy mẫu ngẫu nhiên phân tổ (Stratified K-fold). Cách tiếp cận này không chỉ giúp đánh giá mô hình toàn diện mà còn tạo cơ sở vững chắc cho việc xác định các dấu ấn sinh học có tính ổn định cao [55]. Đáng chú ý, những ứng dụng, cải tiến này được áp dụng đồng nhất cho cả hai kiến trúc, tạo nền tảng công bằng để so sánh hiệu quả giữa các mô hình.

Nghiên cứu đặc biệt chú trọng việc thử nghiệm và thiết kế các baseline phù hợp trong quá trình xác định dấu ấn sinh học. Ngoài việc sử dụng các baseline thông thường như véc-tơ không và véc-tơ trung bình của dữ liệu, nghiên cứu còn đề xuất các thiết kế baseline mới dựa trên đặc trưng của dữ liệu đa omics. Cụ thể, nghiên cứu xem xét việc sử dụng các baseline riêng biệt cho từng loại dữ liệu omics, đồng thời tận dụng thông tin từ các mẫu thuộc cùng kiểu phụ để xây dựng baseline có tính đại diện cao. Những cải tiến này nhằm tối ưu hóa hiệu quả của thuật toán IG trong việc xác định dấu ấn sinh học, đặc biệt trong bối cảnh phức tạp của dữ liệu đa omics với số chiều cao và tính không đồng nhất giữa các nguồn dữ liệu.

Đóng góp quan trọng của nghiên cứu nằm ở thiết kế và thực hiện các thí nghiệm xuyên suốt ba giai đoạn, cung cấp cái nhìn toàn diện về hiệu quả của phương pháp đề xuất. Các thí nghiệm không chỉ đánh giá khả năng phân loại kiểu phụ ung thư vú và khai phá dấu ấn sinh học, mà còn bàn luận tác động của các yếu tố như kiến trúc mô hình, mẫu đặc trưng học được khác nhau, thiết kế baseline, và số lượng đặc trưng trong bối cảnh dữ liệu mất cân bằng - một thách thức phổ biến trong nghiên cứu y sinh. Thông qua cách tiếp cận này, nghiên cứu giới thiệu một hướng đi tiềm năng trong phân loại và khai phá dấu ấn sinh học. Kết quả nghiên cứu có tiềm năng đóng góp cho lĩnh vực y học cá nhân hóa và mở ra hướng phát triển mới trong ứng dụng học máy và phân tích dữ liệu đa omics trong y sinh học.

2.2. Kiến trúc chung của khung chương trình

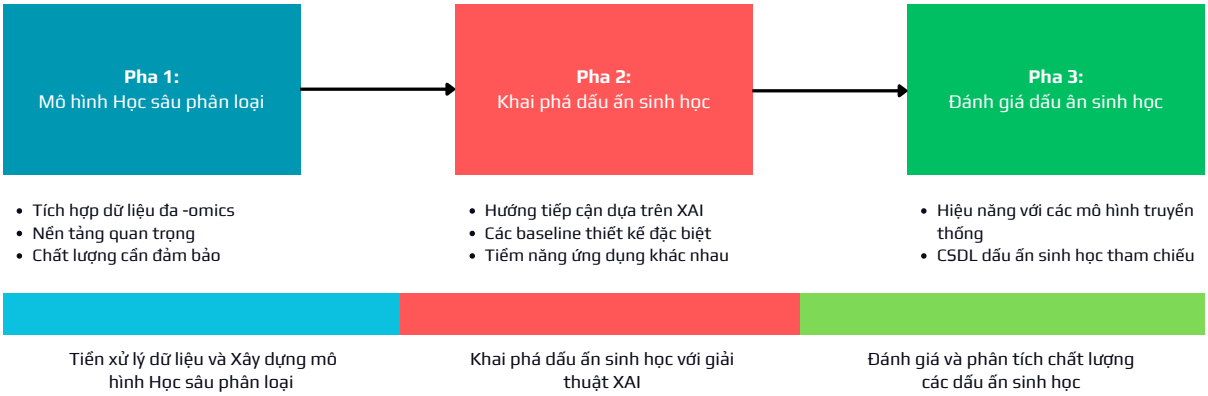

Hình 2.1: Khung chương trình khai phá và đánh giá các dấu ấn sinh học tiềm năng

Nghiên cứu này đề xuất một khung chương trình có hệ thống nhằm khai phá và đánh giá các dấu ấn sinh học tiềm năng trong bệnh ung thư vú. Như được minh họa trong Hình 2.1, khung chương trình được thiết kế theo ba pha riêng biệt nhưng có sự liên kết chặt chẽ, trong đó mỗi pha đóng một vai trò then chốt trong quy trình tổng thể.

Pha 1: Xây dựng các mô hình phân loại

Giai đoạn đầu tiên tập trung vào việc phát triển các mô hình học sâu có khả năng phân loại hiệu quả các kiểu phụ của bệnh ung thư vú. Hiệu năng của mô hình trong giai đoạn này đóng vai trò nền tảng cho toàn bộ quy trình phân tích tiếp theo. Theo [47], giải thích các mô hình là quá trình "trích xuất kiến thức liên quan từ mô hình học máy về các mối quan hệ được chứa trong dữ liệu hoặc được mô hình học được". Từ định nghĩa này, có

thể thấy chất lượng của việc giải thích mô hình và khai phá dấu ấn sinh học phụ thuộc vào hai yếu tố chính: chất lượng của dữ liệu đầu vào và khả năng của mô hình trong việc nắm bắt các đặc trưng có ý nghĩa sinh học từ dữ liệu đó. Hay chính xác hơn là mẫu đặc trưng trừu tượng mà bản thân mô hình phân loại học được. Quá trình xây dựng mô hình do đó đặc biệt chú trọng vào các bước thu thập và tiền xử lý dữ liệu đa omics để đảm bảo tính chính xác và đầy đủ của thông tin, đồng thời tập trung vào thiết kế kiến trúc mạng nơ-ron phù hợp và tối ưu hóa quá trình huấn luyện.

Pha 2: Khai phá dấu ấn sinh học

Giai đoạn thứ hai thực hiện phân tích tổng hợp từ các mô hình học sâu để khai phá dấu ấn sinh học tiềm năng. Phương pháp này sử dụng thuật toán Integrated Gradient kết hợp với chiến lược thiết kế baseline linh hoạt, cho phép thích ứng với các đặc điểm khác nhau của dữ liệu đa omics và bài toán phân loại. Quá trình khai phá được thực hiện thông qua hai bước chính: tính toán mức độ đóng góp của từng đặc trưng đối với quyết định phân loại của các mô hình và tổng hợp những đóng góp này để xác định các dấu ấn sinh học tiềm năng. Tính linh hoạt trong thiết kế baseline không chỉ nâng cao hiệu quả của phương pháp trong bối cảnh hiện tại mà còn tạo tiền đề cho việc mở rộng ứng dụng trong tương lai..

Pha 3: Đánh giá tính hiệu quả

Giai đoạn cuối cùng thực hiện đánh giá các phát hiện thông qua hai khía cạnh: ý nghĩa sinh học và khả năng dự đoán. Về khía cạnh sinh học, các dấu ấn được so sánh với danh sách chuẩn "tiêu chuẩn vàng" - tập hợp các dấu ấn sinh học đã được công nhận trong các nghiên cứu trước đây. Song song với đó, nghiên cứu đánh giá hiệu năng phân loại của các dấu ấn thông qua việc huấn luyện các mô hình học máy truyền thống trên tập đặc trưng đã được chọn lọc. Việc kết hợp hai phương pháp đánh giá này nhằm xác định các dấu ấn sinh học có ý nghĩa về mặt sinh học và có khả năng ứng dụng thực tiễn trong việc phân loại kiểu phụ ung thư vú.

Tích hợp và khả năng mở rộng

Kiến trúc mô-đun hóa của khung chương trình được thể hiện thông qua luồng dữ liệu liền mạch giữa các pha, trong đó kết quả từ quá trình huấn luyện mô hình ở *Pha 1: Xây dựng các mô hình phân loại* được chuyển tiếp trực tiếp vào quá trình phân tích ở *Pha 2:*

Khai phá dấu ấn sinh học, và các dấu ấn sinh học được phát hiện tiếp tục được đánh giá trong *Pha 3: Đánh giá tính hiệu quả*. Cụ thể, các mô hình học sâu đã huấn luyện từ *Pha 1* đóng vai trò quan trọng trong việc áp dụng giải thuật Integrated Gradients ở *Pha 2*, trong khi các dấu ấn sinh học được xác định từ *Pha 2* trở thành đối tượng của quá trình đánh giá toàn diện ở *Pha 3*.

Tính mô-đun hóa này không chỉ đảm bảo tính nhất quán trong quy trình nghiên cứu mà còn tạo điều kiện thuận lợi cho việc thay thế hoặc bổ sung các thành phần mới trong từng pha. Ví dụ, trong *Pha 1*, khung chương trình cho phép thử nghiệm các kiến trúc mạng nơ-ron khác nhau mà không ảnh hưởng đến cấu trúc tổng thể. Tương tự, *Pha 2* có thể được mở rộng để tích hợp các thiết kế baseline mới hoặc các giải thuật giải thích đóng góp khác ngoài Integrated Gradients. Khả năng mở rộng này không chỉ tạo điều kiện cho việc cải tiến liên tục mà còn đảm bảo tính bền vững của nghiên cứu trong tương lai, đồng thời cho phép khung chương trình thích ứng với các tiến bộ mới trong lĩnh vực học sâu, giải thích mô hình và tin sinh học.

2.3. Thiết kế thí nghiệm

Dựa trên kiến trúc tổng thể của khung chương trình đã được trình bày trong Mục 2.2., phần này mô tả chi tiết thiết kế thí nghiệm được triển khai để đánh giá và kiểm chứng hiệu quả của phương pháp đề xuất. Với mục tiêu kép là tối ưu hóa việc phân loại các kiểu phụ ung thư vú và khai phá hiệu quả các dấu ấn sinh học tiềm năng, quy trình thực nghiệm được thiết kế theo ba pha tương ứng với kiến trúc đã đề xuất. Trong đó, mỗi pha được cụ thể hóa với các thông số kỹ thuật, phương pháp thực hiện và tiêu chí đánh giá riêng biệt, đồng thời vẫn đảm bảo sự kết nối chặt chẽ giữa các pha để duy trì tính nhất quán của toàn bộ quá trình nghiên cứu.

Chuẩn bị và tiền xử lý dữ liệu

Quá trình nghiên cứu bắt đầu với việc thu thập và xử lý dữ liệu từ bộ dữ liệu TCGA BRCA trên nền tảng trung tâm dữ liệu mở Xena [46, 50, 61] - một nguồn dữ liệu uy tín và được công nhận rộng rãi trong các nghiên cứu về ung thư. Quy trình xử lý dữ liệu được thiết kế nghiêm ngặt, bắt đầu với việc loại bỏ các mẫu không phù hợp như mẫu kém chất lượng, nằm trong danh sách đen được công bố [28, 29], mẫu mô bình thường lân cận, mẫu di căn, mẫu tái phát và mẫu ung thư vú của nam giới. Tiếp theo, quá trình

lọc chỉ giữ lại các mẫu có đầy đủ thông tin cho cả hai loại dữ liệu omic (GE và CNA) và có nhãn kiểu phụ được thực hiện.

Sau bước làm sạch dữ liệu, tập dữ liệu được chia thành tập huấn luyện chính và tập kiểm thử bằng phương pháp lấy mẫu ngẫu nhiên phân tổ. Stratified K-fold được áp dụng trên tập huấn luyện chính để tạo các cặp tập huấn luyện và kiểm định có phân phối tương tự như tập gốc, đảm bảo tính khách quan trong đánh giá hiệu năng. Ngoài ra, dữ liệu được tiền xử lý thông qua các bước lọc phương sai, chọn đặc trưng bằng ANOVA F-value với FDR, và chuẩn hóa dữ liệu nhằm giảm kích thước dữ liệu, loại bỏ nhiễu, và tăng cường tính phân biệt của các đặc trưng.

Pha 1: Xây dựng các mô hình phân loại

Giai đoạn này tập trung vào việc huấn luyện và tối ưu hóa hai kiến trúc mạng nơ-ron học sâu được lựa chọn thí nghiệm là MOGONET và DeepSSC. Lần lượt huấn luyện các mô hình ứng với các kiến trúc học sâu thí nghiệm trên các tập dữ liệu thu được từ quá trình Stratified K-fold trước đó tạo ra các mô hình khác nhau tương ứng. Áp dụng các kỹ thuật giúp phòng tránh và hạn chế ảnh hưởng của dữ liệu mất cân bằng - một thách thức phổ biến trong dữ liệu y sinh, học quá, tối ưu hóa hiệu quả chung cho các mô hình của cả hai kiến trúc thử nghiệm. Hiệu năng của các mô hình được đánh giá thông qua ba chỉ số chính: Accuracy, F1-weighted và F1-macro trên tập kiểm định của mỗi fold, đảm bảo đánh giá toàn diện khả năng phân loại của mô hình. Loại kiến trúc, chất lượng của mô hình phân loại cũng được cơ sở để ta lựa chọn khai phá trong pha tiếp theo với kì vọng các kiến trúc mô hình, chất lượng mô hình tốt sẽ cho ta các tập dấu ấn sinh học chất lượng

Pha 2: Khai phá dấu ấn sinh học

Pha thứ hai áp dụng giải thuật Integrated Gradient để phân tích mô hình học sâu và xác định các dấu ấn sinh học tiềm năng. Bảy phương pháp baseline được thiết kế và thử nghiệm, bao gồm hai baseline truyền thống ("*zeros*" và "*micro-means*") và năm baseline mới được đề xuất là "*macro-means*", "*micro-mean–zero*", "*macro-mean–zero*", "*dict-default-micro-means*", và "*dict-default-macro-means*". Quá trình tính toán điểm đóng góp của từng đặc trưng được thực hiện theo cách tiếp cận toàn cục. Để có cơ sở so sánh khách quan, phương pháp Feature Ablation từ nghiên cứu MOGONET gốc cũng được triển khai và đánh giá trên cùng tập kiểm định đã được chia.

Pha 3: Đánh giá tính hiệu quả

Giai đoạn cuối cùng thực hiện đánh giá toàn diện chất lượng của các dấu ấn sinh học thông qua hai hướng tiếp cận chính. Đầu tiên, ta đánh giá hiệu năng phân loại bằng cách sử dụng các tốp dấu ấn sinh học khác nhau làm đặc trưng đầu vào cho ba thuật toán phân loại truyền thống: Logistic Regression, Support Vector Machine (SVM) và Random Forest. Hiệu năng được đo lường trên tập kiểm thử thông qua các chỉ số Accuracy, F1-weighted và đặc biệt là F1-macro - chỉ số được chọn làm tiêu chí chính theo sở cứ đã trình bày trong Mục 1.2.2..

Hướng tiếp cận thứ hai tập trung vào việc so sánh với bộ "tiêu chuẩn vàng" được xây dựng từ Comparative Toxicogenomics Database (CTD). Quy trình xây dựng bộ "tiêu chuẩn vàng" được thực hiện thông qua việc trích xuất các gen liên quan đến ung thư vú, sau đó lọc chỉ giữ lại các gen có kí hiệu M và/hoặc T, cuối cùng sắp xếp theo điểm số suy luận giảm dần để ưu tiên các gen có mối liên hệ mạnh nhất với bệnh.

Các kết quả thống kê từ các thí nghiệm sẽ được phân tích theo nhiều góc độ. Thứ nhất, so sánh hiệu năng giữa hai kiến trúc MOGONET và DeepSSC trong *Pha 1* để làm cơ sở đánh giá mô hình phân loại tốt nhất cho các dữ liệu đa omics không cân bằng. Đồng thời, đây cũng là cơ sở để ta đánh giá ảnh hưởng của chất lượng trong Pha 1 đến việc khai phá dấu ấn sinh học ở Pha tiếp theo. Thứ hai, trong *Pha 2*, quá trình khai phá dấu ấn sinh học với bảy thiết kế baseline khác nhau cho giải thuật Integrated Gradient sẽ tạo ra các tập điểm đóng góp đặc trưng khác nhau. Riêng với MOGONET, phương pháp Feature Ablation từ bài báo gốc cũng được triển khai để làm cơ sở so sánh. *Pha 3* thực hiện các thí nghiệm sử dụng các tốp dấu ấn sinh học khác nhau được lựa chọn từ các tập đặc trưng với điểm đóng góp tương ứng. Các đặc trưng hay tốp các dấu ấn sinh học được lựa chọn sẽ được làm đầu vào cho ba thuật toán phân loại truyền thống là Logistic Regression, SVM và Random Forest. Kết quả phân loại này không chỉ giúp đánh giá chất lượng của các dấu ấn sinh học được phát hiện mà còn phản ánh gián tiếp hiệu quả của việc lựa chọn kiến trúc mô hình và thiết kế baseline trong các pha trước đó.

Ngoài việc đánh giá hiệu năng tính toán, các dấu ấn sinh học được tìm thấy còn được so sánh với bộ "tiêu chuẩn vàng" từ Comparative Toxicogenomics Database (CTD) để xác nhận giá trị sinh học. Từ việc tổng hợp và phân tích các kết quả trên, nghiên cứu có thể đưa ra các khuyến nghị về lựa chọn kiến trúc mô hình và thiết kế baseline phù hợp, đặc biệt trong bối cảnh dữ liệu mất cân bằng - một thách thức phổ biến trong phân

tích dữ liệu y sinh. Thiết kế thí nghiệm này không chỉ đảm bảo tính khoa học và khách quan của kết quả, mà còn tạo điều kiện thuận lợi cho việc tái hiện và mở rộng nghiên cứu trong tương lai.

2.4. Các baseline và giải thuật tổng hợp điểm trong khai phá dấu ấn sinh học

Trong phân tích giải thích mô hình học sâu sử dụng Integrated Gradient (IG), việc lựa chọn baseline đóng vai trò then chốt đến kết quả phân tích. Một baseline phù hợp có thể cung cấp điểm tham chiếu có ý nghĩa, từ đó hỗ trợ thuật toán trong việc xác định mức độ đóng góp của các đặc trưng. Nghiên cứu này thực hiện thử nghiệm với nhiều thiết kế baseline khác nhau, xuất phát từ nhận định rằng mỗi bối cảnh phân tích có thể cần những cách tiếp cận riêng biệt và không có một giải pháp đơn lẻ nào tối ưu cho mọi trường hợp. Mặc dù được thử nghiệm ban đầu trong bài toán phân loại kiểu phụ ung thư vú, các baseline được đề xuất có tính tổng quát và có thể điều chỉnh để áp dụng cho nhiều bài toán khác trong lĩnh vực tin sinh học và trí tuệ nhân tạo. Sự đa dạng trong thiết kế baseline này cung cấp cho các nhà nghiên cứu sự linh hoạt trong việc lựa chọn phương pháp phù hợp với đặc thù dữ liệu và mục tiêu phân tích cụ thể của họ.

2.4.1. Phân loại và thiết kế baseline cho Integrated Gradient

Các baseline được đề xuất có thể được phân thành bốn nhóm dựa trên nguyên lý thiết kế và mục đích sử dụng. Để thuận tiện cho việc trình bày, các ký hiệu sau được sử dụng:

- O: số lượng loại omics đầu vào (trong nghiên cứu này $O = 2$, tương ứng với dữ liệu GE và CNA; để đơn giản các công thức ở đây nếu liên quan sẽ sử dụng trực tiếp kí hiệu GE và CNA)
- C: số lượng kiểu phụ cần phân loại ($C = 5$, tương ứng với các kiểu phụ PAM50)
- M: tổng số mẫu trong tập dữ liệu
- A_{ij}: giá trị của đặc trưng thứ j trong mẫu thứ i

- n: số lượng đặc trưng
- $s(i)$: hàm ánh xạ kiểu phụ thực của mẫu thứ i
- g: kiểu phụ đang xét
- g' kiểu phụ khác g
- a_j thành phần giá trị của baseline đang xét ứng với đặc trưng j

Nhóm baseline đơn giản

Baseline "*zeros*" được định nghĩa như một véc tơ có tất cả các phần tử bằng 0:

$$zeros = (\underbrace{0, 0, \ldots, 0}_{n \text{ đặc trưng}}) \tag{2.1}$$

Mặc dù đơn giản trong cấu trúc, baseline này là một trong những baseline phổ biến và được sử dụng rộng rãi trong nhiều bài toán XAI khác nhau. Baseline này có thể mang một số đặc điểm quan trọng:

- Có thể đóng vai trò như một điểm tham chiếu trung tính, không thiên vị về bất kỳ đặc trưng nào
- Có tiềm năng cho phép đánh giá mức độ đóng góp của đặc trưng so với trạng thái "không có thông tin"
- Dễ dàng triển khai và tái tạo kết quả
- Thường được sử dụng trong nhiều nghiên cứu

Tuy nhiên, cũng như mọi phương pháp khác, baseline "*zeros*" có thể có một số hạn chế cần cân nhắc:

- Có thể chưa phản ánh đầy đủ bản chất sinh học của dữ liệu
- Khả năng chưa tận dụng được thông tin thống kê từ tập dữ liệu
- Trong một số trường hợp, có thể dẫn đến kết quả thiên lệch khi dữ liệu có phân phối không đối xứng quanh 0

Nhóm baseline dựa trên giá trị trung bình

Nhóm này được thiết kế với mục đích tận dụng thông tin thống kê từ dữ liệu thông qua hai cách tiếp cận khác nhau trong việc tính toán giá trị trung bình. Những baseline này có thể bổ sung cho các phương pháp đơn giản như baseline "*zeros*" trong một số tình huống phân tích khác nhau:

a) Baseline "micro-means"

Baseline này được xây dựng dựa trên việc tính trung bình cho từng đặc trưng riêng lẻ trên toàn bộ tập dữ liệu:

$$micro\text{-}means = (a_1, a_2, \ldots, a_n) \tag{2.2}$$

Trong đó:

$$a_j = \frac{1}{N}\sum_{i=1}^{M} A_{ij}$$

Baseline "*micro-means*" có thể có một số đặc điểm:

- Có khả năng phản ánh xu hướng trung bình tổng thể của từng đặc trưng
- Có thể phù hợp khi phân phối dữ liệu tương đối đồng đều giữa các lớp
- Dễ dàng trong việc triển khai và tính toán
- Thường được sử dụng trong nhiều nghiên cứu

Tuy nhiên, cần cân nhắc một số khía cạnh:

- Có thể nhạy cảm với sự mất cân bằng dữ liệu giữa các kiểu phụ
- Khả năng chưa tận dụng được thông tin thống kê từ tập dữ liệu
- Trong một số trường hợp, có thể bị ảnh hưởng bởi các giá trị ngoại lai

b) Baseline "macro-means"

Baseline này được đề xuất như một cách tiếp cận thay thế, có thể giải quyết một số hạn chế của *micro-means*:

$$macro\text{-}means = (a_1, a_2, \ldots, a_n) \tag{2.3}$$

Trong đó:

$$a_j = \frac{1}{C} \sum_{g=1}^{C} \frac{\sum\limits_{s(i)=g} A_{ij}}{\sum\limits_{s(i)=g} 1}$$

Baseline "*macro-means*" có thể mang một số đặc điểm tiềm năng:

- Có khả năng giảm thiểu ảnh hưởng của sự mất cân bằng dữ liệu
- Có thể đảm bảo mỗi kiểu phụ có đóng góp tương đương trong việc xác định giá trị baseline
- Có tiềm năng phản ánh tốt hơn đặc trưng của từng kiểu phụ

Tuy nhiên, cũng cần lưu ý một số điểm:

- Có thể đòi hỏi tính toán phức tạp hơn "*micro-means*"
- Trong một số trường hợp, có thể nhạy cảm hơn với các kiểu phụ có ít mẫu

Nhóm baseline sinh học

Nhóm baseline này được đề xuất với định hướng tích hợp kiến thức chuyên ngành về đặc điểm của các loại dữ liệu omics khác nhau. Cách tiếp cận này xuất phát từ quan sát rằng mỗi loại dữ liệu omics có thể có những đặc trưng và thang đo riêng biệt, do đó có thể cần các phương pháp xử lý khác nhau.

a) Baseline "micro-mean–zero"

Baseline này được thiết kế như một sự kết hợp giữa phương pháp "*micro-means*" và "*zeros*":

$$micro\text{-}mean\text{–}zero = (\mathrm{GE}_{\mathrm{micro}}, \mathrm{CNA}_{\mathrm{zero}}) \tag{2.4}$$

Trong đó:

$$\mathrm{GE}_{\mathrm{micro}} = \left\{ \frac{1}{M} \sum_{i=1}^{M} \mathrm{GE}_{ij} \right\}_{j=1}^{n_{\mathrm{GE}}}$$

$$\mathrm{CNA}_{\mathrm{zero}} = \{ \underbrace{0, 0, \ldots, 0}_{n_{\mathrm{CNA}} \text{ đặc trưng}} \}$$

GE_{ij}	:	giá trị biểu hiện gen j trong mẫu i
GE_{micro}	:	tập hợp các giá trị hay véc tơ baseline tương ứng cho dữ liệu biểu hiện gen
n_{GE}	:	số lượng đặc trưng biểu hiện gen
CNA_{zero}	:	tập hợp các giá trị hay véc tơ baseline tương ứng cho dữ liệu biến đổi số lượng bản
n_{CNA}	:	số lượng đặc trưng biến đổi số bản sao

Cơ sở khoa học đằng sau thiết kế này có thể được xem xét từ các khía cạnh khác nhau. Đối với dữ liệu biểu hiện gen (GE):

- Việc sử dụng giá trị trung bình có thể phù hợp khi xem xét mức độ biểu hiện gen [46, 61]
- Các giá trị cao hoặc thấp hơn mức trung bình có thể chỉ ra sự biểu hiện bất thường
- Cách tiếp cận này có thể tương đồng với phương pháp phân tích biểu hiện gen truyền thống

Đối với dữ liệu biến đổi số bản sao (CNA) [46, 61]:

- Giá trị 0 có thể đại diện cho trạng thái không có biến đổi số bản sao
- Các giá trị -2, -1, 1, 2 có thể tương ứng với các mức độ mất hoặc nhân bản đoạn gen
- Baseline 0 có thể phù hợp với tính chất rời rạc của dữ liệu CNA

b) Baseline "macro-mean–zero"

Baseline này được đề xuất như một biến thể của micro-mean–zero, sử dụng phương pháp macro-means cho dữ liệu GE:

$$\textit{macro-mean–zero} = (\mathrm{GE}_{\mathrm{macro}}, \mathrm{CNA}_{\mathrm{zero}}) \tag{2.5}$$

Trong đó:

$$\mathrm{GE}_{\mathrm{macro}} = \left\{ \frac{1}{C} \sum_{g=1}^{C} \frac{\sum_{s(i)=g} \mathrm{GE}_{ij}}{\sum_{s(i)=g} 1} \right\}_{j=1}^{n_{\mathrm{GE}}}$$

$$\text{CNA}_{\text{zero}} = \{\underbrace{0, 0, \ldots, 0}_{n_{\text{CNA}} \text{ features}}\}$$

GE_{ij}	:	giá trị biểu hiện gen j trong mẫu i
n_{GE}	:	số lượng đặc trưng biểu hiện gen
n_{CNA}	:	số lượng đặc trưng biến đổi số bản sao

Các baseline sinh học này có thể mang một số đặc điểm tiềm năng:

- Có khả năng tích hợp hiểu biết về bản chất sinh học của từng loại dữ liệu
- Có thể tạo điều kiện thuận lợi cho việc giải thích kết quả trong ngữ cảnh sinh học
- Có tiềm năng phù hợp với thực tiễn nghiên cứu trong lĩnh vực tin sinh học

Tuy nhiên, cũng cần cân nhắc một số điểm:

- Có thể đòi hỏi hiểu biết chuyên sâu về đặc điểm của từng loại dữ liệu omics
- Hiệu quả của phương pháp có thể phụ thuộc vào nhiều yếu tố: chất lượng và đặc điểm của dữ liệu đầu vào, kiến trúc của mô hình, cũng như các mẫu đặc trưng ẩn mà mô hình học được từ dữ liệu (các mẫu đặc trưng ẩn này không nhất thiết luôn phản ánh chính xác hoàn toàn bản chất sinh học của bài toán)

Nhóm baseline lớp mặc định

Nhóm baseline này được đề xuất dựa trên ý tưởng về lớp mặc định trong phân loại. Cách tiếp cận này xuất phát từ giả thuyết rằng việc xem xét đặc trưng phân biệt của một kiểu phụ có thể hiệu quả hơn khi đối chiếu với đặc điểm chung của các kiểu phụ còn lại.

a) Baseline "dict-default-micro-means"

Với mỗi kiểu phụ g baseline được định nghĩa:

$$dict\text{-}default\text{-}micro\text{-}means_g = (a_1, a_2, \ldots, a_n)$$

Trong đó:

$$a_j = \frac{\sum_{s(i) \neq g} A_{ij}}{\sum_{s(i) \neq g} 1}$$

Baseline này có thể có một số đặc điểm tiềm năng:

- Có khả năng tạo điểm tham chiếu đặc thù cho từng kiểu phụ
- Có thể loại bỏ ảnh hưởng của kiểu phụ đang xét khỏi giá trị baseline
- Có tiềm năng trong việc làm nổi bật các đặc trưng phân biệt của kiểu phụ đang xét

b) Baseline "dict-default-macro-means"

Với mỗi kiểu phụ g baseline được định nghĩa:

$$dict\text{-}default\text{-}macro\text{-}means_g = (a_1, a_2, \ldots, a_n)$$

Trong đó:

$$a_j = \frac{1}{C-1} \sum_{g'=1, g' \neq g}^{C} \frac{\sum_{s(i)=g'} A_{ij}}{\sum_{s(i)=g'} 1}$$

Baseline này có thể mang một số đặc điểm:

- Có khả năng kết hợp ưu điểm của phương pháp "*macro-means*" với ý tưởng về lớp mặc định
- Có tiềm năng trong việc cân bằng đóng góp giữa các kiểu phụ còn lại
- Có thể giúp giảm thiểu ảnh hưởng của sự mất cân bằng dữ liệu

Nhóm baseline lớp mặc định này có thể có một số ý nghĩa tiềm năng trong nghiên cứu:

- Có khả năng hỗ trợ phân tích chi tiết đặc trưng phân biệt của từng kiểu phụ
- Có thể tạo điều kiện thuận lợi cho việc xác định các dấu ấn sinh học đặc trưng
- Có tiềm năng trong việc nâng cao độ tin cậy khi giải thích mô hình cho từng kiểu phụ

Tuy nhiên, cũng cần cân nhắc một số khía cạnh:

- Có thể đòi hỏi tính toán phức tạp hơn các phương pháp truyền thống
- Hiệu quả có thể phụ thuộc vào mức độ phân biệt thực sự giữa các kiểu phụ trong dữ liệu
- Kết quả có thể bị ảnh hưởng bởi chất lượng của việc phân loại ban đầu của mô hình

Qua việc thiết kế và phân tích các nhóm baseline, nghiên cứu đề xuất một số nhận xét và hướng tiếp cận quan trọng. Trước hết, việc thiết kế đa dạng các nhóm baseline khác nhau được kỳ vọng sẽ cung cấp nhiều góc nhìn bổ sung cho bài toán phân tích. Trong đó, mỗi nhóm baseline có thể phát huy hiệu quả trong những tình huống và mục tiêu phân tích khác nhau. Chẳng hạn, trong khi baseline đơn giản có thể phù hợp cho việc đánh giá ban đầu và so sánh với các nghiên cứu khác, thì baseline dựa trên giá trị trung bình có thể thích hợp hơn khi cần tận dụng thông tin thống kê từ dữ liệu. Tương tự, baseline sinh học có thể phát huy hiệu quả trong các trường hợp cần tích hợp kiến thức chuyên ngành, và baseline lớp mặc định có thể đặc biệt hữu ích cho việc phân tích đặc trưng phân biệt của từng kiểu phụ.

Các baseline được thiết kế với kỳ vọng có thể phản ánh được đặc thù của dữ liệu omics và bản chất sinh học của bài toán. Điều này thể hiện qua việc các baseline có khả năng thích ứng với những thách thức phổ biến trong dữ liệu sinh học như sự mất cân bằng giữa các lớp, đồng thời tận dụng được hiểu biết chuyên ngành trong quá trình phân tích. Bộ baseline được đề xuất cũng hướng tới việc mang lại sự linh hoạt cho người sử dụng, cho phép họ lựa chọn phương pháp phù hợp dựa trên đặc điểm cụ thể của dữ liệu, kết hợp nhiều baseline để có cái nhìn đa chiều về tầm quan trọng của đặc trưng, và có thể điều chỉnh, mở rộng cho các bài toán tương tự trong lĩnh vực tin sinh học.

Tuy nhiên, cần lưu ý rằng việc sử dụng các baseline này có thể đi kèm với một số thách thức. Hiệu quả của mỗi baseline có thể phụ thuộc vào nhiều yếu tố như chất lượng dữ liệu, kiến trúc mô hình, và các mẫu đặc trưng ẩn, quy luật mà mô hình học được từ dữ liệu. Việc lựa chọn baseline phù hợp có thể đòi hỏi quá trình thử nghiệm và đánh giá kỹ lưỡng, trong khi kết quả phân tích có thể bị ảnh hưởng bởi sự tương tác phức tạp giữa baseline, đặc điểm của dữ liệu, và cách thức mô hình nắm bắt các mẫu đặc trưng ẩn từ dữ liệu huấn luyện.

2.4.2. Giải thuật tổng hợp điểm quan trọng của đặc trưng

Giải thuật hay thuật toán được thiết kế để tính toán và tổng hợp điểm quan trọng của đặc trưng bằng cách xử lý nhiều mô hình đã được huấn luyện. Chi tiết của được mô tả trong Thuật toán 2.1.

Giai đoạn 1: Tính toán điểm đóng góp cho từng mô hình

Trong giai đoạn này, giải thuật xử lý từng mô hình riêng biệt. Với mỗi mô hình, sau khi tải trọng số và dữ liệu tương ứng, giải thuật tính toán điểm đóng góp cho từng kiểu phụ sử dụng phương pháp Integrated Gradient. Quá trình này được thực hiện theo từng batch để tối ưu việc sử dụng bộ nhớ. Đối với mỗi kiểu phụ, giải thuật sử dụng baseline tương ứng đã được định nghĩa trước.

Giai đoạn 2: Tổng hợp điểm điểm đóng góp trong một mô hình

Sau khi có được điểm đóng góp cho tất cả các kiểu phụ trong một mô hình, giải thuật thực hiện việc tổng hợp bằng cách:

- Xếp chồng (stack) các điểm đóng góp từ tất cả các kiểu phụ
- Tính trung bình tuyệt đối của điểm đóng góp trên các mẫu cho mỗi kiểu phụ
- Tổng hợp điểm đóng góp qua các kiểu phụ

Kết quả của giai đoạn này là một véc tơ điểm quan trọng cho mỗi mô hình.

Giai đoạn 3: Tổng hợp kết quả cuối cùng

Ở giai đoạn cuối, giải thuật tính toán điểm quan trọng cuối cùng cho mỗi đặc trưng bằng cách lấy trung bình các điểm số qua tất cả các mô hình. Các đặc trưng sau đó được sắp xếp theo thứ tự giảm dần của điểm quan trọng và được tổ chức trong một khung dữ liệu có cấu trúc.

Kết quả đầu ra của giải thuật là một ma trận dữ liệu hai chiều chứa danh sách các đặc trưng được sắp xếp theo mức độ quan trọng, có thể được sử dụng trực tiếp cho việc lựa chọn dấu ấn sinh học tiềm năng trong bài toán phân loại kiểu phụ của bệnh ung thư vú.

Thuật toán 2.1: Tính toán và tổng hợp điểm tiềm năng đặc trưng sử dụng IG

Data: num_models: Số lượng mô hình đã được huấn luyện
baselines: Từ điển các baseline cho mỗi mô hình và kiểu phụ
dataset: Tên tập dữ liệu (ví dụ: "TCGA BRCA")
Result: Bảng dữ liệu đã sắp xếp các đặc trưng quan trọng

```
feature_importance_by_models ← khởi tạo từ điển rỗng
for model_index = 1 to num_models do
    Tải trọng số của model_index;
    Tải tập dữ liệu cho model_index;
    Khởi tạo IntegratedGradient;
    for mỗi kiểu phụ trong dataset do
        baseline ← lấy baseline cho kiểu phụ hiện tại từ baselines;
        attributions_subtype ← khởi tạo mảng rỗng;
        for mỗi batch của mẫu trong dataset do
            Tính toán điểm đóng góp sử dụng IntegratedGradient;
            Nối điểm đóng cho tất cả kiểu dữ liệu omics;
            Thêm vào attributions_subtype;
        end
        Lưu trữ attributions_subtype;
    end
    Xếp chồng điểm đóng góp cho tất cả các kiểu phụ;
    Tính trung bình tuyệt đối của điểm đóng góp trên các mẫu cho mỗi kiểu phụ;
    Tổng hợp điểm đóng góp trên các kiểu phụ;
    feature_importance_by_models[model_index] ← điểm tổng;
end
final_feature_importance ← tính trung bình trên tất cả các mô hình;
Sắp xếp các đặc trưng theo final_feature_importance theo thứ tự giảm dần;
result ← tạo dataframe với tên đặc trưng và điểm quan trọng;
return result
```

Chương 3

Thực nghiệm và kết quả

Chương này trình bày chi tiết quá trình triển khai thực nghiệm và các kết quả thu được từ việc áp dụng phương pháp nghiên cứu đã đề xuất. Dựa trên khung thiết kế đã được trình bày trong Chương 2, phần đầu của chương sẽ mô tả cụ thể về dữ liệu thực nghiệm, quy trình xử lý, và môi trường triển khai. Việc đặc tả chi tiết này không chỉ đảm bảo tính minh bạch của nghiên cứu mà còn tạo điều kiện cho việc tái hiện kết quả trong tương lai. Đồng thời, những chi tiết này cũng giúp làm rõ các thách thức đặc thù của dữ liệu sinh học và cách tiếp cận được áp dụng để giải quyết chúng.

3.1. Dữ liệu và môi trường thực thi

3.1.1. Chi tiết dữ liệu thực nghiệm và tiền xử lý

a. Nguồn dữ liệu và quy trình xử lý

Nghiên cứu này sử dụng bộ dữ liệu TCGA BRCA (The Cancer Genome Atlas Breast Invasive Carcinoma), được thu thập từ nền tảng trung tâm dữ liệu mở Xena. TCGA BRCA là một trong những nguồn dữ liệu toàn diện nhất về ung thư vú, cung cấp thông tin đa omics từ các mẫu khối u được thu thập theo tiêu chuẩn nghiêm ngặt. Bộ dữ liệu gốc bao gồm 1247 mẫu từ 1101 bệnh nhân khác nhau, với 20530 đặc trưng cho dữ liệu biểu hiện gen và 24766 đặc trưng cho dữ liệu biến đổi số lượng bản sao [46, 61].

Quá trình lọc dữ liệu được thiết kế với mục tiêu kép: đảm bảo tính đồng nhất sinh

học và độ tin cậy của dữ liệu. Các mẫu mô bình thường lân cận khối u được loại bỏ do không phản ánh đặc tính của khối u. Việc loại bỏ này đặc biệt quan trọng vì mặc dù các mô này có vẻ bình thường về mặt hình thái, chúng có thể đã bị ảnh hưởng bởi môi trường vi mô của khối u. Tương tự, các mẫu di căn ngoài khối u nguyên phát và mẫu tái phát cũng được loại trừ do có thể mang những biến đổi di truyền phụ thêm không đặc trưng cho kiểu phụ gốc của khối u.

Một khía cạnh quan trọng khác trong quá trình lọc dữ liệu là việc xử lý các mẫu có vấn đề về chất lượng. Các mẫu trong danh sách đen được loại bỏ do không đạt các tiêu chuẩn kỹ thuật như độ tinh khiết của RNA hoặc độ bao phủ của giải trình tự. Các mẫu cần biên tập lại, thường do sự không nhất quán trong thông tin lâm sàng hoặc phân tử, cũng được loại bỏ để đảm bảo độ tin cậy của dữ liệu.

Việc loại bỏ các mẫu ung thư vú của nam giới dựa trên cơ sở sinh học vững chắc. Ung thư vú ở nam giới, chiếm khoảng 1% tổng số ca ung thư vú, có những đặc điểm phân tử và đáp ứng điều trị khác biệt so với ung thư vú ở nữ giới. Sự khác biệt này một phần do ảnh hưởng của môi trường hormone khác nhau giữa nam và nữ.

Sau quá trình lọc nghiêm ngặt này, bộ dữ liệu còn lại 1078 mẫu cho dữ liệu biểu hiện gen và 1064 mẫu cho dữ liệu biến đổi số lượng bản sao. Việc đòi hỏi các mẫu phải có đầy đủ thông tin cho cả hai loại dữ liệu omic và có nhãn kiểu phụ dẫn đến việc tập dữ liệu cuối cùng còn 819 mẫu. Mặc dù điều này làm giảm kích thước mẫu, nhưng đây là sự đánh đổi cần thiết để đảm bảo chất lượng của phân tích tích hợp đa omics.

Bảng 3.1: Phân bố mẫu theo kiểu phụ ung thư vú

Kiểu phụ	**Số lượng mẫu**	**Tỷ lệ**
LumA (Luminal A)	409	49.94%
LumB (Luminal B)	187	22.83%
Basal-like	134	16.36%
HER2-enriched	67	8.18%
Normal-like	22	2.69%
Tổng	**819**	**100%**

Phân tích phân bố mẫu theo kiểu phụ cho thấy một sự mất cân bằng đáng kể trong dữ liệu (Bảng 3.1). Kiểu phụ LumA chiếm gần một nửa số mẫu với 409 mẫu (49.94%),

trong khi Normal-like chỉ có 22 mẫu (2.69%). Sự mất cân bằng này phản ánh phần nào tỷ lệ xuất hiện tự nhiên của các kiểu phụ trong quần thể bệnh nhân, với LumA là kiểu phụ phổ biến nhất. Tuy nhiên, mức độ chênh lệch 18.6:1 giữa lớp đa số và thiểu số tạo ra thách thức đáng kể trong việc xây dựng mô hình phân loại công bằng và hiệu quả.

b. Chiến lược xử lý dữ liệu mất cân bằng và tiền xử lý

Để đối phó với thách thức của sự mất cân bằng dữ liệu và đảm bảo tính khách quan trong đánh giá hiệu năng của mô hình, nghiên cứu này áp dụng một chiến lược đa chiều. Chiến lược này được thiết kế dựa trên nguyên tắc bảo toàn cấu trúc tự nhiên của dữ liệu trong khi vẫn đảm bảo khả năng học hiệu quả của mô hình. Quá trình phân chia dữ liệu được thực hiện một cách có hệ thống thông qua hai bước. Đầu tiên, phương pháp Stratified Random Sampling được sử dụng để chia tổng số 819 mẫu thành tập dữ liệu chính (80%, 655 mẫu) và tập kiểm thử (20%, 164 mẫu). Việc sử dụng phương pháp phân tầng đảm bảo rằng cả hai tập dữ liệu đều duy trì tỷ lệ tương đối của các kiểu phụ như trong tập dữ liệu gốc, tránh tình trạng một số kiểu phụ hiếm có thể bị mất hoàn toàn trong quá trình phân chia ngẫu nhiên thông thường.

Tiếp theo, tập dữ liệu chính được chia thành năm phần bằng nhau sử dụng Stratified K-fold với K=5. Phương pháp này không chỉ đảm bảo mỗi phần có phân phối kiểu phụ tương tự nhau mà còn cho phép đánh giá độ ổn định của mô hình qua nhiều lần huấn luyện khác nhau. Đặc biệt, việc tạo ra năm mô hình huấn luyện khác nhau không chỉ quan trọng trong việc đánh giá độ tin cậy của mô hình mà còn tạo tiền đề quan trọng cho việc khai phá dấu ấn sinh học ổn định trong pha tiếp theo của nghiên cứu. Điều này đặc biệt quan trọng trong bối cảnh dữ liệu y sinh, nơi tính ổn định và độ tin cậy của mô hình là yếu tố then chốt.

Bước chọn 2000 đặc trưng sử dụng ANOVA F-value kết hợp FDR (p-value < 5e-2) là một quyết định cân bằng giữa việc giảm kích thước dữ liệu và bảo toàn thông tin sinh học có ý nghĩa. Phương pháp này được lựa chọn vì khả năng xác định các đặc trưng có sự khác biệt đáng kể giữa các nhóm, trong khi vẫn kiểm soát tỷ lệ phát hiện sai.

Việc lọc tương quan với ngưỡng 50% nhằm giảm thiểu sự dư thừa thông tin trong tập đặc trưng. Ngưỡng này được chọn dựa trên cân nhắc giữa việc loại bỏ thông tin dư thừa và việc bảo toàn các tương tác sinh học có thể quan trọng. Trong nhiều trường hợp, các gen có mức độ tương quan cao có thể thuộc cùng một con đường sinh học và việc

duy trì một số mức độ tương quan là cần thiết.

Quá trình chuẩn hóa dữ liệu bằng phương pháp Min-Max scaling được thực hiện một cách cẩn trọng theo từng fold. Đặc biệt quan trọng là việc áp dụng các thông số chuẩn hóa một cách nghiêm ngặt, trong đó các tham số chuẩn hóa chỉ được tính toán từ tập huấn luyện và sau đó áp dụng cho tập kiểm định và kiểm thử. Cách tiếp cận này ngăn chặn hiện tượng rò rỉ thông tin và đảm bảo tính khách quan trong đánh giá hiệu năng của mô hình.

c. Khác biệt so với nghiên cứu MOGONET

Mặc dù nghiên cứu này kế thừa một số phương pháp từ MOGONET, có nhiều điểm khác biệt quan trọng cần được làm rõ. Về quy trình tiền xử lý dữ liệu, do các tác giả của MOGONET không cung cấp mã nguồn cho phần này, nghiên cứu đã tự cài đặt lại toàn bộ quy trình dựa trên mô tả trong bài báo. Điều này có thể dẫn đến một số khác biệt nhỏ trong kết quả cuối cùng dù đã cố gắng tuân thủ chặt chẽ các bước và tham số được mô tả.

Một điểm khác biệt quan trọng là cách xử lý tập kiểm thử. MOGONET không chia giữ tập kiểm thử riêng, mà sử dụng tập kiểm thử trong quá trình huấn luyện, tối ưu tham số và tìm các dấu ấn sinh học. Phương pháp này có thể dẫn đến đánh giá thiên lệch và thiếu tính chuẩn xác. Trong nghiên cứu này, tập kiểm thử được tách biệt hoàn toàn ngay từ đầu và chỉ sử dụng trong đánh giá cuối cùng.

Nghiên cứu này đã áp dụng phương pháp Stratified K-fold một cách nghiêm ngặt, đảm bảo rằng mỗi fold được sử dụng đúng một lần làm tập kiểm định, trong khi MOGONET không đề cập rõ về quy trình phân chia dữ liệu được sử dụng. Hướng tiếp cận ở đây giúp duy trì tỷ lệ các kiểu phụ tương tự trong tập gốc. Điều này đặc biệt quan trọng trong bối cảnh dữ liệu mất cân bằng nặng. Nó giúp tránh tình trạng một số kiểu phụ hiếm có thể bị thiếu hoặc phân bố không đều giữa các phần. Việc chuẩn hóa dữ liệu cũng được thực hiện cẩn thận, chỉ áp dụng các tham số chuẩn hóa từ tập huấn luyện lên tập kiểm định và kiểm thử, điều này không được đề cập rõ ràng trong nghiên cứu MOGONET.

Những điều chỉnh này nhằm tăng cường tính khách quan và độ tin cậy của kết quả nghiên cứu, đồng thời đảm bảo tính phù hợp với bối cảnh cụ thể của các thí nghiệm này. Những thay đổi này sẽ giúp đánh giá chính xác hơn hiệu năng thực sự của mô hình và độ

tin cậy của các dấu ấn sinh học được phát hiện.

3.1.2. Chi tiết kiến trúc và môi trường tính toán

Phần này trình bày chi tiết về các lựa chọn kiến trúc và cấu hình môi trường tính toán được sử dụng trong nghiên cứu. MOGONET và DeepSSC là hai kiến trúc được lựa chọn thực nghiệm với một số điều chỉnh để phù hợp với dữ liệu đầu vào mới. Việc lựa chọn hai kiến trúc này dựa trên các nghiên cứu gần đây, trong đó MOGONET đã được chứng minh là phương pháp tiên tiến nhất cho việc tích hợp dữ liệu đa omics và đặc biệt hiệu quả với dữ liệu mất cân bằng trong lĩnh vực omics. DeepSSC cũng được lựa chọn do khả năng xử lý dữ liệu đa omics hiệu quả và có tiềm năng trong việc khai phá các đặc trưng phân biệt giữa các kiểu phụ khác nhau của bệnh, thậm chí trong một số trường hợp còn cho thấy hiệu năng vượt trội hơn so với MOGONET trên dữ liệu BRCA. Việc thử nghiệm song song trên hai kiến trúc này không chỉ nhằm cải thiện hiệu năng phân loại tổng thể, mà còn tạo cơ hội đánh giá ưu nhược điểm của từng phương pháp trong bối cảnh dữ liệu cụ thể của nghiên cứu.

a. Thiết lập kiến trúc và cấu hình huấn luyện

Việc lựa chọn và điều chỉnh kiến trúc MOGONET và DeepSSC được thực hiện dựa trên cân nhắc kỹ lưỡng về đặc điểm của dữ liệu và mục tiêu của nghiên cứu. Đặc biệt, các điều chỉnh này nhằm tối ưu hóa khả năng học từ dữ liệu đa omics không cân bằng, đồng thời duy trì khả năng giải thích của mô hình - một yêu cầu quan trọng trong ứng dụng y sinh.

Đối với DeepSSC, việc điều chỉnh số nơ-ron trong các lớp phản ánh cấu trúc của dữ liệu đầu vào. Kiến trúc encoder và decoder với cấu trúc 2000-1024-512-1024-2000 được thiết kế theo nguyên tắc "phễu", trong đó kích thước các lớp giảm dần về trung tâm và tăng dần ra ngoài. Cấu trúc này giúp mô hình học được các biểu diễn nén có tính tổng quát cao, đồng thời vẫn có khả năng tái tạo dữ liệu đầu vào một cách hiệu quả.

Lớp tích hợp 1024 nơ-ron (512+512) đóng vai trò quan trọng trong việc kết hợp thông tin từ hai nguồn dữ liệu omics. Kích thước này được chọn để đảm bảo không mất thông tin quan trọng từ mỗi nguồn dữ liệu, đồng thời cho phép mô hình học được các tương tác phức tạp giữa các đặc trưng.

Đối với MOGONET, mặc dù giữ nguyên kiến trúc gốc, việc bổ sung kỹ thuật early stopping với patience=200 là một cải tiến quan trọng. Early stopping được triển khai dựa trên việc theo dõi loss trên tập kiểm định, với patience 200 epoch được chọn để cân bằng giữa việc cho phép mô hình đủ thời gian học các pattern phức tạp và ngăn chặn hiện tượng overfit. Giá trị patience này được xác định thông qua thực nghiệm, cho thấy hiệu quả đặc biệt với dữ liệu không cân bằng, nơi quá trình hội tụ có thể chậm hơn do sự khan hiếm của các mẫu từ lớp thiểu số.

Số bước xấp xỉ cho giải thuật Integrated Gradient được thiết lập là 100. Đây là một thông số quan trọng ảnh hưởng trực tiếp đến độ chính xác của việc tính toán độ quan trọng của đặc trưng. Giá trị 100 được chọn dựa trên phân tích thử nghiệm, cho thấy đây là điểm cân bằng tốt giữa độ chính xác và chi phí tính toán. Các thử nghiệm với số bước cao hơn (200, 500) cho thấy sự cải thiện không đáng kể trong kết quả cuối cùng.

Quá trình tối ưu siêu tham số được thực hiện thông qua tìm kiếm lưới với các thông số chính bao gồm learning rate, batch size và số epoch. Các giá trị learning rate được chọn (0.001, 0.01, 0.1) dựa trên thực tiễn phổ biến trong học sâu, với 0.001 thường cho kết quả ổn định nhất. Batch size (32, 64, 128) được chọn với cân nhắc về kích thước bộ nhớ GPU và nhu cầu cập nhật gradient đủ thường xuyên để xử lý hiệu quả dữ liệu không cân bằng. Số epoch (100, 200, 300) được xác định để đảm bảo mô hình có đủ thời gian hội tụ, đặc biệt với các kiểu phụ hiếm.

b. Tài nguyên tính toán

Môi trường tính toán được xây dựng trên nền tảng Kaggle, cung cấp khả năng tính toán hiệu quả cho cả CPU và GPU. Việc lựa chọn Kaggle không chỉ vì khả năng tính toán mạnh mẽ mà còn vì tính reproducibility cao - một yếu tố quan trọng trong nghiên cứu khoa học. Nền tảng này cung cấp môi trường ổn định và nhất quán, giúp đảm bảo kết quả có thể được tái tạo bởi các nhà nghiên cứu khác.

Cấu hình phần cứng bao gồm CPU Intel(R) Xeon(R) @ 2.00GHz với 4 lõi và bộ nhớ RAM 32GB. Cấu hình CPU này, mặc dù không phải là mạnh nhất có sẵn, nhưng đủ để xử lý hiệu quả các tác vụ tiền xử lý dữ liệu và huấn luyện các mô hình học máy truyền thống. Bộ nhớ RAM 32GB được chọn để đảm bảo khả năng xử lý đồng thời nhiều mẫu dữ liệu đa omics có kích thước lớn.

GPU NVIDIA Tesla P100 với 16GB VRAM đóng vai trò quan trọng trong việc tăng tốc quá trình huấn luyện mô hình học sâu. Tesla P100, mặc dù không phải là GPU mới nhất, nhưng vẫn cung cấp hiệu năng tính toán song song mạnh mẽ với 3584 CUDA cores và băng thông bộ nhớ 732 GB/s. Dung lượng VRAM 16GB cho phép sử dụng batch size đủ lớn để huấn luyện hiệu quả các mô hình học sâu trên dữ liệu đa omics.

Về mặt phần mềm, nghiên cứu sử dụng Python 3.7.9 làm ngôn ngữ lập trình chính, kết hợp với các thư viện chuyên dụng. PyTorch được chọn làm framework chính cho việc xây dựng và huấn luyện các mô hình học sâu. PyTorch được lựa chọn vì tính linh hoạt và khả năng debug tốt, đặc biệt quan trọng trong việc triển khai các kiến trúc mạng phức tạp như MOGONET và DeepSSC. Đồ thị tính toán động của PyTorch cũng tạo thuận lợi cho việc thực hiện các phân tích giải thích mô hình như Integrated Gradient.

Scikit-learn được sử dụng cho việc triển khai các mô hình học máy truyền thống và các công cụ tiền xử lý dữ liệu. Thư viện này cung cấp các implementation chuẩn hóa và được tối ưu hóa cho nhiều thuật toán học máy, đảm bảo tính ổn định và hiệu quả trong quá trình thực nghiệm. Các công cụ tiền xử lý của Scikit-learn, như StandardScaler và StratifiedKFold, được sử dụng để đảm bảo tính nhất quán trong quá trình xử lý dữ liệu.

Captum, một thư viện chuyên dụng cho việc giải thích mô hình học sâu, đóng vai trò quan trọng trong việc triển khai giải thuật Integrated Gradient. Thư viện này cung cấp các cài đặt hiệu quả và được tối ưu hóa cho GPU của nhiều phương pháp giải thích mô hình. Đặc biệt, việc tích hợp chặt chẽ với PyTorch giúp đơn giản hóa quá trình phân tích các mô hình phức tạp như trong nghiên cứu này.

3.2. Kết quả và phân tích

Phần này trình bày và phân tích các kết quả thu được từ ba pha của nghiên cứu. Dựa trên thiết kế thí nghiệm đã trình bày, các kết quả được phân tích từ nhiều góc độ khác nhau bao gồm quá trình huấn luyện mô hình phân loại, khai phá dấu ấn sinh học, và đánh giá tổng thể. Việc đánh giá được thực hiện một cách toàn diện, không chỉ dừng lại ở hiệu năng phân loại mà còn đi sâu vào việc phân tích ý nghĩa sinh học của các dấu ấn được phát hiện.

3.2.1. Kết quả huấn luyện phân loại trong Pha 1

Pha 1 của nghiên cứu tập trung vào việc lựa chọn, xây dựng và huấn luyện mô hình học sâu có khả năng phân loại hiệu quả các kiểu phụ của bệnh ung thư. Mục tiêu này nhằm tạo nền tảng vững chắc cho các bước tiếp theo của nghiên cứu. Cụ thể, bài toán được chọn là phân loại năm kiểu phụ của bệnh ung thư vú, sử dụng dữ liệu tích hợp đa omics gồm biểu hiện gen (GE) và biến đổi số lượng bản sao (CNA). Hai kiến trúc mạng nơ-ron được lựa chọn để thử nghiệm là MOGONET và DeepSSC. Kết quả thu được trên các tập kiểm định ứng với 5 lần thực hiện chia fold được tổng hợp trong Bảng 3.2 dưới đây:

Bảng 3.2: Kết quả huấn luyện đánh giá trên tập kiểm định

Kiến trúc	Fold	Accuracy	F1-weighted	F1-macro
MOGONET	1	87.79%	86.14%	68.59%
	2	82.44%	80.70%	63.13%
	3	87.02%	85.45%	68.40%
	4	84.73%	82.94%	64.85%
	5	84.73%	83.55%	66.14%
DeepSSC	1	89.31%	89.31%	86.99%
	2	85.50%	85.92%	84.42%
	3	87.02%	87.18%	84.37%
	4	90.08%	90.12%	87.80%
	5	91.60%	91.76%	91.32%

Đặc điểm quan trọng của bài toán này là tính chất đa lớp và sự mất cân bằng đáng kể giữa các lớp kiểu phụ trong dữ liệu. Những thách thức này không chỉ tạo ra khó khăn mà còn cung cấp cơ hội để đánh giá một cách toàn diện và khách quan hơn về tiềm năng ứng dụng thực tế của các phương pháp được đề xuất trong nghiên cứu.

Kết quả thí nghiệm cho thấy cả hai kiến trúc đều thể hiện khả năng phân loại khá tốt, tuy nhiên DeepSSC nổi bật với hiệu năng vượt trội trên tất cả các chỉ số đánh giá. Về Accuracy, DeepSSC đạt trung bình 88.70% (dao động 85.50%-91.60%), cao hơn MOGONET với 85.34% (dao động 82.44%-87.79%). Sự chênh lệch 3.36% này phản ánh khả năng phân loại tổng thể tốt hơn của DeepSSC. Sự khác biệt trở nên rõ

ràng hơn ở F1-weighted, với DeepSSC đạt 88.86% (dao động 85.92%-91.76%) so với MOGONET 83.76% (dao động 80.70%-86.14%). Khoảng cách 5.10% này phản ánh khả năng cân bằng giữa độ chính xác và độ bao phủ tốt hơn của DeepSSC, đặc biệt khi xét đến tỷ lệ các lớp trong dữ liệu. Đáng chú ý nhất là sự khác biệt ở F1-macro: DeepSSC đạt 86.98% (dao động 84.37%-91.32%), vượt xa MOGONET với 66.22% (dao động 63.13%-68.59%). Khoảng cách 20.76% này cho thấy DeepSSC xử lý tốt hơn đáng kể với các lớp không cân bằng, một đặc điểm quan trọng trong dữ liệu y sinh học.

Về tính ổn định của mô hình qua các fold, DeepSSC cũng thể hiện ưu thế vượt trội. Độ lệch chuẩn của F1-macro trên DeepSSC là 2.86%, nhỏ hơn đáng kể so với MOGONET (3.52%). Điều này không chỉ phản ánh khả năng tổng quát hóa tốt hơn của DeepSSC trên các tập dữ liệu khác nhau mà còn gợi ý về tính tin cậy cao hơn của mô hình trong việc dự đoán trên các mẫu mới.

Nhìn chung, cả hai mô hình đều cho kết quả khả quan, nhưng DeepSSC đã thể hiện được nhiều ưu điểm vượt trội. Không chỉ đạt được hiệu năng cao hơn trên tất cả các chỉ số, DeepSSC còn cho thấy tính ổn định tốt hơn qua các fold khác nhau. Điều này đặc biệt quan trọng trong bối cảnh dữ liệu y sinh, nơi tính ổn định và độ tin cậy của mô hình là yếu tố then chốt.

3.2.2. Chất lượng các dấu ấn sinh học được khai phá

a. Phân tích hiệu năng tổng quan

Để đánh giá chất lượng của các dấu ấn sinh học được khai phá, nghiên cứu tiến hành phân tích hiệu năng phân loại khi sử dụng chúng làm đặc trưng đầu vào cho các thuật toán học máy truyền thống. Hình 3.1 thể hiện kết quả so sánh hiệu năng của ba mô hình - Logistic Regression, SVM và Random Forest - trên tập kiểm thử với các dấu ấn sinh học được khai phá từ DeepSSC và MOGONET thông qua giải thuật dựa trên Integrated Gradient.

Kết quả được biểu diễn qua ba chỉ số: Accuracy (Hình 3.1a), F1-weighted (Hình 3.1b), và F1-macro (Hình 3.1c). Mỗi biểu đồ được chia thành hai phần, tương ứng với kết quả từ DeepSSC (bên trái) và MOGONET (bên phải). Trục x thể hiện số lượng đặc trưng hàng đầu được sử dụng (từ tốp 100 đến 300), trong khi trục y biểu thị giá trị của chỉ số tương ứng. Đặc biệt, mỗi điểm dữ liệu trên đồ thị là giá trị trung bình của bảy

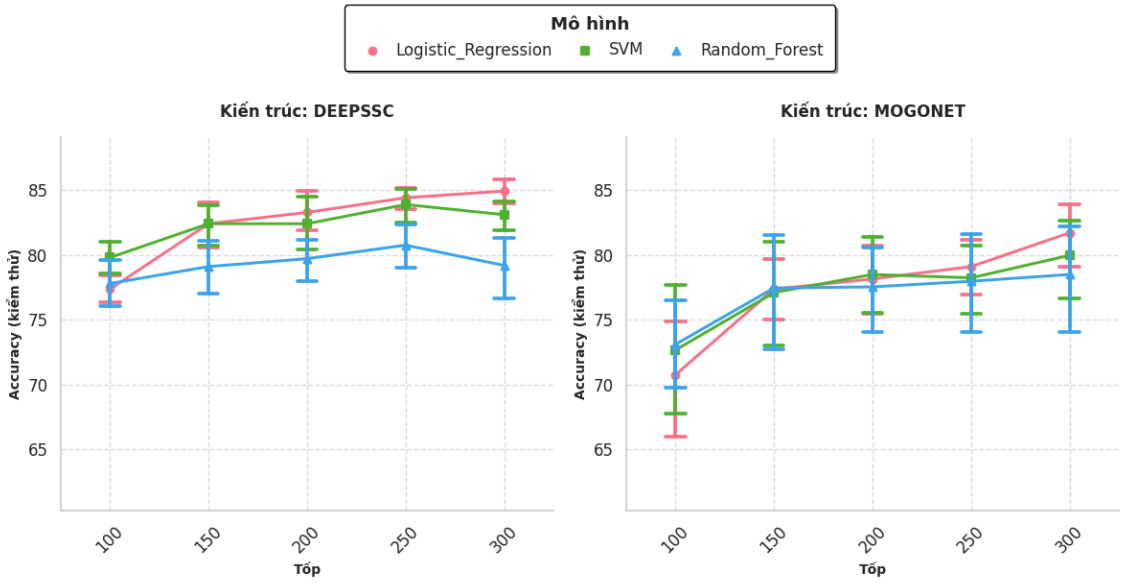

(a) Accuracy

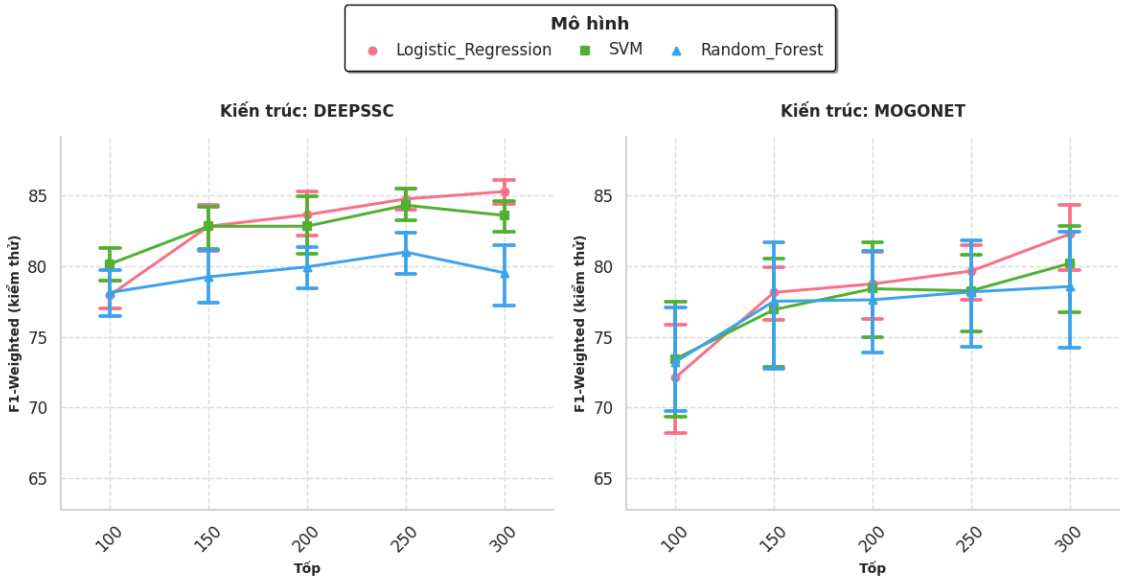

(b) F1-weighted

Hình 3.1: So sánh hiệu năng của ba mô hình - Logistic Regression, SVM và Random Forest - trên tập kiểm thử với các dấu ấn sinh học được khai phá từ DeepSSC và MOGONET thông qua giải thuật dựa trên Integrated Gradient

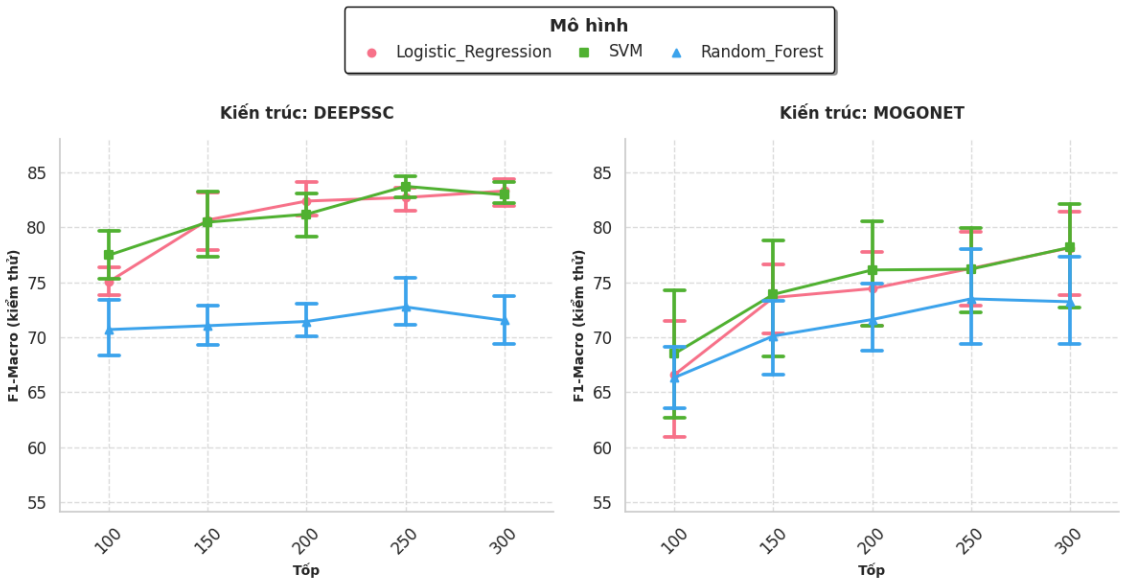

(c) F1-macro

Hình 3.1: So sánh hiệu năng của ba mô hình - Logistic Regression, SVM và Random Forest - trên tập kiểm thử với các dấu ấn sinh học được khai phá từ DeepSSC và MOGONET thông qua giải thuật dựa trên Integrated Gradient (tiếp theo)

baseline khác nhau, với thanh lỗi thể hiện khoảng tin cậy 95%.

Qua các biểu đồ này, có thể quan sát thấy nhiều xu hướng quan trọng về hiệu năng và đặc điểm của hai kiến trúc. Về xu hướng cải thiện hiệu năng, cả MOGONET và DeepSSC đều thể hiện sự tiến bộ rõ rệt khi tăng số lượng đặc trưng từ tốp 100 đến 300. Tuy nhiên, DeepSSC nổi bật với khả năng cải thiện ổn định hơn, thể hiện qua các đường cong mượt mà và thanh sai số nhỏ hơn, cho thấy tính nhất quán trong việc học và trích xuất các đặc trưng quan trọng. Xét về hiệu năng của các mô hình phân loại, cả SVM và Logistic Regression đều thể hiện khả năng vượt trội so với Random Forest, đặc biệt khi làm việc với các dấu ấn sinh học được khai phá từ kiến trúc DeepSSC. Điều này gợi ý một đặc tính quan trọng của các dấu ấn sinh học được tìm thấy - khả năng phân biệt tuyến tính hiệu quả giữa các kiểu phụ của bệnh. Đây là một phát hiện có ý nghĩa thực tiễn quan trọng, vì nó cho thấy tiềm năng sử dụng các mô hình đơn giản, dễ triển khai trong thực tế lâm sàng. Khi so sánh giữa hai kiến trúc, DeepSSC thể hiện ưu thế vượt trội với hiệu năng cao hơn và ổn định hơn trên tất cả các chỉ số đánh giá. Đặc biệt ấn tượng là việc các dấu ấn sinh học được khai phá từ DeepSSC giúp các mô hình phân loại đạt hiệu năng trên 80% ở chỉ số F1-macro ngay từ tốp 150 đặc trưng. Thành tích này không

chỉ khẳng định chất lượng của các dấu ấn sinh học được khai phá mà còn cho thấy khả năng rút gọn số lượng đặc trưng cần thiết cho việc phân loại hiệu quả.

Đáng chú ý, khi so sánh với hiệu năng của các mô hình gốc, các dấu ấn sinh học được khai phá cho thấy khả năng giữ được, thậm chí cải thiện hiệu năng phân loại. Cụ thể, trong khi MOGONET gốc đạt 75% (Accuracy), 73% (F1-weighted), và 56% (F1-macro) trên tập kiểm thử, các mô hình SVM sử dụng tốp 150 đặc trưng đã đạt được 77%, 75%, và 73% tương ứng. Tương tự, với DeepSSC, mặc dù mô hình gốc đã đạt hiệu năng tốt (79%, 80%, 81%), các mô hình đơn giản sử dụng dấu ấn sinh học vẫn có thể duy trì mức hiệu năng tương đương hoặc thậm chí cao hơn.

b. So sánh hiệu năng của các baseline

Phân tích chi tiết về hiệu năng của các baseline khác nhau được thể hiện qua Hình 3.2 và 3.3, tập trung vào chỉ số F1-macro - chỉ số quan trọng nhất trong bối cảnh dữ liệu không cân bằng. Cả hai hình đều biểu diễn hiệu năng của các mô hình học máy truyền thống (Logistic Regression và SVM) trên các đặc trưng được chọn bởi các baseline khác nhau.

Biểu đồ trong Hình 3.2 thể hiện hiệu năng của các mô hình trên tập dấu ấn sinh học được chọn bởi các phương pháp khác nhau. Trục x biểu thị số lượng đặc trưng hàng đầu (từ 100 đến 300), trục y thể hiện giá trị F1-macro trên tập kiểm thử. Mỗi đường biểu diễn một cách tiếp cận với bảy baseline khác nhau cho phương pháp Integrated Gradient đề xuất, cùng với đường biểu diễn cho phương pháp Ablation gốc của MOGONET (được làm nổi bật). Biểu đồ cho phép đánh giá trực quan hiệu năng và độ ổn định của các baseline, đồng thời so sánh với phương pháp Ablation gốc.

Tương tự các biểu đồ trong Hình 3.3 so sánh hiệu năng của các phương pháp khai phá dấu ấn sinh học trên kiến trúc DeepSSC sử dụng thang đo F1-macro với bộ phân loại Logistic Regression và với bộ phân loại SVM. Biểu đồ thể hiện hiệu năng của các mô hình trên tập dấu ấn sinh học được chọn bởi phương pháp Integrated Gradient với bảy baseline khác nhau. Trục x biểu thị số lượng đặc trưng hàng đầu (từ 100 đến 300), trục y thể hiện giá trị F1-macro trên tập kiểm thử. Các đường biểu diễn cho phép so sánh trực quan hiệu năng và độ ổn định của các baseline khác nhau khi áp dụng trên kiến trúc DeepSSC.

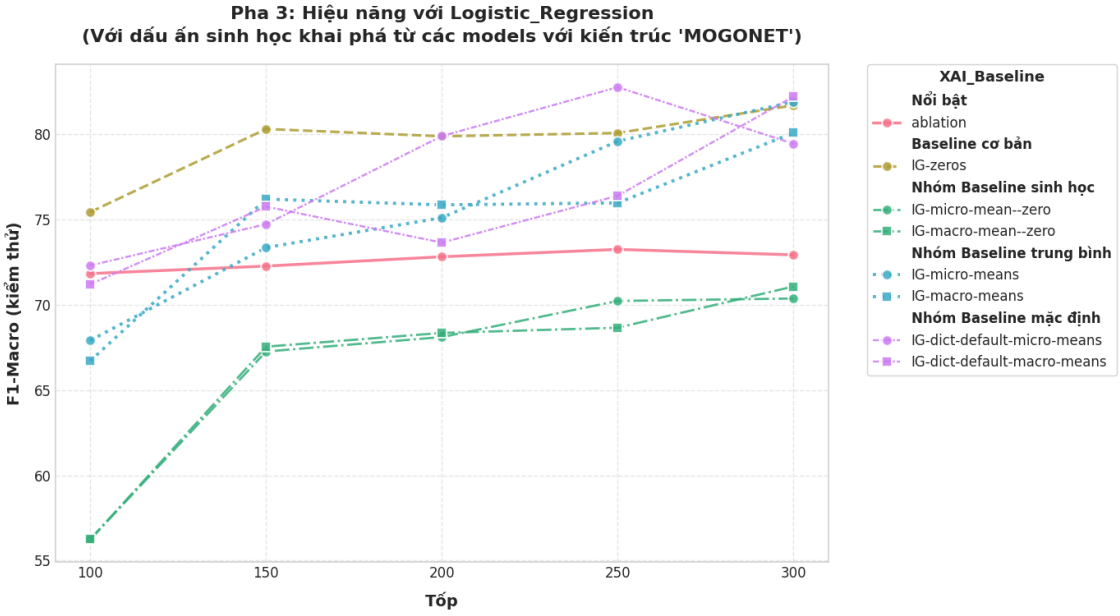

(a) Kết quả với bộ phân loại Logistic Regression

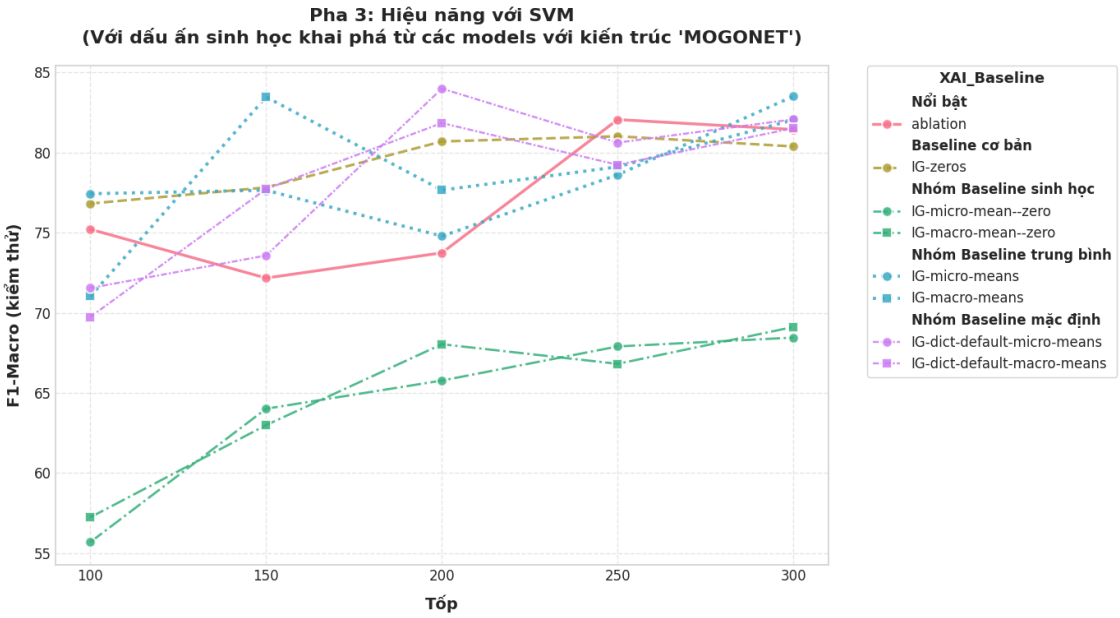

(b) Kết quả với bộ phân loại SVM

Hình 3.2: So sánh hiệu năng của các phương pháp khai phá dấu ấn sinh học trên kiến trúc MOGONET sử dụng thang đo F1-macro

Trên kiến trúc MOGONET (Hình 3.2), baseline "IG-zeros" và nhóm "dict-default" cho thấy hiệu năng ổn định và cao nhất. Cụ thể, "IG-zeros" đạt hiệu năng từ 75% ở tốp

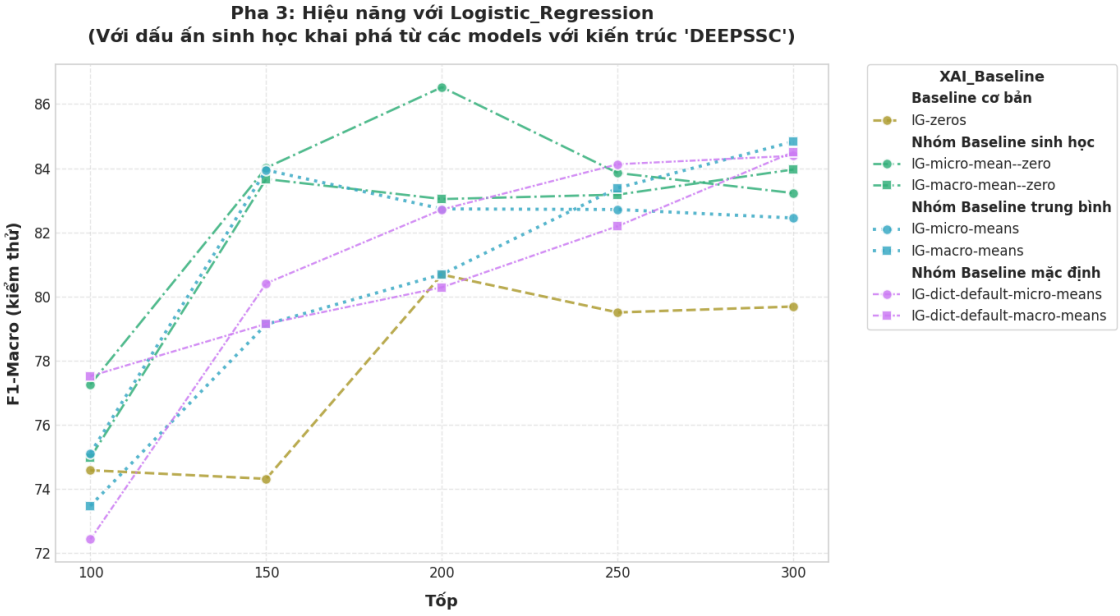

(a) Kết quả với bộ phân loại Logistic Regression

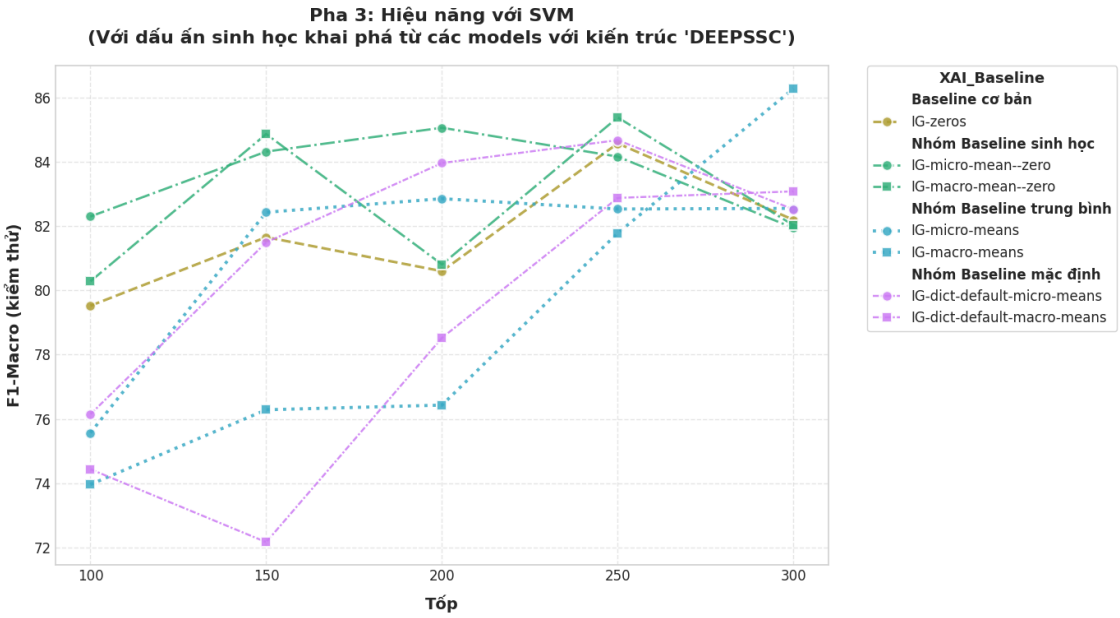

(b) Kết quả với bộ phân loại SVM

Hình 3.3: So sánh hiệu năng của các phương pháp khai phá dấu ấn sinh học trên kiến trúc DeepSSC sử dụng thang đo F1-macro

100 lên 81% ở tốp 300 với Logistic Regression. Đối với SVM, mặc dù có sự dao động nhẹ, baseline này vẫn duy trì hiệu năng cao, dao động từ 77% đến 81%. Nhóm "dict-

default" (bao gồm "IG-dict-default-micro-means" và "IG-dict-default-macro-means") cho kết quả tương đương hoặc đôi khi vượt trội so với "IG-zeros". Đặc biệt với SVM, "IG-dict-default-micro-means" đạt đỉnh 84% ở tốp 200, trong khi "IG-dict-default-macro-means" tăng đều đến 81% ở tốp 300.

Đáng ngạc nhiên, nhóm baseline sinh học ("IG-micro-mean-zero" và "IG-macro-mean-zero") lại cho hiệu năng thấp nhất trên MOGONET, chỉ dao động từ 56% ở tốp 100 đến 70% ở tốp 300. Tuy nhiên, sự cải thiện đáng kể khi tăng số lượng đặc trưng cho thấy các baseline này vẫn có tiềm năng, đặc biệt khi làm việc với số lượng đặc trưng lớn. Ngược lại, trên kiến trúc DeepSSC (Hình 3.3), nhóm baseline sinh học lại cho hiệu năng cao nhất, trái ngược với kết quả trên MOGONET. Với Logistic Regression, chúng đạt 84-86% ở tốp 200-300, trong khi với SVM, hiệu năng dao động từ 82% đến 85%. Trong khi đó, "IG-zeros" và nhóm "dict-default" mặc dù vẫn duy trì hiệu năng tốt nhưng không còn là những lựa chọn tối ưu nhất cho DeepSSC.

So sánh với phương pháp Ablation gốc của MOGONET, nhiều baseline dựa trên Integrated Gradient cho hiệu năng cao hơn, đặc biệt ở các giá trị tốp cao. Điều này khẳng định tiềm năng của phương pháp được đề xuất trong việc khai phá dấu ấn sinh học có giá trị. Một điểm quan trọng đáng lưu ý là mức độ ổn định của hiệu năng giữa các baseline. DeepSSC thể hiện độ ổn định vượt trội với độ dao động nhỏ giữa các baseline, đặc biệt từ tốp 200 trở lên. Điều này được thể hiện rõ qua các đường biểu diễn hiệu năng gần nhau hơn và ít giao nhau hơn so với MOGONET. Khoảng chênh lệch hiệu năng giữa các baseline trên DeepSSC thu hẹp đáng kể khi tăng số lượng đặc trưng, trong khi MOGONET vẫn duy trì sự phân hóa rõ rệt giữa các nhóm baseline.

Sự khác biệt rõ ràng này trong hiệu năng của các baseline trên hai kiến trúc khác nhau là một phát hiện thực nghiệm quan trọng, phản ánh mối quan hệ phức tạp giữa việc lựa chọn baseline và kiến trúc mạng trong bài toán khai phá dấu ấn sinh học. Mặc dù cần có thêm nghiên cứu để hiểu rõ nguyên nhân sâu xa của sự khác biệt này, việc các baseline sinh học hoạt động hiệu quả trên DeepSSC có thể gợi ý rằng kiến trúc này đã học được các đặc trưng có liên quan chặt chẽ hơn với các cơ chế sinh học của dữ liệu. Tuy nhiên, do tính chất phức tạp của các mô hình học sâu, việc xác định chính xác các đặc trưng này đã được học như thế nào vẫn là một bài toán mở. Dù vậy, với khả năng duy trì hiệu năng ổn định giữa các baseline khác nhau, DeepSSC thể hiện là một lựa chọn đáng tin cậy cho việc khai phá dấu ấn sinh học trong bối cảnh dữ liệu không cân bằng.

c. So sánh với "tiêu chuẩn vàng" và phân tích chi tiết dấu ấn sinh học

Để đánh giá giá trị sinh học của các dấu ấn được phát hiện, nghiên cứu tiến hành so sánh kết quả với nguồn dữ liệu CTD. Phân tích này nhằm xác định mức độ trùng khớp giữa các dấu ấn sinh học được phát hiện và kiến thức hiện có về mối liên hệ gen-bệnh trong ung thư vú, đồng thời đánh giá tiềm năng của các phương pháp trong việc khám phá các dấu ấn sinh học mới.

Top	mogonet								deepssc						
	ablation	IG_zeros	IG_dict_default_micro_means	IG_dict_default_macro_means	IG_micro_means	IG_macro_means	IG_micro_mean_zero	IG_macro_mean_zero	IG_zeros	IG_dict_default_micro_means	IG_dict_default_macro_means	IG_micro_means	IG_macro_means	IG_micro_mean_zero	IG_macro_mean_zero
100	2	0	2	2	2	2	0	0	1	3	2	3	2	2	2
150	4	3	3	3	3	3	1	1	1	4	4	4	4	4	3
200	5	3	3	4	3	3	1	1	3	6	6	6	6	6	7
250	7	5	5	5	5	4	2	2	3	9	9	9	9	9	9
300	8	6	6	5	5	5	6	6	4	11	10	11	10	10	9

Hình 3.4: Số lượng các dấu ấn sinh học trùng khớp với CTD theo các tốp

Hình 3.4 trình bày số lượng các dấu ấn sinh học trùng khớp với CTD ở các ngưỡng tốp khác nhau cho các cách tiếp cận và sử dụng baseline khác nhau với hai kiến trúc MOGONET và DeepSSC. Kết quả cho thấy cả hai đều có khả năng xác định được một số dấu ấn sinh học trùng khớp với CTD. Trong đó, DeepSSC có xu hướng xác định được nhiều dấu ấn hơn, đặc biệt ở các ngưỡng tốp cao hơn. Điều này gợi ý về khả năng của DeepSSC trong việc nắm bắt các đặc trưng liên quan đến các dấu ấn sinh học đã được biết đến trong ung thư vú.

Hình 3.5 liệt kê chi tiết các gen cụ thể được xác định bởi mỗi cách tiếp cận ở các ngưỡng tốp khác nhau. Phân tích này cho thấy một số gen xuất hiện thường xuyên trong nhiều phương pháp và ngưỡng khác nhau, bao gồm FABP7, GRB7, CXCL3, và PDZK1. Sự nhất quán này giữa các phương pháp khác nhau gợi ý về tầm quan trọng tiềm năng của chúng trong việc phân biệt các kiểu phụ của ung thư vú.

Đáng chú ý, một số gen đã biết đến trong bệnh học ung thư vú cũng được xác định, đặc biệt ở các ngưỡng tốp cao hơn:

- ERBB2 (HER2): Gen này đóng vai trò then chốt trong việc định nghĩa và điều trị kiểu phụ HER2-positive. Sự xuất hiện của nó trong kết quả không chỉ xác thực độ tin cậy của phương pháp mà còn phản ánh khả năng phát hiện các gen có ý nghĩa lâm sàng quan trọng.

- SERPINB5: Một gen ức chế khối u được biết đến trong ung thư vú, xuất hiện trong

Top	mogonet								deepssc						
	ablation	IG_zeros	IG_dict_default_micro_means	IG_dict_default_macro_means	IG_micro_means	IG_macro_means	IG_micro_mean_zero	IG_macro_mean_zero	IG_zeros	IG_dict_default_micro_means	IG_dict_default_macro_means	IG_micro_means	IG_macro_means	IG_micro_mean_zero	IG_macro_mean_zero
100	FABP7, CXCL3		FABP7, CXCL3	FABP7, CXCL3	FABP7, CXCL3	FABP7, CXCL3			EXO1	FABP7, PDZK1, CXCL3	FABP7, CXCL3	FABP7, PDZK1, CXCL3	FABP7, CXCL3	FABP7, CXCL3	FABP7, CXCL3
150	FABP7, GRB7, CXCL3, CHEK2	FABP7, GRB7, CXCL3	FABP7, GRB7, CXCL3	FABP7, GRB7, CXCL3	FABP7, GRB7, CXCL3	FABP7, GRB7, CXCL3	GRB7	GRB7	EXO1	GRB7, FABP7, PDZK1, CXCL3	GRB7, FABP7, PDZK1, CXCL3	GRB7, FABP7, PDZK1, CXCL3	GRB7, FABP7, PDZK1, CXCL3	GRB7, FABP7, PDZK1, CXCL3	FABP7, GRB7, CXCL3
200	GRB7, CXCL3, FABP7, KCNH1, CHEK2	FABP7, GRB7, CXCL3	FABP7, GRB7, CXCL3	SERPINB5, GRB7, CXCL3, FABP7	FABP7, GRB7, CXCL3	FABP7, GRB7, CXCL3	GRB7	GRB7	XRCC2, EXO1, SLC39A6	GRB7, CXCL3, KLK10, SLC28A1, FABP7, PDZK1	GRB7, CXCL3, KLK10, SLC28A1, FABP7, PDZK1	GRB7, CXCL3, KLK10, SLC28A1, FABP7, PDZK1	GRB7, CXCL3, KLK10, SLC28A1, FABP7, PDZK1	GRB7, CXCL3, KLK10, ATG10, FABP7, PDZK1	GRB7, CXCL3, KLK10, SLC28A1, ATG10, FABP7, PDZK1
250	HEYL, GRB7, CXCL3, FABP7, ERBB2, KCNH1, CHEK2	GRB7, CXCL3, SERPINB5, FABP7, ERBB2	GRB7, CXCL3, FABP7, ERBB2, PDZK1	GRB7, CXCL3, SERPINB5, FABP7, ERBB2	GRB7, CXCL3, FABP7, ERBB2, PDZK1	FABP7, GRB7, CXCL3, ERBB2	GRB7, ERBB2	GRB7, ERBB2	XRCC2, EXO1, SLC39A6	GRB7, CXCL3, KLK10, SLC28A1, SERPINB5, FABP7, CRHR1, ERBB2, PDZK1	GRB7, CXCL3, KLK10, SLC28A1, SERPINB5, FABP7, CRHR1, ERBB2, PDZK1	GRB7, CXCL3, KLK10, SLC28A1, SERPINB5, FABP7, CRHR1, ERBB2, PDZK1	GRB7, CXCL3, KLK10, SLC28A1, SERPINB5, FABP7, CRHR1, ERBB2, PDZK1	GRB7, CXCL3, KLK10, SLC28A1, ATG10, FABP7, CRHR1, ERBB2, PDZK1	GRB7, CXCL3, KLK10, SLC28A1, ATG10, FABP7, CRHR1, ERBB2, PDZK1
300	HEYL, GRB7, CXCL3, RMND1, FABP7, ERBB2, KCNH1, CHEK2	GRB7, CXCL3, SERPINB5, TBX3, FABP7, ERBB2	GRB7, CXCL3, SERPINB5, FABP7, ERBB2, PDZK1	GRB7, CXCL3, SERPINB5, FABP7, ERBB2	GRB7, CXCL3, FABP7, ERBB2, PDZK1	GRB7, CXCL3, SERPINB5, FABP7, ERBB2	UBLCP1, GRB7, ATP6AP1L, ATG10, ERBB2, MRPL13	UBLCP1, GRB7, ATP6AP1L, ATG10, ERBB2, MRPL13	XRCC2, EXO1, SLC39A6, LDHB	GRB7, CXCL3, SLC39A6, KLK10, SLC28A1, SERPINB5, DSC3, FABP7, CRHR1, ERBB2, PDZK1	GRB7, CXCL3, SLC39A6, KLK10, SLC28A1, SERPINB5, FABP7, CRHR1, ERBB2, PDZK1	GRB7, CXCL3, SLC39A6, KLK10, SLC28A1, SERPINB5, DSC3, FABP7, CRHR1, ERBB2, PDZK1	GRB7, CXCL3, SLC39A6, KLK10, SLC28A1, SERPINB5, FABP7, CRHR1, ERBB2, PDZK1	GRB7, CXCL3, KLK10, SLC28A1, SERPINB5, ATG10, FABP7, CRHR1, ERBB2, PDZK1	GRB7, CXCL3, KLK10, SLC28A1, ATG10, FABP7, CRHR1, ERBB2, PDZK1

Hình 3.5: Liệt kê chi tiết các gen trùng lặp theo các tốp

nhiều kết quả phân tích. Gen này đóng vai trò quan trọng trong quá trình di căn và tiến triển của khối u.

- KLK10: Xuất hiện trong nhiều kết quả từ DeepSSC, gen này thuộc họ kallilerin và đã được báo cáo có liên quan đến tiên lượng ung thư vú. Sự hiện diện của nó trong kết quả càng củng cố giá trị của phương pháp được đề xuất.

Ngoài các gen đã biết, nghiên cứu cũng phát hiện một số gen tiềm năng mới như ATG10, UBLCP1, và MRPL13 ở các ngưỡng tốp cao hơn. Sự đa dạng của các loại gen được xác định, bao gồm các gen liên quan đến nhiều quá trình sinh học khác nhau như tín hiệu tế bào (GRB7), chuyển hóa lipid (FABP7), và đáp ứng miễn dịch (CXCL3), phản ánh tính phức tạp của bệnh ung thư vú và khả năng của các phương pháp XAI trong việc nắm bắt các khía cạnh đa dạng của bệnh lý này.

Sự khác biệt giữa các dấu ấn sinh học được xác định và CTD không nên được coi là điểm hạn chế của phương pháp. CTD tổng hợp thông tin từ nhiều nguồn tương tác khác nhau và xếp hạng dựa trên Inference Score, trong khi các phương pháp XAI trong nghiên cứu này tập trung vào việc phân biệt các kiểu phụ ung thư vú. Cụ thể, CTD đánh giá mối liên hệ gen-bệnh dựa trên các nghiên cứu đã công bố về ung thư vú nói chung, không phân biệt vai trò của gen trong việc phân loại các kiểu phụ. Trong khi đó, phương

pháp của nghiên cứu này đặc biệt nhắm vào việc tìm ra các gen có khả năng phân biệt giữa các kiểu phụ khác nhau của bệnh. Điều này có thể giải thích vì sao một số gen được phát hiện có khả năng phân loại tốt trong nghiên cứu của chúng tôi nhưng chưa được ghi nhận nhiều trong CTD - chúng có thể đóng vai trò đặc hiệu trong việc phân biệt các kiểu phụ mà không nhất thiết liên quan mạnh đến cơ chế gây bệnh tổng thể. Ngược lại, một số gen có điểm số cao trong CTD có thể không xuất hiện trong kết quả của chúng tôi vì chúng ảnh hưởng chung đến tất cả các kiểu phụ của bệnh.

3.2.3. Tổng kết

Kết quả thực nghiệm đã cho thấy hiệu quả của phương pháp đề xuất trong việc khai phá dấu ấn sinh học từ dữ liệu đa omics không cân bằng. DeepSSC thể hiện hiệu năng vượt trội với F1-macro đạt 86.98%, cao hơn 20.76% so với MOGONET, đồng thời duy trì độ ổn định tốt hơn với độ lệch chuẩn chỉ 2.86%.

Trong quá trình khai phá dấu ấn sinh học, các baseline dựa trên Integrated Gradient cho hiệu năng cao hơn phương pháp ablation truyền thống, với sự khác biệt đáng chú ý giữa hai kiến trúc: baseline "$zeros$" và "$dict\text{-}default$" hiệu quả nhất trên MOGONET, trong khi baseline sinh học hoạt động tốt nhất trên DeepSSC. Đặc biệt, các dấu ấn sinh học được khai phá thể hiện giá trị cả về mặt tính toán và sinh học, được minh chứng qua hiệu năng cao của các mô hình đơn giản và sự trùng khớp đáng kể với cơ sở dữ liệu CTD. Chi tiết về ý nghĩa của các kết quả này, cũng như mối quan hệ giữa kiến trúc mạng và phương pháp giải thích mô hình sẽ được thảo luận sâu hơn trong Chương 4.

Chương 4

Kết luận và thảo luận

Chương này tổng kết và thảo luận về các kết quả đạt được của nghiên cứu trong việc phát triển khung chương trình phân tích dữ liệu đa omics và khai phá dấu ấn sinh học ung thư vú. Bên cạnh việc đánh giá hiệu quả của các phương pháp đề xuất, chương cũng phân tích, thảo luận mối quan hệ giữa kiến trúc mạng và phương pháp giải thích mô hình, thảo luận về ý nghĩa sinh học của các kết quả, đồng thời chỉ ra những hạn chế hiện tại và đề xuất các hướng phát triển tiềm năng trong tương lai.

4.1. Kết luận

Nghiên cứu này đã phát triển và đánh giá một khung chương trình toàn diện cho việc phân loại kiểu phụ ung thư vú và khai phá các dấu ấn sinh học quan trọng từ dữ liệu đa omics. Thông qua việc kết hợp và cải tiến các phương pháp từ MOGONET và DeepSSC, một cách tiếp cận mới, hiệu quả hơn trong việc phân tích dữ liệu omics phức tạp và không cân bằng đã được đề xuất.

Kết quả cho thấy kiến trúc DeepSSC vượt trội hơn đáng kể so với MOGONET trong việc phân loại các kiểu phụ ung thư vú, đặc biệt trong xử lý dữ liệu không cân bằng với F1-macro đạt 86.98%. Các baseline dựa trên Integrated Gradient đã chứng tỏ hiệu quả trong việc khai phá dấu ấn sinh học, với sự trùng khớp đáng kể với cơ sở dữ liệu CTD và khả năng phát hiện các gen tiềm năng mới. Những kết quả này không chỉ đóng góp vào sự phát triển của lĩnh vực tin sinh học mà còn mở ra triển vọng ứng dụng trong y học chính xác và điều trị cá nhân hóa. Song song với luận văn này, tôi cũng

đã công bố một nghiên cứu liên quan với chủ đề "Multi-omics biomarker discovery with explainable artificial intelligence: A case study in Glioblastoma" tại Hội nghị quốc tế lần thứ 16 về Kỹ thuật Tri thức và Hệ thống (IEEE International Conference on Knowledge and Systems Engineering - KSE 2024). Việc áp dụng thành công cùng một hướng tiếp cận trong nghiên cứu về bệnh u não ác tính (Glioblastoma) càng khẳng định tính khả thi và tiềm năng ứng dụng rộng rãi của phương pháp được đề xuất trong luận văn này cho các bài toán khai phá dấu ấn sinh học từ dữ liệu đa omics. Bên cạnh đó, một công bố gần đây mà tôi có tham gia về chủ đề liên quan là "Application of the SFE Feature Selection Method for Multi-Omic Biomarkers Discovery in Brain Cancer Subtyping" cũng đã được công bố ở hội nghị SOICT 2024.

4.2. Thảo luận về kết quả chính

4.2.1. Mối quan hệ giữa kiến trúc mạng và phương pháp giải thích mô hình

Một phát hiện đáng chú ý từ quá trình nghiên cứu là mối quan hệ phức tạp giữa kiến trúc mạng và hiệu quả của các phương pháp giải thích mô hình. Sự khác biệt về hiệu năng của các baseline trên hai kiến trúc MOGONET và DeepSSC đặt ra những câu hỏi sâu sắc về cách các kiến trúc khác nhau tổ chức và xử lý thông tin từ dữ liệu đa omics.

Trên kiến trúc MOGONET, các baseline đơn giản như "*zeros*" và "*dict-default*" cho hiệu năng tốt nhất, trong khi trên DeepSSC, các baseline sinh học lại thể hiện ưu thế vượt trội. Sự tương phản này có thể phản ánh cách thức học và tổ chức thông tin khác nhau của hai kiến trúc. DeepSSC, với cấu trúc encoder-decoder đối xứng, có thể đang học được các biểu diễn gần với bản chất sinh học của dữ liệu hơn. Trong khi đó, MOGONET có thể đang tạo ra các biểu diễn trừu tượng hơn, phù hợp với các baseline có tính tổng quát cao.

Đặc biệt, độ ổn định cao của DeepSSC giữa các baseline khác nhau là một phát hiện đáng lưu tâm Điều này gợi ý về mối liên hệ giữa cấu trúc kiến trúc mạng và tính ổn định của các phương pháp giải thích mô hình. Tuy nhiên, do bản chất "hộp đen" của các mô hình học sâu, việc xác định chính xác cơ chế học tập của từng kiến trúc vẫn là một thách thức cần được nghiên cứu thêm.

4.2.2. Phân tích hiệu năng và ý nghĩa sinh học

Kết quả nghiên cứu cho thấy DeepSSC vượt trội hơn đáng kể so với MOGONET trong việc phân loại các kiểu phụ ung thư vú. Với độ chính xác trung bình 88.70%, cao hơn 3.3% so với MOGONET, DeepSSC đã chứng tỏ khả năng xử lý hiệu quả dữ liệu phức tạp. Đặc biệt ấn tượng là kết quả F1-macro đạt 86.98%, cao hơn tới 20.76% so với MOGONET, phản ánh khả năng xử lý khá tốt dữ liệu không cân bằng - một thách thức phổ biến trong dữ liệu y sinh.

Trong quá trình khai phá dấu ấn sinh học, các thí nghiệm chỉ ra điểm tối ưu ở khoảng 200-250 đặc trưng cho cả hai kiến trúc. DeepSSC thể hiện sự ổn định đặc biệt ở các giá trị top cao (200-300), trong khi MOGONET có xu hướng tăng chậm lại ở khoảng này. Điều này gợi ý về sự tồn tại của một tập core khoảng 200 gen có vai trò quan trọng trong việc phân biệt các kiểu phụ của bệnh.

Về mặt sinh học, nhiều dấu ấn được phát hiện đã được xác nhận qua sự trùng khớp với dữ liệu CTD. Các gen quan trọng như ERBB2 (HER2), SERPINB5, và KLK10 xuất hiện trong kết quả, củng cố độ tin cậy của phương pháp. Đặc biệt, việc phát hiện các gen tiềm năng mới như ATG10, UBLCP1, và MRPL13 không chỉ mở ra cơ hội nghiên cứu mới về vai trò của chúng trong ung thư vú mà còn chứng tỏ khả năng của phương pháp trong việc phát hiện các mối liên hệ chưa được khám phá.

Đáng chú ý, khi so sánh hiệu năng của các mô hình đánh giá, SVM thường cho kết quả tốt hơn hoặc tương đương với Logistic Regression, đặc biệt trên MOGONET. Sự chênh lệch này ít rõ rệt hơn trên DeepSSC, cho thấy khả năng khai phá các dấu ấn sinh học có tính phân biệt cao của kiến trúc này. Điều này có ý nghĩa quan trọng trong việc áp dụng thực tế, gợi ý rằng các dấu ấn sinh học được khai phá có thể được sử dụng hiệu quả với các mô hình đơn giản, dễ triển khai trong môi trường lâm sàng.

4.2.3. Đóng góp của nghiên cứu

Nghiên cứu này đã góp phần vào việc cải thiện phương pháp phân tích dữ liệu đa omics và khai phá dấu ấn sinh học ung thư vú. Thông qua việc kết hợp các đặc điểm của MOGONET và DeepSSC, nghiên cứu đề xuất một phương pháp phân tích dữ liệu đa omics với một số cải tiến trong quy trình xử lý dữ liệu. Các cải tiến này tập trung vào việc xây dựng quy trình sàng lọc và tiền xử lý dữ liệu phù hợp với đặc thù của bài toán

phân loại kiểu phụ ung thư vú, cùng với việc điều chỉnh phương pháp huấn luyện cho dữ liệu không cân bằng.

Trong lĩnh vực khai phá dấu ấn sinh học, nghiên cứu đã phát triển một cách tiếp cận dựa trên giải thuật Integrated Gradient với việc thiết kế và thử nghiệm các baseline khác nhau. Việc phân tích mối tương tác giữa các baseline với các kiến trúc mạng đã cung cấp những hiểu biết về quá trình khai phá dấu ấn sinh học, đồng thời hỗ trợ việc đánh giá tính ổn định của các kết quả thu được.

4.2.4. Hạn chế và hướng phát triển tương lai

Mặc dù đã đạt được những kết quả đáng kể, nghiên cứu vẫn còn một số hạn chế cần được giải quyết trong tương lai. Một hạn chế quan trọng là phạm vi nghiên cứu hiện tại mới chỉ tập trung vào ung thư vú. Việc mở rộng phương pháp sang các loại ung thư khác sẽ giúp đánh giá tốt hơn tính tổng quát của phương pháp đề xuất. Bên cạnh đó, việc chỉ sử dụng hai loại dữ liệu omics (GE và CNA) cũng là một giới hạn. Tích hợp thêm các loại dữ liệu omics khác như proteomics, metabolomics, hoặc epigenomics có thể giúp có cái nhìn toàn diện hơn về cơ chế bệnh.

Về mặt phương pháp, cần có thêm nghiên cứu sâu về tính ổn định và độ tin cậy của các dấu ấn sinh học được phát hiện, bao gồm khả năng chịu nhiễu và biến động trên dữ liệu thực tế. Việc khám phá tiềm năng của phương pháp học bán giám sát trong DeepSSC cho các tình huống có ít dữ liệu được gán nhãn cũng là một hướng đáng chú ý. Đồng thời, việc phát triển và nghiên cứu kỹ hơn về các baseline phù hợp trong nhiều hoàn cảnh dữ liệu và kiến trúc mạng khác nhau cũng là một hướng nghiên cứu quan trọng.

Một hướng phát triển đầy tiềm năng là việc phát triển phương pháp tổng hợp điểm đóng góp riêng cho từng kiểu phụ, kết hợp ưu điểm của cả MOGONET và DeepSSC. Điều này sẽ cung cấp cái nhìn toàn diện hơn về vai trò của các dấu ấn sinh học trong việc phân biệt các kiểu phụ ung thư. Để tăng cường tính ứng dụng thực tế, việc phát triển các công cụ trực quan hóa tương tác và tích hợp kiến thức chuyên môn sinh học và y học vào quá trình phân tích cũng là những hướng nghiên cứu cần được quan tâm.

4.2.5. Tiềm năng ứng dụng

Khung chương trình được đề xuất trong nghiên cứu này có thể hỗ trợ nhiều khía cạnh trong nghiên cứu và ứng dụng y sinh. Trong môi trường lâm sàng, nó có thể trợ giúp quá trình phân loại kiểu phụ ung thư vú, góp phần cung cấp thông tin cho việc lựa chọn phương pháp điều trị. Các dấu ấn sinh học được khai phá có thể gợi ý những hướng nghiên cứu mới về cơ chế bệnh, từ đó hỗ trợ việc tìm kiếm các mục tiêu điều trị tiềm năng. Trong lĩnh vực nghiên cứu phát triển thuốc, các dấu ấn sinh học được xác định có thể được xem xét như những ứng viên tiềm năng cho việc nghiên cứu thuốc mới hoặc cải thiện hiệu quả của các liệu pháp điều trị hiện có. Những hiểu biết về đặc điểm phân tử của từng kiểu phụ có thể hỗ trợ việc nghiên cứu các phương pháp điều trị phù hợp với từng nhóm bệnh nhân. Phương pháp được đề xuất trong nghiên cứu này, mặc dù hiện tại mới chỉ tập trung vào ung thư vú, có thể được điều chỉnh để phân tích dữ liệu đa omics trong các bệnh lý phức tạp khác. Đặc biệt, trong bối cảnh phát triển của y học chính xác, khả năng khai phá và phân tích các dấu ấn sinh học từ dữ liệu đa omics có thể góp phần vào việc phát triển các phương pháp chẩn đoán và điều trị dựa trên đặc điểm phân tử của từng cá thể. Tuy nhiên, việc áp dụng vào các bối cảnh khác sẽ cần những nghiên cứu và đánh giá thêm để đảm bảo tính hiệu quả và độ tin cậy của phương pháp.

Danh mục công trình khoa học của tác giả liên quan đến luận văn

Bảng 4.1: Danh sách các công trình nghiên cứu

TT	Các tác giả	Tên công trình	Năm	Nơi công bố	Phân loại	Vai trò
1	Hoang Le, Hien Nguyen Minh, Ha Tang Vinh, Diep Thi Hoang	Multi-omics biomarker discovery with explainable artificial intelligence: A case study in Glioblastoma	2024	16th IEEE International Conference on Knowledge and Systems Engineering (KSE 2024)	Hội thảo quốc tế	Tác giả chính đầu tiên
2	Hien Nguyen Minh, Ha Tang Vinh, Hoang Le, Diep Thi Hoang	Application of the SFE Feature Selection Method for Multi-Omic Biomarker Discovery in Brain Cancer Subtyping	2024	13th International Symposium on Information and Communication Technology (SOICT 2024)	Hội thảo quốc tế	Đồng tác giả

Tài liệu tham khảo

Tiếng Anh

[1] M Tom (1997). "Mitchell. Machine Learning. McGraw-Hill Science/Engineering/-Math". In.

[2] Leroy Hood et al. (2004). "Systems biology and new technologies enable predictive and preventative medicine". In: *Science* 306.5696, pp. 640–643.

[3] Cyril Goutte and Eric Gaussier (2005). "A probabilistic interpretation of precision, recall and F-score, with implication for evaluation". In: *European conference on information retrieval*. Springer, pp. 345–359.

[4] Jörg D Hoheisel (2006). "Microarray technology: beyond transcript profiling and genotype analysis". In: *Nature reviews genetics* 7.3, pp. 200–210.

[5] Muin J Khoury et al. (2007). "The continuum of translation research in genomic medicine: how can we accelerate the appropriate integration of human genome discoveries into health care and disease prevention?" In: *Genetics in Medicine* 9.10, pp. 665–674.

[6] L Pray (2008). "Personalized medicine: Hope or hype". In: *Nat Educ* 1.1, p. 72.

[7] Geoffrey S Ginsburg and Huntington F Willard (2009). "Genomic and personalized medicine: foundations and applications". In: *Translational research* 154.6, pp. 277–287.

[8] Haibo He and Edwardo A Garcia (2009). "Learning from imbalanced data". In: *IEEE Transactions on knowledge and data engineering* 21.9, pp. 1263–1284.

[9] Joel S Parker et al. (2009). "Supervised risk predictor of breast cancer based on intrinsic subtypes". In: *Journal of clinical oncology* 27.8, pp. 1160–1167.

[10] Marina Sokolova and Guy Lapalme (2009). “A systematic analysis of performance measures for classification tasks”. In: *Information processing & management* 45.4, pp. 427–437.

[11] Zhong Wang, Mark Gerstein, and Michael Snyder (2009). “RNA-Seq: a revolutionary tool for transcriptomics”. In: *Nature reviews genetics* 10.1, pp. 57–63.

[12] Allan Peter Davis et al. (2010). “The comparative toxicogenomics database: update 2011”. In: *Nucleic acids research* 39.suppl_1, pp. D1067–D1072.

[13] Lincoln D Stein (2010). “The case for cloud computing in genome informatics”. In: *Genome biology* 11, pp. 1–7.

[14] Elaine R Mardis (2011). “A decade’s perspective on DNA sequencing technology”. In: *Nature* 470.7333, pp. 198–203.

[15] Fredrick Van Goor et al. (2011). “Correction of the F508del-CFTR protein processing defect in vitro by the investigational drug VX-809”. In: *Proceedings of the National Academy of Sciences* 108.46, pp. 18843–18848.

[16] Christina Curtis et al. (2012). “The genomic and transcriptomic architecture of 2,000 breast tumours reveals novel subgroups”. In: *Nature* 486.7403, pp. 346–352.

[17] Bonnie Berger, Jian Peng, and Mona Singh (2013). “Computational solutions for omics data”. In: *Nature reviews genetics* 14.5, pp. 333–346.

[18] John N Weinstein et al. (2013). “The cancer genome atlas pan-cancer analysis project”. In: *Nature genetics* 45.10, pp. 1113–1120.

[19] Scott D Grosse (2014). “Economic analyses of genetic tests in personalized medicine: clinical utility first, then cost utility”. In: *GEnEtics in mEdicinE* 16.3, pp. 225–227.

[20] Francis S Collins and Harold Varmus (2015). “A new initiative on precision medicine”. In: *New England journal of medicine* 372.9, pp. 793–795.

[21] Eric D Green, James D Watson, and Francis S Collins (2015). “Human Genome Project: Twenty-five years of big biology”. In: *Nature* 526.7571, pp. 29–31.

[22] J Larry Jameson and Dan L Longo (2015). “Precision medicine—personalized, problematic, and promising”. In: *Obstetrical & gynecological survey* 70.10, pp. 612–614.

[23] Maxwell W Libbrecht and William Stafford Noble (2015). “Machine learning applications in genetics and genomics”. In: *Nature Reviews Genetics* 16.6, pp. 321–332.

[24] Marylyn D Ritchie et al. (2015). “Methods of integrating data to uncover genotype–phenotype interactions”. In: *Nature Reviews Genetics* 16.2, pp. 85–97.

[25] Nicholas J Schork (2015). “Personalized medicine: time for one-person trials”. In: *Nature* 520.7549, pp. 609–611.

[26] Christof Angermueller et al. (2016). “Deep learning for computational biology”. In: *Molecular systems biology* 12.7, p. 878.

[27] Jacques S Beckmann and Daniel Lew (2016). “Reconciling evidence-based medicine and precision medicine in the era of big data: challenges and opportunities”. In: *Genome medicine* 8, pp. 1–11.

[28] Broad Institute TCGA GDAC (2016a). *TCGA Firehose: Blacklisted Samples Report*. Accessed: 2024-12-05. Broad Institute of MIT and Harvard. URL: `https://gdac.broadinstitute.org/runs/stddata__latest/samples_report/Blacklisted_Samples.html`.

[29] — (2016b). *TCGA Firehose: BRCA Redactions Report*. Accessed: 2024-12-05. Broad Institute of MIT and Harvard. URL: `https://gdac.broadinstitute.org/runs/stddata__latest/samples_report/BRCA_Redactions.html`.

[30] Nanibaa’A Garrison et al. (2016). “A systematic literature review of individuals’ perspectives on broad consent and data sharing in the United States”. In: *Genetics in Medicine* 18.7, pp. 663–671.

[31] Marco Tulio Ribeiro, Sameer Singh, and Carlos Guestrin (2016). “" Why should i trust you?" Explaining the predictions of any classifier”. In: *Proceedings of the 22nd ACM SIGKDD international conference on knowledge discovery and data mining*, pp. 1135–1144.

[32] Mohammad Hasanzadeh, Nasrin Shadjou, and Miguel de la Guardia (2017). “Early stage screening of breast cancer using electrochemical biomarker detection”. In: *TrAC Trends in Analytical Chemistry* 91, pp. 67–76.

[33] Yehudit Hasin, Marcus Seldin, and Aldons Lusis (2017). “Multi-omics approaches to disease”. In: *Genome biology* 18, pp. 1–15.

[34] Sijia Huang, Kumardeep Chaudhary, and Lana X Garmire (2017). “More is better: recent progress in multi-omics data integration methods”. In: *Frontiers in genetics* 8, p. 84.

[35] Seonwoo Min, Byunghan Lee, and Sungroh Yoon (2017). “Deep learning in bioinformatics”. In: *Briefings in bioinformatics* 18.5, pp. 851–869.

[36] Mukund Sundararajan, Ankur Taly, and Qiqi Yan (2017). “Axiomatic attribution for deep networks”. In: *International conference on machine learning*. PMLR, pp. 3319–3328.

[37] Sajib Chakraborty et al. (2018). “Onco-multi-OMICS approach: a new frontier in cancer research”. In: *BioMed research international* 2018.1, p. 9836256.

[38] Konrad J Karczewski and Michael P Snyder (2018). “Integrative omics for health and disease”. In: *Nature Reviews Genetics* 19.5, pp. 299–310.

[39] Jingwen Yan et al. (2018). “Network approaches to systems biology analysis of complex disease: integrative methods for multi-omics data”. In: *Briefings in bioinformatics* 19.6, pp. 1370–1381.

[40] Allan Peter Davis et al. (2019). “The comparative toxicogenomics database: update 2019”. In: *Nucleic acids research* 47.D1, pp. D948–D954.

[41] Gökcen Eraslan et al. (2019). “Deep learning: new computational modelling techniques for genomics”. In: *Nature Reviews Genetics* 20.7, pp. 389–403.

[42] Andreas Holzinger et al. (2019). “Causability and explainability of artificial intelligence in medicine”. In: *Wiley Interdisciplinary Reviews: Data Mining and Knowledge Discovery* 9.4, e1312.

[43] Luke Merrick (2019). “Randomized Ablation Feature Importance”. In: *arXiv e-prints*, arXiv–1910.

[44] Michael Olivier et al. (2019). “The need for multi-omics biomarker signatures in precision medicine”. In: *International journal of molecular sciences* 20.19, p. 4781.

[45] James Zou et al. (2019). “A primer on deep learning in genomics”. In: *Nature genetics* 51.1, pp. 12–18.

[46] Mary J Goldman et al. (2020). “Visualizing and interpreting cancer genomics data via the Xena platform”. In: *Nature biotechnology* 38.6, pp. 675–678.

[47] Christoph Molnar (2020). *Interpretable machine learning*. Lulu. com.

[48] G. Nicora et al. (2020). “Integrated Multi-Omics Analyses in Oncology: A Review of Machine Learning Methods and Tools”. In: *Frontiers in Oncology* 10. DOI: 10.3389/fonc.2020.01030.

[49] Harish Guruprasad Ramaswamy et al. (2020). “Ablation-cam: Visual explanations for deep convolutional network via gradient-free localization”. In: *proceedings of the IEEE/CVF winter conference on applications of computer vision*, pp. 983–991.

[50] Indhupriya Subramanian et al. (2020). “Multi-omics data integration, interpretation, and its application”. In: *Bioinformatics and biology insights* 14, p. 1177932219899051.

[51] Allan Peter Davis et al. (2021). “Comparative toxicogenomics database (CTD): update 2021”. In: *Nucleic acids research* 49.D1, pp. D1138–D1143.

[52] Mingon Kang, Euiseong Ko, and T. Mersha (2021). “A roadmap for multi-omics data integration using deep learning”. In: *Briefings in bioinformatics*. DOI: 10.1093/bib/bbab454.

[53] Wojciech Samek et al. (2021). “Explaining deep neural networks and beyond: A review of methods and applications”. In: *Proceedings of the IEEE* 109.3, pp. 247–278.

[54] Tongxin Wang et al. (2021). “MOGONET integrates multi-omics data using graph convolutional networks allowing patient classification and biomarker identification”. In: *Nature communications* 12.1, p. 3445.

[55] Xiaokang Zhang, Inge Jonassen, and Anders Goksøyr (2021). “Machine learning approaches for biomarker discovery using gene expression data”. In: *Bioinformatics*.

[56] Xiaoyu Zhang et al. (2021). “OmiEmbed: A Unified Multi-Task Deep Learning Framework for Multi-Omics Data”. In: *Cancers* 13. DOI: 10.3390/cancers13123047.

[57] Hoang Le et al. (2022). “A biphasic Deep Semi-supervised framework for Suptype Classification and biomarker discovery”. In: *bioRxiv*, pp. 2022–01.

[58] Dongjin Leng et al. (2022). “A benchmark study of deep learning-based multi-omics data fusion methods for cancer”. In: *Genome biology* 23.1, p. 171.

[59] Tasbiraha Athaya et al. (2023). “Multimodal deep learning approaches for single-cell multi-omics data integration”. In: *Briefings in Bioinformatics* 24. DOI: 10.1093/bib/bbad313.

[60] Allan Peter Davis et al. (2023). “Comparative toxicogenomics database (CTD): update 2023”. In: *Nucleic acids research* 51.D1, pp. D1257–D1262.

[61] Mary Goldman et al. (2024). “Visualization and analysis of cancer genomics data using UCSC Xena”. In: *Cancer Research* 84.6_Supplement, pp. 7406–7406.