

ĐẠI HỌC QUỐC GIA HÀ NỘI
TRƯỜNG ĐẠI HỌC CÔNG NGHỆ



VŨ QUANG SƠN

PHÂN LOẠI HỆ GEN THỰC KHUẨN²
DỰA TRÊN PHƯƠNG PHÁP HỌC SÂU

LUẬN VĂN THẠC SĨ KHOA HỌC MÁY TÍNH

HÀ NỘI - 2026

ĐẠI HỌC QUỐC GIA HÀ NỘI
TRƯỜNG ĐẠI HỌC CÔNG NGHỆ

VŨ QUANG SƠN

PHÂN LOẠI HỆ GEN THỰC KHUẨN
DỰA TRÊN PHƯƠNG PHÁP HỌC SÂU

Ngành: Khoa học máy tính

Chuyên ngành: Khoa học máy tính

Mã số: 8480101.01

LUẬN VĂN THẠC SĨ KHOA HỌC MÁY TÍNH

NGƯỜI HƯỚNG DẪN KHOA HỌC: TS. Hoàng Thị Diệp

HÀ NỘI - 2026

**VIETNAM NATIONAL UNIVERSITY, HANOI
UNIVERSITY OF ENGINEERING AND TECHNOLOGY**

Vu Quang Son

**PHAGE LIFESTYLE PREDICTION
BASED ON DEEP LEARNING**

Major: Computer Science

Specialization: Computer Science

Code: 8480101.01

MASTER'S THESIS IN COMPUTER SCIENCE

SUPERVISOR: Dr. Hoang Thi Diep

HANOI - 2026

Lời cảm ơn

Với tất cả lòng kính trọng và biết ơn sâu sắc, tôi xin gửi lời cảm ơn chân thành đến cô Hoàng Thị Diệp, người giảng viên đã tận tình hướng dẫn, định hướng và truyền đạt tri thức quý báu trong suốt quá trình tôi thực hiện luận văn thạc sĩ. Sự hỗ trợ, những lời khuyên bảo và sự kiên nhẫn của cô là nguồn động viên to lớn giúp tôi hoàn thành nghiên cứu này.

Tôi xin trân trọng cảm ơn các thầy, cô giáo đang công tác và giảng dạy tại khoa Công nghệ Thông tin, Đại học Công nghệ - Đại học Quốc gia Hà Nội, những người đã trang bị cho tôi nền tảng kiến thức vững chắc và tạo mọi điều kiện thuận lợi để tôi được học tập và phát triển trong môi trường học thuật chuyên nghiệp.

Tôi xin gửi lời cảm ơn đến các bạn bè, đồng nghiệp đã luôn động viên, chia sẻ kinh nghiệm và hỗ trợ tôi trong suốt quá trình học tập và nghiên cứu.

Cuối cùng, tôi xin dành sự biết ơn sâu sắc nhất đến gia đình, đặc biệt là bố mẹ và người vợ yêu quý, những người đã luôn là nguồn động lực và điểm tựa tinh thần vững chắc cho tôi. Sự hy sinh, thấu hiểu và tình yêu thương vô bờ bến của gia đình là món quà vô giá, giúp tôi có thêm sức mạnh để vượt qua mọi khó khăn và hoàn thành chặng đường học tập thạc sĩ đầy thử thách này.

Tôi xin chân thành cảm ơn!

Lời cam đoan

Tôi là Vũ Quang Sơn, học viên cao học khóa 30, ngành Khoa học máy tính. Tôi xin cam đoan luận văn thạc sĩ “Phân loại hệ gen thực khuẩn dựa trên phương pháp học sâu” là công trình nghiên cứu, xây dựng của riêng mình dưới sự hướng dẫn của cô Hoàng Thị Diệp. Các nội dung nghiên cứu, kết quả trong luận văn là xác thực. Các thông tin sử dụng trong luận văn là có cơ sở và không có nội dung nào sao chép từ các tài liệu mà không ghi rõ trích dẫn tham khảo. Tôi xin chịu trách nhiệm về lời cam đoan này.

Hà Nội, ngày 18 tháng 05 năm 2026

Học viên

Vũ Quang Sơn

Tóm tắt

Tóm tắt: Thực khuẩn thể là vi-rút xâm nhiễm vi khuẩn, được xem là một giải pháp tiềm năng thay thế kháng sinh thông qua liệu pháp thực khuẩn thể. Trong ứng dụng trị liệu, việc xác định chính xác lối sống của thực khuẩn thể, độc lực hay ôn hòa, là một yêu cầu quan trọng, bởi phần lớn các ứng dụng điều trị ưu tiên thực khuẩn thể độc lực; thực khuẩn thể ôn hòa có thể tích hợp vật liệu di truyền vào hệ gen vật chủ theo chu trình tiềm tan và góp phần lan truyền các gen độc lực hay gen kháng kháng sinh qua chuyển gen ngang, từ đó làm tăng rủi ro cho điều trị. Các phương pháp truyền thống dựa trên nuôi cấy trong phòng thí nghiệm thường tốn nhiều thời gian và nguồn lực, khó áp dụng cho phần lớn thực khuẩn thể chưa được nuôi cấy hay gán nhãn, đặt ra nhu cầu về các phương pháp phân loại dựa trên tính toán. Các công cụ hiện có như DeePhage, PhaTYP và ProkBERT đạt hiệu suất khả quan nhưng vẫn mang trong mình những nhược điểm riêng.

Luận văn này đề xuất PhaBERT, một kiến trúc học sâu kết hợp mô hình nền tảng hệ gen DNABERT-2 với mô-đun tích chập đa nhân MKC. Nhờ đó, PhaBERT tận dụng tri thức tiên huấn luyện trên dữ liệu di truyền đa loài cùng với khả năng hoạt động trực tiếp trên dữ liệu di truyền thô thông qua mã hóa BPE mà không bị rò rỉ thông tin.

Thực nghiệm trên bốn nhóm độ dài contig (100-400 bp, 400-800 bp, 800-1.200 bp, 1.200-1.800 bp) với kiểm định chéo phân tầng 5 phần cho thấy PhaBERT đạt độ chính xác lần lượt 82,01%, 87,33%, 89,90% và 91,38%, cải thiện 0,36–6,65% so với các phương pháp tiên tiến gồm PhaTYP, DeePhage và ProkBERT. Nghiên cứu loại bỏ thành phần cho thấy mô-đun MKC đóng góp cải thiện độ chính xác từ 0,49% đến 3,02% so với đường cơ sở DNABERT-2 chỉ dùng đầu phân loại tuyến tính, với mức cải thiện tăng dần theo độ dài contig. Mô hình duy trì sự cân bằng giữa độ nhạy (82,07%–92,38%) và độ đặc hiệu (81,86%–87,63%) trên các phạm vi độ dài được khảo sát. Kết quả nghiên cứu cho thấy hiệu quả của việc kết hợp mô hình nền tảng hệ gen với kiến trúc đặc thù theo tác vụ. Đây là một hướng tiếp cận có nhiều triển vọng cho các bài toán phân tích chuỗi sinh học, nhất là trong phân tích dữ liệu hệ gen môi trường với các chuỗi không hoàn chỉnh hoặc bị phân mảnh.

Từ khóa: *Thực khuẩn thể, Phân loại lối sống, Học sâu, BERT, Mạng nơ-ron tích chập, Tin sinh học, Hệ gen môi trường*

Abstract

Abstract: Bacteriophages are viruses that infect bacteria and are regarded as a potential alternative to antibiotics through phage therapy. In therapeutic applications, accurately identifying the lifestyle of a phage, virulent or temperate, is an important requirement, since most therapeutic applications prioritize virulent phages; temperate phages may integrate their genetic material into the host genome through the lysogenic cycle and contribute to the spread of virulence genes or antibiotic resistance genes via horizontal gene transfer, thereby increasing therapeutic risk. Traditional culture-based laboratory methods are typically time- and resource-intensive and are difficult to apply to the majority of phages that remain uncultured or unlabeled, motivating the need for computational classification methods. Existing tools such as DeePhage, PhaTYP, and ProkBERT achieve promising performance but still have their own limitations.

This thesis proposes PhaBERT, a deep learning architecture that combines the DNABERT-2 genome foundation model with a multi-kernel convolution (MKC) module. Through this design, PhaBERT leverages pre-trained knowledge from multi-species genomic data while operating directly on raw DNA sequences through BPE tokenization without information leakage.

Experiments on four contig length groups (100-400 bp, 400-800 bp, 800-1,200 bp, 1,200-1,800 bp) with 5-fold stratified cross-validation show that PhaBERT achieves accuracies of 82.01%, 87.33%, 89.90%, and 91.38% respectively, improving by 0.36–6.65% over state-of-the-art methods including PhaTYP, DeePhage, and ProkBERT. An ablation study indicates that the MKC module contributes accuracy improvements ranging from 0.49% to 3.02% over the DNABERT-2 baseline using only a linear classification head, with the improvement increasing as contig length grows. The model maintains a balance between sensitivity (82.07%–92.38%) and specificity (81.86%–87.63%) across the length ranges examined. These results suggest the effectiveness of combining a genome foundation model with a task-specific architecture. This is a promising approach for biological sequence analysis tasks, especially metagenomic analysis involving incomplete or fragmented sequences.

Keywords: *Bacteriophage, Lifestyle classification, Deep learning, BERT, Convolutional neural networks, Bioinformatics, Metagenomics*

Mục lục

Lời cảm ơn

Lời cam đoan i

Tóm tắt ii

Abstract iii

Mục lục iv

Danh sách hình vẽ vii

Danh sách bảng viii

Danh mục các từ viết tắt và thuật ngữ ix

Chương 1 Giới thiệu 1

1.1 Đặt vấn đề 1

1.2 Thách thức nghiên cứu 2

1.3 Phát biểu bài toán 2

1.4 Mục tiêu nghiên cứu 3

1.5 Đóng góp của luận văn 4

1.6 Bố cục luận văn 4

Chương 2 Cơ sở lý thuyết 5

2.1 Nền tảng sinh học phân tử và tin sinh học 5

2.1.1 DNA, gen và bộ gen 5

2.1.2 Thực khuẩn thể và phân loại hệ gen 6

2.1.3 Dữ liệu hệ gen môi trường và bài toán phân loại trên contig . . 7

2.2 Nền tảng học sâu 9

2.2.1 Mạng nơ-ron nhân tạo 9

2.2.2	Mạng nơ-ron tích chập	10
2.2.3	Kiến trúc Transformer và cơ chế chú ý	11
2.2.4	BERT và mô hình ngôn ngữ có mặt nạ	13
2.2.5	DNABERT-2: Mô hình nền tảng hệ gen đa loài	13
2.3	Các phương pháp gộp trong mạng nơ-ron tích chập	14
2.3.1	Gộp cực đại và gộp trung bình	15
2.3.2	Gộp toàn cục	15
2.3.3	Gộp thích ứng	16
2.3.4	Gộp chú ý	16
2.4	Các phương pháp tính toán cho phân loại hệ gen thực khuẩn	17
2.4.1	Các phương pháp học máy truyền thống	17
2.4.2	Các phương pháp học sâu	18
2.4.3	Các mô hình nền tảng hệ gen	19
2.4.4	So sánh tổng hợp và khoảng trống nghiên cứu	20
Chương 3	Phương pháp đề xuất	22
3.1	Tổng quan phương pháp	22
3.2	Thu thập dữ liệu và tiền xử lý	23
3.3	Kiến trúc PhaBERT	27
3.3.1	Mạng nền DNABERT-2	27
3.3.2	Mô-đun MKC	28
3.3.3	Kết hợp đặc trưng và đầu phân loại	31
3.4	Chiến lược huấn luyện và tinh chỉnh	31
3.4.1	Giai đoạn 1: Khởi động	32
3.4.2	Giai đoạn 2: Tinh chỉnh đầy đủ	32
3.4.3	Hàm mục tiêu và kỹ thuật chính quy hóa	33
3.5	Kết luận	34
Chương 4	Thực nghiệm và Đánh giá	35
4.1	Thiết lập thực nghiệm	35
4.2	Tài nguyên tính toán	36
4.3	Kết quả thực nghiệm	37
4.3.1	Đánh giá đóng góp của MKC	37
4.3.2	So sánh với các phương pháp tiên tiến	39
4.4	Phân tích lỗi	42

4.4.1 Phân tích lỗi theo lớp nhân	42
4.4.2 Phân tích lỗi theo thành phần GC	43
4.5 Thảo luận	44
4.5.1 Phân tích đóng góp kiến trúc	44
4.5.2 Phân tích xu hướng theo độ dài contig	45
4.5.3 So sánh chiến lược biểu diễn chuỗi	46
4.5.4 Ý nghĩa thực tiễn của cải thiện hiệu suất	46
4.6 Kết luận	47
Chương 5 Kết luận	49
5.1 Kết luận	49
5.2 Đóng góp của nghiên cứu	50
5.3 Hạn chế và hướng phát triển tương lai	52
Tài liệu tham khảo	53

Danh sách hình vẽ

2.1	Chuỗi phân cấp lắp ráp hệ gen từ read, contig, scaffold đến bộ gen hoàn chỉnh	8
2.2	Minh họa mạng nơ-ron truyền thẳng gồm ba lớp đầu vào (x_1, x_2, x_3) , bốn nơ-ron lớp ẩn với hàm kích hoạt ReLU (h_1, h_2, h_3, h_4) , và hai nơ-ron đầu ra (y_1, y_2) . Các đường nối biểu diễn kết nối đầy đủ (fully connected) giữa các lớp liên kề, mỗi kết nối gắn với một trọng số có thể học được.	10
2.3	Kiến trúc Transformer [1] với hai thành phần chính: bộ mã hóa (trái) xử lý chuỗi nguồn qua n lớp gồm cơ chế chú ý đa đầu và mạng truyền thẳng theo vị trí với kết nối tắt; bộ giải mã (phải) tổng hợp đặc trưng từ bộ mã hóa để sinh chuỗi đích thông qua cơ chế chú ý đa đầu có mặt nạ và cơ chế chú ý chéo.	12
3.1	Pipeline tiền xử lý năm bước: chia dữ liệu ở mức hệ gen (5-fold phân tầng), tạo contig bằng cửa sổ trượt, tăng cường dữ liệu bằng chuỗi bổ sung đảo ngược, cân bằng lớp bằng lấy mẫu giảm ngẫu nhiên chỉ trên tập huấn luyện và mã hóa BPE	24
3.2	Kiến trúc chi tiết của PhaBERT	28
4.1	Hiệu suất phân loại của DeePhage, PhaTYP, ProkBERT và PhaBERT trên các nhóm A, B, C, D	41
4.2	Ma trận nhầm lẫn của PhaBERT trên bốn nhóm độ dài contig (số liệu gộp trên tập kiểm định năm phần)	43
4.3	Bản đồ nhiệt tỉ lệ lỗi của PhaBERT theo lưới hai chiều nhóm độ dài $\times$ khoảng GC (số liệu gộp trên tập kiểm định năm phần)	44

Danh sách bảng

2.1	So sánh tổng hợp các phương pháp phân loại hệ gen thực khuẩn . . .	20
3.1	Tham số của sổ trượt cho các nhóm độ dài contig	26
3.2	Thống kê số lượng contig sau tăng cường dữ liệu	27
3.3	Tổng hợp siêu tham số huấn luyện	33
4.1	Nghiên cứu loại bỏ thành phần: so sánh các cấu hình trên bốn nhóm độ dài contig	38
4.2	So sánh hiệu suất PhaBERT, PhaTYP, DeePhage và ProkBERT theo phương pháp kiểm định chéo phân tầng 5 phần trên bốn nhóm độ dài contig	40
4.3	Tỉ lệ lỗi theo lớp nhãn trên bốn nhóm độ dài contig (số liệu gộp trên tập kiểm định năm phần). FPR là tỉ lệ temperate bị nhầm thành virulent, FNR là tỉ lệ virulent bị nhầm thành temperate.	42

Danh mục các từ viết tắt và thuật ngữ

STT	Từ viết tắt/ thuật ngữ	Cụm từ đầy đủ	Cụm từ tiếng Việt
1	Phage	Bacteriophage	Thực khuẩn thể
2	DNA	Deoxyribonucleic Acid	Axit deoxyribonucleic
3	BERT	Bidirectional Encoder Representations from Transformers	Biểu diễn bộ mã hóa hai chiều từ Transformer
4	CNN	Convolutional Neural Network	Mạng nơ-ron tích chập
5	DNABERT-2	DNA Bidirectional Encoder Representations from Transformers version 2	Mô hình BERT cho chuỗi DNA phiên bản 2
6	BPE	Byte Pair Encoding	Mã hóa cặp byte
7	NGS	Next-Generation Sequencing	Giải trình tự thế hệ mới
8	bp	Base pair	Cặp base
9	ORF	Open Reading Frame	Khung đọc mở
10	HMM	Hidden Markov Model	Mô hình Markov ẩn
11	SVM	Support Vector Machine	Máy vector hỗ trợ
12	RF	Random Forest	Rừng ngẫu nhiên
13	LSTM	Long Short-Term Memory	Bộ nhớ ngắn hạn dài
14	Attention	Attention Mechanism	Cơ chế chú ý
15	ReLU	Rectified Linear Unit	Đơn vị tuyến tính chỉnh lưu
16	Adam	Adaptive Moment Estimation	Ước lượng mô-men thích ứng
17	Dropout	Dropout Regularization	Kỹ thuật loại bỏ ngẫu nhiên
18	Batch Norm	Batch Normalization	Chuẩn hóa theo batch
19	Cross-entropy	Cross-entropy Loss	Hàm mất mát entropy chéo
20	Accuracy	Accuracy	Độ chính xác

21	Precision	Precision	Độ chính xác dương
22	Recall	Recall/Sensitivity	Độ nhạy
23	F1-Score	F1-Score	Điểm F1
24	Specificity	Specificity	Độ đặc hiệu
25	AUC	Area Under the Curve	Diện tích dưới đường cong
26	ROC	Receiver Operating Characteristic	Đặc tính hoạt động của bộ thu
27	Contig	Contiguous sequence	Đoạn trình tự DNA liên tục được lắp ráp từ các đoạn đọc ngắn chồng lắp
28	Kernel	Kernel	Kích thước cửa sổ tích chập
29	Virulent phage	Virulent phage	Thực khuẩn thể độc lực
30	Temperate phage	Temperate phage	Thực khuẩn thể ôn hòa
31	Lysogenic cycle	Lysogenic cycle	Chu trình tiềm tan
32	Lytic cycle	Lytic cycle	Chu trình tan
33	Backbone	Backbone network	Mạng nền
34	Prophage	Prophage	Tiền thực khuẩn thể
35	HGT	Horizontal Gene Transfer	Chuyển gen ngang
36	Metagenomics	Metagenomics	Hệ gen môi trường
37	MKC	Multi-Kernel Convolution	Mô đun tích chập đa nhân
38	Ablation study	Ablation study	Nghiên cứu loại bỏ thành phần
39	Cross-validation	Cross-validation	Kiểm định chéo
40	Foundation model	Foundation model	Mô hình nền tảng
41	PhaBERT	Phage BERT	Mô hình PhaBERT
42	Lysogenic conversion	Lysogenic conversion	Biến đổi tiềm tan
43	Phage therapy	Phage therapy	Liệu pháp phage
44	RNN	Recurrent Neural Network	Mạng nơ-ron hồi quy

45	Transformer	Transformer	Kiến trúc Transformer
46	Self-attention	Self-attention Mechanism	Cơ chế tự chú ý
47	Multi-head at- tention	Multi-head Attention	Cơ chế chú ý đa đầu
48	Encoder	Encoder	Bộ mã hóa
49	Decoder	Decoder	Bộ giải mã
50	FFN	Feed-Forward Network	Mạng truyền thẳng
51	Residual con- nection	Residual Connection	Kết nối tắt
52	Layer Norm	Layer Normalization	Chuẩn hóa lớp
53	Positional en- coding	Positional Encoding	Mã hóa vị trí
54	ALiBi	Attention with Linear Bi- ases	Cơ chế chú ý với độ lệch tuyến tính
55	Softmax	Softmax Function	Hàm softmax
56	Tokenization	Tokenization	Phân tách token
57	Fine-tuning	Fine-tuning	Tinh chỉnh
58	Pre-training	Pre-training	Tiền huấn luyện
59	Embedding	Embedding	Biểu diễn nhúng
60	Pooling	Pooling	Gộp đặc trưng
61	Masked Mean Pooling	Masked Mean Pooling	Gộp trung bình có mặt nạ
62	Regularization	Regularization	Chính quy hóa

Chương 1

Giới thiệu

1.1 Đặt vấn đề

Thực khuẩn thể, thường được gọi tắt là phage, là các vi-rút xâm nhiễm và nhân lên bên trong tế bào vi khuẩn. Với số lượng ước tính lên tới 10^{30} cá thể chỉ riêng trong đại dương [2], thực khuẩn thể là dạng sống phong phú nhất trên Trái Đất và đóng vai trò trung tâm trong việc điều hòa quần thể vi khuẩn cũng như thúc đẩy quá trình chuyển gen ngang [3]. Dựa trên chiến lược nhân lên, thực khuẩn thể được phân thành hai nhóm chính: thực khuẩn thể độc lực chỉ thực hiện chu trình tan, và thực khuẩn thể ôn hòa có khả năng tích hợp hệ gen vào nhiễm sắc thể vi khuẩn ở trạng thái tiền thực khuẩn thể [4, 5]. Việc phân loại chính xác lối sống thực khuẩn thể có ý nghĩa quan trọng trong cả nghiên cứu vi sinh vật học lẫn ứng dụng y sinh học. Trong bối cảnh kháng kháng sinh ngày càng gia tăng [6, 7], liệu pháp phage đang được xem xét như một giải pháp thay thế đầy hứa hẹn [8]; tuy nhiên, thực khuẩn thể độc lực thường được xem là phù hợp hơn cho liệu pháp này, trong khi thực khuẩn thể ôn hòa thường không được khuyến nghị vì tiềm ẩn nguy cơ truyền gen kháng kháng sinh sang vi khuẩn bệnh nguyên thông qua biến đổi tiềm tan [8, 9].

Các phương pháp thực nghiệm truyền thống để xác định lối sống phage đòi hỏi nuôi cấy trong phòng thí nghiệm, tốn thời gian và không áp dụng được cho phần lớn phage chưa được phân lập trong các mẫu môi trường [10]. Với sự phát triển của công nghệ giải trình tự thế hệ mới, dữ liệu hệ gen môi trường đã trở thành công cụ quan trọng để nghiên cứu đa dạng sinh học thực khuẩn mà không cần nuôi cấy [11]. Trong phân tích hệ gen môi trường, dữ liệu di truyền của thực khuẩn thường được phục hồi dưới dạng các contig với độ dài biến thiên lớn và thường bị phân mảnh, đặt ra thách thức đặc thù cho các phương pháp phân loại tự động.

Khối lượng dữ liệu hệ gen môi trường ngày càng tăng nhanh đặt ra nhu cầu cấp thiết cho các phương pháp tính toán có khả năng phân loại hệ gen thực khuẩn thể một cách tự động, chính xác, và hoạt động hiệu quả trên các contig ngắn, phân

mảnh mà không phụ thuộc vào nuôi cấy phòng thí nghiệm. Tuy nhiên, việc xây dựng một phương pháp như vậy đối mặt với nhiều thách thức cả về mặt sinh học lẫn kỹ thuật tính toán.

1.2 Thách thức nghiên cứu

Các phương pháp tính toán để dự đoán lối sống thực khuẩn thể phải đối mặt với bốn thách thức cơ bản. Thứ nhất, cơ sở dữ liệu hệ gen thực khuẩn hiện có vẫn còn rất hạn chế so với sự đa dạng khổng lồ của thực khuẩn trong tự nhiên [12]. Thứ hai, thực khuẩn thể không có gen đánh dấu phổ quát như gen 16S rRNA của vi khuẩn [13], khiến các phương pháp phân loại dựa trên gen đánh dấu không khả thi. Thứ ba, dữ liệu hệ gen môi trường thường chứa nhiều contig ngắn, không hoàn chỉnh, thiếu các gen chức năng cần thiết cho các chiến lược phân loại dựa trên đặc trưng sinh học. Thứ tư, thực khuẩn thể có thể chia sẻ trình tự gen với vi khuẩn chủ thông qua chuyển gen ngang, dẫn đến nhầm lẫn trong quá trình phân loại.

Bên cạnh các thách thức sinh học, các phương pháp tính toán hiện có cũng đối mặt với những đánh đổi kỹ thuật quan trọng: yêu cầu hệ gen hoàn chỉnh làm hạn chế ứng dụng trên contig phân mảnh, phụ thuộc vào công cụ dự đoán gen làm giảm hiệu suất trên contig ngắn, và các chiến lược phân tách token dựa trên k-mer chồng lấp dẫn đến rò rỉ thông tin trong quá trình tiền huấn luyện.

1.3 Phát biểu bài toán

Bài toán dự đoán lối sống thực khuẩn thể trong luận văn được phát biểu dưới dạng phân loại nhị phân, nhất quán với các nghiên cứu trước từ PHACTS [14] và BACPHLIP [15] đến DeePhage [16] và PhaTYP [10]. Sự nhất quán này bắt nguồn từ bản chất sinh học của vấn đề, khi hai chiến lược nhân lên của thực khuẩn thể, chu trình tan và chu trình tiềm tan, tương ứng với hai lối sống phân biệt rõ về chức năng. Trên cơ sở đó, luận văn hình thức hóa bài toán như trình bày dưới đây.

Không gian đầu vào. Mỗi mẫu đầu vào là một chuỗi DNA (contig) được phục hồi từ dữ liệu hệ gen môi trường. Gọi $\mathcal{A} = \{A, T, G, C\}$ là bảng chữ cái nucleotide, không gian đầu vào được định nghĩa:

$$s = (s_1, s_2, \dots, s_L) \in \mathcal{A}^L, \quad L \in [100, 1800] \quad (1.1)$$

trong đó L là độ dài chuỗi tính bằng cặp base (bp). Phạm vi $L \in [100, 1800]$ phản ánh điều kiện thực tế của dữ liệu hệ gen môi trường: các contig thường ngắn và phân mảnh, không phải hệ gen thực khuẩn hoàn chỉnh.

Phân nhóm theo độ dài. Do hiệu suất phân loại phụ thuộc mạnh vào độ dài contig [10, 16], toàn bộ không gian đầu vào được phân hoạch thành bốn nhóm không giao nhau theo độ dài:

$$\mathcal{S}_g = \{s \in \mathcal{A}^L \mid L \in R_g\}, \quad g \in \{A, B, C, D\} \quad (1.2)$$

với $R_A = [100, 400]$, $R_B = [400, 800]$, $R_C = [800, 1200]$, $R_D = [1200, 1800]$ (đơn vị bp). Cách phân nhóm này được đề xuất bởi DeePhage [16] với lý do thực tiễn: bốn dải độ dài phủ khoảng độ dài raw reads và độ dài trung bình contigs lắp ráp từ công nghệ giải trình tự thế hệ mới. Mỗi nhóm g tương ứng với một mô hình f_{θ_g} được huấn luyện riêng biệt trên tập dữ liệu của nhóm đó. Quy ước phân nhóm này đã được nghiên cứu tiếp theo kế thừa [10], cho phép so sánh công bằng giữa các phương pháp trên từng dải độ dài.

Không gian nhãn và hàm phân loại. Không gian nhãn gồm hai lớp rời rạc $y \in \{0, 1\}$, trong đó $y = 0$ biểu thị thực khuẩn thể ôn hòa (temperate) và $y = 1$ biểu thị thực khuẩn thể độc lực (virulent). Với mỗi nhóm g , bài toán yêu cầu xây dựng một hàm phân loại:

$$f_{\theta_g} : \mathcal{S}_g \rightarrow \{0, 1\} \quad (1.3)$$

với θ_g là tập tham số riêng của mô hình nhóm g , sao cho f_{θ_g} tối đa hóa xác suất dự đoán đúng nhãn trên phân phối dữ liệu của nhóm tương ứng.

1.4 Mục tiêu nghiên cứu

Mục tiêu của luận văn là phát triển một phương pháp học sâu để phân loại hệ gen thực khuẩn thuộc thể có độc lực hay ôn hòa từ các contig ngắn trong dữ liệu hệ gen môi trường. Phương pháp đề xuất, PhaBERT, kết hợp mô hình nền tảng hệ gen DNABERT-2 [17] với mô-đun CNN chuyên biệt (MKC), khai thác đồng thời biểu diễn ngữ cảnh toàn cục từ mô hình tiền huấn luyện và đặc trưng cục bộ đa tỷ lệ từ CNN. Luận văn đánh giá hiệu suất PhaBERT so với các phương pháp tiên tiến trên bốn nhóm độ dài contig (100–1800 bp) thông qua kiểm định chéo 5 phần phân tầng.

1.5 Đóng góp của luận văn

Luận văn đóng góp vào lĩnh vực sinh tin học thông qua ba đóng góp chính:

1. **Đề xuất kiến trúc PhaBERT:** Xây dựng mô hình học sâu kết hợp mô hình nền tảng hệ gen DNABERT-2 với mô đun MKC (Multi-Kernel Convolutional) gồm nhánh CNN đa cửa sổ tích chập (kích thước 3, 5, 7) và nhánh gộp trung bình có mặt nạ toàn cục, cho bài toán dự đoán lối sống thực khuẩn thể từ contig đầu vào. Phương pháp hoạt động trực tiếp trên chuỗi DNA thô thông qua mã hóa BPE, không phụ thuộc công cụ dự đoán gen, cho phép xử lý hiệu quả các contig ngắn thiếu vùng mã hóa protein hoàn chỉnh.
2. **Đánh giá thực nghiệm toàn diện:** Đánh giá trên bốn nhóm độ dài contig (100–1800 bp) thông qua kiểm định chéo phân tầng 5 phần, cho thấy PhaBERT đạt độ chính xác cao nhất trên tất cả bốn nhóm với 82,01–91,38%, cải thiện 0,36–6,65% so với các phương pháp tiên tiến.
3. **Phân tích loại bỏ thành phần:** Thực hiện nghiên cứu loại bỏ thành phần với bảy cấu hình, chứng minh mô đun MKC đóng góp cải thiện 0,49–3,02% độ chính xác tùy theo độ dài contig.

1.6 Bố cục luận văn

Luận văn gồm năm chương. Chương 1 đặt vấn đề và trình bày mục tiêu nghiên cứu. Chương 2 trình bày cơ sở lý thuyết về sinh học thực khuẩn thể, các kiến trúc học sâu, và tổng quan các phương pháp phân loại hệ gen phage hiện có. Chương 3 mô tả chi tiết phương pháp PhaBERT được đề xuất. Chương 4 đánh giá thực nghiệm và phân tích kết quả. Chương 5 tổng kết và đề xuất hướng phát triển.

Chương 2

Cơ sở lý thuyết

Chương này trình bày các kiến thức nền tảng cần thiết cho việc hiểu và đánh giá các phương pháp phân loại hệ gen thực khuẩn thể từ dữ liệu hệ gen môi trường. Nội dung bao gồm các khái niệm sinh học phân tử và tin sinh học liên quan đến thực khuẩn thể và dữ liệu hệ gen, các kiến trúc học sâu được sử dụng rộng rãi trong phân tích chuỗi sinh học, cơ sở lý thuyết về học chuyển giao, và tổng quan các công trình nghiên cứu liên quan trong lĩnh vực phân loại hệ gen phage.

2.1 Nền tảng sinh học phân tử và tin sinh học

2.1.1 DNA, gen và bộ gen

Axit deoxyribonucleic (DNA) là phân tử mang thông tin di truyền của hầu hết các sinh vật sống và nhiều loại vi-rút. Năm 1953, Watson và Crick xác định rằng DNA có cấu trúc dạng xoắn kép, bao gồm hai chuỗi polynucleotide liên kết bổ sung chạy ngược chiều nhau [18]. Mỗi nucleotide bao gồm một phân tử đường deoxyribose, một nhóm phosphate, và một trong bốn bazơ nitơ: adenine (A), thymine (T), guanine (G), và cytosine (C). Theo nguyên tắc bổ sung Chargaff, A luôn ghép cặp với T và G luôn ghép cặp với C. Trật tự sắp xếp của bốn ký tự nucleotide dọc theo chuỗi DNA mã hóa toàn bộ thông tin di truyền của sinh vật, tạo thành cơ sở cho biểu diễn chuỗi hệ gen trong tin sinh học.

Gen là đơn vị cơ bản của thông tin di truyền, một đoạn DNA mã hóa cho một sản phẩm chức năng, thông thường là protein thông qua quá trình phiên mã (DNA sang RNA) rồi dịch mã (RNA sang chuỗi axit amin). Bộ gen là toàn bộ vật liệu di truyền của một sinh vật, bao gồm tất cả các gen và các vùng DNA không mã hóa. Kích thước bộ gen biến thiên rất lớn giữa các loài: từ vài kilobase (kb) ở các vi-rút nhỏ đến hàng tỷ cặp bazơ (bp) ở sinh vật bậc cao. Đối với thực khuẩn thể, bộ gen có thể là DNA hoặc RNA, dạng sợi đơn hoặc sợi kép, với kích thước dao động từ dưới 10 kb ở các thực khuẩn thể nhỏ đến hơn 600 kb ở một số thực khuẩn thể lớn [19]. Đặc biệt, các nghiên cứu hệ gen môi trường gần đây đã phát hiện hàng

trăm thực khuẩn thể với bộ gen vượt 200 kb, bao gồm các thực khuẩn khổng lồ với bộ gen ghi nhận lên đến 735 kb [20]. Sự đa dạng về kích thước và thành phần nucleotide (tỷ lệ GC) của bộ gen thực khuẩn đặt ra thách thức đáng kể cho các phương pháp phân tích dựa trên thống kê thành phần chuỗi.

2.1.2 Thực khuẩn thể và phân loại hệ gen

Thực khuẩn thể (bacteriophage), hay gọi tắt là phage, là các vi-rút có khả năng xâm nhiễm và nhân lên bên trong tế bào vi khuẩn. Thực khuẩn thể được xem là dạng thực thể sinh học phong phú nhất trên Trái Đất, với số lượng ước tính vượt 10^{30} cá thể chỉ riêng trong môi trường đại dương [2], và hiện diện ở hầu hết mọi môi trường có vi khuẩn sinh sống. Thực khuẩn thể đóng vai trò thiết yếu trong sinh thái vi sinh vật thông qua việc điều hòa quần thể vi khuẩn, đồng thời là tác nhân trung gian quan trọng trong quá trình chuyển gen ngang giữa các vi khuẩn [21].

Dựa trên chiến lược nhân lên, thực khuẩn thể được phân loại thành hai nhóm chính [14, 16]. Thực khuẩn thể độc lực chỉ thực hiện chu trình tan. Sau khi xâm nhiễm, thực khuẩn thể độc lực chiếm đoạt bộ máy tổng hợp của tế bào chủ để nhân bản hệ gen và tổng hợp các thành phần cấu trúc, lắp ráp thành các hạt vi-rút con, rồi phá vỡ tế bào vi khuẩn để giải phóng thế hệ thực khuẩn thể mới. Thực khuẩn thể ôn hòa có khả năng thực hiện cả chu trình tan lẫn chu trình tiềm tan. Trong chu trình tiềm tan, DNA thực khuẩn được tích hợp vào nhiễm sắc thể vi khuẩn thông qua quá trình tái tổ hợp đặc hiệu vị trí được xúc tác bởi enzyme integrase, trở thành prophage. Prophage tồn tại ở trạng thái im lặng và được nhân lên cùng với hệ gen vi khuẩn qua nhiều thế hệ [4]. Khi tế bào chủ tiếp xúc với các tác nhân gây tổn thương ADN như bức xạ tử ngoại (UV), prophage có thể được cảm ứng, tách ra khỏi nhiễm sắc thể vi khuẩn và chuyển sang thực hiện chu trình tan [4].

Việc phân loại chính xác hệ gen thực khuẩn có ý nghĩa thực tiễn quan trọng trong nhiều lĩnh vực ứng dụng. Trong liệu pháp sử dụng thực khuẩn để điều trị các bệnh nhiễm khuẩn kháng kháng sinh [22], thực khuẩn thể độc lực thường được xem là lựa chọn phù hợp vì chúng tiêu diệt vi khuẩn hiệu quả mà không tích hợp vào hệ gen tế bào chủ [22, 23]. Ngược lại, thực khuẩn thể ôn hòa tiềm ẩn nguy cơ truyền các gen độc lực hoặc gen kháng kháng sinh sang vi khuẩn bệnh nguyên thông qua biến đổi tiềm tan [9, 24].


Tuy nhiên, xác định hệ gen thực khuẩn bằng phương pháp thực nghiệm truyền thống đòi hỏi nuôi cấy và phân lập thực khuẩn trong phòng thí nghiệm, một quá trình tốn nhiều thời gian, chi phí cao và không khả thi với phần lớn các thực khuẩn chưa được nuôi cấy trong các mẫu môi trường [10]. Điều này thúc đẩy sự phát triển của các phương pháp tính toán để dự đoán hệ gen thực khuẩn trực tiếp từ dữ liệu di truyền, đặc biệt trong bối cảnh phân tích hệ gen môi trường nơi hệ gen thực khuẩn thường thu được dưới dạng các contig ngắn và phân mảnh.

2.1.3 Dữ liệu hệ gen môi trường và bài toán phân loại trên contig

Hệ gen môi trường (metagenomics, hay siêu hệ gen) là lĩnh vực nghiên cứu vật liệu di truyền được thu thập trực tiếp từ các mẫu môi trường, cho phép phân tích toàn bộ cộng đồng vi sinh vật mà không cần nuôi cấy từng loài riêng lẻ [25]. Phương pháp này đặc biệt quan trọng vì phần lớn vi sinh vật trong tự nhiên không thể nuôi cấy trong điều kiện phòng thí nghiệm. Một nhánh chuyên biệt gọi là *viral metagenomics* (hay *metaviromics*) tập trung vào thành phần vi-rút trong mẫu môi trường. Dữ liệu thu được từ metaviromics cung cấp cái nhìn toàn diện về sự đa dạng và phân bố của các cộng đồng phage trong nhiều hệ sinh thái khác nhau, từ đại dương, đất đến ruột người [11]. Chính nhờ đó, phần lớn sự đa dạng của thực khuẩn thể trong tự nhiên mới được hé lộ, trong khi các phương pháp phân lập truyền thống chỉ tiếp cận được một phần nhỏ quần thể vi-rút thực sự tồn tại trong môi trường [25].

Trong phân tích hệ gen môi trường (metagenomics), dữ liệu thô từ giải trình tự thế hệ mới là các đoạn đọc ngắn gọi là *read*, mỗi read thường có độ dài từ vài chục đến vài trăm cặp bazơ tùy công nghệ sử dụng. Các đoạn đọc này được lắp ráp lại bằng thuật toán lắp ráp trình tự dựa trên vùng chồng lắp giữa chúng, tạo thành các đoạn trình tự dài hơn gọi là *contig* (trình tự liên tục) [26]. Contig đại diện cho một vùng liên tục của bộ gen được tái tạo từ dữ liệu trình tự, song thường chưa đầy đủ do độ phủ không đồng đều, các vùng lắp lại, hoặc sai số kỹ thuật. Ở mức độ lắp ráp cao hơn, các contig được sắp xếp và định hướng tương đối với nhau dựa trên thông tin đọc ghép đôi đầu (paired-end reads) hoặc đọc dài (long reads), tạo thành *scaffold*; khoảng cách giữa các contig trong scaffold thường được điền bằng ký tự “N” để biểu thị vùng trình tự chưa xác định [26]. Chuỗi phân cấp từ đoạn đọc, contig, scaffold đến bộ gen hoàn chỉnh phản ánh mức độ đầy đủ ngày càng

tăng của dữ liệu trình tự thu được (Hình 2.1).



Hình 2.1: Chuỗi phân cấp lắp ráp hệ gen từ read, contig, scaffold đến bộ gen hoàn chỉnh

Trong bối cảnh dự đoán hệ gen thực khuẩn thể, phần lớn dữ liệu đầu vào thực tế tồn tại ở dạng contig, các đoạn bộ gen không hoàn chỉnh với độ dài và mức độ đại diện rất khác nhau. Để đánh giá hiệu năng trên các contig có độ dài điển hình trong dữ liệu metavirome, các nghiên cứu DeePhage [16] và PhaTYP [10] đã thống nhất sử dụng bốn nhóm độ dài: Nhóm A (100–400 bp), Nhóm B (400–800 bp), Nhóm C (800–1200 bp), và Nhóm D (1200–1800 bp). Nhóm A bao phủ độ dài điển hình của các read thô từ giải trình tự Illumina (thường 75–300 bp); Nhóm B–C bao phủ phần lớn contig ngắn thường gặp sau lắp ráp; và Nhóm D đại diện cho các contig trung bình vẫn còn phân mảnh so với bộ gen phage hoàn chỉnh (thường 15–200 kb). Nghiên cứu này kế thừa cùng phân chia nhóm độ dài để đảm bảo khả năng so sánh trực tiếp với các phương pháp tiền nhiệm.

Các contig ngắn, đặc biệt dưới 400 bp, đặt ra thách thức đặc biệt cho phân loại bởi chúng thường không chứa gen hoàn chỉnh, khiến các công cụ dự đoán gen như Prodigal hoặc các công cụ tương đương giảm độ chính xác đáng kể trên các đoạn DNA ngắn có chứa lỗi giải trình tự [27]. Đây là một trong những động lực chính cho việc phát triển các phương pháp học sâu hoạt động trực tiếp trên chuỗi DNA thô thay vì dựa vào đặc trưng protein.

2.2 Nền tảng học sâu

Phần này trình bày các kiến trúc học sâu nền tảng được kế thừa trong nghiên cứu: mạng nơ-ron nhân tạo, mạng nơ-ron tích chập (CNN), kiến trúc Transformer, mô hình BERT, và mô hình nền tảng hệ gen DNABERT-2. Mỗi thành phần cung cấp cơ sở lý thuyết trực tiếp cho một phần của kiến trúc PhaBERT được đề xuất tại Chương 3.

2.2.1 Mạng nơ-ron nhân tạo


Mạng nơ-ron nhân tạo là mô hình tính toán lấy cảm hứng từ cấu trúc và cơ chế hoạt động của hệ thần kinh sinh học, trong đó các đơn vị tính toán cơ bản (nơ-ron nhân tạo) được tổ chức thành các lớp và kết nối với nhau thông qua các trọng số có thể học được [28]. Một mạng nơ-ron truyền thẳng điển hình bao gồm ba thành phần: lớp đầu vào tiếp nhận dữ liệu, một hoặc nhiều lớp ẩn thực hiện các phép biến đổi phi tuyến, và lớp đầu ra tạo kết quả dự đoán (Hình 2.2).

Tại mỗi nơ-ron trong lớp ẩn hoặc lớp đầu ra, tín hiệu đầu vào được tổng hợp bằng tổ hợp tuyến tính có trọng số:

$$z = \sum_{i=1}^n w_i x_i + b \quad (2.1)$$

trong đó x_i là các giá trị đầu vào, w_i là các trọng số tương ứng, b là hệ số lệch (bias), và n là số đầu vào. Kết quả z sau đó được đưa qua hàm kích hoạt phi tuyến f để tạo đầu ra $a = f(z)$ của nơ-ron. Hàm kích hoạt đóng vai trò then chốt trong việc cho phép mạng biểu diễn các ánh xạ phi tuyến phức tạp; nếu thiếu thành phần này, toàn bộ mạng nhiều lớp sẽ tương đương với một phép biến đổi tuyến tính duy nhất [29]. Các hàm kích hoạt phổ biến bao gồm hàm sigmoid $\sigma(z) = 1/(1 + e^{-z})$, hàm tanh, và đặc biệt là hàm ReLU $f(z) = \max(0, z)$ [30], được ưa chuộng nhờ tính đơn giản và khả năng giảm thiểu vấn đề triệt tiêu gradient trong các mạng sâu.

Quá trình huấn luyện mạng nơ-ron dựa trên nguyên lý tối ưu hóa hàm mất mát, đo lường sai lệch giữa đầu ra dự đoán và nhãn thực tế. Thuật toán lan truyền ngược [31] tính toán gradient của hàm mất mát theo từng trọng số bằng quy tắc chuỗi, sau đó các thuật toán tối ưu dựa trên gradient như giảm gradient ngẫu nhiên (Stochastic Gradient Descent, SGD) hoặc các biến thể thích ứng như Adam [32]



Hình 2.2: Minh họa mạng nơ-ron truyền thẳng gồm ba lớp đầu vào (x_1, x_2, x_3), bốn nơ-ron lớp ẩn với hàm kích hoạt ReLU (h_1, h_2, h_3, h_4), và hai nơ-ron đầu ra (y_1, y_2). Các đường nối biểu diễn kết nối đầy đủ (fully connected) giữa các lớp liên kề, mỗi kết nối gắn với một trọng số có thể học được.

cập nhật trọng số theo hướng giảm thiểu hàm mất mát. Nhờ khả năng xấp xỉ hàm phổ quát [33], mạng nơ-ron với ít nhất một lớp ẩn có đủ số nơ-ron về nguyên tắc có thể xấp xỉ bất kỳ hàm liên tục nào với độ chính xác tùy ý, tạo nền tảng lý thuyết cho các kiến trúc học sâu phức tạp hơn.

2.2.2 Mạng nơ-ron tích chập

Mạng nơ-ron tích chập (Convolutional Neural Network, CNN) là một lớp kiến trúc học sâu được thiết kế để trích xuất các đặc trưng cục bộ từ dữ liệu có cấu trúc không gian hoặc chuỗi [34]. Thành phần cốt lõi của CNN là phép tích chập, trong đó một bộ lọc (filter hay kernel) có kích thước cố định trượt dọc theo dữ liệu đầu vào, tính tích vô hướng tại mỗi vị trí để tạo ra bản đồ đặc trưng (feature map). Đối với dữ liệu chuỗi một chiều như chuỗi DNA hoặc chuỗi văn bản, phép tích chập một chiều (Conv1D) được sử dụng: bộ lọc có kích thước k (kernel size) trượt dọc theo chiều dài chuỗi, mỗi vị trí tạo ra một giá trị đặc trưng phản ánh mẫu cục bộ trong cửa sổ k phần tử liên tiếp. Các tham số bổ sung bao gồm bước trượt (stride) quy định khoảng cách giữa các vị trí tính toán liên tiếp, và phần đệm (padding) bổ sung các giá trị ở hai đầu chuỗi để kiểm soát kích thước đầu ra.

Sau phép tích chập, hàm kích hoạt phi tuyến được áp dụng để tăng khả năng biểu diễn của mô hình. Hàm ReLU (Rectified Linear Unit), định nghĩa là $f(x) =$

$\max(0, x)$, được sử dụng phổ biến nhờ tính đơn giản và hiệu quả trong việc giảm thiểu vấn đề triệt tiêu gradient. Lớp chuẩn hóa theo batch (batch normalization) thường được chèn sau phép tích chập để ổn định quá trình huấn luyện bằng cách chuẩn hóa phân phối đầu ra của mỗi lớp.

Lớp gộp (pooling) giảm chiều dữ liệu bằng cách tổng hợp thông tin trong các vùng lân cận, tạo tính bất biến dịch chuyển cục bộ và giảm chi phí tính toán. Các phương pháp gộp đa dạng, từ gộp cực đại, gộp trung bình đến gộp chú ý, được trình bày chi tiết tại Mục 2.3.

Trong phân tích chuỗi sinh học, CNN có khả năng phát hiện các mẫu cục bộ (motif) trong chuỗi DNA mà không cần chỉ định trước vị trí hay dạng thức của chúng. Việc sử dụng nhiều bộ lọc với kích thước kernel khác nhau cho phép trích xuất đồng thời các đặc trưng ở nhiều tỷ lệ, từ các mẫu ngắn vài nucleotide đến các mẫu dài hàng chục nucleotide [34].


2.2.3 Kiến trúc Transformer và cơ chế chú ý

Kiến trúc Transformer được đề xuất bởi Vaswani và cộng sự [1] đã tạo ra bước đột phá trong xử lý ngôn ngữ tự nhiên và sau đó được mở rộng sang nhiều lĩnh vực khác, bao gồm phân tích chuỗi sinh học. Khác với các kiến trúc hồi quy (RNN, LSTM) xử lý chuỗi tuần tự từng phần tử, Transformer xử lý toàn bộ chuỗi đồng thời thông qua cơ chế chú ý, cho phép song song hóa tính toán và nắm bắt hiệu quả các phụ thuộc dài hạn trong chuỗi (Hình 2.3).

Thành phần cốt lõi của Transformer là cơ chế tự chú ý. Cho một chuỗi đầu vào gồm n vector biểu diễn, cơ chế tự chú ý tính toán ba ma trận: truy vấn (Q), khóa (K), và giá trị (V) thông qua các phép biến đổi tuyến tính. Điểm chú ý giữa mỗi cặp vị trí được tính bằng tích vô hướng giữa vector truy vấn và vector khóa tương ứng, chia cho hệ số chuẩn hóa $\sqrt{d_k}$ (với d_k là chiều của vector khóa), sau đó áp dụng hàm softmax để thu được trọng số chú ý:

$$\text{Attention}(Q, K, V) = \text{softmax}\left(\frac{QK^T}{\sqrt{d_k}}\right)V \quad (2.2)$$

Cơ chế chú ý đa đầu mở rộng tự chú ý bằng cách thực hiện song song nhiều phép tự chú ý với các phép chiếu tuyến tính khác nhau, cho phép mô hình đồng thời nắm bắt các kiểu quan hệ khác nhau giữa các vị trí trong chuỗi. Kết quả từ các



Hình 2.3: Kiến trúc Transformer [1] với hai thành phần chính: bộ mã hóa (trái) xử lý chuỗi nguồn qua n lớp gồm cơ chế chú ý đa đầu và mạng truyền thẳng theo vị trí với kết nối tắt; bộ giải mã (phải) tổng hợp đặc trưng từ bộ mã hóa để sinh chuỗi đích thông qua cơ chế chú ý đa đầu có mặt nạ và cơ chế chú ý chéo.

đầu chú ý được nối lại và chiếu qua một lớp tuyến tính để tạo đầu ra cuối cùng.

Do cơ chế tự chú ý không có khái niệm về thứ tự vị trí, Transformer cần bổ sung thông tin vị trí cho các phần tử trong chuỗi. Phương pháp gốc sử dụng mã hóa vị trí dạng hàm sin [1], trong đó vị trí của mỗi phần tử được biểu diễn bằng tổ hợp các hàm sin và cosin với tần số khác nhau, cho phép mô hình suy luận tương đối về khoảng cách giữa các vị trí.

Mỗi lớp Transformer bao gồm một khối chú ý đa đầu và một mạng truyền thẳng gồm hai lớp tuyến tính với hàm kích hoạt phi tuyến ở giữa. Chuẩn hóa lớp và kết nối tắt được áp dụng xung quanh mỗi khối con để ổn định quá trình huấn luyện và tạo điều kiện cho gradient lan truyền qua nhiều lớp.

2.2.4 BERT và mô hình ngôn ngữ có mặt nạ

BERT (Bidirectional Encoder Representations from Transformers) [35] là mô hình ngôn ngữ dựa trên kiến trúc Transformer encoder, được thiết kế để học biểu diễn ngữ cảnh hai chiều từ dữ liệu văn bản không có nhãn. Khác với các mô hình ngôn ngữ truyền thống chỉ xử lý ngữ cảnh theo một chiều (trái sang phải hoặc phải sang trái), BERT đồng thời xem xét ngữ cảnh từ cả hai phía của mỗi token, tạo ra các biểu diễn embedding phong phú hơn.

Kiến trúc BERT bao gồm nhiều lớp Transformer encoder xếp chồng. Phiên bản BERT-base sử dụng 12 lớp với kích thước ẩn 768 và 12 đầu chú ý, tổng cộng khoảng 110 triệu tham số. Đầu vào của BERT là chuỗi token được tạo từ thuật toán phân tách từ phụ (subword tokenization) như WordPiece hoặc Byte Pair Encoding (BPE) [36]. Mỗi token đầu vào được biểu diễn bằng tổng của ba embedding: token embedding, segment embedding, và position embedding.

BERT được huấn luyện trước bằng mục tiêu mô hình hóa ngôn ngữ có mặt nạ (Masked Language Modeling, MLM): một tỷ lệ ngẫu nhiên các token đầu vào (thường 15%) được thay thế bằng token đặc biệt [MASK], và mô hình học dự đoán token gốc dựa trên ngữ cảnh hai chiều xung quanh. Quá trình huấn luyện trước trên kho ngữ liệu lớn cho phép BERT học được các biểu diễn ngôn ngữ tổng quát, sau đó có thể tinh chỉnh (fine-tune) cho các tác vụ cụ thể bằng cách thêm các lớp phân loại phía trên và huấn luyện trên dữ liệu có nhãn của tác vụ đích. Paradigm huấn luyện trước–tinh chỉnh này đã trở thành phương pháp tiêu chuẩn trong xử lý ngôn ngữ tự nhiên và được mở rộng sang phân tích chuỗi sinh học.

2.2.5 DNABERT-2: Mô hình nền tảng hệ gen đa loài

DNABERT-2 [17] là mô hình nền tảng hệ gen đa loài thế hệ mới, được phát triển nhằm khắc phục các hạn chế của DNABERT gốc [37] trong phân tích chuỗi DNA. DNABERT gốc sử dụng phân tách k-mer có chồng lấp (thường $k = 6$), trong đó các token liên kế chia sẻ $k - 1$ nucleotide, gây ra ba vấn đề chính: rò rỉ thông tin trong quá trình học có mặt nạ (mô hình có thể suy luận token bị che từ các token lân cận), kém hiệu quả tính toán (số token xấp xỉ độ dài chuỗi gốc), và giới hạn độ dài cứng 512 token do sử dụng biểu diễn vị trí học được [17].

DNABERT-2 giải quyết các hạn chế này thông qua ba cải tiến kiến trúc chính.

Thứ nhất, phương pháp phân tách token Byte Pair Encoding (BPE) [36] được áp dụng thông qua bộ khung SentencePiece [38]. BPE xây dựng từ điển gồm 4.096 token bằng cách lặp lại việc ghép các cặp ký tự liên kề xuất hiện thường xuyên nhất trong kho ngữ liệu, tạo ra các token có độ dài thay đổi với trung bình khoảng 5 nucleotide mỗi token, giảm độ dài chuỗi khoảng 5 lần so với DNABERT. Quan trọng hơn, BPE loại bỏ hoàn toàn rò rỉ thông tin vì các token không chồng lấp nhau, mỗi nucleotide chỉ thuộc về một token duy nhất. BPE cũng biến đổi mục tiêu MLM thành bài toán dự đoán đoạn (span prediction), trong đó mô hình cần dự đoán cả số lượng nucleotide lẫn danh tính của chúng trong token bị che, được chứng minh giúp tăng hiệu quả học [17, 39].

Thứ hai, mã hóa vị trí ALiBi (Attention with Linear Biases) [40] thay thế biểu diễn vị trí học được, cho phép xử lý chuỗi có độ dài tùy ý mà không cần huấn luyện lại. Thứ ba, Flash Attention [41] được tích hợp để giảm tiêu thụ bộ nhớ và tăng tốc huấn luyện, giúp mô hình hiệu quả hơn 3 lần so với DNABERT trong khi chỉ sử dụng một phần ba số FLOPs mặc dù có nhiều hơn 30% tham số.

DNABERT-2 được huấn luyện trước trên kho ngữ liệu hệ gen đa loài với độ dài chuỗi trung bình khoảng 700 cặp bazơ. Trên bộ chuẩn Genome Understanding Evaluation (GUE) gồm 36 tác vụ thuộc 9 danh mục phân tích hệ gen với chuỗi có độ dài từ 70 đến 10.000 bp, DNABERT-2 đạt hiệu năng tương đương mô hình Nucleotide Transformer 2,5 tỉ tham số [42] trong khi nhỏ hơn 21 lần và yêu cầu ít hơn khoảng 92 lần thời gian GPU trong quá trình huấn luyện trước. Mô hình thể hiện hiệu năng ổn định trên các độ dài chuỗi khác nhau, xử lý hiệu quả các đầu vào ngắn hơn 10 lần hoặc dài hơn 15 lần so với dữ liệu huấn luyện trước.

2.3 Các phương pháp gộp trong mạng nơ-ron tích chập

Lớp gộp là thành phần quan trọng trong kiến trúc mạng nơ-ron tích chập, thực hiện phép giảm chiều dữ liệu bằng cách tổng hợp thông tin từ các vùng lân cận trên bản đồ đặc trưng [29]. Pooling đóng ba vai trò chính: giảm kích thước biểu diễn trung gian để tiết kiệm bộ nhớ và chi phí tính toán, tạo tính bất biến dịch chuyển cục bộ giúp mô hình nhận diện đặc trưng bất kể vị trí chính xác của chúng trong đầu vào, và kiểm soát hiện tượng quá khớp thông qua việc giảm số tham số ở các lớp phía sau [28]. Phần này trình bày các phương pháp gộp phổ biến, từ

các kỹ thuật cơ bản đến các biến thể nâng cao phù hợp với dữ liệu có độ dài biến thiên.

2.3.1 Gộp cực đại và gộp trung bình

Gộp cực đại và gộp trung bình là hai phương pháp gộp cơ bản nhất, hoạt động bằng cách áp dụng một cửa sổ trượt có kích thước cố định k dọc theo bản đồ đặc trưng với bước trượt s .

Gộp cực đại chọn giá trị lớn nhất trong mỗi cửa sổ:

$$y_j = \max_{i \in R_j} x_i \quad (2.3)$$

trong đó R_j là tập các vị trí thuộc cửa sổ gộp thứ j và x_i là giá trị đặc trưng tại vị trí i . Phương pháp này giữ lại đặc trưng nổi bật nhất trong mỗi vùng cục bộ, phù hợp khi tín hiệu quan trọng tập trung tại một số ít vị trí [29].

Gộp trung bình tính giá trị trung bình cộng của tất cả phần tử trong cửa sổ:

$$y_j = \frac{1}{|R_j|} \sum_{i \in R_j} x_i \quad (2.4)$$

trong đó $|R_j|$ là số phần tử trong vùng gộp. Khác với gộp cực đại chỉ giữ lại giá trị đỉnh, gộp trung bình bảo toàn thông tin phân bố tổng thể của vùng, tạo biểu diễn mượt hơn và ít nhạy cảm với nhiễu cục bộ [29].

Hai phương pháp này có đặc tính bổ sung: gộp cực đại nhạy với sự hiện diện của đặc trưng mạnh nhưng bỏ qua phần còn lại, trong khi gộp trung bình phản ánh mức kích hoạt chung nhưng có thể làm mờ các đặc trưng sắc nét khi pha lẫn với các giá trị nhỏ xung quanh.

2.3.2 Gộp toàn cục

Gộp toàn cục mở rộng ý tưởng gộp cục bộ lên toàn bộ bản đồ đặc trưng, rút gọn mỗi kênh thành một giá trị vô hướng duy nhất. Với bản đồ đặc trưng một chiều có độ dài L , gộp trung bình toàn cục (Global Average Pooling, GAP) được định nghĩa:

$$y_c = \frac{1}{L} \sum_{i=1}^L x_c(i) \quad (2.5)$$

trong đó $x_c(i)$ là giá trị tại vị trí i của kênh c . Tương tự, gộp cực đại toàn cục (Global Max Pooling, GMP) lấy giá trị lớn nhất trên toàn bộ chiều dài: $y_c = \max_{i=1}^L x_c(i)$.

GAP được đề xuất bởi Lin và cộng sự [43] như một giải pháp thay thế cho các lớp kết nối đầy đủ (fully connected) ở cuối mạng. Thay vì sử dụng hàng triệu tham số trong lớp fully connected, GAP tạo ra vector đặc trưng có chiều bằng số kênh mà không cần tham số học thêm. Điều này mang lại hai lợi ích: giảm đáng kể nguy cơ quá khớp do loại bỏ lượng lớn tham số, và cho phép mạng xử lý đầu vào có kích thước tùy ý vì kết quả gộp toàn cục luôn có chiều cố định bất kể độ dài đầu vào [43].

2.3.3 Gộp thích ứng

Gộp thích ứng là biến thể trong đó người dùng chỉ định kích thước đầu ra mong muốn L_{out} thay vì kích thước cửa sổ và bước trượt. Hệ thống tự động tính toán các tham số gộp phù hợp dựa trên kích thước đầu vào L_{in} :

$$k = \left\lceil \frac{L_{in}}{L_{out}} \right\rceil, \quad s = \left\lfloor \frac{L_{in}}{L_{out}} \right\rfloor \quad (2.6)$$

trong đó k là kích thước cửa sổ và s là bước trượt được tính tự động. Phép gộp (cực đại hoặc trung bình) sau đó được áp dụng với các tham số này.

Ưu điểm chính của gộp thích ứng là khả năng tạo đầu ra có kích thước cố định từ đầu vào có kích thước bất kỳ, mà không cần cắt ngắn hay đệm thêm dữ liệu. Đặc tính này đặc biệt hữu ích khi xử lý các chuỗi có độ dài biến thiên lớn, cho phép thiết kế kiến trúc mạng linh hoạt mà không phụ thuộc vào giả định về kích thước đầu vào cố định [44].

2.3.4 Gộp chú ý

Gộp chú ý là phương pháp gộp trong đó trọng số tổng hợp được học từ dữ liệu thay vì cố định như gộp trung bình hay gộp cực đại [45]. Cho chuỗi vector đặc trưng $\mathbf{H} = [\mathbf{h}_1, \mathbf{h}_2, \dots, \mathbf{h}_L]$, gộp chú ý tính toán trọng số quan trọng cho từng vị trí rồi tổng hợp có trọng số:

$$\alpha_i = \frac{\exp(f(\mathbf{h}_i))}{\sum_{j=1}^L \exp(f(\mathbf{h}_j))}, \quad \mathbf{v} = \sum_{i=1}^L \alpha_i \mathbf{h}_i \quad (2.7)$$

trong đó f là hàm tính điểm, thường được hiện thực hóa bằng một mạng truyền thẳng nhỏ $f(\mathbf{h}_i) = \mathbf{w}^T \tanh(\mathbf{W}\mathbf{h}_i + \mathbf{b})$ với $\mathbf{W}$, $\mathbf{w}$, $\mathbf{b}$ là các tham số học được [46]. Hàm softmax đảm bảo các trọng số α_i dương và có tổng bằng 1.

Khác với gộp cực đại chỉ giữ một giá trị và gộp trung bình đối xử đồng đều mọi vị trí, gộp chú ý học được cách phân bổ mức độ quan trọng khác nhau cho từng vị trí dựa trên nội dung. Điều này cho phép mô hình tập trung vào các vùng mang nhiều thông tin nhất trong khi vẫn tổng hợp tín hiệu từ toàn bộ chuỗi. Tuy nhiên, gộp chú ý đòi hỏi thêm tham số học và chi phí tính toán cao hơn so với các phương pháp gộp không tham số [45].

2.4 Các phương pháp tính toán cho phân loại hệ gen thực khuẩn

Nhận thức được tầm quan trọng của bài toán phân loại hệ gen thực khuẩn, nhiều phương pháp tính toán đã được phát triển trong thập kỷ qua. Các phương pháp này có thể được phân loại theo ba giai đoạn phát triển: các kỹ thuật học máy truyền thống dựa trên đặc trưng thủ công, các mô hình học sâu với khả năng tự động học biểu diễn, và các mô hình nền tảng hệ gen tận dụng học chuyển giao từ kho ngữ liệu quy mô lớn.

2.4.1 Các phương pháp học máy truyền thống

Các phương pháp học máy truyền thống tiếp cận bài toán phân loại hệ gen phage bằng cách trích xuất đặc trưng thủ công từ bộ gen thực khuẩn, sau đó sử dụng các thuật toán phân loại kinh điển. Mặc dù đạt hiệu năng cao trên bộ gen hoàn chỉnh, các phương pháp này gặp hạn chế đáng kể khi áp dụng cho dữ liệu contig phân mảnh từ phân tích hệ gen môi trường.

PHACTS [14] là một trong những công cụ tính toán đầu tiên cho bài toán này, sử dụng thuật toán Random Forest kết hợp với đặc trưng tương đồng protein. Phương pháp xây dựng một tập protein chuẩn có chú thích lỗi sống, sau đó mã hóa proteome của thực khuẩn cần phân loại thành vector tương đồng thông qua công cụ FASTA35. PHACTS đạt 99% ở chỉ số precision và có chỉ số sensitivity là 88% trên các hệ gen hoàn chỉnh [14], nhưng hiệu năng giảm mạnh trên contig ngắn, chỉ đạt khoảng 50% trên các đoạn 100–1800 bp [16], do các contig ngắn thiếu

vùng mã hóa protein hoàn chỉnh để tạo tín hiệu tương đồng đủ tin cậy.

PhageAI [47] ứng dụng kỹ thuật xử lý ngôn ngữ tự nhiên cho dữ liệu di truyền bằng cách phân tách chuỗi DNA thành các k-mer rồi sử dụng Word2Vec để tạo biểu diễn embedding. Phương pháp áp dụng Recursive Feature Elimination with Cross-Validation (RFECV) để chọn lọc đặc trưng, kết hợp với thuật toán máy vector hỗ trợ (SVM) cho phân loại. PhageAI đạt hiệu năng tốt trên bộ gen hoàn chỉnh, tuy nhiên bị hạn chế trên contig ngắn do tín hiệu ngữ cảnh không đủ để Word2Vec học được biểu diễn có ý nghĩa.

BACPHLIP [15] khai thác sự hiện diện của các vùng protein bảo tồn liên quan đến chu kỳ tiềm tan. Phương pháp sử dụng HMMER3 để nhận diện các vùng protein bảo tồn, tạo vector đặc trưng nhị phân, rồi áp dụng Random Forest cho phân loại. Tuy nhiên, BACPHLIP chỉ phù hợp với bộ gen hoàn chỉnh và trả về kết quả lỗi khi nhận đầu vào là contig phân mảnh [10].

2.4.2 Các phương pháp học sâu

Sự phát triển của công nghệ tính toán song song đã cho phép áp dụng các mô hình học sâu cho bài toán phân loại hệ gen phage, mang lại cải thiện đáng kể về hiệu năng, đặc biệt trên dữ liệu contig phân mảnh.

DeePhage [16] là phương pháp học sâu sử dụng mạng nơ-ron tích chập (CNN) huấn luyện từ đầu trên các contig từ dữ liệu hệ gen môi trường có độ dài từ 100 đến 1800 bp. Chuỗi DNA được mã hóa trực tiếp bằng phương pháp one-hot, trong đó mỗi nucleotide được biểu diễn thành vector nhị phân 4 chiều. DeePhage không phụ thuộc vào dự đoán gen và đạt độ chính xác kiểm định chéo 5 phần lên đến 89%, vượt trội so với PHACTS khoảng 30% trên cùng bộ dữ liệu [16]. Bộ chuẩn đánh giá gồm bốn nhóm độ dài contig A–D do DeePhage thiết lập cũng được sử dụng rộng rãi trong các nghiên cứu tiếp theo. Tuy nhiên, mô hình được huấn luyện từ đầu mà không tận dụng tri thức hệ gen tổng quát từ kho ngữ liệu lớn, và mã hóa one-hot tạo ra biểu diễn thừa không mang thông tin ngữ nghĩa.

PhaTYP [10] là phương pháp đầu tiên ứng dụng kiến trúc BERT cho phân loại hệ gen phage. Phương pháp hoạt động ở cấp độ protein: bộ gen thực khuẩn được dịch mã thành các protein thông qua công cụ dự đoán gen Prodigal [48], các protein đồng nhất được nhóm thành cluster, và mỗi cluster được coi là một token đầu

vào cho mô hình BERT. PhaTYP đạt hiệu năng mạnh trên contig dài, đặc biệt Nhóm D (1200–1800 bp) với 93% độ nhạy và 94% độ chính xác. Tuy nhiên, sự phụ thuộc vào Prodigal, vốn có hiệu suất giảm mạnh trên các đoạn DNA ngắn hơn 200 bp [27], dẫn đến hạn chế đáng kể trên contig ngắn và phân mảnh.

DeepPL [49] sử dụng DNABERT [37] để mã hóa trực tiếp chuỗi DNA cho phân loại lõi sống thực khuẩn thể mà không cần dự đoán gen. Phương pháp dùng phân tách k-mer có chồng lấp ($k = 6$) và phân loại theo cửa sổ trượt ngắn, sau đó gộp dự đoán của các cửa sổ để đưa ra nhãn cho cả chuỗi.

ProkBERT [50] là họ mô hình ngôn ngữ hệ gen dựa trên kiến trúc BERT, được huấn luyện trước trên kho ngữ liệu đa loài từ cơ sở dữ liệu NCBI RefSeq. Phương pháp sử dụng cơ chế phân tách token nhận thức ngữ cảnh cục bộ (Local Context-Aware, LCA), một biến thể k-mer có chồng lấp với kích thước k-mer và độ dịch chuyển điều chỉnh được, cho phép mở rộng ngữ cảnh chuỗi mà không tăng đáng kể chi phí tính toán. Do sử dụng phân tách k-mer có chồng lấp, ProkBERT vẫn chịu ảnh hưởng của rò rỉ thông tin trong quá trình tiền huấn luyện.

2.4.3 Các mô hình nền tảng hệ gen

Sự phát triển của các mô hình nền tảng hệ gen (genomic foundation models) đánh dấu bước tiến quan trọng trong phân tích chuỗi sinh học, cho phép tận dụng tri thức từ kho ngữ liệu hệ gen quy mô lớn thông qua học chuyển giao. Hai mô hình tiêu biểu trong hướng tiếp cận này là DNABERT và DNABERT-2, đã được trình bày chi tiết về mặt kiến trúc tại Mục 2.2.5.

DNABERT [37] là mô hình nền tảng áp dụng kiến trúc BERT cho phân tích chuỗi DNA, được huấn luyện trước trên hệ gen người với phân tách k-mer có chồng lấp ($k = 6$). Mặc dù mở ra hướng tiếp cận mới cho phân tích hệ gen bằng mô hình ngôn ngữ, DNABERT gặp ba hạn chế chính đã được phân tích: rò rỉ thông tin từ token chồng lấp, kém hiệu quả tính toán, và giới hạn độ dài cứng 512 token [17]. DNABERT-2 [17] khắc phục các hạn chế này thông qua BPE tokenization, mã hóa vị trí ALiBi, và Flash Attention, đồng thời mở rộng dữ liệu huấn luyện trước sang kho ngữ liệu đa loài. Trên bộ chuẩn GUE, DNABERT-2 đạt hiệu năng tương đương mô hình Nucleotide Transformer 2,5 tỉ tham số trong khi nhỏ hơn 21 lần [42], cho thấy tiềm năng lớn của các mô hình nền tảng hệ gen kích thước vừa phải khi được

thiết kế kiến trúc phù hợp.

2.4.4 So sánh tổng hợp và khoảng trống nghiên cứu

Bảng 2.1 tổng hợp so sánh các phương pháp phân loại hệ gen thực khuẩn theo các tiêu chí chính: nguồn dữ liệu, phương pháp phân tách token, thuật toán áp dụng và sử dụng mô hình tiền huấn luyện.

Bảng 2.1: So sánh tổng hợp các phương pháp phân loại hệ gen thực khuẩn

Phương pháp	Nguồn dữ liệu	Phân tách token	Thuật toán	Huấn luyện trước
PHACTS [14]	Bộ gen hoàn chỉnh	Vector tương đồng protein	Random Forest	Không
PhageAI [47]	Bộ gen hoàn chỉnh	Word2Vec (k-mer)	SVM	Có
BACPHILIP [15]	Bộ gen hoàn chỉnh	Miền protein bảo tồn	Random Forest	Không
DeePhage [16]	Contig (100–1800 bp)	Mã hóa one-hot	CNN	Không
PhaTYP [10]	Bộ gen và contig	Protein cluster	BERT	Có
DeepPL [49]	Contig	k-mer có chồng lấp	DNABERT	Có
ProkBERT [50]	Hệ gen vi sinh	LCA k-mer	BERT	Có

Qua tổng quan các công trình liên quan, có thể nhận diện một số khoảng trống nghiên cứu chính trong lĩnh vực phân loại hệ gen thực khuẩn từ dữ liệu hệ gen môi trường.

Khoảng trống đầu tiên liên quan đến sự phụ thuộc vào công cụ phát hiện gen. PhaTYP [10] phụ thuộc vào Prodigal [48] để phát hiện protein, dẫn đến thất bại trên contig ngắn vì các công cụ dự đoán gen có hiệu suất giảm mạnh trên các đoạn DNA ngắn hơn 200 bp [27]. Các contig ngắn thường không chứa gen hoàn chỉnh, khiến phương pháp dựa trên protein không khả thi cho phần lớn dữ liệu hệ gen môi trường thực tế.

Ngoài ra, hiện tượng rò rỉ thông tin từ phân tách k-mer có chồng lấp. DNABERT [37], DeepPL [49], và ProkBERT [50] đều sử dụng phân tách k-mer có chồng lấp, trong đó các token liên kế chia sẻ $k - 1$ nucleotide. Điều này gây ra rò rỉ thông tin trong quá trình học có mặt nạ, mô hình có thể suy luận được nội dung của token bị che từ các token xung quanh, làm giảm hiệu quả học biểu diễn [17].

Khoảng trống thứ ba là giới hạn về độ dài chuỗi đầu vào của các mô hình nền dựa trên DNABERT gốc. DNABERT gốc [37] chỉ xử lý tối đa 512 token mỗi lượt do sử dụng biểu diễn vị trí học được, nên các phương pháp kế thừa kiến trúc này phải

chia contig dài thành nhiều cửa sổ ngắn rồi tổng hợp dự đoán, làm hạn chế khả năng nắm bắt phụ thuộc dài hạn xuyên suốt toàn bộ contig. Trong khi đó, dữ liệu hệ gen môi trường thực tế chứa contig với độ dài biến thiên rất lớn, đặt ra nhu cầu về mô hình có thể xử lý chuỗi dài trong một lượt.

Cuối cùng, việc thiếu tri thức từ huấn luyện trước cũng là một hạn chế đáng kể. DeePhage [16] được huấn luyện từ đầu mà không tận dụng tri thức hệ gen từ kho ngữ liệu lớn, hạn chế khả năng tổng quát hóa của mô hình, đặc biệt khi phân tích các chuỗi không hoàn chỉnh với thông tin ngữ cảnh hạn chế.

Các khoảng trống này cho thấy nhu cầu phát triển các phương pháp mới có khả năng hoạt động trực tiếp trên chuỗi DNA thô, sử dụng phân tách token không gây rò rỉ thông tin, xử lý chuỗi có độ dài tùy ý, và tận dụng tri thức từ huấn luyện trước trên kho ngữ liệu hệ gen đa loài.

Chương 3

Phương pháp đề xuất

Chương này trình bày chi tiết phương pháp PhaBERT được đề xuất để dự đoán hệ gen của thực khuẩn thể từ các đoạn contig được tạo ra từ dữ liệu di truyền hoàn chỉnh của thực khuẩn, mô phỏng theo đặc điểm dữ liệu di truyền trong phân tích hệ gen môi trường. Phương pháp kết hợp mô hình nền tảng DNABERT-2 với kiến trúc chuyên biệt bao gồm nhánh CNN đa cửa sổ và nhánh tổng hợp với lớp gộp trung bình có mặt nạ. Nội dung được tổ chức như sau: tổng quan phương pháp và động lực thiết kế, quy trình xây dựng dữ liệu huấn luyện, kiến trúc mô hình, chiến lược huấn luyện hai giai đoạn và kết luận chương.

3.1 Tổng quan phương pháp

Như đã phân tích tại Phần 2.4.4, các phương pháp hiện có cho bài toán dự đoán hệ gen thực khuẩn gặp ba hạn chế chính khi áp dụng trên dữ liệu hệ gen môi trường: (1) phụ thuộc vào công cụ phát hiện protein hoặc cần dữ liệu di truyền hoàn chỉnh, dẫn đến hiệu suất giảm mạnh trên các đoạn contig ngắn; (2) rò rỉ thông tin từ phương pháp mã hóa k-mer chồng lấn, ảnh hưởng đến chất lượng biểu diễn học được; và (3) chưa tận dụng tri thức từ các mô hình tiền huấn luyện trên dữ liệu đa loài, lợi thế giúp cải thiện hiệu suất phân loại.

Để giải quyết các hạn chế trên, học viên đề xuất PhaBERT, một phương pháp học sâu kết hợp mô hình nền tảng DNABERT-2 [17] với kiến trúc MKC. Phương pháp được thiết kế với ba ưu điểm chính: (1) **Độc lập với công cụ dự đoán gen**, hoạt động trực tiếp trên chuỗi DNA đầu vào thông qua mã hóa BPE, không phụ thuộc vào công cụ phát hiện protein, cho phép dự đoán chính xác ngay cả trên các contig ngắn; (2) **Khắc phục rò rỉ thông tin**, mã hóa BPE tạo ra các token con không chồng lấn với độ dài biến đổi, giảm độ dài chuỗi khoảng 5 lần giúp tăng hiệu suất tính toán và loại bỏ hiện tượng rò rỉ thông tin vốn có trong các phương pháp k-mer chồng lấn; (3) **Tận dụng tri thức tiền huấn luyện**, DNABERT-2 đã được tiền huấn luyện trên tập dữ liệu di truyền đa loài quy mô lớn, cho phép

mô hình nắm bắt các đặc trưng phức tạp mà không cần dữ liệu huấn luyện quy mô lớn cho tác vụ cụ thể.

Hình 3.1 minh họa quy trình tiền xử lý dữ liệu, bao gồm năm bước: chia dữ liệu ở mức hệ gen, tạo contig bằng cửa sổ trượt từ hệ gen hoàn chỉnh, tăng cường dữ liệu bằng chuỗi bổ sung đảo ngược, cân bằng lớp bằng lấy mẫu giảm ngẫu nhiên và mã hóa BPE chuyển đổi contig thành chuỗi token. Hình 3.2 minh họa kiến trúc mô hình PhaBERT với ba thành phần chính: DNABERT-2 tạo biểu diễn ngữ cảnh 768 chiều cho mỗi vị trí token, mô-đun MKC, được điều chỉnh từ kiến trúc TextCNN [34], trích xuất đặc trưng cục bộ đa tỷ lệ qua các nhánh tích chập song song đồng thời tổng hợp thông tin toàn cục qua gộp trung bình có mặt nạ, và bộ phân loại đưa ra dự đoán thực khuẩn thể thuộc lớp độc lực hay ôn hòa.

Về chiến lược huấn luyện, PhaBERT áp dụng quy trình hai giai đoạn nhằm tận dụng tối đa tri thức tiền huấn luyện của DNABERT-2 đồng thời tránh hiện tượng mô hình quên đi tri thức đã học khi tiếp thu kiến thức mới. Trong giai đoạn khởi động, toàn bộ tham số của DNABERT-2 được đóng băng và chỉ các lớp phía sau dành cho tác vụ được huấn luyện, giúp khởi tạo ổn định các thành phần mới trước khi tinh chỉnh toàn bộ mô hình. Giai đoạn tiếp theo mở khóa mạng nền và áp dụng tốc độ học phân biệt, tốc độ học thấp hơn cho DNABERT-2 và cao hơn cho các lớp tác vụ, nhằm bảo toàn tri thức tiền huấn luyện trong khi thích nghi với tác vụ phân loại hệ gen. Nền tảng cho toàn bộ quy trình trên là tập dữ liệu huấn luyện được xây dựng từ bộ dữ liệu di truyền hoàn chỉnh của thực khuẩn như được trình bày dưới đây.


3.2 Thu thập dữ liệu và tiền xử lý

Tập dữ liệu huấn luyện được xây dựng bằng cách tích hợp và tinh chỉnh các bộ hệ gen từ hai nghiên cứu trước về phân loại hệ gen thực khuẩn thể. DeePhage [16] cung cấp tập dữ liệu gồm hai phần: phần thứ nhất là tập được kiểm duyệt thủ công, xác minh qua đối chiếu tài liệu thực nghiệm; phần thứ hai là dữ liệu thu thập từ NCBI, sử dụng phương pháp tin sinh học của Mavrich và Hatfull [51] để gán nhãn. DeepPL [49] tiếp đó thực hiện tinh chỉnh và thu thập thêm dữ liệu từ NCBI. Sau khi tổng hợp, tập dữ liệu kết hợp bao gồm 2.241 hệ gen thực khuẩn thể hoàn chỉnh, trong đó 707 hệ gen thuộc lớp ôn hòa (nhãn 0) và 1.534 hệ gen

thuộc lớp độc lực (nhân 1). Tỷ lệ giữa hai lớp xấp xỉ 2:1 cho thấy sự mất cân bằng nhẹ cần được xử lý trong quá trình huấn luyện. Để đảm bảo độ tin cậy của đánh giá, học viên áp dụng kiểm định chéo phân tầng 5 phần, với cách chia phần và quy trình tiền xử lý được trình bày dưới đây.

Quy trình tiền xử lý được tổ chức thành một pipeline gồm năm bước. Bước đầu chia dữ liệu ở mức hệ gen thành 5 phần và chỉ thực hiện một lần; bốn bước còn lại, gồm tạo contig, tăng cường dữ liệu, lấy mẫu giảm ngẫu nhiên và mã hóa BPE, được áp dụng độc lập trong mỗi phần, riêng cho tập huấn luyện và tập kiểm định.

Hình 3.1 minh họa pipeline này.



Hình 3.1: Pipeline tiền xử lý năm bước: chia dữ liệu ở mức hệ gen (5-fold phân tầng), tạo contig bằng cửa sổ trượt, tăng cường dữ liệu bằng chuỗi bổ sung đảo ngược, cân bằng lớp bằng lấy mẫu giảm ngẫu nhiên chỉ trên tập huấn luyện và mã hóa BPE

Bước 1: Chia dữ liệu ở mức hệ gen. Toàn bộ 2.241 hệ gen hoàn chỉnh được chia thành 5 phần theo phương pháp phân tầng với tỷ lệ huấn luyện:kiểm định là 8:2, giữ phân bố ôn hòa:độc lực nhất quán qua các lần chia; mỗi hệ gen chỉ thuộc tập huấn luyện hoặc tập kiểm định trong một phần, không xuất hiện đồng thời ở cả hai. Việc chia được đặt ở bước đầu tiên, trước khi cắt contig, nhằm tránh rò rỉ thông tin giữa tập huấn luyện và tập kiểm định. Như trình bày ở Bước 2, mỗi

hệ gen được cắt thành nhiều contig chồng lẫn bằng cửa sổ trượt, nên các contig sinh ra từ cùng một hệ gen chia sẻ những đoạn DNA trùng nhau; nếu chia phần sau khi đã cắt, các contig gần giống hết nhau từ cùng một hệ gen có thể đồng thời rơi vào cả hai tập, khiến mô hình được đánh giá trên dữ liệu đã gián tiếp thấy khi huấn luyện và làm kết quả thổi phồng. Chia ở mức hệ gen loại bỏ nguy cơ này.

Bước 2: Tạo contig bằng phương pháp cửa sổ trượt. Trong thực tế, dữ liệu thực khuẩn thể thu được từ phân tích dữ liệu hệ gen môi trường thường ở dạng các đoạn DNA ngắn không hoàn chỉnh. Để mô phỏng kịch bản này, trên tập hệ gen đã chia của mỗi fold, học viên tạo contig từ DNA hoàn chỉnh của thực khuẩn bằng phương pháp cửa sổ trượt. Với mỗi lần trượt, độ dài cửa sổ được lấy mẫu ngẫu nhiên từ phân phối chuẩn $\mathcal{N}(\mu_{\text{group}}, \sigma_{\text{group}}^2)$ và được giới hạn trong phạm vi của nhóm tương ứng. Vị trí bắt đầu của cửa sổ tiếp theo được tính bằng $\text{pos} \leftarrow \text{pos} + \text{length} \times (1 - \text{overlap_ratio}_{\text{group}})$, tạo ra sự chồng lẫn có kiểm soát giữa các contig liên tiếp. Ví dụ, với nhóm B có $\mu = 600$ bp, $\sigma = 100$ bp và tỷ lệ chồng lẫn 20%, giả sử độ dài cửa sổ được lấy mẫu là 580 bp: contig đầu tiên bao phủ vị trí 1–580, contig thứ hai bắt đầu tại vị trí $1 + 580 \times 0,8 = 465$, tức bao phủ vị trí 465–1044, với vùng chồng lẫn 116 bp (vị trí 465–580) giữa hai contig liên tiếp. Quá trình tiếp tục cho đến khi hết chuỗi DNA. Học viên chia contig thành bốn nhóm độ dài: A (100–400 bp), B (400–800 bp), C (800–1.200 bp) và D (1.200–1.800 bp) với các tham số được trình bày trong Bảng 3.1. Tỷ lệ chồng lẫn tăng dần theo độ dài nhóm: nhóm ngắn (A) sử dụng tỷ lệ chồng lẫn thấp để tránh tạo quá nhiều contig tương tự và giảm dư thừa, trong khi nhóm dài (D) sử dụng tỷ lệ chồng lẫn cao hơn để tăng số lượng mẫu và đa dạng hóa dữ liệu, đặc biệt quan trọng vì contig dài tự nhiên có số lượng ít hơn.

Bước 3: Tăng cường dữ liệu bằng chuỗi bổ sung đảo ngược. DNA có cấu trúc sợi đôi, trong đó cả hai hướng đọc đều mang thông tin sinh học tương đương. Tận dụng đặc tính này, với mỗi contig học viên tạo thêm chuỗi bổ sung đảo ngược theo quy tắc bổ sung: $A \leftrightarrow T$, $C \leftrightarrow G$ (nếu trong chuỗi có U thì được xử lý tương tự T). Ví dụ:

Chuỗi gốc: ATCGATCG

Chuỗi bổ sung: TAGCTAGC

Chuỗi bổ sung đảo ngược: CGATCGAT

Phép biến đổi này tăng gấp đôi kích thước tập dữ liệu mà không cần thu thập thêm

dữ liệu, đồng thời giúp mô hình học được tính bất biến theo hướng đọc, phản ánh thực tế rằng dữ liệu giải trình tự có thể đến từ cả hai sợi của phân tử DNA.

Bước 4: Xử lý mất cân bằng lớp bằng lấy mẫu giảm ngẫu nhiên. Sau khi thực hiện tăng cường dữ liệu, số lượng contig giữa hai lớp bị chênh lệch đáng kể do thực khuẩn thể ôn hoà có chuỗi DNA dài hơn thực khuẩn thể độc lực nhiều, ảnh hưởng đến quá trình huấn luyện. Để giải quyết vấn đề này, học viên áp dụng phương pháp lấy mẫu giảm ngẫu nhiên trên tập huấn luyện: giữ nguyên toàn bộ mẫu của lớp thiểu số (ôn hòa) và chọn ngẫu nhiên số lượng mẫu tương đương từ lớp đa số (độc lực), tạo ra tập huấn luyện cân bằng với tỷ lệ 1:1. Phương pháp này được lựa chọn vì tính đơn giản, hiệu quả và phù hợp với số lượng contig được sinh ra sau bước 2 và bước 3. Điều quan trọng là phương pháp lấy mẫu giảm ngẫu nhiên chỉ được áp dụng trên tập huấn luyện trong từng fold; tập kiểm định giữ nguyên phân bố gốc để đánh giá hiệu suất trên phân bố thực tế. Bảng 3.2 tổng hợp thống kê số lượng contig sau tăng cường dữ liệu (trước khi áp dụng lấy mẫu giảm ngẫu nhiên).

Bước 5: Mã hóa BPE. Sau khi hoàn tất các bước tiền xử lý, mỗi contig được chuyển đổi thành chuỗi token thông qua mã hóa BPE [36]. Khác với phương pháp k-mer chồng lấn truyền thống, BPE tạo ra các token con không chồng lấn với độ dài biến đổi, giảm độ dài chuỗi khoảng 5 lần và loại bỏ hiện tượng rò rỉ thông tin. Chuỗi token thu được sau đó được đưa vào DNABERT-2 để tạo ra các vector biểu diễn ngữ cảnh 768 chiều cho mỗi vị trí, làm đầu vào cho mô-đun MKC trong giai đoạn huấn luyện và suy luận.

Bảng 3.1: Tham số cửa sổ trượt cho các nhóm độ dài contig

Nhóm	Phạm vi (bp)	μ (bp)	σ (bp)	Tỷ lệ chồng lấn
A	100–400	250	75	10%
B	400–800	600	100	20%
C	800–1.200	1.000	100	30%
D	1.200–1.800	1.500	150	40%

Bảng 3.2: Thống kê số lượng contig sau tăng cường dữ liệu

Nhóm	Tập	Ôn hòa	Độc lực	Tổng
A (100–400 bp)	Huấn luyện	230.156	230.156	460.312
	Kiểm định	57.366	215.054	272.420
B (400–800 bp)	Huấn luyện	95.750	95.750	191.500
	Kiểm định	23.804	89.404	113.208
C (800–1.200 bp)	Huấn luyện	64.162	64.162	128.324
	Kiểm định	15.992	60.148	76.140
D (1.200–1.800 bp)	Huấn luyện	48.626	48.626	97.252
	Kiểm định	12.102	45.698	57.800

3.3 Kiến trúc PhaBERT


Kiến trúc PhaBERT được xây dựng từ ba thành phần chính hoạt động tuần tự: (1) mạng nền DNABERT-2 đóng vai trò trích xuất đặc trưng ngữ cảnh từ chuỗi DNA, (2) mô-đun MKC tiếp tục xử lý các biểu diễn đầu ra của DNABERT-2 và (3) bộ phân loại đưa ra dự đoán nhị phân. Hình 3.2 minh họa kiến trúc tổng thể của mô hình.

3.3.1 Mạng nền DNABERT-2

DNABERT-2 [17] đóng vai trò là mạng nền trích xuất đặc trưng, chuyển đổi chuỗi DNA thô thành các vector biểu diễn 768 chiều. Như đã trình bày chi tiết tại Mục 2.2.5, DNABERT-2 sử dụng mã hóa BPE [36] để phân tách chuỗi DNA thành các token con không chồng lấn, giảm độ dài chuỗi khoảng 5 lần và loại bỏ hiện tượng rò rỉ thông tin vốn có trong các phương pháp k-mer chồng lấn. Chuỗi DNA đầu vào $S = \{s_1, s_2, \dots, s_L\}$ với độ dài L nucleotide được mã hóa như sau:

$$T = \text{BPE}(S) = \{t_1, t_2, \dots, t_n\}, \quad n \approx L/5 \quad (3.1)$$

Mã hóa BPE tạo ra các token con không chồng lấn với độ dài biến đổi, giúp giảm độ dài chuỗi token khoảng 5 lần so với phương pháp k-mer truyền thống [17]. Chuỗi



Hình 3.2: Kiến trúc chi tiết của PhaBERT

token T thu được sau đó được đưa qua DNABERT-2 để tạo ra các biểu diễn ngữ cảnh:

$$\mathbf{H} = \text{DNABERT-2}(T) = \{\mathbf{h}_1, \mathbf{h}_2, \dots, \mathbf{h}_n\}, \quad \mathbf{h}_i \in \mathbb{R}^{768} \quad (3.2)$$

trong đó mỗi vector $\mathbf{h}_i$ mã hóa thông tin của token tương ứng cùng mối quan hệ ngữ cảnh với các token xung quanh thông qua cơ chế tự chú ý. DNABERT-2 sử dụng phương pháp chú ý với thiên lệch tuyến tính ALiBi [40] thay vì biểu diễn vị trí cố định, cho phép mô hình xử lý các chuỗi có độ dài tùy ý mà không cần huấn luyện lại, đặc biệt quan trọng cho dữ liệu hệ metagenome với độ biến thiên về độ dài lớn. Trong giai đoạn khởi động, toàn bộ tham số của DNABERT-2 được đóng băng; trong giai đoạn tinh chỉnh, mô hình nền được mở khóa và cập nhật với tốc độ học thấp để bảo toàn tri thức tiền huấn luyện.

3.3.2 Mô-đun MKC

Từ các biểu diễn ngữ cảnh $\mathbf{H} = \{\mathbf{h}_1, \dots, \mathbf{h}_n\} \in \mathbb{R}^{n \times 768}$ được trích xuất từ DNABERT-2, mô-đun MKC được thiết kế gồm hai nhánh xử lý song song với chức năng bổ trợ lẫn nhau: nhánh CNN đa kích thước của sổ thực hiện trích xuất đặc trưng cục bộ ở nhiều tỷ lệ khác nhau, trong khi nhánh gộp trung bình có mặt nạ tổng hợp

thông tin toàn cục bằng cách tính giá trị trung bình trên toàn bộ các token thực, qua đó loại bỏ ảnh hưởng của các token đệm.

Nhánh CNN đa cửa sổ

Nhánh mạng nơ-ron tích chập đa cửa sổ được điều chỉnh từ kiến trúc TextCNN [34], vốn được đề xuất cho bài toán phân loại văn bản với các bộ lọc tích chập song song có kích thước khác nhau. So với kiến trúc gốc vốn áp dụng trực tiếp lên các biểu diễn từ tĩnh, thiết kế trong nghiên cứu này thực hiện hai điều chỉnh chính: (1) thay thế đầu vào bằng các biểu diễn ngữ cảnh 768 chiều từ DNABERT-2, qua đó tận dụng tri thức tiền huấn luyện trên dữ liệu đa loài thay vì sử dụng embedding khởi tạo ngẫu nhiên; và (2) bổ sung thêm một lớp tích chập xếp chồng cho mỗi nhánh con, tạo thành hai lớp Conv1d liên tiếp nhằm tăng cường khả năng trích xuất đặc trưng phân cấp [52]. Thiết kế đa kích thước cửa sổ song song kế thừa từ TextCNN cho phép mô hình đồng thời nắm bắt các đặc trưng ở nhiều tỷ lệ không gian khác nhau trong một lượt lan truyền thuận, thay vì phụ thuộc vào một kích thước cửa sổ cố định duy nhất.

Cụ thể, nhánh này sử dụng ba nhánh con tích chập song song với các kích thước cửa sổ $k \in \{3, 5, 7\}$. Mỗi nhánh con nhận đầu vào là ma trận chuyển vị $\mathbf{H}^T \in \mathbb{R}^{768 \times n}$ (nhằm phù hợp với định dạng đầu vào của Conv1d) và xử lý qua hai lớp tích chập xếp chồng với giá trị padding tương ứng $\lfloor k/2 \rfloor$ để bảo toàn chiều dài chuỗi:

$$\mathbf{X}_1^{(k)} = \text{ReLU}(\text{BN}(\text{Conv1d}_{k, 768 \rightarrow 256}(\mathbf{H}^T))) \in \mathbb{R}^{256 \times n} \quad (3.3)$$

$$\mathbf{X}_2^{(k)} = \text{ReLU}(\text{BN}(\text{Conv1d}_{k, 256 \rightarrow 128}(\mathbf{X}_1^{(k)}))) \in \mathbb{R}^{128 \times n} \quad (3.4)$$

$$\mathbf{f}^{(k)} = \text{AdaptiveMaxPool1d}(\mathbf{X}_2^{(k)}) \in \mathbb{R}^{128} \quad (3.5)$$

trong đó BN ký hiệu cho BatchNorm1d. Lớp tích chập thứ nhất giảm chiều từ 768 xuống 256 kênh; lớp thứ hai nén tiếp xuống 128 kênh. BatchNorm1d và ReLU được áp dụng sau mỗi lớp tích chập nhằm ổn định quá trình huấn luyện. AdaptiveMaxPool1d trích xuất đặc trưng nổi bật nhất theo chiều chuỗi, tạo ra vector đặc trưng cố định 128 chiều bất kể độ dài contig đầu vào.

Ba kích thước cửa sổ tích chập được lựa chọn nhằm nắm bắt các mẫu đặc trưng ở các tỷ lệ không gian khác nhau trên không gian biểu diễn của DNABERT-2. Cụ

thể, cửa sổ tích chập kích thước 3 tập trung vào các tương quan cục bộ giữa các token lân cận, cửa sổ tích chập kích thước 5 mở rộng phạm vi tiếp nhận sang các mẫu tầm trung trải dài qua nhiều token hơn, và cửa sổ tích chập kích thước 7 tổng hợp thông tin từ vùng ngữ cảnh rộng hơn. Cần lưu ý rằng do đầu vào của mô-đun CNN là các biểu diễn ngữ cảnh từ DNABERT-2 chứ không phải chuỗi nucleotide thô, kích thước cửa sổ tích chập ở đây phản ánh phạm vi tương tác trong không gian đặc trưng học được và không tương ứng trực tiếp với số lượng nucleotide trên trình tự gốc. Ba vector đặc trưng thu được từ các nhánh con được ghép nối tạo thành biểu diễn CNN tổng hợp:

$$\mathbf{f}_{\text{CNN}} = \left[\mathbf{f}^{(3)}; \mathbf{f}^{(5)}; \mathbf{f}^{(7)} \right] \in \mathbb{R}^{384} \quad (3.6)$$

Nhánh Masked Mean Pooling toàn cục

Nhánh thứ hai áp dụng phương pháp gộp trung bình có mặt nạ để tổng hợp thông tin ở mức toàn chuỗi từ các trạng thái ẩn của DNABERT-2. Lớp gộp trung bình có mặt nạ tính giá trị trung bình cộng trên tất cả các token thực, qua đó đảm bảo tính bất định của phép tổng hợp và giảm nguy cơ quá khớp trên tập huấn luyện có kích thước hạn chế. Cho tập các trạng thái ẩn $\mathbf{H} = \{\mathbf{h}_1, \dots, \mathbf{h}_n\}$ từ DNABERT-2 và mặt nạ chú ý $\mathbf{m} \in \{0, 1\}^n$ (trong đó $m_t = 1$ ứng với token thực và $m_t = 0$ ứng với token đệm), biểu diễn toàn cục được tính như sau:

$$\mathbf{g} = \frac{\sum_{t=1}^n m_t \cdot \mathbf{h}_t}{\sum_{t=1}^n m_t} \in \mathbb{R}^{768} \quad (3.7)$$

Vector biểu diễn tổng hợp $\mathbf{g}$ sau đó được chiếu xuống không gian đặc trưng có số chiều thấp hơn thông qua một lớp tuyến tính kết hợp hàm kích hoạt và điều chuẩn:

$$\mathbf{f}_{\text{global}} = \text{Dropout}(\text{ReLU}(\mathbf{W}_g \mathbf{g} + \mathbf{b}_g)) \in \mathbb{R}^{128} \quad (3.8)$$

trong đó $\mathbf{W}_g \in \mathbb{R}^{128 \times 768}$ và $\mathbf{b}_g \in \mathbb{R}^{128}$ lần lượt là ma trận trọng số và vector hệ số dịch của phép chiếu tuyến tính, tỷ lệ dropout được đặt bằng 0,1. Việc sử dụng mặt nạ trong phép gộp trung bình nhằm loại bỏ ảnh hưởng của các token đệm, vốn được thêm vào do các chuỗi trong cùng một batch có độ dài khác nhau, đảm bảo

rằng chỉ các token thực sự mang thông tin sinh học mới đóng góp vào biểu diễn toàn cục của chuỗi.

3.3.3 Kết hợp đặc trưng và đầu phân loại

Dầu ra từ cả hai nhánh được ghép nối để tạo biểu diễn tổng hợp:

$$\mathbf{f}_{\text{combined}} = [\mathbf{f}_{\text{global}}; \mathbf{f}_{\text{CNN}}] = [\mathbf{f}_{\text{global}}; \mathbf{f}^{(3)}; \mathbf{f}^{(5)}; \mathbf{f}^{(7)}] \in \mathbb{R}^{512} \quad (3.9)$$

Vector 512 chiều này kết hợp biểu diễn toàn cục từ masked mean pooling (128 chiều) và đặc trưng cục bộ đa kernel từ các nhánh CNN (384 chiều). Biểu diễn tổng hợp được đưa qua đầu phân loại gồm ba lớp tuyến tính với kích thước giảm dần $512 \rightarrow 256 \rightarrow 64 \rightarrow 2$:

$$\mathbf{z}_1 = \text{Dropout}(\text{ReLU}(\text{LayerNorm}(\mathbf{W}_1 \mathbf{f}_{\text{combined}} + \mathbf{b}_1))), \quad \mathbf{z}_1 \in \mathbb{R}^{256} \quad (3.10)$$

$$\mathbf{z}_2 = \text{Dropout}(\text{ReLU}(\mathbf{W}_2 \mathbf{z}_1 + \mathbf{b}_2)), \quad \mathbf{z}_2 \in \mathbb{R}^{64} \quad (3.11)$$

$$\mathbf{z}_3 = \mathbf{W}_3 \mathbf{z}_2 + \mathbf{b}_3 \in \mathbb{R}^2 \quad (3.12)$$

trong đó $\mathbf{W}_1 \in \mathbb{R}^{256 \times 512}$, $\mathbf{W}_2 \in \mathbb{R}^{64 \times 256}$, $\mathbf{W}_3 \in \mathbb{R}^{2 \times 64}$ là các ma trận trọng số, và dropout rate = 0.1 được áp dụng sau mỗi lớp ẩn để chính quy hóa. Layer Normalization sau lớp đầu tiên ổn định quá trình huấn luyện. Logit nhị phân $\mathbf{z}_3 = [z_{\text{temp}}, z_{\text{vir}}]$ được chuyển thành xác suất qua softmax:

$$P(\text{virulent}|S) = \frac{\exp(z_{\text{vir}})}{\exp(z_{\text{temp}}) + \exp(z_{\text{vir}})} \quad (3.13)$$

Dự đoán cuối cùng là $\hat{y} = \text{argmax}(\text{softmax}(\mathbf{z}_3))$, trong đó $\hat{y} = 0$ tương ứng với thực khuẩn thể ôn hòa (temperate) và $\hat{y} = 1$ tương ứng với thực khuẩn thể độc lực (virulent). Với kiến trúc đã xác định, vấn đề then chốt tiếp theo là chiến lược huấn luyện để tối ưu hóa hiệu quả các thành phần này.

3.4 Chiến lược huấn luyện và tinh chỉnh

Việc tinh chỉnh một mô hình tiền huấn luyện với các lớp đặc thù cho tác vụ được khởi tạo ngẫu nhiên có thể gây ra bất ổn định trong quá trình huấn luyện do sự

không tương thích gradient giữa các trọng số tiền huấn luyện và các trọng số ngẫu nhiên. Để giải quyết vấn đề này, học viên áp dụng chiến lược tinh chỉnh hai giai đoạn: giai đoạn khởi động khởi tạo tham số cho các lớp thuộc MKC trước, sau đó giai đoạn tinh chỉnh toàn bộ mô hình với tốc độ học phân biệt tối ưu hóa toàn bộ kiến trúc.

3.4.1 Giai đoạn 1: Khởi động

Trong giai đoạn khởi động, toàn bộ tham số của DNABERT-2 (117M tham số) được đóng băng, chỉ các lớp thuộc MKC được huấn luyện trong 1 epoch. Mục đích của giai đoạn này là cho phép các lớp được khởi tạo ngẫu nhiên học được cấu hình tham số phù hợp với các biểu diễn DNABERT-2 đã đóng băng trước khi thực hiện bất kỳ cập nhật nào lên các trọng số tiền huấn luyện. Việc đóng băng mô hình nền ngăn chặn các gradient lớn từ các lớp ngẫu nhiên lan truyền ngược qua DNABERT-2, bảo toàn tri thức genomic đã học. Các lớp đặc thù cho tác vụ được tối ưu hóa bằng AdamW [53] với tốc độ học 2×10^{-3} , hệ số suy giảm trọng số 1×10^{-4} , và các hệ số momentum $\beta_1 = 0.9$, $\beta_2 = 0.999$. Tốc độ học tuân theo lịch trình one-cycle [54] với 30% giai đoạn khởi động, hệ số chia ban đầu bằng 5 và hệ số chia cuối bằng 10.

3.4.2 Giai đoạn 2: Tinh chỉnh đầy đủ

Sau giai đoạn khởi động, toàn bộ kiến trúc được mở khóa và tối ưu hóa với tốc độ học phân biệt—chiến lược áp dụng tốc độ học khác nhau cho các thành phần khác nhau của mô hình [55]. Cụ thể, các tham số DNABERT-2 được cập nhật với tốc độ học 1×10^{-5} và hệ số suy giảm trọng số 1×10^{-5} để cho phép thích nghi nhẹ nhàng với tác vụ phân loại thực khuẩn thể mà không làm mất các tri thức học trong quá trình tiền huấn luyện. Trong khi đó, các lớp đặc thù cho tác vụ (CNN, global pooling, lớp phân loại) nhận tốc độ học 1×10^{-4} với hệ số suy giảm trọng số 1×10^{-4} , cao gấp 10 lần so với mô hình DNABERT-2, để cho phép tối ưu hóa tích cực hơn nhằm nắm bắt các đặc trưng đặc thù của hệ gen thực khuẩn. Cả hai nhóm tham số đều sử dụng AdamW [53] với $\beta_1 = 0.9$, $\beta_2 = 0.999$, $\epsilon = 10^{-6}$. Giai đoạn tinh chỉnh sử dụng lịch trình one-cycle [54] với 10% giai đoạn khởi động, hệ số chia ban đầu bằng 5 và hệ số chia cuối bằng 50, kéo dài tối đa 10 epoch. Học

viên áp dụng chiến lược dừng sớm dựa trên độ chính xác trên tập kiểm định với ngưỡng kiên nhẫn 3 epoch để ngăn hiện tượng quá khớp.

3.4.3 Hàm mục tiêu và kỹ thuật chính quy hóa

Học viên sử dụng hàm binary cross-entropy làm mục tiêu tối ưu hóa cho tác vụ phân loại nhị phân:

$$\mathcal{L}_{\text{BCE}} = -\frac{1}{N} \sum_{i=1}^N [y_i \log(\hat{y}_i) + (1 - y_i) \log(1 - \hat{y}_i)] \quad (3.14)$$

trong đó N là batch size, $y_i \in \{0, 1\}$ là nhãn thực (0 = temperate, 1 = virulent), và $\hat{y}_i = P(\text{virulent}|S_i)$ là xác suất dự đoán. Để ngăn hiện tượng quá khớp, học viên kết hợp nhiều kỹ thuật chính quy hóa: **Suy Giảm Trọng Số** thông qua AdamW với $\lambda = 1 \times 10^{-4}$ cho các lớp đặc thù cho tác vụ và $\lambda = 1 \times 10^{-5}$ cho DNABERT-2; **Dropout** với rate = 0.1 được áp dụng sau global pooling và trong đầu phân loại; **Layer Normalization** ổn định quá trình huấn luyện và cải thiện khả năng tổng quát hóa; và **Dừng Sớm** dừng huấn luyện khi hiệu suất kiểm định không cải thiện sau 3 epoch liên tiếp.

Bảng 3.3 tổng hợp các siêu tham số huấn luyện cho cả hai giai đoạn.

Bảng 3.3: Tổng hợp siêu tham số huấn luyện

Siêu tham số	Giai đoạn 1 (Khởi động)	Giai đoạn 2 (Tĩnh chỉnh)
Số epoch tối đa	1	10
Optimizer	AdamW	AdamW
Tốc độ học (mạng nền)	— (đóng băng)	1×10^{-5}
Tốc độ học (đặc thù tác vụ)	2×10^{-3}	1×10^{-4}
Suy giảm trọng số (mạng nền)	—	1×10^{-5}
Suy giảm trọng số (đặc thù tác vụ)	1×10^{-4}	1×10^{-4}
β_1, β_2	0.9, 0.999	0.9, 0.999
Lịch trình tốc độ học	One-cycle (30% warmup)	One-cycle (10% warmup)
Dropout rate	0.1	0.1
Batch size (effective)	32	32
Dừng sớm	—	Patience = 3

3.5 Kết luận

Chương này đã trình bày phương pháp PhaBERT cho bài toán dự đoán hệ gen thực khuẩn thể từ contig thu được qua phân tích hệ gen môi trường. Phương pháp kết hợp mô hình nền tảng DNABERT-2 với mô-đun MKC gồm nhánh CNN đa kernel và gộp trung bình có mặt nạ toàn cục, hoạt động trực tiếp trên chuỗi DNA thô mà không phụ thuộc vào công cụ dự đoán gen. Chiến lược huấn luyện hai giai đoạn với tốc độ học phân biệt cho phép bảo toàn tri thức tiền huấn luyện trong khi thích nghi hiệu quả với tác vụ phân loại. Chương tiếp theo đánh giá hiệu suất của PhaBERT thông qua kiểm định chéo 5 phần phân tầng, so sánh với các phương pháp tiên tiến PhaTYP, DeePhage và ProkBERT trên bốn nhóm độ dài contig từ 100 đến 1.800 bp.

Chương 4

Thực nghiệm và Đánh giá

Chương này trình bày các thực nghiệm được thực hiện để đánh giá hiệu suất của PhaBERT trong bài toán phân loại hệ gen thực khuẩn thể. Quy trình xây dựng tập dữ liệu, kiến trúc mô hình và chiến lược huấn luyện đã được mô tả chi tiết trong Chương 3, chương này tập trung vào đánh giá thực nghiệm, so sánh với các phương pháp tiên tiến, và phân tích hiệu quả của phương pháp đề xuất. Nội dung được tổ chức như sau: thiết lập thực nghiệm và môi trường tính toán, kết quả so sánh trên bốn nhóm độ dài contig, thảo luận về các yếu tố đóng góp vào hiệu suất cùng ý nghĩa thực tiễn của cải thiện, và kết luận chương.

4.1 Thiết lập thực nghiệm

Tập dữ liệu được xây dựng theo quy trình mô tả trong Phần 3.2, bao gồm 2.241 hệ gen thực khuẩn thể hoàn chỉnh (707 ôn hòa và 1.534 độc lực), được chia thành bốn nhóm theo độ dài contig: A (100–400 bp), B (400–800 bp), C (800–1.200 bp) và D (1.200–1.800 bp). Việc phân chia thành bốn nhóm độ dài theo DeePhage [16] cho phép đánh giá một cách có hệ thống ảnh hưởng của độ dài contig đến hiệu suất phân loại, một yếu tố đặc biệt quan trọng trong phân tích dữ liệu hệ gen môi trường, nơi các contig thu được sau quá trình lắp ráp thường có độ dài biến thiên lớn [56]. Các contig được tạo bằng phương pháp cửa sổ trượt với bộ tham số riêng cho từng nhóm (Bảng 3.1), sau đó được tăng cường bằng chuỗi bổ sung đảo ngược và cân bằng lớp bằng phương pháp lấy mẫu giảm ngẫu nhiên trên tập huấn luyện (Bảng 3.2). Quá trình đánh giá được thực hiện theo phương pháp kiểm định chéo phân tầng 5 phần với tỷ lệ huấn luyện:kiểm định là 8:2 trong mỗi phần, nhằm đảm bảo phân bố lớp nhất quán giữa các tập con [16].

PhaBERT được so sánh với bốn phương pháp đại diện cho các hướng tiếp cận khác nhau trong bài toán phân loại hệ gen thực khuẩn thể: (1) DNABERT-2 [17] với đầu phân loại tuyến tính đơn giản, đóng vai trò đường cơ sở trực tiếp để đánh giá đóng góp riêng của kiến trúc MKC; (2) DeePhage [16], phương pháp học sâu

sử dụng mạng nơ-ron tích chập trên mã hóa one-hot mà không qua giai đoạn tiền huấn luyện; (3) PhaTYP [10], phương pháp dựa trên BERT với đặc trưng protein được hỗ trợ bởi Prodigal [48]; và (4) ProkBERT [50], mô hình BERT tiền huấn luyện trên hệ gen sinh vật nhân sơ với phương pháp mã hóa LCA k-mer chồng lấn. Bốn phương pháp được lựa chọn đại diện cho các chiến lược biểu diễn chuỗi khác nhau: mã hóa BPE (DNABERT-2 và PhaBERT), mã hóa dựa trên protein (PhaTYP), mã hóa one-hot (DeePhage) và mã hóa k-mer (ProkBERT), cho phép đánh giá toàn diện ảnh hưởng của chiến lược biểu diễn đầu vào đến hiệu suất phân loại. Nhằm đảm bảo so sánh công bằng, tất cả các phương pháp được đưa vào so sánh đều được huấn luyện và đánh giá trên cùng tập dữ liệu, cùng cách chia kiểm định chéo phân tầng 5 phần như PhaBERT.

Hiệu suất phân loại được đánh giá bằng ba chỉ số, nhất quán với các nghiên cứu trước [10, 16]: độ nhạy (*sensitivity*, $S_n = TP/(TP + FN)$) đo khả năng phát hiện đúng thực khuẩn thể độc lực, độ đặc hiệu (*specificity*, $S_p = TN/(TN + FP)$) đo khả năng nhận diện đúng thực khuẩn thể ôn hòa, và độ chính xác tổng thể (*accuracy*, $Acc = (TP + TN)/(TP + FN + TN + FP)$) đo hiệu suất phân loại trên toàn bộ tập dữ liệu.

4.2 Tài nguyên tính toán

Tất cả các thực nghiệm được thực hiện trên môi trường phần cứng bao gồm GPU NVIDIA RTX 5070Ti, CPU Intel i5 13500, và 64GB RAM. Môi trường phần mềm sử dụng Python 3.10 làm ngôn ngữ lập trình chính, kết hợp với PyTorch 2.1.0 và CUDA 12.1 cho việc huấn luyện mô hình học sâu trên GPU. Thư viện Transformers phiên bản 4.28.0 từ Hugging Face được sử dụng để tải và tinh chỉnh mô hình DNABERT-2 tiền huấn luyện. Ngoài ra, các thư viện hỗ trợ bao gồm NumPy 1.26.4 cho xử lý mảng số, Pandas 2.2.3 cho thao tác dữ liệu dạng bảng, Scikit-learn 1.6.1 cho các phương pháp học máy baseline và đánh giá mô hình, BioPython 1.85 cho xử lý chuỗi sinh học, và Matplotlib 3.9.4 cùng Seaborn 0.13.2 cho trực quan hóa kết quả.

4.3 Kết quả thực nghiệm

4.3.1 Đánh giá đóng góp của MKC

Để đánh giá đóng góp của kiến trúc chuyên biệt cho tác vụ, học viên thực hiện nghiên cứu loại bỏ thành phần nhằm so sánh bảy cấu hình: (1) đường cơ sở DNABERT-2, tức mô hình DNABERT-2 chỉ với đầu phân loại tuyến tính đơn giản, không tích hợp mô-đun MKC; (2) PhaBERT, kiến trúc đề xuất đầy đủ với nhánh CNN đa cửa sổ kết hợp gộp trung bình có mặt nạ toàn cục; (3) DNABERT-2-CNN, biến thể chỉ sử dụng nhánh CNN đa cửa sổ mà không có nhánh gộp toàn cục; (4) DNABERT-2-P, biến thể thay thế toàn bộ mô-đun MKC bằng cơ chế gộp chú ý; (5) PhaBERT-NO-K5, biến thể loại bỏ nhánh tích chập kích thước cửa sổ 5; (6) PhaBERT-NO-K3, biến thể loại bỏ nhánh tích chập kích thước cửa sổ 3; và (7) PhaBERT-NO-K7, biến thể loại bỏ nhánh tích chập kích thước cửa sổ 7. So sánh đường cơ sở DNABERT-2 với PhaBERT cho phép đánh giá đóng góp tổng thể của mô-đun MKC, so sánh DNABERT-2-CNN và DNABERT-2-P với đường cơ sở cho phép tách biệt đóng góp riêng của từng thành phần, trong khi ba biến thể PhaBERT-NO-K cho phép đánh giá đóng góp riêng của từng kích thước cửa sổ tích chập trong nhánh CNN đa cửa sổ. Bảng 4.1 trình bày kết quả so sánh chi tiết.

Cả ba biến thể (PhaBERT, DNABERT-2-CNN, DNABERT-2-P) đều vượt trội so với đường cơ sở DNABERT-2 một cách nhất quán trên tất cả các nhóm độ dài, xác nhận rằng các thành phần kiến trúc bổ sung mang lại cải thiện có ý nghĩa so với việc chỉ sử dụng đầu phân loại tuyến tính. So với đường cơ sở DNABERT-2, PhaBERT cải thiện độ chính xác lần lượt 0,49% (Nhóm A), 1,77% (Nhóm B), 2,65% (Nhóm C) và 3,02% (Nhóm D), với mức cải thiện tăng dần theo độ dài contig. Đặc biệt, độ đặc hiệu được cải thiện đáng kể: tăng 8,61% ở Nhóm A (từ 73,25% lên 81,86%) và 5,26% ở Nhóm B (từ 79,27% lên 84,53%), cho thấy mô-đun MKC nâng cao đáng kể khả năng nhận diện thực khuẩn thể ôn hòa. Xu hướng cải thiện tăng dần theo độ dài phản ánh đặc tính của nhánh CNN đa cửa sổ với ba kích thước bộ lọc (3, 5, 7) theo thiết kế kế thừa từ TextCNN [34]: khi chuỗi dài hơn, các mô-típ chức năng đặc trưng của hệ gen thực khuẩn thể trở nên hoàn chỉnh và phong phú hơn, cho phép các bộ lọc tích chập ở nhiều tỷ lệ không gian khai thác hiệu quả hơn các mẫu cục bộ.

Bảng 4.1: Nghiên cứu loại bỏ thành phần: so sánh các cấu hình trên bốn nhóm độ dài contig

Cấu hình	Chỉ số (%)	Nhóm A (100–400 bp)	Nhóm B (400–800 bp)	Nhóm C (800–1.200 bp)	Nhóm D (1.200–1.800 bp)
DNABERT-2	Sn	83,68 ± 4,22	87,24 ± 2,98	87,68 ± 4,61	88,75 ± 2,39
	Sp	73,25 ± 5,48	79,27 ± 4,01	85,75 ± 4,57	86,99 ± 4,76
	Acc	81,52 ± 2,32	85,56 ± 1,69	87,25 ± 2,85	88,36 ± 1,37
PhaBERT	Sn	82,07 ± 2,27	88,11 ± 2,35	90,69 ± 1,45	92,38 ± 1,43
	Sp	81,86 ± 3,93	84,53 ± 4,73	86,92 ± 3,76	87,63 ± 3,59
	Acc	82,01 ± 1,38	87,33 ± 1,16	89,90 ± 0,94	91,38 ± 0,89
DNABERT-2-CNN	Sn	82,68 ± 1,88	88,11 ± 2,05	91,21 ± 1,45	91,75 ± 1,80
	Sp	80,44 ± 5,62	84,63 ± 3,71	86,25 ± 2,05	88,58 ± 3,65
	Acc	82,18 ± 0,60	87,36 ± 1,20	90,16 ± 0,93	91,07 ± 1,13
DNABERT-2-P	Sn	85,12 ± 1,54	89,04 ± 2,43	90,84 ± 1,57	91,72 ± 1,19
	Sp	77,65 ± 3,22	82,49 ± 4,06	86,30 ± 4,54	88,74 ± 3,30
	Acc	83,54 ± 0,97	87,63 ± 1,28	89,88 ± 0,93	91,08 ± 0,76
PhaBERT-NO-K5	Sn	85,05 ± 2,43	88,31 ± 1,05	91,12 ± 1,54	91,57 ± 1,65
	Sp	78,03 ± 3,19	84,19 ± 3,05	86,71 ± 3,69	88,91 ± 3,23
	Acc	83,56 ± 1,53	87,44 ± 0,53	90,18 ± 0,98	90,99 ± 0,96
PhaBERT-NO-K3	Sn	84,18 ± 2,77	88,61 ± 2,47	91,80 ± 1,54	92,22 ± 2,40
	Sp	78,65 ± 4,14	83,50 ± 4,45	85,53 ± 3,28	86,92 ± 5,87
	Acc	83,00 ± 1,41	87,51 ± 1,20	90,49 ± 1,17	91,07 ± 1,05
PhaBERT-NO-K7	Sn	83,62 ± 1,09	89,54 ± 1,66	90,95 ± 1,65	91,56 ± 1,46
	Sp	78,47 ± 4,62	82,06 ± 3,39	87,47 ± 2,73	89,20 ± 3,33
	Acc	82,55 ± 0,69	87,95 ± 1,07	90,21 ± 1,02	91,05 ± 0,92

So sánh hai thành phần riêng lẻ cho thấy sự khác biệt đáng chú ý giữa DNABERT-2-CNN (chỉ nhánh CNN đa cửa sổ) và DNABERT-2-P (chỉ gộp chú ý). DNABERT-2-P đạt độ chính xác cao hơn ở Nhóm A (83,54% so với 82,18%) và Nhóm B (87,63% so với 87,36%), trong khi DNABERT-2-CNN nhỉnh hơn ở Nhóm C (90,16% so với 89,88%) và hai biến thể đạt kết quả gần tương đương ở Nhóm D (91,07% so với 91,08%). Xu hướng này cho thấy gộp chú ý mang lại lợi thế trên các contig ngắn, nơi việc tập trung vào các vùng có tính thông tin cao giúp bù đắp cho lượng thông tin trình tự hạn chế, trong khi CNN đa cửa sổ phát huy hiệu quả hơn trên các contig dài nhờ khả năng khai thác các mô-típ chức năng hoàn chỉnh hơn.

PhaBERT, kết hợp cả hai nhánh CNN đa cửa sổ và gộp trung bình có mặt nạ, thể hiện ưu thế rõ rệt trên contig dài: đạt độ chính xác cao nhất ở Nhóm D (91,38%) cùng độ nhạy vượt trội (92,38% so với 91,75% của DNABERT-2-CNN và 91,72%

của DNABERT-2-P). Đồng thời, PhaBERT đạt độ đặc hiệu cao nhất trong các cấu hình ablation ở Nhóm A (81,86%) và Nhóm C (86,92%), cho thấy sự kết hợp hai nhánh cải thiện khả năng nhận diện thực khuẩn thể ôn hòa. Nhìn tổng thể, việc kết hợp trích xuất đặc trưng cục bộ đa tỷ lệ từ CNN với tổng hợp thông tin toàn cục từ gộp trung bình có mặt nạ mang lại hiệu suất cân bằng và ổn định hơn so với từng thành phần riêng lẻ trên toàn phổ độ dài contig.

Kết quả loại bỏ từng kích thước cửa sổ tích chập (PhaBERT-NO-K5, PhaBERT-NO-K3, PhaBERT-NO-K7) cho thấy mỗi nhánh tích chập đóng góp thực sự so với đường cơ sở DNABERT-2, nhưng thông tin giữa các nhánh chồng lấn đáng kể. Cụ thể, loại bỏ bất kỳ một kích thước cửa sổ nào chỉ làm thay đổi độ chính xác trong khoảng $\pm 0,3-1,5\%$ so với mô hình đầy đủ, nằm trong biên dao động của kiểm định chéo 5 phần. Trên contig ngắn (Nhóm A), các biến thể thiếu một nhánh thậm chí đạt độ chính xác cao hơn mô hình đầy đủ (83,56% của PhaBERT-NO-K5 so với 82,01% của PhaBERT), phản ánh hiệu ứng chính quy hóa: khi tín hiệu trình tự hạn chế, ít tham số hơn giúp mô hình tổng quát hóa tốt hơn do giảm nguy cơ quá khớp. Ngược lại, trên contig dài nhất (Nhóm D), mô hình đầy đủ đạt kết quả cao nhất (91,38% so với 90,99–91,05% của các biến thể NO-K), cho thấy lợi ích của việc khai thác đặc trưng đa tỷ lệ chỉ phát huy rõ ràng khi trình tự đủ dài để chứa các mô-típ chức năng đa dạng ở nhiều kích thước khác nhau.

Điểm đáng chú ý là so sánh giữa DNABERT-2-CNN (ba nhánh CNN, không có gộp toàn cục, 384 chiều đặc trưng) với các biến thể PhaBERT-NO-K (hai nhánh CNN kết hợp gộp trung bình có mặt nạ, cũng 384 chiều đặc trưng): hai nhóm cấu hình này đạt hiệu suất gần tương đương trên hầu hết các nhóm. Kết quả này cho thấy việc thay thế một nhánh tích chập bằng nhánh gộp trung bình có mặt nạ mang lại hiệu quả tương đương, xác nhận rằng cả hai loại nhánh đều trích xuất thông tin phân loại ở mức tương đương từ biểu diễn ẩn của DNABERT-2. Nói cách khác, giá trị của kiến trúc MKC nằm ở việc cung cấp nhiều góc nhìn vào cùng một tín hiệu hệ gen, tạo biểu diễn ổn định hơn so với đường cơ sở, nhưng lợi ích biên giảm dần khi thêm nhiều nhánh, do thông tin giữa các nhánh chồng lấn đáng kể.

4.3.2 So sánh với các phương pháp tiên tiến

Bảng 4.2 trình bày kết quả so sánh toàn diện giữa PhaBERT và các phương pháp tiên tiến trên bốn nhóm độ dài contig, sử dụng phương pháp kiểm định chéo phân

tầng 5 phần.


Bảng 4.2: So sánh hiệu suất PhaBERT, PhaTYP, DeePhage và ProkBERT theo phương pháp kiểm định chéo phân tầng 5 phần trên bốn nhóm độ dài contig

Phương pháp	Chỉ số (%)	Nhóm A (100–400 bp)	Nhóm B (400–800 bp)	Nhóm C (800–1.200 bp)	Nhóm D (1.200–1.800 bp)
PhaBERT	Sn	82,07 ± 2,27	88,11 ± 2,35	90,69 ± 1,45	92,38 ± 1,43
	Sp	81,86 ± 3,93	84,53 ± 4,73	86,92 ± 3,76	87,63 ± 3,59
	Acc	82,01 ± 1,38	87,33 ± 1,16	89,90 ± 0,94	91,38 ± 0,89
PhaTYP	Sn	79,07 ± 0,87	86,74 ± 0,53	90,09 ± 0,90	92,29 ± 0,79
	Sp	78,77 ± 2,47	85,06 ± 2,52	87,65 ± 2,81	89,75 ± 2,70
	Acc	78,92 ± 0,86	85,90 ± 1,11	88,87 ± 1,02	91,02 ± 1,00
DeePhage	Sn	80,09 ± 1,22	86,46 ± 2,18	89,20 ± 1,00	91,17 ± 1,49
	Sp	71,79 ± 2,87	77,18 ± 3,94	80,31 ± 4,95	80,84 ± 3,80
	Acc	78,07 ± 0,42	84,17 ± 0,81	87,37 ± 0,64	89,10 ± 0,62
ProkBERT	Sn	80,65 ± 1,15	85,67 ± 0,74	83,61 ± 1,97	85,00 ± 0,99
	Sp	80,80 ± 2,70	84,15 ± 2,74	85,72 ± 2,67	83,68 ± 2,61
	Acc	80,68 ± 0,82	85,35 ± 0,71	84,03 ± 1,38	84,73 ± 0,61

Hình 4.1 minh họa trực quan hiệu suất của các phương pháp trên bốn nhóm độ dài.

PhaBERT đạt độ chính xác cao nhất trên tất cả bốn nhóm contig, với các giá trị lần lượt là 82,01%, 87,33%, 89,90% và 91,38%. So với các phương pháp tiên tiến, PhaBERT cải thiện 0,36–3,09% so với PhaTYP, 2,29–3,94% so với DeePhage, và 1,33–6,65% so với ProkBERT. Đặc biệt, mô hình duy trì độ nhạy cao (82,07%–92,38%) trong khi đạt độ đặc hiệu ở mức cạnh tranh (81,86%–87,63%), cho thấy khả năng phân loại cân bằng giữa hai lớp thực khuẩn. Sự cân bằng này có ý nghĩa thực tiễn quan trọng: độ nhạy cao đảm bảo phát hiện đầy đủ thực khuẩn thể độc lực cho ứng dụng liệu pháp điều trị [57], trong khi độ đặc hiệu cao giảm thiểu phân loại sai thực khuẩn thể ôn hòa, vốn có thể mang gen tiềm ẩn không phù hợp cho liệu pháp [58].

Đáng chú ý, trên Nhóm D (1200–1800 bp), PhaBERT cao hơn PhaTYP với 91,38% so với 91,02% về độ chính xác và 92,38% so với 92,29% về độ nhạy. PhaTYP vẫn đạt độ đặc hiệu cao hơn ở Nhóm D (89,75% so với 87,63%), cho thấy đặc trưng protein mang lại lợi thế trong việc nhận diện phage ôn hòa trên các contig dài chứa đầy đủ các vùng mã hóa protein. Tuy nhiên, PhaBERT đạt hiệu suất tổng thể cao



Hình 4.1: Hiệu suất phân loại của DeePhage, PhaTYP, ProkBERT và PhaBERT trên các nhóm A, B, C, D

hơn nhờ độ nhạy vượt trội, đồng thời vượt DeePhage 2,29% và ProkBERT 6,65% trên nhóm này.

DeePhage [16] đạt độ chính xác từ 78,07% đến 89,09%, cải thiện đều đặn theo độ dài contig nhưng luôn thấp hơn PhaBERT và PhaTYP. Độ đặc hiệu thấp hơn độ nhạy trên tất cả các nhóm (chênh lệch 8–10%), cho thấy mô hình có xu hướng thiên lệch về phân loại phage độc lực do sử dụng mã hóa one-hot không mang thông tin ngữ cảnh và huấn luyện từ đầu trên tập dữ liệu giới hạn. Tuy nhiên, DeePhage vượt ProkBERT ở Nhóm C (87,37% so với 84,03%) và Nhóm D (89,09% so với 84,73%), cho thấy kiến trúc CNN vẫn có khả năng cạnh tranh với các mô hình Transformer khi contig đủ dài để chứa các mô-típ chức năng hoàn chỉnh.

ProkBERT [50] thể hiện hiện tượng bão hòa: độ chính xác đạt cao nhất ở Nhóm B (85,35%) rồi giảm xuống 84,03% (Nhóm C) và 84,73% (Nhóm D), trở thành phương pháp có hiệu suất thấp nhất trên contig dài. Hiện tượng này phản ánh hạn chế của chiến lược mã hóa LCA k-mer chồng lấn, gây rò rỉ thông tin trong quá trình tiền huấn luyện và tạo dư thừa token [17]. Ngược lại, mã hóa BPE [36] trong PhaBERT loại bỏ hoàn toàn hiện tượng rò rỉ thông tin đồng thời giảm độ dài chuỗi token khoảng 5 lần, cho phép mô hình khai thác hiệu quả các trình tự dài hơn.

4.4 Phân tích lỗi

Ngoài việc báo cáo các chỉ số hiệu suất tổng hợp, học viên tiến hành phân tích lỗi chi tiết nhằm làm rõ các điểm yếu của PhaBERT và định hướng cho các cải tiến trong tương lai. Khác với các con số hiệu năng trong Bảng 4.2, phân tích trong phần này gộp toàn bộ dự đoán trên tập kiểm định của cả năm phần rồi mới cắt theo từng lát (lớp nhân, thành phần GC), do mỗi mẫu cần một dự đoán để gán vào lát tương ứng. Vì vậy, các số liệu dưới đây mang tính mô tả hành vi của mô hình trên tập kiểm định, bổ trợ cho các con số hiệu năng đã báo cáo.


4.4.1 Phân tích lỗi theo lớp nhân

Để xác định lỗi rơi vào lớp nào, học viên tách tỉ lệ lỗi theo nhãn thật của mỗi mẫu. Với lớp temperate, tỉ lệ lỗi chính là tỉ lệ dương tính giả (FPR, $FPR = FP/(FP + TN)$), tức tỉ lệ thực khuẩn thể ôn hòa bị nhầm thành độc lực; với lớp virulent, tỉ lệ lỗi là tỉ lệ âm tính giả (FNR, $FNR = FN/(FN + TP)$), tức tỉ lệ thực khuẩn thể độc lực bị nhầm thành ôn hòa. Bảng 4.3 trình bày hai tỉ lệ này trên bốn nhóm độ dài, và Hình 4.2 minh họa các ma trận nhầm lẫn tương ứng.

Bảng 4.3: Tỉ lệ lỗi theo lớp nhân trên bốn nhóm độ dài contig (số liệu gộp trên tập kiểm định năm phần). FPR là tỉ lệ temperate bị nhầm thành virulent, FNR là tỉ lệ virulent bị nhầm thành temperate.

Nhóm độ dài	FPR (%)	FNR (%)	n temperate	n virulent
Nhóm A (100–400 bp)	18,19	17,93	291.080	1.100.668
Nhóm B (400–800 bp)	15,55	11,91	120.762	457.798
Nhóm C (800–1.200 bp)	13,10	9,31	81.102	307.976
Nhóm D (1.200–1.800 bp)	12,43	7,62	61.430	233.892

Kết quả cho thấy lỗi phân bố không đồng đều giữa hai lớp. Trên cả bốn nhóm độ dài, FPR luôn cao hơn FNR, nghĩa là thực khuẩn thể ôn hòa, lớp thiểu số, là lớp bị phân loại sai nhiều hơn. Đây là hệ quả trực tiếp của việc mô hình học thiên về lớp đa số (virulent). Đáng chú ý, khoảng cách giữa hai tỉ lệ lỗi nói rộng theo độ dài contig: ở Nhóm A hai tỉ lệ gần tương đương (18,19% so với 17,93%), nhưng đến Nhóm D, FPR (12,43%) cao gần gấp 1,6 lần FNR (7,62%). Nói cách khác, khi




Hình 4.2: Ma trận nhầm lẫn của PhaBERT trên bốn nhóm độ dài contig (số liệu gộp trên tập kiểm định năm phần)

contig đủ dài để mô hình phân loại chính xác hơn về tổng thể, phần lỗi còn lại có xu hướng dồn vào việc nhầm thực khuẩn thể ôn hòa thành độc lực, tức lớp thiếu số bị nhầm thành đa số.

4.4.2 Phân tích lỗi theo thành phần GC

Bên cạnh phân tích lỗi theo nhóm độ dài, học viên khảo sát ảnh hưởng của thành phần GC (tỉ lệ phần trăm base G và C trong contig) đến tỉ lệ lỗi. Các contig được chia thành bốn khoảng GC cố định theo sinh học: dưới 35%, 35–45%, 45–55% và trên 55%. Hình 4.3 trình bày tỉ lệ lỗi theo từng khoảng GC trên cả bốn nhóm độ dài dưới dạng bản đồ nhiệt hai chiều độ dài $\times$ GC.

Quan hệ tỉ lệ lỗi tương ứng với tỉ lệ thành phần GC được thể hiện ở Hình 4.3. Mô hình mạnh nhất ở khoảng GC trung bình (35–55%) và yếu hần ở hai cực, đặc biệt ở khoảng GC cao (trên 55%). Trên toàn cục, tỉ lệ lỗi ở khoảng GC trên 55% lên đến 24,83%, cao hơn gấp đôi so với mức 10,59% ở khoảng 45–55%; ở các contig ngắn (Nhóm A), con số này còn lên đến 28,86%. Ở cực còn lại, khoảng GC dưới 35% cũng có tỉ lệ lỗi toàn cục tăng lên 19,20%, cao hơn rõ rệt so với mức nền



Hình 4.3: Bản đồ nhiệt tỉ lệ lỗi của PhaBERT theo lưới hai chiều nhóm độ dài $\times$ khoảng GC (số liệu gộp trên tập kiểm định năm phần)

khoảng 10–11% ở vùng GC trung bình, xác nhận cả hai nhánh của đường cong chữ U. Quan trọng hơn, mẫu hình chữ U này lặp lại nhất quán trên cả bốn nhóm độ dài (Hình 4.3), cho thấy đây là một đặc tính cố hữu của mô hình. Điều này xảy ra do lượng dữ liệu ở hai đầu ít hơn so với lượng dữ liệu ở vùng tỷ lệ GC từ 35% tới 55%

4.5 Thảo luận

Phần này phân tích các yếu tố đóng góp vào hiệu suất của PhaBERT, đánh giá xu hướng theo độ dài contig và so sánh các chiến lược biểu diễn chuỗi của các phương pháp được đánh giá.

4.5.1 Phân tích đóng góp kiến trúc

Hiệu suất vượt trội của PhaBERT trên tất cả bốn nhóm contig xuất phát từ ba yếu tố bổ trợ lẫn nhau. Thứ nhất, PhaBERT hoạt động trực tiếp trên chuỗi DNA thô thông qua mã hóa BPE [36], không phụ thuộc vào công cụ phát hiện gen như Prodigal [48] mà PhaTYP yêu cầu. Trên các contig ngắn, Prodigal thường không phát hiện được các vùng mã hóa protein hoàn chỉnh do chuỗi quá ngắn để chứa

các khung đọc mở đầy đủ [27], khiến PhaTYP mất đi nguồn thông tin chính; trong khi đó PhaBERT vẫn khai thác được tín hiệu từ trình tự nucleotide thô. Thứ hai, DNABERT-2 đã được tiền huấn luyện trên tập dữ liệu di truyền đa loài quy mô lớn [17], cho phép mô hình tổng quát hóa tốt hơn so với DeePhage vốn được huấn luyện từ đầu trên tập dữ liệu có kích thước hạn chế, một ưu thế của học chuyển giao đã được chứng minh rộng rãi trong lĩnh vực xử lý ngôn ngữ tự nhiên [35, 55]. Thứ ba, kiến trúc MKC với ba nhánh tích chập song song có kích thước cửa sổ 3, 5, 7 [34] kết hợp với gộp trung bình có mặt nạ cho phép mô hình đồng thời nắm bắt các đặc trưng cục bộ ở nhiều tỷ lệ không gian và tổng hợp thông tin toàn cục, bổ sung hiệu quả cho biểu diễn ngữ cảnh từ bộ mã hóa transformer. Kết quả loại bỏ từng kích thước cửa sổ (Bảng 4.1) cho thấy các nhánh tích chập có mức đóng góp tương đương nhau và thông tin giữa chúng chồng lấn đáng kể, phù hợp với nhận định của Zhang và Wallace [59] rằng hiệu suất của mạng tích chập đa cửa sổ ít nhạy cảm với việc lựa chọn kích thước bộ lọc cụ thể, mà phụ thuộc chủ yếu vào việc sử dụng đồng thời nhiều kích thước.

4.5.2 Phân tích xu hướng theo độ dài contig

Kết quả so sánh giữa đường cơ sở DNABERT-2 và PhaBERT (Bảng 4.1) cho thấy đóng góp của mô-đun MKC tăng dần theo độ dài contig: độ chính xác cải thiện từ 0,49% ở Nhóm A (từ 81,52% lên 82,01%) đến 3,02% ở Nhóm D (từ 88,36% lên 91,38%). Xu hướng này phản ánh rằng khi trình tự dài hơn, các mô-típ chức năng đặc trưng của hệ gen thực khuẩn thể như các vùng điều hòa, các gen liên quan đến chu trình tan và chu trình tiềm tan trở nên hoàn chỉnh hơn, cho phép các bộ lọc tích chập ở nhiều tỷ lệ không gian [34] khai thác hiệu quả hơn.

Trên toàn bộ bốn nhóm, PhaBERT là phương pháp duy nhất đạt độ chính xác cao nhất ở tất cả các nhóm và duy trì mức cải thiện đều đặn từ contig ngắn đến contig dài, trong khi các phương pháp còn lại đều thể hiện hạn chế ở một số nhóm nhất định: PhaTYP đạt hiệu suất thấp ở Nhóm A (78,92%), DeePhage luôn thấp hơn PhaBERT và PhaTYP dù cải thiện đều đặn theo độ dài, và ProkBERT gặp hiện tượng bão hòa từ Nhóm B trở đi khiến hiệu suất giảm xuống thấp nhất trên contig dài.

4.5.3 So sánh chiến lược biểu diễn chuỗi

Kết quả thực nghiệm cho phép rút ra một số nhận xét về ảnh hưởng của chiến lược biểu diễn chuỗi đến hiệu suất phân loại. Mã hóa BPE [36] được sử dụng trong DNABERT-2 và PhaBERT thể hiện ưu thế rõ rệt nhờ ba đặc tính: loại bỏ hiện tượng rò rỉ thông tin giữa các token liên kề, giảm độ dài chuỗi token khoảng 5 lần so với trình tự gốc, và chuyển đổi bài toán mô hình hóa ngôn ngữ có mặt nạ thành bài toán dự đoán đoạn, vốn đã được chứng minh là cải thiện chất lượng học biểu diễn [39]. Phương pháp mã hóa dựa trên protein của PhaTYP [10] đạt độ đặc hiệu cao nhất trên contig dài (Nhóm D: 89,75%) nhờ khai thác thông tin ở cấp độ protein, tuy nhiên PhaBERT vẫn tốt hơn về độ chính xác tổng thể (91,38% so với 91,02%) nhờ độ nhạy cao hơn. Phương pháp này cũng phụ thuộc vào Prodigal [48], công cụ dự đoán gen có hiệu quả giảm đáng kể trên các đoạn DNA ngắn [27]. Mã hóa one-hot trong DeePhage [16] là chiến lược biểu diễn đơn giản nhất, không mang thông tin ngữ cảnh và không tận dụng tri thức từ tiền huấn luyện, dẫn đến hiệu suất thấp nhất trên contig ngắn; tuy nhiên, kiến trúc CNN cho phép DeePhage cải thiện đều đặn tỷ lệ thuận với độ dài contig. Mã hóa LCA k-mer trong ProkBERT [50] là phương pháp duy nhất cho thấy hiện tượng bão hòa trên trình tự dài, phản ánh hạn chế cơ bản của việc sử dụng k-mer chồng lấn [17].

Nhìn chung, kết quả thực nghiệm khẳng định rằng sự kết hợp giữa chiến lược mã hóa hiệu quả (BPE), tiền huấn luyện trên dữ liệu đa dạng (DNABERT-2) và kiến trúc trích xuất đặc trưng chuyên biệt cho tác vụ (MKC) tạo nên lợi thế tổng hợp, cho phép PhaBERT đạt hiệu suất tốt trên phổ độ dài contig phổ biến trong phân tích hệ gen môi trường.

4.5.4 Ý nghĩa thực tiễn của cải thiện hiệu suất

Trong bối cảnh liệu pháp phage, việc phân loại chính xác lối sống thực khuẩn thể có ý nghĩa an toàn quan trọng. Các hướng dẫn thực hành lâm sàng khuyến nghị ưu tiên sử dụng thực khuẩn thể độc lực cho điều trị, do thực khuẩn thể ôn hòa tiềm ẩn rủi ro biến đổi tiềm tan [58]. Khi phage ôn hòa bị phân loại sai thành độc lực và được sử dụng trong điều trị, chúng có thể tích hợp vào hệ gen vi khuẩn dưới dạng prophage, từ đó chuyển các gen độc lực cho vật chủ thông qua cơ chế chuyển gen ngang [24]. Các ví dụ điển hình đã được ghi nhận bao gồm độc tố tả

(CTXphi), độc tố Shiga (stx1/stx2) và độc tố bạch hầu. Ngược lại, khi phage độc lực bị phân loại sai thành ôn hòa, các ứng viên điều trị tiềm năng sẽ bị loại bỏ, đặc biệt đáng tiếc trong bối cảnh kháng kháng sinh đang là vấn đề y tế toàn cầu nghiêm trọng [57].

Ở quy mô dữ liệu hệ gen môi trường, các cơ sở dữ liệu vi-rút như IMG/VR phiên bản 4 hiện lưu trữ hơn 15 triệu hệ gen và mảnh hệ gen vi-rút [60], trong đó đa số chưa có chú thích lối sống và khó phân loại bằng phương pháp đối sánh trình tự do số lượng phage đã được chú thích còn rất hạn chế [10]. Trong bối cảnh phải xử lý tự động một khối lượng trình tự lớn như vậy, ngay cả một mức cải thiện độ chính xác khiêm tốn cũng có thể tạo ra khác biệt đáng kể về số lượng trình tự được phân loại đúng.

4.6 Kết luận

Chương này đã trình bày kết quả đánh giá toàn diện PhaBERT trên bốn nhóm độ dài contig thông qua kiểm định chéo phân tầng 5 phần, bao gồm nghiên cứu loại bỏ thành phần với bảy cấu hình (DNABERT-2, PhaBERT, DNABERT-2-CNN, DNABERT-2-P, PhaBERT-NO-K5, PhaBERT-NO-K3 và PhaBERT-NO-K7), cùng so sánh với ba phương pháp tiên tiến khác. Kết quả nghiên cứu loại bỏ thành phần cho thấy mô-đun MKC cải thiện độ chính xác từ 0,49% đến 3,02% so với đường cơ sở DNABERT-2, trong đó mức cải thiện độ đặc hiệu đặc biệt đáng kể (lên đến 8,61% ở Nhóm A). So sánh các thành phần riêng lẻ cho thấy gộp chú ý (DNABERT-2-P) mang lại lợi thế trên contig ngắn, trong khi CNN đa cửa sổ (DNABERT-2-CNN) phát huy hiệu quả trên contig trung bình và dài; sự kết hợp cả hai nhánh trong PhaBERT mang lại hiệu suất cân bằng và ổn định nhất trên toàn phổ độ dài. Kết quả loại bỏ từng kích thước cửa sổ tích chập cho thấy các nhánh có mức đóng góp tương đương và thông tin chồng lấn đáng kể, lợi ích biên giảm dần khi thêm nhánh, nhưng sự kết hợp đa tỷ lệ vẫn mang lại tính ổn định cao hơn so với từng thành phần riêng lẻ, đặc biệt trên contig dài. Trong so sánh toàn diện với các phương pháp tiên tiến, PhaBERT đạt độ chính xác cao nhất trên tất cả bốn nhóm contig (100–1.800 bp) với khoảng từ 82,01% đến 91,38%, cải thiện từ 0,36 đến 6,65% so với phương pháp tốt nhất tiếp theo. Phân tích cho thấy ba yếu tố chính đóng góp vào hiệu suất này: xử lý trực tiếp trên trình tự DNA thô thông qua mã hóa BPE, học chuyển giao từ mô hình nền tảng tiền huấn luyện trên dữ

liệu đa loài, và trích xuất đặc trưng đa tỷ lệ từ mô-đun MKC. Ngoài ra, phân tích lỗi chi tiết (Phần 4.4) làm rõ hai điểm yếu còn tồn tại của mô hình: xu hướng thiên lệch về lớp đa số khiến thực khuẩn thể ôn hòa bị phân loại sai nhiều hơn, và tỉ lệ lỗi tăng cao ở các contig có thành phần GC cực trị theo mẫu hình chữ U. Chương tiếp theo tổng kết các đóng góp của nghiên cứu, thảo luận các hạn chế và đề xuất hướng phát triển trong tương lai.

Chương 5

Kết luận

Chương này tổng kết các kết quả nghiên cứu của luận văn và đánh giá ý nghĩa của phương pháp PhaBERT được đề xuất trong Chương 3 và kiểm chứng tại Chương 4. Nội dung được tổ chức theo ba phần: tóm tắt kết quả và nhận định chính, tổng hợp các đóng góp của nghiên cứu, và thảo luận về hạn chế cùng hướng phát triển trong tương lai.

5.1 Kết luận

Luận văn này nghiên cứu bài toán phân loại hệ gen thực khuẩn thể từ dữ liệu hệ gen môi trường, một thách thức quan trọng trong sinh tin học hiện đại. Các phương pháp hiện có gặp khó khăn khi xử lý contig ngắn do phụ thuộc vào công cụ dự đoán gen như Prodigal [48], vốn không hoạt động hiệu quả trên các đoạn DNA ngắn thiếu khung đọc mở hoàn chỉnh [27]. Để giải quyết vấn đề này, luận văn đề xuất PhaBERT, một kiến trúc học sâu lai kết hợp mô hình nền tảng hệ gen DNABERT-2 [17] với mô-đun MKC gồm nhánh CNN đa cửa sổ và gộp trung bình có mặt nạ toàn cục. Phương pháp hoạt động trực tiếp trên chuỗi DNA thô thông qua mã hóa BPE, không phụ thuộc vào công cụ dự đoán gen, và được huấn luyện theo chiến lược hai giai đoạn với tốc độ học phân biệt để tối ưu hóa đồng thời mạng nền và các thành phần chuyên biệt cho tác vụ.

Phương pháp được đánh giá toàn diện trên bốn nhóm độ dài contig (100–400 bp, 400–800 bp, 800–1.200 bp, 1.200–1.800 bp) thông qua kiểm định chéo phân tầng 5 phần trên tập dữ liệu gồm 2.241 hệ gen thực khuẩn thể hoàn chỉnh. Như trình bày trong Bảng 4.2, PhaBERT đạt độ chính xác cao nhất trên tất cả bốn nhóm contig với các giá trị lần lượt là 82,01%, 87,33%, 89,90% và 91,38%. So với các phương pháp tiên tiến, PhaBERT cải thiện 0,36–3,09% so với PhaTYP [10], 2,29–3,94% so với DeePhage [16], và 1,33–6,65% so với ProkBERT [50].

Kết quả nghiên cứu chứng minh tính hiệu quả của việc kết hợp mô hình nền tảng hệ gen tiền huấn luyện với kiến trúc chuyên biệt MKC cho bài toán dự đoán lỗi

sống thực khuẩn thể. Như đã phân tích chi tiết trong Chương 4, PhaBERT không chỉ cải thiện độ chính xác dự đoán trên contig ngắn và trung bình mà còn khắc phục được các hạn chế quan trọng của các phương pháp hiện có như sự phụ thuộc vào công cụ dự đoán gen và khả năng xử lý hạn chế trên các contig ngắn, phân mảnh. Sự kết hợp giữa biểu diễn ngữ cảnh toàn cục từ DNABERT-2 và trích xuất đặc trưng cục bộ chuyên biệt từ CNN đa cửa sổ tạo ra lợi thế rõ rệt so với từng thành phần riêng lẻ, mở ra hướng tiếp cận triển vọng cho việc tích hợp các mô hình tiền huấn luyện với các thành phần kiến trúc chuyên biệt cho các tác vụ đặc thù.

5.2 Đóng góp của nghiên cứu

Về mặt phương pháp, luận văn đề xuất PhaBERT, một kiến trúc học sâu lai kết hợp mô hình nền tảng hệ gen DNABERT-2 với mô-đun MKC chuyên biệt cho bài toán phân loại hệ gen thực khuẩn thể. Kiến trúc nhánh song song kép bao gồm nhánh CNN đa cửa sổ với ba kích thước (3, 5, 7) để trích xuất các đặc trưng cục bộ ở nhiều tỷ lệ không gian, và gộp trung bình có mặt nạ để tổng hợp biểu diễn toàn cục từ toàn bộ các biểu diễn token của DNABERT-2. Chiến lược huấn luyện hai giai đoạn với tốc độ học phân biệt, giai đoạn một đóng băng mạng nền để huấn luyện đầu phân loại, giai đoạn hai tinh chỉnh toàn bộ mô hình với tốc độ học thấp hơn cho mạng nền, cho phép tối ưu hóa hiệu quả cả biểu diễn tiền huấn luyện lẫn các thành phần chuyên biệt cho tác vụ. Phương pháp này khác biệt với các hướng tiếp cận trước đây bằng cách hoạt động trực tiếp trên chuỗi DNA thô thông qua mã hóa BPE, loại bỏ sự phụ thuộc vào công cụ phát hiện gen và cho phép xử lý hiệu quả các contig ngắn.

Về mặt kết quả thực nghiệm, luận văn cung cấp đánh giá trên bốn nhóm độ dài contig từ 100 đến 1.800 bp thông qua kiểm định chéo phân tầng 5 phần, cho thấy PhaBERT đạt độ chính xác cao nhất trên tất cả bốn nhóm với mức cải thiện 0,36–6,65% so với các phương pháp tiên tiến. Nghiên cứu loại bỏ thành phần với bảy cấu hình gồm đường cơ sở DNABERT-2, PhaBERT, DNABERT-2-CNN (chỉ nhánh CNN đa cửa sổ), DNABERT-2-AP (gộp chú ý), PhaBERT-NO-K5, PhaBERT-NO-K3 và PhaBERT-NO-K7, chứng minh rằng mô-đun MKC đóng góp cải thiện độ chính xác từ 0,49% đến 3,02% tùy theo độ dài contig, với mức cải thiện độ đặc hiệu đặc biệt đáng kể (8,61%) trên contig ngắn. So sánh các thành phần riêng lẻ

cho thấy gộp chú ý mang lại lợi thế trên contig ngắn, trong khi CNN đa cửa sổ phát huy hiệu quả trên contig trung bình và dài; sự kết hợp cả hai nhánh trong PhaBERT mang lại hiệu suất cân bằng và ổn định nhất trên toàn phổ độ dài. Kết quả loại bỏ từng kích thước cửa sổ tích chập cho thấy các nhánh có mức đóng góp tương đương và thông tin chồng lấn đáng kể, xác nhận rằng giá trị của kiến trúc đa tỷ lệ nằm ở sự kết hợp tổng thể chứ không phải ở bất kỳ kích thước cửa sổ riêng lẻ nào. Kết quả này xác nhận giả thuyết rằng các mô hình nền tảng hệ gen cung cấp nền tảng biểu diễn mạnh mẽ cho các tác vụ hạ nguồn, nhưng vẫn cần các thành phần kiến trúc chuyên biệt để đạt hiệu suất tối ưu. Phân tích chi tiết về hiệu suất trên từng nhóm độ dài cũng cung cấp những nhận định quan trọng về điểm mạnh và hạn chế của từng phương pháp, giúp định hướng cho các nghiên cứu tiếp theo.

Về mặt ứng dụng thực tiễn, PhaBERT giải quyết một thách thức quan trọng trong phân tích dữ liệu hệ gen môi trường: phân loại hệ gen thực khuẩn thể từ các contig phân mảnh thu được qua quá trình lắp ráp hệ gen môi trường. Khả năng xử lý trực tiếp trên chuỗi DNA thô mà không cần công cụ dự đoán gen như Prodigal [48] làm cho phương pháp đặc biệt phù hợp với các tình huống thực tế, nơi contig thường ngắn và thiếu các vùng mã hóa protein hoàn chỉnh. Hiệu suất cân bằng giữa độ nhạy và độ đặc hiệu trên tất cả các nhóm độ dài cho thấy PhaBERT có tiềm năng tích hợp vào các quy trình phân tích hệ gen môi trường tự động, hỗ trợ nghiên cứu về tương tác giữa thực khuẩn thể và vi khuẩn, động lực quần thể vi sinh vật, và ứng dụng liệu pháp thực khuẩn thể. Hơn nữa, khuôn khổ lai ghép giữa mô hình nền tảng tiền huấn luyện với các thành phần kiến trúc chuyên biệt cho tác vụ mở ra một hướng tiếp cận có thể mở rộng sang nhiều bài toán tin sinh học hạ nguồn khác như dự đoán vi khuẩn chủ, phát hiện prophage, phân loại chức năng gen và chú giải hệ gen vi sinh vật, qua đó góp phần thúc đẩy nghiên cứu trong lĩnh vực tin sinh học tính toán.

Tầm quan trọng của việc cải thiện độ chính xác phân loại được thể hiện rõ hơn khi đặt trong bối cảnh quy mô và hệ quả của dữ liệu hệ gen môi trường. Các cơ sở dữ liệu vi-rút từ hệ gen môi trường như IMG/VR phiên bản 4 hiện lưu trữ hơn 15 triệu hệ gen và mảnh hệ gen vi-rút [60], cho thấy khối lượng trình tự cần phân loại trong các phân tích hạ nguồn là rất lớn. Ở quy mô này, ngay cả những sai lệch nhỏ về tỷ lệ phân loại cũng có thể tích lũy thành một số lượng đáng kể các

trình tự bị gán nhãn sai. Hệ quả của việc phân loại sai lỗi sống không chỉ giới hạn ở khía cạnh thống kê: việc nhầm lẫn giữa thực khuẩn thể độc lực và ôn hòa có thể dẫn tới những suy luận sai lệch về động lực quần thể vi sinh vật, tiềm năng chuyển gen ngang, cũng như tính phù hợp của thực khuẩn thể cho ứng dụng liệu pháp [10, 16]. Do đó, mức cải thiện 0,36–6,65% mà PhaBERT đạt được so với các phương pháp tiên tiến trên tập đánh giá của luận văn (Bảng 4.2) có thể mang lại lợi ích thực tiễn đáng kể khi được áp dụng trên các tập dữ liệu hệ gen môi trường quy mô lớn, mặc dù mức độ cụ thể còn phụ thuộc vào đặc điểm phân bố và chất lượng trình tự của từng tập dữ liệu.

5.3 Hạn chế và hướng phát triển tương lai

Một hạn chế của PhaBERT là việc sử dụng lấy mẫu giảm ngẫu nhiên để xử lý mất cân bằng nhãn, vốn có thể làm mất một phần thông tin từ lớp đa số. Phân tích lỗi theo lớp nhãn (Phần 4.4.1) cho thấy mô hình vẫn còn thiên lệch về phía lớp đa số. Các nghiên cứu tiếp theo có thể khảo sát những chiến lược giữ trọn dữ liệu huấn luyện mà vẫn hạn chế thiên lệch, chẳng hạn gán trọng số lớp hoặc sử dụng hàm Focal Loss [61].

Hạn chế thứ hai liên quan đến việc PhaBERT hoạt động thuần túy trên chuỗi nucleotide, chưa khai thác thông tin ở cấp độ protein. Mặc dù PhaBERT đạt độ chính xác cao nhất trên tất cả bốn nhóm contig, PhaTYP [10] vẫn đạt độ đặc hiệu cao hơn trên contig dài (Nhóm D: 89,75% so với 87,63%) nhờ khai thác đặc trưng protein. Điều này cho thấy thông tin ở cấp độ protein cung cấp tín hiệu phân loại bổ sung quan trọng, đặc biệt cho việc nhận diện thực khuẩn thể ôn hòa trên các trình tự dài chứa đầy đủ các vùng mã hóa protein.

Cuối cùng, luận văn chưa đánh giá mô hình trên một tập dữ liệu độc lập hoàn toàn, cũng như chưa so sánh với các mô hình nền tảng hệ gen quy mô lớn hơn như Nucleotide Transformer [42]; nghiên cứu mới chỉ sử dụng DNABERT-2 làm mạng nền, do chi phí tính toán của các mô hình lớn cao và nằm ngoài phạm vi tài nguyên hiện có. Hướng phát triển tiếp theo là kiểm chứng PhaBERT trên dữ liệu hệ gen môi trường độc lập và đánh giá mô-đun MKC trên nhiều mạng nền khác nhau, qua đó đánh giá chặt chẽ hơn khả năng tổng quát hóa của mô hình trong các điều kiện triển khai thực tế.

Tài liệu tham khảo

- [1] Ashish Vaswani, Noam Shazeer, Niki Parmar, Jakob Uszkoreit, Llion Jones, Aidan N Gomez, Łukasz Kaiser, and Illia Polosukhin. Attention is all you need. *Advances in neural information processing systems*, 30, 2017.
- [2] Curtis A Suttle. Marine viruses—major players in the global ecosystem. *Nature reviews microbiology*, 5(10):801–812, 2007.
- [3] Anne Chevallereau, Benoît J Pons, Stineke van Houte, and Edze R Westra. Interactions between bacterial and phage communities in natural environments. *Nature Reviews Microbiology*, 20(1):49–62, 2022.
- [4] Cristina Howard-Varona, Katherine R Hargreaves, Stephen T Abedon, and Matthew B Sullivan. Lysogeny in nature: mechanisms, impact and ecology of temperate phages. *The ISME journal*, 11(7):1511–1520, 2017.
- [5] Jakob T Rostøl, Cora Chmielowska, Alberto Marina, et al. Revisiting the life cycle of temperate phages. *Nature Reviews Microbiology*, 2026.
- [6] Christopher J L Murray et al. Global burden of bacterial antimicrobial resistance in 2019: a systematic analysis. *The Lancet*, 399(10325):629–655, 2022.
- [7] Mohsen Naghavi, Stein Emil Vollset, Kevin S Ikuta, et al. Global burden of bacterial antimicrobial resistance 1990–2021: a systematic analysis with forecasts to 2050. *The Lancet*, 404(10459):1199–1226, 2024.
- [8] Steffanie A Strathdee, Graham F Hatfull, Vivek K Mutalik, and Robert T Schooley. Phage therapy: From biological mechanisms to future directions. *Cell*, 186(1):17–31, 2023.
- [9] Vimathi S Gummalla, Yujie Zhang, Yen-Te Liao, and Vivian C H Wu. The role of temperate phages in bacterial pathogenicity. *Microorganisms*, 11(3):541, 2023.
- [10] Jiayu Shang, Xubo Tang, and Yanni Sun. Phatyp: predicting the lifestyle for bacteriophages using bert. *Briefings in Bioinformatics*, 24(1):bbac487, 2023.

- [11] Pacifica Sommers, Anushila Chatterjee, Arvind Varsani, and Gareth Trubl. Integrating viral metagenomics into an ecological framework. *Annual Review of Virology*, 8(1):133–158, 2021.
- [12] Clara Rolland, Johannes Wittmann, Lorenz C Reimer, Joaquim Sardà Carbasse, Isabel Schober, Christian-Alexander Dudek, Christian Ebeling, Julia Koblitz, Boyke Bunk, and Jörg Overmann. PhageDive: the comprehensive strain database of prokaryotic viral diversity. *Nucleic Acids Research*, 53(D1):D819–D825, 2024.
- [13] Kenneth E Schackart III, Jessica B Graham, Alise J Ponsero, and Bonnie L Hurwitz. Evaluation of computational phage detection tools for metagenomic datasets. *Frontiers in Microbiology*, 14:1078760, 2023.
- [14] Katelyn McNair, Barbara A Bailey, and Robert A Edwards. Phacts, a computational approach to classifying the lifestyle of phages. *Bioinformatics*, 28(5):614–618, 2012.
- [15] Adam J Hockenberry and Claus O Wilke. Bacphlip: predicting bacteriophage lifestyle from conserved protein domains. *PeerJ*, 9:e11396, 2021.
- [16] Shufang Wu, Zhencheng Fang, Jie Tan, Mo Li, Chunhui Wang, Qian Guo, Congmin Xu, Xiaoqing Jiang, and Huaiqiu Zhu. DeepPhage: distinguishing virulent and temperate phage-derived sequences in metavirome data with a deep learning approach. *Gigascience*, 10(9):giab056, 2021.
- [17] Zhihan Zhou, Yanrong Ji, Weijian Li, Pratik Dutta, Ramana Davuluri, and Han Liu. DNABERT-2: Efficient foundation model and benchmark for multi-species genomes. In *The Twelfth International Conference on Learning Representations (ICLR)*, 2024.
- [18] J. D. Watson and F. H. C. Crick. Molecular structure of nucleic acids: a structure for deoxyribose nucleic acid. *Nature*, 171:737–738, 1953.
- [19] Harald Brüssow and Roger W. Hendrix. Phage genomics: small is beautiful. *Cell*, 108(1):13–16, 2002.
- [20] Basem Al-Shayeb, Rohan Sachdeva, Lin-Xing Chen, Fred Ward, Patrick Munk, Audra Devoto, Cindy J Castelle, Matthew R Olm, Keith Bouma-Gregson, Yuki

- Amano, et al. Clades of huge phages from across Earth’s ecosystems. *Nature*, 578(7795):425–431, 2020.
- [21] Britt Koskella and Michael A Brockhurst. Bacteria–phage coevolution as a driver of ecological and evolutionary processes in microbial communities. *FEMS microbiology reviews*, 38(5):916–931, 2014.
 - [22] Fernando L Gordillo Altamirano and Jeremy J Barr. Phage therapy in the postantibiotic era. *Clinical Microbiology Reviews*, 32(2):e00066–18, 2019.
 - [23] Kaitlyn E Kortright, Benjamin K Chan, Jonathan L Koff, and Paul E Turner. Phage therapy: a renewed approach to combat antibiotic-resistant bacteria. *Cell Host & Microbe*, 25(2):219–232, 2019.
 - [24] Harald Brüssow, Carlos Canchaya, and Wolf-Dietrich Hardt. Phages and the evolution of bacterial pathogens: from genomic rearrangements to lysogenic conversion. *Microbiology and Molecular Biology Reviews*, 68(3):560–602, 2004.
 - [25] John L Mokili, Forest Rohwer, and Bas E Dutilh. Metagenomics and future perspectives in virus discovery. *Current opinion in virology*, 2(1):63–77, 2012.
 - [26] Martin Ayling, Matthew D Clark, and Richard M Leggett. New approaches for metagenome assembly with short reads. *Briefings in Bioinformatics*, 21(2):584–594, 2020.
 - [27] William L Trimble, Kevin P Keegan, Mark D’Souza, Andreas Wilke, Jared Wilkening, Jack Gilbert, and Folker Meyer. Short-read reading-frame predictors are not created equal: sequence error causes loss of signal. *BMC bioinformatics*, 13(1):183, 2012.
 - [28] Yann LeCun, Yoshua Bengio, and Geoffrey Hinton. Deep learning. *Nature*, 521(7553):436–444, 2015.
 - [29] Ian Goodfellow, Yoshua Bengio, and Aaron Courville. *Deep Learning*. MIT Press, 2016.
 - [30] Vinod Nair and Geoffrey E. Hinton. Rectified linear units improve restricted Boltzmann machines. In *Proceedings of the 27th International Conference on Machine Learning (ICML)*, pages 807–814, 2010.

- [31] David E. Rumelhart, Geoffrey E. Hinton, and Ronald J. Williams. Learning representations by back-propagating errors. *Nature*, 323(6088):533–536, 1986.
- [32] Diederik P. Kingma and Jimmy Ba. Adam: A method for stochastic optimization. In *The Third International Conference on Learning Representations (ICLR)*, 2015.
- [33] Kurt Hornik, Maxwell Stinchcombe, and Halbert White. Multilayer feedforward networks are universal approximators. *Neural Networks*, 2(5):359–366, 1989.
- [34] Yoon Kim. Convolutional neural networks for sentence classification. In *Proceedings of the 2014 Conference on Empirical Methods in Natural Language Processing (EMNLP)*, pages 1746–1751, 2014.
- [35] Jacob Devlin, Ming-Wei Chang, Kenton Lee, and Kristina Toutanova. Bert: Pre-training of deep bidirectional transformers for language understanding. In *Proceedings of the 2019 conference of the North American chapter of the association for computational linguistics: human language technologies, volume 1 (long and short papers)*, pages 4171–4186, 2019.
- [36] Rico Sennrich, Barry Haddow, and Alexandra Birch. Neural machine translation of rare words with subword units. In *Proceedings of the 54th Annual Meeting of the Association for Computational Linguistics (Volume 1: Long Papers)*, pages 1715–1725, 2016.
- [37] Yanrong Ji, Zhihan Zhou, Han Liu, and Ramana V Davuluri. Dnabert: pre-trained bidirectional encoder representations from transformers model for dna-language in genome. *Bioinformatics*, 37(15):2112–2120, 2021.
- [38] Taku Kudo and John Richardson. SentencePiece: A simple and language independent subword tokenizer and detokenizer for neural text processing. In *Proceedings of the 2018 Conference on Empirical Methods in Natural Language Processing: System Demonstrations*, pages 66–71, 2018.
- [39] Colin Raffel, Noam Shazeer, Adam Roberts, Katherine Lee, Sharan Narang, Michael Matena, Yanqi Zhou, Wei Li, and Peter J Liu. Exploring the limits of transfer learning with a unified text-to-text transformer. *Journal of Machine Learning Research*, 21(140):1–67, 2020.

- [40] Ofir Press, Noah A Smith, and Mike Lewis. Train short, test long: Attention with linear biases enables input length extrapolation. In *The Tenth International Conference on Learning Representations (ICLR)*, 2022.
- [41] Tri Dao, Dan Fu, Stefano Ermon, Atri Rudra, and Christopher Ré. Flashattention: Fast and memory-efficient exact attention with io-awareness. *Advances in neural information processing systems*, 35:16344–16359, 2022.
- [42] Hugo Dalla-Torre, Liam Gonzalez, Javier Mendoza-Revilla, Nicolas Lopez Caranza, Adam Henryk Grzywaczewski, Francesco Oteri, Christian Dallago, Evan Trop, Bernardo P de Almeida, Hassan Sirelkhatim, et al. Nucleotide transformer: building and evaluating robust foundation models for human genomics. *Nature Methods*, 22(2):287–297, 2025.
- [43] Min Lin, Qiang Chen, and Shuicheng Yan. Network in network. In *Proceedings of the 2nd International Conference on Learning Representations (ICLR)*, 2014.
- [44] Kaiming He, Xiangyu Zhang, Shaoqing Ren, and Jian Sun. Spatial pyramid pooling in deep convolutional networks for visual recognition. *IEEE Transactions on Pattern Analysis and Machine Intelligence*, 37(9):1904–1916, 2015.
- [45] Zhouhan Lin, Minwei Feng, Cicero Nogueira dos Santos, Mo Yu, Bing Xiang, Bowen Zhou, and Yoshua Bengio. A structured self-attentive sentence embedding. In *The Fifth International Conference on Learning Representations (ICLR)*, 2017.
- [46] Zichao Yang, Diyi Yang, Chris Dyer, Xiaodong He, Alex Smola, and Eduard Hovy. Hierarchical attention networks for document classification. In *Proceedings of the 2016 Conference of the North American Chapter of the Association for Computational Linguistics: Human Language Technologies*, pages 1480–1489, 2016.
- [47] Piotr Tynecki, Arkadiusz Guziński, Joanna Kazimierczak, Michał Jadczuk, Jarosław Dastyh, and Agnieszka Onisko. Phageai-bacteriophage life cycle recognition with machine learning and natural language processing. *BioRxiv*, pages 2020–07, 2020.

- [48] Doug Hyatt, Gwo-Liang Chen, Philip F LoCascio, Miriam L Land, Frank W Larimer, and Loren J Hauser. Prodigal: prokaryotic gene recognition and translation initiation site identification. *BMC bioinformatics*, 11(1):119, 2010.
- [49] Yujie Zhang, Mark Mao, Robert Zhang, Yen-Te Liao, and Vivian CH Wu. Deeppl: A deep-learning-based tool for the prediction of bacteriophage lifecycle. *PLOS Computational Biology*, 20(10):e1012525, 2024.
- [50] Balázs Ligeti, István Szepesi-Nagy, Babett Bodnár, Noémi Ligeti-Nagy, and János Juhász. Prokbert family: genomic language models for microbiome applications. *Frontiers in Microbiology*, 14:1331233, 2024.
- [51] Travis N. Mavrich and Graham F. Hatfull. Bacteriophage evolution differs by host, lifestyle and genome. *Nature Microbiology*, 2(9):17112, 2017.
- [52] Rie Johnson and Tong Zhang. Deep pyramid convolutional neural networks for text categorization. In *Proceedings of the 55th Annual Meeting of the Association for Computational Linguistics (Volume 1: Long Papers)*, pages 562–570, 2017.
- [53] Ilya Loshchilov and Frank Hutter. Decoupled weight decay regularization. In *The Seventh International Conference on Learning Representations (ICLR)*, 2019.
- [54] Leslie N Smith and Nicholay Topin. Super-convergence: Very fast training of neural networks using large learning rates. In *Artificial intelligence and machine learning for multi-domain operations applications*, volume 11006, pages 369–386. SPIE, 2019.
- [55] Jeremy Howard and Sebastian Ruder. Universal language model fine-tuning for text classification. In *Proceedings of the 56th Annual Meeting of the Association for Computational Linguistics (Volume 1: Long Papers)*, pages 328–339, 2018.
- [56] Jay S Ghurye, Victoria Cepeda-Espinoza, and Mihai Pop. Metagenomic assembly: overview, challenges and applications. *The Yale journal of biology and medicine*, 89(3):353, 2016.
- [57] Taher Azimi, Mehrdad Mosadegh, Mohammad Javad Nasiri, Sahar Sabour, Samira Karimaei, and Ahmad Nasser. Phage therapy as a renewed therapeutic

approach to mycobacterial infections: a comprehensive review. *Infection and Drug Resistance*, pages 2943–2959, 2019.

- [58] Ron Feiner, Tal Argov, Lev Rabinovich, Nadejda Sigal, Ilya Borovok, and Anat A Herskovits. A new perspective on lysogeny: prophages as active regulatory switches of bacteria. *Nature Reviews Microbiology*, 13(10):641–650, 2015.
- [59] Ye Zhang and Byron Wallace. A sensitivity analysis of (and practitioners’ guide to) convolutional neural networks for sentence classification. In *Proceedings of the Eighth International Joint Conference on Natural Language Processing*, pages 253–263, 2017.
- [60] Antonio Pedro Camargo, Stephen Nayfach, I-Min A Chen, Krishnaveni Palaniappan, Anna Ratner, Ken Chu, Stephan J Ritter, T B K Reddy, Supratim Mukherjee, Frederik Schulz, Lee Call, Russell Y Neches, Tanja Woyke, Natalia N Ivanova, Emiley A Eloie-Fadrosh, Nikos C Kyrpides, and Simon Roux. IMG/VR v4: an expanded database of uncultivated virus genomes within a framework of extensive functional, taxonomic, and ecological metadata. *Nucleic Acids Research*, 51(D1):D733–D743, 2023.
- [61] Tsung-Yi Lin, Priya Goyal, Ross Girshick, Kaiming He, and Piotr Dollár. Focal loss for dense object detection. In *Proceedings of the IEEE international conference on computer vision*, pages 2980–2988, 2017.