Phân loại lối sống thực khuẩn thể dựa trên phương pháp học sâu

Báo cáo tiến độ Luận văn Thạc sĩ

Vũ Quang Sơn

Trường Đại học Công nghệ – ĐHQGHN

Hướng dẫn: TS. Điệp Thị Hoàng

Tháng 3/2026

Nội dung báo cáo

1. Bài toán & Động lực nghiên cứu
2. Dữ liệu & Tiền xử lý
3. Mô hình đề xuất & Đóng góp kỹ thuật
4. Kết quả thực nghiệm
5. Kế hoạch & Tiến độ luận văn

Bài toán & Động lực nghiên cứu

Bài toán: Phân loại lối sống thực khuẩn thể (phage)

- **Độc lực (virulent)**: chỉ thực hiện chu trình tan
- **Ôn hòa (temperate)**: có thể tích hợp vào hệ gen vật chủ

Tầm quan trọng:

- Liệu pháp phage: chỉ dùng phage độc lực
- Phage ôn hòa có thể truyền gen kháng kháng sinh

Thách thức hiện tại:

1. Contig ngắn (100–1800 bp) từ metagenomic assembly
2. Phụ thuộc công cụ dự đoán gen – thất bại trên trình tự ngắn
3. Rò rỉ thông tin từ k-mer tokenization chồng lấn
4. Không có gen đánh dấu phổ quát cho phage

Mục tiêu

Phát triển phương pháp phân loại **trực tiếp từ chuỗi contig thô**, không phụ thuộc công cụ phát hiện gen, hiệu quả trên contig ngắn.

Dữ liệu & Tiền xử lý

Nguồn dữ liệu:

- Tổng hợp từ DeePhage & DeepPL
- **2.241** hệ gen phage hoàn chỉnh
- 707 ôn hòa + 1.534 độc lực ($\approx$1:2)
- Đánh giá: stratified **5-fold cross-validation**

Quy trình tiền xử lý (3 bước):

1. **Cửa sổ trượt** – tạo contig mô phỏng metagenomic
   4 nhóm: A (100–400bp), B (400–800bp), C (800–1200bp), D (1200–1800bp)
2. **Đảo ngược bổ sung** – tăng gấp đôi dữ liệu
   Tận dụng cấu trúc sợi đôi DNA: $A \leftrightarrow T$, $C \leftrightarrow G$
3. **Random Undersampling** – cân bằng lớp 1:1

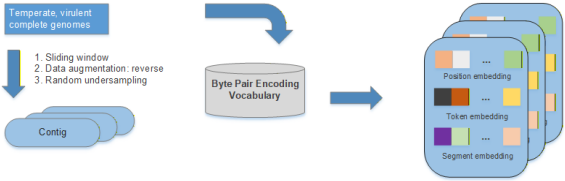

Hình: Quy trình tiền xử lý dữ liệu

Mô hình PhaBERT-CNN

Kiến trúc 3 thành phần:

1. **DNABERT-2** – mô hình nền tảng hệ gen
   BPE tokenization: giảm 5× chiều dài, loại bỏ rò rỉ thông tin
2. **MKCA** (Multi-Kernel Conv. Attention)
   Nhánh CNN (kernel 3,5,7) + Attention Pooling
3. **Đầu phân loại** – dự đoán nhị phân

Huấn luyện 2 giai đoạn:

- GĐ1: Đóng băng backbone, huấn luyện MKCA
- GĐ2: Mở khóa toàn bộ, tốc độ học phân biệt

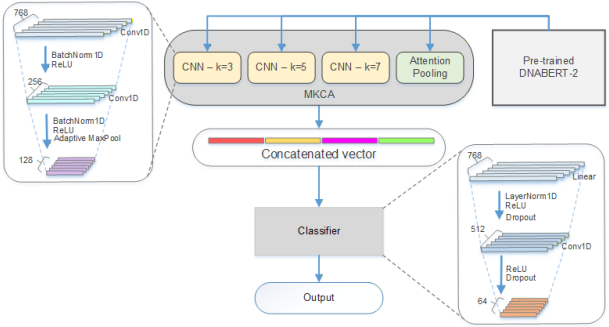

Hình: Kiến trúc PhaBERT-CNN

Kết quả thực nghiệm

Dữ liệu: 2.241 hệ gen phage (707 ôn hòa, 1.534 độc lực) – 5-fold cross-validation

Bảng 1: So sánh Accuracy (%) trên 4 nhóm độ dài contig

Phương pháp	A (100-400bp)	B (400-800bp)	C (800-1200bp)	D (1200-1800bp)
PhaBERT-CNN	**81.59**	**87.91**	**90.01**	90.69
PhaTYP	78.92	85.90	88.87	**91.02**
DeePhage	78.07	84.17	87.40	89.09
ProkBERT	80.68	85.35	84.03	84.73
DNABERT-2 (baseline)	81.52	85.56	87.25	87.26

Kết quả nổi bật:

- **Tốt nhất** trên nhóm A, B, C
- Cải thiện **0.91–5.98%** so với SOTA
- Sensitivity: 82.00–91.12%

Nhận xét:

- Nhóm D: PhaTYP nhỉnh hơn 0.34% nhờ đặc trưng protein
- ProkBERT stagnation từ nhóm B do k-mer chồng lấn
- PhaBERT-CNN ổn định nhất trên mọi nhóm

Phân tích đóng góp của MKCA (Ablation Study)

DNABERT-2 vs PhaBERT-CNN:

Nhóm	DNABERT-2	PhaBERT-CNN	Δacc
A	81.52	**81.59**	+0.07
B	85.56	**87.91**	+2.35
C	87.25	**90.01**	+2.76
D	87.26	**90.69**	+3.43

Xu hướng:

- Đóng góp MKCA **tăng dần** theo độ dài contig
- Specificity cải thiện tới **+6.90%** (Nhóm A)
- Contig dài → motif hoàn chỉnh hơn → CNN hiệu quả hơn

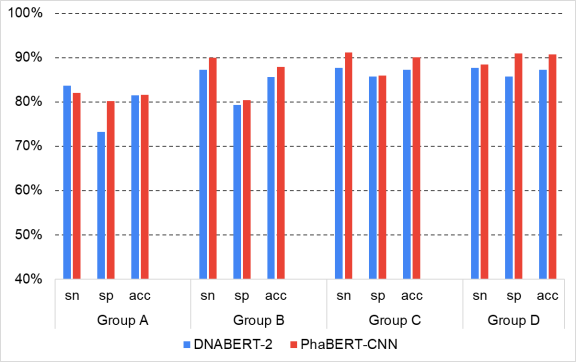

Hình: So sánh DNABERT-2 vs PhaBERT-CNN

Kết luận

MKCA (CNN đa kernel + Attention Pooling) bổ sung hiệu quả cho DNABERT-2: nhánh CNN trích xuất đặc

Kế hoạch & Tiến độ luận văn

Tiến độ viết luận văn:

Chương	Nội dung	Tiến độ
Chương 1	Giới thiệu	95%
Chương 2	Cơ sở lý thuyết	95%
Chương 3	Phương pháp đề xuất	85%
Chương 4	Thực nghiệm & Đánh giá	95%
Chương 5	Kết luận	90%
Tổng thể		**~92%**

Đã hoàn thành thêm:

- ✓ Trang bìa, lời cam đoan, tóm tắt Việt/Anh
- ✓ Danh mục hình, bảng, thuật ngữ, tài liệu tham khảo

Công việc còn lại:

- Rà soát thuật ngữ tiếng Việt xuyên suốt
- Hoàn thiện hình vẽ minh họa pipeline
- Hiệu đính và định dạng theo quy định
- Kiểm tra trích dẫn và tài liệu tham khảo

Timeline:

Thời gian	Công việc
T3/2026	Hoàn thiện Chương 3
T4/2026	Rà soát Chương 1, 2, 4
T4/2026	Hiệu đính toàn bộ
T5/2026	Nộp & bảo vệ luận văn

Cảm ơn thầy cô!

Phần hỏi đáp

Vũ Quang Sơn
Trường Đại học Công nghệ – ĐHQGHN