

Phân loại hệ gen thực khuẩn
dựa trên phương pháp học sâu
Luận văn Thạc sĩ Công nghệ thông tin

Vũ Quang Sơn

Trường Đại học Công nghệ – ĐHQGHN

Hướng dẫn: TS. Diệp Thị Hoàng

2026

Nội dung trình bày

- 1 Động lực nghiên cứu
- 2 Phát biểu bài toán
- 3 Đóng góp của luận văn
- 4 Dữ liệu & Tiền xử lý
- 5 Mô hình đề xuất
- 6 Kết quả thực nghiệm
- 7 Hạn chế & Hướng phát triển
- 8 Kết luận

Thực khuẩn thể (phage)

- **Độc lực** → chu trình tan
- **Ôn hòa** → tích hợp hệ gen vật chủ


Tại sao cần phân loại?

- Liệu pháp phage: **chỉ dùng độc lực**
- Ôn hòa → truyền gen kháng kháng sinh

Thách thức

1. Contig ngắn (100–1800 bp)
2. Phụ thuộc công cụ dự đoán gen
3. Rò rỉ thông tin (k-mer chồng lấn)
4. Không có gen đánh dấu phổ quát

Phát biểu bài toán



4 nhóm: A: 100–400 | B: 400–800 | C: 800–1200 | D: 1200–1800 (bp)
Mỗi nhóm g có mô hình f_{θ_g} riêng biệt

1 Kiến trúc PhaBERT-CNN

DNABERT-2 + MKC (CNN kernel 3,5,7 + gộp trung bình có mặt nạ)

→ Trực tiếp trên chuỗi DNA thô, không cần dự đoán gen

2 Đánh giá toàn diện

5-fold CV $\times$ 4 nhóm độ dài

→ **82,01–91,38%** accuracy, cải thiện **0,36–6,65%** vs SOTA

3 Ablation study (7 cấu hình)

→ MKC đóng góp **+0,49 – +4,12%** accuracy


2.241 hệ gen phage

707 ôn hòa + 1.534 độc lực

5-fold cross-validation

3 bước xử lý:

- ❶ Cửa sổ trượt
- ❷ Đảo ngược bổ sung
- ❸ Undersampling 1:1



Kiến trúc PhaBERT-CNN


3 thành phần:

- 1 DNABERT-2
(BPE tokenization)
- 2 MKC
(CNN kernel 3,5,7
+ masked avg pool)
- 3 Classification head

Huấn luyện 2 GD:

GD1: Freeze backbone

GD2: Unfreeze + LR phân biệt



Kết quả thực nghiệm

Phương pháp	A	B	C	D
	100-400bp	400-800bp	800-1200bp	1200-1800bp
PhaBERT-CNN	82,01	87,33	89,90	91,38
PhaTYP	78,92	85,90	88,87	91,02
DeePhage	78,07	84,17	87,40	89,09
ProkBERT	80,68	85,35	84,03	84,73
DNABERT-2	81,52	85,56	87,25	88,36

Chỉ số: Accuracy (%) – 5-fold stratified cross-validation


- Sn: 82–92% (cao nhất mọi nhóm) → phát hiện tốt phage độc lực cho liệu pháp
- PhaTYP Sp cao hơn nhóm C, D nhờ đặc trưng protein (87,65/89,75 vs 86,92/87,63)
- DeePhage Sp thấp nhất (71–80%) → thiên lệch phân loại độc lực

Ablation Study – Đóng góp của MKC

Cấu hình	A	B	C	D
DNABERT-2	81,52	85,56	87,25	88,36
+ Pooling	83,54	87,63	89,88	91,08
+ CNN	82,18	87,36	90,16	91,07
PhaBERT	82,01	87,33	89,90	91,38

Accuracy (%) – 5-fold CV

- Pooling $\succ$ CNN ở contig ngắn (A, B)
- CNN $\succ$ Pooling ở contig dài (C)
- Kết hợp $\rightarrow$ tốt nhất ở D (**91,38%**)
- Sp: **+8,61%** nhóm A (73,25 $\rightarrow$ 81,86)



Hạn chế & Hướng phát triển

Hạn chế

Random undersampling

Mất thông tin lớp đa số
(class weighting, focal loss chưa cải thiện)

Chỉ dùng nucleotide

Chưa khai thác đặc trưng protein

Hướng phát triển

Data augmentation

Đột biến ngẫu nhiên, mixup

Đa phương thức

DNABERT-2 + ESM-2/ProtBERT

Mở rộng ứng dụng

Dự đoán host, phát hiện prophage

PhaBERT-CNN = DNABERT-2 +
MKC → trực tiếp trên chuỗi DNA thô

Accuracy: **82,01 – 91,38%** trên 4 nhóm contig (100–1800 bp)

Cải thiện **0,36–6,65%** so với SOTA | MKC: **+0,49 – +4,12%**

Không phụ thuộc công cụ dự đoán gen
→ phù hợp contig ngắn, phân mảnh

Cảm ơn thầy cô!

Phần hỏi đáp

Vũ Quang Sơn

Trường Đại học Công nghệ – ĐHQGHN