

Phân loại hệ gen thực khuẩn
dựa trên phương pháp học sâu
Luận văn Thạc sĩ Công nghệ thông tin

Vũ Quang Sơn

Đại học Công nghệ – ĐHQGHN

Giảng viên hướng dẫn: TS. Diệp Thị Hoàng

05-2026

Thực khuẩn thể (phage)

- **Độc lực** → chu trình tan, tấn công vào gen vật chủ
- **Ôn hòa** → có chu trình tiềm tan, tích hợp vào gen vật chủ


Tại sao cần phân loại?

- Liệu pháp phage: **chỉ dùng độc lực**
- Ôn hòa → truyền gen kháng kháng sinh

Động lực nghiên cứu

- Các phương pháp nuôi cấy truyền thống tốn nhiều chi phí và thời gian.

Phát biểu bài toán



- Dữ liệu đầu vào được chia thành 4 nhóm: A (100–400), B(400–800), C(800–1200), D(1200–1800)
- Mỗi nhóm được thực hiện xử lý trên 1 mô hình riêng

Phương pháp	Biểu diễn	Hạn chế chính
PhaTYP	Protein (BERT)	Cần Prodigal phát hiện protein → fail contig ngắn
DeePhage	One-hot (CNN)	Không tận dụng các mô hình tiền huấn luyện
ProkBERT	LCA k-mer (BERT)	Sử dụng K-mer chồng lán → Rò rỉ thông tin
DeepPL	k-mer (DNABERT)	Giới hạn độ dài dữ liệu đầu vào 512bp cho 1 cửa sổ

Cần một phương pháp có thể khắc phục các nhược điểm trên

Kiến trúc PhaBERT: là sự kết hợp của mô hình nền tảng DNABERT-2 và mô-đun MKC(Multi-Kernal Convolutional) gồm nhiều nhánh CNN có kích thước độ cửa sổ tích chập khác nhau cùng 1 nhánh pooling toàn cục với các ưu điểm:

- 1 Xử lý trực tiếp trên chuỗi DNA thô, độ dài bất kỳ, không cần công cụ tiền xử lý.
- 2 Sử dụng BPE trong quá trình tokenization nên không rò rỉ thông tin.
- 3 Kết hợp mô hình xử lý chuyên biệt với mô hình nền tảng cho hiệu suất tối ưu trên bài toán.


Kiến trúc PhaBERT

2 thành phần:

1 DNABERT-2

2 MKC

- Các nhánh CNN
- Nhánh pooling
- Đầu phân loại




2.241 hệ gen phage

707 ôn hòa + 1.534 độc lực

5-fold cross-validation

3 bước xử lý:

- 1 Cửa sổ trượt tạo contig
- 2 Tăng cường dữ liệu với đảo ngược bổ sung
- 3 Cân bằng tỷ lệ nhãn với Random Undersampling



GD1: Freeze backbone

Đóng băng DNABERT-2
Chỉ huấn luyện mô-đun MKC
1 epochs

**GD2: Unfreeze all**

Tinh chỉnh toàn bộ mô hình
Mỗi phần có tốc độ học phân
biệt
10 epochs

Thiết lập thực nghiệm

Phương pháp đánh giá:

- Kiểm định chéo phân tầng 5 phần


Kết quả so sánh

Phương pháp	A	B	C	D
	100-400bp	400-800bp	800-1200bp	1200-1800bp
PhaBERT	82,01	87,33	89,90	91,38
PhaTYP	78,92	85,90	88,87	91,02
DeePhage	78,07	84,17	87,37	89,09
ProkBERT	80,68	85,35	84,03	84,73
DNABERT-2	81,52	85,56	87,25	88,36

Chỉ số: Accuracy (%) – 5-fold stratified cross-validation


- PhaBERT cho chỉ số accuracy cao nhất so với các phương pháp còn lại

Phân tích Sensitivity/Specificity



- PhaBERT cho Sn cao nhất mọi nhóm (82–92%)
→ phát hiện tốt phage độc lực
- PhaTYP Sp tốt hơn ở 3 nhóm (B, C, D) → nhờ đặc trưng cấp độ protein

Ablation Study



Hạn chế

- Việc sử dụng Random Undersampling có thể mất thông tin quan trọng
- Mô hình hiện tại chỉ sử dụng đặc trưng cấp độ nucleotide.

Hướng phát triển

- Sử dụng phương pháp xử lý mất cân bằng nhãn khác để không làm mất dữ liệu
- Kết hợp đặc trưng cấp độ protein.

Cảm ơn thầy cô!

Vũ Quang Sơn

Trường Đại học Công nghệ – ĐHQGHN

Thống kê dữ liệu chi tiết

Nhóm	Tập	Ôn hòa	Độc lực	Tổng
A (100–400 bp)	Huấn luyện	230.156	230.156	460.312
	Kiểm định	57.366	215.054	272.420
B (400–800 bp)	Huấn luyện	95.750	95.750	191.500
	Kiểm định	23.804	89.404	113.208
C (800–1200 bp)	Huấn luyện	55.024	55.024	110.048
	Kiểm định	13.694	51.424	65.118
D (1200–1800 bp)	Huấn luyện	42.780	42.780	85.560
	Kiểm định	10.640	39.960	50.600

Số liệu sau tăng cường (RC). Undersampling 1:1 chỉ áp dụng trên tập huấn luyện.

Ablation đầy đủ 7 cấu hình

Cấu hình	Nhóm A			Nhóm B			Nhóm C			Nhóm D		
	Sn	Sp	Acc	Sn	Sp	Acc	Sn	Sp	Acc	Sn	Sp	Acc
DNABERT-2	83,68	73,25	81,52	87,24	79,27	85,56	87,68	85,75	87,25	88,75	86,99	88,36
PhaBERT	82,07	81,86	82,01	88,11	84,53	87,33	90,69	86,92	89,90	92,38	87,63	91,38
DNABERT-2-CNN	82,68	80,44	82,18	88,11	84,63	87,36	91,21	86,25	90,16	91,75	88,58	91,07
DNABERT-2-P	85,12	77,65	83,54	89,04	84,49	87,63	90,84	86,30	89,88	91,72	88,74	91,08
PhaBERT-NO-K5	85,05	78,03	83,56	88,31	84,19	87,44	91,12	86,71	90,18	92,22	86,92	90,99
PhaBERT-NO-K3	84,18	78,65	83,00	88,61	83,50	85,51	91,80	85,53	90,49	92,22	86,92	91,05
PhaBERT-NO-K7	83,62	78,47	82,55	89,54	82,06	87,95	90,95	87,47	90,21	91,56	89,20	91,05

So sánh chi tiết với các phương pháp tiên tiến

Phương pháp	Nhóm A (100–400 bp)			Nhóm B (400–800 bp)			Nhóm C (800–1200 bp)			Nhóm D (1200–1800 bp)		
	Sn	Sp	Acc	Sn	Sp	Acc	Sn	Sp	Acc	Sn	Sp	Acc
PhaBERT	82,07	81,86	82,01	88,11	84,53	87,33	90,69	86,92	89,90	92,38	87,63	91,38
PhaTYP	79,07	78,77	78,92	86,74	85,06	85,90	90,09	87,65	88,87	92,29	89,75	91,02
DeePhage	80,09	71,79	78,07	86,46	77,18	84,17	88,20	80,31	87,37	91,17	80,84	89,09
ProkBERT	80,65	80,80	80,68	85,67	84,15	85,35	83,61	85,72	84,03	85,00	83,68	84,73

Kiểm định chéo phân tầng 5 phần. Sn = Độ nhạy, Sp = Độ đặc hiệu, Acc = Độ chính xác.

Thuật toán Byte Pair Encoding (BPE)

Thuật toán:

- 1 Khởi tạo từ điển $V = \{A, T, G, C\}$
- 2 Đếm tần suất mọi cặp token liên kề
- 3 Ghép cặp có tần suất cao nhất $\rightarrow$ token mới
- 4 Lặp bước 2-3 cho đến $|V| = 4.096$

Kết quả:

- Token có độ dài biến đổi, trung bình ≈ 5 nt/token
- Giảm $\sim 5\times$ độ dài chuỗi so với k-mer
- Không chồng lấn $\rightarrow$ loại bỏ rò rỉ thông tin

Ví dụ trên chuỗi DNA:

Gốc: A T C G A T C G A T G C

Bước 1: AT C G AT C G AT G C
(ghép “AT” - tần suất cao nhất)

Bước 2: AT CG AT CG AT G C
(ghép “CG”)

Bước 3: ATCG ATCG AT G C
(ghép “AT”+“CG”)

Mỗi nucleotide thuộc
đúng 1 token duy nhất