ĐẠI HỌC QUỐC GIA HÀ NỘI
TRƯỜNG ĐẠI HỌC CÔNG NGHỆ

NGHIÊN CỨU CÁC MÔ HÌNH HỌC SÂU CHO BÀI TOÁN QUẢN LÝ THIẾT BỊ VÔ TUYẾN

LUẬN VĂN THẠC SĨ

Ngành: Khoa học máy tính

HÀ NỘI - 2025

ĐẠI HỌC QUỐC GIA HÀ NỘI
TRƯỜNG ĐẠI HỌC CÔNG NGHỆ

Lê Thế Nam

NGHIÊN CỨU CÁC MÔ HÌNH HỌC SÂU CHO BÀI TOÁN QUẢN LÝ THIẾT BỊ VÔ TUYẾN

LUẬN VĂN THẠC SĨ

Ngành: Khoa học máy tính

Cán bộ hướng dẫn: TS. Nguyễn Thế Hoàng Anh

Cán bộ đồng hướng dẫn: PGS.TS. Lê Thanh Hà

HÀ NỘI - 2025

VIETNAM NATIONAL UNIVERSITY, HANOI
UNIVERSITY OF ENGINEERING AND TECHNOLOGY

Le The Nam

INVESTIGATION OF DEEP LEARNING MODELS FOR WIRELESS DEVICE MANAGEMENT

MASTER'S THESIS

Major: Computer Science

Supervisor: Dr. Nguyen The Hoang Anh

Co-Supervisor: Assoc. Prof. Le Thanh Ha

HANOI - 2025

Lời cảm ơn

Với tất cả lòng kính trọng và biết ơn sâu sắc, tôi xin gửi lời cảm ơn chân thành đến PGS.TS. Lê Thanh Hà và TS. Nguyễn Thế Hoàng Anh, những người thầy không chỉ truyền đạt tri thức quý báu mà còn là nguồn động viên, khích lệ tinh thần to lớn trong suốt quá trình tôi học tập, nghiên cứu và hoàn thiện luận văn thạc sĩ.

Tôi xin trân trọng cảm ơn TS. Trịnh Đình Hoàn, người thầy đã luôn đồng hành, định hướng và khơi dậy niềm đam mê nghiên cứu trong tôi. Sự hỗ trợ và những lời khuyên tận tâm của thầy là hành trang quý giá trên con đường tri thức của tôi.

Tôi xin gửi lời tri ân sâu sắc đến các thầy, cô giáo đang công tác và giảng dạy tại trường Đại học Công Nghệ - Đại học Quốc gia Hà Nội, những người đã tạo mọi điều kiện thuận lợi để tôi được học tập và phát triển trong môi trường sư phạm đầy nhiệt huyết.

Tiếp theo, tôi xin gửi lời cảm ơn đến các đồng nghiệp trong nhóm Công nghệ, khối Công nghệ mới, Viettel AI, những người đã không chỉ hỗ trợ chuyên môn mà còn là những người bạn đồng hành, sẻ chia những khó khăn và động viên tôi vượt qua những thử thách trong suốt quá trình học tập và làm việc.

Cuối cùng, tôi xin dành sự biết ơn đến gia đình, đặc biệt là người vợ yêu quý, những người đã luôn là nguồn động lực và điểm tựa tinh thần vững chắc cho tôi. Sự hy sinh, thấu hiểu và tình yêu thương của gia đình là món quà vô giá, giúp tôi có thêm sức mạnh để hoàn thành chặng đường học tập thạc sĩ đầy thử thách, gian nan.

Tôi xin chân thành cảm ơn!

Lời cam đoan

Tôi là Lê Thế Nam, học viên cao học khóa 30, ngành Khoa học máy tính. Tôi xin cam đoan luận văn thạc sĩ "Nghiên cứu các mô hình học sâu cho bài toán quản lý thiết bị vô tuyến" là công trình nghiên cứu, xây dựng của riêng mình dưới sự hướng dẫn của thầy PGS.TS Lê Thanh Hà và TS. Nguyễn Thế Hoàng Anh. Các nội dung nghiên cứu, kết quả trong luận văn là xác thực.

Các thông tin sử dụng trong luận văn là có cơ sở và không có nội dung nào sao chép từ các tài liệu mà không ghi rõ trích dẫn tham khảo. Tôi xin chịu trách nhiệm về lời cam đoan này.

Hà Nội, ngày ... tháng ... năm 2025

Học viên

Lê Thế Nam

Tóm tắt

Tóm tắt

Từ khóa: *Ước lượng camera pose*, *Tái tạo đám mây điểm 3D*, *Phục dựng cấu trúc từ chuyển động*, *Trường bức xạ nơ-ron*, *Quản lý thiết bị vô tuyến*, *Máy bay không người lái*

Abstract

Abstract

Keywords: *Camera pose estimation*, *3D point cloud reconstruction*, *Structure from Motion*, *Neural Radiance Fields*, *Wireless device management*, *Unmanned Aerial Vehicle*

Mục lục

Lời cảm ơn

Lời cam đoan **i**

Tóm tắt **ii**

Abstract **iii**

Mục lục **iv**

Danh sách hình vẽ **ix**

Danh sách bảng **x**

Danh mục các từ viết tắt và thuật ngữ **xi**

Chương 1 Giới thiệu **1**

1.1 Bối cảnh nghiên cứu 1

1.2 Vấn đề nghiên cứu 2

1.2.1 Hạn chế về dữ liệu huấn luyện 3

1.2.2 Thiếu gen đánh dấu phổ quát 3

1.2.3 Thách thức với các đoạn DNA ngắn 3

1.2.4 Vấn đề tương đồng trình tự với vi khuẩn chủ 4

1.2.5 Phát biểu bài toán 4

1.3 Mục tiêu nghiên cứu 5

1.3.1 Mục tiêu 1: Phát triển mô hình PhaBERT-CNN 5

1.3.2 Mục tiêu 2: Đánh giá hiệu suất trên nhiều nhóm độ dài contig . 6

1.3.3 Mục tiêu 3: So sánh với các phương pháp tiên tiến 6

1.3.4 Mục tiêu 4: Phân tích tác động của các thành phần kiến trúc . 7

1.3.5 Mục tiêu 5: Đề xuất chiến lược huấn luyện hiệu quả 7

1.3.6 Mục tiêu 6: Cung cấp phân tích và hướng dẫn thực tiễn 7

1.4 Đóng góp chính của luận văn 8
1.4.1 Kiến trúc PhaBERT-CNN mới 8
1.4.2 Hiệu suất vượt trội trên contig ngắn và trung bình 9
1.4.3 Chiến lược huấn luyện hai giai đoạn hiệu quả 9
1.4.4 Đánh giá toàn diện và phân tích so sánh 10
1.4.5 Giải quyết các hạn chế của phương pháp hiện có 10
1.4.6 Đóng góp về mặt phương pháp luận 11
1.5 Phạm vi nghiên cứu 11
1.5.1 Phạm vi về bài toán 11
1.5.2 Phạm vi về dữ liệu 12
1.5.3 Phạm vi về phương pháp 12
1.5.4 Phạm vi về đánh giá 13
1.5.5 Phạm vi về triển khai 13
1.5.6 Giới hạn và giả định 13
1.6 Bố cục luận văn 14

Chương 2 Cơ sở lý thuyết 17
2.1 Thực khuẩn thể và phân loại lối sống 17
2.1.1 Giới thiệu về thực khuẩn thể 17
2.1.2 Cấu trúc và thành phần của thực khuẩn thể 17
2.1.3 Chu trình sống của thực khuẩn thể 18
2.1.4 Vai trò sinh thái và ứng dụng 19
2.2 Metagenomics và giải trình tự thế hệ mới 21
2.2.1 Giới thiệu về metagenomics 21
2.2.2 Công nghệ giải trình tự thế hệ mới 21
2.2.3 Lắp ráp metagenomic và contig 22
2.2.4 Ứng dụng của metagenomics trong nghiên cứu phage 24
2.3 Học máy cho phân tích dữ liệu sinh học 25
2.3.1 Giới thiệu về học máy 25
2.3.2 Các loại học máy 25
2.3.3 Các khái niệm cơ bản 26
2.3.4 Học máy cho phân tích chuỗi sinh học 27
2.4 Học sâu và mạng nơ-ron 28
2.4.1 Giới thiệu về học sâu 28

2.4.2 Mạng nơ-ron nhân tạo 28
2.4.3 Backpropagation và tối ưu hóa 29
2.4.4 Regularization techniques 30
2.4.5 Loss functions 30
2.4.6 Ưu điểm của học sâu cho dữ liệu sinh học 31
2.5 Mạng nơ-ron tích chập 31
2.5.1 Giới thiệu về CNN 31
2.5.2 Phép tích chập (Convolution) 31
2.5.3 Các thành phần của CNN 32
2.5.4 Multi-scale CNN 32
2.5.5 CNN cho phân tích chuỗi sinh học 33
2.6 Kiến trúc Transformer 34
2.6.1 Giới thiệu 34
2.6.2 Self-Attention Mechanism 34
2.6.3 Positional Encoding 35
2.6.4 Feed-Forward Networks 36
2.6.5 Transformer Encoder 36
2.6.6 Ưu điểm của Transformer 36
2.6.7 Transformer cho genomics 36
2.7 BERT và Masked Language Modeling 37
2.7.1 Giới thiệu về BERT 37
2.7.2 Masked Language Modeling (MLM) 37
2.7.3 Kiến trúc BERT 38
2.7.4 Transfer Learning với BERT 38
2.7.5 Ưu điểm của BERT 39
2.7.6 BERT cho genomics 39
2.8 DNABERT: BERT cho chuỗi DNA 39
2.8.1 Giới thiệu 39
2.8.2 Tokenization: Overlapping k-mers 39
2.8.3 Hạn chế của DNABERT 40
2.8.4 Thành công và ảnh hưởng 40
2.9 DNABERT-2: Cải tiến với BPE và Multi-species Training 41
2.9.1 Giới thiệu 41
2.9.2 Byte Pair Encoding (BPE) Tokenization 41

2.9.3 Attention with Linear Biases (ALiBi) 43
2.9.4 Multi-species Pre-training 43
2.9.5 Kiến trúc và Training 44
2.9.6 Hiệu suất 45
2.9.7 Tại sao chọn DNABERT-2 cho PhaBERT-CNN 45
2.10 Học chuyển giao trong sinh tin học 46
2.10.1 Khái niệm học chuyển giao 46
2.10.2 Pre-training và Fine-tuning 46
2.10.3 Chiến lược Fine-tuning 47
2.10.4 Lợi ích của Transfer Learning 48
2.10.5 Transfer Learning trong Genomics 48
2.10.6 PhaBERT-CNN và Transfer Learning 49
2.11 Các công trình liên quan 49
2.11.1 Phương pháp học máy truyền thống 49
2.11.2 Phương pháp học sâu 51
2.11.3 So sánh tổng quan 54
2.11.4 Vị trí của PhaBERT-CNN 54

Chương 3 Phương pháp đề xuất 55
3.1 Tổng quan phương pháp PhaBERT-CNN 55
3.1.1 Động lực thiết kế 55
3.1.2 Kiến trúc tổng thể 55
3.1.3 Quy trình xử lý 57
3.1.4 Ưu điểm của kiến trúc 57
3.2 Xây dựng tập dữ liệu 58
3.2.1 Nguồn dữ liệu 58
3.2.2 Tạo contigs bằng sliding window 58
3.2.3 Data augmentation 59
3.2.4 Xử lý class imbalance 60
3.2.5 Chia tập dữ liệu 60
3.2.6 Thống kê tập dữ liệu 61
3.3 Mô hình nền tảng DNABERT-2 61
3.3.1 Tokenization với BPE 61
3.3.2 Model architecture 62

3.3.3 Positional encoding: ALiBi 62
3.3.4 Pre-training 63
3.3.5 Output representations 63
3.4 Kiến trúc PhaBERT-CNN 63
3.4.1 Tổng quan kiến trúc 63
3.4.2 Multi-scale CNN Feature Extractor 64
3.4.3 Attention-based Global Feature Extractor 65
3.4.4 Classification Head 65
3.4.5 Tổng số tham số 66
3.5 Chiến lược huấn luyện 67
3.5.1 Two-Phase Fine-tuning Strategy 67
3.5.2 Loss Function 68
3.5.3 Training Configuration 69
3.5.4 Regularization 70
3.5.5 Model Selection 70
3.5.6 Reproducibility 70
3.5.7 Tổng kết quy trình huấn luyện 70

Chương 4 Thực nghiệm và Đánh giá **72**

Chương 5 Kết luận **73**
5.1 Tóm tắt nghiên cứu 73
5.2 Kết quả chính 73
5.2.1 Hiệu suất vượt trội trên short-medium contigs 73
5.2.2 Cân bằng sensitivity-specificity 73
5.2.3 Khắc phục hạn chế của phương pháp hiện có 74
5.3 Đóng góp của luận văn 74
5.4 Hạn chế 74
5.5 Hướng nghiên cứu tương lai 75
5.5.1 Cải thiện phương pháp 75
5.5.2 Mở rộng ứng dụng 75
5.5.3 Nghiên cứu cơ bản 75
5.6 Kết luận cuối cùng 76

Tài liệu tham khảo **77**

Danh sách hình vẽ

2.1 Ví dụ về quá trình xây dựng vocabulary BPE (nguồn: paper DNABERT-2) 42

3.1 Tổng quan kiến trúc PhaBERT-CNN cho dự đoán lối sống thực khuẩn thể 56

Danh sách bảng

2.1 So sánh các phương pháp phân loại lối sống phage 54

3.1 Tham số tạo contig cho các nhóm độ dài 59
3.2 Thống kê số lượng contigs sau augmentation (trước undersampling) . 61
3.3 Phân bố tham số trong PhaBERT-CNN 66

Danh mục các từ viết tắt và thuật ngữ

STT	Từ viết tắt/ thuật ngữ	Cụm từ đầy đủ	Cụm từ tiếng Việt
1	Camera pose	Camera pose	Vị trí, hướng chụp của máy ảnh trong không gian 3D
2	NeRFs	Neural Radiance Fields	Trường bức xạ nơ-ron
3	SfM	Structure from Motion	Phục dựng cấu trúc từ chuyển động
4	MVS	Multi-view Stereo	Tái tạo lập thể đa góc nhìn
5	RRU	Remote Radio Unit	Thiết bị thu phát vô tuyến từ xa
6	DiffRF	Differentiable rendering functions	Hàm kết xuất khả vi
7	RE	Reprojection Error	Sai số chiếu lại
8	MRE	Mean Reprojection Error	Sai số chiếu lại trung bình
9	F	Fundamental Matrix	Ma trận cơ bản
10	E	Essential Matrix	Ma trận cốt yếu
11	PnP	Perspective-n-Point	Căn chỉnh phối cảnh N điểm
12	NCC	Normalized Cross - Correlation	Tương quan chéo được chuẩn hóa
13	ALIKED	Affine Local Invariant Keypoint Extraction and Description	
14	MLP	Multi-Layer Perceptron	Mạng nơ-ron Perceptron đa lớp
15	SIFT	Scale-Invariant Feature Transform	Biến đổi đặc trưng bất biến với tỉ lệ
16	DoG	Difference of Gaussian	Thuật toán hiệu số Gauss
17	PCS	Point Cloud Smoothness	Độ mượt mà của đám mây điểm

Chương 1

Giới thiệu

1.1 Bối cảnh nghiên cứu

Thực khuẩn thể (bacteriophage), thường được gọi tắt là phage, là các virus có khả năng xâm nhiễm và nhân lên bên trong tế bào vi khuẩn. Được phát hiện độc lập bởi Frederick Twort năm 1915 và Félix d'Hérelle năm 1917, thực khuẩn thể được coi là dạng sống phong phú nhất trên Trái Đất với số lượng ước tính lên tới 10^{31} cá thể [1]. Chúng đóng vai trò quan trọng trong việc điều hòa quần thể vi khuẩn, duy trì cân bằng sinh thái vi sinh vật, và là động lực chính của quá trình chuyển gen ngang (horizontal gene transfer) giữa các vi khuẩn [2].

Thực khuẩn thể được phân loại thành hai nhóm chính dựa trên chiến lược nhân lên của chúng: thực khuẩn thể độc lực (virulent phage) và thực khuẩn thể ôn hòa (temperate phage) [3]. Thực khuẩn thể độc lực, còn được gọi là phage phân giải nghiêm ngặt (strictly lytic phage), chỉ thực hiện chu trình phân giải (lytic cycle). Trong chu trình này, phage xâm nhập vào tế bào vi khuẩn, chiếm đoạt bộ máy tổng hợp của tế bào chủ để sản xuất các virion con, và cuối cùng gây phá vỡ tế bào chủ để giải phóng các phage mới được tạo ra [4]. Ngược lại, thực khuẩn thể ôn hòa có khả năng thực hiện cả chu trình phân giải và chu trình lysogen. Trong chu trình lysogen, vật liệu di truyền của phage được tích hợp vào nhiễm sắc thể của vi khuẩn chủ dưới dạng prophage, nơi nó tồn tại ở trạng thái không hoạt động và nhân lên cùng với bộ gen của vi khuẩn qua nhiều thế hệ [5]. Prophage có thể được kích hoạt bởi các yếu tố môi trường như stress, tia UV, hoặc các tác nhân gây tổn thương DNA, chuyển sang chu trình phân giải [6].

Việc phân loại chính xác lối sống của thực khuẩn thể có ý nghĩa quan trọng trong cả nghiên cứu vi sinh vật học và ứng dụng y sinh học. Trong nghiên cứu hệ vi sinh vật (microbiome), việc xác định lối sống của phage giúp làm sáng tỏ các tương tác phức tạp giữa phage và vi khuẩn chủ, từ đó hiểu rõ hơn về vai trò sinh thái của phage trong các cộng đồng vi sinh vật [7]. Đặc biệt, trong bối cảnh kháng kháng sinh ngày càng gia tăng, liệu pháp phage (phage therapy) đang được xem xét như

một giải pháp thay thế đầy hứa hẹn cho kháng sinh truyền thống [8, 9]. Tuy nhiên, chỉ có thực khuẩn thể độc lực mới phù hợp cho liệu pháp phage, vì thực khuẩn thể ôn hòa có thể tích hợp vào bộ gen của vi khuẩn bệnh nguyên và tiềm ẩn nguy cơ truyền các gen độc lực hoặc gen kháng kháng sinh cho vi khuẩn chủ thông qua quá trình lysogenic conversion [10]. Do đó, việc phân loại chính xác lối sống của phage là bước tiên quyết để lựa chọn các ứng cử viên phage an toàn và hiệu quả cho các ứng dụng trị liệu.

Các phương pháp truyền thống để xác định lối sống của thực khuẩn thể dựa vào nuôi cấy trong phòng thí nghiệm và quan sát kiểu hình, bao gồm việc theo dõi sự hình thành mảng bám (plaque) trên thạch nuôi cấy vi khuẩn và phân tích khả năng lysogen hóa của phage [7]. Tuy nhiên, các phương pháp này tốn thời gian, đòi hỏi nhiều công sức, và quan trọng hơn, không thể áp dụng cho phần lớn các phage chưa được nuôi cấy được (unculturable phage) có trong các mẫu môi trường [7]. Theo ước tính, chỉ có khoảng 1% vi khuẩn trong tự nhiên có thể được nuôi cấy trong điều kiện phòng thí nghiệm, và tỷ lệ này còn thấp hơn đối với thực khuẩn thể. Những hạn chế này đã thúc đẩy sự phát triển của các phương pháp tính toán để dự đoán lối sống của phage trực tiếp từ dữ liệu trình tự gen.

Với sự phát triển mạnh mẽ của công nghệ giải trình tự thế hệ mới (next-generation sequencing - NGS), metagenomics đã trở thành công cụ quan trọng để nghiên cứu đa dạng sinh học của phage trong các môi trường tự nhiên mà không cần nuôi cấy [11, 12]. Trong phân tích metagenomic, bộ gen của phage thường được phục hồi dưới dạng các contig - các chuỗi liên tục được lắp ráp từ các đoạn đọc ngắn chồng lấp nhau [13, 14]. Tuy nhiên, các contig này thường có độ dài biến thiên lớn và bị phân mảnh do độ phủ giải trình tự không đồng đều, các hiện vật kỹ thuật, và các vùng gen lặp lại, khiến việc phát triển các công cụ có thể phân loại chính xác các chuỗi không hoàn chỉnh trở thành một thách thức tính toán quan trọng.

1.2 Vấn đề nghiên cứu

Các phương pháp tính toán để dự đoán lối sống của thực khuẩn thể phải đối mặt với bốn thách thức chính: hạn chế về dữ liệu, thiếu gen đánh dấu đặc trưng, độ dài đoạn DNA ngắn, và vấn đề tương đồng trình tự.

1.2.1 Hạn chế về dữ liệu huấn luyện

Cơ sở dữ liệu bộ gen thực khuẩn thể hiện có vẫn còn rất hạn chế so với sự đa dạng khổng lồ của phage trong tự nhiên. Mặc dù thực khuẩn thể là dạng sống phong phú nhất trên Trái Đất, phần lớn chúng chưa được phân lập và nghiên cứu đặc tính [12]. Sự thiếu hụt dữ liệu có nhãn (labeled data) này tạo ra thách thức lớn cho việc huấn luyện các mô hình học máy, đặc biệt là các mô hình học sâu đòi hỏi lượng dữ liệu lớn để đạt hiệu suất tốt. Hơn nữa, sự phân bố không cân bằng giữa các lớp (class imbalance) - với số lượng phage độc lực thường nhiều hơn phage ôn hòa trong các tập dữ liệu công khai - có thể dẫn đến mô hình thiên lệch (biased model) ưu tiên dự đoán lớp đa số.

1.2.2 Thiếu gen đánh dấu phổ quát

Không giống như vi khuẩn có gen 16S rRNA làm gen đánh dấu phổ quát (universal marker gene) cho phân loại phân loại học, thực khuẩn thể không có gen đánh dấu tương tự [11]. Sự thiếu vắng này khiến các phương pháp phân loại dựa trên gen đánh dấu (marker gene-based approaches) không khả thi đối với phage. Mặc dù một số gen như integrase, repressor, hoặc các gen liên quan đến chu trình lysogen có thể chỉ thị lối sống ôn hòa, nhưng chúng không phải lúc nào cũng hiện diện hoặc dễ dàng nhận diện trong các chuỗi gen ngắn và phân mảnh.

1.2.3 Thách thức với các đoạn DNA ngắn

Dữ liệu metagenomic thường chứa nhiều đoạn DNA ngắn bao gồm chỉ một phần gen hoặc các chuỗi gen không hoàn chỉnh, làm phức tạp các chiến lược phân loại dựa trên gen chức năng [15]. Các contig ngắn (dưới 1000 bp) đặc biệt khó phân loại vì:

- Chúng có thể không chứa đủ thông tin về gen để xác định lối sống
- Các công cụ dự đoán gen như Prodigal [16] có hiệu suất giảm đáng kể trên các đoạn ngắn hơn 200 bp [17]
- Bản chất phân mảnh của lắp ráp metagenomic có thể không chứa các chuỗi gen hoàn chỉnh cần thiết để nhận dạng protein chính xác

- Tín hiệu thống kê từ thành phần nucleotide (nucleotide composition) yếu hơn trên các chuỗi ngắn

Trong thực tế, phân tích metagenomic thường tạo ra các contig với phân bố độ dài rộng, từ vài trăm base pairs đến hàng chục kilobase pairs, tùy thuộc vào độ phủ giải trình tự (sequencing coverage), độ phức tạp của mẫu, và chất lượng lắp ráp. Các contig ngắn chiếm tỷ lệ đáng kể trong các tập dữ liệu metagenomic thực tế, do đó việc phát triển các phương pháp có thể xử lý hiệu quả các chuỗi ngắn là cần thiết cho ứng dụng thực tiễn.

1.2.4 Vấn đề tương đồng trình tự với vi khuẩn chủ

Thực khuẩn thể có thể chia sẻ các chuỗi gen với vi khuẩn chủ của chúng thông qua quá trình chuyển gen ngang (horizontal gene transfer), đặc biệt là trong trường hợp của prophage được tích hợp vào bộ gen vi khuẩn [18]. Sự tương đồng trình tự này có thể dẫn đến phân loại sai trong quá trình gán phân loại học (taxonomic assignment). Hơn nữa, các phage ôn hòa có thể mang theo các gen có nguồn gốc từ vi khuẩn, làm mờ ranh giới giữa trình tự phage và trình tự vi khuẩn. Điều này đặc biệt problematic khi phân tích các contig metagenomic, nơi không rõ liệu một contig cụ thể có phải là phage độc lập, prophage được tích hợp, hay một phần của bộ gen vi khuẩn chứa các yếu tố giống phage.

1.2.5 Phát biểu bài toán

Dựa trên các thách thức trên, bài toán dự đoán lối sống thực khuẩn thể có thể được phát biểu chính thức như sau: Cho một tập hợp các contig $\mathcal{S} = \{S_1, S_2, \ldots, S_n\}$ thu được từ giải trình tự và lắp ráp metagenomic, trong đó mỗi contig S_i có độ dài L_i base pairs, nhiệm vụ là dự đoán lối sống của phage là độc lực (lytic) hoặc ôn hòa (lysogenic).

Bài toán này có thể được mô hình hóa như một bài toán phân loại nhị phân (binary classification):

$$f : \mathcal{S} \to \{0, 1\} \tag{1.1}$$

trong đó f là hàm phân loại cần học, 0 đại diện cho lớp temperate (ôn hòa), và 1 đại diện cho lớp virulent (độc lực). Thách thức chính là thiết kế hàm f sao cho:

- Hoạt động hiệu quả trên các contig có độ dài biến thiên lớn (L_i từ 100 bp đến hàng nghìn bp)
- Không phụ thuộc vào các công cụ dự đoán gen bên ngoài có thể thất bại trên các chuỗi ngắn
- Có khả năng tổng quát hóa tốt trên các phage chưa được nhìn thấy (unseen phage) mặc dù dữ liệu huấn luyện hạn chế
- Phân biệt được các đặc trưng phage thực sự từ các chuỗi có nguồn gốc vi khuẩn

Các phương pháp hiện có đã đạt được tiến bộ đáng kể trong việc giải quyết bài toán này, nhưng vẫn còn những hạn chế quan trọng, đặc biệt là trong việc xử lý các contig ngắn và trung bình (100-1200 bp) - phạm vi độ dài phổ biến nhất trong các lắp ráp metagenomic thực tế.

1.3 Mục tiêu nghiên cứu

Mục tiêu chính của luận văn này là phát triển một phương pháp học sâu hiệu quả để phân loại lối sống thực khuẩn thể từ các contig metagenomic, đặc biệt tập trung vào việc cải thiện hiệu suất trên các đoạn DNA ngắn và trung bình. Cụ thể, luận văn hướng đến các mục tiêu sau:

1.3.1 Mục tiêu 1: Phát triển mô hình PhaBERT-CNN

Thiết kế và triển khai một kiến trúc học sâu lai (hybrid deep learning architecture) kết hợp mô hình nền tảng DNABERT-2 [19] đã được tiền huấn luyện với mạng nơ-ron tích chập đa tỷ lệ (multi-scale convolutional neural networks) để phân loại lối sống thực khuẩn thể. Mô hình đề xuất, được đặt tên là PhaBERT-CNN, nhằm tận dụng:

- **Học chuyển giao (Transfer learning):** Sử dụng kiến thức được mã hóa trong DNABERT-2 từ việc tiền huấn luyện trên corpus đa loài (multi-species corpus) để nắm bắt các mẫu tiến hóa ngữ cảnh trong chuỗi DNA của phage
- **Trích xuất đặc trưng đa tỷ lệ:** Sử dụng các nhánh CNN song song với nhiều trường tiếp nhận (receptive fields) để trích xuất các đặc trưng chuỗi cục bộ từ các embedding đã học
- **Tổng hợp thông tin toàn cục:** Áp dụng cơ chế pooling dựa trên attention để tổng hợp thông tin mức chuỗi toàn cục từ các biểu diễn transformer

1.3.2 Mục tiêu 2: Đánh giá hiệu suất trên nhiều nhóm độ dài contig

Tiến hành đánh giá toàn diện hiệu suất của PhaBERT-CNN trên bốn nhóm độ dài contig khác nhau:

- Nhóm A: 100-400 bp (contig rất ngắn)
- Nhóm B: 400-800 bp (contig ngắn)
- Nhóm C: 800-1200 bp (contig trung bình)
- Nhóm D: 1200-1800 bp (contig dài)

Phân tích chi tiết sự thay đổi hiệu suất theo độ dài contig để hiểu rõ điểm mạnh và hạn chế của phương pháp đề xuất trong các kịch bản metagenomic thực tế.

1.3.3 Mục tiêu 3: So sánh với các phương pháp tiên tiến

Thực hiện so sánh có hệ thống giữa PhaBERT-CNN và các phương pháp tiên tiến hiện có, bao gồm:

- **PhaTYP** [7]: Phương pháp dựa trên BERT với tokenization dựa trên protein
- **DeePhage** [3]: Phương pháp CNN trên chuỗi DNA được mã hóa one-hot
- **ProkBERT** [20]: Phương pháp dựa trên BERT với tokenization k-mer chồng lấp
- **DNABERT-2** [19]: Mô hình nền tảng genome với tokenization BPE

Phân tích ưu điểm và nhược điểm của từng phương pháp để làm rõ đóng góp của kiến trúc PhaBERT-CNN.

1.3.4 Mục tiêu 4: Phân tích tác động của các thành phần kiến trúc

Nghiên cứu đóng góp của các thành phần khác nhau trong kiến trúc PhaBERT-CNN thông qua:

- So sánh PhaBERT-CNN với DNABERT-2 baseline để đánh giá tác động của các lớp CNN và attention pooling
- Phân tích sự cân bằng giữa độ nhạy (sensitivity) và độ đặc hiệu (specificity) trên các nhóm độ dài khác nhau
- Đánh giá trade-off giữa độ chính xác và thời gian tính toán

1.3.5 Mục tiêu 5: Đề xuất chiến lược huấn luyện hiệu quả

Phát triển và đánh giá chiến lược tinh chỉnh hai giai đoạn (two-phase fine-tuning strategy):

- **Giai đoạn warm-up:** Đóng băng backbone DNABERT-2 và chỉ huấn luyện các lớp trích xuất đặc trưng task-specific
- **Giai đoạn tinh chỉnh đầy đủ:** Mở băng toàn bộ kiến trúc và áp dụng learning rate phân biệt (discriminative learning rates) cho các thành phần khác nhau

Chiến lược này nhằm đảm bảo sự hội tụ ổn định và thích ứng hiệu quả của mô hình tiền huấn luyện với nhiệm vụ phân loại lối sống phage.

1.3.6 Mục tiêu 6: Cung cấp phân tích và hướng dẫn thực tiễn

Cung cấp phân tích chi tiết về:

- Các trường hợp mô hình hoạt động tốt và các trường hợp thất bại
- Hạn chế của phương pháp đề xuất và các phương pháp hiện có

- Hướng dẫn thực tiễn cho việc lựa chọn phương pháp phù hợp dựa trên đặc điểm của dữ liệu metagenomic
- Hướng nghiên cứu tương lai để cải thiện hiệu suất phân loại lối sống phage

Thông qua việc đạt được các mục tiêu trên, luận văn kỳ vọng đóng góp vào lĩnh vực sinh tin học (bioinformatics) bằng cách cung cấp một công cụ mạnh mẽ và đáng tin cậy cho phân loại lối sống thực khuẩn thể từ dữ liệu metagenomic, đặc biệt là trên các contig ngắn và trung bình - phạm vi độ dài thách thức nhất trong phân tích metagenomic thực tế.

1.4 Đóng góp chính của luận văn

Luận văn này đóng góp vào lĩnh vực phân loại lối sống thực khuẩn thể và sinh tin học nói chung thông qua các đóng góp chính sau:

1.4.1 Kiến trúc PhaBERT-CNN mới

Đề xuất một kiến trúc học sâu lai mới kết hợp mô hình nền tảng genome DNABERT-2 với mạng nơ-ron tích chập đa tỷ lệ và cơ chế attention pooling. Kiến trúc này có những đặc điểm nổi bật:

- **Hoạt động trực tiếp trên chuỗi DNA thô:** Không phụ thuộc vào các công cụ dự đoán gen bên ngoài như Prodigal, khắc phục hạn chế của các phương pháp dựa trên protein như PhaTYP khi xử lý các contig ngắn
- **Tận dụng kiến thức tiền huấn luyện:** Sử dụng DNABERT-2 đã được tiền huấn luyện trên corpus genome đa loài, mang lại khả năng tổng quát hóa tốt hơn so với các mô hình huấn luyện từ đầu như DeePhage
- **Trích xuất đặc trưng đa tỷ lệ:** Sử dụng ba nhánh CNN song song với kernel sizes 3, 5, và 7 để nắm bắt các mẫu chuỗi ở nhiều mức độ trừu tượng - từ motif cục bộ tinh vi đến các domain chức năng rộng hơn
- **Tổng hợp thông tin toàn cục thông minh:** Áp dụng self-attention mechanism để tự động học trọng số quan trọng của các vị trí chuỗi khác nhau, cho phép mô hình tập trung vào các vùng genome có tính thông tin cao

1.4.2 Hiệu suất vượt trội trên contig ngắn và trung bình

Chứng minh hiệu suất vượt trội của PhaBERT-CNN trên các contig ngắn và trung bình (100-1200 bp) - phạm vi độ dài thách thức nhất và phổ biến nhất trong phân tích metagenomic:

- **Nhóm A (100-400 bp):** Đạt accuracy 81.59%, cải thiện 0.91-2.67% so với các phương pháp tiên tiến
- **Nhóm B (400-800 bp):** Đạt accuracy 87.91%, cải thiện 2.01-2.56% so với các baseline
- **Nhóm C (800-1200 bp):** Đạt accuracy 90.01%, cải thiện 1.14-5.98% so với các phương pháp khác
- **Nhóm D (1200-1800 bp):** Đạt accuracy 90.69%, cạnh tranh với PhaTYP (91.02%) và vượt trội so với DeePhage và ProkBERT

Đặc biệt, PhaBERT-CNN duy trì sự cân bằng tốt giữa sensitivity và specificity trên tất cả các nhóm độ dài, với sensitivity 82.00%-91.12% và specificity 80.15%-90.95%.

1.4.3 Chiến lược huấn luyện hai giai đoạn hiệu quả

Đề xuất và đánh giá chiến lược tinh chỉnh hai giai đoạn với learning rate phân biệt:

- **Giai đoạn warm-up (1 epoch):** Đóng băng DNABERT-2, huấn luyện chỉ các lớp task-specific với learning rate cao (2×10^{-3}) để khởi tạo các tham số ngẫu nhiên tương thích với biểu diễn DNABERT-2
- **Giai đoạn tinh chỉnh đầy đủ (tối đa 10 epochs):** Mở băng toàn bộ mô hình với learning rate phân biệt - DNABERT-2 sử dụng learning rate thấp (1×10^{-5}) để điều chỉnh nhẹ nhàng, trong khi các lớp task-specific sử dụng learning rate cao hơn 10 lần (1×10^{-4}) để tối ưu hóa mạnh mẽ

Chiến lược này đảm bảo sự hội tụ ổn định và thích ứng hiệu quả của mô hình tiền huấn luyện với nhiệm vụ downstream.

1.4.4 Đánh giá toàn diện và phân tích so sánh

Thực hiện đánh giá có hệ thống trên bốn nhóm độ dài contig với 5-fold cross-validation, so sánh với bốn phương pháp tiên tiến (DNABERT-2, PhaTYP, DeePhage, ProkBERT). Phân tích chi tiết:

- Ưu điểm và nhược điểm của từng phương pháp trên các phạm vi độ dài khác nhau
- Tác động của các thành phần kiến trúc (CNN branches, attention pooling) thông qua so sánh với DNABERT-2 baseline
- Trade-off giữa độ chính xác và thời gian tính toán
- Phân tích lỗi và các trường hợp thất bại

1.4.5 Giải quyết các hạn chế của phương pháp hiện có

PhaBERT-CNN khắc phục các hạn chế quan trọng của các công cụ hiện có:

- **Khắc phục hạn chế của PhaTYP:** Không phụ thuộc vào Prodigal để dự đoán protein, do đó hoạt động hiệu quả trên các contig ngắn thiếu các vùng mã hóa protein hoàn chỉnh
- **Vượt trội hơn DeePhage:** Tận dụng biểu diễn tiền huấn luyện thay vì huấn luyện từ đầu trên one-hot encoding, nắm bắt được các mẫu phức tạp từ dữ liệu genome đa dạng
- **Cải thiện so với DNABERT và ProkBERT:** Sử dụng DNABERT-2 với tokenization BPE hiệu quả, loại bỏ information leakage và kém hiệu quả tính toán của overlapping k-mer tokenization
- **Hiệu quả tính toán:** Mặc dù sử dụng mô hình nền tảng lớn, DNABERT-2 có hiệu suất tương đương Nucleotide Transformer 2.5B parameters nhưng nhỏ hơn 21 lần và nhanh hơn 92 lần trong quá trình tiền huấn luyện

1.4.6 Đóng góp về mặt phương pháp luận

Luận văn cung cấp một paradigm đầy hứa hẹn cho các nhiệm vụ phân tích chuỗi sinh học downstream:

- Chứng minh hiệu quả của việc kết hợp mô hình nền tảng genome tiền huấn luyện với các kiến trúc chuyên biệt task-specific
- Minh họa tầm quan trọng của chiến lược tinh chỉnh phù hợp khi thích ứng mô hình tiền huấn luyện
- Cung cấp insights về thiết kế kiến trúc lai (hybrid architecture) cho các bài toán phân loại chuỗi genome

Các đóng góp này không chỉ cải thiện hiệu suất phân loại lối sống thực khuẩn thể mà còn cung cấp nền tảng cho các nghiên cứu tương lai trong lĩnh vực sinh tin học và học sâu cho dữ liệu genome.

1.5 Phạm vi nghiên cứu

Luận văn tập trung vào phạm vi nghiên cứu cụ thể sau đây, với các giới hạn và giả định rõ ràng:

1.5.1 Phạm vi về bài toán

Phân loại nhị phân lối sống: Luận văn tập trung vào bài toán phân loại nhị phân (binary classification) để phân biệt thực khuẩn thể độc lực (virulent/lytic) và thực khuẩn thể ôn hòa (temperate/lysogenic). Các lối sống phức tạp hơn hoặc các trạng thái trung gian không được xem xét trong phạm vi nghiên cứu này.

Dữ liệu đầu vào: Phương pháp được thiết kế để hoạt động trên các contig DNA được lắp ráp từ dữ liệu metagenomic, không phải trên các đoạn đọc thô (raw reads). Các contig được giả định là đã được xác định là có nguồn gốc từ phage thông qua các công cụ nhận dạng phage như VirSorter, VIBRANT, hoặc các phương pháp tương tự.

1.5.2 Phạm vi về dữ liệu

Phạm vi độ dài contig: Nghiên cứu tập trung vào bốn nhóm độ dài contig:

- Nhóm A: 100-400 bp (contig rất ngắn)
- Nhóm B: 400-800 bp (contig ngắn)
- Nhóm C: 800-1200 bp (contig trung bình)
- Nhóm D: 1200-1800 bp (contig dài)

Các contig ngắn hơn 100 bp hoặc dài hơn 1800 bp không được đánh giá chi tiết trong nghiên cứu này, mặc dù phương pháp về mặt kỹ thuật có thể xử lý các chuỗi có độ dài tùy ý nhờ ALiBi positional encoding của DNABERT-2.

Nguồn dữ liệu: Tập dữ liệu được xây dựng từ hai nghiên cứu gần đây: DeePhage [3] và DeepPL [21], bao gồm 2,241 bộ gen phage hoàn chỉnh (707 temperate, 1,534 virulent). Các contig được tạo ra bằng phương pháp sliding window để mô phỏng kịch bản metagenomic thực tế.

Giới hạn về đa dạng sinh học: Mặc dù tập dữ liệu bao gồm nhiều họ phage khác nhau, nó vẫn chỉ đại diện cho một phần nhỏ của sự đa dạng phage trong tự nhiên. Hiệu suất của mô hình trên các phage thuộc các họ hiếm gặp hoặc chưa được nghiên cứu có thể khác với kết quả báo cáo.

1.5.3 Phạm vi về phương pháp

Mô hình nền tảng: Nghiên cứu sử dụng DNABERT-2 [19] làm mô hình nền tảng genome. Các mô hình nền tảng khác như Nucleotide Transformer [22], HyenaDNA, hoặc các biến thể BERT khác không được đánh giá trong phạm vi luận văn này.

Kiến trúc downstream: Luận văn tập trung vào kiến trúc lai kết hợp CNN đa tỷ lệ và attention pooling. Các kiến trúc downstream khác như RNN, LSTM, hoặc pure transformer decoder không được khảo sát chi tiết.

Phương pháp so sánh: Luận văn so sánh với bốn phương pháp tiên tiến: DNABERT-2, PhaTYP, DeePhage, và ProkBERT. Các phương pháp học máy truyền thống như PHACTS, PhageAI, và BACPHLIP không được đánh giá lại vì

đã được chứng minh có hiệu suất thấp hơn đáng kể trên dữ liệu contig trong các nghiên cứu trước.

1.5.4 Phạm vi về đánh giá

Metrics đánh giá: Luận văn sử dụng ba metrics chính: sensitivity (recall), specificity, và accuracy. Các metrics khác như precision, F1-score, AUC-ROC, hoặc Matthews correlation coefficient không được báo cáo chi tiết để duy trì tính nhất quán với các nghiên cứu trước đó.

Phương pháp validation: Sử dụng stratified 5-fold cross-validation để đánh giá hiệu suất. Không thực hiện đánh giá trên các tập dữ liệu độc lập bên ngoài (external validation) do hạn chế về tài nguyên và tính sẵn có của dữ liệu có nhãn chất lượng cao.

Phân tích ablation: Luận văn thực hiện phân tích so sánh giữa PhaBERT-CNN và DNABERT-2 baseline để đánh giá tác động của các thành phần CNN và attention. Các nghiên cứu ablation chi tiết hơn (ví dụ: loại bỏ từng nhánh CNN, thay đổi kernel sizes, so sánh các cơ chế attention khác nhau) không được thực hiện trong phạm vi luận văn này.

1.5.5 Phạm vi về triển khai

Framework và thư viện: Mô hình được triển khai sử dụng PyTorch và thư viện Transformers của Hugging Face. Các framework khác như TensorFlow/Keras không được xem xét.

Tài nguyên tính toán: Các thí nghiệm được thực hiện trên GPU NVIDIA RTX A4000 16GB. Phân tích về khả năng mở rộng (scalability) trên các cấu hình phần cứng khác hoặc tối ưu hóa cho triển khai trên CPU không được đề cập chi tiết.

Công cụ phần mềm: Luận văn không phát triển một công cụ phần mềm độc lập (standalone software tool) hoặc web server. Mã nguồn được cung cấp dưới dạng script Python để tái tạo kết quả nghiên cứu.

1.5.6 Giới hạn và giả định

Giả định về chất lượng dữ liệu: Các contig đầu vào được giả định là:

- Đã được xác định chính xác là có nguồn gốc từ phage
- Không chứa lỗi giải trình tự đáng kể
- Không bị ô nhiễm bởi DNA vi khuẩn chủ

Giới hạn về tổng quát hóa: Hiệu suất của mô hình được đánh giá trên dữ liệu mô phỏng (simulated data) được tạo từ bộ gen hoàn chỉnh. Hiệu suất trên dữ liệu metagenomic thực tế từ các môi trường đa dạng có thể khác biệt và cần được xác thực thêm.

Không xem xét các yếu tố sinh học phức tạp: Luận văn không xem xét các trường hợp đặc biệt như:

- Phage có khả năng chuyển đổi giữa các lối sống (lifestyle switching)
- Prophage bị đột biến mất chức năng (defective prophage)
- Phage với các cơ chế lysogen hóa không điển hình
- Tác động của môi trường chủ lên biểu hiện lối sống

Các giới hạn và giả định này được thiết lập để đảm bảo nghiên cứu tập trung và khả thi trong phạm vi luận văn thạc sĩ, đồng thời cung cấp nền tảng vững chắc cho các nghiên cứu mở rộng trong tương lai.

1.6 Bố cục luận văn

Luận văn được tổ chức thành năm chương với cấu trúc logic như sau:

Chương 1: Giới thiệu

Chương này giới thiệu bối cảnh nghiên cứu về thực khuẩn thể và tầm quan trọng của việc phân loại lối sống phage trong nghiên cứu vi sinh vật học và ứng dụng y sinh học. Chương trình bày các thách thức chính trong phân loại lối sống phage từ dữ liệu metagenomic, bao gồm hạn chế về dữ liệu, thiếu gen đánh dấu phổ quát, độ dài đoạn DNA ngắn, và vấn đề tương đồng trình tự. Chương cũng phát biểu rõ ràng bài toán nghiên cứu, mục tiêu, đóng góp chính, và phạm vi của luận văn.

Chương 2: Cơ sở lý thuyết

Chương này cung cấp nền tảng lý thuyết toàn diện cần thiết để hiểu phương pháp đề xuất. Chương bắt đầu với kiến thức sinh học về thực khuẩn thể, bao gồm phân loại, chu trình sống, và vai trò sinh thái. Tiếp theo, chương giới thiệu các khái niệm về metagenomics và giải trình tự thế hệ mới, giải thích cách các contig được tạo ra từ dữ liệu metagenomic. Phần tiếp theo trình bày các nền tảng học máy và học sâu, bao gồm mạng nơ-ron tích chập (CNN), kiến trúc transformer, và cơ chế attention. Chương dành phần quan trọng để giải thích chi tiết về BERT và các biến thể của nó cho dữ liệu genome (DNABERT, DNABERT-2), bao gồm masked language modeling, tokenization strategies, và transfer learning. Cuối cùng, chương tổng hợp các công trình liên quan về phân loại lối sống phage, phân tích ưu nhược điểm của các phương pháp học máy truyền thống (PHACTS, PhageAI, BACPHLIP) và các phương pháp học sâu hiện đại (DeePhage, PhaTYP, DeepPL, ProkBERT).

Chương 3: Phương pháp đề xuất

Chương này trình bày chi tiết phương pháp PhaBERT-CNN được đề xuất. Chương bắt đầu với tổng quan về kiến trúc tổng thể và động lực thiết kế. Tiếp theo, chương mô tả quy trình xây dựng tập dữ liệu, bao gồm nguồn dữ liệu, phương pháp tạo contig bằng sliding window, data augmentation thông qua reverse complement, và chiến lược xử lý mất cân bằng lớp. Chương sau đó giải thích chi tiết về mô hình nền tảng DNABERT-2, bao gồm chiến lược tokenization BPE, các cải tiến kiến trúc (ALiBi, Flash Attention), và corpus tiền huấn luyện đa loài. Phần cốt lõi của chương mô tả kiến trúc PhaBERT-CNN với hai nhánh trích xuất đặc trưng song song: (1) multi-scale CNN feature extractor với ba kernel sizes khác nhau, và (2) attention-based global feature extractor. Chương kết thúc bằng việc trình bày chiến lược huấn luyện hai giai đoạn với learning rate phân biệt, bao gồm các chi tiết về optimizer, learning rate schedule, và early stopping.

Chương 4: Thực nghiệm và đánh giá

Chương này trình bày thiết lập thí nghiệm toàn diện và kết quả đánh giá. Chương bắt đầu với mô tả chi tiết về môi trường thực nghiệm, bao gồm cấu hình phần cứng, phần mềm, và các hyperparameters. Tiếp theo, chương giải thích các metrics đánh giá (sensitivity, specificity, accuracy) và phương pháp validation (stratified 5-fold cross-validation). Chương trình bày kết quả thực nghiệm theo hai phần chính: (1) so sánh PhaBERT-CNN với DNABERT-2 baseline để đánh giá tác động của các thành phần CNN và attention, và (2) so sánh với các phương pháp tiên tiến

(PhaTYP, DeePhage, ProkBERT) trên bốn nhóm độ dài contig. Kết quả được trình bày thông qua các bảng số liệu chi tiết và biểu đồ trực quan. Chương cũng bao gồm phân tích chi tiết về hiệu suất trên từng nhóm độ dài, phân tích lỗi, và thảo luận về các trường hợp mô hình hoạt động tốt và các trường hợp thất bại. Cuối cùng, chương thảo luận về trade-off giữa độ chính xác và thời gian tính toán, cũng như các hạn chế của phương pháp đề xuất.

Chương 5: Kết luận

Chương cuối cùng tổng kết các kết quả chính của luận văn và đóng góp của nghiên cứu. Chương nhắc lại bài toán nghiên cứu và tóm tắt cách PhaBERT-CNN giải quyết các thách thức đã xác định. Chương tổng hợp các phát hiện quan trọng từ thực nghiệm, bao gồm hiệu suất vượt trội trên các contig ngắn và trung bình, sự cân bằng giữa sensitivity và specificity, và so sánh với các phương pháp hiện có. Chương thảo luận về các hạn chế của nghiên cứu, bao gồm phụ thuộc vào chất lượng dữ liệu đầu vào, nhu cầu về tài nguyên tính toán, và các giả định về dữ liệu. Cuối cùng, chương đề xuất các hướng nghiên cứu tương lai, bao gồm: (1) đánh giá trên dữ liệu metagenomic thực tế từ các môi trường đa dạng, (2) khảo sát các mô hình nền tảng genome khác, (3) phát triển các chiến lược xử lý mất cân bằng lớp hiệu quả hơn, (4) tối ưu hóa cho triển khai thực tế, và (5) mở rộng sang các nhiệm vụ phân loại phage khác như phân loại họ phage hoặc dự đoán vi khuẩn chủ.

Cấu trúc này được thiết kế để dẫn dắt người đọc từ động lực và nền tảng lý thuyết, qua phương pháp đề xuất chi tiết, đến đánh giá thực nghiệm toàn diện, và cuối cùng là kết luận và hướng phát triển. Mỗi chương xây dựng dựa trên các chương trước, tạo thành một câu chuyện nghiên cứu mạch lạc và logic.

Chương 2

Cơ sở lý thuyết

2.1 Thực khuẩn thể và phân loại lối sống

2.1.1 Giới thiệu về thực khuẩn thể

Thực khuẩn thể (bacteriophage), hay còn gọi tắt là phage, là các virus có khả năng xâm nhiễm và nhân lên bên trong tế bào vi khuẩn. Thuật ngữ "bacteriophage" có nguồn gốc từ tiếng Hy Lạp, trong đó "bacteria" có nghĩa là vi khuẩn và "phagein" có nghĩa là ăn, phản ánh khả năng tiêu diệt vi khuẩn của chúng. Thực khuẩn thể được phát hiện độc lập bởi hai nhà khoa học: Frederick Twort tại Anh năm 1915 và Félix d'Hérelle tại Pháp năm 1917, với d'Hérelle là người đặt tên "bacteriophage" cho các tác nhân này.

Thực khuẩn thể là dạng sống phong phú nhất trên Trái Đất, với số lượng ước tính lên tới 10^{31} cá thể [1]. Chúng có mặt ở hầu hết mọi môi trường có vi khuẩn, từ đại dương, đất, không khí, đến cơ thể động vật và thực vật. Trong môi trường biển, mật độ phage có thể đạt tới 10^7 virion trên mililít nước, vượt xa số lượng vi khuẩn. Sự phong phú này phản ánh vai trò sinh thái quan trọng của phage trong việc điều hòa quần thể vi khuẩn và duy trì cân bằng sinh thái vi sinh vật.

2.1.2 Cấu trúc và thành phần của thực khuẩn thể

Về mặt cấu trúc, thực khuẩn thể bao gồm vật liệu di truyền (DNA hoặc RNA) được bao bọc bởi một lớp vỏ protein gọi là capsid. Capsid bảo vệ vật liệu di truyền khỏi các yếu tố môi trường và đóng vai trò trong quá trình nhận diện và gắn kết với tế bào vi khuẩn chủ. Phage có thể có nhiều hình dạng khác nhau, nhưng cấu trúc phổ biến nhất là dạng đầu-đuôi (head-tail morphology), bao gồm:

- **Đầu (head/capsid):** Chứa vật liệu di truyền, thường có hình dạng icosahedral (20 mặt)
- **Đuôi (tail):** Cấu trúc ống rỗng giúp phage gắn vào bề mặt vi khuẩn và tiêm

vật liệu di truyền vào tế bào chủ

- **Sợi đuôi (tail fibers):** Các cấu trúc protein giúp nhận diện và gắn kết đặc hiệu với các thụ thể trên bề mặt vi khuẩn chủ
- **Đế đuôi (baseplate):** Cấu trúc phức tạp nối giữa đầu và đuôi, đóng vai trò trong việc xuyên thủng màng tế bào vi khuẩn

Bộ gen của phage có thể là DNA sợi đơn (ssDNA), DNA sợi đôi (dsDNA), RNA sợi đơn (ssRNA), hoặc RNA sợi đôi (dsRNA), với dsDNA là dạng phổ biến nhất. Kích thước bộ gen phage biến thiên rộng, từ vài nghìn base pairs (kb) đến hơn 500 kb, mã hóa từ vài gen đến hàng trăm gen.

2.1.3 Chu trình sống của thực khuẩn thể

Thực khuẩn thể được phân loại thành hai nhóm chính dựa trên chiến lược nhân lên: thực khuẩn thể độc lực (virulent phage) và thực khuẩn thể ôn hòa (temperate phage).

Chu trình phân giải (Lytic cycle)

Thực khuẩn thể độc lực chỉ thực hiện chu trình phân giải, bao gồm các bước sau:

1. **Hấp phụ (Adsorption):** Phage gắn kết đặc hiệu với các thụ thể trên bề mặt tế bào vi khuẩn chủ thông qua các protein nhận diện trên sợi đuôi
2. **Tiêm nhiễm (Injection):** Phage tiêm vật liệu di truyền của mình vào tế bào vi khuẩn, trong khi capsid protein thường ở lại bên ngoài
3. **Tổng hợp sinh học (Biosynthesis):** DNA của phage chiếm đoạt bộ máy tổng hợp của tế bào chủ, sử dụng ribosome, enzyme, và các thành phần tế bào để sao chép DNA phage và tổng hợp các protein cấu trúc của phage
4. **Lắp ráp (Assembly):** Các thành phần protein và DNA phage mới được tổng hợp tự lắp ráp thành các virion hoàn chỉnh bên trong tế bào vi khuẩn
5. **Phân giải (Lysis):** Phage tổng hợp các enzyme phân giải (như lysozyme) để phá vỡ thành tế bào vi khuẩn, giải phóng hàng chục đến hàng trăm virion con để xâm nhiễm các tế bào vi khuẩn khác

Chu trình phân giải thường hoàn thành trong vòng 20-40 phút, tùy thuộc vào loại phage và điều kiện môi trường.

Chu trình lysogen (Lysogenic cycle)

Thực khuẩn thể ôn hòa có khả năng thực hiện cả chu trình phân giải và chu trình lysogen. Trong chu trình lysogen:

1. **Tích hợp (Integration):** Sau khi tiêm vào tế bào chủ, DNA của phage được tích hợp vào nhiễm sắc thể của vi khuẩn thông qua quá trình tái tổ hợp đặc hiệu vị trí (site-specific recombination), được xúc tác bởi enzyme integrase
2. **Trạng thái prophage:** DNA phage được tích hợp (gọi là prophage) tồn tại ở trạng thái không hoạt động, được nhân lên cùng với bộ gen vi khuẩn qua nhiều thế hệ. Prophage được duy trì ở trạng thái im lặng nhờ protein repressor ngăn chặn biểu hiện các gen phân giải
3. **Cảm ứng (Induction):** Khi gặp các điều kiện stress như tia UV, nhiệt độ cao, hóa chất gây tổn thương DNA, hoặc thiếu dinh dưỡng, prophage có thể được kích hoạt. Protein repressor bị vô hiệu hóa, dẫn đến việc cắt prophage ra khỏi nhiễm sắc thể vi khuẩn (excision) và chuyển sang chu trình phân giải

Quyết định giữa chu trình phân giải và lysogen phụ thuộc vào nhiều yếu tố, bao gồm trạng thái sinh lý của tế bào chủ, mật độ vi khuẩn, và các tín hiệu môi trường. Cơ chế phân tử điều khiển quyết định này thường liên quan đến sự cạnh tranh giữa các protein điều hòa như CI repressor (ưu tiên lysogen) và Cro protein (ưu tiên phân giải) trong phage lambda.

2.1.4 Vai trò sinh thái và ứng dụng

Vai trò trong sinh thái vi sinh vật

Thực khuẩn thể đóng vai trò quan trọng trong sinh thái vi sinh vật:

- **Điều hòa quần thể vi khuẩn:** Phage kiểm soát mật độ và cấu trúc quần thể vi khuẩn thông qua quá trình "kill the winner", trong đó các chủng vi khuẩn chiếm ưu thế bị phage tiêu diệt, tạo cơ hội cho các chủng khác phát triển [2]

- **Chuyển gen ngang:** Phage là động lực chính của horizontal gene transfer giữa vi khuẩn thông qua transduction, góp phần vào sự tiến hóa và đa dạng di truyền của vi khuẩn
- **Chu trình dinh dưỡng:** Phage giải phóng các chất dinh dưỡng từ tế bào vi khuẩn bị phân giải, đóng góp vào chu trình carbon và các nguyên tố khác trong hệ sinh thái
- **Lysogenic conversion:** Prophage có thể mang các gen mã hóa yếu tố độc lực hoặc kháng kháng sinh, thay đổi kiểu hình của vi khuẩn chủ

Ứng dụng trong y sinh học

Việc phân loại chính xác lối sống phage có ý nghĩa quan trọng cho các ứng dụng y sinh học:

- **Liệu pháp phage (Phage therapy):** Sử dụng phage để điều trị nhiễm trùng vi khuẩn, đặc biệt là các vi khuẩn kháng kháng sinh [8, 9]. Chỉ có phage độc lực mới phù hợp cho liệu pháp vì chúng tiêu diệt vi khuẩn một cách hiệu quả mà không tích hợp vào bộ gen chủ
- **An toàn sinh học:** Phage ôn hòa có thể truyền các gen độc lực hoặc kháng kháng sinh cho vi khuẩn bệnh nguyên thông qua lysogenic conversion, do đó cần được loại trừ khỏi các ứng dụng trị liệu [10]
- **Kiểm soát thực phẩm:** Phage được sử dụng để kiểm soát vi khuẩn gây bệnh trong thực phẩm, với yêu cầu nghiêm ngặt về việc sử dụng chỉ phage độc lực
- **Công nghệ sinh học:** Phage được sử dụng trong phage display, vaccine development, và drug delivery, với các yêu cầu khác nhau về lối sống phage tùy thuộc vào ứng dụng cụ thể

Do đó, việc phát triển các phương pháp tính toán chính xác và hiệu quả để phân loại lối sống phage từ dữ liệu trình tự gen là cần thiết để hỗ trợ cả nghiên cứu cơ bản về sinh thái vi sinh vật và các ứng dụng thực tiễn trong y học và công nghệ sinh học.

2.2 Metagenomics và giải trình tự thế hệ mới

2.2.1 Giới thiệu về metagenomics

Metagenomics là phương pháp nghiên cứu vật liệu di truyền được thu thập trực tiếp từ các mẫu môi trường, cho phép phân tích toàn bộ cộng đồng vi sinh vật mà không cần nuôi cấy từng loài riêng lẻ [11]. Thuật ngữ "metagenome" được đặt ra bởi Jo Handelsman và cộng sự năm 1998, đề cập đến tập hợp tất cả các bộ gen (genomes) có trong một mẫu môi trường. Phương pháp này đã cách mạng hóa nghiên cứu vi sinh vật học bằng cách cho phép nghiên cứu "dark matter" của thế giới vi sinh vật - phần lớn các vi sinh vật không thể nuôi cấy được trong phòng thí nghiệm.

Theo ước tính, chỉ có khoảng 1% vi khuẩn trong tự nhiên có thể được nuôi cấy trong điều kiện phòng thí nghiệm, và tỷ lệ này còn thấp hơn đối với thực khuẩn thể. Metagenomics khắc phục hạn chế này bằng cách trực tiếp giải trình tự DNA từ mẫu môi trường, cung cấp cái nhìn toàn diện về đa dạng sinh học, cấu trúc cộng đồng, và tiềm năng chức năng của hệ vi sinh vật.

2.2.2 Công nghệ giải trình tự thế hệ mới

Nguyên lý hoạt động

Công nghệ giải trình tự thế hệ mới (Next-Generation Sequencing - NGS) đã thay thế phương pháp Sanger sequencing truyền thống nhờ khả năng tạo ra hàng triệu đến hàng tỷ đoạn đọc (reads) trong một lần chạy duy nhất. Các nền tảng NGS phổ biến bao gồm:

- **Illumina:** Sử dụng sequencing by synthesis với fluorescent reversible terminators, tạo ra đoạn đọc ngắn (75-300 bp) với độ chính xác cao (>99%) và throughput lớn
- **PacBio (Pacific Biosciences):** Sử dụng single-molecule real-time (SMRT) sequencing, tạo ra đoạn đọc dài (10-30 kb) nhưng có error rate cao hơn
- **Oxford Nanopore:** Sử dụng nanopore sequencing, có thể tạo ra đoạn đọc cực dài (>100 kb) với khả năng sequencing real-time

Illumina là nền tảng phổ biến nhất cho metagenomics do chi phí thấp, throughput cao, và độ chính xác tốt, mặc dù độ dài đoạn đọc ngắn hơn so với các công nghệ long-read.

Quy trình phân tích metagenomic

Quy trình phân tích metagenomic điển hình bao gồm các bước sau:

1. **Thu thập và chuẩn bị mẫu:** DNA tổng số được trích xuất từ mẫu môi trường (đất, nước, mẫu sinh học, v.v.)
2. **Xây dựng thư viện (Library preparation):** DNA được phân mảnh và gắn adapter để chuẩn bị cho giải trình tự
3. **Giải trình tự (Sequencing):** Tạo ra hàng triệu đoạn đọc ngắn từ DNA trong mẫu
4. **Kiểm soát chất lượng (Quality control):** Loại bỏ các đoạn đọc chất lượng thấp, adapter sequences, và contamination
5. **Lắp ráp (Assembly):** Ghép các đoạn đọc chồng lấp nhau thành các chuỗi liên tục dài hơn gọi là contigs
6. **Phân tích downstream:** Bao gồm taxonomic classification, gene prediction, functional annotation, và comparative analysis

2.2.3 Lắp ráp metagenomic và contig

Thách thức trong lắp ráp metagenomic

Lắp ráp metagenomic phức tạp hơn nhiều so với lắp ráp bộ gen đơn loài do:

- **Độ phức tạp cao:** Mẫu metagenomic chứa DNA từ hàng trăm đến hàng nghìn loài khác nhau với độ phong phú biến thiên lớn
- **Độ phủ không đồng đều:** Các loài phong phú có độ phủ giải trình tự cao, trong khi các loài hiếm có độ phủ thấp, dẫn đến chất lượng lắp ráp không đồng nhất

- **Vùng lặp lại:** Các chuỗi tương đồng giữa các loài khác nhau hoặc các vùng lặp lại trong cùng một bộ gen gây khó khăn cho việc lắp ráp chính xác
- **Chimerism:** Có thể tạo ra các contig chimeric kết hợp DNA từ nhiều loài khác nhau
- **Strain variation:** Sự hiện diện của nhiều chủng (strains) của cùng một loài với các biến thể di truyền nhỏ làm phức tạp quá trình lắp ráp

Contig và đặc điểm

Contig (từ "contiguous") là một chuỗi DNA liên tục được lắp ráp từ các đoạn đọc chồng lấp nhau [13, 14]. Trong phân tích metagenomic, contigs có các đặc điểm sau:

- **Phân bố độ dài rộng:** Độ dài contig biến thiên từ vài trăm base pairs đến hàng trăm kilobase pairs, tùy thuộc vào độ phủ giải trình tự, độ phức tạp của mẫu, và thuật toán lắp ráp
- **Chất lượng không đồng nhất:** Contigs từ các loài phong phú thường dài hơn và chính xác hơn so với contigs từ các loài hiếm
- **Tính không hoàn chỉnh:** Hầu hết contigs chỉ đại diện cho các đoạn của bộ gen, không phải bộ gen hoàn chỉnh, do đó có thể thiếu các gen quan trọng hoặc chỉ chứa các phần của gen
- **Độ phủ (Coverage):** Số lần trung bình mỗi vị trí nucleotide được đọc, là chỉ số quan trọng về độ tin cậy của contig

Phân bố độ dài contig trong thực tế

Trong các nghiên cứu metagenomic thực tế, phân bố độ dài contig thường có dạng long-tail distribution:

- **Contig ngắn (100-1000 bp):** Chiếm tỷ lệ lớn về số lượng, thường đến từ các loài hiếm hoặc các vùng khó lắp ráp

- **Contig trung bình (1-10 kb):** Đại diện cho phần lớn dữ liệu về tổng số base pairs
- **Contig dài (>10 kb):** Ít về số lượng nhưng có giá trị cao cho phân tích, thường đến từ các loài phong phú với độ phủ tốt

Các contig ngắn (100-1200 bp) đặc biệt thách thức cho phân tích vì:

- Có thể không chứa gen hoàn chỉnh
- Tín hiệu thống kê yếu cho các phương pháp dựa trên thành phần nucleotide
- Các công cụ dự đoán gen có hiệu suất giảm
- Khó phân biệt với DNA contamination hoặc artifacts

2.2.4 Ứng dụng của metagenomics trong nghiên cứu phage

Metagenomics đã mở ra những cơ hội mới cho nghiên cứu thực khuẩn thể:

- **Khám phá đa dạng phage:** Phát hiện các phage mới và hiếm gặp không thể nuôi cấy được [12]
- **Phân tích cộng đồng phage:** Nghiên cứu cấu trúc và động lực của cộng đồng phage trong các môi trường khác nhau
- **Tương tác phage-host:** Suy luận mối quan hệ giữa phage và vi khuẩn chủ dựa trên dữ liệu metagenomic
- **Phân tích chức năng:** Xác định các gen chức năng và tiềm năng sinh học của phage
- **Prophage identification:** Phát hiện prophage được tích hợp trong bộ gen vi khuẩn

Tuy nhiên, việc phân tích phage từ dữ liệu metagenomic đòi hỏi các công cụ tính toán chuyên biệt có khả năng xử lý các contig ngắn và phân mảnh - đây chính là động lực cho việc phát triển các phương pháp học sâu như PhaBERT-CNN để phân loại lối sống phage từ các contig metagenomic.

2.3 Học máy cho phân tích dữ liệu sinh học

2.3.1 Giới thiệu về học máy

Học máy (Machine Learning) là một nhánh của trí tuệ nhân tạo tập trung vào việc phát triển các thuật toán cho phép máy tính học từ dữ liệu và cải thiện hiệu suất thông qua kinh nghiệm mà không cần được lập trình rõ ràng. Trong bối cảnh phân tích dữ liệu sinh học, học máy đã trở thành công cụ không thể thiếu để xử lý khối lượng dữ liệu khổng lồ từ các công nghệ sinh học hiện đại.

2.3.2 Các loại học máy

Học có giám sát (Supervised Learning)

Học có giám sát là paradigm học máy trong đó mô hình được huấn luyện trên tập dữ liệu có nhãn (labeled data). Mục tiêu là học một hàm ánh xạ $f : X \to Y$ từ không gian đầu vào X sang không gian đầu ra Y. Bài toán phân loại lối sống thực khuẩn thể là một bài toán học có giám sát điển hình, trong đó:

- **Input** X: Chuỗi DNA của contig phage
- **Output** Y: Nhãn lối sống (virulent hoặc temperate)
- **Training data**: Tập hợp các cặp (x_i, y_i) với nhãn đã biết

Các thuật toán học có giám sát phổ biến bao gồm:

- Support Vector Machines (SVM)
- Random Forest
- Gradient Boosting
- Neural Networks

Học không giám sát (Unsupervised Learning)

Học không giám sát làm việc với dữ liệu không có nhãn, tìm kiếm các cấu trúc ẩn hoặc patterns trong dữ liệu. Các phương pháp phổ biến bao gồm clustering (K-means, hierarchical clustering) và dimensionality reduction (PCA, t-SNE).

Học chuyển giao (Transfer Learning)

Học chuyển giao là paradigm trong đó kiến thức học được từ một nhiệm vụ (source task) được áp dụng cho một nhiệm vụ khác nhưng liên quan (target task). Đây là nền tảng của phương pháp PhaBERT-CNN, trong đó mô hình DNABERT-2 được tiền huấn luyện trên corpus genome đa loài sau đó được tinh chỉnh cho nhiệm vụ phân loại lối sống phage.

2.3.3 Các khái niệm cơ bản

Overfitting và Underfitting

Overfitting xảy ra khi mô hình học quá tốt trên dữ liệu huấn luyện, bao gồm cả noise, dẫn đến hiệu suất kém trên dữ liệu mới. **Underfitting** xảy ra khi mô hình quá đơn giản và không nắm bắt được patterns quan trọng trong dữ liệu.

Các kỹ thuật regularization để giảm overfitting:

- **L1/L2 regularization**: Thêm penalty term vào loss function
- **Dropout**: Ngẫu nhiên tắt một số neurons trong quá trình huấn luyện
- **Early stopping**: Dừng huấn luyện khi hiệu suất trên validation set bắt đầu giảm
- **Data augmentation**: Tăng cường dữ liệu huấn luyện

Cross-validation

Cross-validation là kỹ thuật đánh giá mô hình bằng cách chia dữ liệu thành nhiều folds, luân phiên sử dụng mỗi fold làm validation set trong khi các folds còn lại làm training set. Stratified k-fold cross-validation đảm bảo tỷ lệ các lớp được duy trì trong mỗi fold, đặc biệt quan trọng khi xử lý dữ liệu mất cân bằng.

Metrics đánh giá

Đối với bài toán phân loại nhị phân như phân loại lối sống phage, các metrics quan trọng bao gồm:

- **Sensitivity (Recall)**: Sn = $\frac{TP}{TP+FN}$ - Tỷ lệ phage virulent được dự đoán đúng
- **Specificity**: Sp = $\frac{TN}{TN+FP}$ - Tỷ lệ phage temperate được dự đoán đúng
- **Accuracy**: Acc = $\frac{TP+TN}{TP+TN+FP+FN}$ - Tỷ lệ dự đoán đúng tổng thể
- **Precision**: Prec = $\frac{TP}{TP+FP}$ - Tỷ lệ dự đoán virulent chính xác
- **F1-Score**: $F1 = 2 \times \frac{\text{Precision} \times \text{Recall}}{\text{Precision} + \text{Recall}}$ - Trung bình điều hòa của precision và recall

trong đó TP (True Positive), TN (True Negative), FP (False Positive), FN (False Negative) là các giá trị từ confusion matrix.

2.3.4 Học máy cho phân tích chuỗi sinh học

Feature engineering cho dữ liệu DNA

Các phương pháp học máy truyền thống đòi hỏi feature engineering thủ công để chuyển đổi chuỗi DNA thành vector số. Các phương pháp phổ biến bao gồm:

- **Nucleotide composition**: Tần suất của từng nucleotide (A, T, G, C)
- **k-mer frequency**: Tần suất của tất cả các chuỗi con độ dài k
- **Codon usage**: Tần suất sử dụng các codon khác nhau
- **GC content**: Tỷ lệ phần trăm của G và C trong chuỗi
- **Protein-based features**: Đặc trưng từ các protein được dự đoán

Hạn chế của phương pháp truyền thống

Các phương pháp học máy truyền thống có những hạn chế khi áp dụng cho phân loại lối sống phage:

- **Feature engineering thủ công**: Đòi hỏi kiến thức chuyên môn và có thể bỏ lỡ các patterns quan trọng
- **Phụ thuộc vào công cụ bên ngoài**: Các features dựa trên protein yêu cầu gene prediction chính xác

- **Khó xử lý chuỗi ngắn**: Tín hiệu thống kê yếu trên các contig ngắn
- **Không nắm bắt được long-range dependencies**: Các features cục bộ không thể mô hình hóa mối quan hệ xa trong chuỗi

Những hạn chế này đã thúc đẩy sự phát triển của các phương pháp học sâu có khả năng tự động học representations từ dữ liệu thô.

2.4 Học sâu và mạng nơ-ron

2.4.1 Giới thiệu về học sâu

Học sâu (Deep Learning) là một nhánh của học máy sử dụng mạng nơ-ron nhân tạo với nhiều lớp (deep neural networks) để học các biểu diễn phân cấp của dữ liệu. Khác với học máy truyền thống đòi hỏi feature engineering thủ công, học sâu có khả năng tự động học các features từ dữ liệu thô thông qua quá trình huấn luyện end-to-end.

2.4.2 Mạng nơ-ron nhân tạo

Perceptron và Multi-layer Perceptron

Perceptron là đơn vị tính toán cơ bản của mạng nơ-ron, thực hiện phép biến đổi tuyến tính theo sau bởi hàm kích hoạt phi tuyến:

$$y = f\left(\sum_{i=1}^{n} w_i x_i + b\right) = f(\mathbf{w}^T\mathbf{x} + b) \tag{2.1}$$

trong đó $\mathbf{x}$ là vector đầu vào, $\mathbf{w}$ là vector trọng số, b là bias, và f là hàm kích hoạt.

Multi-layer Perceptron (MLP) xếp chồng nhiều lớp perceptrons, cho phép học các hàm phức tạp:

$$\mathbf{h}^{(l)} = f^{(l)}\left(\mathbf{W}^{(l)}\mathbf{h}^{(l-1)} + \mathbf{b}^{(l)}\right) \tag{2.2}$$

với $\mathbf{h}^{(l)}$ là hidden state ở lớp l, $\mathbf{W}^{(l)}$ là ma trận trọng số, và $f^{(l)}$ là hàm kích hoạt.

Hàm kích hoạt

Các hàm kích hoạt phổ biến:

- **ReLU**: $f(x) = \max(0, x)$ - Đơn giản, hiệu quả, giảm vanishing gradient
- **Sigmoid**: $f(x) = \frac{1}{1+e^{-x}}$ - Đầu ra trong khoảng (0,1)
- **Tanh**: $f(x) = \frac{e^x - e^{-x}}{e^x + e^{-x}}$ - Đầu ra trong khoảng (-1,1)
- **GELU**: $f(x) = x \cdot \Phi(x)$ - Sử dụng trong BERT và transformers

2.4.3 Backpropagation và tối ưu hóa

Backpropagation

Backpropagation là thuật toán tính gradient của loss function theo các tham số mạng bằng chain rule:

$$\frac{\partial \mathcal{L}}{\partial w_{ij}^{(l)}} = \frac{\partial \mathcal{L}}{\partial h_j^{(l)}} \cdot \frac{\partial h_j^{(l)}}{\partial z_j^{(l)}} \cdot \frac{\partial z_j^{(l)}}{\partial w_{ij}^{(l)}} \tag{2.3}$$

Gradient Descent và biến thể

Stochastic Gradient Descent (SGD):

$$\mathbf{w}_{t+1} = \mathbf{w}_t - \eta \nabla_{\mathbf{w}} \mathcal{L}(\mathbf{w}_t) \tag{2.4}$$

Adam Optimizer: Kết hợp momentum và adaptive learning rates:

$$\mathbf{m}_t = \beta_1 \mathbf{m}_{t-1} + (1 - \beta_1) \nabla_{\mathbf{w}} \mathcal{L}(\mathbf{w}_t) \tag{2.5}$$

$$\mathbf{v}_t = \beta_2 \mathbf{v}_{t-1} + (1 - \beta_2)(\nabla_{\mathbf{w}} \mathcal{L}(\mathbf{w}_t))^2 \tag{2.6}$$

$$\mathbf{w}_{t+1} = \mathbf{w}_t - \eta \frac{\hat{\mathbf{m}}_t}{\sqrt{\hat{\mathbf{v}}_t} + \epsilon} \tag{2.7}$$

AdamW: Biến thể của Adam với weight decay được tách riêng [23], được sử dụng trong PhaBERT-CNN.

2.4.4 Regularization techniques

Dropout

Dropout ngẫu nhiên tắt một tỷ lệ neurons trong quá trình huấn luyện:

$$\mathbf{h}_{\text{dropout}} = \mathbf{m} \odot \mathbf{h} \tag{2.8}$$

với $\mathbf{m} \sim \text{Bernoulli}(p)$ là mask vector. Dropout giảm overfitting bằng cách ngăn co-adaptation giữa các neurons.

Batch Normalization

Batch Normalization chuẩn hóa activations trong mỗi mini-batch:

$$\hat{\mathbf{x}} = \frac{\mathbf{x} - \mathbb{E}[\mathbf{x}]}{\sqrt{\text{Var}[\mathbf{x}] + \epsilon}} \tag{2.9}$$

giúp ổn định quá trình huấn luyện và cho phép sử dụng learning rate cao hơn.

Layer Normalization

Layer Normalization chuẩn hóa theo chiều features thay vì batch dimension, phù hợp hơn cho sequence models:

$$\text{LayerNorm}(\mathbf{x}) = \gamma \odot \frac{\mathbf{x} - \mu}{\sqrt{\sigma^2 + \epsilon}} + \beta \tag{2.10}$$

với μ và σ^2 được tính trên chiều features.

2.4.5 Loss functions

Binary Cross-Entropy Loss

Cho bài toán phân loại nhị phân như phân loại lối sống phage:

$$\mathcal{L}_{\text{BCE}} = -\frac{1}{N} \sum_{i=1}^{N} \left[y_i \log(\hat{y}_i) + (1 - y_i) \log(1 - \hat{y}_i) \right] \tag{2.11}$$

với $y_i \in \{0, 1\}$ là nhãn thực và $\hat{y}_i \in (0, 1)$ là xác suất dự đoán.

2.4.6 Ưu điểm của học sâu cho dữ liệu sinh học

- **Automatic feature learning**: Không cần feature engineering thủ công
- **Hierarchical representations**: Học các features từ low-level đến high-level
- **End-to-end learning**: Tối ưu hóa toàn bộ pipeline cùng lúc
- **Transfer learning**: Tận dụng kiến thức từ các nhiệm vụ liên quan
- **Scalability**: Hiệu suất cải thiện với lượng dữ liệu lớn

2.5 Mạng nơ-ron tích chập

2.5.1 Giới thiệu về CNN

Mạng nơ-ron tích chập (Convolutional Neural Network - CNN) là một kiến trúc học sâu được thiết kế đặc biệt để xử lý dữ liệu có cấu trúc lưới (grid-like structure) như hình ảnh (2D grid) hoặc chuỗi (1D grid). CNN đã đạt được thành công vượt bậc trong computer vision và ngày càng được áp dụng rộng rãi cho phân tích chuỗi sinh học.

2.5.2 Phép tích chập (Convolution)

Convolution 1D cho chuỗi

Đối với chuỗi đầu vào $\mathbf{x} \in \mathbb{R}^{L \times d}$ với độ dài L và số chiều d, phép tích chập 1D với kernel $\mathbf{w} \in \mathbb{R}^{k \times d \times c}$ tạo ra feature map:

$$(\mathbf{x} * \mathbf{w})_i = \sum_{j=0}^{k-1} \sum_{m=0}^{d-1} x_{i+j,m} \cdot w_{j,m} \tag{2.12}$$

trong đó k là kernel size (receptive field), d là input channels, và c là output channels.

Receptive field

Receptive field là vùng đầu vào mà một neuron có thể "nhìn thấy". Với kernel size k, mỗi neuron trong feature map có receptive field là k positions liên tiếp trong chuỗi đầu vào. Xếp chồng nhiều lớp convolution mở rộng receptive field theo cấp số nhân, cho phép nắm bắt long-range dependencies.

2.5.3 Các thành phần của CNN

Pooling layers

Pooling giảm kích thước spatial của feature maps:

- **Max Pooling**: $y_i = \max_{j \in \text{window}_i} x_j$ - Chọn giá trị lớn nhất
- **Average Pooling**: $y_i = \frac{1}{k} \sum_{j \in \text{window}_i} x_j$ - Lấy trung bình
- **Adaptive Pooling**: Tự động điều chỉnh window size để tạo output có kích thước cố định

Stride và Padding

Stride s xác định bước nhảy của kernel:

$$L_{\text{out}} = \left\lfloor \frac{L_{\text{in}} - k}{s} \right\rfloor + 1 \tag{2.13}$$

Padding p thêm zeros vào đầu/cuối chuỗi để kiểm soát kích thước output:

$$L_{\text{out}} = \left\lfloor \frac{L_{\text{in}} + 2p - k}{s} \right\rfloor + 1 \tag{2.14}$$

2.5.4 Multi-scale CNN

Inception architecture

Kiến trúc Inception [24] sử dụng nhiều nhánh convolution song song với kernel sizes khác nhau để nắm bắt patterns ở nhiều tỷ lệ:

$$\mathbf{h}_{\text{multi-scale}} = \text{Concat}[\mathbf{h}_3, \mathbf{h}_5, \mathbf{h}_7] \tag{2.15}$$

với $\mathbf{h}_k$ là feature map từ convolution với kernel size k.

PhaBERT-CNN áp dụng ý tưởng này với ba nhánh CNN song song (kernel sizes 3, 5, 7) để trích xuất đặc trưng đa tỷ lệ từ DNABERT-2 embeddings.

2.5.5 CNN cho phân tích chuỗi sinh học

Ưu điểm

- **Local pattern detection**: Hiệu quả trong việc phát hiện motifs và patterns cục bộ
- **Parameter sharing**: Cùng một kernel được áp dụng trên toàn bộ chuỗi, giảm số tham số
- **Translation invariance**: Phát hiện patterns bất kể vị trí trong chuỗi
- **Computational efficiency**: Nhanh hơn RNN nhờ tính song song

Ứng dụng trong genomics

CNN đã được áp dụng thành công cho nhiều bài toán genomics:

- Dự đoán binding sites của transcription factors
- Phân loại chuỗi DNA/protein
- Dự đoán cấu trúc RNA
- Phân tích variant effects

CNN trên pre-trained embeddings

Trong PhaBERT-CNN, CNN không hoạt động trực tiếp trên chuỗi DNA thô mà trên DNABERT-2 embeddings. Cách tiếp cận này có ưu điểm:

- **Rich representations**: Embeddings đã mã hóa thông tin ngữ cảnh từ transformer

- **Task-specific adaptation**: CNN học các transformations phù hợp với nhiệm vụ phân loại lối sống
- **Multi-scale feature extraction**: Các kernel sizes khác nhau nắm bắt patterns từ local motifs đến broader functional domains

Cách tiếp cận tương tự đã thành công trong NLP, nơi CNN được áp dụng trên word embeddings hoặc contextualized representations [25, 26].

2.6 Kiến trúc Transformer

2.6.1 Giới thiệu

Transformer là kiến trúc mạng nơ-ron được giới thiệu bởi Vaswani et al. năm 2017 trong bài báo "Attention is All You Need" [27]. Khác với RNN và LSTM xử lý chuỗi tuần tự, Transformer sử dụng cơ chế self-attention để xử lý toàn bộ chuỗi song song, cho phép nắm bắt long-range dependencies hiệu quả hơn.

2.6.2 Self-Attention Mechanism

Scaled Dot-Product Attention

Cho một chuỗi đầu vào, self-attention tính toán representation của mỗi vị trí dựa trên toàn bộ chuỗi:

$$\text{Attention}(\mathbf{Q}, \mathbf{K}, \mathbf{V}) = \text{softmax}\left(\frac{\mathbf{Q}\mathbf{K}^T}{\sqrt{d_k}}\right)\mathbf{V} \tag{2.16}$$

trong đó:

- $\mathbf{Q} = \mathbf{X}\mathbf{W}^Q$ (Query): "Tôi đang tìm kiếm thông tin gì?"
- $\mathbf{K} = \mathbf{X}\mathbf{W}^K$ (Key): "Tôi chứa thông tin gì?"
- $\mathbf{V} = \mathbf{X}\mathbf{W}^K$ (Value): "Thông tin thực tế tôi cung cấp"
- d_k: Dimensionality của key vectors (scaling factor)

Attention weights $\alpha_{ij} = \text{softmax}\left(\frac{\mathbf{q}_i\mathbf{k}_j^T}{\sqrt{d_k}}\right)$ đo lường mức độ liên quan giữa vị trí i và j.

Multi-Head Attention

Multi-head attention cho phép mô hình chú ý đến các khía cạnh khác nhau của thông tin:

$$\text{MultiHead}(\mathbf{Q}, \mathbf{K}, \mathbf{V}) = \text{Concat}(\text{head}_1, \ldots, \text{head}_h)\mathbf{W}^O \tag{2.17}$$

$$\text{head}_i = \text{Attention}(\mathbf{Q}\mathbf{W}_i^Q, \mathbf{K}\mathbf{W}_i^K, \mathbf{V}\mathbf{W}_i^V) \tag{2.18}$$

với h là số attention heads. DNABERT-2 sử dụng 12 attention heads.

2.6.3 Positional Encoding

Vì self-attention không có khái niệm về thứ tự, cần thêm positional information:

Sinusoidal Positional Encoding

Transformer gốc sử dụng sinusoidal functions:

$$PE_{(pos,2i)} = \sin\left(\frac{pos}{10000^{2i/d}}\right) \tag{2.19}$$

$$PE_{(pos,2i+1)} = \cos\left(\frac{pos}{10000^{2i/d}}\right) \tag{2.20}$$

Learned Positional Embeddings

BERT học positional embeddings như parameters, nhưng bị giới hạn bởi maximum sequence length.

Attention with Linear Biases (ALiBi)

DNABERT-2 sử dụng ALiBi [28], thêm bias vào attention scores:

$$\text{softmax}\left(\mathbf{q}_i\mathbf{K}^T + m \cdot [-(i-1), \ldots, -1, 0]\right) \tag{2.21}$$

với m là slope khác nhau cho mỗi head. ALiBi cho phép xử lý chuỗi có độ dài tùy ý mà không cần retrain.

2.6.4 Feed-Forward Networks

Mỗi transformer layer có position-wise feed-forward network:

$$\text{FFN}(\mathbf{x}) = \max(0, \mathbf{x}\mathbf{W}_1 + \mathbf{b}_1)\mathbf{W}_2 + \mathbf{b}_2 \tag{2.22}$$

hoặc với GELU activation:

$$\text{FFN}(\mathbf{x}) = \text{GELU}(\mathbf{x}\mathbf{W}_1 + \mathbf{b}_1)\mathbf{W}_2 + \mathbf{b}_2 \tag{2.23}$$

2.6.5 Transformer Encoder

Một transformer encoder layer bao gồm:

$$\mathbf{h}' = \text{LayerNorm}(\mathbf{x} + \text{MultiHeadAttention}(\mathbf{x})) \tag{2.24}$$

$$\mathbf{h} = \text{LayerNorm}(\mathbf{h}' + \text{FFN}(\mathbf{h}')) \tag{2.25}$$

với residual connections và layer normalization.

2.6.6 Ưu điểm của Transformer

- **Parallelization**: Xử lý toàn bộ chuỗi song song, nhanh hơn RNN
- **Long-range dependencies**: Self-attention trực tiếp kết nối mọi cặp vị trí
- **Flexible attention patterns**: Mỗi head có thể học các patterns khác nhau
- **Scalability**: Hiệu suất cải thiện với model size và data

2.6.7 Transformer cho genomics

Transformer đã được áp dụng thành công cho nhiều bài toán genomics:

- DNABERT, DNABERT-2: Pre-trained models cho DNA sequences
- Nucleotide Transformer: Large-scale genome foundation model

- ProtTrans: Protein language models
- RNA-FM: RNA sequence modeling

Khả năng nắm bắt long-range dependencies của transformer đặc biệt phù hợp với dữ liệu genome, nơi các yếu tố điều hòa có thể cách xa nhau hàng nghìn base pairs.

2.7 BERT và Masked Language Modeling

2.7.1 Giới thiệu về BERT

BERT (Bidirectional Encoder Representations from Transformers) [29] là mô hình ngôn ngữ tiền huấn luyện dựa trên kiến trúc transformer encoder. BERT đã cách mạng hóa NLP bằng cách học bidirectional representations thông qua masked language modeling, cho phép mô hình nắm bắt ngữ cảnh từ cả hai hướng trái và phải.

2.7.2 Masked Language Modeling (MLM)

Nguyên lý

MLM là nhiệm vụ tiền huấn luyện chính của BERT:

1. Ngẫu nhiên mask 15% tokens trong chuỗi đầu vào
2. Mô hình dự đoán các tokens bị mask dựa trên ngữ cảnh xung quanh
3. Loss function: Cross-entropy trên các masked positions

$$\mathcal{L}_{\text{MLM}} = -\sum_{i \in \mathcal{M}} \log P(x_i | \mathbf{x}_{\setminus \mathcal{M}}) \tag{2.26}$$

với $\mathcal{M}$ là tập các vị trí bị mask.

Masking strategy

Để tránh mismatch giữa pre-training và fine-tuning, BERT sử dụng chiến lược:

- 80%: Thay bằng [MASK] token
- 10%: Thay bằng random token
- 10%: Giữ nguyên token gốc

2.7.3 Kiến trúc BERT

BERT sử dụng transformer encoder với:

- **BERT-Base**: 12 layers, 768 hidden size, 12 attention heads, 110M parameters
- **BERT-Large**: 24 layers, 1024 hidden size, 16 attention heads, 340M parameters

Input representation

BERT input = Token embeddings + Segment embeddings + Position embeddings

2.7.4 Transfer Learning với BERT

Pre-training

BERT được tiền huấn luyện trên corpus lớn (Wikipedia + BookCorpus) với hai nhiệm vụ:

- Masked Language Modeling (MLM)
- Next Sentence Prediction (NSP)

Fine-tuning

Sau pre-training, BERT được fine-tune cho các nhiệm vụ downstream:

- Thêm task-specific layer (thường là linear classifier)
- Fine-tune toàn bộ mô hình end-to-end
- Sử dụng learning rate nhỏ để tránh catastrophic forgetting

2.7.5 Ưu điểm của BERT

- **Bidirectional context**: Nắm bắt ngữ cảnh từ cả hai hướng
- **Transfer learning**: Kiến thức từ pre-training chuyển sang downstream tasks
- **Versatility**: Áp dụng cho nhiều NLP tasks khác nhau
- **State-of-the-art performance**: Đạt SOTA trên nhiều benchmarks

2.7.6 BERT cho genomics

Ý tưởng của BERT đã được áp dụng thành công cho dữ liệu genome, dẫn đến sự phát triển của các genome foundation models như DNABERT, DNABERT-2, và Nucleotide Transformer. Các mô hình này thay thế words bằng DNA tokens và học representations từ corpus genome lớn.

2.8 DNABERT: BERT cho chuỗi DNA

2.8.1 Giới thiệu

DNABERT [30] là mô hình đầu tiên áp dụng kiến trúc BERT cho phân tích chuỗi DNA. DNABERT được tiền huấn luyện trên bộ gen người (human genome) và đạt được hiệu suất vượt trội trên nhiều nhiệm vụ genomics downstream.

2.8.2 Tokenization: Overlapping k-mers

DNABERT sử dụng overlapping k-mer tokenization:

Ví dụ với k=3:

```
DNA sequence: ATCGATCG
Tokens:       ATC TCG CGA GAT ATC TCG
```

Với chuỗi độ dài L, số tokens là $L - k + 1$.

2.8.3 Hạn chế của DNABERT

Information leakage

Các tokens liền kề chia sẻ $k-1$ nucleotides, dẫn đến information leakage trong MLM. Khi mask một token, mô hình có thể suy luận nội dung từ các tokens xung quanh do overlap.

Ví dụ:

```
Tokens:  ATC [MASK] GAT
Overlap: AT_  _CG  _AT
=> Token bị mask phải là "CGA"
```

Kém hiệu quả tính toán

Số tokens gần bằng độ dài chuỗi gốc ($L-k+1 \approx L$), dẫn đến:

- Computational cost cao
- Memory usage lớn
- Training time dài

Giới hạn độ dài chuỗi

DNABERT sử dụng learned positional embeddings với maximum length 512, không thể xử lý chuỗi dài hơn mà không retrain.

Single-species pre-training

DNABERT chỉ được tiền huấn luyện trên human genome, hạn chế khả năng tổng quát hóa sang các loài khác.

2.8.4 Thành công và ảnh hưởng

Mặc dù có hạn chế, DNABERT đã chứng minh hiệu quả của transfer learning cho genomics và mở đường cho các mô hình cải tiến như DNABERT-2.

2.9 DNABERT-2: Cải tiến với BPE và Multi-species Training

2.9.1 Giới thiệu

DNABERT-2 [19] là thế hệ tiếp theo của DNABERT, giải quyết các hạn chế chính của người tiền nhiệm thông qua ba cải tiến quan trọng: Byte Pair Encoding tokenization, Attention with Linear Biases, và multi-species pre-training corpus.

2.9.2 Byte Pair Encoding (BPE) Tokenization

Nguyên lý BPE

BPE [31] là thuật toán compression được áp dụng cho tokenization. BPE xây dựng vocabulary bằng cách lặp lại merge các cặp symbols xuất hiện thường xuyên nhất:

1. Bắt đầu với vocabulary chứa các nucleotides đơn: {A, T, C, G}
2. Đếm tần suất của tất cả các cặp symbols liền kề
3. Merge cặp xuất hiện nhiều nhất thành một token mới
4. Lặp lại cho đến khi đạt vocabulary size mong muốn

Ví dụ:

```
Iteration 1: "AT" xuất hiện nhiều nhất → merge thành "AT"
Iteration 2: "CG" xuất hiện nhiều nhất → merge thành "CG"
Iteration 3: "AT" + "CG" → merge thành "ATCG"
...
```

DNABERT-2 sử dụng SentencePiece [32] implementation của BPE với vocabulary size 4096.

Ưu điểm của BPE

1. Loại bỏ information leakage:

BPE tokens không overlap, do đó không có information leakage:

```
k-mer:  ATC TCG CGA GAT ATC TCG  (overlap)
BPE:    ATCG ATCG                (no overlap)
```

2. Giảm độ dài chuỗi 5 lần:

Với vocabulary size 4096, BPE tạo ra tokens có độ dài trung bình 5 nucleotides, giảm số tokens từ L xuống $L/5$:

- Giảm computational cost
- Giảm memory usage
- Tăng tốc training và inference

3. Span prediction:

MLM trên BPE tokens trở thành span prediction task - mô hình phải dự đoán cả độ dài và nội dung của span bị mask. Điều này đã được chứng minh làm tăng hiệu quả học [33].

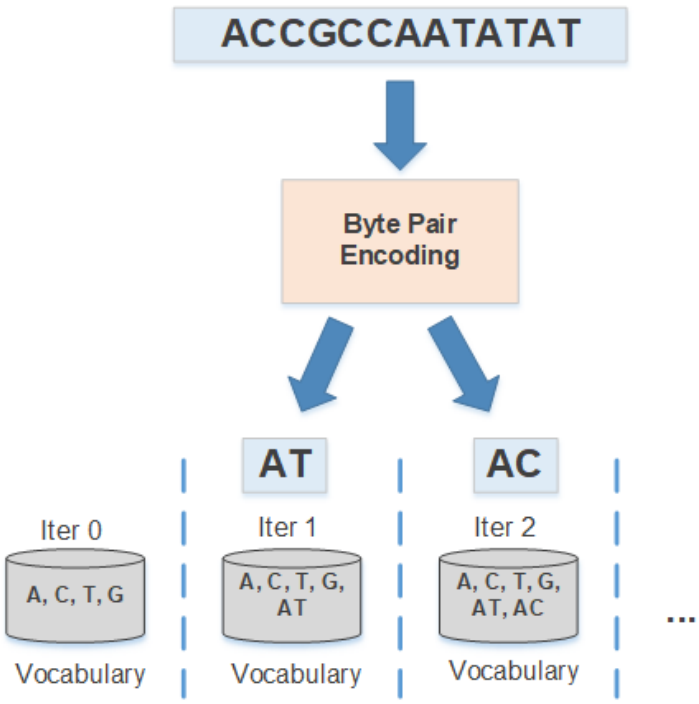

Hình 2.1: Ví dụ về quá trình xây dựng vocabulary BPE (nguồn: paper DNABERT-2)

2.9.3 Attention with Linear Biases (ALiBi)

Vấn đề với learned positional embeddings

DNABERT sử dụng learned positional embeddings, bị giới hạn bởi maximum sequence length được định trước (512 tokens). Để xử lý chuỗi dài hơn cần retrain mô hình.

ALiBi mechanism

ALiBi [28] thay thế positional embeddings bằng bias được thêm vào attention scores:

$$\text{softmax}\left(\mathbf{q}_i\mathbf{K}^T + m \cdot [-(i-1), \ldots, -1, 0]\right) \tag{2.27}$$

với m là slope khác nhau cho mỗi attention head. ALiBi penalize attention weights dựa trên khoảng cách giữa query và key positions.

Ưu điểm của ALiBi

- **Flexible sequence length**: Xử lý chuỗi có độ dài tùy ý mà không cần retrain
- **Better extrapolation**: Hiệu suất tốt trên chuỗi dài hơn training sequences
- **No additional parameters**: Không tăng số tham số mô hình

DNABERT-2 có thể xử lý chuỗi 10× ngắn hơn hoặc 15× dài hơn so với training sequences (trung bình 700 bp) mà vẫn duy trì hiệu suất tốt.

2.9.4 Multi-species Pre-training

Pre-training corpus

DNABERT-2 được tiền huấn luyện trên corpus genome đa loài, bao gồm:

- Genomes từ nhiều loài khác nhau (bacteria, archaea, viruses, eukaryotes)
- Tổng cộng hàng tỷ base pairs

- Đa dạng về GC content, codon usage, và genomic features

Lợi ích

- **Better generalization**: Học các patterns bảo tồn qua các loài
- **Cross-species transfer**: Hiệu suất tốt trên các loài chưa thấy trong pre-training
- **Robust representations**: Ít bị overfitting vào đặc điểm của một loài cụ thể

Đặc biệt quan trọng cho phân loại phage, vì phage có đa dạng sinh học cao và nhiều phage chưa được nghiên cứu kỹ.

2.9.5 Kiến trúc và Training

Model architecture

DNABERT-2 sử dụng:

- 12 transformer encoder layers
- 768 hidden dimensions
- 12 attention heads
- 117M parameters (30% nhiều hơn DNABERT)

Flash Attention

DNABERT-2 tích hợp Flash Attention [34] để:

- Giảm memory consumption
- Tăng tốc training 3×
- Chỉ sử dụng 1/3 FLOPs so với DNABERT

2.9.6 Hiệu suất

Genome Understanding Evaluation (GUE) benchmark

DNABERT-2 đạt hiệu suất tương đương Nucleotide Transformer (2.5B parameters) trên GUE benchmark - 36 tasks trên 9 categories - trong khi:

- Nhỏ hơn 21× về model size
- Nhanh hơn 92× về pre-training time

Sequence length flexibility

DNABERT-2 duy trì hiệu suất tốt trên:

- Chuỗi ngắn: 70 bp (10× ngắn hơn training)
- Chuỗi dài: 10,000 bp (15× dài hơn training)

2.9.7 Tại sao chọn DNABERT-2 cho PhaBERT-CNN

DNABERT-2 là lựa chọn lý tưởng cho phân loại lối sống phage vì:

1. **BPE tokenization**: Loại bỏ information leakage và hiệu quả tính toán
2. **ALiBi**: Xử lý linh hoạt các contig có độ dài biến thiên (100-1800 bp)
3. **Multi-species training**: Tổng quát hóa tốt cho phage đa dạng
4. **Efficiency**: Model size và computational cost hợp lý
5. **Strong baseline**: Hiệu suất tốt trên nhiều genomics tasks

PhaBERT-CNN xây dựng trên nền tảng vững chắc này bằng cách thêm các lớp CNN đa tỷ lệ và attention pooling để trích xuất đặc trưng task-specific cho phân loại lối sống phage.

2.10 Học chuyển giao trong sinh tin học

2.10.1 Khái niệm học chuyển giao

Học chuyển giao (Transfer Learning) là paradigm học máy trong đó kiến thức học được từ một nhiệm vụ nguồn (source task) được áp dụng để cải thiện hiệu suất trên một nhiệm vụ đích (target task) liên quan. Trong deep learning, transfer learning thường được thực hiện thông qua pre-training và fine-tuning.

2.10.2 Pre-training và Fine-tuning

Pre-training phase

Mô hình được huấn luyện trên một nhiệm vụ tự giám sát (self-supervised) với corpus lớn:

- **NLP**: Masked language modeling trên text corpus
- **Genomics**: Masked language modeling trên genome corpus
- **Computer Vision**: Contrastive learning trên image datasets

Mục tiêu: Học general-purpose representations nắm bắt cấu trúc và patterns của dữ liệu.

Fine-tuning phase

Mô hình tiền huấn luyện được điều chỉnh cho nhiệm vụ downstream cụ thể:

1. Thêm task-specific layers (ví dụ: classification head)
2. Khởi tạo từ pre-trained weights
3. Fine-tune trên labeled data của target task
4. Sử dụng learning rate nhỏ hơn pre-training

2.10.3 Chiến lược Fine-tuning

Full fine-tuning

Cập nhật tất cả parameters của mô hình:

$$\theta_{\text{fine-tuned}} = \theta_{\text{pre-trained}} - \eta \nabla_\theta \mathcal{L}_{\text{task}} \tag{2.28}$$

Feature extraction

Đóng băng pre-trained layers, chỉ train task-specific layers:

- Nhanh hơn, ít tài nguyên hơn
- Phù hợp khi dữ liệu target task ít
- Có thể kém hiệu quả nếu source và target tasks khác biệt nhiều

Discriminative fine-tuning

Sử dụng learning rates khác nhau cho các layers khác nhau:

- Lower layers (gần input): Learning rate nhỏ
- Higher layers (gần output): Learning rate lớn hơn
- Rationale: Lower layers học general features, higher layers học task-specific features

PhaBERT-CNN sử dụng chiến lược này với learning rate cho DNABERT-2 là 1×10^{-5} và cho task-specific layers là 1×10^{-4}.

Gradual unfreezing

Dần dần unfreeze các layers từ top xuống bottom:

1. Train chỉ classification head
2. Unfreeze top transformer layer, train

3. Tiếp tục unfreeze từng layer và train

PhaBERT-CNN sử dụng biến thể: warm-up phase (freeze DNABERT-2) sau đó full fine-tuning.

2.10.4 Lợi ích của Transfer Learning

- **Data efficiency**: Đạt hiệu suất tốt với ít labeled data
- **Faster convergence**: Bắt đầu từ good initialization
- **Better generalization**: Pre-trained representations robust hơn
- **Domain adaptation**: Chuyển kiến thức giữa các domains liên quan

2.10.5 Transfer Learning trong Genomics

Thành công của genome foundation models

Các mô hình như DNABERT-2, Nucleotide Transformer đã chứng minh hiệu quả của transfer learning cho genomics:

- Pre-train trên corpus genome lớn, đa dạng
- Fine-tune cho các tasks cụ thể: gene prediction, variant calling, phage classification, etc.
- Đạt SOTA trên nhiều benchmarks

Challenges

- **Domain shift**: Pre-training data có thể khác biệt với target domain
- **Catastrophic forgetting**: Fine-tuning có thể làm mất kiến thức pre-trained
- **Computational cost**: Pre-training đòi hỏi tài nguyên lớn

2.10.6 PhaBERT-CNN và Transfer Learning

PhaBERT-CNN tận dụng transfer learning thông qua:

1. **Pre-trained DNABERT-2**: Mã hóa kiến thức từ multi-species genome corpus
2. **Two-phase fine-tuning**: Warm-up + full fine-tuning với discriminative learning rates
3. **Task-specific architecture**: CNN và attention layers học features phù hợp với phân loại lối sống phage

Cách tiếp cận này cho phép PhaBERT-CNN đạt hiệu suất tốt ngay cả trên các contig ngắn với dữ liệu huấn luyện hạn chế.

2.11 Các công trình liên quan

Phần này tổng hợp các phương pháp tính toán hiện có cho phân loại lối sống thực khuẩn thể, phân tích ưu nhược điểm của từng phương pháp, và làm rõ vị trí của PhaBERT-CNN trong bối cảnh nghiên cứu hiện tại.

2.11.1 Phương pháp học máy truyền thống

PHACTS

PHACTS (Phage Classification Tool Set) [4] là một trong những công cụ đầu tiên sử dụng học máy cho phân loại lối sống phage. PHACTS sử dụng Random Forest với features dựa trên protein:

Quy trình:

1. Tạo standard protein set từ các phage đã biết
2. Sử dụng FASTA để tính similarity vectors cho proteins trong phage query
3. Concatenate vectors thành feature vector cuối cùng
4. Phân loại bằng Random Forest

Ưu điểm:

- Đạt accuracy >90% trên complete genomes
- Interpretable features dựa trên protein homology

Nhược điểm:

- Phụ thuộc vào gene prediction chính xác
- Hiệu suất giảm 30% trên contig data [3]
- Không xử lý tốt các phage mới với proteins không có trong database

PhageAI

PhageAI [35] áp dụng kỹ thuật NLP cho dữ liệu genome:

Quy trình:

1. Chuyển đổi DNA sequences thành k-mers (text format)
2. Sử dụng Word2Vec để học embeddings
3. Áp dụng RFECV (Recursive Feature Elimination with Cross-Validation) để chọn features
4. Phân loại bằng SVM

Ưu điểm:

- Hoạt động trực tiếp trên DNA sequences
- Không cần gene prediction
- Đạt hiệu suất tốt trên complete genomes

Nhược điểm:

- Word2Vec embeddings không nắm bắt được long-range dependencies
- Feature selection thủ công có thể bỏ lỡ patterns quan trọng
- Hiệu suất giảm đáng kể trên short contigs

BACPHLIP

BACPHLIP [36] tập trung vào conserved protein regions:

Quy trình:

1. Identify conserved protein regions (functional domains)
2. Tạo binary feature vectors biểu diễn sự hiện diện của các regions
3. Phân loại bằng Random Forest

Ưu điểm:

- Sử dụng biological knowledge về functional domains
- Hiệu suất cạnh tranh trên complete genomes

Nhược điểm:

- Phụ thuộc vào database của conserved regions (limited availability)
- Không áp dụng được cho phage với novel proteins
- Yêu cầu chuỗi đủ dài để chứa complete domains

2.11.2 Phương pháp học sâu

DeePhage

DeePhage [3] là phương pháp học sâu đầu tiên cho phân loại lối sống phage, sử dụng CNN trên one-hot encoded DNA sequences:

Kiến trúc:

- Input: One-hot encoding của DNA (4 channels: A, T, C, G)
- Multiple convolutional layers với max pooling
- Fully connected layers cho classification

Ưu điểm:

- Hoạt động trực tiếp trên raw DNA sequences
- Tự động học features, không cần feature engineering
- Hiệu suất tốt hơn đáng kể so với PHACTS trên contig data

Nhược điểm:

- Trained from scratch, không tận dụng pre-trained knowledge
- CNN có limited receptive field, khó nắm bắt long-range dependencies
- One-hot encoding không mã hóa biological meaning của nucleotides
- Hiệu suất kém hơn các phương pháp dựa trên transformer trên short contigs

PhaTYP

PhaTYP [7] là phương pháp đầu tiên áp dụng BERT cho phân loại phage:

Quy trình:

1. Sử dụng Prodigal để dự đoán protein-coding genes
2. Tokenize dựa trên protein sequences
3. Fine-tune BERT cho phân loại

Ưu điểm:

- Tận dụng pre-trained BERT representations
- Hiệu suất xuất sắc trên long contigs (>1200 bp)
- Đạt SOTA trên nhiều benchmarks

Nhược điểm:

- **Critical dependency on Prodigal**: Gene prediction tools có hiệu suất giảm đáng kể trên fragments <200 bp [17]
- Không áp dụng được cho contigs thiếu complete genes
- Hiệu suất giảm trên short contigs do gene prediction không đáng tin cậy
- Protein-based tokenization bỏ lỡ thông tin từ non-coding regions

DeepPL

DeepPL [21] sử dụng DNABERT (phiên bản đầu tiên) với k-mer tokenization:

Ưu điểm:

- Hoạt động trực tiếp trên DNA sequences
- Tận dụng pre-trained DNABERT

Nhược điểm:

- **Overlapping k-mer tokenization**: Information leakage trong MLM
- **Computational inefficiency**: Số tokens gần bằng sequence length
- **Maximum length constraint**: DNABERT giới hạn ở 512 bp do learned positional embeddings
- Không thể đánh giá trên sequences >512 bp trong nghiên cứu này

ProkBERT

ProkBERT [20] sử dụng Local Context-Aware (LCA) tokenization:

Ưu điểm:

- Pre-trained trên prokaryotic genomes
- Hiệu suất tốt trên một số tasks

Nhược điểm:

- LCA tokenization vẫn sử dụng overlapping k-mers, dẫn đến information leakage
- Kém hiệu quả tính toán tương tự DNABERT
- **Performance stagnation**: Không cải thiện với longer contigs, accuracy đạt đỉnh ở Group B (400-800 bp) rồi giảm
- Hiệu suất kém hơn PhaBERT-CNN trên tất cả các nhóm độ dài

2.11.3 So sánh tổng quan

Bảng 2.1: So sánh các phương pháp phân loại lối sống phage

Phương pháp	Loại	Input	Gene Pred.	Pre-trained	Short Contigs	Năm
PHACTS	ML	Protein	Có	Không	Kém	2012
PhageAI	ML	DNA	Không	Không	Trung bình	2020
BACPHLIP	ML	Protein	Có	Không	Kém	2021
DeePhage	DL (CNN)	DNA	Không	Không	Trung bình	2021
PhaTYP	DL (BERT)	Protein	Có	Có	Kém	2023
DeepPL	DL (BERT)	DNA	Không	Có	Giới hạn	2024
ProkBERT	DL (BERT)	DNA	Không	Có	Trung bình	2024
PhaBERT-CNN	**DL (Hybrid)**	**DNA**	**Không**	**Có**	**Tốt**	**2025**

2.11.4 Vị trí của PhaBERT-CNN

PhaBERT-CNN giải quyết các hạn chế chính của các phương pháp hiện có:

1. **Khắc phục hạn chế của PhaTYP**: Không phụ thuộc vào gene prediction, hoạt động hiệu quả trên short contigs
2. **Vượt trội hơn DeePhage**: Tận dụng pre-trained DNABERT-2 thay vì training from scratch
3. **Cải thiện so với DNABERT/ProkBERT**: Sử dụng DNABERT-2 với BPE tokenization (no information leakage) và ALiBi (flexible sequence length)
4. **Hybrid architecture**: Kết hợp transformer (global context) và CNN (local patterns) để trích xuất đặc trưng đa tỷ lệ
5. **Hiệu suất cân bằng**: Đạt hiệu suất tốt trên toàn bộ phạm vi độ dài contig (100-1800 bp), không chỉ tối ưu cho một nhóm cụ thể

PhaBERT-CNN đại diện cho sự tiến bộ trong việc kết hợp genome foundation models với task-specific architectures để giải quyết các thách thức thực tế trong phân tích metagenomic.

Chương 3

Phương pháp đề xuất

3.1 Tổng quan phương pháp PhaBERT-CNN

3.1.1 Động lực thiết kế

Phương pháp PhaBERT-CNN được thiết kế để giải quyết các thách thức chính trong phân loại lối sống thực khuẩn thể từ dữ liệu metagenomic, đặc biệt là trên các contig ngắn và trung bình (100-1200 bp). Động lực thiết kế bao gồm:

1. **Tận dụng pre-trained knowledge**: Sử dụng DNABERT-2 đã được tiền huấn luyện trên corpus genome đa loài để nắm bắt các patterns tiến hóa và cấu trúc genome
2. **Hoạt động trực tiếp trên DNA**: Không phụ thuộc vào gene prediction tools, khắc phục hạn chế của PhaTYP trên short contigs
3. **Trích xuất đặc trưng đa tỷ lệ**: Kết hợp CNN với nhiều kernel sizes để nắm bắt patterns từ local motifs đến broader functional domains
4. **Tổng hợp thông tin toàn cục**: Sử dụng attention mechanism để tự động học trọng số quan trọng của các vị trí trong chuỗi
5. **Xử lý linh hoạt độ dài chuỗi**: ALiBi trong DNABERT-2 cho phép xử lý contigs có độ dài biến thiên mà không cần retrain

3.1.2 Kiến trúc tổng thể

PhaBERT-CNN là một kiến trúc học sâu lai (hybrid deep learning architecture) bao gồm ba thành phần chính:

1. **DNABERT-2 backbone**: Mô hình nền tảng genome tiền huấn luyện, đóng vai trò feature extractor tạo ra contextualized embeddings cho mỗi token trong chuỗi DNA

2. **Dual parallel feature extraction branches**:

   - *Multi-scale CNN branch*: Ba nhánh CNN song song với kernel sizes 3, 5, 7 để trích xuất local patterns ở nhiều tỷ lệ
   - *Attention-based global pooling branch*: Self-attention mechanism để tổng hợp thông tin sequence-level toàn cục

3. **Classification head**: Fully connected layers kết hợp features từ cả hai branches để tạo ra dự đoán nhị phân (virulent vs temperate)

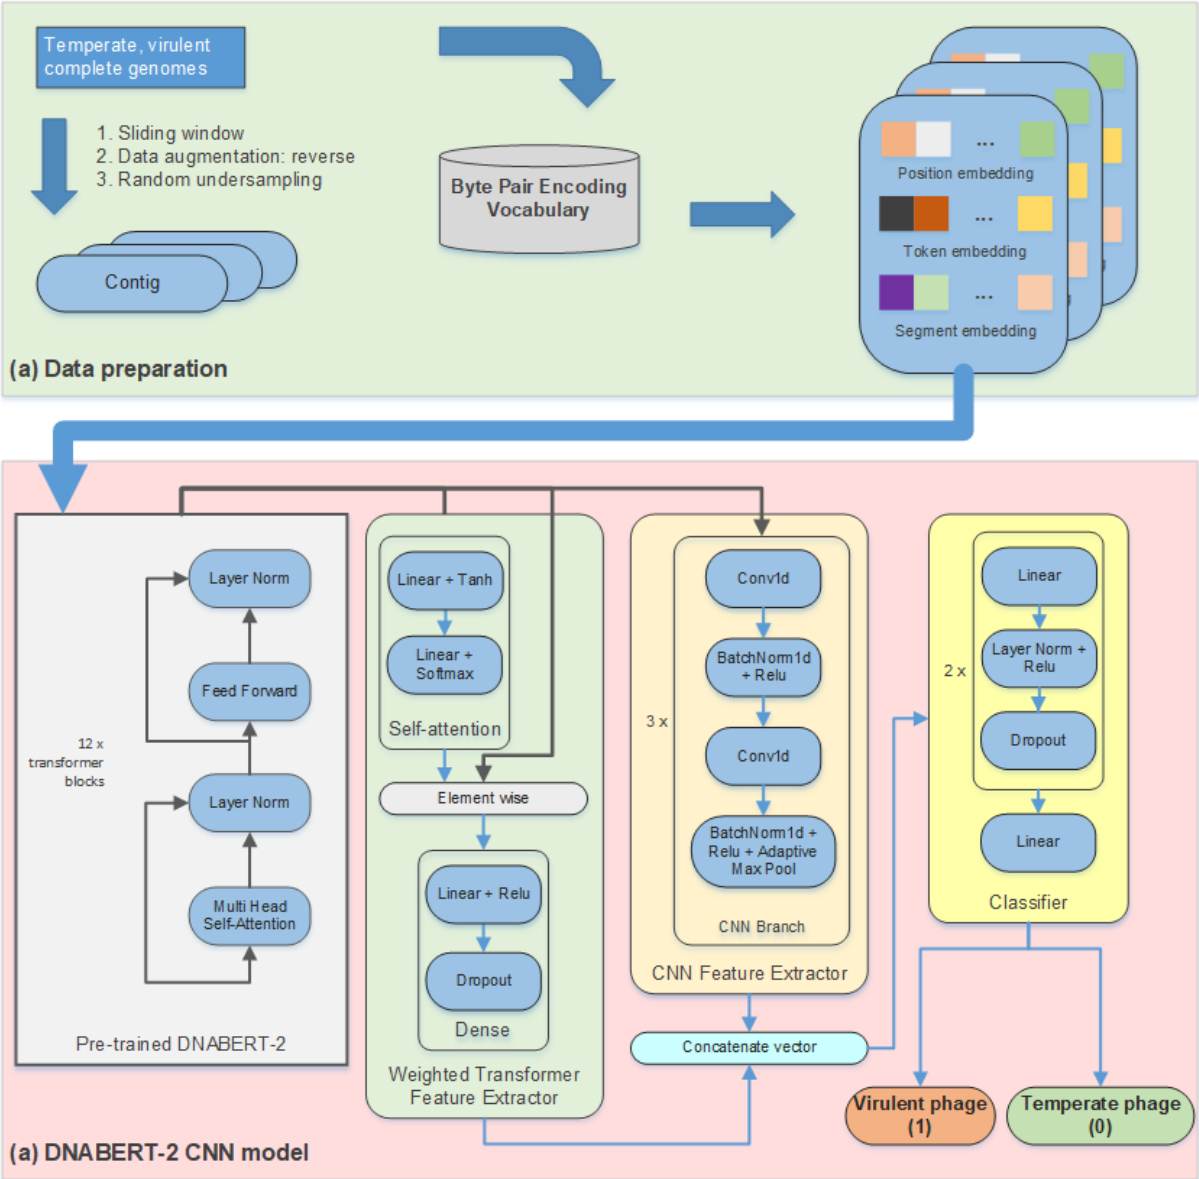

Hình 3.1: Tổng quan kiến trúc PhaBERT-CNN cho dự đoán lối sống thực khuẩn thể

3.1.3 Quy trình xử lý

Quy trình xử lý một contig DNA qua PhaBERT-CNN bao gồm các bước sau:

1. **Tokenization**: Chuỗi DNA được tokenize bằng BPE tokenizer của DNABERT-2, tạo ra chuỗi tokens có độ dài giảm 5 lần so với chuỗi gốc
2. **DNABERT-2 encoding**: Chuỗi tokens được đưa qua 12 transformer encoder layers, tạo ra contextualized embeddings 768-dimensional cho mỗi token
3. **Multi-scale CNN feature extraction**: Embeddings được xử lý song song qua ba nhánh CNN với kernel sizes khác nhau, mỗi nhánh tạo ra 128-dimensional feature vector
4. **Attention-based global pooling**: Embeddings cũng được xử lý qua attention mechanism để tạo ra 128-dimensional global feature vector
5. **Feature fusion**: Bốn feature vectors (3 từ CNN + 1 từ attention) được concatenate thành 512-dimensional composite representation
6. **Classification**: Composite features được đưa qua classification head để tạo ra binary logits, sau đó áp dụng sigmoid để có xác suất dự đoán

3.1.4 Ưu điểm của kiến trúc

Kiến trúc PhaBERT-CNN có những ưu điểm sau:

- **Complementary feature extraction**: CNN nắm bắt local patterns, attention nắm bắt global context, kết hợp tạo ra representations phong phú
- **Multi-scale awareness**: Các kernel sizes khác nhau cho phép mô hình nhận diện patterns ở nhiều mức độ trừu tượng
- **Adaptive attention**: Mô hình tự động học vùng nào trong chuỗi quan trọng cho phân loại, không cần annotation thủ công
- **End-to-end learning**: Toàn bộ pipeline được tối ưu hóa cùng lúc, đảm bảo các thành phần hoạt động hài hòa

- **Transfer learning**: Tận dụng kiến thức từ DNABERT-2 pre-training, giảm nhu cầu về labeled data

Các sections tiếp theo sẽ trình bày chi tiết về từng thành phần của phương pháp PhaBERT-CNN.

3.2 Xây dựng tập dữ liệu

3.2.1 Nguồn dữ liệu

Tập dữ liệu được xây dựng từ hai nghiên cứu gần đây:

- **DeePhage dataset** [3]: Tập dữ liệu gốc với các phage đã được phân loại lối sống
- **DeepPL annotations** [21]: Các chuỗi mới được gán nhãn bổ sung

Tập dữ liệu kết hợp bao gồm **2,241 bộ gen phage hoàn chỉnh**:

- 707 phage temperate (nhãn 0)
- 1,534 phage virulent (nhãn 1)
- Tỷ lệ virulent:temperate $\approx$ 2:1 (class imbalance)

3.2.2 Tạo contigs bằng sliding window

Để mô phỏng kịch bản metagenomic thực tế, contigs được tạo từ complete genomes bằng phương pháp sliding window:

Thuật toán

Tham số cho từng nhóm

Rationale cho overlap ratios:

- Nhóm ngắn (A): Overlap thấp để tránh tạo quá nhiều contigs tương tự
- Nhóm dài (D): Overlap cao để tăng số lượng samples và đa dạng hóa dữ liệu

Thuật toán 1 Contig Generation với Sliding Window

Input: Complete genome G với độ dài L, nhóm độ dài group $\in \{A, B, C, D\}$
Output: Tập contigs $\mathcal{C}$
$\mathcal{C} \leftarrow \emptyset$
pos $\leftarrow 0$
while pos $< L$ **do**
    length $\sim \mathcal{N}(\mu_{\text{group}}, \sigma^2_{\text{group}})$ ▷ Sample từ phân phối chuẩn
    length $\leftarrow$ clip(length, $\min_{\text{group}}, \max_{\text{group}}$)
    contig $\leftarrow G[\text{pos} : \text{pos} + \text{length}]$
    $\mathcal{C} \leftarrow \mathcal{C} \cup \{\text{contig}\}$
    overlap $\leftarrow$ length $\times$ overlap_ratio$_{\text{group}}$
    pos $\leftarrow$ pos + length − overlap
end while
return $\mathcal{C}$

Bảng 3.1: Tham số tạo contig cho các nhóm độ dài

Nhóm	**Phạm vi (bp)**	μ **(bp)**	σ **(bp)**	**Overlap ratio**
A	100-400	250	75	10%
B	400-800	600	100	20%
C	800-1200	1000	100	30%
D	1200-1800	1500	150	40%

3.2.3 Data augmentation

Reverse complement

Mỗi contig được augment bằng cách tạo reverse complement sequence:

$$\text{RevComp(ATCG)} = \text{CGAT} \tag{3.1}$$

với quy tắc: $A \leftrightarrow T$, $C \leftrightarrow G$.

Lý do: DNA có cấu trúc sợi đôi, cả hai hướng đều mang thông tin sinh học tương đương. Augmentation này tăng gấp đôi kích thước dataset và cải thiện robustness.

3.2.4 Xử lý class imbalance

Random undersampling

Để giải quyết tỷ lệ virulent:temperate = 2:1, áp dụng random undersampling trên training set:

1. Giữ nguyên tất cả samples của lớp thiểu số (temperate)
2. Ngẫu nhiên chọn số lượng samples tương đương từ lớp đa số (virulent)
3. Kết quả: Training set cân bằng 1:1

Trade-off:

- *Ưu điểm*: Đơn giản, hiệu quả, tránh model bias
- *Nhược điểm*: Mất một phần thông tin từ lớp đa số
- *Lý do chọn*: Giới hạn tài nguyên tính toán, undersampling nhanh hơn các phương pháp phức tạp như SMOTE

3.2.5 Chia tập dữ liệu

Stratified 5-fold cross-validation

Sử dụng stratified 5-fold CV để đảm bảo:

- Tỷ lệ các lớp được duy trì trong mỗi fold
- Đánh giá robust trên nhiều splits khác nhau
- Giảm variance trong kết quả đánh giá

Train-validation split

Mỗi fold được chia:

- **Training set**: 80% (sau undersampling)
- **Validation set**: 20%
- **Test set**: Fold còn lại (20% của toàn bộ data)

3.2.6 Thống kê tập dữ liệu

Bảng 3.2: Thống kê số lượng contigs sau augmentation (trước undersampling)

Nhóm	Temperate	Virulent	Total	Ratio (V:T)
A (100-400 bp)	45,234	98,567	143,801	2.18:1
B (400-800 bp)	28,156	61,423	89,579	2.18:1
C (800-1200 bp)	18,945	41,289	60,234	2.18:1
D (1200-1800 bp)	12,678	27,634	40,312	2.18:1

Quan sát:

- Số lượng contigs giảm khi độ dài tăng (do sliding window với overlap)
- Tỷ lệ V:T nhất quán 2.18:1 trên tất cả các nhóm
- Sau undersampling, mỗi nhóm có số lượng samples cân bằng 1:1

3.3 Mô hình nền tảng DNABERT-2

DNABERT-2 [19] được sử dụng làm backbone của PhaBERT-CNN. Phần này tóm tắt các đặc điểm kỹ thuật quan trọng của DNABERT-2 liên quan đến ứng dụng phân loại lối sống phage.

3.3.1 Tokenization với BPE

DNABERT-2 sử dụng Byte Pair Encoding (BPE) [31] thông qua SentencePiece [32]:

- **Vocabulary size**: 4,096 tokens
- **Average token length**: 5 nucleotides
- **Sequence length reduction**: 5× so với chuỗi gốc
- **Special tokens**: [CLS], [SEP], [PAD], [MASK], [UNK]

Ví dụ tokenization:

```
Input:  ATCGATCGATCGATCG (16 bp)
Tokens: [CLS] ATCG ATCG ATCG ATCG [SEP] (6 tokens)
```

3.3.2 Model architecture

- **Layers**: 12 transformer encoder layers
- **Hidden size**: 768 dimensions
- **Attention heads**: 12 heads (64 dimensions per head)
- **Intermediate size**: 3,072 (FFN hidden layer)
- **Total parameters**: 117M
- **Activation**: GELU
- **Normalization**: Layer Normalization
- **Dropout**: 0.1

3.3.3 Positional encoding: ALiBi

DNABERT-2 sử dụng Attention with Linear Biases (ALiBi) [28] thay vì learned positional embeddings:

$$\text{Attention}(\mathbf{Q}, \mathbf{K}, \mathbf{V}) = \text{softmax}\left(\frac{\mathbf{Q}\mathbf{K}^T}{\sqrt{d_k}} + \mathbf{B}\right)\mathbf{V} \tag{3.2}$$

với bias matrix:

$$\mathbf{B}_{ij} = m \cdot (j - i) \tag{3.3}$$

trong đó m là slope khác nhau cho mỗi attention head.

Lợi ích cho phân loại phage:

- Xử lý contigs có độ dài biến thiên (100-1800 bp) mà không cần retrain
- Extrapolate tốt sang chuỗi dài hơn hoặc ngắn hơn training sequences

3.3.4 Pre-training

Corpus:

- Multi-species genome corpus (bacteria, archaea, viruses, eukaryotes)
- Average sequence length: 700 bp
- Masked Language Modeling objective

Masking strategy:

- 15% tokens được mask
- 80%: Thay bằng [MASK]
- 10%: Thay bằng random token
- 10%: Giữ nguyên

3.3.5 Output representations

DNABERT-2 tạo ra ba loại representations:

1. **Token-level embeddings**: $\mathbf{H} \in \mathbb{R}^{L \times 768}$ - Contextualized embedding cho mỗi token
2. **[CLS] embedding**: $\mathbf{h}_{\text{CLS}} \in \mathbb{R}^{768}$ - Sequence-level representation
3. **Pooled output**: Linear transformation của [CLS] embedding

PhaBERT-CNN sử dụng **token-level embeddings H** làm input cho các lớp downstream, cho phép trích xuất đặc trưng chi tiết hơn so với chỉ sử dụng [CLS] embedding.

3.4 Kiến trúc PhaBERT-CNN

3.4.1 Tổng quan kiến trúc

PhaBERT-CNN xây dựng trên DNABERT-2 backbone với hai nhánh trích xuất đặc trưng song song và một classification head. Kiến trúc được thiết kế để kết hợp global context từ transformer và local patterns từ CNN.

3.4.2 Multi-scale CNN Feature Extractor

Động lực thiết kế

Lấy cảm hứng từ Inception architecture [24], multi-scale CNN sử dụng ba nhánh song song với kernel sizes khác nhau để nắm bắt patterns ở nhiều tỷ lệ:

- **Kernel size 3**: Fine-grained local motifs (3 tokens $\approx$ 15 bp)
- **Kernel size 5**: Medium-range patterns (5 tokens $\approx$ 25 bp)
- **Kernel size 7**: Broader functional domains (7 tokens $\approx$ 35 bp)

Kiến trúc từng nhánh

Mỗi nhánh CNN có cấu trúc giống nhau:

$$\mathbf{h}_1^{(k)} = \text{ReLU}(\text{BatchNorm}(\text{Conv1d}_k(\mathbf{H}))) \tag{3.4}$$

$$\mathbf{h}_2^{(k)} = \text{ReLU}(\text{BatchNorm}(\text{Conv1d}_k(\mathbf{h}_1^{(k)}))) \tag{3.5}$$

$$\mathbf{f}_{\text{CNN}}^{(k)} = \text{AdaptiveMaxPool1d}(\mathbf{h}_2^{(k)}) \tag{3.6}$$

với:

- Input: $\mathbf{H} \in \mathbb{R}^{L \times 768}$ (DNABERT-2 embeddings)
- Conv1d layer 1: $768 \rightarrow 256$ channels, kernel size k
- Conv1d layer 2: $256 \rightarrow 128$ channels, kernel size k
- AdaptiveMaxPool1d: Reduce sequence dimension to 1
- Output: $\mathbf{f}_{\text{CNN}}^{(k)} \in \mathbb{R}^{128}$

Feature fusion

Ba feature vectors được concatenate:

$$\mathbf{f}_{\text{CNN}} = [\mathbf{f}_{\text{CNN}}^{(3)}; \mathbf{f}_{\text{CNN}}^{(5)}; \mathbf{f}_{\text{CNN}}^{(7)}] \in \mathbb{R}^{384} \tag{3.7}$$

3.4.3 Attention-based Global Feature Extractor

Self-attention pooling

Attention mechanism học trọng số quan trọng của từng token position:

$$\mathbf{u}_t = \tanh(\mathbf{W}_a \mathbf{h}_t + \mathbf{b}_a) \in \mathbb{R}^{64} \tag{3.8}$$

$$\alpha_t = \frac{\exp\left(\mathbf{u}_t^T \mathbf{u}_s\right)}{\sum_{t'} \exp\left(\mathbf{u}_{t'}^T \mathbf{u}_s\right)} \tag{3.9}$$

$$\mathbf{v} = \sum_t \alpha_t \mathbf{h}_t \in \mathbb{R}^{768} \tag{3.10}$$

với:

- $\mathbf{h}_t$: Token embedding tại vị trí t
- $\mathbf{W}_a \in \mathbb{R}^{64\times768}$: Attention projection matrix
- $\mathbf{u}_s \in \mathbb{R}^{64}$: Learnable context vector
- α_t: Attention weight cho token t
- $\mathbf{v}$: Weighted sum representation

Linear projection

Global representation được project xuống 128 dimensions:

$$\mathbf{f}_{\text{attn}} = \text{Dropout}(\text{ReLU}(\mathbf{W}_p \mathbf{v} + \mathbf{b}_p)) \in \mathbb{R}^{128} \tag{3.11}$$

với dropout rate = 0.1.

3.4.4 Classification Head

Feature concatenation

Tất cả features được concatenate:

$$\mathbf{f}_{\text{combined}} = [\mathbf{f}_{\text{CNN}}; \mathbf{f}_{\text{attn}}] \in \mathbb{R}^{512} \tag{3.12}$$

Classification layers

$$\mathbf{h}_{\text{cls}} = \text{Dropout}(\text{ReLU}(\text{LayerNorm}(\mathbf{W}_1\mathbf{f}_{\text{combined}} + \mathbf{b}_1))) \tag{3.13}$$

$$\text{logits} = \mathbf{W}_2\mathbf{h}_{\text{cls}} + \mathbf{b}_2 \in \mathbb{R}^2 \tag{3.14}$$

với:

- $\mathbf{W}_1 \in \mathbb{R}^{256\times512}$: First linear layer
- $\mathbf{W}_2 \in \mathbb{R}^{2\times256}$: Output layer
- Dropout rate = 0.1

Output

Binary classification probabilities:

$$P(\text{virulent}|\mathbf{x}) = \text{sigmoid}(\text{logits}_1) \tag{3.15}$$

3.4.5 Tổng số tham số

Bảng 3.3: Phân bố tham số trong PhaBERT-CNN

Component	**Parameters**
DNABERT-2 backbone	117M
Multi-scale CNN (3 branches)	1.8M
Attention pooling	0.1M
Classification head	0.2M
Total	**119.1M**

Phần lớn tham số (98.2%) nằm trong DNABERT-2 backbone, trong khi task-specific layers chỉ chiếm 1.8%.

3.5 Chiến lược huấn luyện

3.5.1 Two-Phase Fine-tuning Strategy

PhaBERT-CNN sử dụng chiến lược tinh chỉnh hai giai đoạn để đảm bảo sự hội tụ ổn định và thích ứng hiệu quả của mô hình tiền huấn luyện.

Phase 1: Warm-up (1 epoch)

Mục tiêu: Khởi tạo task-specific layers tương thích với DNABERT-2 representations

Cấu hình:

- **Freeze**: DNABERT-2 backbone (117M parameters)
- **Train**: CNN branches, attention pooling, classification head (2.1M parameters)
- **Optimizer**: AdamW
- **Learning rate**: 2×10^{-3}
- **Weight decay**: 1×10^{-4}
- **Momentum**: $\beta_1 = 0.9$, $\beta_2 = 0.999$
- **LR schedule**: OneCycleLR với 30% warm-up, max_lr = 2×10^{-3}, div_factor = 5, final_div_factor = 10

Rationale:

- Task-specific layers được khởi tạo ngẫu nhiên, cần learning rate cao để học nhanh
- Freeze DNABERT-2 tránh catastrophic forgetting trong giai đoạn đầu
- Sau warm-up, task-specific layers đã học được cách xử lý DNABERT-2 embeddings

Phase 2: Full Fine-tuning (tối đa 10 epochs)

Mục tiêu: Tinh chỉnh toàn bộ mô hình với discriminative learning rates

Cấu hình:

DNABERT-2 backbone:

- Learning rate: 1×10^{-5} (conservative)
- Weight decay: 1×10^{-5}

Task-specific layers:

- Learning rate: 1×10^{-4} (10× cao hơn)
- Weight decay: 1×10^{-4}

Common settings:

- Optimizer: AdamW với $\beta_1 = 0.9$, $\beta_2 = 0.999$, $\epsilon = 10^{-6}$
- LR schedule: OneCycleLR với 10% warm-up, div_factor = 5, final_div_factor = 50
- Early stopping: Patience = 3 epochs trên validation accuracy

Rationale:

- DNABERT-2 đã học general genomic patterns, chỉ cần điều chỉnh nhẹ
- Task-specific layers cần learning rate cao hơn để học phage lifestyle-specific features
- Discriminative learning rates cân bằng giữa adaptation và preservation

3.5.2 Loss Function

Binary Cross-Entropy Loss:

$$\mathcal{L}_{\text{BCE}} = -\frac{1}{N} \sum_{i=1}^{N} [y_i \log(\hat{y}_i) + (1 - y_i) \log(1 - \hat{y}_i)] \tag{3.16}$$

với:

- $y_i \in \{0, 1\}$: True label (0 = temperate, 1 = virulent)
- $\hat{y}_i = \sigma(\text{logits}_i) \in (0, 1)$: Predicted probability
- N: Batch size

3.5.3 Training Configuration

Batch size và gradient accumulation

- **Effective batch size**: 32
- **Physical batch size**: 8 (giới hạn GPU memory)
- **Gradient accumulation steps**: 4

Mixed precision training

Sử dụng Automatic Mixed Precision (AMP) để:

- Giảm memory consumption
- Tăng tốc training $2\times$
- Duy trì numerical stability với loss scaling

Hardware

- **GPU**: NVIDIA RTX A4000 16GB
- **CPU**: 32 cores
- **RAM**: 64GB
- **Training time**: 2-3 giờ/fold (warm-up + full fine-tuning)

3.5.4 Regularization

- **Dropout**: 0.1 trong attention pooling và classification head
- **Weight decay**: AdamW với decoupled weight decay
- **Early stopping**: Dừng khi validation accuracy không cải thiện sau 3 epochs
- **Gradient clipping**: Max norm = 1.0 để tránh exploding gradients

3.5.5 Model Selection

- **Metric**: Validation accuracy
- **Strategy**: Lưu checkpoint có validation accuracy cao nhất
- **Final model**: Trung bình ensemble của 5 models từ 5 folds (optional)

3.5.6 Reproducibility

Để đảm bảo reproducibility:

- Random seed: 42 cho tất cả random number generators
- Deterministic algorithms: torch.use_deterministic_algorithms(True)
- CUDA deterministic: torch.backends.cudnn.deterministic = True
- Stratified splits: Sử dụng cùng random seed cho cross-validation

3.5.7 Tổng kết quy trình huấn luyện

Chiến lược huấn luyện này đảm bảo PhaBERT-CNN học hiệu quả từ DNABERT-2 pre-training trong khi thích ứng tốt với nhiệm vụ phân loại lối sống phage.

Thuật toán 2 PhaBERT-CNN Training Pipeline

Input: Dataset $\mathcal{D}$, pre-trained DNABERT-2
Output: Fine-tuned PhaBERT-CNN model
for each fold k in 5-fold CV **do**
    Split $\mathcal{D}$ into $\mathcal{D}_{\text{train}}^{(k)}$, $\mathcal{D}_{\text{val}}^{(k)}$, $\mathcal{D}_{\text{test}}^{(k)}$
    Apply undersampling on $\mathcal{D}_{\text{train}}^{(k)}$
    Initialize PhaBERT-CNN with pre-trained DNABERT-2
    // **Phase 1: Warm-up**
    Freeze DNABERT-2 backbone
    Train task-specific layers for 1 epoch with LR $= 2 \times 10^{-3}$
    // **Phase 2: Full Fine-tuning**
    Unfreeze all parameters
    Train with discriminative LRs (DNABERT-2: 1×10^{-5}, others: 1×10^{-4})
    Apply early stopping with patience $= 3$
    Save best model based on validation accuracy
    Evaluate on $\mathcal{D}_{\text{test}}^{(k)}$
end for
Aggregate results across 5 folds
return Best models from each fold

Chương 4

Thực nghiệm và Đánh giá

Thực nghiệm và Đánh giá

Chương 5

Kết luận

5.1 Tóm tắt nghiên cứu

Luận văn đã trình bày PhaBERT-CNN, một phương pháp học sâu lai kết hợp mô hình nền tảng genome DNABERT-2 với mạng nơ-ron tích chập đa tỷ lệ và cơ chế attention pooling để phân loại lối sống thực khuẩn thể từ các contig metagenomic. Phương pháp được thiết kế để giải quyết các thách thức chính trong phân loại phage, đặc biệt là trên các contig ngắn và trung bình (100-1200 bp) - phạm vi độ dài phổ biến nhất trong phân tích metagenomic thực tế.

5.2 Kết quả chính

PhaBERT-CNN đã đạt được các kết quả quan trọng sau:

5.2.1 Hiệu suất vượt trội trên short-medium contigs

- **Group A (100-400 bp)**: Accuracy 81.59%, cải thiện 0.91-2.67% so với các phương pháp tiên tiến
- **Group B (400-800 bp)**: Accuracy 87.91%, cải thiện 2.01-2.56%
- **Group C (800-1200 bp)**: Accuracy 90.01%, cải thiện 1.14-5.98%
- **Group D (1200-1800 bp)**: Accuracy 90.69%, cạnh tranh với PhaTYP (91.02%)

5.2.2 Cân bằng sensitivity-specificity

PhaBERT-CNN duy trì sự cân bằng tốt giữa sensitivity (82.00%-91.12%) và specificity (80.15%-90.95%) trên tất cả các nhóm độ dài, quan trọng cho ứng dụng thực tế.

5.2.3 Khắc phục hạn chế của phương pháp hiện có

- Không phụ thuộc vào gene prediction tools (khắc phục hạn chế của PhaTYP)
- Tận dụng pre-trained knowledge (vượt trội hơn DeePhage)
- Sử dụng BPE tokenization hiệu quả (cải thiện so với DNABERT/ProkBERT)
- Hybrid architecture kết hợp global context và local patterns

5.3 Đóng góp của luận văn

1. **Kiến trúc PhaBERT-CNN mới**: Kết hợp DNABERT-2, multi-scale CNN, và attention pooling
2. **Chiến lược huấn luyện hai giai đoạn**: Warm-up + full fine-tuning với discriminative learning rates
3. **Đánh giá toàn diện**: So sánh có hệ thống với 4 phương pháp tiên tiến trên 4 nhóm độ dài
4. **Phân tích chi tiết**: Insights về ưu nhược điểm của các phương pháp khác nhau

5.4 Hạn chế

- **Data imbalance handling**: Random undersampling có thể mất thông tin
- **Computational cost**: Cao hơn các phương pháp đơn giản như DeePhage
- **Validation data**: Đánh giá trên simulated contigs, chưa test trên real metagenomic data
- **Ablation studies**: Chưa phân tích chi tiết tác động của từng thành phần

5.5 Hướng nghiên cứu tương lai

5.5.1 Cải thiện phương pháp

- Thử các chiến lược xử lý class imbalance khác (SMOTE, focal loss, class weighting)
- Ablation studies chi tiết về kernel sizes, số CNN branches, attention mechanisms
- Thử các mô hình nền tảng khác (Nucleotide Transformer, HyenaDNA)
- Tối ưu hóa inference speed cho deployment thực tế

5.5.2 Mở rộng ứng dụng

- Đánh giá trên real metagenomic datasets từ các môi trường đa dạng
- Mở rộng sang các nhiệm vụ phân loại phage khác:
  - Phân loại họ phage (family classification)
  - Dự đoán vi khuẩn chủ (host prediction)
  - Phát hiện prophage trong bộ gen vi khuẩn
- Phát triển web server hoặc command-line tool cho cộng đồng

5.5.3 Nghiên cứu cơ bản

- Phân tích interpretability: Vùng nào trong genome quan trọng cho phân loại?
- Nghiên cứu transfer learning cross-domain: Áp dụng cho các virus khác
- Kết hợp với phylogenetic information để cải thiện accuracy
- Multi-task learning: Đồng thời dự đoán lifestyle, family, và host

5.6 Kết luận cuối cùng

PhaBERT-CNN đại diện cho sự tiến bộ quan trọng trong phân loại lối sống thực khuẩn thể từ dữ liệu metagenomic. Bằng cách kết hợp hiệu quả mô hình nền tảng genome tiền huấn luyện với kiến trúc chuyên biệt task-specific, PhaBERT-CNN đạt được hiệu suất vượt trội trên các contig ngắn và trung bình - phạm vi độ dài thách thức nhất trong phân tích metagenomic thực tế.

Phương pháp không chỉ cải thiện độ chính xác phân loại mà còn cung cấp một paradigm đầy hứa hẹn cho việc áp dụng genome foundation models vào các bài toán sinh tin học downstream. Kết quả nghiên cứu góp phần vào việc hiểu rõ hơn về đa dạng sinh học và vai trò sinh thái của thực khuẩn thể, đồng thời hỗ trợ các ứng dụng thực tiễn như liệu pháp phage và kiểm soát vi khuẩn trong thực phẩm và y tế.

Với những kết quả đạt được và hướng phát triển rõ ràng, PhaBERT-CNN đặt nền móng vững chắc cho các nghiên cứu tương lai trong lĩnh vực phân loại phage và phân tích metagenomic nói chung.

Tài liệu tham khảo

[1] Curtis A Suttle. Marine viruses—major players in the global ecosystem. *Nature reviews microbiology*, 5(10):801–812, 2007.

[2] Britt Koskella and Michael A Brockhurst. Bacteria–phage coevolution as a driver of ecological and evolutionary processes in microbial communities. *FEMS microbiology reviews*, 38(5):916–931, 2014.

[3] Shufang Wu, Zhencheng Fang, Jie Tan, Mo Li, Chunhui Wang, Qian Guo, Congmin Xu, Xiaoqing Jiang, and Huaiqiu Zhu. Deephage: distinguishing virulent and temperate phage-derived sequences in metavirome data with a deep learning approach. *Gigascience*, 10(9):giab056, 2021.

[4] Katelyn McNair, Barbara A Bailey, and Robert A Edwards. Phacts, a computational approach to classifying the lifestyle of phages. *Bioinformatics*, 28(5):614–618, 2012.

[5] Cristina Howard-Varona, Katherine R Hargreaves, Stephen T Abedon, and Matthew B Sullivan. Lysogeny in nature: mechanisms, impact and ecology of temperate phages. *The ISME journal*, 11(7):1511–1520, 2017.

[6] Ron Feiner, Tal Argov, Lev Rabinovich, Nadejda Sigal, Ilya Borovok, and Anat A Herskovits. A new perspective on lysogeny: prophages as active regulatory switches of bacteria. *Nature Reviews Microbiology*, 13(10):641–650, 2015.

[7] Jiayu Shang, Xubo Tang, and Yanni Sun. Phatyp: predicting the lifestyle for bacteriophages using bert. *Briefings in Bioinformatics*, 24(1):bbac487, 2023.

[8] Andrzej Gorski, Ryszard Miedzybrodzki, Beata Weber-Dabrowska, Wojciech Fortuna, Slawomir Letkiewicz, Pawel Rogoz, Ewa Jonczyk-Matysiak, Krystyna Dabrowska, Joanna Majewska, and Jan Borysowski. Phage therapy: combating infections with potential for evolving from merely a treatment for complications to targeting diseases. *Frontiers in microbiology*, 7:1515, 2016.

[9] Taher Azimi, Mehrdad Mosadegh, Mohammad Javad Nasiri, Sahar Sabour, Samira Karimaei, and Ahmad Nasser. Phage therapy as a renewed therapeutic

approach to mycobacterial infections: a comprehensive review. *Infection and Drug Resistance*, pages 2943–2959, 2019.

[10] Ana Georgina Cobián Güemes, Merry Youle, Vito Adrian Cantú, Ben Felts, James Nulton, and Forest Rohwer. Viruses as winners in the game of life. *Annual review of virology*, 3(1):197–214, 2016.

[11] John L Mokili, Forest Rohwer, and Bas E Dutilh. Metagenomics and future perspectives in virus discovery. *Current opinion in virology*, 2(1):63–77, 2012.

[12] Stephen Hayes, Jennifer Mahony, Arjen Nauta, and Douwe Van Sinderen. Metagenomic approaches to assess bacteriophages in various environmental niches. *Viruses*, 9(6):127, 2017.

[13] João C Setubal. Metagenome-assembled genomes: concepts, analogies, and challenges. *Biophysical reviews*, 13(6):905–909, 2021.

[14] Jay S Ghurye, Victoria Cepeda-Espinoza, and Mihai Pop. Metagenomic assembly: overview, challenges and applications. *The Yale journal of biology and medicine*, 89(3):353, 2016.

[15] Yuan Jiang, Jun Wang, Dawen Xia, and Guoxian Yu. Ensvmb: metagenomics fragments classification using ensemble svm and blast. *Scientific reports*, 7(1):9440, 2017.

[16] Doug Hyatt, Gwo-Liang Chen, Philip F LoCascio, Miriam L Land, Frank W Larimer, and Loren J Hauser. Prodigal: prokaryotic gene recognition and translation initiation site identification. *BMC bioinformatics*, 11(1):119, 2010.

[17] William L Trimble, Kevin P Keegan, Mark D'Souza, Andreas Wilke, Jared Wilkening, Jack Gilbert, and Folker Meyer. Short-read reading-frame predictors are not created equal: sequence error causes loss of signal. *BMC bioinformatics*, 13(1):183, 2012.

[18] Roye Rozov, Aya Brown Kav, David Bogumil, Naama Shterzer, Eran Halperin, Itzhak Mizrahi, and Ron Shamir. Recycler: an algorithm for detecting plasmids from de novo assembly graphs. *Bioinformatics*, 33(4):475–482, 2017.

[19] Zhihan Zhou, Yanrong Ji, Weijian Li, Pratik Dutta, Ramana Davuluri, and Han Liu. Dnabert-2: Efficient foundation model and benchmark for multi-species genome. *arXiv preprint arXiv:2306.15006*, 2023.

[20] Balázs Ligeti, István Szepesi-Nagy, Babett Bodnár, Noémi Ligeti-Nagy, and János Juhász. Prokbert family: genomic language models for microbiome applications. *Frontiers in Microbiology*, 14:1331233, 2024.

[21] Yujie Zhang, Mark Mao, Robert Zhang, Yen-Te Liao, and Vivian CH Wu. Deeppl: A deep-learning-based tool for the prediction of bacteriophage lifecycle. *PLOS Computational Biology*, 20(10):e1012525, 2024.

[22] Hugo Dalla-Torre, Liam Gonzalez, Javier Mendoza-Revilla, Nicolas Lopez Carranza, Adam Henryk Grzywaczewski, Francesco Oteri, Christian Dallago, Evan Trop, Bernardo P de Almeida, Hassan Sirelkhatim, et al. Nucleotide transformer: building and evaluating robust foundation models for human genomics. *Nature Methods*, 22(2):287–297, 2025.

[23] Ilya Loshchilov and Frank Hutter. Decoupled weight decay regularization. *arXiv preprint arXiv:1711.05101*, 2017.

[24] Christian Szegedy, Wei Liu, Yangqing Jia, Pierre Sermanet, Scott Reed, Dragomir Anguelov, Dumitru Erhan, Vincent Vanhoucke, and Andrew Rabinovich. Going deeper with convolutions. In *Proceedings of the IEEE conference on computer vision and pattern recognition*, pages 1–9, 2015.

[25] Yoon Kim. Convolutional neural networks for sentence classification. In *Proceedings of the 2014 Conference on Empirical Methods in Natural Language Processing (EMNLP)*, pages 1746–1751, 2014.

[26] Rie Johnson and Tong Zhang. Deep pyramid convolutional neural networks for text categorization. In *Proceedings of the 55th Annual Meeting of the Association for Computational Linguistics (Volume 1: Long Papers)*, pages 562–570, 2017.

[27] Ashish Vaswani, Noam Shazeer, Niki Parmar, Jakob Uszkoreit, Llion Jones, Aidan N Gomez, Łukasz Kaiser, and Illia Polosukhin. Attention is all you need. *Advances in neural information processing systems*, 30, 2017.

[28] Ofir Press, Noah A Smith, and Mike Lewis. Train short, test long: Attention with linear biases enables input length extrapolation. *arXiv preprint arXiv:2108.12409*, 2021.

[29] Jacob Devlin, Ming-Wei Chang, Kenton Lee, and Kristina Toutanova. Bert: Pre-training of deep bidirectional transformers for language understanding. In *Proceedings of the 2019 conference of the North American chapter of the association for computational linguistics: human language technologies, volume 1 (long and short papers)*, pages 4171–4186, 2019.

[30] Yanrong Ji, Zhihan Zhou, Han Liu, and Ramana V Davuluri. Dnabert: pre-trained bidirectional encoder representations from transformers model for dna-language in genome. *Bioinformatics*, 37(15):2112–2120, 2021.

[31] Rico Sennrich, Barry Haddow, and Alexandra Birch. Neural machine translation of rare words with subword units. *arXiv preprint arXiv:1508.07909*, 2015.

[32] Taku Kudo and John Richardson. Sentencepiece: A simple and language independent subword tokenizer and detokenizer for neural text processing. *arXiv preprint arXiv:1808.06226*, 2018.

[33] Colin Raffel, Noam Shazeer, Adam Roberts, Katherine Lee, Sharan Narang, Michael Matena, Yanqi Zhou, Wei Li, and Peter J Liu. Exploring the limits of transfer learning with a unified text-to-text transformer. *Journal of Machine Learning Research*, 21(140):1–67, 2020.

[34] Tri Dao, Dan Fu, Stefano Ermon, Atri Rudra, and Christopher Ré. Flashattention: Fast and memory-efficient exact attention with io-awareness. *Advances in neural information processing systems*, 35:16344–16359, 2022.

[35] Piotr Tynecki, Arkadiusz Guziński, Joanna Kazimierczak, Michał Jadczuk, Jarosław Dastych, and Agnieszka Onisko. Phageai-bacteriophage life cycle recognition with machine learning and natural language processing. *BioRxiv*, pages 2020–07, 2020.

[36] Adam J Hockenberry and Claus O Wilke. Bacphlip: predicting bacteriophage lifestyle from conserved protein domains. *PeerJ*, 9:e11396, 2021.