ĐẠI HỌC QUỐC GIA HÀ NỘI
TRƯỜNG ĐẠI HỌC CÔNG NGHỆ

PHÂN LOẠI LỐI SỐNG THỰC KHUẨN THỂ DỰA TRÊN PHƯƠNG PHÁP HỌC SÂU

LUẬN VĂN THẠC SĨ

Ngành: Khoa học máy tính

HÀ NỘI - 2026

ĐẠI HỌC QUỐC GIA HÀ NỘI
TRƯỜNG ĐẠI HỌC CÔNG NGHỆ

Vũ Quang Sơn

PHÂN LOẠI LỐI SỐNG THỰC KHUẨN THỂ DỰA TRÊN PHƯƠNG PHÁP HỌC SÂU

LUẬN VĂN THẠC SĨ

Ngành: Khoa học máy tính

Cán bộ hướng dẫn: TS. Điệp Thị Hoàng

HÀ NỘI - 2026

VIETNAM NATIONAL UNIVERSITY, HANOI
UNIVERSITY OF ENGINEERING AND TECHNOLOGY

Vu Quang Son

DEEP LEARNING BASED METHODS FOR PHAGE LIFESTYLE PREDICTION

MASTER'S THESIS

Major: Computer Science

Supervisor: Dr. Diep Thi Hoang

HANOI - 2026

Lời cảm ơn

Với tất cả lòng kính trọng và biết ơn sâu sắc, tôi xin gửi lời cảm ơn chân thành đến cô TS. Điệp Thị Hoàng, người thầy đã tận tình hướng dẫn, định hướng và truyền đạt tri thức quý báu trong suốt quá trình tôi thực hiện luận văn thạc sĩ. Sự hỗ trợ, những lời khuyên bảo và sự kiên nhẫn của cô là nguồn động viên to lớn giúp tôi hoàn thành nghiên cứu này.

Tôi xin trân trọng cảm ơn các thầy, cô giáo đang công tác và giảng dạy tại Khoa Công nghệ Thông tin, trường Đại học Công Nghệ - Đại học Quốc gia Hà Nội, những người đã trang bị cho tôi nền tảng kiến thức vững chắc và tạo mọi điều kiện thuận lợi để tôi được học tập và phát triển trong môi trường học thuật chuyên nghiệp.

Tôi xin gửi lời cảm ơn đến các bạn bè, đồng nghiệp đã luôn động viên, chia sẻ kinh nghiệm và hỗ trợ tôi trong suốt quá trình học tập và nghiên cứu.

Cuối cùng, tôi xin dành sự biết ơn sâu sắc nhất đến gia đình, đặc biệt là bố mẹ và người vợ yêu quý, những người đã luôn là nguồn động lực và điểm tựa tinh thần vững chắc cho tôi. Sự hy sinh, thấu hiểu và tình yêu thương vô bờ bến của gia đình là món quà vô giá, giúp tôi có thêm sức mạnh để vượt qua mọi khó khăn và hoàn thành chặng đường học tập thạc sĩ đầy thử thách này.

Tôi xin chân thành cảm ơn!

Lời cam đoan

Tôi là Vũ Quang Sơn, học viên cao học khóa 30, ngành Khoa học máy tính. Tôi xin cam đoan luận văn thạc sĩ "Phân loại lối sống thực khuẩn thể dựa trên phương pháp học sâu" là công trình nghiên cứu, xây dựng của riêng mình dưới sự hướng dẫn của cô TS. Điệp Thị Hoàng. Các nội dung nghiên cứu, kết quả trong luận văn là xác thực.

Các thông tin sử dụng trong luận văn là có cơ sở và không có nội dung nào sao chép từ các tài liệu mà không ghi rõ trích dẫn tham khảo. Tôi xin chịu trách nhiệm về lời cam đoan này.

Hà Nội, ngày ... tháng ... năm 2025

Học viên

Vũ Quang Sơn

Tóm tắt

Thực khuẩn thể (bacteriophage) là virus xâm nhiễm vi khuẩn, có tiềm năng ứng dụng trong liệu pháp phage thay thế kháng sinh. Việc phân loại chính xác lối sống của thực khuẩn thể - độc lực (virulent) hay ôn hòa (temperate) - là yêu cầu thiết yếu cho các ứng dụng trị liệu, vì chỉ phage độc lực mới an toàn để sử dụng. Các phương pháp truyền thống dựa vào nuôi cấy tốn thời gian và không áp dụng được cho phần lớn phage chưa nuôi cấy được. Các công cụ tính toán hiện có như PhaTYP và DeePhage vẫn gặp hạn chế khi xử lý các contig ngắn từ dữ liệu metagenomic.

Luận văn này đề xuất PhaBERT-CNN, một kiến trúc học sâu kết hợp mô hình nền tảng genome DNABERT-2 với mạng nơ-ron tích chập đa tỷ lệ và cơ chế attention pooling. Khác với PhaTYP phụ thuộc vào dự đoán protein, PhaBERT-CNN hoạt động trực tiếp trên chuỗi DNA thô, khắc phục hạn chế khi xử lý contig ngắn. Mô hình tận dụng biểu diễn tiền huấn luyện từ DNABERT-2, sử dụng các nhánh CNN song song với kernel sizes 3, 5, và 7 để trích xuất đặc trưng đa tỷ lệ, và áp dụng self-attention để tập trung vào các vùng genome có tính thông tin cao.

Thực nghiệm trên bốn nhóm độ dài contig (100-400 bp, 400-800 bp, 800-1200 bp, 1200-1800 bp) với 5-fold cross-validation cho thấy PhaBERT-CNN đạt accuracy 81.59%, 87.91%, 90.01%, và 90.69% tương ứng, cải thiện 0.91-5.98% so với các phương pháp tiên tiến như PhaTYP, DeePhage, và ProkBERT. Mô hình duy trì sự cân bằng tốt giữa sensitivity (82.00%-91.12%) và specificity (80.15%-90.95%) trên tất cả các phạm vi độ dài.

Kết quả nghiên cứu chứng minh hiệu quả của việc kết hợp mô hình nền tảng genome với kiến trúc chuyên biệt task-specific, cung cấp một paradigm đầy hứa hẹn cho các nhiệm vụ phân tích chuỗi sinh học, đặc biệt trong bối cảnh phân tích metagenomic với các chuỗi không hoàn chỉnh.

Từ khóa: *Thực khuẩn thể*, *Phân loại lối sống*, *Học sâu*, *BERT*, *Mạng nơ-ron tích chập*, *Sinh tin học*, *Metagenomics*

Abstract

Bacteriophages are viruses that infect bacteria, showing promise as alternatives to antibiotics in phage therapy. Accurate classification of phage lifestyle - virulent or temperate - is essential for therapeutic applications, as only virulent phages are safe for use. Traditional laboratory-based methods are time-consuming and inapplicable to the majority of unculturable phages. Existing computational tools such as PhaTYP and DeePhage still face limitations when processing short contigs from metagenomic data.

This thesis proposes PhaBERT-CNN, a novel hybrid deep learning architecture that combines the DNABERT-2 genome foundation model with multi-scale convolutional neural networks and attention pooling mechanism. Unlike PhaTYP which relies on protein prediction, PhaBERT-CNN operates directly on raw DNA sequences, overcoming limitations when processing short contigs. The model leverages pre-trained representations from DNABERT-2, uses parallel CNN branches with kernel sizes 3, 5, and 7 to extract multi-scale features, and applies self-attention mechanism to focus on highly informative genomic regions.

Experiments on four contig length groups (100-400 bp, 400-800 bp, 800-1200 bp, 1200-1800 bp) with 5-fold cross-validation demonstrate that PhaBERT-CNN achieves accuracies of 81.59%, 87.91%, 90.01%, and 90.69% respectively, improving 0.91-5.98% over state-of-the-art methods including PhaTYP, DeePhage, and ProkBERT. The model maintains a good balance between sensitivity (82.00%-91.12%) and specificity (80.15%-90.95%) across all length ranges.

The research results demonstrate the effectiveness of combining genome foundation models with task-specific architectures, providing a promising paradigm for biological sequence analysis tasks, particularly in metagenomic analysis with incomplete sequences.

Keywords: *Bacteriophage*, *Lifestyle classification*, *Deep learning*, *BERT*, *Convolutional neural networks*, *Bioinformatics*, *Metagenomics*

Mục lục

Lời cảm ơn

Lời cam đoan **i**

Tóm tắt **ii**

Abstract **iii**

Mục lục **iv**

Danh sách hình vẽ **vi**

Danh sách bảng **vii**

Danh mục các từ viết tắt và thuật ngữ **viii**

Chương 1 Giới thiệu **1**

1.1 Bối cảnh nghiên cứu 1

1.2 Vấn đề nghiên cứu 2

1.3 Mục tiêu và đóng góp 2

1.4 Phạm vi nghiên cứu 3

1.5 Bố cục luận văn 3

Chương 2 Cơ sở lý thuyết **5**

2.1 Nền tảng sinh học phân tử và tin sinh học 5

2.1.1 DNA, gen và bộ gen 5

2.1.2 Thực khuẩn thể và phân loại hệ gen 6

2.1.3 Dữ liệu metagenomics và bài toán phân loại trên contig 7

2.2 Các phương pháp tính toán cho phân loại lối sống thực khuẩn 9

2.3 Học chuyển giao trong tin sinh học 15

Chương 3 Phương pháp đề xuất **17**

3.1 Tổng quan phương pháp 17
3.2 Thu thập dữ liệu và tiền xử lý 19
3.3 Kiến trúc PhaBERT-CNN 20
3.3.1 DNABERT-2 Backbone 21
3.3.2 Mô-đun Modified TextCNN 22
3.3.3 Kết Hợp Đặc Trưng và Đầu Phân Loại 24
3.4 Chiến lược huấn luyện và tinh chỉnh 25
3.4.1 Giai Đoạn 1: Khởi Động 26
3.4.2 Giai Đoạn 2: Tinh Chỉnh Đầy Đủ 26
3.5 Kết luận 26

Chương 4 Thực nghiệm và Đánh giá 28
4.1 Thiết lập thực nghiệm 28
4.2 Tài nguyên tính toán 29
4.3 Kết quả thực nghiệm 29
4.3.1 So sánh PhaBERT-CNN và DNABERT-2 29
4.3.2 So sánh với các phương pháp tiên tiến 30
4.4 Kết luận 31

Chương 5 Kết luận 33
5.1 Kết luận 33
5.2 Thảo luận về kết quả chính 34
5.2.1 Phân tích kết quả 34
5.2.2 Đóng góp của nghiên cứu 35
5.2.3 Hạn chế và hướng phát triển tương lai 36

Tài liệu tham khảo 38

Danh sách hình vẽ

2.1 Chuỗi phân cấp lắp ráp hệ gen từ read, contig, scaffold đến bộ gen hoàn chỉnh 8

3.1 Kiến trúc chi tiết của PhaBERT-CNN 21

4.1 So sánh hiệu suất của DNABERT-2 và PhaBERT-CNN trên bốn nhóm độ dài contig 30

4.2 Hiệu suất phân loại của DeePhage, PhaTYP, ProkBERT và PhaBERT-CNN trên các nhóm A, B, C, D 32

Danh sách bảng

2.1 So sánh tổng hợp các phương pháp phân loại lối sống thực khuẩn . . 14

3.1 Thống kê số lượng contig sau augmentation (trước undersampling) . 20

4.1 So sánh hiệu suất PhaBERT-CNN, PhaTYP, DeePhage và ProkBERT theo 5-fold cross-validation trên bốn nhóm độ dài contig 31

Danh mục các từ viết tắt và thuật ngữ

STT	Từ viết tắt/ thuật ngữ	Cụm từ đầy đủ	Cụm từ tiếng Việt
1	Phage	Bacteriophage	Thực khuẩn thể
2	DNA	Deoxyribonucleic Acid	Axit deoxyribonucleic
3	BERT	Bidirectional Encoder Representations from Transformers	Biểu diễn bộ mã hóa hai chiều từ Transformer
4	CNN	Convolutional Neural Network	Mạng nơ-ron tích chập
5	DNABERT-2	DNA Bidirectional Encoder Representations from Transformers version 2	Mô hình BERT cho chuỗi DNA phiên bản 2
6	BPE	Byte Pair Encoding	Mã hóa cặp byte
7	NGS	Next-Generation Sequencing	Giải trình tự thế hệ mới
8	bp	Base pair	Cặp base
9	ORF	Open Reading Frame	Khung đọc mở
10	HMM	Hidden Markov Model	Mô hình Markov ẩn
11	SVM	Support Vector Machine	Máy vector hỗ trợ
12	RF	Random Forest	Rừng ngẫu nhiên
13	LSTM	Long Short-Term Memory	Bộ nhớ ngắn hạn dài
14	Attention	Attention Mechanism	Cơ chế chú ý
15	ReLU	Rectified Linear Unit	Đơn vị tuyến tính chỉnh lưu
16	Adam	Adaptive Moment Estimation	Ước lượng mô-men thích ứng
17	Dropout	Dropout Regularization	Kỹ thuật loại bỏ ngẫu nhiên
18	Batch Norm	Batch Normalization	Chuẩn hóa theo batch
19	Cross-entropy	Cross-entropy Loss	Hàm mất mát entropy chéo
20	Accuracy	Accuracy	Độ chính xác

21	Precision	Precision	Độ chính xác dương
22	Recall	Recall/Sensitivity	Độ nhạy
23	F1-Score	F1-Score	Điểm F1
24	Specificity	Specificity	Độ đặc hiệu
25	AUC	Area Under the Curve	Diện tích dưới đường cong
26	ROC	Receiver Operating Characteristic	Đặc tính hoạt động của bộ thu
27	Contig	Contiguous sequence	Contig (đoạn DNA liên tục)
28	Kernel	Kernel	Kích thước cửa sổ tích chập
29	Virulent phage	Virulent phage	Thực khuẩn thể độc lực
30	Temperate phage	Temperate phage	Thực khuẩn thể ôn hòa
31	Lysogenic cycle	Lysogenic cycle	Chu trình tiềm tan
32	Lytic cycle	Lytic cycle	Chu trình tan

Chương 1

Giới thiệu

1.1 Bối cảnh nghiên cứu

Thực khuẩn thể (bacteriophage), thường được gọi tắt là phage, là các virus xâm nhiễm và nhân lên bên trong tế bào vi khuẩn. Với số lượng ước tính lên tới 10^{31} cá thể [1], thực khuẩn thể là dạng sống phong phú nhất trên Trái Đất và đóng vai trò trung tâm trong việc điều hòa quần thể vi khuẩn cũng như thúc đẩy quá trình chuyển gen ngang [2]. Dựa trên chiến lược nhân lên, thực khuẩn thể được phân thành hai nhóm chính: thực khuẩn thể độc lực (virulent phage) chỉ thực hiện chu trình phân giải, và thực khuẩn thể ôn hòa (temperate phage) có khả năng tích hợp hệ gen vào nhiễm sắc thể vi khuẩn ở trạng thái prophage [3] (xem Mục 2.1.2 để biết thêm chi tiết).

Việc phân loại chính xác lối sống thực khuẩn thể có ý nghĩa quan trọng trong cả nghiên cứu vi sinh vật học lẫn ứng dụng y sinh học. Trong bối cảnh kháng kháng sinh ngày càng gia tăng, liệu pháp phage đang được xem xét như một giải pháp thay thế đầy hứa hẹn [4]; tuy nhiên, chỉ có thực khuẩn thể độc lực mới phù hợp, vì thực khuẩn thể ôn hòa tiềm ẩn nguy cơ truyền gen kháng kháng sinh sang vi khuẩn bệnh nguyên thông qua biến đổi tiềm tan [5].

Các phương pháp thực nghiệm truyền thống để xác định lối sống phage đòi hỏi nuôi cấy trong phòng thí nghiệm, tốn thời gian và không áp dụng được cho phần lớn phage chưa được phân lập trong các mẫu môi trường [6]. Với sự phát triển của công nghệ giải trình tự thế hệ mới, metagenomics đã trở thành công cụ quan trọng để nghiên cứu đa dạng sinh học phage mà không cần nuôi cấy [7]. Trong phân tích metagenomic, hệ gen phage thường được phục hồi dưới dạng các contig, các đoạn trình tự liên tục được lắp ráp từ các đoạn đọc ngắn chồng lấp, với độ dài biến thiên lớn và thường bị phân mảnh (xem Mục 2.1.3 để biết thêm chi tiết).

1.2 Vấn đề nghiên cứu

Các phương pháp tính toán để dự đoán lối sống thực khuẩn thể phải đối mặt với bốn thách thức chính. Thứ nhất, cơ sở dữ liệu hệ gen phage hiện có vẫn còn rất hạn chế so với sự đa dạng khổng lồ của phage trong tự nhiên [8]. Thứ hai, thực khuẩn thể không có gen đánh dấu phổ quát như gen 16S rRNA của vi khuẩn [7], khiến các phương pháp phân loại dựa trên gen đánh dấu không khả thi. Thứ ba, dữ liệu metagenomic thường chứa nhiều đoạn DNA ngắn, không hoàn chỉnh, làm phức tạp các chiến lược phân loại dựa trên gen chức năng [9]. Thứ tư, thực khuẩn thể có thể chia sẻ trình tự gen với vi khuẩn chủ thông qua chuyển gen ngang [10], dẫn đến phân loại sai trong quá trình gán phân loại học.

Dựa trên các thách thức trên, bài toán dự đoán lối sống thực khuẩn thể được phát biểu như sau: cho một tập hợp các contig $\mathcal{S} = \{S_1, S_2, \ldots, S_n\}$ thu được từ giải trình tự và lắp ráp metagenomic, trong đó mỗi contig S_i có độ dài L_i base pairs, nhiệm vụ là học hàm phân loại $f : \mathcal{S} \to \{0, 1\}$ trong đó 0 đại diện cho lớp temperate và 1 đại diện cho lớp virulent, sao cho f hoạt động hiệu quả trên các contig có độ dài biến thiên lớn mà không phụ thuộc vào các công cụ dự đoán gen bên ngoài.

Các phương pháp hiện có đã đạt được tiến bộ đáng kể nhưng vẫn còn những hạn chế quan trọng. Các phương pháp học máy truyền thống như PHACTS [11], PhageAI [12], và BACPHLIP [13] được thiết kế cho hệ gen hoàn chỉnh và hiệu suất giảm mạnh trên contig phân mảnh. DeePhage [14] hoạt động trực tiếp trên contig nhưng thiếu tri thức tiền huấn luyện, hạn chế khả năng tổng quát hóa. PhaTYP [6] tận dụng kiến trúc BERT song lại phụ thuộc vào công cụ dự đoán gen Prodigal [15], vốn kém hiệu quả trên các contig ngắn [16]. DeepPL [17] và ProkBERT [18] sử dụng tokenization k-mer chồng lấp, gây ra rò rỉ thông tin trong quá trình tiền huấn luyện và bị giới hạn về độ dài chuỗi đầu vào [19]. Tổng quan chi tiết về từng phương pháp được trình bày trong Mục 2.2.

1.3 Mục tiêu và đóng góp

Mục tiêu chính của luận văn là phát triển PhaBERT-CNN, một phương pháp học sâu lai kết hợp mô hình nền tảng genome DNABERT-2 [19] với mạng nơ-ron tích chập đa tỷ lệ và cơ chế attention pooling để phân loại lối sống thực khuẩn thể từ

các contig metagenomic. Phương pháp được thiết kế để hoạt động trực tiếp trên chuỗi DNA thô thông qua BPE tokenization, không phụ thuộc vào công cụ dự đoán gen, và được đánh giá toàn diện trên bốn nhóm độ dài contig thông qua stratified 5-fold cross-validation.

Luận văn đóng góp vào lĩnh vực sinh tin học thông qua bốn đóng góp chính. Thứ nhất, đề xuất kiến trúc PhaBERT-CNN mới kết hợp DNABERT-2 với hai nhánh song song: nhánh CNN đa tỷ lệ để trích xuất đặc trưng cục bộ và nhánh attention pooling để nắm bắt ngữ cảnh toàn cục. Thứ hai, phát triển phương pháp phân loại lối sống phage hoạt động trực tiếp trên chuỗi DNA thô thông qua BPE tokenization, loại bỏ sự phụ thuộc vào các công cụ dự đoán gen bên ngoài. Thứ ba, thực hiện đánh giá có hệ thống so sánh với các phương pháp tiên tiến trên bốn nhóm độ dài contig, chứng minh hiệu suất cải thiện đáng kể trên các contig ngắn và trung bình. Thứ tư, cung cấp phân tích chi tiết về ưu điểm, hạn chế, và hướng phát triển của phương pháp, đặt nền móng cho các nghiên cứu tương lai về ứng dụng genomic foundation models vào các bài toán sinh tin học downstream.

1.4 Phạm vi nghiên cứu

Luận văn tập trung vào bài toán phân loại nhị phân lối sống thực khuẩn thể (virulent/temperate) từ các contig DNA trong phạm vi độ dài 100–1800 bp, được chia thành bốn nhóm theo độ dài. Phương pháp sử dụng DNABERT-2 làm mô hình nền tảng genome và được đánh giá thông qua stratified 5-fold cross-validation với các chỉ số sensitivity, specificity, và accuracy. Các contig đầu vào được giả định đã được xác định là có nguồn gốc từ phage thông qua các công cụ nhận dạng phage; luận văn không xem xét bước nhận dạng phage từ dữ liệu metagenomic thô. Phương pháp được so sánh với các phương pháp tiên tiến gần đây để đánh giá hiệu suất trên các contig có độ dài biến thiên lớn.

1.5 Bố cục luận văn

Luận văn được tổ chức thành năm chương. **Chương 1** giới thiệu bối cảnh nghiên cứu về thực khuẩn thể, các thách thức trong phân loại lối sống phage từ dữ liệu metagenomic, mục tiêu và đóng góp chính, phạm vi nghiên cứu, và bố cục luận văn. **Chương 2** cung cấp nền tảng lý thuyết về sinh học thực khuẩn thể, metagenomics,

các kiến trúc học sâu (CNN, Transformer, BERT), mô hình DNABERT-2, và tổng quan các công trình liên quan về phân loại lối sống phage. **Chương 3** trình bày chi tiết phương pháp PhaBERT-CNN, bao gồm quy trình xây dựng dữ liệu, kiến trúc mô hình với DNABERT-2 backbone và Modified TextCNN, và chiến lược huấn luyện hai giai đoạn. **Chương 4** trình bày thiết lập thực nghiệm, kết quả so sánh PhaBERT-CNN với DNABERT-2 baseline và các phương pháp tiên tiến trên bốn nhóm độ dài contig. **Chương 5** tổng kết đóng góp của luận văn, phân tích ưu điểm và hạn chế của phương pháp, và đề xuất các hướng nghiên cứu tương lai.

Chương 2

Cơ sở lý thuyết

Chương này trình bày các kiến thức nền tảng cần thiết để hiểu phương pháp PhaBERT-CNN được đề xuất trong luận văn. Nội dung được tổ chức thành bốn phần chính: (1) các khái niệm sinh học phân tử và tin sinh học bao gồm DNA, gen, thực khuẩn thể, siêu hệ gen và siêu hệ gen virus; (2) nền tảng học máy và học sâu gồm mạng nơ-ron tích chập, Transformer, BERT và các chỉ số đánh giá hiệu năng; (3) tổng quan về học chuyển giao trong tin sinh học; và (4) tổng quan các công trình liên quan về phân loại hệ gen phage.

2.1 Nền tảng sinh học phân tử và tin sinh học

2.1.1 DNA, gen và bộ gen

Axit deoxyribonucleic (DNA) là phân tử mang thông tin di truyền của hầu hết các sinh vật sống và nhiều loại virus. Năm 1953, Watson và Crick xác định rằng DNA có cấu trúc dạng xoắn kép, bao gồm hai chuỗi polynucleotide liên kết bổ sung chạy ngược chiều nhau [20]. Mỗi nucleotide bao gồm một phân tử đường deoxyribose, một nhóm phosphate, và một trong bốn bazơ nitơ: adenine (A), thymine (T), guanine (G), và cytosine (C). Theo nguyên tắc bổ sung Chargaff, A luôn ghép cặp với T và G luôn ghép cặp với C. Trật tự sắp xếp của bốn ký tự nucleotide dọc theo chuỗi DNA mã hóa toàn bộ thông tin di truyền của sinh vật, tạo thành cơ sở cho biểu diễn chuỗi hệ gen trong tin sinh học.

Gen là đơn vị cơ bản của thông tin di truyền, một đoạn DNA mã hóa cho một sản phẩm chức năng, thông thường là protein thông qua quá trình phiên mã (DNA sang RNA) rồi dịch mã (RNA sang chuỗi axit amin). Bộ gen là toàn bộ vật liệu di truyền của một sinh vật, bao gồm tất cả các gen và các vùng DNA không mã hóa. Kích thước bộ gen biến thiên rất lớn giữa các loài: từ vài kilobase (kb) ở các virus nhỏ đến hàng tỷ cặp bazơ (bp) ở sinh vật bậc cao. Đối với thực khuẩn thể, bộ gen có thể là DNA hoặc RNA, dạng sợi đơn hoặc sợi kép, với kích thước dao động từ dưới 10 kb ở các thực khuẩn thể nhỏ đến hơn 600 kb ở một số thực khuẩn

thể lớn [21]. Đặc biệt, các nghiên cứu metagenomics gần đây đã phát hiện hàng trăm thực khuẩn thể với bộ gen vượt 200 kb, bao gồm các *huge phage* với bộ gen ghi nhận lên đến 735 kb [22]. Sự đa dạng về kích thước và thành phần nucleotide (tỷ lệ GC) của bộ gen thực khuẩn đặt ra thách thức đáng kể cho các phương pháp phân tích dựa trên thống kê thành phần chuỗi.

2.1.2 Thực khuẩn thể và phân loại hệ gen

Thực khuẩn thể (bacteriophage), hay gọi tắt là phage, là các virus có khả năng xâm nhiễm và nhân lên bên trong tế bào vi khuẩn. Thực khuẩn thể được xem là dạng thực thể sinh học phong phú nhất trên Trái Đất, với số lượng ước tính vượt 10^{30} cá thể chỉ riêng trong môi trường đại dương [1], và hiện diện ở hầu hết mọi môi trường có vi khuẩn sinh sống. Thực khuẩn thể đóng vai trò thiết yếu trong sinh thái vi sinh vật thông qua việc điều hòa quần thể vi khuẩn, đồng thời là tác nhân trung gian quan trọng trong quá trình chuyển gen ngang giữa các vi khuẩn [2].

Dựa trên chiến lược nhân lên, thực khuẩn thể được phân loại thành hai nhóm chính [11, 14]. Thực khuẩn thể độc lực chỉ thực hiện chu trình tan. Sau khi xâm nhiễm, thực khuẩn thể độc lực chiếm đoạt bộ máy tổng hợp của tế bào chủ để nhân bản hệ gen và tổng hợp các thành phần cấu trúc, lắp ráp thành các hạt virus con, rồi phá vỡ tế bào vi khuẩn để giải phóng thế hệ thực khuẩn thể mới. Thực khuẩn thể ôn hòa có khả năng thực hiện cả chu trình tan lẫn chu trình tiềm tan. Trong chu trình tiềm tan, DNA thực khuẩn được tích hợp vào nhiễm sắc thể vi khuẩn thông qua quá trình tái tổ hợp đặc hiệu vị trí được xúc tác bởi enzyme integrase, trở thành prophage. Prophage tồn tại ở trạng thái im lặng và được nhân lên cùng với hệ gen vi khuẩn qua nhiều thế hệ [3]. Khi tế bào chủ tiếp xúc với các tác nhân gây tổn thương ADN như bức xạ tử ngoại (UV), prophage có thể được cảm ứng, tách ra khỏi nhiễm sắc thể vi khuẩn và chuyển sang thực hiện chu trình tan [3].

Việc phân loại chính xác hệ gen thực khuẩn có ý nghĩa thực tiễn quan trọng trong nhiều lĩnh vực ứng dụng. Trong liệu pháp sử dụng thực khuẩn để điều trị các bệnh nhiễm khuẩn kháng kháng sinh [23], chỉ thực khuẩn thể độc lực mới được xem là phù hợp vì chúng tiêu diệt vi khuẩn hiệu quả mà không tích hợp vào hệ gen tế bào chủ [23, 24]. Ngược lại, thực khuẩn thể ôn hòa tiềm ẩn nguy cơ truyền các gen độc lực hoặc gen kháng kháng sinh sang vi khuẩn bệnh nguyên thông qua biến đổi tiềm tan [25].

Tuy nhiên, xác định hệ gen thực khuẩn bằng phương pháp thực nghiệm truyền thống đòi hỏi nuôi cấy và phân lập thực khuẩn trong phòng thí nghiệm, một quá trình tốn nhiều thời gian, chi phí cao và không khả thi với phần lớn các thực khuẩn chưa được nuôi cấy trong các mẫu môi trường [6]. Điều này thúc đẩy sự phát triển của các phương pháp tính toán để dự đoán hệ gen thực khuẩn trực tiếp từ dữ liệu di truyền, đặc biệt trong bối cảnh metagenomics nơi hệ gen thực khuẩn thường thu được dưới dạng các contig ngắn và phân mảnh.

2.1.3 Dữ liệu metagenomics và bài toán phân loại trên contig

Metagenomics (siêu hệ gen hay hệ gen môi trường) là lĩnh vực nghiên cứu vật liệu di truyền được thu thập trực tiếp từ các mẫu môi trường, cho phép phân tích toàn bộ cộng đồng vi sinh vật mà không cần nuôi cấy từng loài riêng lẻ [7]. Phương pháp này đặc biệt quan trọng vì phần lớn vi sinh vật trong tự nhiên không thể nuôi cấy trong điều kiện phòng thí nghiệm. Một nhánh chuyên biệt gọi là *viral metagenomics* (hay *metaviromics*) tập trung vào thành phần virus trong mẫu môi trường. Dữ liệu thu được từ metaviromics cung cấp cái nhìn toàn diện về sự đa dạng và phân bố của các cộng đồng phage trong nhiều hệ sinh thái khác nhau, từ đại dương, đất đến ruột người [8, 26]. Chính nhờ đó, phần lớn sự đa dạng của thực khuẩn thể trong tự nhiên mới được hé lộ, trong khi các phương pháp phân lập truyền thống chỉ tiếp cận được một phần nhỏ quần thể virus thực sự tồn tại trong môi trường [7].

Trong phân tích siêu hệ gen (metagenomics), dữ liệu thô từ giải trình tự thế hệ mới là các đoạn đọc ngắn gọi là *read*, mỗi read thường có độ dài từ vài chục đến vài trăm cặp bazơ tùy công nghệ sử dụng. Các đoạn đọc này được lắp ráp lại bằng thuật toán lắp ráp trình tự dựa trên vùng chồng lấp giữa chúng, tạo thành các đoạn trình tự dài hơn gọi là *contig* (trình tự liên tục) [27]. Contig đại diện cho một vùng liên tục của bộ gen được tái tạo từ dữ liệu trình tự, song thường chưa đầy đủ do độ phủ không đồng đều, các vùng lặp lại, hoặc sai số kỹ thuật. Ở mức độ lắp ráp cao hơn, các contig được sắp xếp và định hướng tương đối với nhau dựa trên thông tin đọc ghép đôi đầu (paired-end reads) hoặc đọc dài (long reads), tạo thành *scaffold*; khoảng cách giữa các contig trong scaffold thường được điền bằng ký tự "N" để biểu thị vùng trình tự chưa xác định [28]. Chuỗi phân cấp từ đoạn đọc, contig, scaffold đến bộ gen hoàn chỉnh phản ánh mức độ đầy đủ ngày càng

tăng của dữ liệu trình tự thu được (Hình 2.1).

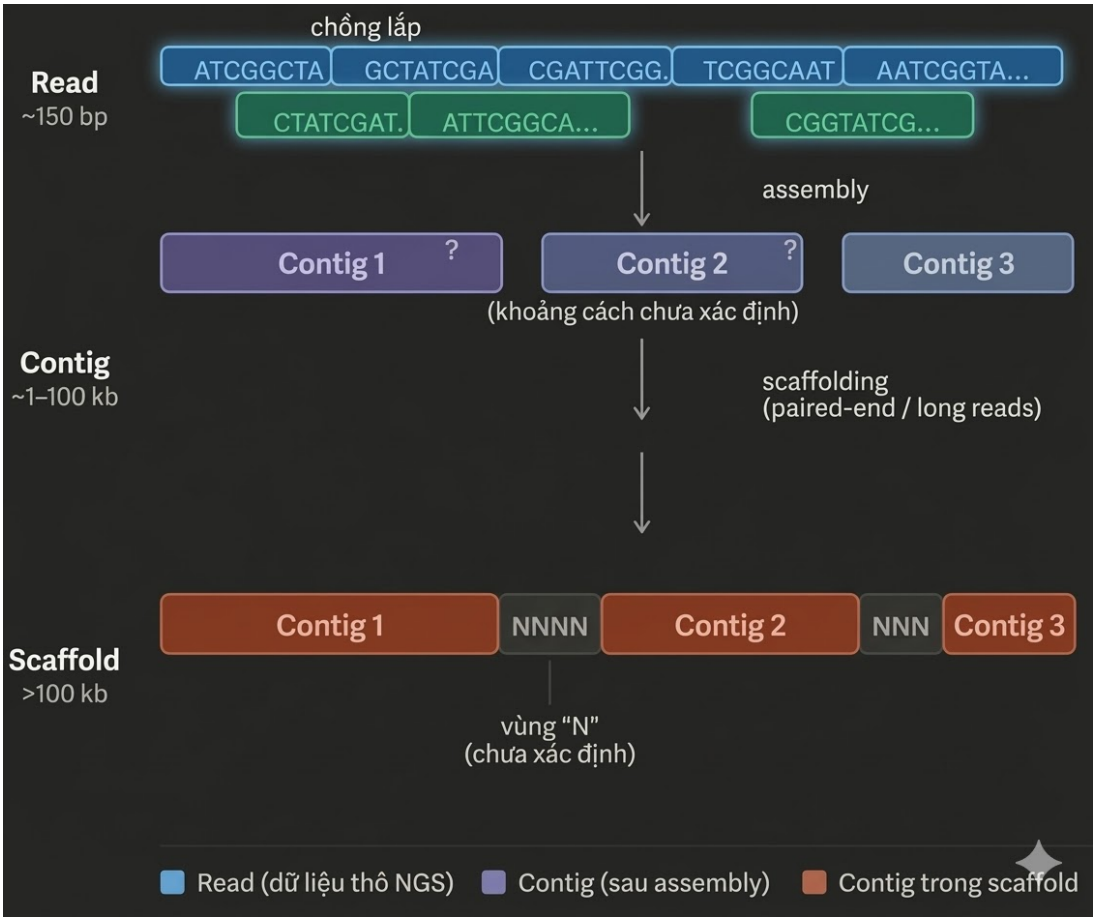

Hình 2.1: Chuỗi phân cấp lắp ráp hệ gen từ read, contig, scaffold đến bộ gen hoàn chỉnh

Trong bối cảnh dự đoán hệ gen thực khuẩn thể, phần lớn dữ liệu đầu vào thực tế tồn tại ở dạng contig, các đoạn bộ gen không hoàn chỉnh với độ dài và mức độ đại diện rất khác nhau. Để đánh giá hiệu năng trên các contig có độ dài điển hình trong dữ liệu metavirome, các nghiên cứu DeePhage [14] và PhaTYP [6] đã thống nhất sử dụng bốn nhóm độ dài: Nhóm A (100–400 bp), Nhóm B (400–800 bp), Nhóm C (800–1200 bp), và Nhóm D (1200–1800 bp). Nhóm A bao phủ độ dài điển hình của các read thô từ giải trình tự Illumina (thường 75–300 bp); Nhóm B–C bao phủ phần lớn contig ngắn thường gặp sau lắp ráp; và Nhóm D đại diện cho các contig trung bình vẫn còn phân mảnh so với bộ gen phage hoàn chỉnh (thường 15–200 kb). Nghiên cứu này kế thừa cùng phân chia nhóm độ dài để đảm bảo khả năng so sánh trực tiếp với các phương pháp tiền nhiệm.

Các contig ngắn, đặc biệt dưới 400 bp, đặt ra thách thức đặc biệt cho phân loại bởi chúng thường không chứa gen hoàn chỉnh, khiến các công cụ dự đoán gen như

Prodigal hoặc các công cụ tương đương giảm độ chính xác đáng kể trên các đoạn DNA ngắn có chứa lỗi giải trình tự [16]. Đây là một trong những động lực chính cho việc phát triển các phương pháp học sâu hoạt động trực tiếp trên chuỗi DNA thô thay vì dựa vào đặc trưng protein, điển hình như mô hình PhaBERT-CNN được đề xuất trong luận văn này.

2.2 Các phương pháp tính toán cho phân loại lối sống thực khuẩn

Nhận thức được tầm quan trọng của bài toán phân loại lối sống thực khuẩn, nhiều phương pháp tính toán đã được phát triển, từ các kỹ thuật học máy truyền thống đến các mô hình học sâu hiện đại và các mô hình nền tảng hệ gen. Phần này trình bày tổng quan các công trình liên quan, tổ chức theo sự phát triển của phương pháp luận: từ học máy truyền thống dựa trên đặc trưng thủ công, đến học sâu với khả năng tự động học biểu diễn, và cuối cùng là các mô hình nền tảng tận dụng học chuyển giao từ kho ngữ liệu hệ gen quy mô lớn.

Các phương pháp học máy truyền thống

Các phương pháp học máy truyền thống như PHACTS [11], PhageAI [12], và BACPHLIP [13] đạt hiệu năng cao trên bộ gen thực khuẩn hoàn chỉnh, với độ chính xác thường vượt 90%. Tuy nhiên, các phương pháp này được thiết kế và tối ưu hóa cho bộ gen hoàn chỉnh, do đó gặp khó khăn đáng kể khi áp dụng cho dữ liệu contig phân mảnh từ metagenomics.

PHACTS [11] sử dụng thuật toán Random Forest kết hợp với đặc trưng tương đồng protein. Phương pháp mã hóa dữ liệu của PHACTS gồm hai bước: (1) tạo tập protein chuẩn có chú thích lối sống, và (2) mã hóa proteome của thực khuẩn cần phân loại thành vector tương đồng thông qua công cụ FASTA35, so sánh với tập protein chuẩn, sau đó nối các vector tương đồng này để tạo vector mã hóa cuối cùng. PHACTS đạt độ chính xác cao trên bộ gen hoàn chỉnh (xấp xỉ 90%), nhưng hiệu năng giảm mạnh trên contig ngắn—chỉ đạt khoảng 50% độ chính xác trên các đoạn contig trong khoảng 100–1800 bp [14], tương đương với dự đoán ngẫu nhiên. Nguyên nhân là các contig ngắn thiếu vùng mã hóa protein hoàn chỉnh để tạo tín hiệu tương đồng đủ tin cậy.

PhageAI [12] ứng dụng kỹ thuật xử lý ngôn ngữ tự nhiên cho dữ liệu di truyền, sử dụng phân tách k-mer để chuyển đổi chuỗi DNA thành định dạng văn bản, sau đó áp dụng Word2Vec để tạo biểu diễn embedding đặc trưng. Nguồn dữ liệu của PhageAI là bộ gen thực khuẩn hoàn chỉnh. Phương pháp này sử dụng Recursive Feature Elimination with Cross-Validation (RFECV) để loại bỏ các đặc trưng dư thừa, chỉ giữ lại những đặc trưng có ảnh hưởng đáng kể đến hiệu năng phân loại. Thuật toán máy vector hỗ trợ (Support Vector Machine — SVM) được sử dụng cho phân loại và cho kết quả tốt nhất. PhageAI đạt độ chính xác cao trên bộ gen hoàn chỉnh, tuy nhiên bị hạn chế trên contig ngắn do tín hiệu ngữ cảnh không đủ để Word2Vec học được biểu diễn có ý nghĩa.

BACPHLIP [13] khai thác sự hiện diện của các protein bảo tồn liên quan đến chu kỳ tiềm tan. Nguồn dữ liệu là bộ gen thực khuẩn hoàn chỉnh. Phương pháp mã hóa của BACPHLIP gồm hai bước: (1) nhận diện các vùng protein bảo tồn thông qua công cụ HMMER3, và (2) tạo vector đặc trưng nhị phân biểu diễn sự hiện diện của các vùng bảo tồn này. Thuật toán Random Forest được sử dụng cho phân loại và cho hiệu năng cạnh tranh. Tuy nhiên, sự khan hiếm dữ liệu về các vùng protein bảo tồn gây khó khăn cho ứng dụng thực tế. Theo khuyến nghị của tác giả, BACPHLIP chỉ phù hợp với bộ gen hoàn chỉnh và trả về kết quả lỗi khi nhận đầu vào là contig phân mảnh [6].

Các phương pháp học sâu

Sự phát triển của công nghệ tính toán song song đã cho phép phát triển và công bố các mô hình học sâu tinh vi như DeePhage [14], PhaTYP [6], DeepPL [17], và ProkBERT [18]. Các tiến bộ công nghệ này dẫn đến cải thiện dần hiệu năng phân loại, đặc biệt trên dữ liệu contig phân mảnh, làm cho phân loại thực khuẩn bằng tính toán ngày càng khả thi cho các ứng dụng thực tế.

DeePhage [14] là phương pháp học sâu đầu tiên được đề xuất cho bài toán phân loại lối sống phage trên dữ liệu metagenomics. Nguồn dữ liệu của DeePhage là các contig metagenomic với độ dài từ 100 đến 1800 bp, được chia thành bốn nhóm: Nhóm A (100–400 bp), Nhóm B (400–800 bp), Nhóm C (800–1200 bp), và Nhóm D (1200–1800 bp). Phương pháp phân tách token của DeePhage là mã hóa one-hot trực tiếp trên chuỗi DNA thô, trong đó mỗi nucleotide được mã hóa thành vector nhị phân 4 chiều: A = [0,0,0,1], C = [0,0,1,0], G = [0,1,0,0], T = [1,0,0,0]. Thuật

toán sử dụng là mạng nơ-ron tích chập (CNN) được huấn luyện từ đầu (from scratch) mà không sử dụng huấn luyện trước. DeePhage không phụ thuộc vào dự đoán gen, có khả năng xử lý contig ngắn, đạt độ chính xác kiểm định chéo 5 lần lên đến 89%—vượt trội so với PHACTS và PhagePred lần lượt khoảng 30% và 10%—đồng thời nhanh hơn 810 lần về thời gian tính toán so với PHACTS [14]. Bộ chuẩn đánh giá gồm bốn nhóm độ dài contig A–D do DeePhage thiết lập cũng được sử dụng rộng rãi trong các nghiên cứu tiếp theo. Hạn chế chính của DeePhage là mô hình được huấn luyện từ đầu mà không tận dụng được tri thức hệ gen tổng quát từ kho ngữ liệu lớn, và mã hóa one-hot tạo ra biểu diễn thưa (sparse) không mang thông tin ngữ nghĩa.

PhaTYP [6] là phương pháp đầu tiên ứng dụng kiến trúc BERT cho bài toán phân loại lối sống phage. Nguồn dữ liệu của PhaTYP là bộ gen thực khuẩn hoàn chỉnh và contig. Phương pháp phân tách token của PhaTYP hoạt động ở cấp độ protein: genome thực khuẩn được dịch mã thành các protein thông qua công cụ dự đoán gen Prodigal [15], sau đó các protein đồng nhất được nhóm lại thành các cluster, mỗi cluster được coi là một token. Mỗi genome thực khuẩn được coi là một "câu" gồm các token là protein cluster. Thuật toán sử dụng là BERT (Transformer encoder) được huấn luyện trước bằng học tự giám sát trên chuỗi protein, sau đó tinh chỉnh cho tác vụ phân loại lối sống. PhaTYP đạt hiệu năng mạnh trên contig dài, đặc biệt là Nhóm D (1200–1800 bp) với 92.29% độ nhạy, 89.75% độ đặc hiệu, và 91.02% độ chính xác. Tuy nhiên, PhaTYP phụ thuộc vào bước dự đoán gen trung gian—Prodigal vốn có hiệu suất giảm mạnh trên các đoạn DNA ngắn hơn 200 bp [16]—dẫn đến hạn chế đáng kể trên contig ngắn và phân mảnh [6].

DeepPL [17] sử dụng DNABERT [29] để mã hóa chuỗi DNA cho phân loại lối sống phage. Nguồn dữ liệu là các contig metagenomic. Phương pháp phân tách token của DeepPL là k-mer có chồng lấp (overlapping k-mer), thường với $k = 6$, trong đó các token liền kề chia sẻ $k - 1$ nucleotide. Thuật toán sử dụng là DNABERT, một mô hình BERT được huấn luyện trước trên hệ gen người. DeepPL không phụ thuộc vào dự đoán gen, hoạt động trực tiếp trên chuỗi DNA. Tuy nhiên, DeepPL kế thừa hạn chế của DNABERT gốc về giới hạn độ dài chuỗi tối đa 512 token do sử dụng biểu diễn vị trí học được (learned positional embedding) [29]—tương đương khoảng 500 bp với $k = 6$. Do hạn chế này, DeepPL không thể xử lý contig dài hơn trong bộ chuẩn của nghiên cứu (lên đến 1800 bp) và do đó bị loại khỏi so sánh

trực tiếp. Ngoài ra, phân tách k-mer có chồng lấp gây ra hiện tượng rò rỉ thông tin trong quá trình học có mặt nạ và kém hiệu quả tính toán do số token xấp xỉ độ dài chuỗi gốc.

ProkBERT [18] là họ mô hình ngôn ngữ hệ gen vi sinh. Nguồn dữ liệu huấn luyện trước là hệ gen vi khuẩn đa loài. Phương pháp phân tách token của ProkBERT sử dụng cơ chế nhận thức ngữ cảnh cục bộ (Local Context-Aware — LCA)—một biến thể k-mer có chồng lấp với độ dịch chuyển điều chỉnh được, cho phép mở rộng ngữ cảnh mà không làm tăng đáng kể chi phí tính toán. Thuật toán sử dụng là BERT được huấn luyện trước trên kho ngữ liệu hệ gen vi sinh đa loài. ProkBERT đạt hiệu năng trung bình trên bộ chuẩn phân loại phage, với độ chính xác dao động từ 80.68% đến 85.35%. Đáng chú ý, khác với các phương pháp khác có xu hướng cải thiện đều đặn khi độ dài contig tăng, ProkBERT cho thấy hiện tượng trì trệ hiệu năng trên contig dài hơn, với độ chính xác đạt đỉnh 85.35% ở Nhóm B rồi giảm xuống khoảng 84% ở Nhóm C và D. Mẫu hiệu năng này gợi ý những hạn chế tiềm ẩn trong khả năng nắm bắt phụ thuộc dài hạn hoặc các mẫu chuỗi phức tạp có trong các đoạn hệ gen mở rộng. Do vẫn dựa trên k-mer có chồng lấp, LCA tokenization tiềm ẩn hiện tượng rò rỉ thông tin trong giai đoạn tiền huấn luyện tương tự DNABERT gốc [18, 29].

Các mô hình nền tảng hệ gen

Sự phát triển của các mô hình nền tảng hệ gen (genomic foundation models) đánh dấu bước tiến quan trọng trong phân tích chuỗi sinh học, cho phép tận dụng tri thức từ kho ngữ liệu hệ gen quy mô lớn thông qua học chuyển giao.

DNABERT [29] là mô hình nền tảng đầu tiên áp dụng kiến trúc BERT cho phân tích chuỗi DNA. Nguồn dữ liệu huấn luyện trước là hệ gen người. Phương pháp phân tách token của DNABERT là k-mer có chồng lấp, thường với $k = 6$, trong đó chuỗi DNA được chia thành các đoạn con liên tiếp độ dài k, các token liền kề chia sẻ $k - 1$ nucleotide. Thuật toán sử dụng là BERT được huấn luyện trước với mục tiêu mô hình hóa ngôn ngữ có mặt nạ (masked language modeling) trên hệ gen người. DNABERT gặp ba hạn chế chính [19]: (1) rò rỉ thông tin—do các token liền kề chia sẻ $k-1$ nucleotide, mô hình có thể suy luận được nội dung của token bị che từ các token xung quanh, làm giảm hiệu quả học; (2) kém hiệu quả tính toán—số token xấp xỉ độ dài chuỗi gốc ($L - k + 1 \approx L$), dẫn đến chi phí tính toán cao; (3)

giới hạn độ dài cứng 512 token do sử dụng biểu diễn vị trí học được, không thể ngoại suy sang chuỗi dài hơn.

DNABERT-2 [19] là mô hình nền tảng hệ gen đa loài thế hệ mới, khắc phục các hạn chế của DNABERT thông qua ba cải tiến kiến trúc chính. Nguồn dữ liệu huấn luyện trước là kho ngữ liệu hệ gen đa loài bao gồm nhiều sinh vật khác nhau, với độ dài chuỗi trung bình khoảng 700 cặp bazơ. Phương pháp phân tách token của DNABERT-2 là Byte Pair Encoding (BPE) [30] thông qua bộ khung SentencePiece [31]. BPE xây dựng từ điển 4.096 token bằng cách lặp lại việc ghép các cặp ký tự liền kề xuất hiện thường xuyên nhất trong kho ngữ liệu, tạo ra các token có độ dài thay đổi với độ dài trung bình khoảng 5 nucleotide, giảm độ dài chuỗi khoảng 5 lần so với DNABERT. BPE loại bỏ hoàn toàn rò rỉ thông tin vì các token không chồng lấp nhau, mỗi nucleotide chỉ thuộc về một token duy nhất. Ngoài ra, BPE biến đổi mô hình hóa ngôn ngữ có mặt nạ thành bài toán dự đoán đoạn (span prediction)—mô hình cần dự đoán cả số lượng nucleotide lẫn danh tính của chúng trong token bị che, được chứng minh giúp tăng hiệu quả học [19, 32].

Thuật toán của DNABERT-2 là BERT với các cải tiến kiến trúc: (1) mã hóa vị trí ALiBi (Attention with Linear Biases) [33] thay thế biểu diễn vị trí học được, cho phép xử lý chuỗi có độ dài tùy ý mà không cần huấn luyện lại; (2) tích hợp Flash Attention [34] giúp giảm tiêu thụ bộ nhớ và tăng tốc huấn luyện, làm cho mô hình hiệu quả hơn 3 lần so với DNABERT trong khi chỉ sử dụng một phần ba số FLOPs mặc dù có nhiều hơn 30% tham số. DNABERT-2 được huấn luyện trước với mục tiêu mô hình hóa ngôn ngữ có mặt nạ trên kho ngữ liệu đa loài.

Trên bộ chuẩn Genome Understanding Evaluation (GUE)—một tập dữ liệu toàn diện gồm 36 tác vụ thuộc 9 danh mục phân tích hệ gen với chuỗi có độ dài từ 70 đến 10.000 bp—DNABERT-2 đạt hiệu năng tương đương mô hình Nucleotide Transformer 2,5 tỉ tham số [35] trong khi nhỏ hơn 21 lần và yêu cầu ít hơn khoảng 92 lần thời gian GPU trong quá trình huấn luyện trước. DNABERT-2 vượt trội DNABERT trên 23 trong số 28 tập dữ liệu thuộc bộ chuẩn GUE. Mô hình thể hiện hiệu năng ổn định trên các độ dài chuỗi khác nhau, xử lý hiệu quả các đầu vào ngắn hơn 10 lần hoặc dài hơn 15 lần so với những gì gặp trong quá trình huấn luyện trước.

So sánh tổng hợp các phương pháp

Bảng 2.1 tổng hợp so sánh các phương pháp phân loại lối sống thực khuẩn theo các tiêu chí chính: nguồn dữ liệu, phương pháp phân tách token, thuật toán áp dụng, huấn luyện trước, và hiệu năng trên contig ngắn.

Bảng 2.1: So sánh tổng hợp các phương pháp phân loại lối sống thực khuẩn

Phương pháp	Nguồn dữ liệu	Phân tách token	Thuật toán	Huấn luyện trước	Contig ngắn
PHACTS [11]	Bộ gen hoàn chỉnh	Vector tương đồng protein	Random Forest	Không	Yếu (∼50%)
PhageAI [12]	Bộ gen hoàn chỉnh	Word2Vec (k-mer)	SVM	Có	Trung bình
BACPHLIP [13]	Bộ gen hoàn chỉnh	Miền protein bảo tồn	Random Forest	Không	Yếu (lỗi)
DeePhage [14]	Contig (100–1800 bp)	Mã hóa one-hot	CNN	Không	Trung bình (89%)
PhaTYP [6]	Bộ gen và contig	Protein cluster	BERT	Có	Yếu (<200 bp)
DeepPL [17]	Contig	k-mer có chồng lấp	DNABERT	Có	Bị loại (≤500 bp)
ProkBERT [18]	Hệ gen vi sinh	LCA k-mer	BERT	Có	Trung bình (trì trệ)
PhaBERT-CNN	**Contig (100–1800 bp)**	**BPE**	**DNABERT-2 + CNN**	**Có**	**Tốt**

Khoảng trống nghiên cứu và động lực

Qua tổng quan các công trình liên quan, có thể xác định bốn khoảng trống nghiên cứu chính cần giải quyết trong phân loại lối sống thực khuẩn từ dữ liệu metagenomics:

(1) Sự phụ thuộc vào dự đoán gen. PhaTYP [6] phụ thuộc vào Prodigal [15] để phát hiện protein, dẫn đến thất bại trên contig ngắn vì các công cụ dự đoán gen có hiệu suất giảm mạnh trên các đoạn DNA ngắn hơn 200 bp [16]. Các contig ngắn thường không chứa gen hoàn chỉnh, khiến phương pháp dựa trên protein không khả thi.

(2) Rò rỉ thông tin từ phân tách k-mer có chồng lấp. DNABERT [29], DeepPL [17], và ProkBERT [18] sử dụng phân tách k-mer có chồng lấp, trong đó các token liền kề chia sẻ $k-1$ nucleotide. Điều này gây ra rò rỉ thông tin trong quá trình học có mặt nạ—mô hình có thể suy luận được nội dung của token bị che từ các token xung quanh—làm giảm hiệu quả học [19].

(3) Giới hạn độ dài chuỗi. DeepPL [17] kế thừa giới hạn 512 token của DNABERT gốc do sử dụng biểu diễn vị trí học được, tương đương khoảng 500 bp với $k = 6$. Giới hạn này khiến DeepPL không thể xử lý contig dài hơn trong bộ chuẩn (lên đến 1800 bp).

(4) Thiếu tri thức huấn luyện trước. DeePhage [14] được huấn luyện từ đầu

mà không tận dụng tri thức hệ gen từ huấn luyện trước trên kho ngữ liệu lớn. Điều này hạn chế khả năng tổng quát hóa của mô hình, đặc biệt khi phân tích các chuỗi không hoàn chỉnh với thông tin ngữ cảnh hạn chế.

PhaBERT-CNN được đề xuất nhằm giải quyết đồng thời cả bốn khoảng trống này: (1) hoạt động trực tiếp trên chuỗi DNA thô không cần dự đoán gen, (2) sử dụng DNABERT-2 với phân tách BPE loại bỏ rò rỉ thông tin, (3) tận dụng mã hóa vị trí ALiBi cho phép xử lý chuỗi có độ dài tùy ý, và (4) khai thác tri thức hệ gen từ huấn luyện trước đa loài của DNABERT-2 thông qua học chuyển giao. Ngoài ra, PhaBERT-CNN kết hợp kiến trúc CNN đa tỷ lệ để trích xuất đặc trưng cục bộ từ biểu diễn DNABERT-2 và cơ chế gộp chú ý để tổng hợp thông tin toàn cục, tạo ra một giải pháp toàn diện cho phân loại lối sống phage trên dữ liệu metagenomics.

2.3 Học chuyển giao trong tin sinh học

Học chuyển giao (transfer learning) là mô hình học máy trong đó tri thức thu được từ việc huấn luyện trên tác vụ hoặc kho ngữ liệu nguồn được tái sử dụng để cải thiện hiệu năng trên tác vụ mục tiêu với ít dữ liệu có nhãn hơn [36, 37]. Trong bối cảnh deep learning hiện đại, điều này thường được hiện thực hóa qua paradigm huấn luyện trước–tinh chỉnh (pretrain–fine-tune): mô hình được huấn luyện trước trên corpus lớn không nhãn, sau đó tinh chỉnh cho tác vụ cụ thể [38, 39].

Có ba chiến lược tinh chỉnh chính. Trích xuất đặc trưng (feature extraction) đóng băng toàn bộ mạng nền (backbone) và chỉ huấn luyện các lớp đặc thù tác vụ, bảo toàn hoàn toàn tri thức huấn luyện trước nhưng hạn chế khả năng thích nghi. Tinh chỉnh toàn bộ (full fine-tuning) cập nhật toàn bộ tham số, cho phép thích nghi tối đa nhưng có nguy cơ quá khớp (overfitting) khi dữ liệu có nhãn ít. Tinh chỉnh phân biệt (discriminative fine-tuning) [39] áp dụng tốc độ học khác nhau cho các nhóm tham số—tốc độ học thấp cho mạng nền để bảo toàn tri thức huấn luyện trước, tốc độ học cao hơn cho các lớp đặc thù tác vụ để thích nghi nhanh. Chiến lược này cân bằng giữa bảo toàn tri thức tổng quát và thích nghi đặc thù của bài toán.

Một thách thức quan trọng là quên thảm khốc (catastrophic forgetting)—hiện tượng mô hình quên tri thức đã học trong huấn luyện trước khi tinh chỉnh quá mạnh trên tác vụ cụ thể. Để giảm thiểu, các kỹ thuật như tốc độ học phân biệt,

mở khóa dần dần (gradual unfreezing, dần mở khóa các lớp từ trên xuống dưới) và chính quy hóa (regularization: giảm trọng số, dropout) thường được kết hợp [39].

Chương 3

Phương pháp đề xuất

Chương này trình bày chi tiết phương pháp PhaBERT-CNN được đề xuất để dự đoán lối sống thực khuẩn thể từ các contig metagenomic. Phương pháp kết hợp mô hình nền tảng genome DNABERT-2 với kiến trúc chuyên biệt task-specific bao gồm mạng nơ-ron tích chập đa tỷ lệ và cơ chế attention pooling. Chương được tổ chức thành các phần chính: Phần 3.1 giới thiệu tổng quan về phương pháp PhaBERT-CNN, bao gồm động lực thiết kế và quy trình xử lý tổng thể từ đầu vào DNA sequence đến đầu ra dự đoán lifestyle; Phần 3.2 mô tả quy trình thu thập và tiền xử lý dữ liệu, bao gồm nguồn dữ liệu, phương pháp tạo contig bằng sliding window, data augmentation với reverse complement, và xử lý class imbalance; Phần 3.3 trình bày chi tiết kiến trúc PhaBERT-CNN với ba thành phần chính (DNABERT-2 backbone, nhánh song song kép với multi-scale CNN và attention-based pooling, đầu phân loại).

3.1 Tổng quan phương pháp

Các phương pháp hiện có cho dự đoán lối sống thực khuẩn thể gặp phải những hạn chế quan trọng khi áp dụng trên dữ liệu di truyền được thu thập từ các mẫu trong môi trường. Các phương pháp học máy truyền thống như PHACTS[11], PhageAI[12], và BACPHLIP[13] yêu cầu dữ liệu di truyền đầy đủ và phụ thuộc vào việc nhận diện các protein bảo tồn, dẫn đến hiệu suất giảm mạnh trên các đoạn dữ liệu di truyền ngắn. Các phương pháp học sâu gần đây như DeePhage[14] sử dụng phương pháp mã hóa one-hot đạt độ chính xác 78.07–89.09% trên các contig 100–1800 bp nhưng không tận dụng được các mô hình tiền huấn luyện. PhaTYP[6] cải thiện hiệu suất lên 91.02% nhưng phụ thuộc vào công cụ phát hiện protein (Prodigal[15]), dẫn đến hiệu suất giảm đáng kể trên các contig ngắn. DeepPL[17] sử dụng DNABERT với 6-mer có chồng lấp đạt độ chính xác 94.65%, tuy nhiên các phương pháp k-mer chồng lấn gặp phải vấn đề rò rỉ thông tin và kém hiệu quả về mặt tính toán.

Để giải quyết các hạn chế trên, học viên đề xuất PhaBERT-CNN, một phương pháp học sâu kết hợp mô hình nền tảng DNABERT-2[19] kết hợp với kiến trúc Modified TextCNN. Phương pháp được thiết kế với bốn ưu điểm chính: (1) **Độc lập với công cụ phát hiện gene**—hoạt động trực tiếp trên chuỗi DNA đầu vào thông qua BPE tokenization, không phụ thuộc vào công cụ phát hiện gene, cho phép dự đoán chính xác ngay cả trên các contig ngắn thiếu vùng mã hóa protein hoàn chỉnh; (2) **Khắc phục rò rỉ thông tin**—BPE tokenization tạo ra các token con không chồng lấn với độ dài biến đổi, giảm độ dài chuỗi khoảng 5 lần và loại bỏ hoàn toàn tình trạng lộ lọt thông tin vốn có trong các phương pháp k-mer chồng lấn; (3) **Tận dụng đặc trưng di truyền tiền huấn luyện**—DNABERT-2 đã được tiền huấn luyện trên kho dữ liệu di truyền đa loài, cho phép mô hình nắm bắt các đặc trưng phức tạp mà không cần dữ liệu huấn luyện quy mô lớn cho tác vụ cụ thể.

Hình 3.1 minh họa quy trình xử lý tổng thể của PhaBERT-CNN, bao gồm bốn giai đoạn chính. Đầu tiên, chuỗi DNA đầu vào được nén bởi BPE. Tiếp theo, DNABERT-2 chuyển đổi chuỗi token thành các biểu diễn 768 chiều cho mỗi vị trí. Các biểu diễn này sau đó được xử lý bởi Modified TextCNN, được điều chỉnh từ kiến trúc TextCNN [40] với các nhánh tích chập song song có kích thước kernel khác nhau để trích xuất đa dạng các đặc trưng cục bộ; trong khi nhánh Attention Pooling [41] tổng hợp thông tin toàn cục có trọng số. Cuối cùng, đầu ra của Modified TextCNN đưa vào lớp phân loại để tạo ra dự đoán là thực khuẩn thể độc lực hay thực khuẩn thể ôn hòa. Chi tiết kiến trúc của PhaBERT-CNN được trình bày trong Phần 3.3.

Về chiến lược huấn luyện, PhaBERT-CNN áp dụng quy trình hai giai đoạn nhằm tận dụng tối đa tri thức tiền huấn luyện của DNABERT-2 trong khi tránh hiện tượng quên tri thức tiền huấn luyện. Trong giai đoạn khởi động, toàn bộ tham số của DNABERT-2 được đóng băng và chỉ các lớp cho tác vụ phía sau được huấn luyện, giúp khởi tạo ổn định các thành phần mới trước khi tinh chỉnh toàn bộ mô hình. Giai đoạn tiếp theo mở khóa backbone và áp dụng tốc độ học phân biệt, tốc độ học thấp hơn cho DNABERT-2 và cao hơn cho các lớp tác vụ phía sau, để bảo toàn tri thức tiền huấn luyện của DNABERT-2 trong khi thích nghi với tác vụ phân loại lối sống. Chi tiết chiến lược huấn luyện được trình bày trong Phần 3.4.

3.2 Thu thập dữ liệu và tiền xử lý

Tập dữ liệu huấn luyện được xây dựng bằng cách tích hợp và tinh chỉnh các bộ hệ gen từ hai nghiên cứu trước về phân loại lối sống thực khuẩn thể. DeePhage [14] cung cấp tập dữ liệu gồm 2 phần, phần 1 là tập được kiểm duyệt thủ công được xác minh qua đối chiếu tài liệu thực nghiệm, phần 2 là dữ liệu thu thập được từ NCBI, sử dụng phương pháp tin sinh học của Mavrich và Hatfull [42] để gán nhãn. DeepPL [17] tiếp đó thực hiện tinh chỉnh và thu thập thêm dữ liệu từ NCBI. Sau khi tổng hợp, tập dữ liệu kết hợp bao gồm 2,241 hệ gen phage hoàn chỉnh, trong đó 707 phage thuộc lớp temperate (nhãn 0) và 1,534 phage thuộc lớp virulent (nhãn 1). Tỷ lệ nhãn 1:0 là $\approx$ 2:1 cho thấy sự mất cân bằng nhẹ và cần được xử lý trong quá trình huấn luyện. Để đảm bảo kết quả đánh giá, học viên sử dụng stratified 5-fold cross-validation với tỷ lệ dữ liệu trong tập huấn luyện và kiểm thử là 8:2 trong mỗi fold, đảm bảo phân phối lớp được duy trì nhất quán qua các lần chia.

Quy trình tiền xử lý dữ liệu bao gồm ba bước liên tiếp: tạo contig bằng cửa sổ trượt, tăng cường dữ liệu với đảo ngược chuỗi, và xử lý mất cân bằng dữ liệu với phương pháp Random Sampling. Bước 1, học viên tạo contig bằng phương pháp cửa sổ trượt. Trong thực tế, dữ liệu thực khuẩn thu được từ metagenomic thường ở dạng các đoạn DNA ngắn không hoàn chỉnh. Để mô phỏng kịch bản này, học viên tạo contig từ bộ gen thực khuẩn hoàn chỉnh bằng phương pháp cửa sổ trượt: với mỗi hệ gen, độ dài cửa sổ được lấy mẫu ngẫu nhiên từ phân phối chuẩn $\mathcal{N}(\mu_{\text{group}}, \sigma^2_{\text{group}})$ và được giới hạn trong phạm vi của nhóm tương ứng; vị trí bắt đầu của cửa sổ tiếp theo được tính bằng $\text{pos} \leftarrow \text{pos} + \text{length} \times (1 - \text{overlap_ratio}_{\text{group}})$, tạo ra sự chồng lấn có kiểm soát giữa các contig liên tiếp. Học viên chia contig thành bốn nhóm độ dài A (100–400 bp), B (400–800 bp), C (800–1200 bp), và D (1200–1800 bp) với tham số được trình bày trong Bảng **??**. Overlap ratio tăng dần theo độ dài nhóm: nhóm ngắn (A) dùng overlap thấp để tránh tạo quá nhiều contig tương tự và giảm dư thừa, trong khi nhóm dài (D) dùng overlap cao hơn để tăng số lượng mẫu và đa dạng hóa dữ liệu, đặc biệt quan trọng vì contig dài tự nhiên ít hơn. Bước 2, học viên thực hiện tăng cường dữ liệu với đảo ngược chuỗi bổ sung. DNA có cấu trúc sợi đôi, trong đó cả hai hướng đọc đều mang thông tin sinh học tương đương. Tận dụng đặc tính này, với mỗi contig học viên tạo thêm chuỗi đảo ngược với quy tắc

bổ sung: $A \leftrightarrow T$, $C \leftrightarrow G$. Nếu trong chuỗi có U thì sẽ xử lý như là với T. Ví dụ:

Chuỗi gốc:	ATCGATCG
Chuỗi bổ sung:	TAGCTAGC
Đảo ngược bổ sung:	CGATCGAT

Phép biến đổi này tăng gấp đôi kích thước bộ dữ liệu mà không cần thu thập thêm dữ liệu, đồng thời giúp mô hình học được tính bất biến theo hướng đọc, phản ánh thực tế dữ liệu có thể đến từ cả hai sợi của DNA. Bước 3, học viên xử lý mất cân bằng dữ liệu bằng Random Undersampling. Sau khi thực hiện tăng cường dữ liệu, số lượng contig của 2 lớp bị chênh lệch lớn ảnh hưởng tới quá trình huấn luyện. Để giải quyết vấn đề này, học viên áp dụng phương pháp Random Undersampling trên tập huấn luyện: giữ nguyên toàn bộ mẫu của lớp thiểu số (temperate) và ngẫu nhiên chọn số lượng mẫu tương đương từ lớp đa số (virulent), tạo ra tập huấn luyện cân bằng với tỷ lệ 1:1. Phương pháp này được chọn vì đơn giản, hiệu quả, và phù hợp lượng contig được sinh ra sau khi thực hiện bước 1 và 2. Quan trọng là Random Undersampling chỉ được áp dụng trên tập huấn luyện; tập kiểm định giữ nguyên phân phối gốc để đánh giá hiệu suất trên phân phối thực tế. Bảng 3.1 tổng hợp thống kê số lượng contig sau tăng cường dữ liệu (trước Random Undersampling).

Bảng 3.1: Thống kê số lượng contig sau augmentation (trước undersampling)

Nhóm	**Temperate**	**Virulent**	**Total**	**Ratio (V:T)**
A (100–400 bp)	**TODO**	**TODO**	**TODO**	**TODO**
B (400–800 bp)	**TODO**	**TODO**	**TODO**	**TODO**
C (800–1200 bp)	**TODO**	**TODO**	**TODO**	**TODO**
D (1200–1800 bp)	**TODO**	**TODO**	**TODO**	**TODO**

3.3 Kiến trúc PhaBERT-CNN

Kiến trúc PhaBERT-CNN được xây dựng từ ba thành phần chính hoạt động tuần tự: (1) DNABERT-2 backbone đóng vai trò trích xuất đặc trưng ngữ cảnh từ chuỗi DNA, (2) Mô đun Modified TextCNN tiếp tục xử lý các biểu diễn đầu ra của DNABERT-2 và (3) bộ phân loại đưa ra dự đoán nhị phân. Hình 3.1 minh họa kiến trúc tổng thể của mô hình.

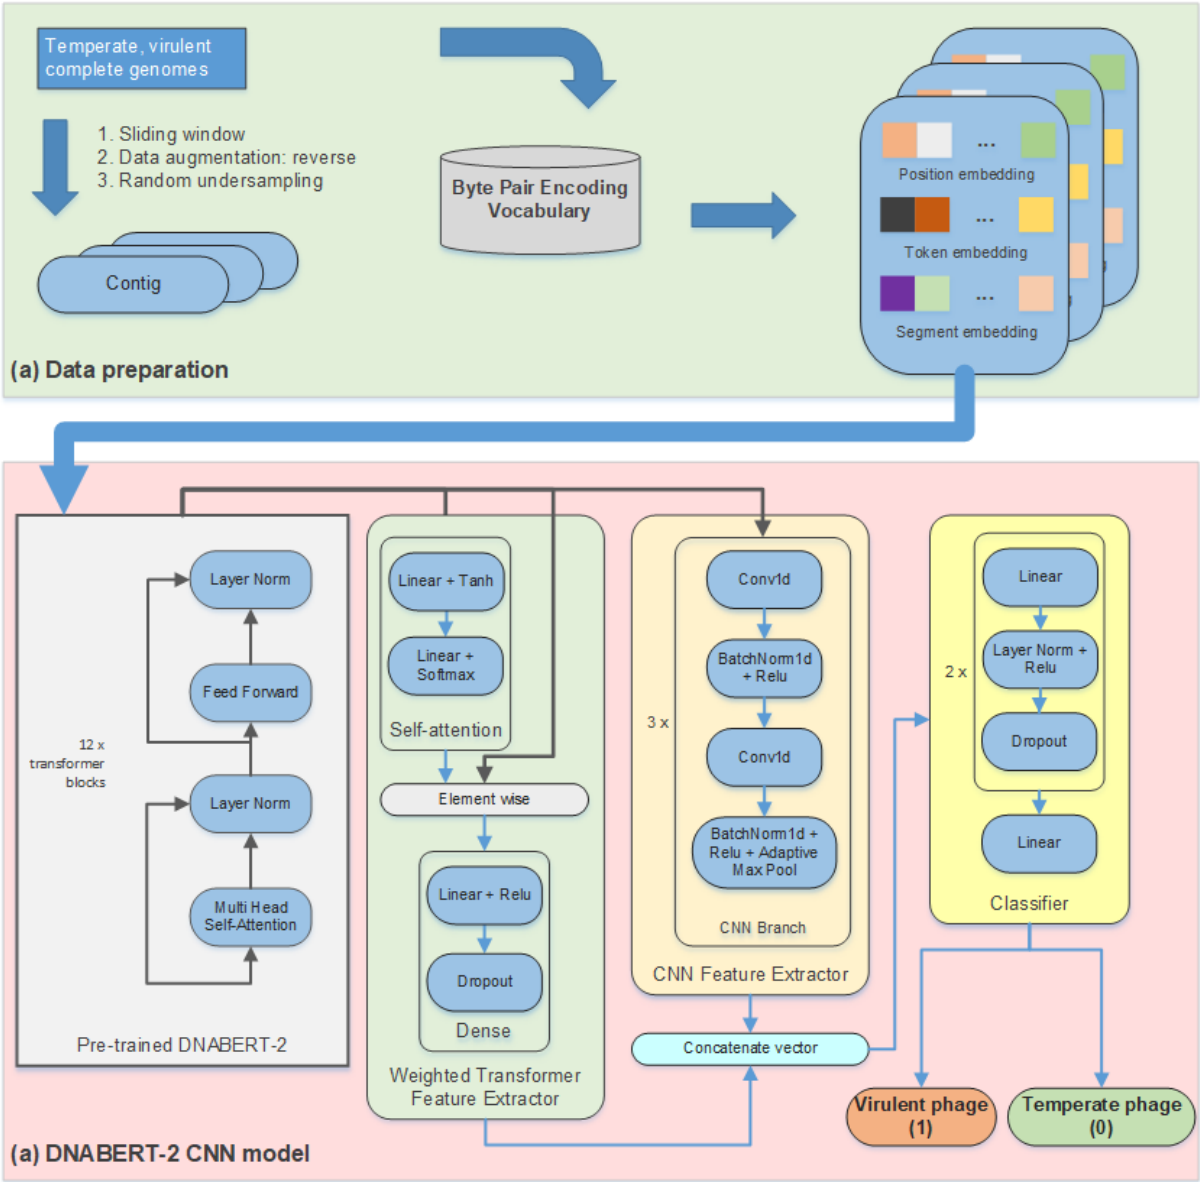

Hình 3.1: Kiến trúc chi tiết của PhaBERT-CNN

3.3.1 DNABERT-2 Backbone

DNABERT-2 [19] đóng vai trò là backbone trích xuất đặc trưng, chuyển đổi chuỗi DNA thô thành các véc-tơ 768 chiều. Chuỗi DNA đầu vào $S = \{s_1, s_2, \ldots, s_L\}$ với độ dài L cặp ba-zơ trước tiên được tokenize bằng Byte Pair Encoding (BPE)[30]:

$$T = \text{BPE}(S) = \{t_1, t_2, \ldots, t_n\}, \quad n \approx L/5 \tag{3.1}$$

BPE tạo ra các token con không chồng lấn với độ dài biến đổi, giúp giảm độ dài chuỗi token khoảng 5 lần so với phương pháp k-mer truyền thống [19]. Cách tiếp

cận này không chỉ cải thiện đáng kể hiệu quả tính toán mà còn loại bỏ hiện tượng rò rỉ thông tin vốn có trong các phương pháp k-mer chồng lấn, nơi các token liền kề chia sẻ $k-1$ nucleotide và vô tình tiết lộ thông tin về các vị trí bị che. Chuỗi token T thu được sau đó được đưa qua DNABERT-2 để tạo ra các biểu diễn ngữ cảnh:

$$\mathbf{H} = \text{DNABERT-2}(T) = \{\mathbf{h}_1, \mathbf{h}_2, \ldots, \mathbf{h}_n\}, \quad \mathbf{h}_i \in \mathbb{R}^{768} \tag{3.2}$$

trong đó mỗi vector $\mathbf{h}_i$ mã hóa thông tin của token tương ứng cùng mối quan hệ ngữ cảnh với các token xung quanh thông qua cơ chế tự chú ý. DNABERT-2 sử dụng Attention with Linear Biases (ALiBi) [33] thay vì sử dụng biểu diễn vị trí cố định, cho phép mô hình xử lý các chuỗi có độ dài tùy ý mà không cần huấn luyện lại, đặc biệt quan trọng cho dữ liệu metagenomic với độ biến thiên độ dài lớn. Trong giai đoạn khởi động, toàn bộ tham số của DNABERT-2 được đóng băng; trong giai đoạn tinh chỉnh, mô hình nền DNABERT-2 được mở khóa và cập nhật với tốc độ học thấp để bảo toàn tri thức tiền huấn luyện.

3.3.2 Mô-đun Modified TextCNN

Từ các biểu diễn ngữ cảnh $\mathbf{H} = \{\mathbf{h}_1, \ldots, \mathbf{h}_n\} \in \mathbb{R}^{n \times 768}$ được trích xuất bởi DNABERT-2, mô-đun Modified TextCNN được thiết kế với hai nhánh song song có chức năng bổ trợ nhau: nhánh CNN đa kernel thực hiện trích xuất đặc trưng cục bộ đa tỷ lệ, trong khi nhánh Attention Pooling tổng hợp thông tin ngữ cảnh toàn cục thông qua cơ chế gán trọng số thích nghi theo tầm quan trọng của từng vị trí chuỗi.

Nhánh CNN đa cửa sổ

Nhánh CNN đa kernel được điều chỉnh từ kiến trúc TextCNN [40], vốn được đề xuất cho bài toán phân loại văn bản với các bộ lọc tích chập song song có kích thước khác nhau. So với kiến trúc gốc áp dụng trực tiếp lên biểu diễn từ tĩnh, thiết kế trong nghiên cứu này thực hiện hai điều chỉnh chính: (1) thay thế đầu vào bằng các biểu diễn ngữ cảnh 768 chiều từ DNABERT-2, tận dụng tri thức tiền huấn luyện trên dữ liệu đa loài thay vì embedding ngẫu nhiên; (2) bổ sung một lớp tích chập xếp chồng cho mỗi nhánh con, tạo thành hai lớp Conv1d liên tiếp nhằm tăng cường khả năng trích xuất đặc trưng phân cấp từ các biểu diễn học

được [43]. Thiết kế đa kernel song song kế thừa từ TextCNN [40] cho phép mô hình đồng thời trích xuất các đặc trưng ở nhiều tỷ lệ không gian khác nhau trong một lần forward pass, thay vì phải chọn một kích thước cửa sổ cố định.

Cụ thể, nhánh này sử dụng ba nhánh con tích chập song song với kích thước cửa sổ $k \in \{3, 5, 7\}$. Mỗi nhánh con nhận đầu vào là ma trận $\mathbf{H}^T \in \mathbb{R}^{768 \times n}$ (chuyển vị để phù hợp với định dạng Conv1d) và xử lý qua hai lớp tích chập xếp chồng với padding tương ứng $\lfloor k/2 \rfloor$ nhằm bảo toàn chiều dài chuỗi:

$$\mathbf{X}_1^{(k)} = \mathrm{ReLU}\big(\mathrm{BN}\big(\mathrm{Conv1d}_{k,\,768\to256}(\mathbf{H}^T)\big)\big) \in \mathbb{R}^{256 \times n} \tag{3.3}$$

$$\mathbf{X}_2^{(k)} = \mathrm{ReLU}\Big(\mathrm{BN}\Big(\mathrm{Conv1d}_{k,\,256\to128}(\mathbf{X}_1^{(k)})\Big)\Big) \in \mathbb{R}^{128 \times n} \tag{3.4}$$

$$\mathbf{f}^{(k)} = \mathrm{AdaptiveMaxPool1d}(\mathbf{X}_2^{(k)}) \in \mathbb{R}^{128} \tag{3.5}$$

trong đó BN ký hiệu cho BatchNorm1d. Lớp tích chập thứ nhất giảm chiều từ 768 xuống 256 kênh; lớp thứ hai nén tiếp xuống 128 kênh. BatchNorm1d và ReLU được áp dụng sau mỗi lớp tích chập nhằm ổn định quá trình huấn luyện. AdaptiveMaxPool1d trích xuất đặc trưng nổi bật nhất theo chiều chuỗi, tạo ra vector đặc trưng cố định 128 chiều bất kể độ dài contig đầu vào.

Ba kích thước kernel được lựa chọn để nắm bắt các mẫu ngữ nghĩa ở các tỷ lệ không gian khác nhau trên không gian biểu diễn của DNABERT-2. Kernel kích thước 3 tập trung vào các tương quan cục bộ giữa các token lân cận. Kernel kích thước 5 nắm bắt các mẫu tầm trung trải dài qua nhiều token hơn. Kernel kích thước 7 tổng hợp thông tin từ vùng ngữ cảnh rộng hơn trong không gian embedding. Cần lưu ý rằng do đầu vào của mô-đun CNN là các vector biểu diễn ngữ cảnh từ DNABERT-2 chứ không phải chuỗi nucleotide thô, kích thước kernel phản ánh phạm vi tương tác trong không gian đặc trưng học được, không tương ứng trực tiếp với số lượng nucleotide. Ba vector đặc trưng từ các nhánh con được ghép nối tạo thành biểu diễn CNN tổng hợp:

$$\mathbf{f}_{\mathrm{CNN}} = \Big[\mathbf{f}^{(3)};\, \mathbf{f}^{(5)};\, \mathbf{f}^{(7)}\Big] \in \mathbb{R}^{384} \tag{3.6}$$

Nhánh Attention Pooling toàn cục

Nhánh thứ hai áp dụng cơ chế Attention Pooling [41] để tổng hợp thông tin mức chuỗi từ các biểu diễn được sinh ra từ DNABERT-2, tự động gán trọng số phản ánh tầm quan trọng của từng vị trí trên chuỗi. Cho tập hidden states $\mathbf{H} = \{\mathbf{h}_1, \ldots, \mathbf{h}_n\}$ từ DNABERT-2, điểm chú ý cho mỗi vị trí t được tính qua hai lớp tuyến tính liên tiếp:

$$\mathbf{e}_t = \tanh(\mathbf{W}_a \mathbf{h}_t + \mathbf{b}_a), \quad \mathbf{e}_t \in \mathbb{R}^{64} \tag{3.7}$$

$$s_t = \mathbf{w}_s^T \mathbf{e}_t + b_s, \quad s_t \in \mathbb{R} \tag{3.8}$$

$$\alpha_t = \frac{\exp(s_t)}{\sum_{t'=1}^{n} \exp(s_{t'})}, \quad \alpha_t \in [0, 1], \ \sum_{t=1}^{n} \alpha_t = 1 \tag{3.9}$$

trong đó $\mathbf{W}_a \in \mathbb{R}^{64\times768}$, $\mathbf{b}_a \in \mathbb{R}^{64}$ là tham số của lớp chiếu ẩn, và $\mathbf{w}_s \in \mathbb{R}^{64}$, $b_s \in \mathbb{R}$ là tham số của lớp tính điểm scalar. Biểu diễn chuỗi toàn cục được tổng hợp bằng tổng có trọng số chú ý:

$$\mathbf{v} = \sum_{t=1}^{n} \alpha_t \mathbf{h}_t \in \mathbb{R}^{768} \tag{3.10}$$

Biểu diễn tổng hợp $\mathbf{v}$ sau đó được chiếu tuyến tính xuống không gian đặc trưng compact:

$$\mathbf{f}_{\text{attn}} = \text{Dropout}(\text{ReLU}(\mathbf{W}_p \mathbf{v} + \mathbf{b}_p)) \in \mathbb{R}^{128} \tag{3.11}$$

trong đó $\mathbf{W}_p \in \mathbb{R}^{128\times768}$, $\mathbf{b}_p \in \mathbb{R}^{128}$, và tỷ lệ dropout bằng 0.1. So với các phương pháp tổng hợp thông thường như max pooling hay average pooling, attention pooling mang lại ưu điểm về trọng số thích nghi—cơ chế chú ý học cách phân bổ trọng số dựa trên ngữ cảnh chuỗi thay vì xử lý đồng đều mọi vị trí, giúp mô hình tập trung vào các vùng biểu diễn quan trọng nhất cho tác vụ phân loại.

3.3.3 Kết Hợp Đặc Trưng và Đầu Phân Loại

Đầu ra từ cả hai nhánh được ghép nối để tạo biểu diễn tổng hợp:

$$\mathbf{f}_{\text{combined}} = [\mathbf{f}_{\text{attn}}; \mathbf{f}_{\text{CNN}}] = [\mathbf{f}_{\text{attn}}; \mathbf{f}^{(3)}; \mathbf{f}^{(5)}; \mathbf{f}^{(7)}] \in \mathbb{R}^{512} \tag{3.12}$$

Vector 512 chiều này kết hợp cả ngữ cảnh toàn cục từ nhánh attention (128 chiều) và đặc trưng cục bộ đa tỷ lệ từ các nhánh CNN (384 chiều). Biểu diễn tổng hợp được đưa qua đầu phân loại gồm ba lớp tuyến tính với kích thước giảm dần $512 \to 256 \to 64 \to 2$:

$$\mathbf{z}_1 = \text{Dropout}(\text{ReLU}(\text{LayerNorm}(\mathbf{W}_1\mathbf{f}_{\text{combined}} + \mathbf{b}_1))), \quad \mathbf{z}_1 \in \mathbb{R}^{256} \tag{3.13}$$

$$\mathbf{z}_2 = \text{Dropout}(\text{ReLU}(\mathbf{W}_2\mathbf{z}_1 + \mathbf{b}_2)), \quad \mathbf{z}_2 \in \mathbb{R}^{64} \tag{3.14}$$

$$\mathbf{z}_3 = \mathbf{W}_3\mathbf{z}_2 + \mathbf{b}_3 \in \mathbb{R}^2 \tag{3.15}$$

trong đó $\mathbf{W}_1 \in \mathbb{R}^{256\times512}$, $\mathbf{W}_2 \in \mathbb{R}^{64\times256}$, $\mathbf{W}_3 \in \mathbb{R}^{2\times64}$ là các ma trận trọng số, và dropout rate $= 0.1$ được áp dụng sau mỗi lớp ẩn để regularization. Layer Normalization sau lớp đầu tiên ổn định quá trình huấn luyện. Logit nhị phân $\mathbf{z}_3 = [z_{\text{temp}}, z_{\text{vir}}]$ được chuyển thành xác suất qua softmax:

$$P(\text{virulent}|S) = \frac{\exp(z_{\text{vir}})}{\exp(z_{\text{temp}}) + \exp(z_{\text{vir}})} \tag{3.16}$$

Dự đoán cuối cùng là $\hat{y} = \text{argmax}(\text{softmax}(\mathbf{z}_3))$, trong đó $\hat{y} = 0$ tương ứng với thực khuẩn thể ôn hòa (temperate) và $\hat{y} = 1$ tương ứng với thực khuẩn thể độc lực (virulent).

3.4 Chiến lược huấn luyện và tinh chỉnh

Việc tinh chỉnh một mô hình tiền huấn luyện với các lớp đặc thù cho tác vụ được khởi tạo ngẫu nhiên có thể gây ra bất ổn định trong quá trình huấn luyện do sự không tương thích gradient giữa các trọng số tiền huấn luyện và các trọng số ngẫu nhiên. Để giải quyết vấn đề này, học viên áp dụng chiến lược tinh chỉnh hai giai đoạn: giai đoạn khởi động khởi tạo tham số cho các lớp thuộc Modified TextCNN trước, sau đó giai đoạn tinh chỉnh toàn bộ mô hình với tốc độ học phân biệt tối ưu hóa toàn bộ kiến trúc.

3.4.1 Giai Đoạn 1: Khởi Động

Trong giai đoạn khởi động, toàn bộ tham số của DNABERT-2 (117M tham số) được đóng băng, chỉ các lớp thuộc Modified TextCNN được huấn luyện trong 1 epoch. Mục đích của giai đoạn này là cho phép các lớp được khởi tạo ngẫu nhiên học được cấu hình tham số phù hợp với các biểu diễn DNABERT-2 đã đóng băng trước khi thực hiện bất kỳ cập nhật nào lên các trọng số tiền huấn luyện. Việc đóng băng mô hình nền ngăn chặn các gradient lớn từ các lớp ngẫu nhiên lan truyền ngược qua DNABERT-2, bảo toàn tri thức genomic đã học.

3.4.2 Giai Đoạn 2: Tinh Chỉnh Đầy Đủ

Sau giai đoạn khởi động, toàn bộ kiến trúc được mở khóa và tối ưu hóa với tốc độ học phân biệt—chiến lược áp dụng tốc độ học khác nhau cho các thành phần khác nhau của mô hình [39]. Cụ thể, các tham số DNABERT-2 được cập nhật với tốc độ học thấp để cho phép thích nghi nhẹ nhàng với tác vụ phân loại thực khuẩn thể mà không làm mất các tri thức học trong quá trình tiền huấn luyện. Trong khi đó, các lớp đặc thù cho tác vụ (CNN, attention, lớp phân loại) nhận tốc độ học cao hơn để cho phép tối ưu hóa tích cực hơn nhằm nắm bắt các đặc trưng đặc thù của lối sống thực khuẩn.

3.5 Kết luận

Chương này đã trình bày phương pháp PhaBERT-CNN qua bốn phần chính. Phần 3.2 mô tả quy trình xây dựng tập dữ liệu từ 2,241 hệ gen phage hoàn chỉnh thông qua sliding window contig generation, tăng cường dữ liệu bằng reverse complement, và cân bằng lớp bằng Random Undersampling. Phần 3.3 trình bày kiến trúc PhaBERT-CNN với DNABERT-2 làm backbone trích xuất biểu diễn ngữ cảnh, tiếp theo là mô đun Modified TextCNN gồm nhánh CNN đa tỷ lệ ($k \in \{3, 5, 7\}$) và nhánh attention pooling xử lý song song, tạo ra biểu diễn tổng hợp 512 chiều đưa qua đầu phân loại. Phần 3.4 mô tả chiến lược huấn luyện hai giai đoạn: khởi động với backbone đóng băng để ổn định các lớp đặc thù cho tác vụ, sau đó tinh chỉnh đầy đủ với tốc độ học phân biệt để bảo toàn tri thức tiền huấn luyện trong khi thích nghi với tác vụ phân loại lối sống. Chương tiếp theo trình bày kết quả thực

nghiệm đánh giá hiệu suất của PhaBERT-CNN so với các phương pháp tiên tiến trên bốn nhóm độ dài contig.

Chương 4

Thực nghiệm và Đánh giá

Chương này trình bày các thực nghiệm được thực hiện để đánh giá hiệu suất của PhaBERT-CNN trong bài toán phân loại lối sống thực khuẩn thể. Quy trình xây dựng tập dữ liệu, kiến trúc mô hình và chiến lược huấn luyện đã được mô tả chi tiết trong Chương 3; chương này tập trung vào đánh giá thực nghiệm, so sánh với các phương pháp tiên tiến, và phân tích hiệu quả của phương pháp đề xuất. Phần 4.1 mô tả thiết kế thực nghiệm bao gồm cấu trúc tập dữ liệu, các phương pháp baseline được so sánh, và các chỉ số đánh giá được sử dụng. Phần 4.2 trình bày chi tiết về môi trường phần cứng và phần mềm phục vụ cho quá trình huấn luyện và đánh giá mô hình. Phần 4.3 trình bày kết quả thực nghiệm trên bốn nhóm độ dài contig khác nhau, bao gồm so sánh trực tiếp với DNABERT-2 baseline và so sánh toàn diện với các phương pháp tiên tiến. Cuối cùng, Phần 4.4 tổng kết các kết quả chính và đóng góp của chương.

4.1 Thiết lập thực nghiệm

Tập dữ liệu được xây dựng theo quy trình mô tả trong Phần 3.2, bao gồm 2,241 hệ gen thực khuẩn hoàn chỉnh được chia thành bốn nhóm độ dài contig A (100–400 bp), B (400–800 bp), C (800–1200 bp), và D (1200–1800 bp), với đánh giá theo stratified 5-fold cross-validation.

PhaBERT-CNN được so sánh với bốn phương pháp: DNABERT-2 [19] với đầu phân loại tuyến tính đơn giản (dense head) đóng vai trò baseline trực tiếp để đánh giá đóng góp của kiến trúc CNN và attention pooling; DeePhage [14], phương pháp học sâu sớm sử dụng CNN trên mã hóa one-hot; PhaTYP [6], phương pháp dựa trên BERT với protein features được trích xuất bởi Prodigal [15]; và ProkBERT [18], mô hình BERT tiền huấn luyện trên genome prokaryote với tokenization LCA. DeepPL [17] bị loại khỏi so sánh do DNABERT nền tảng của nó sử dụng positional embeddings học được với giới hạn tối đa 512 bp, không phù hợp để đánh giá trên các contig lên đến 1800 bp trong thiết kế thực nghiệm này.

Hiệu suất được đánh giá bằng ba chỉ số nhất quán với các nghiên cứu trước [6, 14]: sensitivity ($sn = TP/(TP + FN)$) đo khả năng phát hiện đúng thực khuẩn thể độc lực, specificity ($sp = TN/(TN + FP)$) đo khả năng phát hiện đúng thực khuẩn thể ôn hòa, và accuracy ($acc = (TP + TN)/(TP + FN + TN + FP)$) đo hiệu suất phân loại tổng thể.

4.2 Tài nguyên tính toán

Tất cả các thực nghiệm được thực hiện trên môi trường phần cứng bao gồm GPU NVIDIA RTX 5070Ti, CPU Intel i5 13500, và 64GB RAM. Môi trường phần mềm sử dụng Python 3.10 làm ngôn ngữ lập trình chính, kết hợp với PyTorch 2.1.0 và CUDA 12.1 cho việc huấn luyện mô hình học sâu trên GPU. Thư viện Transformers phiên bản 4.28.0 từ Hugging Face được sử dụng để tải và tinh chỉnh mô hình DNABERT-2 tiền huấn luyện. Ngoài ra, các thư viện hỗ trợ bao gồm NumPy 1.26.4 cho xử lý mảng số, Pandas 2.2.3 cho thao tác dữ liệu dạng bảng, Scikit-learn 1.6.1 cho các phương pháp học máy baseline và đánh giá mô hình, BioPython 1.85 cho xử lý chuỗi sinh học, và Matplotlib 3.9.4 cùng Seaborn 0.13.2 cho trực quan hóa kết quả.

4.3 Kết quả thực nghiệm

4.3.1 So sánh PhaBERT-CNN và DNABERT-2

Để đánh giá đóng góp của kiến trúc task-specific, học viên so sánh trực tiếp PhaBERT-CNN với DNABERT-2 baseline trên cả bốn nhóm độ dài. Hình 4.1 minh họa kết quả so sánh này.

PhaBERT-CNN vượt trội DNABERT-2 nhất quán trên tất cả các nhóm độ dài. Ở Nhóm A, cả hai mô hình đạt accuracy tương đương (DNABERT-2: 81.52%, PhaBERT-CNN: 81.59%), nhưng PhaBERT-CNN cải thiện đáng kể về specificity (80.15% so với 73.25% của DNABERT-2, tức tăng 6.90%) với mức đánh đổi sensitivity không đáng kể. Cải thiện về accuracy tăng dần theo độ dài contig: Nhóm B và C đạt mức tăng lần lượt 2.35% và 2.76%, trong khi Nhóm D ghi nhận cải thiện rõ rệt nhất với 3.43% về accuracy và 5.20% về specificity. Kết quả này cho thấy thành phần CNN trích xuất hiệu quả các mẫu cục bộ và phụ thuộc tầm xa đặc

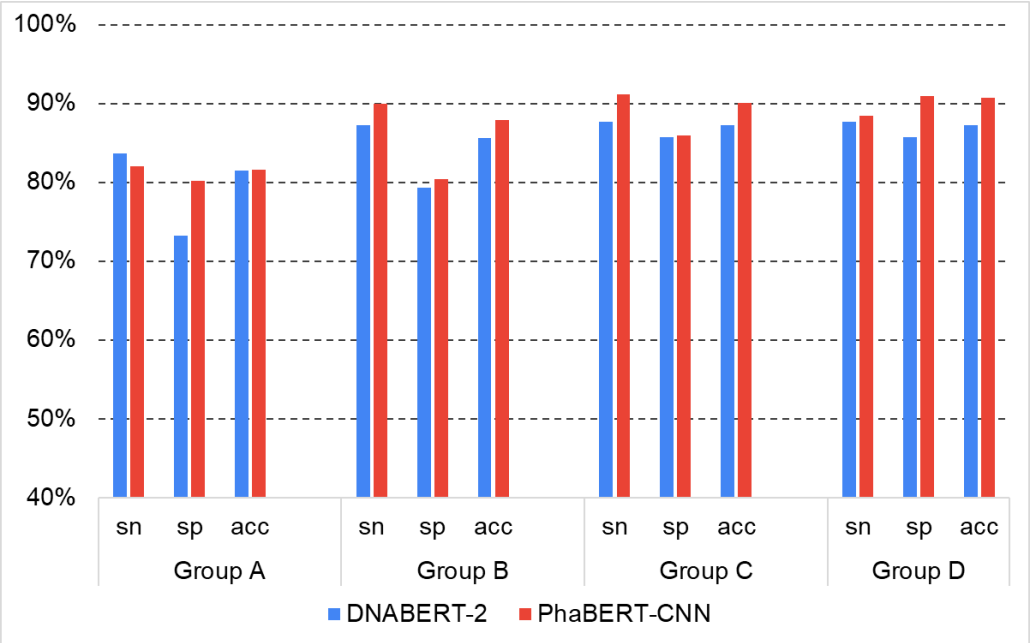

Hình 4.1: So sánh hiệu suất của DNABERT-2 và PhaBERT-CNN trên bốn nhóm độ dài contig

trưng của genome phage, bổ sung cho biểu diễn ngữ cảnh toàn cục của transformer encoder, đặc biệt khi chuỗi đủ dài để chứa các motif chức năng hoàn chỉnh.

4.3.2 So sánh với các phương pháp tiên tiến

Bảng 4.1 trình bày kết quả so sánh toàn diện giữa PhaBERT-CNN và các phương pháp baseline trên bốn nhóm độ dài contig, sử dụng 5-fold cross-validation.

Hình 4.2 minh họa trực quan hiệu suất của các phương pháp trên bốn nhóm độ dài.

PhaBERT-CNN đạt hiệu suất tốt nhất trên ba nhóm contig ngắn và trung bình (A, B, C), với accuracy lần lượt là 81.59%, 87.91%, và 90.01%. Trên các nhóm này, PhaBERT-CNN cải thiện 0.91–2.67% so với PhaTYP, 2.17–3.24% so với DeePhage, và 0.91–5.98% so với ProkBERT. Đặc biệt, mô hình duy trì sensitivity cao (82.00%–91.12%) trong khi đạt specificity cạnh tranh (80.15%–85.93%), cho thấy khả năng phân loại cân bằng giữa hai lớp phage.

Trên Nhóm D (1200–1800 bp), PhaTYP đạt accuracy cao nhất (91.02%) với sensitivity vượt trội (92.29%), trong khi PhaBERT-CNN đạt 90.69% accuracy, kém PhaTYP chỉ 0.34%. Tuy nhiên, PhaBERT-CNN vẫn vượt trội DeePhage 1.60% và

Bảng 4.1: So sánh hiệu suất PhaBERT-CNN, PhaTYP, DeePhage và ProkBERT theo 5-fold cross-validation trên bốn nhóm độ dài contig

Phương pháp	Chỉ số (%)	Nhóm A (100–400 bp)	Nhóm B (400–800 bp)	Nhóm C (800–1200 bp)	Nhóm D (1200–1800 bp)
PhaBERT-CNN	sn	**82.00**	**89.91**	**91.12**	88.47
	sp	80.15	80.44	85.93	**90.95**
	acc	**81.59**	**87.91**	**90.01**	90.69
PhaTYP	sn	79.07	86.74	90.09	**92.29**
	sp	78.77	**85.06**	**87.65**	89.75
	acc	78.92	85.90	88.87	**91.02**
DeePhage	sn	80.09	86.46	89.17	91.17
	sp	71.79	77.18	80.13	80.84
	acc	78.07	84.17	87.40	89.09
ProkBERT	sn	80.65	85.67	83.61	85.00
	sp	**80.80**	84.15	85.72	83.68
	acc	80.68	85.35	84.03	84.73

ProkBERT 5.96% trên nhóm này. Đáng chú ý, PhaBERT-CNN đạt specificity cao nhất ở Nhóm D (90.95%), vượt trội PhaTYP (89.75%), cho thấy khả năng phát hiện phage ôn hòa tốt hơn trên contig dài.

DeePhage thể hiện hiệu suất trung bình với accuracy từ 78.07% đến 89.09%, cải thiện đều đặn theo độ dài contig nhưng luôn thấp hơn các phương pháp dựa trên transformer. ProkBERT có xu hướng đặc biệt: accuracy đạt đỉnh ở Nhóm B (85.35%) rồi giảm xuống khoảng 84% ở Nhóm C và D, gợi ý rằng tokenization LCA chồng lấn của ProkBERT gặp khó khăn trong việc nắm bắt các phụ thuộc tầm xa trong chuỗi dài hơn.

4.4 Kết luận

Chương này đã trình bày kết quả đánh giá PhaBERT-CNN trên bốn nhóm độ dài contig thông qua 5-fold cross-validation. PhaBERT-CNN đạt hiệu suất tốt nhất trên contig ngắn và trung bình (100–1200 bp) với accuracy 81.59%–90.01%, cải thiện 0.91–5.98% so với các phương pháp tiên tiến, đồng thời duy trì kết quả cạnh tranh trên contig dài với 90.69% accuracy ở Nhóm D. Chương tiếp theo phân tích chi tiết các kết quả này, thảo luận về ưu điểm và hạn chế của phương pháp, và đề

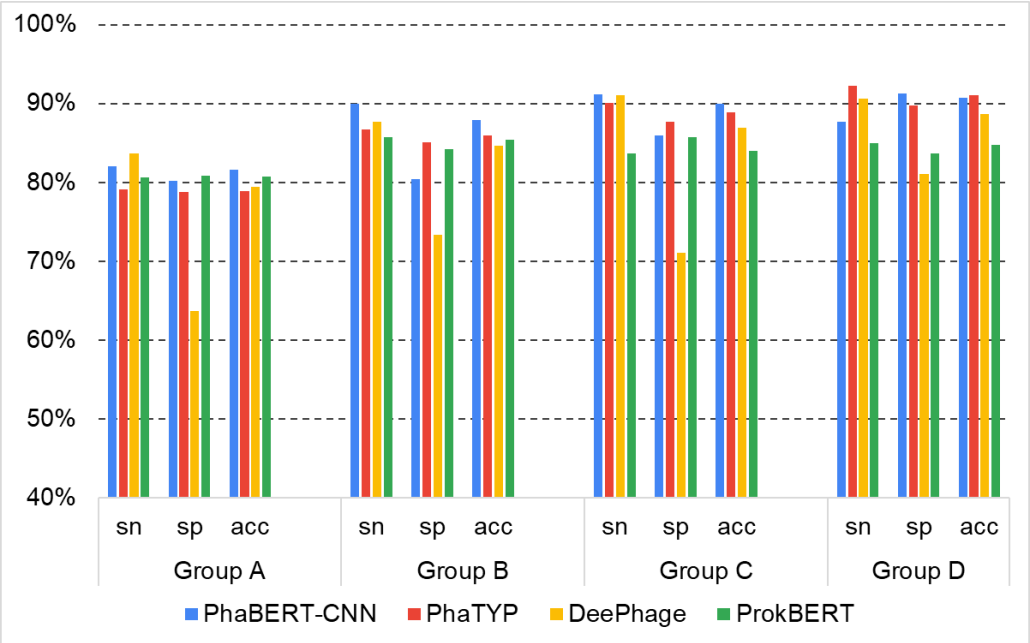

Hình 4.2: Hiệu suất phân loại của DeePhage, PhaTYP, ProkBERT và PhaBERT-CNN trên các nhóm A, B, C, D

xuất hướng nghiên cứu tương lai.

Chương 5

Kết luận

5.1 Kết luận

Luận văn này nghiên cứu bài toán phân loại lối sống thực khuẩn thể từ dữ liệu metagenomic, một thách thức quan trọng trong sinh tin học hiện đại. Các phương pháp hiện có gặp khó khăn khi xử lý contig ngắn do phụ thuộc vào công cụ dự đoán gene như Prodigal [15], vốn không hoạt động hiệu quả trên các đoạn DNA ngắn thiếu ORF hoàn chỉnh [16]. Để giải quyết vấn đề này, luận văn đề xuất PhaBERT-CNN, một kiến trúc học sâu lai kết hợp mô hình nền tảng genome DNABERT-2 [19] với mô đun Modified TextCNN gồm nhánh CNN đa tỷ lệ và nhánh attention pooling. Phương pháp hoạt động trực tiếp trên chuỗi DNA thô thông qua BPE tokenization, không phụ thuộc vào công cụ dự đoán gene, và được huấn luyện theo chiến lược hai giai đoạn với discriminative learning rates để tối ưu hóa cả backbone và các thành phần task-specific.

Phương pháp được đánh giá toàn diện trên bốn nhóm độ dài contig (100–400 bp, 400–800 bp, 800–1200 bp, 1200–1800 bp) thông qua stratified 5-fold cross-validation trên tập dữ liệu gồm 2,241 hệ gen thực khuẩn thể hoàn chỉnh. Như trình bày trong Bảng 4.1, PhaBERT-CNN đạt hiệu suất tốt nhất trên ba nhóm contig ngắn và trung bình (A, B, C) với accuracy lần lượt là 81.59%, 87.91%, và 90.01%. So với các phương pháp tiên tiến, PhaBERT-CNN cải thiện 0.91–2.67% so với PhaTYP [6], 2.17–3.24% so với DeePhage [14], và 0.91–5.98% so với ProkBERT [18] trên các nhóm này. Trên contig dài (Nhóm D), PhaBERT-CNN duy trì kết quả cạnh tranh với 90.69% accuracy, chỉ kém PhaTYP 0.34% nhưng vẫn vượt trội DeePhage 1.60% và ProkBERT 5.96%.

Kết quả nghiên cứu chứng minh tính hiệu quả của việc kết hợp mô hình nền tảng genome tiền huấn luyện với kiến trúc chuyên biệt Modified TextCNN cho bài toán phân loại lối sống thực khuẩn thể. PhaBERT-CNN không chỉ cải thiện độ chính xác phân loại trên contig ngắn và trung bình mà còn khắc phục được các hạn chế quan trọng của phương pháp hiện có như phụ thuộc công cụ phát hiện gene và

khả năng tổng quát hóa hạn chế. Sự kết hợp giữa biểu diễn ngữ cảnh toàn cục từ DNABERT-2 và trích xuất đặc trưng cục bộ chuyên biệt từ CNN đa tỷ lệ tạo ra lợi thế rõ rệt so với từng thành phần riêng lẻ, mở ra hướng tiếp cận đầy hứa hẹn cho việc kết hợp các mô hình tiền huấn luyện với các lớp cho các tác vụ đặc thù.

5.2 Thảo luận về kết quả chính

5.2.1 Phân tích kết quả

PhaBERT-CNN đạt hiệu suất tốt hơn trên ba nhóm contig ngắn và trung bình (A, B, C) với accuracy từ 81.59% đến 90.01%, cao hơn đáng kể so với các phương pháp được so sánh. Hiệu suất này xuất phát từ ba yếu tố bổ sung cho nhau. Thứ nhất, PhaBERT-CNN hoạt động trực tiếp trên chuỗi DNA thô thông qua BPE tokenization, không phụ thuộc vào công cụ phát hiện gene như Prodigal mà PhaTYP yêu cầu. Trên contig ngắn, Prodigal thường hoạt động không hiệu quả, khiến PhaTYP mất đi nguồn thông tin chính; trong khi đó PhaBERT-CNN vẫn khai thác được tín hiệu từ chuỗi nucleotide thô. Thứ hai, DNABERT-2 đã được tiền huấn luyện trên tập dữ liệu di truyền đa loài quy mô lớn [19], cho phép mô hình tổng quát hóa tốt hơn DeePhage vốn được huấn luyện từ đầu trên tập dữ liệu hạn chế. Thứ ba, kiến trúc Modified TextCNN với ba nhánh tích chập song song với kích thước cửa sổ khác nhau và attention pooling cho phép mô hình đồng thời nắm bắt các đặc trưng cục bộ ở nhiều tỷ lệ không gian và tổng hợp ngữ cảnh toàn cục có trọng số, giúp cải thiện hiệu suất phân loại.

Kết quả so sánh giữa DNABERT-2 đơn thuần và PhaBERT-CNN (Hình 4.1) cho thấy việc thêm Modified TextCNN giúp cải thiện hiệu suất tổng thể. Chỉ số accuracy tăng dần theo độ dài contig—từ 0.07% ở Nhóm A (81.52% lên 81.59%) đến 3.43% ở Nhóm D (87.26% lên 90.69%), phản ánh rằng khi chuỗi dài hơn, các motif chức năng trở nên rõ ràng hơn và CNN có thể khai thác chúng hiệu quả hơn. Kết quả này xác nhận việc kết hợp mô hình tiền huấn luyện với Modified TextCNN mang lại lợi ích rõ rệt.

Trên Nhóm D (1200–1800 bp), PhaTYP vượt PhaBERT-CNN với accuracy 91.02% so với 90.69%, một khoảng cách nhỏ chỉ 0.34%. Hiệu suất vượt trội của PhaTYP trên contig dài xuất phát từ khả năng tận dụng các đặc trưng protein có mặt trong chuỗi dài, cung cấp tín hiệu bổ sung về chức năng sinh học mà PhaBERT-CNN

chưa khai thác. Tuy nhiên, PhaBERT-CNN đạt specificity cao nhất ở Nhóm D (90.95%), vượt trội PhaTYP (89.75%) và tất cả các phương pháp khác, cho thấy khả năng phát hiện phage ôn hòa chính xác hơn trên contig dài.

So sánh với các phương pháp còn lại cho thấy rõ ưu thế của việc sử dụng mô hình tiền huấn luyện. DeePhage thể hiện hiệu suất trung bình với accuracy từ 78.07% đến 89.09%, cải thiện đều đặn theo độ dài contig nhưng luôn thấp hơn các phương pháp dựa trên transformer. Hạn chế này xuất phát từ việc DeePhage sử dụng CNN trên mã hóa one-hot, không tận dụng được kiến thức từ tiền huấn luyện và chỉ học từ tập dữ liệu huấn luyện hạn chế [14]. ProkBERT có xu hướng đặc biệt: accuracy đạt đỉnh ở Nhóm B (85.35%) rồi dao động quanh mức 84% ở Nhóm C (84.03%) và Nhóm D (84.73%), không cải thiện đáng kể dù độ dài contig tăng lên. Hiện tượng stagnation này phản ánh hạn chế của chiến lược k-mer tokenization chồng lấn, vốn có thể gây rò rỉ thông tin giữa các token liền kề và không mở rộng hiệu quả cho chuỗi dài hơn [18, 19]. Ngược lại, PhaBERT-CNN duy trì hiệu suất ổn định và cải thiện đều đặn trên tất cả các nhóm độ dài, cho thấy BPE tokenization và kiến trúc lai transformer–CNN giải quyết tốt hơn các thách thức khi phân loại đoạn trình tự ngắn trong dữ liệu metagenomics.

5.2.2 Đóng góp của nghiên cứu

Về mặt phương pháp, luận văn đề xuất PhaBERT-CNN, một kiến trúc học sâu lai kết hợp mô hình nền tảng genome DNABERT-2 với mô đun Modified TextCNN chuyên biệt cho bài toán phân loại lối sống thực khuẩn thể. Kiến trúc nhánh song song kép bao gồm nhánh CNN đa tỷ lệ với ba kernel sizes (3, 5, 7) để trích xuất các đặc trưng cục bộ ở nhiều tỷ lệ không gian, và nhánh attention pooling để tổng hợp biểu diễn toàn cục có trọng số từ các token embeddings của DNABERT-2. Chiến lược huấn luyện hai giai đoạn với discriminative learning rates—giai đoạn 1 đóng băng backbone để huấn luyện classification head, giai đoạn 2 fine-tune toàn bộ mô hình với learning rate thấp hơn cho backbone—cho phép tối ưu hóa hiệu quả cả pre-trained representations và task-specific components. Phương pháp này khác biệt với các tiếp cận trước đây bằng cách hoạt động trực tiếp trên chuỗi DNA thô thông qua BPE tokenization, loại bỏ phụ thuộc vào gene prediction tools và cho phép xử lý hiệu quả các contig ngắn thiếu ORF hoàn chỉnh.

Về mặt kết quả thực nghiệm, luận văn cung cấp đánh giá toàn diện trên bốn

nhóm độ dài contig từ 100 đến 1800 bp thông qua stratified 5-fold cross-validation, cho thấy PhaBERT-CNN cải thiện state-of-the-art trên contig ngắn và trung bình với mức tăng accuracy 0.91–5.98% so với các phương pháp tiên tiến. Nghiên cứu chứng minh rằng việc kết hợp pre-trained genomic embeddings với task-specific architecture mang lại lợi ích rõ rệt: so sánh trực tiếp với DNABERT-2 baseline cho thấy các thành phần CNN và attention pooling đóng góp cải thiện accuracy từ 0.07% đến 3.43% tùy theo độ dài contig, với cải thiện specificity đặc biệt đáng kể (6.90%) trên contig ngắn. Kết quả này xác nhận giả thuyết rằng genomic foundation models cung cấp nền tảng mạnh mẽ cho các tác vụ downstream, nhưng vẫn cần các thành phần chuyên biệt để đạt hiệu suất tối ưu. Phân tích chi tiết về hiệu suất trên từng nhóm độ dài cũng cung cấp insights quan trọng về điểm mạnh và hạn chế của từng phương pháp, giúp định hướng nghiên cứu tương lai.

Về mặt ứng dụng thực tiễn, PhaBERT-CNN giải quyết một thách thức quan trọng trong phân tích dữ liệu metagenomics: phân loại lối sống thực khuẩn thể từ các contig phân mảnh thu được qua quá trình lắp ráp metagenomics. Khả năng xử lý trực tiếp trên chuỗi DNA thô mà không cần công cụ phát hiện gene như Prodigal [15] làm cho phương pháp đặc biệt phù hợp với các tình huống thực tế, nơi contig thường ngắn và thiếu các vùng mã hóa protein hoàn chỉnh. Hiệu suất cân bằng giữa độ nhạy và độ đặc hiệu trên tất cả các nhóm độ dài cho thấy PhaBERT-CNN có tiềm năng tích hợp vào các quy trình phân tích metagenomics tự động, hỗ trợ nghiên cứu về tương tác phage–vi khuẩn, động lực quần thể vi sinh vật, và ứng dụng liệu pháp thực khuẩn thể (phage therapy). Hơn nữa, khuôn khổ lai ghép giữa mô hình nền tảng tiền huấn luyện với các thành phần kiến trúc chuyên biệt cho tác vụ mở ra một hướng tiếp cận có thể mở rộng sang nhiều bài toán tin sinh học hạ nguồn khác như dự đoán vi khuẩn chủ, phát hiện prophage, phân loại chức năng gen, và chú giải bộ gen vi sinh vật, qua đó góp phần thúc đẩy nghiên cứu trong lĩnh vực tin sinh học tính toán.

5.2.3 Hạn chế và hướng phát triển tương lai

Một hạn chế đáng chú ý của PhaBERT-CNN là việc sử dụng phương pháp random undersampling để xử lý vấn đề mất cân bằng nhãn trong tập huấn luyện. Mặc dù đơn giản và tiết kiệm tài nguyên tính toán, phương pháp này có nguy cơ làm mất thông tin từ lớp đa số do loại bỏ ngẫu nhiên các mẫu nhằm cân bằng với lớp

thiểu số. Các chiến lược thay thế đáng được khảo sát bao gồm: (1) gán trọng số lớp (class weighting) — tăng trọng số cho lớp thiểu số trực tiếp trong hàm mục tiêu; (2) focal loss [44] — tập trung tối ưu hóa vào các mẫu khó phân loại; và (3) tăng cường dữ liệu tổng hợp (synthetic oversampling) thông qua các kỹ thuật như bổ sung chuỗi bù trừ ngược chiều (reverse complement), đột biến ngẫu nhiên tỷ lệ thấp, hoặc mixup trên không gian nhúng (embedding space). Những chiến lược này cho phép giữ toàn bộ thông tin huấn luyện trong khi vẫn hạn chế thiên lệch về lớp đa số. Nghiên cứu tiếp theo nên đánh giá có hệ thống các phương án trên để xác định chiến lược tối ưu cho bài toán phân loại lối sống thực khuẩn thể.

Hạn chế thứ hai liên quan đến hiệu suất trên các contig dài, nơi PhaTYP [6] vượt trội PhaBERT-CNN nhờ khai thác đặc trưng protein. Điều này cho thấy thông tin ở cấp độ protein cung cấp tín hiệu phân loại bổ sung quan trọng, đặc biệt trên các chuỗi dài chứa đầy đủ các vùng mã hóa protein. Hướng phát triển tự nhiên là mở rộng PhaBERT-CNN theo kiến trúc đa phương thức, trong đó chuỗi nucleotide được xử lý qua DNABERT-2 [19] song song với đặc trưng protein được trích xuất qua các mô hình ngôn ngữ protein như ESM-2 [45] hoặc ProtBERT [46]. Cơ chế tích hợp có thể là cross-attention để kết hợp thông tin từ hai phương thức, hoặc hợp nhất muộn (late fusion) kết hợp đầu ra từ hai nhánh độc lập. Quan trọng hơn, kiến trúc cần được thiết kế để hoạt động bền vững khi đặc trưng protein không khả dụng — ví dụ trên contig ngắn — thông qua tính toán có điều kiện (conditional computation) hoặc cơ chế cổng thích nghi (learned gating). Cách tiếp cận này có tiềm năng cải thiện hiệu suất trên contig dài trong khi vẫn duy trì ưu thế trên contig ngắn, hướng tới một phương pháp phân loại thống nhất trên toàn bộ phổ độ dài contig.

Tài liệu tham khảo

[1] Curtis A Suttle. Marine viruses—major players in the global ecosystem. *Nature reviews microbiology*, 5(10):801–812, 2007.

[2] Britt Koskella and Michael A Brockhurst. Bacteria–phage coevolution as a driver of ecological and evolutionary processes in microbial communities. *FEMS microbiology reviews*, 38(5):916–931, 2014.

[3] Cristina Howard-Varona, Katherine R Hargreaves, Stephen T Abedon, and Matthew B Sullivan. Lysogeny in nature: mechanisms, impact and ecology of temperate phages. *The ISME journal*, 11(7):1511–1520, 2017.

[4] Andrzej Gorski, Ryszard Miedzybrodzki, Beata Weber-Dabrowska, Wojciech Fortuna, Slawomir Letkiewicz, Pawel Rogoz, Ewa Jonczyk-Matysiak, Krystyna Dabrowska, Joanna Majewska, and Jan Borysowski. Phage therapy: combating infections with potential for evolving from merely a treatment for complications to targeting diseases. *Frontiers in microbiology*, 7:1515, 2016.

[5] Ana Georgina Cobián Güemes, Merry Youle, Vito Adrian Cantú, Ben Felts, James Nulton, and Forest Rohwer. Viruses as winners in the game of life. *Annual review of virology*, 3(1):197–214, 2016.

[6] Jiayu Shang, Xubo Tang, and Yanni Sun. Phatyp: predicting the lifestyle for bacteriophages using bert. *Briefings in Bioinformatics*, 24(1):bbac487, 2023.

[7] John L Mokili, Forest Rohwer, and Bas E Dutilh. Metagenomics and future perspectives in virus discovery. *Current opinion in virology*, 2(1):63–77, 2012.

[8] Stephen Hayes, Jennifer Mahony, Arjen Nauta, and Douwe Van Sinderen. Metagenomic approaches to assess bacteriophages in various environmental niches. *Viruses*, 9(6):127, 2017.

[9] Yuan Jiang, Jun Wang, Dawen Xia, and Guoxian Yu. Ensvmb: metagenomics fragments classification using ensemble svm and blast. *Scientific reports*, 7(1):9440, 2017.

[10] Roye Rozov, Aya Brown Kav, David Bogumil, Naama Shterzer, Eran Halperin, Itzhak Mizrahi, and Ron Shamir. Recycler: an algorithm for detecting plasmids from de novo assembly graphs. *Bioinformatics*, 33(4):475–482, 2017.

[11] Katelyn McNair, Barbara A Bailey, and Robert A Edwards. Phacts, a computational approach to classifying the lifestyle of phages. *Bioinformatics*, 28(5):614–618, 2012.

[12] Piotr Tynecki, Arkadiusz Guziński, Joanna Kazimierczak, Michał Jadczuk, Jarosław Dastych, and Agnieszka Onisko. Phageai-bacteriophage life cycle recognition with machine learning and natural language processing. *BioRxiv*, pages 2020–07, 2020.

[13] Adam J Hockenberry and Claus O Wilke. Bacphlip: predicting bacteriophage lifestyle from conserved protein domains. *PeerJ*, 9:e11396, 2021.

[14] Shufang Wu, Zhencheng Fang, Jie Tan, Mo Li, Chunhui Wang, Qian Guo, Congmin Xu, Xiaoqing Jiang, and Huaiqiu Zhu. Deephage: distinguishing virulent and temperate phage-derived sequences in metavirome data with a deep learning approach. *Gigascience*, 10(9):giab056, 2021.

[15] Doug Hyatt, Gwo-Liang Chen, Philip F LoCascio, Miriam L Land, Frank W Larimer, and Loren J Hauser. Prodigal: prokaryotic gene recognition and translation initiation site identification. *BMC bioinformatics*, 11(1):119, 2010.

[16] William L Trimble, Kevin P Keegan, Mark D'Souza, Andreas Wilke, Jared Wilkening, Jack Gilbert, and Folker Meyer. Short-read reading-frame predictors are not created equal: sequence error causes loss of signal. *BMC bioinformatics*, 13(1):183, 2012.

[17] Yujie Zhang, Mark Mao, Robert Zhang, Yen-Te Liao, and Vivian CH Wu. Deeppl: A deep-learning-based tool for the prediction of bacteriophage lifecycle. *PLOS Computational Biology*, 20(10):e1012525, 2024.

[18] Balázs Ligeti, István Szepesi-Nagy, Babett Bodnár, Noémi Ligeti-Nagy, and János Juhász. Prokbert family: genomic language models for microbiome applications. *Frontiers in Microbiology*, 14:1331233, 2024.

[19] Zhihan Zhou, Yanrong Ji, Weijian Li, Pratik Dutta, Ramana Davuluri, and Han Liu. Dnabert-2: Efficient foundation model and benchmark for multi-species genome. *arXiv preprint arXiv:2306.15006*, 2023.

[20] J. D. Watson and F. H. C. Crick. Molecular structure of nucleic acids: a structure for deoxyribose nucleic acid. *Nature*, 171:737–738, 1953.

[21] Harald Brüssow and Roger W. Hendrix. Phage genomics: small is beautiful. *Cell*, 108(1):13–16, 2002.

[22] Basem Al-Shayeb, Rohan Sachdeva, Lin-Xing Chen, Fred Ward, Patrick Munk, Audra Devoto, Cindy J Castelle, Matthew R Olm, Keith Bouma-Gregson, Yuki Amano, et al. Clades of huge phages from across Earth's ecosystems. *Nature*, 578(7795):425–431, 2020.

[23] Fernando L Gordillo Altamirano and Jeremy J Barr. Phage therapy in the postantibiotic era. *Clinical Microbiology Reviews*, 32(2):e00066–18, 2019.

[24] Kaitlyn E Kortright, Benjamin K Chan, Jonathan L Koff, and Paul E Turner. Phage therapy: a renewed approach to combat antibiotic-resistant bacteria. *Cell Host & Microbe*, 25(2):219–232, 2019.

[25] Harald Brüssow, Carlos Canchaya, and Wolf-Dietrich Hardt. Phages and the evolution of bacterial pathogens: from genomic rearrangements to lysogenic conversion. *Microbiology and Molecular Biology Reviews*, 68(3):560–602, 2004.

[26] Joanne B Emerson, Brian C Thomas, Karen Andrade, Eric E Allen, Karla B Heidelberg, and Jillian F Banfield. Dynamic viral populations in hypersaline systems as revealed by metagenomic assembly. *Applied and environmental microbiology*, 78(17):6309–6320, 2012.

[27] Jay S Ghurye, Victoria Cepeda-Espinoza, and Mihai Pop. Metagenomic assembly: overview, challenges and applications. *The Yale journal of biology and medicine*, 89(3):353, 2016.

[28] João C Setubal. Metagenome-assembled genomes: concepts, analogies, and challenges. *Biophysical reviews*, 13(6):905–909, 2021.

[29] Yanrong Ji, Zhihan Zhou, Han Liu, and Ramana V Davuluri. Dnabert: pre-trained bidirectional encoder representations from transformers model for dna-language in genome. *Bioinformatics*, 37(15):2112–2120, 2021.

[30] Rico Sennrich, Barry Haddow, and Alexandra Birch. Neural machine translation of rare words with subword units. *arXiv preprint arXiv:1508.07909*, 2015.

[31] Taku Kudo and John Richardson. Sentencepiece: A simple and language independent subword tokenizer and detokenizer for neural text processing. *arXiv preprint arXiv:1808.06226*, 2018.

[32] Colin Raffel, Noam Shazeer, Adam Roberts, Katherine Lee, Sharan Narang, Michael Matena, Yanqi Zhou, Wei Li, and Peter J Liu. Exploring the limits of transfer learning with a unified text-to-text transformer. *Journal of Machine Learning Research*, 21(140):1–67, 2020.

[33] Ofir Press, Noah A Smith, and Mike Lewis. Train short, test long: Attention with linear biases enables input length extrapolation. *arXiv preprint arXiv:2108.12409*, 2021.

[34] Tri Dao, Dan Fu, Stefano Ermon, Atri Rudra, and Christopher Ré. Flashattention: Fast and memory-efficient exact attention with io-awareness. *Advances in neural information processing systems*, 35:16344–16359, 2022.

[35] Hugo Dalla-Torre, Liam Gonzalez, Javier Mendoza-Revilla, Nicolas Lopez Carranza, Adam Henryk Grzywaczewski, Francesco Oteri, Christian Dallago, Evan Trop, Bernardo P de Almeida, Hassan Sirelkhatim, et al. Nucleotide transformer: building and evaluating robust foundation models for human genomics. *Nature Methods*, 22(2):287–297, 2025.

[36] Sinno Jialin Pan and Qiang Yang. A survey on transfer learning. *IEEE Transactions on Knowledge and Data Engineering*, 22(10):1345–1359, 2010.

[37] Fuzhen Zhuang, Zhiyuan Qi, Keyu Duan, Dongbo Xi, Yongchun Zhu, Hengshu Zhu, Hui Xiong, and Qing He. A comprehensive survey on transfer learning. *Proceedings of the IEEE*, 109(1):43–76, 2021.

[38] Jacob Devlin, Ming-Wei Chang, Kenton Lee, and Kristina Toutanova. Bert: Pre-training of deep bidirectional transformers for language understanding. In *Proceedings of the 2019 conference of the North American chapter of the association for computational linguistics: human language technologies, volume 1 (long and short papers)*, pages 4171–4186, 2019.

[39] Jeremy Howard and Sebastian Ruder. Universal language model fine-tuning for text classification. pages 328–339, 2018.

[40] Yoon Kim. Convolutional neural networks for sentence classification. In *Proceedings of the 2014 Conference on Empirical Methods in Natural Language Processing (EMNLP)*, pages 1746–1751, 2014.

[41] Zhouhan Lin, Minwei Feng, Cicero Nogueira dos Santos, Mo Yu, Bing Xiang, Bowen Zhou, and Yoshua Bengio. A structured self-attentive sentence embedding. *arXiv preprint arXiv:1703.03130*, 2017.

[42] Travis N. Mavrich and Graham F. Hatfull. Bacteriophage evolution differs by host, lifestyle and genome. *Nature Microbiology*, 2(9):17112, 2017.

[43] Rie Johnson and Tong Zhang. Deep pyramid convolutional neural networks for text categorization. In *Proceedings of the 55th Annual Meeting of the Association for Computational Linguistics (Volume 1: Long Papers)*, pages 562–570, 2017.

[44] Tsung-Yi Lin, Priya Goyal, Ross Girshick, Kaiming He, and Piotr Dollár. Focal loss for dense object detection. In *Proceedings of the IEEE international conference on computer vision*, pages 2980–2988, 2017.

[45] Zeming Lin, Halil Akin, Roshan Rao, Brian Hie, Zhongkai Zhu, Wenting Lu, Nikita Smetanin, Robert Verkuil, Ori Kabeli, Yilun Shmueli, et al. Evolutionary-scale prediction of atomic-level protein structure with a language model. *Science*, 379(6637):1123–1130, 2023.

[46] Ahmed Elnaggar, Michael Heinzinger, Christian Dallago, Ghalia Rehawi, Yu Wang, Llion Jones, Tom Gibbs, Tamas Feher, Christoph Angerer, Martin Steinegger, et al. Prottrans: Toward understanding the language of life through self-supervised learning. *IEEE transactions on pattern analysis and machine intelligence*, 44(10):7112–7127, 2021.