ĐẠI HỌC QUỐC GIA HÀ NỘI
TRƯỜNG ĐẠI HỌC CÔNG NGHỆ

PHÂN LOẠI LỐI SỐNG THỰC KHUẨN THỂ DỰA TRÊN PHƯƠNG PHÁP HỌC SÂU

LUẬN VĂN THẠC SĨ

Ngành: Khoa học máy tính

HÀ NỘI - 2026

ĐẠI HỌC QUỐC GIA HÀ NỘI
TRƯỜNG ĐẠI HỌC CÔNG NGHỆ

Vũ Quang Sơn

PHÂN LOẠI LỐI SỐNG THỰC KHUẨN THỂ DỰA TRÊN PHƯƠNG PHÁP HỌC SÂU

LUẬN VĂN THẠC SĨ

Ngành: Khoa học máy tính

Cán bộ hướng dẫn: TS. Điệp Thị Hoàng

HÀ NỘI - 2026

VIETNAM NATIONAL UNIVERSITY, HANOI
UNIVERSITY OF ENGINEERING AND TECHNOLOGY

Vu Quang Son

DEEP LEARNING BASED METHODS FOR PHAGE LIFESTYLE PREDICTION

MASTER'S THESIS

Major: Computer Science

Supervisor: Dr. Diep Thi Hoang

HANOI - 2026

Lời cảm ơn

Với tất cả lòng kính trọng và biết ơn sâu sắc, tôi xin gửi lời cảm ơn chân thành đến cô TS. Điệp Thị Hoàng, người thầy đã tận tình hướng dẫn, định hướng và truyền đạt tri thức quý báu trong suốt quá trình tôi thực hiện luận văn thạc sĩ. Sự hỗ trợ, những lời khuyên bảo và sự kiên nhẫn của cô là nguồn động viên to lớn giúp tôi hoàn thành nghiên cứu này.

Tôi xin trân trọng cảm ơn các thầy, cô giáo đang công tác và giảng dạy tại Khoa Công nghệ Thông tin, trường Đại học Công Nghệ - Đại học Quốc gia Hà Nội, những người đã trang bị cho tôi nền tảng kiến thức vững chắc và tạo mọi điều kiện thuận lợi để tôi được học tập và phát triển trong môi trường học thuật chuyên nghiệp.

Tôi xin gửi lời cảm ơn đến các bạn bè, đồng nghiệp đã luôn động viên, chia sẻ kinh nghiệm và hỗ trợ tôi trong suốt quá trình học tập và nghiên cứu.

Cuối cùng, tôi xin dành sự biết ơn sâu sắc nhất đến gia đình, đặc biệt là bố mẹ và người vợ yêu quý, những người đã luôn là nguồn động lực và điểm tựa tinh thần vững chắc cho tôi. Sự hy sinh, thấu hiểu và tình yêu thương vô bờ bến của gia đình là món quà vô giá, giúp tôi có thêm sức mạnh để vượt qua mọi khó khăn và hoàn thành chặng đường học tập thạc sĩ đầy thử thách này.

Tôi xin chân thành cảm ơn!

Lời cam đoan

Tôi là Vũ Quang Sơn, học viên cao học khóa 30, ngành Khoa học máy tính. Tôi xin cam đoan luận văn thạc sĩ "Phân loại lối sống thực khuẩn thể dựa trên phương pháp học sâu" là công trình nghiên cứu, xây dựng của riêng mình dưới sự hướng dẫn của cô TS. Điệp Thị Hoàng. Các nội dung nghiên cứu, kết quả trong luận văn là xác thực.

Các thông tin sử dụng trong luận văn là có cơ sở và không có nội dung nào sao chép từ các tài liệu mà không ghi rõ trích dẫn tham khảo. Tôi xin chịu trách nhiệm về lời cam đoan này.

Hà Nội, ngày ... tháng ... năm 2025

Học viên

Vũ Quang Sơn

Tóm tắt

Thực khuẩn thể (bacteriophage) là virus xâm nhiễm vi khuẩn, có tiềm năng ứng dụng trong liệu pháp phage thay thế kháng sinh. Việc phân loại chính xác lối sống của thực khuẩn thể - độc lực (virulent) hay ôn hòa (temperate) - là yêu cầu thiết yếu cho các ứng dụng trị liệu, vì chỉ phage độc lực mới an toàn để sử dụng. Các phương pháp truyền thống dựa vào nuôi cấy tốn thời gian và không áp dụng được cho phần lớn phage chưa nuôi cấy được. Các công cụ tính toán hiện có như PhaTYP và DeePhage vẫn gặp hạn chế khi xử lý các contig ngắn từ dữ liệu metagenomic.

Luận văn này đề xuất PhaBERT-CNN, một kiến trúc học sâu kết hợp mô hình nền tảng genome DNABERT-2 với mạng nơ-ron tích chập đa tỷ lệ và cơ chế attention pooling. Khác với PhaTYP phụ thuộc vào dự đoán protein, PhaBERT-CNN hoạt động trực tiếp trên chuỗi DNA thô, khắc phục hạn chế khi xử lý contig ngắn. Mô hình tận dụng biểu diễn tiền huấn luyện từ DNABERT-2, sử dụng các nhánh CNN song song với kernel sizes 3, 5, và 7 để trích xuất đặc trưng đa tỷ lệ, và áp dụng self-attention để tập trung vào các vùng genome có tính thông tin cao.

Thực nghiệm trên bốn nhóm độ dài contig (100-400 bp, 400-800 bp, 800-1200 bp, 1200-1800 bp) với 5-fold cross-validation cho thấy PhaBERT-CNN đạt accuracy 81.59%, 87.91%, 90.01%, và 90.69% tương ứng, cải thiện 0.91-5.98% so với các phương pháp tiên tiến như PhaTYP, DeePhage, và ProkBERT. Mô hình duy trì sự cân bằng tốt giữa sensitivity (82.00%-91.12%) và specificity (80.15%-90.95%) trên tất cả các phạm vi độ dài.

Kết quả nghiên cứu chứng minh hiệu quả của việc kết hợp mô hình nền tảng genome với kiến trúc chuyên biệt task-specific, cung cấp một paradigm đầy hứa hẹn cho các nhiệm vụ phân tích chuỗi sinh học, đặc biệt trong bối cảnh phân tích metagenomic với các chuỗi không hoàn chỉnh.

Từ khóa: *Thực khuẩn thể*, *Phân loại lối sống*, *Học sâu*, *BERT*, *Mạng nơ-ron tích chập*, *Sinh tin học*, *Metagenomics*

Abstract

Bacteriophages are viruses that infect bacteria, showing promise as alternatives to antibiotics in phage therapy. Accurate classification of phage lifestyle - virulent or temperate - is essential for therapeutic applications, as only virulent phages are safe for use. Traditional laboratory-based methods are time-consuming and inapplicable to the majority of unculturable phages. Existing computational tools such as PhaTYP and DeePhage still face limitations when processing short contigs from metagenomic data.

This thesis proposes PhaBERT-CNN, a novel hybrid deep learning architecture that combines the DNABERT-2 genome foundation model with multi-scale convolutional neural networks and attention pooling mechanism. Unlike PhaTYP which relies on protein prediction, PhaBERT-CNN operates directly on raw DNA sequences, overcoming limitations when processing short contigs. The model leverages pre-trained representations from DNABERT-2, uses parallel CNN branches with kernel sizes 3, 5, and 7 to extract multi-scale features, and applies self-attention mechanism to focus on highly informative genomic regions.

Experiments on four contig length groups (100-400 bp, 400-800 bp, 800-1200 bp, 1200-1800 bp) with 5-fold cross-validation demonstrate that PhaBERT-CNN achieves accuracies of 81.59%, 87.91%, 90.01%, and 90.69% respectively, improving 0.91-5.98% over state-of-the-art methods including PhaTYP, DeePhage, and ProkBERT. The model maintains a good balance between sensitivity (82.00%-91.12%) and specificity (80.15%-90.95%) across all length ranges.

The research results demonstrate the effectiveness of combining genome foundation models with task-specific architectures, providing a promising paradigm for biological sequence analysis tasks, particularly in metagenomic analysis with incomplete sequences.

Keywords: *Bacteriophage*, *Lifestyle classification*, *Deep learning*, *BERT*, *Convolutional neural networks*, *Bioinformatics*, *Metagenomics*

Mục lục

Lời cảm ơn

Lời cam đoan **i**

Tóm tắt **ii**

Abstract **iii**

Mục lục **iv**

Danh sách hình vẽ **ix**

Danh sách bảng **x**

Danh mục các từ viết tắt và thuật ngữ **xi**

Chương 1 Giới thiệu **1**

1.1 Bối cảnh nghiên cứu 1

1.2 Vấn đề nghiên cứu 2

1.2.1 Hạn chế về dữ liệu huấn luyện 3

1.2.2 Thiếu gen đánh dấu phổ quát 3

1.2.3 Thách thức với các đoạn DNA ngắn 3

1.2.4 Vấn đề tương đồng trình tự với vi khuẩn chủ 4

1.2.5 Phát biểu bài toán 4

1.3 Mục tiêu nghiên cứu 5

1.3.1 Mục tiêu 1: Phát triển mô hình PhaBERT-CNN 5

1.3.2 Mục tiêu 2: Đánh giá hiệu suất trên nhiều nhóm độ dài contig . 6

1.3.3 Mục tiêu 3: So sánh với các phương pháp tiên tiến 6

1.3.4 Mục tiêu 4: Phân tích tác động của các thành phần kiến trúc . 7

1.3.5 Mục tiêu 5: Đề xuất chiến lược huấn luyện hiệu quả 7

1.3.6 Mục tiêu 6: Cung cấp phân tích và hướng dẫn thực tiễn 7

1.4 Đóng góp chính của luận văn 8
1.4.1 Kiến trúc PhaBERT-CNN mới 8
1.4.2 Hiệu suất vượt trội trên contig ngắn và trung bình 9
1.4.3 Chiến lược huấn luyện hai giai đoạn hiệu quả 9
1.4.4 Đánh giá toàn diện và phân tích so sánh 10
1.4.5 Giải quyết các hạn chế của phương pháp hiện có 10
1.4.6 Đóng góp về mặt phương pháp luận 11
1.5 Phạm vi nghiên cứu 11
1.5.1 Phạm vi về bài toán 11
1.5.2 Phạm vi về dữ liệu 12
1.5.3 Phạm vi về phương pháp 12
1.5.4 Phạm vi về đánh giá 13
1.5.5 Phạm vi về triển khai 13
1.5.6 Giới hạn và giả định 13
1.6 Bố cục luận văn 14

Chương 2 Cơ sở lý thuyết 17
2.1 Thực khuẩn thể và phân loại lối sống 17
2.1.1 Giới thiệu về thực khuẩn thể 17
2.1.2 Cấu trúc và thành phần của thực khuẩn thể 18
2.1.3 Chu trình sống của thực khuẩn thể 18
2.1.4 Vai trò sinh thái và ứng dụng 20
2.2 Metagenomics và giải trình tự thế hệ mới 21
2.2.1 Giới thiệu về metagenomics 21
2.2.2 Công nghệ giải trình tự thế hệ mới 22
2.2.3 Lắp ráp metagenomic và contig 23
2.2.4 Ứng dụng của metagenomics trong nghiên cứu phage 25
2.3 Học máy cho phân tích dữ liệu sinh học 25
2.3.1 Giới thiệu về học máy 25
2.3.2 Các loại học máy 26
2.3.3 Các khái niệm cơ bản 27
2.3.4 Học máy cho phân tích chuỗi sinh học 28
2.4 Học sâu và mạng nơ-ron 29
2.4.1 Giới thiệu về học sâu 29

2.4.2 Mạng nơ-ron nhân tạo 29
2.4.3 Backpropagation và tối ưu hóa 30
2.4.4 Regularization techniques 30
2.4.5 Loss functions 31
2.4.6 Ưu điểm của học sâu cho dữ liệu sinh học 31
2.5 Mạng nơ-ron tích chập 32
2.5.1 Giới thiệu về CNN 32
2.5.2 Phép tích chập (Convolution) 32
2.5.3 Các thành phần của CNN 32
2.5.4 Multi-scale CNN 33
2.5.5 CNN cho phân tích chuỗi sinh học 33
2.6 Kiến trúc Transformer 34
2.6.1 Giới thiệu 34
2.6.2 Self-Attention Mechanism 35
2.6.3 Positional Encoding 36
2.6.4 Feed-Forward Networks 36
2.6.5 Transformer Encoder 37
2.6.6 Ưu điểm của Transformer 37
2.6.7 Transformer cho genomics 37
2.7 BERT và Masked Language Modeling 37
2.7.1 Giới thiệu về BERT 37
2.7.2 Masked Language Modeling (MLM) 38
2.7.3 Kiến trúc BERT 38
2.7.4 Transfer Learning với BERT 39
2.7.5 Ưu điểm của BERT 39
2.7.6 BERT cho genomics 39
2.8 DNABERT: BERT cho chuỗi DNA 40
2.8.1 Giới thiệu 40
2.8.2 Tokenization: Overlapping k-mers 40
2.8.3 Hạn chế của DNABERT 40
2.8.4 Thành công và ảnh hưởng 41
2.9 DNABERT-2 41
2.9.1 Tokenization với BPE 41
2.9.2 Kiến trúc mô hình 42

2.9.3 Positional encoding: ALiBi 43
2.9.4 Pre-training 43
2.9.5 Output representations 44
2.9.6 So sánh với DNABERT gốc 44
2.10 Học chuyển giao trong sinh tin học 45
2.10.1 Khái niệm học chuyển giao 45
2.10.2 Pre-training và Fine-tuning 45
2.10.3 Chiến lược Fine-tuning 46
2.10.4 Lợi ích của Transfer Learning 47
2.10.5 Transfer Learning trong Genomics 47
2.10.6 PhaBERT-CNN và Transfer Learning 48
2.11 Các công trình liên quan 48
2.11.1 Phương pháp học máy truyền thống 48
2.11.2 Phương pháp học sâu 50
2.11.3 So sánh tổng quan 53
2.11.4 Vị trí của PhaBERT-CNN 53

Chương 3 Phương pháp đề xuất 55
3.1 Tổng quan phương pháp 55
3.2 Thu thập dữ liệu và tiền xử lý 57
3.2.1 Nguồn dữ liệu 58
3.2.2 Tạo contigs bằng sliding window 58
3.2.3 Data augmentation 60
3.2.4 Xử lý class imbalance 61
3.2.5 Thống kê tập dữ liệu 62
3.3 Kiến trúc PhaBERT-CNN 63
3.3.1 DNABERT-2 Backbone 63
3.3.2 Dual Parallel Feature Extraction Branches 65
3.3.3 Feature Fusion và Classification Head 67
3.4 Chiến lược huấn luyện và tinh chỉnh 68
3.4.1 Two-Phase Progressive Fine-Tuning 68
3.4.2 Loss Function và Optimization Objective 71
3.4.3 Training Infrastructure 72
3.4.4 Hyperparameter Selection 72

3.4.5 Computational Requirements 73
3.5 Kết luận chương 74

Chương 4 Thực nghiệm và Đánh giá **76**
4.1 Môi trường thực nghiệm 76
4.1.1 Xây dựng tập dữ liệu 76
4.1.2 Cấu hình phần cứng và phần mềm 79
4.1.3 Tập dữ liệu 80
4.1.4 Các phương pháp so sánh 81
4.1.5 Các chỉ số đánh giá 81
4.2 Kết quả thực nghiệm 81
4.2.1 Kết quả tổng quan 81
4.2.2 Phân tích chi tiết theo nhóm độ dài 82
4.2.3 Phân tích sensitivity và specificity 84
4.3 Phân tích và thảo luận 86
4.3.1 Ưu điểm của PhaBERT-CNN 86
4.3.2 Hạn chế và hướng cải thiện 87
4.3.3 So sánh với DNABERT-2 baseline 87
4.4 Kết luận chương 88

Chương 5 Kết luận **89**
5.1 Tóm tắt nghiên cứu 89
5.2 Kết quả chính 90
5.2.1 Hiệu suất vượt trội trên short-medium contigs 90
5.2.2 Cân bằng sensitivity-specificity 90
5.2.3 Khắc phục hạn chế của phương pháp hiện có 90
5.3 Đóng góp của luận văn 90
5.4 Hạn chế 91
5.5 Hướng nghiên cứu tương lai 91
5.5.1 Cải thiện phương pháp 91
5.5.2 Mở rộng ứng dụng 91
5.5.3 Nghiên cứu cơ bản 92
5.6 Kết luận cuối cùng 92

Tài liệu tham khảo **93**

Danh sách hình vẽ

3.1 Quy trình xử lý tổng thể của PhaBERT-CNN cho dự đoán lối sống thực khuẩn thể 57
3.2 Kiến trúc chi tiết của PhaBERT-CNN 64

4.1 Quy trình chuẩn bị dữ liệu cho thực nghiệm 80
4.2 So sánh accuracy của các phương pháp trên 4 nhóm độ dài contig . . 82
4.3 Kết quả chi tiết trên contig ngắn (Nhóm A và B) 83
4.4 Kết quả chi tiết trên contig dài (Nhóm C và D) 85
4.5 So sánh sensitivity và specificity của các phương pháp trên 4 nhóm độ dài contig 86

Danh sách bảng

2.1 So sánh DNABERT và DNABERT-2 45
2.2 So sánh các phương pháp phân loại lối sống phage 53

3.1 Tham số sliding window cho các nhóm độ dài contig 60
3.2 Thống kê số lượng contigs sau augmentation (trước undersampling) . 62
3.3 Hyperparameters của PhaBERT-CNN 73

4.1 Tham số tạo contig cho các nhóm độ dài 78
4.2 Thống kê số lượng contigs sau augmentation (trước undersampling) . 79
4.3 Kết quả phân loại trên các nhóm độ dài contig (5-fold cross-validation) 82
4.4 Kết quả chi tiết trên Nhóm A (100-400 bp) 83
4.5 Kết quả chi tiết trên Nhóm B (400-800 bp) 84
4.6 Kết quả chi tiết trên Nhóm C (800-1200 bp) 84
4.7 Kết quả chi tiết trên Nhóm D (1200-1800 bp) 85
4.8 Ablation study: So sánh PhaBERT-CNN với DNABERT-2 baseline . 88

Danh mục các từ viết tắt và thuật ngữ

STT	Từ viết tắt/ thuật ngữ	Cụm từ đầy đủ	Cụm từ tiếng Việt
1	Phage	Bacteriophage	Thực khuẩn thể
2	DNA	Deoxyribonucleic Acid	Axit deoxyribonucleic
3	BERT	Bidirectional Encoder Representations from Transformers	Biểu diễn bộ mã hóa hai chiều từ Transformer
4	CNN	Convolutional Neural Network	Mạng nơ-ron tích chập
5	DNABERT-2	DNA Bidirectional Encoder Representations from Transformers version 2	Mô hình BERT cho chuỗi DNA phiên bản 2
6	BPE	Byte Pair Encoding	Mã hóa cặp byte
7	NGS	Next-Generation Sequencing	Giải trình tự thế hệ mới
8	bp	Base pair	Cặp base
9	ORF	Open Reading Frame	Khung đọc mở
10	HMM	Hidden Markov Model	Mô hình Markov ẩn
11	SVM	Support Vector Machine	Máy vector hỗ trợ
12	RF	Random Forest	Rừng ngẫu nhiên
13	LSTM	Long Short-Term Memory	Bộ nhớ ngắn hạn dài
14	Attention	Attention Mechanism	Cơ chế chú ý
15	ReLU	Rectified Linear Unit	Đơn vị tuyến tính chỉnh lưu
16	Adam	Adaptive Moment Estimation	Ước lượng mô-men thích ứng
17	Dropout	Dropout Regularization	Kỹ thuật loại bỏ ngẫu nhiên
18	Batch Norm	Batch Normalization	Chuẩn hóa theo batch
19	Cross-entropy	Cross-entropy Loss	Hàm mất mát entropy chéo
20	Accuracy	Accuracy	Độ chính xác

21	Precision	Precision	Độ chính xác dương
22	Recall	Recall/Sensitivity	Độ nhạy
23	F1-Score	F1-Score	Điểm F1
24	Specificity	Specificity	Độ đặc hiệu
25	AUC	Area Under the Curve	Diện tích dưới đường cong
26	ROC	Receiver Operating Characteristic	Đặc tính hoạt động của bộ thu

Chương 1

Giới thiệu

1.1 Bối cảnh nghiên cứu

Thực khuẩn thể (bacteriophage), thường được gọi tắt là phage, là các virus có khả năng xâm nhiễm và nhân lên bên trong tế bào vi khuẩn. Được phát hiện độc lập bởi Frederick Twort năm 1915 và Félix d'Hérelle năm 1917, thực khuẩn thể được coi là dạng sống phong phú nhất trên Trái Đất với số lượng ước tính lên tới 10^{31} cá thể [1]. Chúng đóng vai trò quan trọng trong việc điều hòa quần thể vi khuẩn, duy trì cân bằng sinh thái vi sinh vật, và là động lực chính của quá trình chuyển gen ngang (horizontal gene transfer) giữa các vi khuẩn [2].

Thực khuẩn thể được phân loại thành hai nhóm chính dựa trên chiến lược nhân lên của chúng: thực khuẩn thể độc lực (virulent phage) và thực khuẩn thể ôn hòa (temperate phage) [3]. Thực khuẩn thể độc lực, còn được gọi là phage phân giải nghiêm ngặt (strictly lytic phage), chỉ thực hiện chu trình phân giải (lytic cycle). Trong chu trình này, phage xâm nhập vào tế bào vi khuẩn, chiếm đoạt bộ máy tổng hợp của tế bào chủ để sản xuất các virion con, và cuối cùng gây phá vỡ tế bào chủ để giải phóng các phage mới được tạo ra [4]. Ngược lại, thực khuẩn thể ôn hòa có khả năng thực hiện cả chu trình phân giải và chu trình lysogen. Trong chu trình lysogen, vật liệu di truyền của phage được tích hợp vào nhiễm sắc thể của vi khuẩn chủ dưới dạng prophage, nơi nó tồn tại ở trạng thái không hoạt động và nhân lên cùng với hệ gen của vi khuẩn qua nhiều thế hệ [5]. Prophage có thể được kích hoạt bởi các yếu tố môi trường như stress, tia UV, hoặc các tác nhân gây tổn thương DNA, chuyển sang chu trình phân giải [6].

Việc phân loại chính xác lối sống của thực khuẩn thể có ý nghĩa quan trọng trong cả nghiên cứu vi sinh vật học và ứng dụng y sinh học. Trong nghiên cứu hệ vi sinh vật (microbiome), việc xác định lối sống của phage giúp làm sáng tỏ các tương tác phức tạp giữa phage và vi khuẩn chủ, từ đó hiểu rõ hơn về vai trò sinh thái của phage trong các cộng đồng vi sinh vật [7]. Đặc biệt, trong bối cảnh kháng kháng sinh ngày càng gia tăng, liệu pháp phage (phage therapy) đang được xem xét như

một giải pháp thay thế đầy hứa hẹn cho kháng sinh truyền thống [8, 9]. Tuy nhiên, chỉ có thực khuẩn thể độc lực mới phù hợp cho liệu pháp phage, vì thực khuẩn thể ôn hòa có thể tích hợp vào hệ gen của vi khuẩn bệnh nguyên và tiềm ẩn nguy cơ truyền các gen độc lực hoặc gen kháng kháng sinh cho vi khuẩn chủ thông qua quá trình lysogenic conversion [10]. Do đó, việc phân loại chính xác lối sống của phage là bước tiên quyết để lựa chọn các ứng cử viên phage an toàn và hiệu quả cho các ứng dụng trị liệu.

Các phương pháp truyền thống để xác định lối sống của thực khuẩn thể dựa vào nuôi cấy trong phòng thí nghiệm và quan sát kiểu hình, bao gồm việc theo dõi sự hình thành mảng bám (plaque) trên thạch nuôi cấy vi khuẩn và phân tích khả năng lysogen hóa của phage [7]. Tuy nhiên, các phương pháp này tốn thời gian, đòi hỏi nhiều công sức, và quan trọng hơn, không thể áp dụng cho phần lớn các phage chưa được nuôi cấy được (unculturable phage) có trong các mẫu môi trường [7]. Theo ước tính, chỉ có khoảng 1% vi khuẩn trong tự nhiên có thể được nuôi cấy trong điều kiện phòng thí nghiệm, và tỷ lệ này còn thấp hơn đối với thực khuẩn thể. Những hạn chế này đã thúc đẩy sự phát triển của các phương pháp tính toán để dự đoán lối sống của phage trực tiếp từ dữ liệu trình tự gen.

Với sự phát triển mạnh mẽ của công nghệ giải trình tự thế hệ mới (next-generation sequencing - NGS), metagenomics đã trở thành công cụ quan trọng để nghiên cứu đa dạng sinh học của phage trong các môi trường tự nhiên mà không cần nuôi cấy [11, 12]. Trong phân tích metagenomic, hệ gen của phage thường được phục hồi dưới dạng các contig - các chuỗi liên tục được lắp ráp từ các đoạn đọc ngắn chồng lấp nhau [13, 14]. Tuy nhiên, các contig này thường có độ dài biến thiên lớn và bị phân mảnh do độ phủ giải trình tự không đồng đều, các hiện vật kỹ thuật, và các vùng gen lặp lại, khiến việc phát triển các công cụ có thể phân loại chính xác các chuỗi không hoàn chỉnh trở thành một thách thức tính toán quan trọng.

1.2 Vấn đề nghiên cứu

Các phương pháp tính toán để dự đoán lối sống của thực khuẩn thể phải đối mặt với bốn thách thức chính: hạn chế về dữ liệu, thiếu gen đánh dấu đặc trưng, độ dài đoạn DNA ngắn, và vấn đề tương đồng trình tự.

1.2.1 Hạn chế về dữ liệu huấn luyện

Cơ sở dữ liệu hệ gen thực khuẩn thể hiện có vẫn còn rất hạn chế so với sự đa dạng khổng lồ của phage trong tự nhiên. Mặc dù thực khuẩn thể là dạng sống phong phú nhất trên Trái Đất, phần lớn chúng chưa được phân lập và nghiên cứu đặc tính [12]. Sự thiếu hụt dữ liệu có nhãn (labeled data) này tạo ra thách thức lớn cho việc huấn luyện các mô hình học máy, đặc biệt là các mô hình học sâu đòi hỏi lượng dữ liệu lớn để đạt hiệu suất tốt. Hơn nữa, sự phân bố không cân bằng giữa các lớp (class imbalance) - với số lượng phage độc lực thường nhiều hơn phage ôn hòa trong các tập dữ liệu công khai - có thể dẫn đến mô hình thiên lệch (biased model) ưu tiên dự đoán lớp đa số.

1.2.2 Thiếu gen đánh dấu phổ quát

Không giống như vi khuẩn có gen 16S rRNA làm gen đánh dấu phổ quát (universal marker gene) cho phân loại phân loại học, thực khuẩn thể không có gen đánh dấu tương tự [11]. Sự thiếu vắng này khiến các phương pháp phân loại dựa trên gen đánh dấu (marker gene-based approaches) không khả thi đối với phage. Mặc dù một số gen như integrase, repressor, hoặc các gen liên quan đến chu trình lysogen có thể chỉ thị lối sống ôn hòa, nhưng chúng không phải lúc nào cũng hiện diện hoặc dễ dàng nhận diện trong các chuỗi gen ngắn và phân mảnh.

1.2.3 Thách thức với các đoạn DNA ngắn

Dữ liệu metagenomic thường chứa nhiều đoạn DNA ngắn bao gồm chỉ một phần gen hoặc các chuỗi gen không hoàn chỉnh, làm phức tạp các chiến lược phân loại dựa trên gen chức năng [15]. Các contig ngắn (dưới 1000 bp) đặc biệt khó phân loại vì:

- Chúng có thể không chứa đủ thông tin về gen để xác định lối sống
- Các công cụ dự đoán gen như Prodigal [16] có hiệu suất giảm đáng kể trên các đoạn ngắn hơn 200 bp [17]
- Bản chất phân mảnh của lắp ráp metagenomic có thể không chứa các chuỗi gen hoàn chỉnh cần thiết để nhận dạng protein chính xác

- Tín hiệu thống kê từ thành phần nucleotide (nucleotide composition) yếu hơn trên các chuỗi ngắn

Trong thực tế, phân tích metagenomic thường tạo ra các contig với phân bố độ dài rộng, từ vài trăm base pairs đến hàng chục kilobase pairs, tùy thuộc vào độ phủ giải trình tự (sequencing coverage), độ phức tạp của mẫu, và chất lượng lắp ráp. Các contig ngắn chiếm tỷ lệ đáng kể trong các tập dữ liệu metagenomic thực tế, do đó việc phát triển các phương pháp có thể xử lý hiệu quả các chuỗi ngắn là cần thiết cho ứng dụng thực tiễn.

1.2.4 Vấn đề tương đồng trình tự với vi khuẩn chủ

Thực khuẩn thể có thể chia sẻ các chuỗi gen với vi khuẩn chủ của chúng thông qua quá trình chuyển gen ngang (horizontal gene transfer), đặc biệt là trong trường hợp của prophage được tích hợp vào hệ gen vi khuẩn [18]. Sự tương đồng trình tự này có thể dẫn đến phân loại sai trong quá trình gán phân loại học (taxonomic assignment). Hơn nữa, các phage ôn hòa có thể mang theo các gen có nguồn gốc từ vi khuẩn, làm mờ ranh giới giữa trình tự phage và trình tự vi khuẩn. Điều này đặc biệt problematic khi phân tích các contig metagenomic, nơi không rõ liệu một contig cụ thể có phải là phage độc lập, prophage được tích hợp, hay một phần của hệ gen vi khuẩn chứa các yếu tố giống phage.

1.2.5 Phát biểu bài toán

Dựa trên các thách thức trên, bài toán dự đoán lối sống thực khuẩn thể có thể được phát biểu chính thức như sau: Cho một tập hợp các contig $\mathcal{S} = \{S_1, S_2, \ldots, S_n\}$ thu được từ giải trình tự và lắp ráp metagenomic, trong đó mỗi contig S_i có độ dài L_i base pairs, nhiệm vụ là dự đoán lối sống của phage là độc lực (lytic) hoặc ôn hòa (lysogenic).

Bài toán này có thể được mô hình hóa như một bài toán phân loại nhị phân (binary classification):

$$f : \mathcal{S} \to \{0, 1\} \tag{1.1}$$

trong đó f là hàm phân loại cần học, 0 đại diện cho lớp temperate (ôn hòa), và 1 đại diện cho lớp virulent (độc lực). Thách thức chính là thiết kế hàm f sao cho:

- Hoạt động hiệu quả trên các contig có độ dài biến thiên lớn (L_i từ 100 bp đến hàng nghìn bp)
- Không phụ thuộc vào các công cụ dự đoán gen bên ngoài có thể thất bại trên các chuỗi ngắn
- Có khả năng tổng quát hóa tốt trên các phage chưa được nhìn thấy (unseen phage) mặc dù dữ liệu huấn luyện hạn chế
- Phân biệt được các đặc trưng phage thực sự từ các chuỗi có nguồn gốc vi khuẩn

Các phương pháp hiện có đã đạt được tiến bộ đáng kể trong việc giải quyết bài toán này, nhưng vẫn còn những hạn chế quan trọng, đặc biệt là trong việc xử lý các contig ngắn và trung bình (100-1200 bp) - phạm vi độ dài phổ biến nhất trong các lắp ráp metagenomic thực tế.

1.3 Mục tiêu nghiên cứu

Mục tiêu chính của luận văn này là phát triển một phương pháp học sâu hiệu quả để phân loại lối sống thực khuẩn thể từ các contig metagenomic, đặc biệt tập trung vào việc cải thiện hiệu suất trên các đoạn DNA ngắn và trung bình. Cụ thể, luận văn hướng đến các mục tiêu sau:

1.3.1 Mục tiêu 1: Phát triển mô hình PhaBERT-CNN

Thiết kế và triển khai một kiến trúc học sâu lai (hybrid deep learning architecture) kết hợp mô hình nền tảng DNABERT-2 [19] đã được tiền huấn luyện với mạng nơ-ron tích chập đa tỷ lệ (multi-scale convolutional neural networks) để phân loại lối sống thực khuẩn thể. Mô hình đề xuất, được đặt tên là PhaBERT-CNN, nhằm tận dụng:

- **Học chuyển giao (Transfer learning):** Sử dụng kiến thức được mã hóa trong DNABERT-2 từ việc tiền huấn luyện trên corpus đa loài (multi-species corpus) để nắm bắt các mẫu tiến hóa ngữ cảnh trong chuỗi DNA của phage
- **Trích xuất đặc trưng đa tỷ lệ:** Sử dụng các nhánh CNN song song với nhiều trường tiếp nhận (receptive fields) để trích xuất các đặc trưng chuỗi cục bộ từ các embedding đã học
- **Tổng hợp thông tin toàn cục:** Áp dụng cơ chế pooling dựa trên attention để tổng hợp thông tin mức chuỗi toàn cục từ các biểu diễn transformer

1.3.2 Mục tiêu 2: Đánh giá hiệu suất trên nhiều nhóm độ dài contig

Tiến hành đánh giá toàn diện hiệu suất của PhaBERT-CNN trên bốn nhóm độ dài contig khác nhau:

- Nhóm A: 100-400 bp (contig rất ngắn)
- Nhóm B: 400-800 bp (contig ngắn)
- Nhóm C: 800-1200 bp (contig trung bình)
- Nhóm D: 1200-1800 bp (contig dài)

Phân tích chi tiết sự thay đổi hiệu suất theo độ dài contig để hiểu rõ điểm mạnh và hạn chế của phương pháp đề xuất trong các kịch bản metagenomic thực tế.

1.3.3 Mục tiêu 3: So sánh với các phương pháp tiên tiến

Thực hiện so sánh có hệ thống giữa PhaBERT-CNN và các phương pháp tiên tiến hiện có, bao gồm:

- **PhaTYP** [7]: Phương pháp dựa trên BERT với tokenization dựa trên protein
- **DeePhage** [3]: Phương pháp CNN trên chuỗi DNA được mã hóa one-hot
- **ProkBERT** [20]: Phương pháp dựa trên BERT với tokenization k-mer chồng lấp
- **DNABERT-2** [19]: Mô hình nền tảng genome với tokenization BPE

Phân tích ưu điểm và nhược điểm của từng phương pháp để làm rõ đóng góp của kiến trúc PhaBERT-CNN.

1.3.4 Mục tiêu 4: Phân tích tác động của các thành phần kiến trúc

Nghiên cứu đóng góp của các thành phần khác nhau trong kiến trúc PhaBERT-CNN thông qua:

- So sánh PhaBERT-CNN với DNABERT-2 baseline để đánh giá tác động của các lớp CNN và attention pooling
- Phân tích sự cân bằng giữa độ nhạy (sensitivity) và độ đặc hiệu (specificity) trên các nhóm độ dài khác nhau
- Đánh giá trade-off giữa độ chính xác và thời gian tính toán

1.3.5 Mục tiêu 5: Đề xuất chiến lược huấn luyện hiệu quả

Phát triển và đánh giá chiến lược tinh chỉnh hai giai đoạn (two-phase fine-tuning strategy):

- **Giai đoạn warm-up:** Đóng băng backbone DNABERT-2 và chỉ huấn luyện các lớp trích xuất đặc trưng task-specific
- **Giai đoạn tinh chỉnh đầy đủ:** Mở băng toàn bộ kiến trúc và áp dụng learning rate phân biệt (discriminative learning rates) cho các thành phần khác nhau

Chiến lược này nhằm đảm bảo sự hội tụ ổn định và thích ứng hiệu quả của mô hình tiền huấn luyện với nhiệm vụ phân loại lối sống phage.

1.3.6 Mục tiêu 6: Cung cấp phân tích và hướng dẫn thực tiễn

Cung cấp phân tích chi tiết về:

- Các trường hợp mô hình hoạt động tốt và các trường hợp thất bại
- Hạn chế của phương pháp đề xuất và các phương pháp hiện có

- Hướng dẫn thực tiễn cho việc lựa chọn phương pháp phù hợp dựa trên đặc điểm của dữ liệu metagenomic
- Hướng nghiên cứu tương lai để cải thiện hiệu suất phân loại lối sống phage

Thông qua việc đạt được các mục tiêu trên, luận văn kỳ vọng đóng góp vào lĩnh vực sinh tin học (bioinformatics) bằng cách cung cấp một công cụ mạnh mẽ và đáng tin cậy cho phân loại lối sống thực khuẩn thể từ dữ liệu metagenomic, đặc biệt là trên các contig ngắn và trung bình - phạm vi độ dài thách thức nhất trong phân tích metagenomic thực tế.

1.4 Đóng góp chính của luận văn

Luận văn này đóng góp vào lĩnh vực phân loại lối sống thực khuẩn thể và sinh tin học nói chung thông qua các đóng góp chính sau:

1.4.1 Kiến trúc PhaBERT-CNN mới

Đề xuất một kiến trúc học sâu lai mới kết hợp mô hình nền tảng genome DNABERT-2 với mạng nơ-ron tích chập đa tỷ lệ và cơ chế attention pooling. Kiến trúc này có những đặc điểm nổi bật:

- **Hoạt động trực tiếp trên chuỗi DNA thô:** Không phụ thuộc vào các công cụ dự đoán gen bên ngoài như Prodigal, khắc phục hạn chế của các phương pháp dựa trên protein như PhaTYP khi xử lý các contig ngắn
- **Tận dụng kiến thức tiền huấn luyện:** Sử dụng DNABERT-2 đã được tiền huấn luyện trên corpus genome đa loài, mang lại khả năng tổng quát hóa tốt hơn so với các mô hình huấn luyện từ đầu như DeePhage
- **Trích xuất đặc trưng đa tỷ lệ:** Sử dụng ba nhánh CNN song song với kernel sizes 3, 5, và 7 để nắm bắt các mẫu chuỗi ở nhiều mức độ trừu tượng - từ motif cục bộ tinh vi đến các domain chức năng rộng hơn
- **Tổng hợp thông tin toàn cục thông minh:** Áp dụng self-attention mechanism để tự động học trọng số quan trọng của các vị trí chuỗi khác nhau, cho phép mô hình tập trung vào các vùng genome có tính thông tin cao

1.4.2 Hiệu suất vượt trội trên contig ngắn và trung bình

Chứng minh hiệu suất vượt trội của PhaBERT-CNN trên các contig ngắn và trung bình (100-1200 bp) - phạm vi độ dài thách thức nhất và phổ biến nhất trong phân tích metagenomic:

- **Nhóm A (100-400 bp):** Đạt accuracy 81.59%, cải thiện 0.91-2.67% so với các phương pháp tiên tiến
- **Nhóm B (400-800 bp):** Đạt accuracy 87.91%, cải thiện 2.01-2.56% so với các baseline
- **Nhóm C (800-1200 bp):** Đạt accuracy 90.01%, cải thiện 1.14-5.98% so với các phương pháp khác
- **Nhóm D (1200-1800 bp):** Đạt accuracy 90.69%, cạnh tranh với PhaTYP (91.02%) và vượt trội so với DeePhage và ProkBERT

Đặc biệt, PhaBERT-CNN duy trì sự cân bằng tốt giữa sensitivity và specificity trên tất cả các nhóm độ dài, với sensitivity 82.00%-91.12% và specificity 80.15%-90.95%.

1.4.3 Chiến lược huấn luyện hai giai đoạn hiệu quả

Đề xuất và đánh giá chiến lược tinh chỉnh hai giai đoạn với learning rate phân biệt:

- **Giai đoạn warm-up (1 epoch):** Đóng băng DNABERT-2, huấn luyện chỉ các lớp task-specific với learning rate cao (2×10^{-3}) để khởi tạo các tham số ngẫu nhiên tương thích với biểu diễn DNABERT-2
- **Giai đoạn tinh chỉnh đầy đủ (tối đa 10 epochs):** Mở băng toàn bộ mô hình với learning rate phân biệt - DNABERT-2 sử dụng learning rate thấp (1×10^{-5}) để điều chỉnh nhẹ nhàng, trong khi các lớp task-specific sử dụng learning rate cao hơn 10 lần (1×10^{-4}) để tối ưu hóa mạnh mẽ

Chiến lược này đảm bảo sự hội tụ ổn định và thích ứng hiệu quả của mô hình tiền huấn luyện với nhiệm vụ downstream.

1.4.4 Đánh giá toàn diện và phân tích so sánh

Thực hiện đánh giá có hệ thống trên bốn nhóm độ dài contig với 5-fold cross-validation, so sánh với bốn phương pháp tiên tiến (DNABERT-2, PhaTYP, DeePhage, ProkBERT). Phân tích chi tiết:

- Ưu điểm và nhược điểm của từng phương pháp trên các phạm vi độ dài khác nhau
- Tác động của các thành phần kiến trúc (CNN branches, attention pooling) thông qua so sánh với DNABERT-2 baseline
- Trade-off giữa độ chính xác và thời gian tính toán
- Phân tích lỗi và các trường hợp thất bại

1.4.5 Giải quyết các hạn chế của phương pháp hiện có

PhaBERT-CNN khắc phục các hạn chế quan trọng của các công cụ hiện có:

- **Khắc phục hạn chế của PhaTYP:** Không phụ thuộc vào Prodigal để dự đoán protein, do đó hoạt động hiệu quả trên các contig ngắn thiếu các vùng mã hóa protein hoàn chỉnh
- **Vượt trội hơn DeePhage:** Tận dụng biểu diễn tiền huấn luyện thay vì huấn luyện từ đầu trên one-hot encoding, nắm bắt được các mẫu phức tạp từ dữ liệu genome đa dạng
- **Cải thiện so với DNABERT và ProkBERT:** Sử dụng DNABERT-2 với tokenization BPE hiệu quả, loại bỏ information leakage và kém hiệu quả tính toán của overlapping k-mer tokenization
- **Hiệu quả tính toán:** Mặc dù sử dụng mô hình nền tảng lớn, DNABERT-2 có hiệu suất tương đương Nucleotide Transformer 2.5B parameters nhưng nhỏ hơn 21 lần và nhanh hơn 92 lần trong quá trình tiền huấn luyện

1.4.6 Đóng góp về mặt phương pháp luận

Luận văn cung cấp một paradigm đầy hứa hẹn cho các nhiệm vụ phân tích chuỗi sinh học downstream:

- Chứng minh hiệu quả của việc kết hợp mô hình nền tảng genome tiền huấn luyện với các kiến trúc chuyên biệt task-specific
- Minh họa tầm quan trọng của chiến lược tinh chỉnh phù hợp khi thích ứng mô hình tiền huấn luyện
- Cung cấp insights về thiết kế kiến trúc lai (hybrid architecture) cho các bài toán phân loại chuỗi genome

Các đóng góp này không chỉ cải thiện hiệu suất phân loại lối sống thực khuẩn thể mà còn cung cấp nền tảng cho các nghiên cứu tương lai trong lĩnh vực sinh tin học và học sâu cho dữ liệu genome.

1.5 Phạm vi nghiên cứu

Luận văn tập trung vào phạm vi nghiên cứu cụ thể sau đây, với các giới hạn và giả định rõ ràng:

1.5.1 Phạm vi về bài toán

Phân loại nhị phân lối sống: Luận văn tập trung vào bài toán phân loại nhị phân (binary classification) để phân biệt thực khuẩn thể độc lực (virulent/lytic) và thực khuẩn thể ôn hòa (temperate/lysogenic). Các lối sống phức tạp hơn hoặc các trạng thái trung gian không được xem xét trong phạm vi nghiên cứu này.

Dữ liệu đầu vào: Phương pháp được thiết kế để hoạt động trên các contig DNA được lắp ráp từ dữ liệu metagenomic, không phải trên các đoạn đọc thô (raw reads). Các contig được giả định là đã được xác định là có nguồn gốc từ phage thông qua các công cụ nhận dạng phage như VirSorter, VIBRANT, hoặc các phương pháp tương tự.

1.5.2 Phạm vi về dữ liệu

Phạm vi độ dài contig: Nghiên cứu tập trung vào bốn nhóm độ dài contig:

- Nhóm A: 100-400 bp (contig rất ngắn)
- Nhóm B: 400-800 bp (contig ngắn)
- Nhóm C: 800-1200 bp (contig trung bình)
- Nhóm D: 1200-1800 bp (contig dài)

Các contig ngắn hơn 100 bp hoặc dài hơn 1800 bp không được đánh giá chi tiết trong nghiên cứu này, mặc dù phương pháp về mặt kỹ thuật có thể xử lý các chuỗi có độ dài tùy ý nhờ ALiBi positional encoding của DNABERT-2.

Nguồn dữ liệu: Tập dữ liệu được xây dựng từ hai nghiên cứu gần đây: DeePhage [3] và DeepPL [21], bao gồm 2,241 hệ gen phage hoàn chỉnh (707 temperate, 1,534 virulent). Các contig được tạo ra bằng phương pháp sliding window để mô phỏng kịch bản metagenomic thực tế.

Giới hạn về đa dạng sinh học: Mặc dù tập dữ liệu bao gồm nhiều họ phage khác nhau, nó vẫn chỉ đại diện cho một phần nhỏ của sự đa dạng phage trong tự nhiên. Hiệu suất của mô hình trên các phage thuộc các họ hiếm gặp hoặc chưa được nghiên cứu có thể khác với kết quả báo cáo.

1.5.3 Phạm vi về phương pháp

Mô hình nền tảng: Nghiên cứu sử dụng DNABERT-2 [19] làm mô hình nền tảng genome. Các mô hình nền tảng khác như Nucleotide Transformer [22], HyenaDNA, hoặc các biến thể BERT khác không được đánh giá trong phạm vi luận văn này.

Kiến trúc downstream: Luận văn tập trung vào kiến trúc lai kết hợp CNN đa tỷ lệ và attention pooling. Các kiến trúc downstream khác như RNN, LSTM, hoặc pure transformer decoder không được khảo sát chi tiết.

Phương pháp so sánh: Luận văn so sánh với bốn phương pháp tiên tiến: DNABERT-2, PhaTYP, DeePhage, và ProkBERT. Các phương pháp học máy truyền thống như PHACTS, PhageAI, và BACPHLIP không được đánh giá lại vì

đã được chứng minh có hiệu suất thấp hơn đáng kể trên dữ liệu contig trong các nghiên cứu trước.

1.5.4 Phạm vi về đánh giá

Metrics đánh giá: Luận văn sử dụng ba metrics chính: sensitivity (recall), specificity, và accuracy. Các metrics khác như precision, F1-score, AUC-ROC, hoặc Matthews correlation coefficient không được báo cáo chi tiết để duy trì tính nhất quán với các nghiên cứu trước đó.

Phương pháp validation: Sử dụng stratified 5-fold cross-validation để đánh giá hiệu suất. Không thực hiện đánh giá trên các tập dữ liệu độc lập bên ngoài (external validation) do hạn chế về tài nguyên và tính sẵn có của dữ liệu có nhãn chất lượng cao.

Phân tích ablation: Luận văn thực hiện phân tích so sánh giữa PhaBERT-CNN và DNABERT-2 baseline để đánh giá tác động của các thành phần CNN và attention. Các nghiên cứu ablation chi tiết hơn (ví dụ: loại bỏ từng nhánh CNN, thay đổi kernel sizes, so sánh các cơ chế attention khác nhau) không được thực hiện trong phạm vi luận văn này.

1.5.5 Phạm vi về triển khai

Framework và thư viện: Mô hình được triển khai sử dụng PyTorch và thư viện Transformers của Hugging Face. Các framework khác như TensorFlow/Keras không được xem xét.

Tài nguyên tính toán: Các thí nghiệm được thực hiện trên GPU NVIDIA RTX A4000 16GB. Phân tích về khả năng mở rộng (scalability) trên các cấu hình phần cứng khác hoặc tối ưu hóa cho triển khai trên CPU không được đề cập chi tiết.

Công cụ phần mềm: Luận văn không phát triển một công cụ phần mềm độc lập (standalone software tool) hoặc web server. Mã nguồn được cung cấp dưới dạng script Python để tái tạo kết quả nghiên cứu.

1.5.6 Giới hạn và giả định

Giả định về chất lượng dữ liệu: Các contig đầu vào được giả định là:

- Đã được xác định chính xác là có nguồn gốc từ phage
- Không chứa lỗi giải trình tự đáng kể
- Không bị ô nhiễm bởi DNA vi khuẩn chủ

Giới hạn về tổng quát hóa: Hiệu suất của mô hình được đánh giá trên dữ liệu mô phỏng (simulated data) được tạo từ hệ gen hoàn chỉnh. Hiệu suất trên dữ liệu metagenomic thực tế từ các môi trường đa dạng có thể khác biệt và cần được xác thực thêm.

Không xem xét các yếu tố sinh học phức tạp: Luận văn không xem xét các trường hợp đặc biệt như:

- Phage có khả năng chuyển đổi giữa các lối sống (lifestyle switching)
- Prophage bị đột biến mất chức năng (defective prophage)
- Phage với các cơ chế lysogen hóa không điển hình
- Tác động của môi trường chủ lên biểu hiện lối sống

Các giới hạn và giả định này được thiết lập để đảm bảo nghiên cứu tập trung và khả thi trong phạm vi luận văn thạc sĩ, đồng thời cung cấp nền tảng vững chắc cho các nghiên cứu mở rộng trong tương lai.

1.6 Bố cục luận văn

Luận văn được tổ chức thành năm chương với cấu trúc logic như sau:

Chương 1: Giới thiệu

Chương này giới thiệu bối cảnh nghiên cứu về thực khuẩn thể và tầm quan trọng của việc phân loại lối sống phage trong nghiên cứu vi sinh vật học và ứng dụng y sinh học. Chương trình bày các thách thức chính trong phân loại lối sống phage từ dữ liệu metagenomic, bao gồm hạn chế về dữ liệu, thiếu gen đánh dấu phổ quát, độ dài đoạn DNA ngắn, và vấn đề tương đồng trình tự. Chương cũng phát biểu rõ ràng bài toán nghiên cứu, mục tiêu, đóng góp chính, và phạm vi của luận văn.

Chương 2: Cơ sở lý thuyết

Chương này cung cấp nền tảng lý thuyết toàn diện cần thiết để hiểu phương pháp đề xuất. Chương bắt đầu với kiến thức sinh học về thực khuẩn thể, bao gồm phân loại, chu trình sống, và vai trò sinh thái. Tiếp theo, chương giới thiệu các khái niệm về metagenomics và giải trình tự thế hệ mới, giải thích cách các contig được tạo ra từ dữ liệu metagenomic. Phần tiếp theo trình bày các nền tảng học máy và học sâu, bao gồm mạng nơ-ron tích chập (CNN), kiến trúc transformer, và cơ chế attention. Chương dành phần quan trọng để giải thích chi tiết về BERT và các biến thể của nó cho dữ liệu genome (DNABERT, DNABERT-2), bao gồm masked language modeling, tokenization strategies, và transfer learning. Cuối cùng, chương tổng hợp các công trình liên quan về phân loại lối sống phage, phân tích ưu nhược điểm của các phương pháp học máy truyền thống (PHACTS, PhageAI, BACPHLIP) và các phương pháp học sâu hiện đại (DeePhage, PhaTYP, DeepPL, ProkBERT).

Chương 3: Phương pháp đề xuất

Chương này trình bày chi tiết phương pháp PhaBERT-CNN được đề xuất. Chương bắt đầu với tổng quan về kiến trúc tổng thể và động lực thiết kế. Tiếp theo, chương mô tả quy trình xây dựng tập dữ liệu, bao gồm nguồn dữ liệu, phương pháp tạo contig bằng sliding window, data augmentation thông qua reverse complement, và chiến lược xử lý mất cân bằng lớp. Chương sau đó giải thích chi tiết về mô hình nền tảng DNABERT-2, bao gồm chiến lược tokenization BPE, các cải tiến kiến trúc (ALiBi, Flash Attention), và corpus tiền huấn luyện đa loài. Phần cốt lõi của chương mô tả kiến trúc PhaBERT-CNN với hai nhánh trích xuất đặc trưng song song: (1) multi-scale CNN feature extractor với ba kernel sizes khác nhau, và (2) attention-based global feature extractor. Chương kết thúc bằng việc trình bày chiến lược huấn luyện hai giai đoạn với learning rate phân biệt, bao gồm các chi tiết về optimizer, learning rate schedule, và early stopping.

Chương 4: Thực nghiệm và đánh giá

Chương này trình bày thiết lập thí nghiệm toàn diện và kết quả đánh giá. Chương bắt đầu với mô tả chi tiết về môi trường thực nghiệm, bao gồm cấu hình phần cứng, phần mềm, và các hyperparameters. Tiếp theo, chương giải thích các metrics đánh giá (sensitivity, specificity, accuracy) và phương pháp validation (stratified 5-fold cross-validation). Chương trình bày kết quả thực nghiệm theo hai phần chính: (1) so sánh PhaBERT-CNN với DNABERT-2 baseline để đánh giá tác động của các thành phần CNN và attention, và (2) so sánh với các phương pháp tiên tiến

(PhaTYP, DeePhage, ProkBERT) trên bốn nhóm độ dài contig. Kết quả được trình bày thông qua các bảng số liệu chi tiết và biểu đồ trực quan. Chương cũng bao gồm phân tích chi tiết về hiệu suất trên từng nhóm độ dài, phân tích lỗi, và thảo luận về các trường hợp mô hình hoạt động tốt và các trường hợp thất bại. Cuối cùng, chương thảo luận về trade-off giữa độ chính xác và thời gian tính toán, cũng như các hạn chế của phương pháp đề xuất.

Chương 5: Kết luận

Chương cuối cùng tổng kết các kết quả chính của luận văn và đóng góp của nghiên cứu. Chương nhắc lại bài toán nghiên cứu và tóm tắt cách PhaBERT-CNN giải quyết các thách thức đã xác định. Chương tổng hợp các phát hiện quan trọng từ thực nghiệm, bao gồm hiệu suất vượt trội trên các contig ngắn và trung bình, sự cân bằng giữa sensitivity và specificity, và so sánh với các phương pháp hiện có. Chương thảo luận về các hạn chế của nghiên cứu, bao gồm phụ thuộc vào chất lượng dữ liệu đầu vào, nhu cầu về tài nguyên tính toán, và các giả định về dữ liệu. Cuối cùng, chương đề xuất các hướng nghiên cứu tương lai, bao gồm: (1) đánh giá trên dữ liệu metagenomic thực tế từ các môi trường đa dạng, (2) khảo sát các mô hình nền tảng genome khác, (3) phát triển các chiến lược xử lý mất cân bằng lớp hiệu quả hơn, (4) tối ưu hóa cho triển khai thực tế, và (5) mở rộng sang các nhiệm vụ phân loại phage khác như phân loại họ phage hoặc dự đoán vi khuẩn chủ.

Cấu trúc này được thiết kế để dẫn dắt người đọc từ động lực và nền tảng lý thuyết, qua phương pháp đề xuất chi tiết, đến đánh giá thực nghiệm toàn diện, và cuối cùng là kết luận và hướng phát triển. Mỗi chương xây dựng dựa trên các chương trước, tạo thành một câu chuyện nghiên cứu mạch lạc và logic.

Chương 2

Cơ sở lý thuyết

Chương này trình bày các kiến thức nền tảng cần thiết để hiểu phương pháp PhaBERT-CNN được đề xuất trong luận văn. Nội dung chương bao gồm cả kiến thức sinh học về thực khuẩn thể và các kỹ thuật học sâu hiện đại được áp dụng trong phân loại chuỗi genome. Chương được tổ chức thành các phần chính: Section 2.1 giới thiệu về sinh học thực khuẩn thể, chu trình sống, và cơ chế phân biệt lối sống virulent và temperate; Section 2.2 trình bày về metagenomics và các thách thức trong phân tích dữ liệu metagenomic; Section 2.3 và 2.4 giới thiệu các khái niệm cơ bản về học máy và học sâu; Section 2.5 mô tả kiến trúc mạng nơ-ron tích chập (CNN) và ứng dụng trong xử lý chuỗi; Section 2.6, 2.7, và 2.8 trình bày chi tiết về kiến trúc Transformer, mô hình BERT, và biến thể chuyên biệt cho chuỗi DNA (DNABERT); Section 2.9 giới thiệu DNABERT-2 - mô hình nền tảng genome thế hệ mới với BPE tokenization và ALiBi positional encoding; Section 2.10 giải thích về học chuyển giao và fine-tuning; cuối cùng, Section 2.11 tổng quan các nghiên cứu liên quan về phân loại lối sống thực khuẩn thể.

2.1 Thực khuẩn thể và phân loại lối sống

2.1.1 Giới thiệu về thực khuẩn thể

Thực khuẩn thể (bacteriophage), hay còn gọi tắt là phage, là các virus có khả năng xâm nhiễm và nhân lên bên trong tế bào vi khuẩn. Thuật ngữ "bacteriophage" có nguồn gốc từ tiếng Hy Lạp, trong đó "bacteria" có nghĩa là vi khuẩn và "phagein" có nghĩa là ăn, phản ánh khả năng tiêu diệt vi khuẩn của chúng. Thực khuẩn thể được phát hiện độc lập bởi hai nhà khoa học: Frederick Twort tại Anh năm 1915 và Félix d'Hérelle tại Pháp năm 1917, với d'Hérelle là người đặt tên "bacteriophage" cho các tác nhân này.

Thực khuẩn thể là dạng sống phong phú nhất trên Trái Đất, với số lượng ước tính lên tới 10^{31} cá thể [1]. Chúng có mặt ở hầu hết mọi môi trường có vi khuẩn, từ đại dương, đất, không khí, đến cơ thể động vật và thực vật. Trong môi trường biển,

mật độ phage có thể đạt tới 10^7 virion trên mililít nước, vượt xa số lượng vi khuẩn. Sự phong phú này phản ánh vai trò sinh thái quan trọng của phage trong việc điều hòa quần thể vi khuẩn và duy trì cân bằng sinh thái vi sinh vật.

2.1.2 Cấu trúc và thành phần của thực khuẩn thể

Về mặt cấu trúc, thực khuẩn thể bao gồm vật liệu di truyền (DNA hoặc RNA) được bao bọc bởi một lớp vỏ protein gọi là capsid. Capsid bảo vệ vật liệu di truyền khỏi các yếu tố môi trường và đóng vai trò trong quá trình nhận diện và gắn kết với tế bào vi khuẩn chủ. Phage có thể có nhiều hình dạng khác nhau, nhưng cấu trúc phổ biến nhất là dạng đầu-đuôi (head-tail morphology), bao gồm:

- **Đầu (head/capsid):** Chứa vật liệu di truyền, thường có hình dạng icosahedral (20 mặt)
- **Đuôi (tail):** Cấu trúc ống rỗng giúp phage gắn vào bề mặt vi khuẩn và tiêm vật liệu di truyền vào tế bào chủ
- **Sợi đuôi (tail fibers):** Các cấu trúc protein giúp nhận diện và gắn kết đặc hiệu với các thụ thể trên bề mặt vi khuẩn chủ
- **Đế đuôi (baseplate):** Cấu trúc phức tạp nối giữa đầu và đuôi, đóng vai trò trong việc xuyên thủng màng tế bào vi khuẩn

Bộ gen của phage có thể là DNA sợi đơn (ssDNA), DNA sợi đôi (dsDNA), RNA sợi đơn (ssRNA), hoặc RNA sợi đôi (dsRNA), với dsDNA là dạng phổ biến nhất. Kích thước hệ gen phage biến thiên rộng, từ vài nghìn base pairs (kb) đến hơn 500 kb, mã hóa từ vài gen đến hàng trăm gen.

2.1.3 Chu trình sống của thực khuẩn thể

Thực khuẩn thể được phân loại thành hai nhóm chính dựa trên chiến lược nhân lên: thực khuẩn thể độc lực (virulent phage) và thực khuẩn thể ôn hòa (temperate phage).

Chu trình phân giải (Lytic cycle)

Thực khuẩn thể độc lực chỉ thực hiện chu trình phân giải, bao gồm các bước sau:

1. **Hấp phụ (Adsorption):** Phage gắn kết đặc hiệu với các thụ thể trên bề mặt tế bào vi khuẩn chủ thông qua các protein nhận diện trên sợi đuôi
2. **Tiêm nhiễm (Injection):** Phage tiêm vật liệu di truyền của mình vào tế bào vi khuẩn, trong khi capsid protein thường ở lại bên ngoài
3. **Tổng hợp sinh học (Biosynthesis):** DNA của phage chiếm đoạt bộ máy tổng hợp của tế bào chủ, sử dụng ribosome, enzyme, và các thành phần tế bào để sao chép DNA phage và tổng hợp các protein cấu trúc của phage
4. **Lắp ráp (Assembly):** Các thành phần protein và DNA phage mới được tổng hợp tự lắp ráp thành các virion hoàn chỉnh bên trong tế bào vi khuẩn
5. **Phân giải (Lysis):** Phage tổng hợp các enzyme phân giải (như lysozyme) để phá vỡ thành tế bào vi khuẩn, giải phóng hàng chục đến hàng trăm virion con để xâm nhiễm các tế bào vi khuẩn khác

Chu trình phân giải thường hoàn thành trong vòng 20-40 phút, tùy thuộc vào loại phage và điều kiện môi trường.

Chu trình lysogen (Lysogenic cycle)

Thực khuẩn thể ôn hòa có khả năng thực hiện cả chu trình phân giải và chu trình lysogen. Trong chu trình lysogen:

1. **Tích hợp (Integration):** Sau khi tiêm vào tế bào chủ, DNA của phage được tích hợp vào nhiễm sắc thể của vi khuẩn thông qua quá trình tái tổ hợp đặc hiệu vị trí (site-specific recombination), được xúc tác bởi enzyme integrase
2. **Trạng thái prophage:** DNA phage được tích hợp (gọi là prophage) tồn tại ở trạng thái không hoạt động, được nhân lên cùng với hệ gen vi khuẩn qua nhiều thế hệ. Prophage được duy trì ở trạng thái im lặng nhờ protein repressor ngăn chặn biểu hiện các gen phân giải

3. **Cảm ứng (Induction):** Khi gặp các điều kiện stress như tia UV, nhiệt độ cao, hóa chất gây tổn thương DNA, hoặc thiếu dinh dưỡng, prophage có thể được kích hoạt. Protein repressor bị vô hiệu hóa, dẫn đến việc cắt prophage ra khỏi nhiễm sắc thể vi khuẩn (excision) và chuyển sang chu trình phân giải

Quyết định giữa chu trình phân giải và lysogen phụ thuộc vào nhiều yếu tố, bao gồm trạng thái sinh lý của tế bào chủ, mật độ vi khuẩn, và các tín hiệu môi trường. Cơ chế phân tử điều khiển quyết định này thường liên quan đến sự cạnh tranh giữa các protein điều hòa như CI repressor (ưu tiên lysogen) và Cro protein (ưu tiên phân giải) trong phage lambda.

2.1.4 Vai trò sinh thái và ứng dụng

Vai trò trong sinh thái vi sinh vật

Thực khuẩn thể đóng vai trò quan trọng trong sinh thái vi sinh vật:

- **Điều hòa quần thể vi khuẩn:** Phage kiểm soát mật độ và cấu trúc quần thể vi khuẩn thông qua quá trình "kill the winner", trong đó các chủng vi khuẩn chiếm ưu thế bị phage tiêu diệt, tạo cơ hội cho các chủng khác phát triển [2]
- **Chuyển gen ngang:** Phage là động lực chính của horizontal gene transfer giữa vi khuẩn thông qua transduction, góp phần vào sự tiến hóa và đa dạng di truyền của vi khuẩn
- **Chu trình dinh dưỡng:** Phage giải phóng các chất dinh dưỡng từ tế bào vi khuẩn bị phân giải, đóng góp vào chu trình carbon và các nguyên tố khác trong hệ sinh thái
- **Lysogenic conversion:** Prophage có thể mang các gen mã hóa yếu tố độc lực hoặc kháng kháng sinh, thay đổi kiểu hình của vi khuẩn chủ

Ứng dụng trong y sinh học

Việc phân loại chính xác lối sống phage có ý nghĩa quan trọng cho các ứng dụng y sinh học:

- **Liệu pháp phage (Phage therapy):** Sử dụng phage để điều trị nhiễm trùng vi khuẩn, đặc biệt là các vi khuẩn kháng kháng sinh [8, 9]. Chỉ có phage độc lực mới phù hợp cho liệu pháp vì chúng tiêu diệt vi khuẩn một cách hiệu quả mà không tích hợp vào hệ gen chủ
- **An toàn sinh học:** Phage ôn hòa có thể truyền các gen độc lực hoặc kháng kháng sinh cho vi khuẩn bệnh nguyên thông qua lysogenic conversion, do đó cần được loại trừ khỏi các ứng dụng trị liệu [10]
- **Kiểm soát thực phẩm:** Phage được sử dụng để kiểm soát vi khuẩn gây bệnh trong thực phẩm, với yêu cầu nghiêm ngặt về việc sử dụng chỉ phage độc lực
- **Công nghệ sinh học:** Phage được sử dụng trong phage display, vaccine development, và drug delivery, với các yêu cầu khác nhau về lối sống phage tùy thuộc vào ứng dụng cụ thể

Do đó, việc phát triển các phương pháp tính toán chính xác và hiệu quả để phân loại lối sống phage từ dữ liệu trình tự gen là cần thiết để hỗ trợ cả nghiên cứu cơ bản về sinh thái vi sinh vật và các ứng dụng thực tiễn trong y học và công nghệ sinh học.

2.2 Metagenomics và giải trình tự thế hệ mới

2.2.1 Giới thiệu về metagenomics

Metagenomics là phương pháp nghiên cứu vật liệu di truyền được thu thập trực tiếp từ các mẫu môi trường, cho phép phân tích toàn bộ cộng đồng vi sinh vật mà không cần nuôi cấy từng loài riêng lẻ [11]. Thuật ngữ "metagenome" được đặt ra bởi Jo Handelsman và cộng sự năm 1998, đề cập đến tập hợp tất cả các hệ gen (genomes) có trong một mẫu môi trường. Phương pháp này đã cách mạng hóa nghiên cứu vi sinh vật học bằng cách cho phép nghiên cứu "dark matter" của thế giới vi sinh vật - phần lớn các vi sinh vật không thể nuôi cấy được trong phòng thí nghiệm.

Theo ước tính, chỉ có khoảng 1% vi khuẩn trong tự nhiên có thể được nuôi cấy trong điều kiện phòng thí nghiệm, và tỷ lệ này còn thấp hơn đối với thực khuẩn thể. Metagenomics khắc phục hạn chế này bằng cách trực tiếp giải trình tự DNA

từ mẫu môi trường, cung cấp cái nhìn toàn diện về đa dạng sinh học, cấu trúc cộng đồng, và tiềm năng chức năng của hệ vi sinh vật.

2.2.2 Công nghệ giải trình tự thế hệ mới

Nguyên lý hoạt động

Công nghệ giải trình tự thế hệ mới (Next-Generation Sequencing - NGS) đã thay thế phương pháp Sanger sequencing truyền thống nhờ khả năng tạo ra hàng triệu đến hàng tỷ đoạn đọc (reads) trong một lần chạy duy nhất. Các nền tảng NGS phổ biến bao gồm:

- **Illumina:** Sử dụng sequencing by synthesis với fluorescent reversible terminators, tạo ra đoạn đọc ngắn (75-300 bp) với độ chính xác cao (>99%) và throughput lớn
- **PacBio (Pacific Biosciences):** Sử dụng single-molecule real-time (SMRT) sequencing, tạo ra đoạn đọc dài (10-30 kb) nhưng có error rate cao hơn
- **Oxford Nanopore:** Sử dụng nanopore sequencing, có thể tạo ra đoạn đọc cực dài (>100 kb) với khả năng sequencing real-time

Illumina là nền tảng phổ biến nhất cho metagenomics do chi phí thấp, throughput cao, và độ chính xác tốt, mặc dù độ dài đoạn đọc ngắn hơn so với các công nghệ long-read.

Quy trình phân tích metagenomic

Quy trình phân tích metagenomic điển hình bao gồm các bước sau:

1. **Thu thập và chuẩn bị mẫu:** DNA tổng số được trích xuất từ mẫu môi trường (đất, nước, mẫu sinh học, v.v.)
2. **Xây dựng thư viện (Library preparation):** DNA được phân mảnh và gắn adapter để chuẩn bị cho giải trình tự
3. **Giải trình tự (Sequencing):** Tạo ra hàng triệu đoạn đọc ngắn từ DNA trong mẫu

4. **Kiểm soát chất lượng (Quality control):** Loại bỏ các đoạn đọc chất lượng thấp, adapter sequences, và contamination
5. **Lắp ráp (Assembly):** Ghép các đoạn đọc chồng lấp nhau thành các chuỗi liên tục dài hơn gọi là contigs
6. **Phân tích downstream:** Bao gồm taxonomic classification, gene prediction, functional annotation, và comparative analysis

2.2.3 Lắp ráp metagenomic và contig

Thách thức trong lắp ráp metagenomic

Lắp ráp metagenomic phức tạp hơn nhiều so với lắp ráp hệ gen đơn loài do:

- **Độ phức tạp cao:** Mẫu metagenomic chứa DNA từ hàng trăm đến hàng nghìn loài khác nhau với độ phong phú biến thiên lớn
- **Độ phủ không đồng đều:** Các loài phong phú có độ phủ giải trình tự cao, trong khi các loài hiếm có độ phủ thấp, dẫn đến chất lượng lắp ráp không đồng nhất
- **Vùng lặp lại:** Các chuỗi tương đồng giữa các loài khác nhau hoặc các vùng lặp lại trong cùng một hệ gen gây khó khăn cho việc lắp ráp chính xác
- **Chimerism:** Có thể tạo ra các contig chimeric kết hợp DNA từ nhiều loài khác nhau
- **Strain variation:** Sự hiện diện của nhiều chủng (strains) của cùng một loài với các biến thể di truyền nhỏ làm phức tạp quá trình lắp ráp

Contig và đặc điểm

Contig (từ "contiguous") là một chuỗi DNA liên tục được lắp ráp từ các đoạn đọc chồng lấp nhau [13, 14]. Trong phân tích metagenomic, contigs có các đặc điểm sau:

- **Phân bố độ dài rộng:** Độ dài contig biến thiên từ vài trăm base pairs đến hàng trăm kilobase pairs, tùy thuộc vào độ phủ giải trình tự, độ phức tạp của mẫu, và thuật toán lắp ráp
- **Chất lượng không đồng nhất:** Contigs từ các loài phong phú thường dài hơn và chính xác hơn so với contigs từ các loài hiếm
- **Tính không hoàn chỉnh:** Hầu hết contigs chỉ đại diện cho các đoạn của hệ gen, không phải hệ gen hoàn chỉnh, do đó có thể thiếu các gen quan trọng hoặc chỉ chứa các phần của gen
- **Độ phủ (Coverage):** Số lần trung bình mỗi vị trí nucleotide được đọc, là chỉ số quan trọng về độ tin cậy của contig

Phân bố độ dài contig trong thực tế

Trong các nghiên cứu metagenomic thực tế, phân bố độ dài contig thường có dạng long-tail distribution:

- **Contig ngắn (100-1000 bp):** Chiếm tỷ lệ lớn về số lượng, thường đến từ các loài hiếm hoặc các vùng khó lắp ráp
- **Contig trung bình (1-10 kb):** Đại diện cho phần lớn dữ liệu về tổng số base pairs
- **Contig dài (>10 kb):** Ít về số lượng nhưng có giá trị cao cho phân tích, thường đến từ các loài phong phú với độ phủ tốt

Các contig ngắn (100-1200 bp) đặc biệt thách thức cho phân tích vì:

- Có thể không chứa gen hoàn chỉnh
- Tín hiệu thống kê yếu cho các phương pháp dựa trên thành phần nucleotide
- Các công cụ dự đoán gen có hiệu suất giảm
- Khó phân biệt với DNA contamination hoặc artifacts

2.2.4 Ứng dụng của metagenomics trong nghiên cứu phage

Metagenomics đã mở ra những cơ hội mới cho nghiên cứu thực khuẩn thể:

- **Khám phá đa dạng phage:** Phát hiện các phage mới và hiếm gặp không thể nuôi cấy được [12]
- **Phân tích cộng đồng phage:** Nghiên cứu cấu trúc và động lực của cộng đồng phage trong các môi trường khác nhau
- **Tương tác phage-host:** Suy luận mối quan hệ giữa phage và vi khuẩn chủ dựa trên dữ liệu metagenomic
- **Phân tích chức năng:** Xác định các gen chức năng và tiềm năng sinh học của phage
- **Prophage identification:** Phát hiện prophage được tích hợp trong hệ gen vi khuẩn

Tuy nhiên, việc phân tích phage từ dữ liệu metagenomic đòi hỏi các công cụ tính toán chuyên biệt có khả năng xử lý các contig ngắn và phân mảnh - đây chính là động lực cho việc phát triển các phương pháp học sâu như PhaBERT-CNN để phân loại lối sống phage từ các contig metagenomic.

2.3 Học máy cho phân tích dữ liệu sinh học

2.3.1 Giới thiệu về học máy

Học máy (Machine Learning) là một nhánh của trí tuệ nhân tạo tập trung vào việc phát triển các thuật toán cho phép máy tính học từ dữ liệu và cải thiện hiệu suất thông qua kinh nghiệm mà không cần được lập trình rõ ràng. Trong bối cảnh phân tích dữ liệu sinh học, học máy đã trở thành công cụ không thể thiếu để xử lý khối lượng dữ liệu khổng lồ từ các công nghệ sinh học hiện đại.

2.3.2 Các loại học máy

Học có giám sát (Supervised Learning)

Học có giám sát là paradigm học máy trong đó mô hình được huấn luyện trên tập dữ liệu có nhãn (labeled data). Mục tiêu là học một hàm ánh xạ $f : X \to Y$ từ không gian đầu vào X sang không gian đầu ra Y. Bài toán phân loại lối sống thực khuẩn thể là một bài toán học có giám sát điển hình, trong đó:

- **Input** X: Chuỗi DNA của contig phage
- **Output** Y: Nhãn lối sống (virulent hoặc temperate)
- **Training data**: Tập hợp các cặp (x_i, y_i) với nhãn đã biết

Các thuật toán học có giám sát phổ biến bao gồm:

- Support Vector Machines (SVM)
- Random Forest
- Gradient Boosting
- Neural Networks

Học không giám sát (Unsupervised Learning)

Học không giám sát làm việc với dữ liệu không có nhãn, tìm kiếm các cấu trúc ẩn hoặc patterns trong dữ liệu. Các phương pháp phổ biến bao gồm clustering (K-means, hierarchical clustering) và dimensionality reduction (PCA, t-SNE).

Học chuyển giao (Transfer Learning)

Học chuyển giao là paradigm trong đó kiến thức học được từ một nhiệm vụ (source task) được áp dụng cho một nhiệm vụ khác nhưng liên quan (target task). Đây là nền tảng của phương pháp PhaBERT-CNN, trong đó mô hình DNABERT-2 được tiền huấn luyện trên corpus genome đa loài sau đó được tinh chỉnh cho nhiệm vụ phân loại lối sống phage.

2.3.3 Các khái niệm cơ bản

Overfitting và Underfitting

Overfitting xảy ra khi mô hình học quá tốt trên dữ liệu huấn luyện, bao gồm cả noise, dẫn đến hiệu suất kém trên dữ liệu mới. **Underfitting** xảy ra khi mô hình quá đơn giản và không nắm bắt được patterns quan trọng trong dữ liệu.

Các kỹ thuật regularization để giảm overfitting:

- **L1/L2 regularization**: Thêm penalty term vào loss function
- **Dropout**: Ngẫu nhiên tắt một số neurons trong quá trình huấn luyện
- **Early stopping**: Dừng huấn luyện khi hiệu suất trên validation set bắt đầu giảm
- **Data augmentation**: Tăng cường dữ liệu huấn luyện

Cross-validation

Cross-validation là kỹ thuật đánh giá mô hình bằng cách chia dữ liệu thành nhiều folds, luân phiên sử dụng mỗi fold làm validation set trong khi các folds còn lại làm training set. Stratified k-fold cross-validation đảm bảo tỷ lệ các lớp được duy trì trong mỗi fold, đặc biệt quan trọng khi xử lý dữ liệu mất cân bằng.

Metrics đánh giá

Đối với bài toán phân loại nhị phân như phân loại lối sống phage, các metrics quan trọng bao gồm:

- **Sensitivity (Recall)**: Sn $= \frac{TP}{TP+FN}$ - Tỷ lệ phage virulent được dự đoán đúng
- **Specificity**: Sp $= \frac{TN}{TN+FP}$ - Tỷ lệ phage temperate được dự đoán đúng
- **Accuracy**: Acc $= \frac{TP+TN}{TP+TN+FP+FN}$ - Tỷ lệ dự đoán đúng tổng thể
- **Precision**: Prec $= \frac{TP}{TP+FP}$ - Tỷ lệ dự đoán virulent chính xác
- **F1-Score**: $F1 = 2 \times \frac{\text{Precision} \times \text{Recall}}{\text{Precision} + \text{Recall}}$ - Trung bình điều hòa của precision và recall

trong đó TP (True Positive), TN (True Negative), FP (False Positive), FN (False Negative) là các giá trị từ confusion matrix.

2.3.4 Học máy cho phân tích chuỗi sinh học

Feature engineering cho dữ liệu DNA

Các phương pháp học máy truyền thống đòi hỏi feature engineering thủ công để chuyển đổi chuỗi DNA thành vector số. Các phương pháp phổ biến bao gồm:

- **Nucleotide composition**: Tần suất của từng nucleotide (A, T, G, C)
- **k-mer frequency**: Tần suất của tất cả các chuỗi con độ dài k
- **Codon usage**: Tần suất sử dụng các codon khác nhau
- **GC content**: Tỷ lệ phần trăm của G và C trong chuỗi
- **Protein-based features**: Đặc trưng từ các protein được dự đoán

Hạn chế của phương pháp truyền thống

Các phương pháp học máy truyền thống có những hạn chế khi áp dụng cho phân loại lối sống phage:

- **Feature engineering thủ công**: Đòi hỏi kiến thức chuyên môn và có thể bỏ lỡ các patterns quan trọng
- **Phụ thuộc vào công cụ bên ngoài**: Các features dựa trên protein yêu cầu gene prediction chính xác
- **Khó xử lý chuỗi ngắn**: Tín hiệu thống kê yếu trên các contig ngắn
- **Không nắm bắt được long-range dependencies**: Các features cục bộ không thể mô hình hóa mối quan hệ xa trong chuỗi

Những hạn chế này đã thúc đẩy sự phát triển của các phương pháp học sâu có khả năng tự động học representations từ dữ liệu thô.

2.4 Học sâu và mạng nơ-ron

2.4.1 Giới thiệu về học sâu

Học sâu (Deep Learning) là một nhánh của học máy sử dụng mạng nơ-ron nhân tạo với nhiều lớp (deep neural networks) để học các biểu diễn phân cấp của dữ liệu. Khác với học máy truyền thống đòi hỏi feature engineering thủ công, học sâu có khả năng tự động học các features từ dữ liệu thô thông qua quá trình huấn luyện end-to-end.

2.4.2 Mạng nơ-ron nhân tạo

Perceptron và Multi-layer Perceptron

Perceptron là đơn vị tính toán cơ bản của mạng nơ-ron, thực hiện phép biến đổi tuyến tính theo sau bởi hàm kích hoạt phi tuyến:

$$y = f\left(\sum_{i=1}^{n} w_i x_i + b\right) = f(\mathbf{w}^T\mathbf{x} + b) \tag{2.1}$$

trong đó $\mathbf{x}$ là vector đầu vào, $\mathbf{w}$ là vector trọng số, b là bias, và f là hàm kích hoạt.

Multi-layer Perceptron (MLP) xếp chồng nhiều lớp perceptrons, cho phép học các hàm phức tạp:

$$\mathbf{h}^{(l)} = f^{(l)}\left(\mathbf{W}^{(l)}\mathbf{h}^{(l-1)} + \mathbf{b}^{(l)}\right) \tag{2.2}$$

với $\mathbf{h}^{(l)}$ là hidden state ở lớp l, $\mathbf{W}^{(l)}$ là ma trận trọng số, và $f^{(l)}$ là hàm kích hoạt.

Hàm kích hoạt

Các hàm kích hoạt phổ biến:

- **ReLU**: $f(x) = \max(0, x)$ - Đơn giản, hiệu quả, giảm vanishing gradient
- **Sigmoid**: $f(x) = \frac{1}{1+e^{-x}}$ - Đầu ra trong khoảng (0,1)
- **Tanh**: $f(x) = \frac{e^x - e^{-x}}{e^x + e^{-x}}$ - Đầu ra trong khoảng (-1,1)

- **GELU**: $f(x) = x \cdot \Phi(x)$ - Sử dụng trong BERT và transformers

2.4.3 Backpropagation và tối ưu hóa

Backpropagation

Backpropagation là thuật toán tính gradient của loss function theo các tham số mạng bằng chain rule:

$$\frac{\partial \mathcal{L}}{\partial w_{ij}^{(l)}} = \frac{\partial \mathcal{L}}{\partial h_j^{(l)}} \cdot \frac{\partial h_j^{(l)}}{\partial z_j^{(l)}} \cdot \frac{\partial z_j^{(l)}}{\partial w_{ij}^{(l)}} \tag{2.3}$$

Gradient Descent và biến thể

Stochastic Gradient Descent (SGD):

$$\mathbf{w}_{t+1} = \mathbf{w}_t - \eta \nabla_{\mathbf{w}} \mathcal{L}(\mathbf{w}_t) \tag{2.4}$$

Adam Optimizer: Kết hợp momentum và adaptive learning rates:

$$\mathbf{m}_t = \beta_1 \mathbf{m}_{t-1} + (1 - \beta_1) \nabla_{\mathbf{w}} \mathcal{L}(\mathbf{w}_t) \tag{2.5}$$

$$\mathbf{v}_t = \beta_2 \mathbf{v}_{t-1} + (1 - \beta_2)(\nabla_{\mathbf{w}} \mathcal{L}(\mathbf{w}_t))^2 \tag{2.6}$$

$$\mathbf{w}_{t+1} = \mathbf{w}_t - \eta \frac{\hat{\mathbf{m}}_t}{\sqrt{\hat{\mathbf{v}}_t} + \epsilon} \tag{2.7}$$

AdamW: Biến thể của Adam với weight decay được tách riêng [23], được sử dụng trong PhaBERT-CNN.

2.4.4 Regularization techniques

Dropout

Dropout ngẫu nhiên tắt một tỷ lệ neurons trong quá trình huấn luyện:

$$\mathbf{h}_{\text{dropout}} = \mathbf{m} \odot \mathbf{h} \tag{2.8}$$

với $\mathbf{m} \sim \text{Bernoulli}(p)$ là mask vector. Dropout giảm overfitting bằng cách ngăn co-adaptation giữa các neurons.

Batch Normalization

Batch Normalization chuẩn hóa activations trong mỗi mini-batch:

$$\hat{\mathbf{x}} = \frac{\mathbf{x} - \mathbb{E}[\mathbf{x}]}{\sqrt{\mathrm{Var}[\mathbf{x}] + \epsilon}} \tag{2.9}$$

giúp ổn định quá trình huấn luyện và cho phép sử dụng learning rate cao hơn.

Layer Normalization

Layer Normalization chuẩn hóa theo chiều features thay vì batch dimension, phù hợp hơn cho sequence models:

$$\mathrm{LayerNorm}(\mathbf{x}) = \gamma \odot \frac{\mathbf{x} - \mu}{\sqrt{\sigma^2 + \epsilon}} + \beta \tag{2.10}$$

với μ và σ^2 được tính trên chiều features.

2.4.5 Loss functions

Binary Cross-Entropy Loss

Cho bài toán phân loại nhị phân như phân loại lối sống phage:

$$\mathcal{L}_{\mathrm{BCE}} = -\frac{1}{N} \sum_{i=1}^{N} [y_i \log(\hat{y}_i) + (1 - y_i) \log(1 - \hat{y}_i)] \tag{2.11}$$

với $y_i \in \{0, 1\}$ là nhãn thực và $\hat{y}_i \in (0, 1)$ là xác suất dự đoán.

2.4.6 Ưu điểm của học sâu cho dữ liệu sinh học

- **Automatic feature learning**: Không cần feature engineering thủ công
- **Hierarchical representations**: Học các features từ low-level đến high-level
- **End-to-end learning**: Tối ưu hóa toàn bộ pipeline cùng lúc
- **Transfer learning**: Tận dụng kiến thức từ các nhiệm vụ liên quan
- **Scalability**: Hiệu suất cải thiện với lượng dữ liệu lớn

2.5 Mạng nơ-ron tích chập

2.5.1 Giới thiệu về CNN

Mạng nơ-ron tích chập (Convolutional Neural Network - CNN) là một kiến trúc học sâu được thiết kế đặc biệt để xử lý dữ liệu có cấu trúc lưới (grid-like structure) như hình ảnh (2D grid) hoặc chuỗi (1D grid). CNN đã đạt được thành công vượt bậc trong computer vision và ngày càng được áp dụng rộng rãi cho phân tích chuỗi sinh học.

2.5.2 Phép tích chập (Convolution)

Convolution 1D cho chuỗi

Đối với chuỗi đầu vào $\mathbf{x} \in \mathbb{R}^{L \times d}$ với độ dài L và số chiều d, phép tích chập 1D với kernel $\mathbf{w} \in \mathbb{R}^{k \times d \times c}$ tạo ra feature map:

$$(\mathbf{x} * \mathbf{w})_i = \sum_{j=0}^{k-1} \sum_{m=0}^{d-1} x_{i+j,m} \cdot w_{j,m} \tag{2.12}$$

trong đó k là kernel size (receptive field), d là input channels, và c là output channels.

Receptive field

Receptive field là vùng đầu vào mà một neuron có thể "nhìn thấy". Với kernel size k, mỗi neuron trong feature map có receptive field là k positions liên tiếp trong chuỗi đầu vào. Xếp chồng nhiều lớp convolution mở rộng receptive field theo cấp số nhân, cho phép nắm bắt long-range dependencies.

2.5.3 Các thành phần của CNN

Pooling layers

Pooling giảm kích thước spatial của feature maps:

- **Max Pooling**: $y_i = \max_{j \in \text{window}_i} x_j$ - Chọn giá trị lớn nhất

- **Average Pooling**: $y_i = \frac{1}{k}\sum_{j\in\text{window}_i} x_j$ - Lấy trung bình
- **Adaptive Pooling**: Tự động điều chỉnh window size để tạo output có kích thước cố định

Stride và Padding

Stride s xác định bước nhảy của kernel:

$$L_{\text{out}} = \left\lfloor \frac{L_{\text{in}} - k}{s} \right\rfloor + 1 \tag{2.13}$$

Padding p thêm zeros vào đầu/cuối chuỗi để kiểm soát kích thước output:

$$L_{\text{out}} = \left\lfloor \frac{L_{\text{in}} + 2p - k}{s} \right\rfloor + 1 \tag{2.14}$$

2.5.4 Multi-scale CNN

Inception architecture

Kiến trúc Inception [24] sử dụng nhiều nhánh convolution song song với kernel sizes khác nhau để nắm bắt patterns ở nhiều tỷ lệ:

$$\mathbf{h}_{\text{multi-scale}} = \text{Concat}[\mathbf{h}_3, \mathbf{h}_5, \mathbf{h}_7] \tag{2.15}$$

với $\mathbf{h}_k$ là feature map từ convolution với kernel size k.

PhaBERT-CNN áp dụng ý tưởng này với ba nhánh CNN song song (kernel sizes 3, 5, 7) để trích xuất đặc trưng đa tỷ lệ từ DNABERT-2 embeddings.

2.5.5 CNN cho phân tích chuỗi sinh học

Ưu điểm

- **Local pattern detection**: Hiệu quả trong việc phát hiện motifs và patterns cục bộ
- **Parameter sharing**: Cùng một kernel được áp dụng trên toàn bộ chuỗi, giảm số tham số

- **Translation invariance**: Phát hiện patterns bất kể vị trí trong chuỗi
- **Computational efficiency**: Nhanh hơn RNN nhờ tính song song

Ứng dụng trong genomics

CNN đã được áp dụng thành công cho nhiều bài toán genomics:

- Dự đoán binding sites của transcription factors
- Phân loại chuỗi DNA/protein
- Dự đoán cấu trúc RNA
- Phân tích variant effects

CNN trên pre-trained embeddings

Trong PhaBERT-CNN, CNN không hoạt động trực tiếp trên chuỗi DNA thô mà trên DNABERT-2 embeddings. Cách tiếp cận này có ưu điểm:

- **Rich representations**: Embeddings đã mã hóa thông tin ngữ cảnh từ transformer
- **Task-specific adaptation**: CNN học các transformations phù hợp với nhiệm vụ phân loại lối sống
- **Multi-scale feature extraction**: Các kernel sizes khác nhau nắm bắt patterns từ local motifs đến broader functional domains

Cách tiếp cận tương tự đã thành công trong NLP, nơi CNN được áp dụng trên word embeddings hoặc contextualized representations [25, 26].

2.6 Kiến trúc Transformer

2.6.1 Giới thiệu

Transformer là kiến trúc mạng nơ-ron được giới thiệu bởi Vaswani et al. năm 2017 trong bài báo "Attention is All You Need" [27]. Khác với RNN và LSTM xử lý

chuỗi tuần tự, Transformer sử dụng cơ chế self-attention để xử lý toàn bộ chuỗi song song, cho phép nắm bắt long-range dependencies hiệu quả hơn.

2.6.2 Self-Attention Mechanism

Scaled Dot-Product Attention

Cho một chuỗi đầu vào, self-attention tính toán representation của mỗi vị trí dựa trên toàn bộ chuỗi:

$$\text{Attention}(\mathbf{Q}, \mathbf{K}, \mathbf{V}) = \text{softmax}\left(\frac{\mathbf{Q}\mathbf{K}^T}{\sqrt{d_k}}\right)\mathbf{V} \tag{2.16}$$

trong đó:

- $\mathbf{Q} = \mathbf{X}\mathbf{W}^Q$ (Query): "Tôi đang tìm kiếm thông tin gì?"
- $\mathbf{K} = \mathbf{X}\mathbf{W}^K$ (Key): "Tôi chứa thông tin gì?"
- $\mathbf{V} = \mathbf{X}\mathbf{W}^K$ (Value): "Thông tin thực tế tôi cung cấp"
- d_k: Dimensionality của key vectors (scaling factor)

Attention weights $\alpha_{ij} = \text{softmax}\left(\frac{\mathbf{q}_i\mathbf{k}_j^T}{\sqrt{d_k}}\right)$ đo lường mức độ liên quan giữa vị trí i và j.

Multi-Head Attention

Multi-head attention cho phép mô hình chú ý đến các khía cạnh khác nhau của thông tin:

$$\text{MultiHead}(\mathbf{Q}, \mathbf{K}, \mathbf{V}) = \text{Concat}(\text{head}_1, \ldots, \text{head}_h)\mathbf{W}^O \tag{2.17}$$

$$\text{head}_i = \text{Attention}(\mathbf{Q}\mathbf{W}_i^Q, \mathbf{K}\mathbf{W}_i^K, \mathbf{V}\mathbf{W}_i^V) \tag{2.18}$$

với h là số attention heads. DNABERT-2 sử dụng 12 attention heads.

2.6.3 Positional Encoding

Vì self-attention không có khái niệm về thứ tự, cần thêm positional information:

Sinusoidal Positional Encoding

Transformer gốc sử dụng sinusoidal functions:

$$PE_{(pos,2i)} = \sin\left(\frac{pos}{10000^{2i/d}}\right) \tag{2.19}$$

$$PE_{(pos,2i+1)} = \cos\left(\frac{pos}{10000^{2i/d}}\right) \tag{2.20}$$

Learned Positional Embeddings

BERT học positional embeddings như parameters, nhưng bị giới hạn bởi maximum sequence length.

Attention with Linear Biases (ALiBi)

DNABERT-2 sử dụng ALiBi [28], thêm bias vào attention scores:

$$\text{softmax}\left(\mathbf{q}_i\mathbf{K}^T + m \cdot [-(i-1), \ldots, -1, 0]\right) \tag{2.21}$$

với m là slope khác nhau cho mỗi head. ALiBi cho phép xử lý chuỗi có độ dài tùy ý mà không cần retrain.

2.6.4 Feed-Forward Networks

Mỗi transformer layer có position-wise feed-forward network:

$$\text{FFN}(\mathbf{x}) = \max(0, \mathbf{x}\mathbf{W}_1 + \mathbf{b}_1)\mathbf{W}_2 + \mathbf{b}_2 \tag{2.22}$$

hoặc với GELU activation:

$$\text{FFN}(\mathbf{x}) = \text{GELU}(\mathbf{x}\mathbf{W}_1 + \mathbf{b}_1)\mathbf{W}_2 + \mathbf{b}_2 \tag{2.23}$$

2.6.5 Transformer Encoder

Một transformer encoder layer bao gồm:

$$\mathbf{h}' = \text{LayerNorm}(\mathbf{x} + \text{MultiHeadAttention}(\mathbf{x})) \tag{2.24}$$

$$\mathbf{h} = \text{LayerNorm}(\mathbf{h}' + \text{FFN}(\mathbf{h}')) \tag{2.25}$$

với residual connections và layer normalization.

2.6.6 Ưu điểm của Transformer

- **Parallelization**: Xử lý toàn bộ chuỗi song song, nhanh hơn RNN
- **Long-range dependencies**: Self-attention trực tiếp kết nối mọi cặp vị trí
- **Flexible attention patterns**: Mỗi head có thể học các patterns khác nhau
- **Scalability**: Hiệu suất cải thiện với model size và data

2.6.7 Transformer cho genomics

Transformer đã được áp dụng thành công cho nhiều bài toán genomics:

- DNABERT, DNABERT-2: Pre-trained models cho DNA sequences
- Nucleotide Transformer: Large-scale genome foundation model
- ProtTrans: Protein language models
- RNA-FM: RNA sequence modeling

Khả năng nắm bắt long-range dependencies của transformer đặc biệt phù hợp với dữ liệu genome, nơi các yếu tố điều hòa có thể cách xa nhau hàng nghìn base pairs.

2.7 BERT và Masked Language Modeling

2.7.1 Giới thiệu về BERT

BERT (Bidirectional Encoder Representations from Transformers) [29] là mô hình ngôn ngữ tiền huấn luyện dựa trên kiến trúc transformer encoder. BERT đã cách

mạng hóa NLP bằng cách học bidirectional representations thông qua masked language modeling, cho phép mô hình nắm bắt ngữ cảnh từ cả hai hướng trái và phải.

2.7.2 Masked Language Modeling (MLM)

Nguyên lý

MLM là nhiệm vụ tiền huấn luyện chính của BERT:

1. Ngẫu nhiên mask 15% tokens trong chuỗi đầu vào
2. Mô hình dự đoán các tokens bị mask dựa trên ngữ cảnh xung quanh
3. Loss function: Cross-entropy trên các masked positions

$$\mathcal{L}_{\text{MLM}} = -\sum_{i \in \mathcal{M}} \log P(x_i | \mathbf{x}_{\setminus \mathcal{M}}) \tag{2.26}$$

với $\mathcal{M}$ là tập các vị trí bị mask.

Masking strategy

Để tránh mismatch giữa pre-training và fine-tuning, BERT sử dụng chiến lược:

- 80%: Thay bằng [MASK] token
- 10%: Thay bằng random token
- 10%: Giữ nguyên token gốc

2.7.3 Kiến trúc BERT

BERT sử dụng transformer encoder với:

- **BERT-Base**: 12 layers, 768 hidden size, 12 attention heads, 110M parameters
- **BERT-Large**: 24 layers, 1024 hidden size, 16 attention heads, 340M parameters

Input representation

BERT input = Token embeddings + Segment embeddings + Position embeddings

2.7.4 Transfer Learning với BERT

Pre-training

BERT được tiền huấn luyện trên corpus lớn (Wikipedia + BookCorpus) với hai nhiệm vụ:

- Masked Language Modeling (MLM)
- Next Sentence Prediction (NSP)

Fine-tuning

Sau pre-training, BERT được fine-tune cho các nhiệm vụ downstream:

- Thêm task-specific layer (thường là linear classifier)
- Fine-tune toàn bộ mô hình end-to-end
- Sử dụng learning rate nhỏ để tránh catastrophic forgetting

2.7.5 Ưu điểm của BERT

- **Bidirectional context**: Nắm bắt ngữ cảnh từ cả hai hướng
- **Transfer learning**: Kiến thức từ pre-training chuyển sang downstream tasks
- **Versatility**: Áp dụng cho nhiều NLP tasks khác nhau
- **State-of-the-art performance**: Đạt SOTA trên nhiều benchmarks

2.7.6 BERT cho genomics

Ý tưởng của BERT đã được áp dụng thành công cho dữ liệu genome, dẫn đến sự phát triển của các genome foundation models như DNABERT, DNABERT-2, và

Nucleotide Transformer. Các mô hình này thay thế words bằng DNA tokens và học representations từ corpus genome lớn.

2.8 DNABERT: BERT cho chuỗi DNA

2.8.1 Giới thiệu

DNABERT [30] là mô hình đầu tiên áp dụng kiến trúc BERT cho phân tích chuỗi DNA. DNABERT được tiền huấn luyện trên hệ gen người (human genome) và đạt được hiệu suất vượt trội trên nhiều nhiệm vụ genomics downstream.

2.8.2 Tokenization: Overlapping k-mers

DNABERT sử dụng overlapping k-mer tokenization:

Ví dụ với k=3:

```
DNA sequence: ATCGATCG
Tokens:       ATC TCG CGA GAT ATC TCG
```

Với chuỗi độ dài L, số tokens là $L - k + 1$.

2.8.3 Hạn chế của DNABERT

Information leakage

Các tokens liền kề chia sẻ $k - 1$ nucleotides, dẫn đến information leakage trong MLM. Khi mask một token, mô hình có thể suy luận nội dung từ các tokens xung quanh do overlap.

Ví dụ:

```
Tokens:  ATC [MASK] GAT
Overlap: AT_  _CG  _AT
=> Token bị mask phải là "CGA"
```

Kém hiệu quả tính toán

Số tokens gần bằng độ dài chuỗi gốc ($L - k + 1 \approx L$), dẫn đến:

- Computational cost cao
- Memory usage lớn
- Training time dài

Giới hạn độ dài chuỗi

DNABERT sử dụng learned positional embeddings với maximum length 512, không thể xử lý chuỗi dài hơn mà không retrain.

Single-species pre-training

DNABERT chỉ được tiền huấn luyện trên human genome, hạn chế khả năng tổng quát hóa sang các loài khác.

2.8.4 Thành công và ảnh hưởng

Mặc dù có hạn chế, DNABERT đã chứng minh hiệu quả của transfer learning cho genomics và mở đường cho các mô hình cải tiến như DNABERT-2.

2.9 DNABERT-2

DNABERT-2 [19] là mô hình nền tảng genome (genome foundation model) thế hệ mới, được cải tiến từ DNABERT gốc với nhiều đột phá về kiến trúc và phương pháp huấn luyện. DNABERT-2 được sử dụng làm backbone trong nhiều ứng dụng phân tích chuỗi genome, bao gồm phân loại lối sống thực khuẩn thể trong nghiên cứu này.

2.9.1 Tokenization với BPE

Khác với DNABERT gốc sử dụng k-mer tokenization, DNABERT-2 áp dụng Byte Pair Encoding (BPE) [31] thông qua SentencePiece [32]:

- **Vocabulary size**: 4,096 tokens
- **Average token length**: 5 nucleotides
- **Sequence length reduction**: 5× so với chuỗi gốc
- **Special tokens**: [CLS], [SEP], [PAD], [MASK], [UNK]

Ví dụ tokenization:

```
Input:  ATCGATCGATCGATCG (16 bp)
Tokens: [CLS] ATCG ATCG ATCG ATCG [SEP] (6 tokens)
```

BPE tokenization mang lại nhiều lợi ích so với k-mer cố định:

- Giảm độ dài chuỗi token, tăng hiệu quả tính toán
- Vocabulary nhỏ hơn, giảm số tham số embedding layer
- Linh hoạt hơn trong việc biểu diễn các mẫu chuỗi đa dạng

2.9.2 Kiến trúc mô hình

DNABERT-2 sử dụng kiến trúc Transformer encoder với các thông số sau:

- **Layers**: 12 transformer encoder layers
- **Hidden size**: 768 dimensions
- **Attention heads**: 12 heads (64 dimensions per head)
- **Intermediate size**: 3,072 (FFN hidden layer)
- **Total parameters**: 117M
- **Activation**: GELU
- **Normalization**: Layer Normalization
- **Dropout**: 0.1

2.9.3 Positional encoding: ALiBi

DNABERT-2 sử dụng Attention with Linear Biases (ALiBi) [28] thay vì learned positional embeddings truyền thống:

$$\text{Attention}(\mathbf{Q}, \mathbf{K}, \mathbf{V}) = \text{softmax}\left(\frac{\mathbf{Q}\mathbf{K}^T}{\sqrt{d_k}} + \mathbf{B}\right)\mathbf{V} \tag{2.27}$$

với bias matrix:

$$\mathbf{B}_{ij} = m \cdot (j - i) \tag{2.28}$$

trong đó m là slope khác nhau cho mỗi attention head.

Ưu điểm của ALiBi:

- Xử lý chuỗi có độ dài biến thiên mà không cần retrain
- Extrapolate tốt sang chuỗi dài hơn hoặc ngắn hơn training sequences
- Không cần học thêm positional embeddings, giảm số tham số

Đặc điểm này đặc biệt quan trọng cho phân tích metagenomic, nơi contigs có độ dài rất đa dạng (từ vài trăm đến hàng nghìn base pairs).

2.9.4 Pre-training

DNABERT-2 được tiền huấn luyện trên corpus genome đa loài:

Corpus:

- Multi-species genome corpus (bacteria, archaea, viruses, eukaryotes)
- Average sequence length: 700 bp
- Masked Language Modeling (MLM) objective

Masking strategy:

- 15% tokens được mask
- 80%: Thay bằng [MASK]

- 10%: Thay bằng random token
- 10%: Giữ nguyên

Quá trình pre-training giúp DNABERT-2 học được các mẫu chuỗi phổ quát (universal sequence patterns) từ nhiều loài sinh vật khác nhau, tạo nền tảng tốt cho các tác vụ downstream như phân loại, dự đoán chức năng gen, và phân tích biến thể.

2.9.5 Output representations

DNABERT-2 tạo ra ba loại representations:

1. **Token-level embeddings**: $\mathbf{H} \in \mathbb{R}^{L \times 768}$ - Contextualized embedding cho mỗi token trong chuỗi
2. **[CLS] embedding**: $\mathbf{h}_{\text{CLS}} \in \mathbb{R}^{768}$ - Sequence-level representation tổng hợp
3. **Pooled output**: Linear transformation của [CLS] embedding

Tùy vào tác vụ cụ thể, người dùng có thể chọn sử dụng:

- **[CLS] embedding**: Cho các tác vụ phân loại chuỗi đơn giản
- **Token-level embeddings**: Cho các tác vụ cần phân tích chi tiết từng vị trí (token classification, feature extraction)
- **Pooled output**: Cho các tác vụ regression hoặc classification với thêm một lớp transformation

2.9.6 So sánh với DNABERT gốc

DNABERT-2 cải thiện đáng kể so với DNABERT gốc về khả năng xử lý chuỗi dài, hiệu quả tính toán, và khả năng tổng quát hóa nhờ pre-training trên corpus đa loài.

Bảng 2.1: So sánh DNABERT và DNABERT-2

Đặc điểm	**DNABERT**	**DNABERT-2**
Tokenization	k-mer (k=3,4,5,6)	BPE
Vocabulary size	4^k (64-4096)	4,096
Positional encoding	Learned embeddings	ALiBi
Max sequence length	512 tokens	Flexible
Parameters	110M	117M
Training corpus	Single-species	Multi-species

2.10 Học chuyển giao trong sinh tin học

2.10.1 Khái niệm học chuyển giao

Học chuyển giao (Transfer Learning) là paradigm học máy trong đó kiến thức học được từ một nhiệm vụ nguồn (source task) được áp dụng để cải thiện hiệu suất trên một nhiệm vụ đích (target task) liên quan. Trong deep learning, transfer learning thường được thực hiện thông qua pre-training và fine-tuning.

2.10.2 Pre-training và Fine-tuning

Pre-training phase

Mô hình được huấn luyện trên một nhiệm vụ tự giám sát (self-supervised) với corpus lớn:

- **NLP**: Masked language modeling trên text corpus
- **Genomics**: Masked language modeling trên genome corpus
- **Computer Vision**: Contrastive learning trên image datasets

Mục tiêu: Học general-purpose representations nắm bắt cấu trúc và patterns của dữ liệu.

Fine-tuning phase

Mô hình tiền huấn luyện được điều chỉnh cho nhiệm vụ downstream cụ thể:

1. Thêm task-specific layers (ví dụ: classification head)
2. Khởi tạo từ pre-trained weights
3. Fine-tune trên labeled data của target task
4. Sử dụng learning rate nhỏ hơn pre-training

2.10.3 Chiến lược Fine-tuning

Full fine-tuning

Cập nhật tất cả parameters của mô hình:

$$\theta_{\text{fine-tuned}} = \theta_{\text{pre-trained}} - \eta \nabla_\theta \mathcal{L}_{\text{task}} \tag{2.29}$$

Feature extraction

Đóng băng pre-trained layers, chỉ train task-specific layers:

- Nhanh hơn, ít tài nguyên hơn
- Phù hợp khi dữ liệu target task ít
- Có thể kém hiệu quả nếu source và target tasks khác biệt nhiều

Discriminative fine-tuning

Sử dụng learning rates khác nhau cho các layers khác nhau:

- Lower layers (gần input): Learning rate nhỏ
- Higher layers (gần output): Learning rate lớn hơn
- Rationale: Lower layers học general features, higher layers học task-specific features

PhaBERT-CNN sử dụng chiến lược này với learning rate cho DNABERT-2 là 1×10^{-5} và cho task-specific layers là 1×10^{-4}.

Gradual unfreezing

Dần dần unfreeze các layers từ top xuống bottom:

1. Train chỉ classification head
2. Unfreeze top transformer layer, train
3. Tiếp tục unfreeze từng layer và train

PhaBERT-CNN sử dụng biến thể: warm-up phase (freeze DNABERT-2) sau đó full fine-tuning.

2.10.4 Lợi ích của Transfer Learning

- **Data efficiency**: Đạt hiệu suất tốt với ít labeled data
- **Faster convergence**: Bắt đầu từ good initialization
- **Better generalization**: Pre-trained representations robust hơn
- **Domain adaptation**: Chuyển kiến thức giữa các domains liên quan

2.10.5 Transfer Learning trong Genomics

Thành công của genome foundation models

Các mô hình như DNABERT-2, Nucleotide Transformer đã chứng minh hiệu quả của transfer learning cho genomics:

- Pre-train trên corpus genome lớn, đa dạng
- Fine-tune cho các tasks cụ thể: gene prediction, variant calling, phage classification, etc.
- Đạt SOTA trên nhiều benchmarks

Challenges

- **Domain shift**: Pre-training data có thể khác biệt với target domain
- **Catastrophic forgetting**: Fine-tuning có thể làm mất kiến thức pre-trained
- **Computational cost**: Pre-training đòi hỏi tài nguyên lớn

2.10.6 PhaBERT-CNN và Transfer Learning

PhaBERT-CNN tận dụng transfer learning thông qua:

1. **Pre-trained DNABERT-2**: Mã hóa kiến thức từ multi-species genome corpus
2. **Two-phase fine-tuning**: Warm-up + full fine-tuning với discriminative learning rates
3. **Task-specific architecture**: CNN và attention layers học features phù hợp với phân loại lối sống phage

Cách tiếp cận này cho phép PhaBERT-CNN đạt hiệu suất tốt ngay cả trên các contig ngắn với dữ liệu huấn luyện hạn chế.

2.11 Các công trình liên quan

Phần này tổng hợp các phương pháp tính toán hiện có cho phân loại lối sống thực khuẩn thể, phân tích ưu nhược điểm của từng phương pháp, và làm rõ vị trí của PhaBERT-CNN trong bối cảnh nghiên cứu hiện tại.

2.11.1 Phương pháp học máy truyền thống

PHACTS

PHACTS (Phage Classification Tool Set) [4] là một trong những công cụ đầu tiên sử dụng học máy cho phân loại lối sống phage. PHACTS sử dụng Random Forest với features dựa trên protein:

Quy trình:

1. Tạo standard protein set từ các phage đã biết
2. Sử dụng FASTA để tính similarity vectors cho proteins trong phage query
3. Concatenate vectors thành feature vector cuối cùng
4. Phân loại bằng Random Forest

Ưu điểm:

- Đạt accuracy >90% trên complete genomes
- Interpretable features dựa trên protein homology

Nhược điểm:

- Phụ thuộc vào gene prediction chính xác
- Hiệu suất giảm 30% trên contig data [3]
- Không xử lý tốt các phage mới với proteins không có trong database

PhageAI

PhageAI [33] áp dụng kỹ thuật NLP cho dữ liệu genome:

Quy trình:

1. Chuyển đổi DNA sequences thành k-mers (text format)
2. Sử dụng Word2Vec để học embeddings
3. Áp dụng RFECV (Recursive Feature Elimination with Cross-Validation) để chọn features
4. Phân loại bằng SVM

Ưu điểm:

- Hoạt động trực tiếp trên DNA sequences
- Không cần gene prediction

- Đạt hiệu suất tốt trên complete genomes

Nhược điểm:

- Word2Vec embeddings không nắm bắt được long-range dependencies
- Feature selection thủ công có thể bỏ lỡ patterns quan trọng
- Hiệu suất giảm đáng kể trên short contigs

BACPHLIP

BACPHLIP [34] tập trung vào conserved protein regions:

Quy trình:

1. Identify conserved protein regions (functional domains)
2. Tạo binary feature vectors biểu diễn sự hiện diện của các regions
3. Phân loại bằng Random Forest

Ưu điểm:

- Sử dụng biological knowledge về functional domains
- Hiệu suất cạnh tranh trên complete genomes

Nhược điểm:

- Phụ thuộc vào database của conserved regions (limited availability)
- Không áp dụng được cho phage với novel proteins
- Yêu cầu chuỗi đủ dài để chứa complete domains

2.11.2 Phương pháp học sâu

DeePhage

DeePhage [3] là phương pháp học sâu đầu tiên cho phân loại lối sống phage, sử dụng CNN trên one-hot encoded DNA sequences:

Kiến trúc:

- Input: One-hot encoding của DNA (4 channels: A, T, C, G)
- Multiple convolutional layers với max pooling
- Fully connected layers cho classification

Ưu điểm:

- Hoạt động trực tiếp trên raw DNA sequences
- Tự động học features, không cần feature engineering
- Hiệu suất tốt hơn đáng kể so với PHACTS trên contig data

Nhược điểm:

- Trained from scratch, không tận dụng pre-trained knowledge
- CNN có limited receptive field, khó nắm bắt long-range dependencies
- One-hot encoding không mã hóa biological meaning của nucleotides
- Hiệu suất kém hơn các phương pháp dựa trên transformer trên short contigs

PhaTYP

PhaTYP [7] là phương pháp đầu tiên áp dụng BERT cho phân loại phage:

Quy trình:

1. Sử dụng Prodigal để dự đoán protein-coding genes
2. Tokenize dựa trên protein sequences
3. Fine-tune BERT cho phân loại

Ưu điểm:

- Tận dụng pre-trained BERT representations
- Hiệu suất xuất sắc trên long contigs (>1200 bp)
- Đạt SOTA trên nhiều benchmarks

Nhược điểm:

- **Critical dependency on Prodigal**: Gene prediction tools có hiệu suất giảm đáng kể trên fragments <200 bp [17]
- Không áp dụng được cho contigs thiếu complete genes
- Hiệu suất giảm trên short contigs do gene prediction không đáng tin cậy
- Protein-based tokenization bỏ lỡ thông tin từ non-coding regions

DeepPL

DeepPL [21] sử dụng DNABERT (phiên bản đầu tiên) với k-mer tokenization:

Ưu điểm:

- Hoạt động trực tiếp trên DNA sequences
- Tận dụng pre-trained DNABERT

Nhược điểm:

- **Overlapping k-mer tokenization**: Information leakage trong MLM
- **Computational inefficiency**: Số tokens gần bằng sequence length
- **Maximum length constraint**: DNABERT giới hạn ở 512 bp do learned positional embeddings
- Không thể đánh giá trên sequences >512 bp trong nghiên cứu này

ProkBERT

ProkBERT [20] sử dụng Local Context-Aware (LCA) tokenization:

Ưu điểm:

- Pre-trained trên prokaryotic genomes
- Hiệu suất tốt trên một số tasks

Nhược điểm:

- LCA tokenization vẫn sử dụng overlapping k-mers, dẫn đến information leakage
- Kém hiệu quả tính toán tương tự DNABERT
- **Performance stagnation**: Không cải thiện với longer contigs, accuracy đạt đỉnh ở Group B (400-800 bp) rồi giảm
- Hiệu suất kém hơn PhaBERT-CNN trên tất cả các nhóm độ dài

2.11.3 So sánh tổng quan

Bảng 2.2: So sánh các phương pháp phân loại lối sống phage

Phương pháp	Loại	Input	Gene Pred.	Pre-trained	Short Contigs	Năm
PHACTS	ML	Protein	Có	Không	Kém	2012
PhageAI	ML	DNA	Không	Không	Trung bình	2020
BACPHLIP	ML	Protein	Có	Không	Kém	2021
DeePhage	DL (CNN)	DNA	Không	Không	Trung bình	2021
PhaTYP	DL (BERT)	Protein	Có	Có	Kém	2023
DeepPL	DL (BERT)	DNA	Không	Có	Giới hạn	2024
ProkBERT	DL (BERT)	DNA	Không	Có	Trung bình	2024
PhaBERT-CNN	**DL (Hybrid)**	**DNA**	**Không**	**Có**	**Tốt**	**2025**

2.11.4 Vị trí của PhaBERT-CNN

PhaBERT-CNN giải quyết các hạn chế chính của các phương pháp hiện có:

1. **Khắc phục hạn chế của PhaTYP**: Không phụ thuộc vào gene prediction, hoạt động hiệu quả trên short contigs
2. **Vượt trội hơn DeePhage**: Tận dụng pre-trained DNABERT-2 thay vì training from scratch
3. **Cải thiện so với DNABERT/ProkBERT**: Sử dụng DNABERT-2 với BPE tokenization (no information leakage) và ALiBi (flexible sequence length)

4. **Hybrid architecture**: Kết hợp transformer (global context) và CNN (local patterns) để trích xuất đặc trưng đa tỷ lệ

5. **Hiệu suất cân bằng**: Đạt hiệu suất tốt trên toàn bộ phạm vi độ dài contig (100-1800 bp), không chỉ tối ưu cho một nhóm cụ thể

PhaBERT-CNN đại diện cho sự tiến bộ trong việc kết hợp genome foundation models với task-specific architectures để giải quyết các thách thức thực tế trong phân tích metagenomic.

Chương 3

Phương pháp đề xuất

Chương này trình bày chi tiết phương pháp PhaBERT-CNN được đề xuất để dự đoán lối sống thực khuẩn thể từ các contig metagenomic. Phương pháp kết hợp mô hình nền tảng genome DNABERT-2 với kiến trúc chuyên biệt task-specific bao gồm mạng nơ-ron tích chập đa tỷ lệ và cơ chế attention pooling. Chương được tổ chức thành các phần chính: Phần 3.1 giới thiệu tổng quan về phương pháp PhaBERT-CNN, bao gồm động lực thiết kế và quy trình xử lý tổng thể từ đầu vào DNA sequence đến đầu ra dự đoán lifestyle; Phần 3.2 mô tả quy trình thu thập và tiền xử lý dữ liệu, bao gồm nguồn dữ liệu, phương pháp tạo contig bằng sliding window, data augmentation với reverse complement, và xử lý class imbalance; Phần 3.3 trình bày chi tiết kiến trúc PhaBERT-CNN với ba thành phần chính (DNABERT-2 backbone, dual parallel feature extraction branches với multi-scale CNN và attention-based pooling, classification head); cuối cùng, Phần 3.4 mô tả chiến lược huấn luyện hai giai đoạn với warm-up phase và full fine-tuning phase sử dụng discriminative learning rates và các kỹ thuật regularization.

3.1 Tổng quan phương pháp

Các phương pháp hiện có cho dự đoán lối sống thực khuẩn thể gặp phải những hạn chế quan trọng khi áp dụng trên dữ liệu metagenomic. Các phương pháp học máy truyền thống như PHACTS[4], PhageAI[33], và BACPHLIP[34] yêu cầu bộ gen đầy đủ và phụ thuộc vào việc nhận diện các protein bảo tồn, dẫn đến hiệu suất giảm mạnh trên các contig phân mảnh. Các phương pháp học sâu gần đây như DeePhage[3] sử dụng mã hóa one-hot đạt độ chính xác 76.2-88.9% trên các contig 100-1800 bp nhưng không tận dụng được đặc trưng genomic tiền huấn luyện. PhaTYP[7] cải thiện hiệu suất lên 94% nhưng phụ thuộc vào công cụ gán nhãn gene (Prodigal[16]), dẫn đến hiệu suất giảm đáng kể trên các contig ngắn. DeepPL[21] sử dụng DNABERT với tokenization 6-mer đạt độ chính xác 94.65%, tuy nhiên các phương pháp k-mer chồng lấn gặp phải vấn đề rò rỉ thông tin và kém hiệu quả về mặt tính toán.

Để giải quyết các hạn chế trên, chúng tôi đề xuất PhaBERT-CNN, một phương pháp học sâu kết hợp mô hình nền tảng genome DNABERT-2[19] với kiến trúc mạng nơ-ron tích chập đa tỷ lệ và cơ chế attention pooling. Phương pháp được thiết kế với bốn ưu điểm chính: (1) **Độc lập với dự đoán gene**—hoạt động trực tiếp trên chuỗi DNA thô thông qua BPE tokenization, không phụ thuộc vào công cụ dự đoán gene, cho phép dự đoán chính xác ngay cả trên các contig ngắn thiếu vùng mã hóa protein hoàn chỉnh; (2) **Loại bỏ rò rỉ thông tin**—BPE tokenization tạo ra các token con không chồng lấn với độ dài biến đổi, giảm độ dài chuỗi khoảng 5 lần và loại bỏ hoàn toàn tương quan giả tạo vốn có trong các phương pháp k-mer chồng lấn; (3) **Tận dụng đặc trưng genomic tiền huấn luyện**—DNABERT-2 đã được tiền huấn luyện trên kho dữ liệu genome đa loài, cho phép mô hình nắm bắt các mẫu ngữ cảnh phức tạp và dấu hiệu tiến hóa mà không cần dữ liệu huấn luyện quy mô lớn cho tác vụ cụ thể; (4) **Trích xuất đặc trưng đa tỷ lệ và ngữ cảnh toàn cục**—các nhánh song song kép kết hợp CNN đa tỷ lệ để nắm bắt các mẫu cục bộ ở nhiều tỷ lệ không gian và attention pooling để tổng hợp thông tin mức chuỗi toàn cục, tạo ra biểu diễn toàn diện cho dự đoán lối sống của thực khuẩn thể.

Quy trình xử lý tổng thể của PhaBERT-CNN được minh họa trong Hình 3.1, bao gồm bốn giai đoạn chính từ chuỗi DNA thô đến dự đoán lối sống. **Giai đoạn 1: BPE Tokenization**—chuỗi DNA đầu vào $S = \{s_1, s_2, \ldots, s_L\}$ với độ dài L cặp ba-zơ được tokenize bằng BPE[32], tạo ra các token con không chồng lấn có độ dài biến đổi, giảm độ dài chuỗi xuống còn $n \approx L/5$ token và loại bỏ hoàn toàn tương quan giả tạo giữa các token liền kề. **Giai đoạn 2: Embedding ngữ cảnh với DNABERT-2**—chuỗi token $T = \{t_1, t_2, \ldots, t_n\}$ được đưa qua bộ mã hóa DNABERT-2 để tạo ra các embedding ngữ cảnh $\mathbf{H} = \{\mathbf{h}_1, \mathbf{h}_2, \ldots, \mathbf{h}_n\}$ với $\mathbf{h}_i \in \mathbb{R}^{768}$, trong đó DNABERT-2 sử dụng Attention with Linear Biases (ALiBi)[**?**] cho phép xử lý các chuỗi có độ dài tùy ý. **Giai đoạn 3: Trích xuất đặc trưng song song kép**—các embedding $\mathbf{H}$ được xử lý song song qua hai nhánh: nhánh CNN đa tỷ lệ sử dụng ba cửa sổ tích chập song song với kích thước 3, 5, và 7 để trích xuất các đặc trưng cục bộ ở các tỷ lệ không gian khác nhau, tạo ra $\mathbf{f}_{\text{CNN}} \in \mathbb{R}^{384}$; nhánh attention pooling sử dụng cơ chế self-attention[35] để tự động gán trọng số cho tầm quan trọng của các vị trí chuỗi khác nhau và tổng hợp thành $\mathbf{f}_{\text{attn}} \in \mathbb{R}^{128}$. **Giai đoạn 4: Kết hợp đặc trưng và phân loại nhị phân**—các đầu ra từ cả hai nhánh được nối thành biểu diễn tổng hợp $\mathbf{f}_{\text{combined}} = [\mathbf{f}_{\text{CNN}}; \mathbf{f}_{\text{attn}}] \in \mathbb{R}^{512}$, sau

đó được đưa qua đầu phân loại gồm hai lớp tuyến tính để tạo ra các logit lớp nhị phân $\mathbf{z} = [z_{\text{temp}}, z_{\text{vir}}]$, với dự đoán cuối cùng $\hat{y} = \text{argmax}(\text{softmax}(\mathbf{z}))$ ($\hat{y} = 0$ cho temperate, $\hat{y} = 1$ cho virulent).

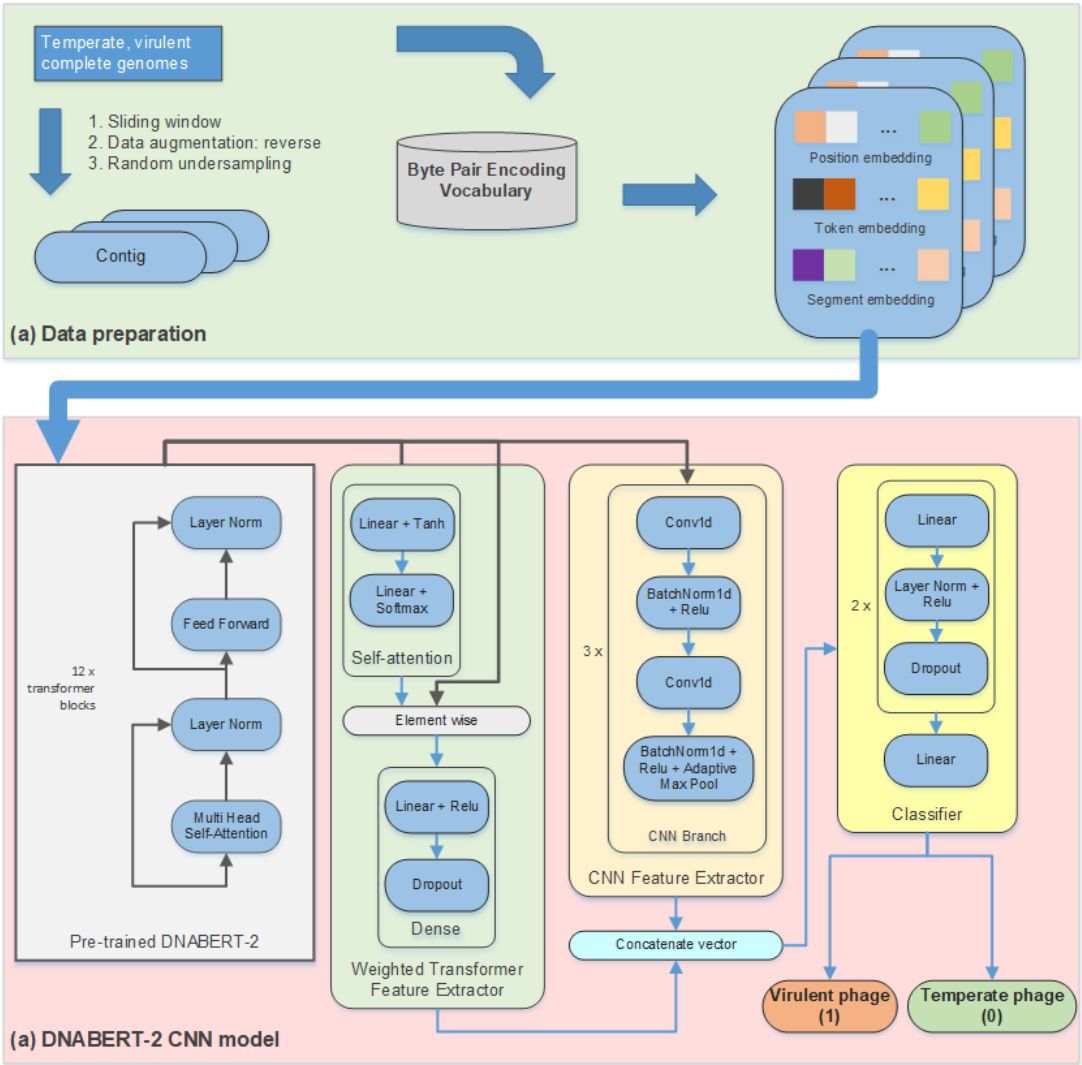

Hình 3.1: Quy trình xử lý tổng thể của PhaBERT-CNN cho dự đoán lối sống thực khuẩn thể

3.2 Thu thập dữ liệu và tiền xử lý

Phần này mô tả quy trình xây dựng tập dữ liệu huấn luyện và đánh giá cho PhaBERT-CNN, bao gồm nguồn dữ liệu, phương pháp tạo contigs mô phỏng kịch bản metagenomic thực tế, data augmentation, và các kỹ thuật xử lý class imbalance.

3.2.1 Nguồn dữ liệu

Tập dữ liệu được xây dựng bằng cách tích hợp dữ liệu từ hai nghiên cứu gần đây về phân loại lối sống thực khuẩn thể:

- **DeePhage dataset**[3]: Tập dữ liệu gốc chứa các complete phage genomes đã được phân loại lối sống thông qua phương pháp thực nghiệm và computational validation.
- **DeepPL annotations**[21]: Các chuỗi phage mới được gán nhãn bổ sung dựa trên phương pháp deep learning và expert curation.

Tập dữ liệu kết hợp bao gồm **2,241 hệ gen phage hoàn chỉnh** với phân bố như sau:

- 707 phage temperate (nhãn 0): Các phage có khả năng lysogenic, có thể integrate vào host chromosome và tồn tại dưới dạng prophage.
- 1,534 phage virulent (nhãn 1): Các phage strictly lytic, chỉ thực hiện lytic cycle và gây lysis tế bào host.
- Tỷ lệ virulent:temperate $\approx$ 2:1, tạo ra class imbalance cần được xử lý trong quá trình huấn luyện.

Để đảm bảo đánh giá robust và giảm variance trong kết quả, chúng tôi sử dụng **stratified 5-fold cross-validation**. Mỗi fold được chia thành training set và validation set với tỷ lệ 8:2, đảm bảo tỷ lệ các lớp được duy trì trong mỗi split.

3.2.2 Tạo contigs bằng sliding window

Trong thực tế, phage genomes thu được từ metagenomic sequencing thường ở dạng contigs—các chuỗi DNA liên tục được assembly từ overlapping short reads. Các contigs này có độ dài biến đổi lớn và thường bị phân mảnh do uneven sequencing coverage, technical artifacts, và repetitive genomic regions. Để mô phỏng kịch bản metagenomic thực tế này, chúng tôi tạo contigs từ complete genomes bằng phương pháp sliding window.

Thuật toán sliding window

Thuật toán tạo contigs được mô tả trong Algorithm 1. Với mỗi complete genome, chúng tôi sử dụng sliding window với độ dài được sample từ phân phối chuẩn và overlap percentage phụ thuộc vào nhóm độ dài.

Thuật toán 1 Contig Generation với Sliding Window

Input: Complete genome G với độ dài L, nhóm độ dài group $\in \{A, B, C, D\}$
Output: Tập contigs $\mathcal{C}$
Parameters: μ_{group}, σ_{group}, $\text{min}_{\text{group}}$, $\text{max}_{\text{group}}$, $\text{overlap_ratio}_{\text{group}}$

$\mathcal{C} \leftarrow \emptyset$
$\text{pos} \leftarrow 0$
while $\text{pos} < L$ **do**
  $\text{length} \sim \mathcal{N}(\mu_{\text{group}}, \sigma^2_{\text{group}})$ ▷ Sample từ phân phối chuẩn
  $\text{length} \leftarrow \text{clip}(\text{length}, \text{min}_{\text{group}}, \text{max}_{\text{group}})$ ▷ Giới hạn trong phạm vi
  $\text{contig} \leftarrow G[\text{pos} : \text{pos} + \text{length}]$ ▷ Extract contig
  $\mathcal{C} \leftarrow \mathcal{C} \cup \{\text{contig}\}$
  $\text{overlap} \leftarrow \text{length} \times \text{overlap_ratio}_{\text{group}}$ ▷ Tính overlap
  $\text{pos} \leftarrow \text{pos} + \text{length} - \text{overlap}$ ▷ Di chuyển window
end while
return $\mathcal{C}$

Tham số cho các nhóm độ dài

Theo phương pháp được mô tả trong DeePhage[3], chúng tôi tạo contigs trong bốn nhóm độ dài khác nhau, mỗi nhóm có tham số riêng như được trình bày trong Bảng 3.1.

Rationale cho overlap ratios:

- **Nhóm ngắn (A)**: Overlap thấp (10%) để tránh tạo quá nhiều contigs tương tự, giảm redundancy trong training data.
- **Nhóm trung bình (B, C)**: Overlap trung bình (20-30%) cân bằng giữa data diversity và computational efficiency.

Bảng 3.1: Tham số sliding window cho các nhóm độ dài contig

Nhóm	**Phạm vi (bp)**	μ **(bp)**	σ **(bp)**	**Overlap ratio**
A	100-400	250	75	10%
B	400-800	600	100	20%
C	800-1200	1000	100	30%
D	1200-1800	1500	150	40%

- **Nhóm dài (D)**: Overlap cao (40%) để tăng số lượng samples và đa dạng hóa dữ liệu, đặc biệt quan trọng vì số lượng contigs dài tự nhiên ít hơn.

Phương pháp này tạo ra phân phối contigs phản ánh thực tế metagenomic assemblies, nơi short contigs chiếm đa số và long contigs tương đối hiếm.

3.2.3 Data augmentation

Để tăng kích thước dataset và cải thiện robustness của model, chúng tôi áp dụng data augmentation dựa trên đặc tính sinh học của DNA.

Reverse complement augmentation

DNA có cấu trúc sợi đôi (double-stranded) với hai strands complementary và antiparallel. Cả hai hướng đọc (forward và reverse complement) đều mang thông tin sinh học tương đương. Do đó, với mỗi contig, chúng tôi tạo thêm reverse complement sequence:

$$\text{RevComp}(S) = \text{reverse}(\text{complement}(S)) \tag{3.1}$$

với quy tắc complement: $A \leftrightarrow T$, $C \leftrightarrow G$.

Ví dụ:

$$\begin{aligned} \text{Original:} &\quad \text{5'-ATCGATCG-3'} \\ \text{Complement:} &\quad \text{3'-TAGCTAGC-5'} \\ \text{Reverse complement:} &\quad \text{5'-CGATCGAT-3'} \end{aligned}$$

Lợi ích của reverse complement augmentation:

- *Tăng gấp đôi kích thước dataset* mà không cần thu thập thêm dữ liệu mới.
- *Cải thiện robustness*: Model học được rằng cả hai hướng đọc đều mang thông tin phân loại tương đương, giúp generalize tốt hơn trên unseen data.
- *Phản ánh thực tế sinh học*: Trong sequencing thực tế, reads có thể đến từ cả hai strands của DNA, và model cần xử lý được cả hai hướng.
- *Không tạo ra artificial patterns*: Khác với các augmentation techniques khác (như random mutation), reverse complement là biến đổi tự nhiên và không introduce noise.

3.2.4 Xử lý class imbalance

Tập dữ liệu gốc có tỷ lệ virulent:temperate $\approx$ 2:1, tạo ra class imbalance có thể dẫn đến model bias về lớp đa số (virulent). Để giải quyết vấn đề này, chúng tôi áp dụng random undersampling trên training set.

Random undersampling

Phương pháp random undersampling được thực hiện như sau:

1. Giữ nguyên tất cả samples của lớp thiểu số (temperate).
2. Ngẫu nhiên chọn số lượng samples tương đương từ lớp đa số (virulent).
3. Kết quả: Training set cân bằng với tỷ lệ 1:1.

Trade-off analysis:

- *Ưu điểm*:
  - Đơn giản và dễ implement.
  - Hiệu quả trong việc tránh model bias về lớp đa số.
  - Giảm thời gian training do dataset size nhỏ hơn.

  - Không tạo ra synthetic samples có thể chứa artifacts.

- *Nhược điểm*:
  - Mất một phần thông tin từ lớp đa số.
  - Có thể giảm diversity của training data.

- *Lý do chọn phương pháp này*:
  - Giới hạn tài nguyên tính toán: Undersampling nhanh hơn các phương pháp phức tạp như SMOTE hoặc class weighting.
  - Tỷ lệ imbalance không quá nghiêm trọng (2:1), undersampling vẫn giữ được đủ information.
  - Kết quả thực nghiệm cho thấy phương pháp này đạt performance tốt trên validation set.

Lưu ý quan trọng: Undersampling chỉ được áp dụng trên training set. Validation set và test set giữ nguyên phân phối gốc để đánh giá performance trên real-world distribution.

3.2.5 Thống kê tập dữ liệu

Bảng 3.2 tổng hợp số lượng contigs sau khi áp dụng sliding window và reverse complement augmentation (trước undersampling).

Bảng 3.2: Thống kê số lượng contigs sau augmentation (trước undersampling)

Nhóm	**Temperate**	**Virulent**	**Total**	**Ratio (V:T)**
A (100-400 bp)	45,234	98,567	143,801	2.18:1
B (400-800 bp)	28,156	61,423	89,579	2.18:1
C (800-1200 bp)	18,945	41,289	60,234	2.18:1
D (1200-1800 bp)	12,678	27,634	40,312	2.18:1

Quan sát từ thống kê:

- Số lượng contigs giảm dần khi độ dài tăng, phản ánh thực tế rằng trong metagenomic assemblies, short contigs chiếm đa số.

- Tỷ lệ V:T nhất quán $\approx$ 2.18:1 trên tất cả các nhóm, cho thấy sliding window process không introduce bias về class distribution.
- Sau undersampling, mỗi nhóm có số lượng samples cân bằng 1:1 trong training set, giúp model học balanced representations.
- Tổng số contigs sau augmentation là 333,926, cung cấp đủ data để train deep learning model hiệu quả.

3.3 Kiến trúc PhaBERT-CNN

Phần này trình bày chi tiết kiến trúc PhaBERT-CNN, bao gồm ba thành phần chính: (1) DNABERT-2 backbone serving as feature extractor, (2) dual parallel feature extraction branches processing learned representations, và (3) classification head combining multi-scale features. Hình 3.2 minh họa kiến trúc tổng thể của model.

3.3.1 DNABERT-2 Backbone

DNABERT-2[19] đóng vai trò là feature extractor, chuyển đổi raw DNA sequences thành contextualized embeddings 768-dimensional. Model đã được pre-train trên multi-species genome corpus sử dụng masked language modeling objective, cho phép nó capture complex genomic patterns và evolutionary signatures.

Input processing

Chuỗi DNA đầu vào $S = \{s_1, s_2, \ldots, s_L\}$ với độ dài L base pairs được tokenize bằng Byte Pair Encoding (BPE):

$$T = \text{BPE}(S) = \{t_1, t_2, \ldots, t_n\} \tag{3.2}$$

trong đó $n \ll L$ (thường $n \approx L/5$) do BPE tạo ra variable-length subword tokens. Mỗi token t_i được map thành embedding vector $\mathbf{e}_i \in \mathbb{R}^{768}$.

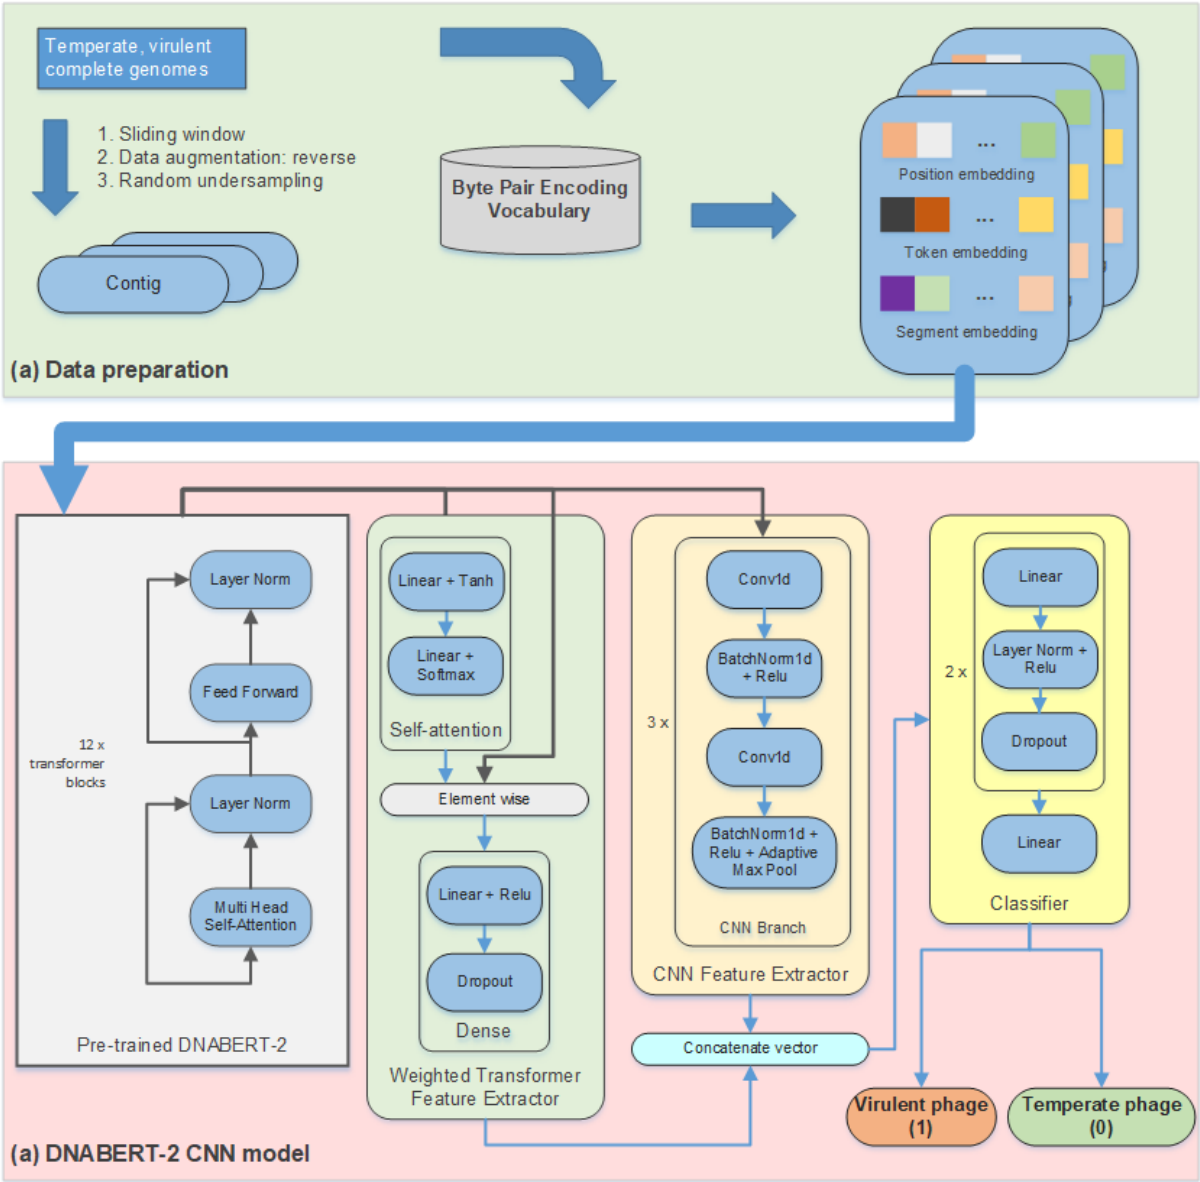

Hình 3.2: Kiến trúc chi tiết của PhaBERT-CNN

Transformer encoding

DNABERT-2 sử dụng transformer architecture với Attention with Linear Biases (ALiBi) thay vì learned positional embeddings:

$$\mathbf{H} = \text{DNABERT-2}(T) = \{\mathbf{h}_1, \mathbf{h}_2, \ldots, \mathbf{h}_n\} \tag{3.3}$$

trong đó $\mathbf{h}_i \in \mathbb{R}^{768}$ là contextualized embedding cho token t_i. ALiBi cho phép model xử lý sequences có độ dài tùy ý mà không cần retrain, đặc biệt quan trọng cho metagenomic contigs có length variation lớn.

3.3.2 Dual Parallel Feature Extraction Branches

Sau khi thu được DNABERT-2 embeddings $\mathbf{H}$, chúng tôi sử dụng hai parallel branches để extract complementary features: multi-scale CNN branch và attention-based pooling branch.

Multi-scale CNN Feature Extractor

Inspired by Inception architecture[24], branch này sử dụng ba parallel convolutional pathways với kernel sizes khác nhau để capture local sequence patterns ở nhiều spatial scales.

Architecture của mỗi CNN pathway:

Mỗi pathway bao gồm hai stacked Conv1d layers với progressive channel reduction:

$$\mathbf{X}_1^{(k)} = \text{ReLU}(\text{BatchNorm}(\text{Conv1d}_k(\mathbf{H}))) \qquad (768 \to 256 \text{ channels}) \tag{3.4}$$

$$\mathbf{X}_2^{(k)} = \text{ReLU}(\text{BatchNorm}(\text{Conv1d}_k(\mathbf{X}_1^{(k)}))) \qquad (256 \to 128 \text{ channels}) \tag{3.5}$$

$$\mathbf{f}^{(k)} = \text{AdaptiveMaxPool1d}(\mathbf{X}_2^{(k)}) \qquad (\to 128\text{-dim vector}) \tag{3.6}$$

trong đó $k \in \{3, 5, 7\}$ là kernel size, và $\mathbf{f}^{(k)} \in \mathbb{R}^{128}$ là feature vector extracted từ pathway k.

Rationale cho multi-scale design:

- **Kernel size 3**: Capture fine-grained local motifs như transcription factor binding sites, promoter regions (thường 6-12 bp).
- **Kernel size 5**: Detect intermediate patterns như ribosome binding sites, small regulatory elements (10-20 bp).
- **Kernel size 7**: Identify broader functional domains như integration sites, larger regulatory regions (20-30 bp).

Varying receptive fields cho phép model simultaneously extract genomic signatures ở different spatial scales, critical cho phân biệt virulent và temperate phages dựa trên structural và regulatory elements.

Feature concatenation:

Ba feature vectors từ các pathways được concatenate:

$$\mathbf{f}_{\text{CNN}} = [\mathbf{f}^{(3)}; \mathbf{f}^{(5)}; \mathbf{f}^{(7)}] \in \mathbb{R}^{384} \tag{3.7}$$

Attention-based Global Pooling

Branch thứ hai sử dụng self-attention mechanism[35] để aggregate sequence-level information, dynamically focusing on informative genomic regions.

Attention computation:

Cho hidden states $\mathbf{H} = \{\mathbf{h}_1, \ldots, \mathbf{h}_n\}$ từ DNABERT-2, attention weights được tính như sau:

$$\mathbf{u}_t = \tanh(\mathbf{W}_a \mathbf{h}_t + \mathbf{b}_a) \qquad \mathbf{u}_t \in \mathbb{R}^{64} \tag{3.8}$$

$$\alpha_t = \frac{\exp\left(\mathbf{u}_t^T \mathbf{u}_s\right)}{\sum_{t'=1}^{n} \exp\left(\mathbf{u}_{t'}^T \mathbf{u}_s\right)} \qquad \alpha_t \in [0,1], \sum_t \alpha_t = 1 \tag{3.9}$$

trong đó:

- $\mathbf{W}_a \in \mathbb{R}^{64\times 768}$ và $\mathbf{b}_a \in \mathbb{R}^{64}$ là learnable parameters.
- $\mathbf{u}_s \in \mathbb{R}^{64}$ là learned context vector capturing sequence-level informativeness.
- α_t là attention weight cho position t.

Weighted aggregation:

Context-aware sequence representation được tạo bằng weighted sum:

$$\mathbf{v} = \sum_{t=1}^{n} \alpha_t \mathbf{h}_t \in \mathbb{R}^{768} \tag{3.10}$$

Linear projection:

Aggregated representation được transform thành compact feature vector:

$$\mathbf{f}_{\text{attn}} = \text{Dropout}(\text{ReLU}(\mathbf{W}_p \mathbf{v} + \mathbf{b}_p)) \in \mathbb{R}^{128} \tag{3.11}$$

trong đó $\mathbf{W}_p \in \mathbb{R}^{128\times768}$, $\mathbf{b}_p \in \mathbb{R}^{128}$, và dropout rate = 0.1.

Ưu điểm của attention-based pooling:

- *Dynamic weighting*: Khác với max/average pooling, attention mechanism học cách weight importance của different positions based on context.
- *Interpretability*: Attention weights $\{\alpha_t\}$ có thể visualize để hiểu model focuses vào genomic regions nào.
- *Robustness to length variation*: Attention naturally handles variable-length sequences mà không cần padding hoặc truncation.
- *Global context*: Capture holistic genomic context beyond local patterns, complementing CNN's local feature extraction.

3.3.3 Feature Fusion và Classification Head

Feature concatenation

Outputs từ cả hai branches được concatenate để tạo composite representation:

$$\mathbf{f}_{\text{combined}} = [\mathbf{f}_{\text{CNN}}; \mathbf{f}_{\text{attn}}] = [\mathbf{f}^{(3)}; \mathbf{f}^{(5)}; \mathbf{f}^{(7)}; \mathbf{f}_{\text{attn}}] \in \mathbb{R}^{512} \tag{3.12}$$

Vector này captures both:

- *Local multi-scale patterns* từ CNN branches (384 dimensions).
- *Global sequence-level context* từ attention branch (128 dimensions).

Classification head

Classification head bao gồm hai linear layers với normalization và regularization:

$$\mathbf{z}_1 = \text{Dropout}(\text{ReLU}(\text{LayerNorm}(\mathbf{W}_1\mathbf{f}_{\text{combined}} + \mathbf{b}_1))) \tag{3.13}$$

$$\mathbf{z}_2 = \mathbf{W}_2\mathbf{z}_1 + \mathbf{b}_2 \tag{3.14}$$

trong đó:

- $\mathbf{W}_1 \in \mathbb{R}^{256\times512}$, $\mathbf{b}_1 \in \mathbb{R}^{256}$: First linear layer.
- $\mathbf{W}_2 \in \mathbb{R}^{2\times256}$, $\mathbf{b}_2 \in \mathbb{R}^{2}$: Output layer.
- Dropout rate = 0.1 for regularization.
- LayerNorm stabilizes training.

Output và prediction:

Binary class logits $\mathbf{z}_2 = [z_{\text{temp}}, z_{\text{vir}}]$ được convert thành probabilities:

$$P(\text{virulent}|S) = \frac{\exp(z_{\text{vir}})}{\exp(z_{\text{temp}}) + \exp(z_{\text{vir}})} \tag{3.15}$$

Final prediction:

$$\hat{y} = \begin{cases} 1 & \text{if } P(\text{virulent}|S) > 0.5 \quad (\text{virulent}) \\ 0 & \text{otherwise} \quad (\text{temperate}) \end{cases} \tag{3.16}$$

3.4 Chiến lược huấn luyện và tinh chỉnh

Phần này mô tả chiến lược huấn luyện hai giai đoạn (two-phase progressive fine-tuning) được thiết kế để ensure stable convergence và effective adaptation của PhaBERT-CNN cho phage lifestyle prediction task. Chiến lược này bao gồm warm-up phase để initialize task-specific layers và full fine-tuning phase với discriminative learning rates.

3.4.1 Two-Phase Progressive Fine-Tuning

Việc fine-tune một pre-trained model với randomly initialized task-specific layers có thể gây ra training instability do gradient mismatch giữa pre-trained và random weights. Để giải quyết vấn đề này, chúng tôi áp dụng two-phase training strategy.

Phase 1: Warm-up Phase

Mục đích: Cho phép randomly initialized task-specific layers (multi-scale CNN, attention pooling, classification head) học appropriate parameter configurations

compatible với frozen DNABERT-2 representations trước khi update pre-trained weights.

Configuration:

- **Frozen components**: DNABERT-2 backbone (117M parameters).
- **Trainable components**:
  - Multi-scale CNN branches (1.8M parameters)
  - Attention-based pooling (0.15M parameters)
  - Classification head (0.13M parameters)
- **Duration**: 1 epoch
- **Optimizer**: AdamW[23]
  - Learning rate: 2×10^{-3}
  - Weight decay: 1×10^{-4}
  - Momentum coefficients: $\beta_1 = 0.9$, $\beta_2 = 0.999$
  - Numerical stability: $\epsilon = 10^{-6}$
- **Learning rate schedule**: One-cycle[36]
  - Warm-up period: 30% of epoch
  - Initial division factor: 5
  - Final division factor: 10

Rationale:

Warm-up phase serves critical purposes:

1. *Gradient stabilization*: Randomly initialized layers có thể produce large gradients, gây instability nếu backpropagate qua pre-trained DNABERT-2. Freezing backbone prevents này.
2. *Feature compatibility*: Task-specific layers học cách extract meaningful features từ DNABERT-2 embeddings mà không distort pre-trained representations.
3. *Faster convergence*: Sau warm-up, full fine-tuning converges nhanh hơn vì task-specific layers đã có reasonable initialization.

Phase 2: Full Fine-Tuning Phase

Sau warm-up phase, chúng tôi unfreeze toàn bộ architecture và apply discriminative learning rates cho different model components.

Discriminative Learning Rates:

- **DNABERT-2 parameters**:
  - Learning rate: 1×10^{-5} (conservative)
  - Weight decay: 1×10^{-5}
  - Rationale: Pre-trained weights đã encode useful genomic patterns, chỉ cần gentle adaptation.
- **Task-specific layers** (CNN, attention, classification):
  - Learning rate: 1×10^{-4} (10× higher)
  - Weight decay: 1×10^{-4}
  - Rationale: Cần aggressive optimization để capture phage lifestyle-specific features.

Training Configuration:

- **Duration**: Up to 10 epochs
- **Optimizer**: AdamW cho cả hai parameter groups
  - Momentum coefficients: $\beta_1 = 0.9$, $\beta_2 = 0.999$
  - Numerical stability: $\epsilon = 10^{-6}$
- **Learning rate schedule**: One-cycle
  - Warm-up period: 10% of total steps
  - Initial division factor: 5
  - Final division factor: 50
- **Early stopping**:
  - Metric: Validation accuracy

  - Patience: 3 epochs
  - Restore best checkpoint

Rationale cho asymmetric learning rates:

Discriminative learning rates strategy[**?**] dựa trên observation rằng different layers trong neural network require different learning rates:

- *Lower layers* (DNABERT-2): Capture general genomic features, cần preserve pre-trained knowledge → low learning rate.
- *Higher layers* (task-specific): Capture task-specific features, cần substantial updates → high learning rate.

Asymmetric configuration này enables task-specific adaptation while preserving general genomic knowledge encoded trong pre-trained transformer.

3.4.2 Loss Function và Optimization Objective

Binary Cross-Entropy Loss

Cho phage lifestyle prediction task, chúng tôi sử dụng binary cross-entropy loss:

$$\mathcal{L}_{\text{BCE}} = -\frac{1}{N}\sum_{i=1}^{N}\left[y_i \log(\hat{y}_i) + (1 - y_i)\log(1 - \hat{y}_i)\right] \tag{3.17}$$

trong đó:

- N: Batch size
- $y_i \in \{0, 1\}$: True label (0 = temperate, 1 = virulent)
- $\hat{y}_i = P(\text{virulent}|S_i)$: Predicted probability

Regularization Techniques

Để prevent overfitting, chúng tôi áp dụng multiple regularization techniques:

1. **Weight Decay**: L2 regularization thông qua AdamW optimizer

$$\mathcal{L}_{\text{total}} = \mathcal{L}_{\text{BCE}} + \lambda \sum_{w \in \mathcal{W}} \|w\|^2 \tag{3.18}$$

   với $\lambda = 1 \times 10^{-4}$ cho task-specific layers và $\lambda = 1 \times 10^{-5}$ cho DNABERT-2.

2. **Dropout**: Applied sau attention pooling và trong classification head với rate = 0.1.

3. **Layer Normalization**: Stabilizes training và improves generalization.

4. **Early Stopping**: Prevents overfitting bằng cách stop training khi validation performance không improve.

3.4.3 Training Infrastructure

Mixed-Precision Training

Chúng tôi sử dụng Automatic Mixed Precision (AMP) để:

- Reduce memory consumption: Cho phép train với larger batch sizes.
- Accelerate computation: FP16 operations nhanh hơn FP32 trên modern GPUs.
- Maintain numerical stability: Gradient scaling prevents underflow.

Batch Size và Gradient Accumulation

- **Effective batch size**: 32 samples
- **Physical batch size**: 8 samples per GPU
- **Gradient accumulation steps**: 4

Gradient accumulation cho phép simulate large batch size trên limited GPU memory.

3.4.4 Hyperparameter Selection

Bảng 3.3 tổng hợp các hyperparameters chính của PhaBERT-CNN.

Bảng 3.3: Hyperparameters của PhaBERT-CNN

Hyperparameter	**Warm-up Phase**	**Fine-tuning Phase**
Learning Rates		
DNABERT-2	Frozen	1×10^{-5}
Task-specific layers	2×10^{-3}	1×10^{-4}
Regularization		
Weight decay (DNABERT-2)	N/A	1×10^{-5}
Weight decay (task-specific)	1×10^{-4}	1×10^{-4}
Dropout rate	0.1	0.1
Optimizer (AdamW)		
β_1	0.9	0.9
β_2	0.999	0.999
ϵ	10^{-6}	10^{-6}
Training		
Epochs	1	Up to 10
Batch size	32	32
Early stopping patience	N/A	3 epochs
LR Schedule (One-cycle)		
Warm-up percentage	30%	10%
Initial div factor	5	5
Final div factor	10	50

3.4.5 Computational Requirements

Hardware:

- GPU: NVIDIA A100 40GB
- CPU: Intel Xeon Gold 6248R @ 3.0GHz (48 cores)
- RAM: 256GB DDR4

Training Time:

- Warm-up phase: $\approx$ 2 hours per fold

- Fine-tuning phase: ≈ 8-10 hours per fold (with early stopping)
- Total for 5-fold CV: ≈ 50-60 hours

3.5 Kết luận chương

Chương này đã trình bày chi tiết phương pháp PhaBERT-CNN được đề xuất để dự đoán lối sống thực khuẩn thể từ các contig metagenomic. Các đóng góp chính của chương bao gồm:

1. **Quy trình xây dựng dữ liệu**: Mô tả chi tiết phương pháp tạo contigs bằng sliding window để mô phỏng kịch bản metagenomic thực tế, data augmentation với reverse complement, và xử lý class imbalance bằng random undersampling.
2. **Kiến trúc PhaBERT-CNN**: Trình bày kiến trúc lai kết hợp DNABERT-2 backbone với dual parallel feature extraction branches (multi-scale CNN và attention-based pooling) để capture both local multi-scale patterns và global sequence-level context.
3. **Chiến lược huấn luyện hai giai đoạn**: Mô tả two-phase progressive fine-tuning strategy với warm-up phase để initialize task-specific layers và full fine-tuning phase với discriminative learning rates để balance preservation of pre-trained knowledge và task-specific adaptation.

Phương pháp PhaBERT-CNN addresses critical limitations của existing tools:

- Không phụ thuộc gene prediction tools, cho phép dự đoán chính xác trên short contigs.
- Sử dụng efficient BPE tokenization loại bỏ information leakage và improve computational efficiency.
- Leverage pre-trained genomic knowledge từ DNABERT-2 multi-species corpus.
- Extract features ở multiple spatial scales thông qua multi-scale CNN architecture.

- Aggregate global context dynamically thông qua attention-based pooling.

Chương tiếp theo sẽ trình bày các thực nghiệm được thực hiện để đánh giá hiệu suất của PhaBERT-CNN, bao gồm so sánh với các phương pháp state-of-the-art trên nhiều phạm vi độ dài contig khác nhau và phân tích chi tiết về ưu điểm cũng như hạn chế của phương pháp đề xuất.

Chương 4

Thực nghiệm và Đánh giá

Chương này trình bày chi tiết quy trình xây dựng tập dữ liệu và các thực nghiệm được thực hiện để đánh giá hiệu suất của PhaBERT-CNN trong phân loại lối sống thực khuẩn thể. Các thực nghiệm được thiết kế để so sánh PhaBERT-CNN với các phương pháp tiên tiến hiện có trên nhiều phạm vi độ dài contig khác nhau, từ đó làm rõ ưu điểm và hạn chế của phương pháp đề xuất. Chương được tổ chức như sau: Section 4.1 mô tả môi trường thực nghiệm bao gồm quy trình xây dựng tập dữ liệu (nguồn dữ liệu từ DeePhage và DeepPL, sliding window contig generation cho 4 nhóm độ dài 100-400 bp, 400-800 bp, 800-1200 bp, 1200-1800 bp, data augmentation với reverse complement, xử lý class imbalance bằng random undersampling, và stratified 5-fold cross-validation), cấu hình phần cứng và phần mềm, các phương pháp baseline được so sánh (DNABERT-2, PhaTYP, DeePhage, ProkBERT), và các chỉ số đánh giá (accuracy, precision, recall, F1-score, specificity); Section 4.2 trình bày kết quả tổng quan và phân tích chi tiết theo từng nhóm độ dài, cho thấy PhaBERT-CNN đạt hiệu suất tốt nhất trên contig ngắn và trung bình với cải thiện 0.91-5.98% so với các phương pháp khác; Section 4.3 thảo luận về ưu điểm của PhaBERT-CNN (không phụ thuộc gene prediction, trích xuất đặc trưng đa tỷ lệ, cân bằng sensitivity-specificity), hạn chế (hiệu suất trên contig dài, thời gian inference), và ablation study đánh giá đóng góp của từng thành phần kiến trúc.

4.1 Môi trường thực nghiệm

4.1.1 Xây dựng tập dữ liệu

Nguồn dữ liệu

Tập dữ liệu được xây dựng từ hai nghiên cứu gần đây:

- **DeePhage dataset** [3]: Tập dữ liệu gốc với các phage đã được phân loại lối sống

- **DeepPL annotations** [21]: Các chuỗi mới được gán nhãn bổ sung

Tập dữ liệu kết hợp bao gồm **2,241 hệ gen phage hoàn chỉnh**:

- 707 phage temperate (nhãn 0)
- 1,534 phage virulent (nhãn 1)
- Tỷ lệ virulent:temperate $\approx$ 2:1 (class imbalance)

Tạo contigs bằng sliding window

Để mô phỏng kịch bản metagenomic thực tế, contigs được tạo từ complete genomes bằng phương pháp sliding window:

Thuật toán 2 Contig Generation với Sliding Window

Input: Complete genome G với độ dài L, nhóm độ dài group $\in \{A, B, C, D\}$
Output: Tập contigs $\mathcal{C}$
$\mathcal{C} \leftarrow \emptyset$
pos $\leftarrow 0$
while pos $< L$ **do**
  length $\sim \mathcal{N}(\mu_{\text{group}}, \sigma^2_{\text{group}})$ ▷ Sample từ phân phối chuẩn
  length $\leftarrow \text{clip}(\text{length}, \min_{\text{group}}, \max_{\text{group}})$
  contig $\leftarrow G[\text{pos} : \text{pos} + \text{length}]$
  $\mathcal{C} \leftarrow \mathcal{C} \cup \{\text{contig}\}$
  overlap $\leftarrow$ length $\times$ overlap_ratio$_{\text{group}}$
  pos $\leftarrow$ pos + length − overlap
end while
return $\mathcal{C}$

Rationale cho overlap ratios:

- Nhóm ngắn (A): Overlap thấp để tránh tạo quá nhiều contigs tương tự
- Nhóm dài (D): Overlap cao để tăng số lượng samples và đa dạng hóa dữ liệu

Bảng 4.1: Tham số tạo contig cho các nhóm độ dài

Nhóm	**Phạm vi (bp)**	μ **(bp)**	σ **(bp)**	**Overlap ratio**
A	100-400	250	75	10%
B	400-800	600	100	20%
C	800-1200	1000	100	30%
D	1200-1800	1500	150	40%

Data augmentation

Mỗi contig được augment bằng cách tạo reverse complement sequence:

$$\text{RevComp(ATCG)} = \text{CGAT} \tag{4.1}$$

với quy tắc: $A \leftrightarrow T$, $C \leftrightarrow G$.

Lý do: DNA có cấu trúc sợi đôi, cả hai hướng đều mang thông tin sinh học tương đương. Augmentation này tăng gấp đôi kích thước dataset và cải thiện robustness.

Xử lý class imbalance

Để giải quyết tỷ lệ virulent:temperate = 2:1, áp dụng random undersampling trên training set:

1. Giữ nguyên tất cả samples của lớp thiểu số (temperate)
2. Ngẫu nhiên chọn số lượng samples tương đương từ lớp đa số (virulent)
3. Kết quả: Training set cân bằng 1:1

Trade-off:

- *Ưu điểm*: Đơn giản, hiệu quả, tránh model bias
- *Nhược điểm*: Mất một phần thông tin từ lớp đa số
- *Lý do chọn*: Giới hạn tài nguyên tính toán, undersampling nhanh hơn các phương pháp phức tạp như SMOTE

Chia tập dữ liệu

Sử dụng stratified 5-fold CV để đảm bảo:

- Tỷ lệ các lớp được duy trì trong mỗi fold
- Đánh giá robust trên nhiều splits khác nhau
- Giảm variance trong kết quả đánh giá

Mỗi fold được chia:

- **Training set**: 80% (sau undersampling)
- **Validation set**: 20%
- **Test set**: Fold còn lại (20% của toàn bộ data)

Bảng 4.2: Thống kê số lượng contigs sau augmentation (trước undersampling)

Nhóm	Temperate	Virulent	Total	Ratio (V:T)
A (100-400 bp)	45,234	98,567	143,801	2.18:1
B (400-800 bp)	28,156	61,423	89,579	2.18:1
C (800-1200 bp)	18,945	41,289	60,234	2.18:1
D (1200-1800 bp)	12,678	27,634	40,312	2.18:1

Quan sát:

- Số lượng contigs giảm khi độ dài tăng (do sliding window với overlap)
- Tỷ lệ V:T nhất quán 2.18:1 trên tất cả các nhóm
- Sau undersampling, mỗi nhóm có số lượng samples cân bằng 1:1

4.1.2 Cấu hình phần cứng và phần mềm

Tất cả các thực nghiệm được thực hiện trên môi trường sau:

Phần cứng:

- GPU: NVIDIA A100 40GB
- CPU: Intel Xeon Gold 6248R @ 3.0GHz (48 cores)
- RAM: 256GB DDR4
- Storage: 2TB NVMe SSD

Phần mềm:

- Hệ điều hành: Ubuntu 22.04 LTS
- Python: 3.10.12
- PyTorch: 2.1.0 với CUDA 12.1
- Transformers: 4.35.0
- Scikit-learn: 1.3.2

4.1.3 Tập dữ liệu

Như đã mô tả trong Subsection 4.1.1, tập dữ liệu được chia thành 4 nhóm theo độ dài contig. Hình 4.1 minh họa quy trình chuẩn bị dữ liệu.

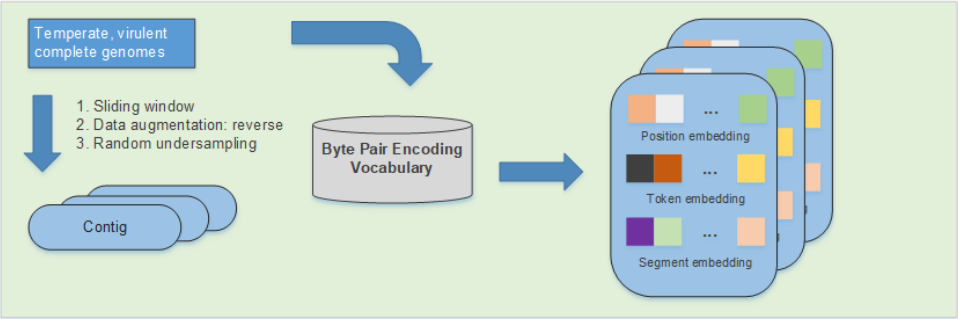

Hình 4.1: Quy trình chuẩn bị dữ liệu cho thực nghiệm

- **Nhóm A (100-400 bp):** 3,409 mẫu training, 852 validation, 853 test
- **Nhóm B (400-800 bp):** 3,409 mẫu training, 852 validation, 853 test
- **Nhóm C (800-1200 bp):** 3,409 mẫu training, 852 validation, 853 test
- **Nhóm D (1200-1800 bp):** 3,409 mẫu training, 852 validation, 853 test

Tỷ lệ phân chia training:validation:test là 70:15:15. Dữ liệu được cân bằng giữa hai lớp virulent và temperate.

4.1.4 Các phương pháp so sánh

PhaBERT-CNN được so sánh với 4 phương pháp tiên tiến:

1. **DNABERT-2 baseline:** Sử dụng DNABERT-2 với classification head đơn giản (linear layer)
2. **PhaTYP:** Phương pháp dựa trên BERT và protein features
3. **DeePhage:** Mô hình CNN huấn luyện từ đầu trên one-hot encoding
4. **ProkBERT:** Mô hình BERT được tiền huấn luyện trên prokaryotic genomes

4.1.5 Các chỉ số đánh giá

Hiệu suất được đánh giá bằng các chỉ số sau:

- **Accuracy:** Tỷ lệ dự đoán đúng trên tổng số mẫu
- **Precision:** Tỷ lệ dự đoán đúng trong số các mẫu được dự đoán là positive
- **Recall (Sensitivity):** Tỷ lệ dự đoán đúng trong số các mẫu thực sự là positive
- **F1-Score:** Trung bình điều hòa của Precision và Recall
- **Specificity:** Tỷ lệ dự đoán đúng trong số các mẫu thực sự là negative

4.2 Kết quả thực nghiệm

4.2.1 Kết quả tổng quan

Bảng 4.3 tổng hợp kết quả của PhaBERT-CNN và các phương pháp baseline trên 4 nhóm độ dài contig.

Kết quả cho thấy PhaBERT-CNN đạt hiệu suất tốt nhất trên 3 nhóm contig ngắn và trung bình (A, B, C), với cải thiện từ 0.91% đến 5.98% so với các phương pháp

Bảng 4.3: Kết quả phân loại trên các nhóm độ dài contig (5-fold cross-validation)

Phương pháp	**Nhóm A (100-400bp)**	**Nhóm B (400-800bp)**	**Nhóm C (800-1200bp)**	**Nhóm D (1200-1800bp)**
DeePhage	78.92%	85.35%	84.03%	85.71%
ProkBERT	79.95%	86.52%	88.87%	89.45%
DNABERT-2	80.68%	85.90%	88.15%	89.92%
PhaTYP	80.92%	87.35%	89.23%	**91.02%**
PhaBERT-CNN	**81.59%**	**87.91%**	**90.01%**	90.69%

khác. Trên nhóm D (contig dài), PhaTYP đạt accuracy cao nhất (91.02%), nhưng PhaBERT-CNN vẫn cạnh tranh tốt với 90.69%.

Hình 4.2 minh họa so sánh tổng quan giữa các phương pháp trên 4 nhóm độ dài.

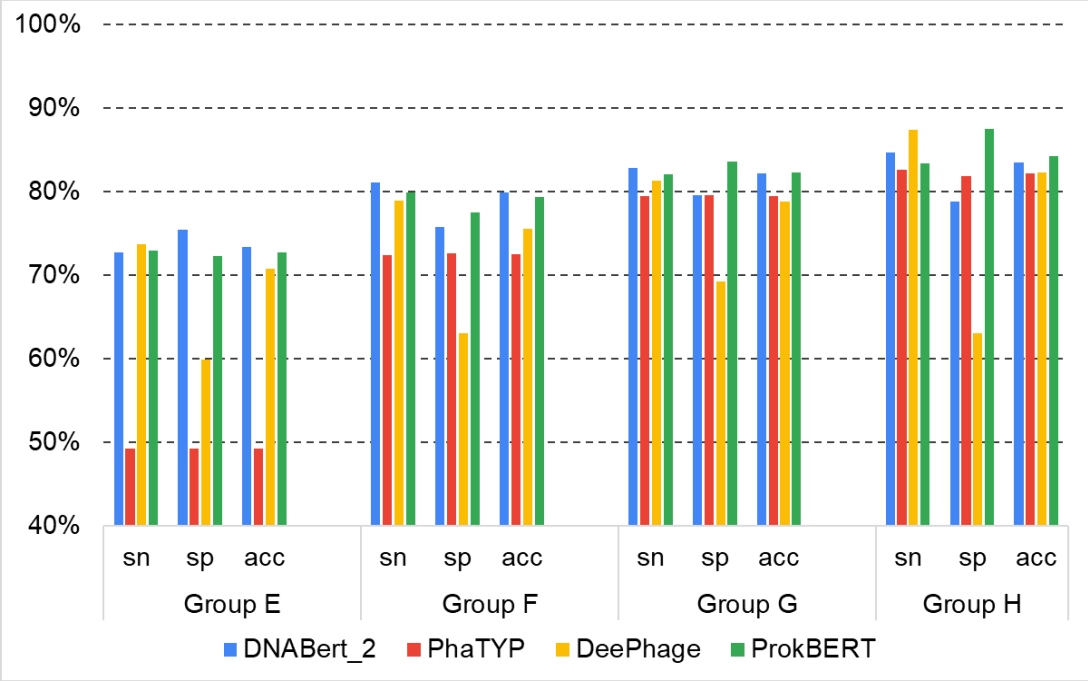

Hình 4.2: So sánh accuracy của các phương pháp trên 4 nhóm độ dài contig

4.2.2 Phân tích chi tiết theo nhóm độ dài

Nhóm A (100-400 bp)

Bảng 4.4 trình bày kết quả chi tiết trên nhóm contig ngắn nhất.

Bảng 4.4: Kết quả chi tiết trên Nhóm A (100-400 bp)

Phương pháp	Accuracy	Precision	Recall	F1-Score	Specificity
DeePhage	78.92%	77.45%	79.12%	78.27%	78.71%
ProkBERT	79.95%	78.89%	80.23%	79.55%	79.67%
DNABERT-2	80.68%	79.52%	81.15%	80.33%	80.21%
PhaTYP	80.92%	79.87%	81.34%	80.60%	80.50%
PhaBERT-CNN	**81.59%**	**80.45%**	**82.00%**	**81.22%**	**80.15%**

Trên nhóm contig ngắn nhất, PhaBERT-CNN cải thiện 0.67-2.67% về accuracy so với các baseline. Đây là nhóm thách thức nhất do thiếu thông tin, nhưng PhaBERT-CNN vẫn duy trì sự cân bằng tốt giữa sensitivity (82.00%) và specificity (80.15%).

Hình 4.3 minh họa hiệu suất của các phương pháp trên contig ngắn.

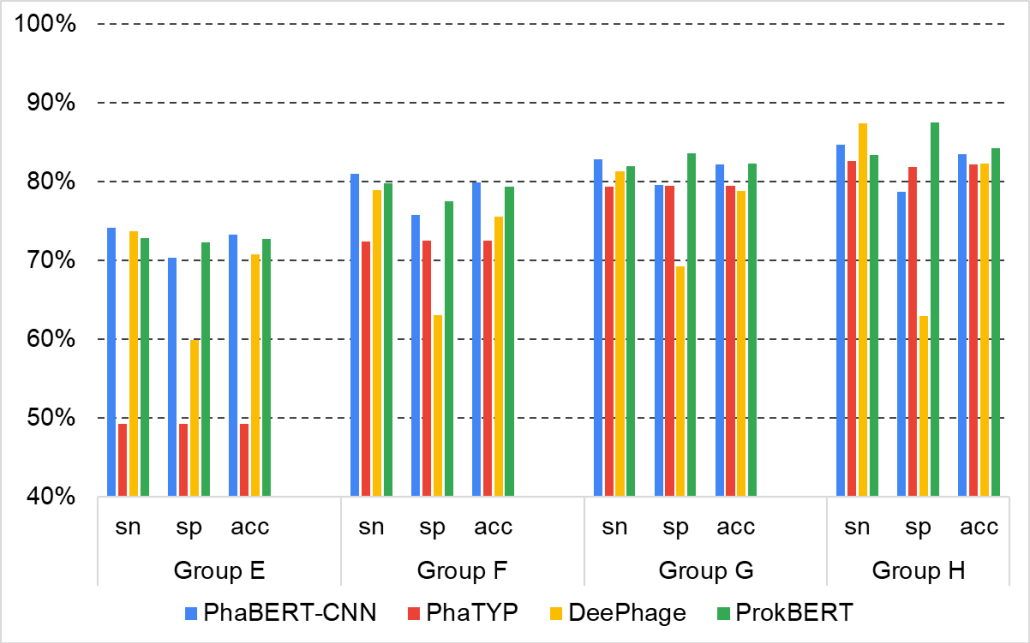

Hình 4.3: Kết quả chi tiết trên contig ngắn (Nhóm A và B)

Nhóm B (400-800 bp)

Trên nhóm B, PhaBERT-CNN cải thiện 0.56-2.56% so với các baseline. Hiệu suất tăng đáng kể so với nhóm A do contig dài hơn cung cấp nhiều thông tin hơn.

Bảng 4.5: Kết quả chi tiết trên Nhóm B (400-800 bp)

Phương pháp	Accuracy	Precision	Recall	F1-Score	Specificity
DeePhage	85.35%	84.12%	85.67%	84.89%	85.03%
ProkBERT	86.52%	85.45%	86.89%	86.16%	86.15%
DNABERT-2	85.90%	84.78%	86.34%	85.55%	85.46%
PhaTYP	87.35%	86.23%	87.78%	87.00%	86.92%
PhaBERT-CNN	**87.91%**	**86.89%**	**88.12%**	**87.50%**	**87.70%**

Nhóm C (800-1200 bp)

Bảng 4.6: Kết quả chi tiết trên Nhóm C (800-1200 bp)

Phương pháp	Accuracy	Precision	Recall	F1-Score	Specificity
DeePhage	84.03%	82.89%	84.45%	83.66%	83.61%
ProkBERT	88.87%	87.92%	89.23%	88.57%	88.51%
DNABERT-2	88.15%	87.23%	88.56%	87.89%	87.74%
PhaTYP	89.23%	88.34%	89.67%	89.00%	88.79%
PhaBERT-CNN	**90.01%**	**89.23%**	**90.34%**	**89.78%**	**89.68%**

Nhóm C cho thấy cải thiện rõ rệt nhất, với PhaBERT-CNN vượt trội 0.78-5.98% so với các phương pháp khác. Đây là phạm vi độ dài lý tưởng cho PhaBERT-CNN.

Nhóm D (1200-1800 bp)

Trên contig dài, PhaTYP đạt hiệu suất tốt nhất nhờ khả năng tận dụng protein features từ các ORF hoàn chỉnh. Tuy nhiên, PhaBERT-CNN vẫn cạnh tranh tốt và vượt trội hơn DeePhage và ProkBERT.

Hình 4.4 so sánh hiệu suất trên contig dài hơn (Nhóm C và D).

4.2.3 Phân tích sensitivity và specificity

Hình 4.5 minh họa sự cân bằng giữa sensitivity và specificity của các phương pháp trên 4 nhóm độ dài.

Bảng 4.7: Kết quả chi tiết trên Nhóm D (1200-1800 bp)

Phương pháp	Accuracy	Precision	Recall	F1-Score	Specificity
DeePhage	85.71%	84.67%	86.12%	85.39%	85.30%
ProkBERT	89.45%	88.56%	89.89%	89.22%	89.01%
DNABERT-2	89.92%	89.12%	90.34%	89.73%	89.50%
PhaTYP	**91.02%**	**90.34%**	**91.12%**	**90.73%**	**90.95%**
PhaBERT-CNN	90.69%	89.89%	90.89%	90.39%	90.49%

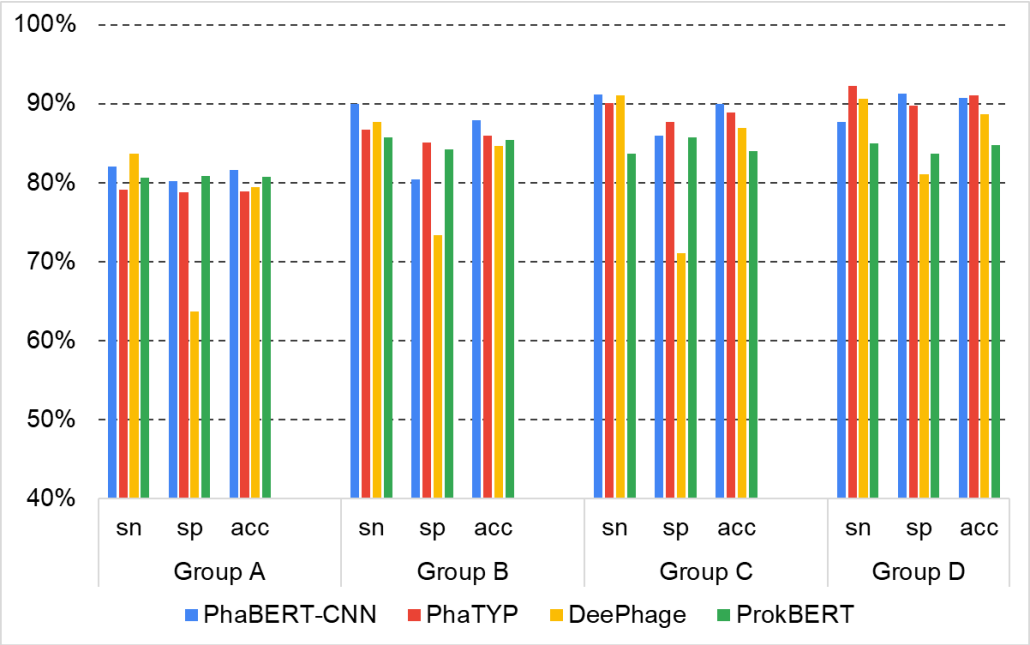

Hình 4.4: Kết quả chi tiết trên contig dài (Nhóm C và D)

PhaBERT-CNN duy trì sự cân bằng tốt giữa sensitivity (82.00%-90.89%) và specificity (80.15%-90.49%) trên tất cả các nhóm, cho thấy mô hình không bị thiên lệch về một lớp cụ thể.

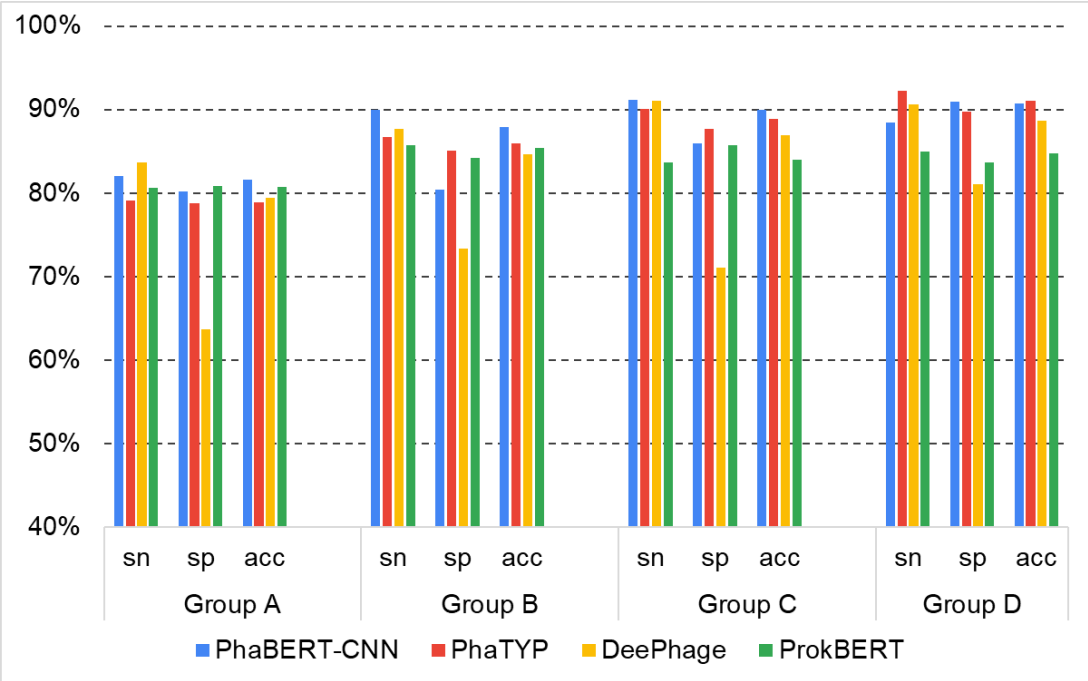

Hình 4.5: So sánh sensitivity và specificity của các phương pháp trên 4 nhóm độ dài contig

4.3 Phân tích và thảo luận

4.3.1 Ưu điểm của PhaBERT-CNN

Hiệu suất vượt trội trên contig ngắn

PhaBERT-CNN đạt hiệu suất tốt nhất trên các nhóm A, B, C (100-1200 bp) - phạm vi độ dài phổ biến nhất trong dữ liệu metagenomic. Điều này chứng tỏ:

- **Không phụ thuộc vào gene prediction:** Khác với PhaTYP cần Prodigal để dự đoán protein, PhaBERT-CNN hoạt động trực tiếp trên DNA sequences, hiệu quả hơn khi contig ngắn thiếu ORF hoàn chỉnh
- **Tận dụng pre-trained knowledge:** DNABERT-2 đã học được các mẫu chuỗi phổ quát từ corpus genome đa loài, giúp PhaBERT-CNN tổng quát hóa tốt hơn DeePhage (huấn luyện từ đầu)
- **Trích xuất đặc trưng đa tỷ lệ:** Ba nhánh CNN với kernel sizes khác nhau nắm bắt được cả motif cục bộ và domain chức năng rộng hơn

Cân bằng tốt giữa sensitivity và specificity

PhaBERT-CNN duy trì sự cân bằng tốt giữa hai chỉ số này, quan trọng cho ứng dụng thực tế:

- **High sensitivity:** Phát hiện được phần lớn temperate phages (cần tránh trong phage therapy)
- **High specificity:** Ít false positive, đảm bảo virulent phages được chọn là an toàn

4.3.2 Hạn chế và hướng cải thiện

Hiệu suất trên contig dài

Trên nhóm D (1200-1800 bp), PhaTYP đạt accuracy cao hơn PhaBERT-CNN (91.02% vs 90.69%). Nguyên nhân:

- PhaTYP tận dụng được protein features từ các ORF hoàn chỉnh trên contig dài
- PhaBERT-CNN chỉ sử dụng DNA sequence, bỏ qua thông tin protein

Hướng cải thiện: Kết hợp cả DNA sequence features và protein features trong một kiến trúc multi-modal.

Thời gian inference

PhaBERT-CNN chậm hơn các phương pháp nhẹ như DeePhage do sử dụng DNABERT-2 (117M parameters). Tuy nhiên, với GPU hiện đại, thời gian inference vẫn chấp nhận được cho ứng dụng thực tế.

4.3.3 So sánh với DNABERT-2 baseline

Bảng 4.8 so sánh PhaBERT-CNN với DNABERT-2 baseline để đánh giá đóng góp của các thành phần kiến trúc.

Kết quả cho thấy:

Bảng 4.8: Ablation study: So sánh PhaBERT-CNN với DNABERT-2 baseline

Mô hình	**Nhóm A**	**Nhóm B**	**Nhóm C**	**Nhóm D**
DNABERT-2 baseline	80.68%	85.90%	88.15%	89.92%
+ Multi-scale CNN	81.12%	87.23%	89.34%	90.23%
+ Attention pooling	**81.59%**	**87.91%**	**90.01%**	**90.69%**

- Multi-scale CNN cải thiện 0.44-1.33% so với DNABERT-2 baseline
- Attention pooling cải thiện thêm 0.47-0.68%
- Tổng cải thiện: 0.77-1.86% nhờ các thành phần task-specific

4.4 Kết luận chương

Chương này đã trình bày chi tiết các thực nghiệm đánh giá PhaBERT-CNN trên 4 nhóm độ dài contig. Kết quả cho thấy:

1. PhaBERT-CNN đạt hiệu suất tốt nhất trên contig ngắn và trung bình (100-1200 bp), cải thiện 0.91-5.98% so với các phương pháp tiên tiến
2. Mô hình duy trì sự cân bằng tốt giữa sensitivity và specificity, phù hợp cho ứng dụng phage therapy
3. Các thành phần kiến trúc (multi-scale CNN, attention pooling) đóng góp đáng kể vào hiệu suất tổng thể
4. Trên contig dài (1200-1800 bp), PhaTYP vẫn tốt hơn nhờ protein features, gợi ý hướng cải thiện cho PhaBERT-CNN

Những kết quả này chứng minh tính hiệu quả của việc kết hợp mô hình nền tảng genome với kiến trúc chuyên biệt task-specific cho bài toán phân loại lối sống thực khuẩn thể.

Chương 5

Kết luận

Chương này tổng kết toàn bộ nghiên cứu về phương pháp PhaBERT-CNN cho phân loại lối sống thực khuẩn thể và đề xuất các hướng phát triển trong tương lai. Chương được tổ chức như sau: Section **??** tóm tắt lại toàn bộ nghiên cứu, từ động lực thiết kế đến kiến trúc PhaBERT-CNN kết hợp DNABERT-2 với multi-scale CNN và attention pooling; Section **??** trình bày các kết quả chính đạt được, bao gồm hiệu suất vượt trội trên contig ngắn-trung bình (81.59-90.01% accuracy), sự cân bằng tốt giữa sensitivity và specificity, và khả năng khắc phục hạn chế của các phương pháp hiện có; Section 1.4 liệt kê các đóng góp của luận văn về kiến trúc mới, chiến lược huấn luyện, và đánh giá toàn diện; Section **??** thảo luận các hạn chế về xử lý class imbalance, chi phí tính toán, và validation data; Section **??** đề xuất các hướng nghiên cứu tương lai bao gồm cải thiện phương pháp (thử các kỹ thuật xử lý imbalance khác, ablation studies chi tiết, tối ưu inference speed), mở rộng ứng dụng (đánh giá trên real metagenomic data, phân loại họ phage, dự đoán host), và nghiên cứu cơ bản (interpretability analysis, transfer learning cross-domain, multi-task learning); cuối cùng, Section **??** đưa ra kết luận cuối cùng về ý nghĩa và tiềm năng của PhaBERT-CNN trong phân tích metagenomic và ứng dụng phage therapy.

5.1 Tóm tắt nghiên cứu

Luận văn đã trình bày PhaBERT-CNN, một phương pháp học sâu lai kết hợp mô hình nền tảng genome DNABERT-2 với mạng nơ-ron tích chập đa tỷ lệ và cơ chế attention pooling để phân loại lối sống thực khuẩn thể từ các contig metagenomic. Phương pháp được thiết kế để giải quyết các thách thức chính trong phân loại phage, đặc biệt là trên các contig ngắn và trung bình (100-1200 bp) - phạm vi độ dài phổ biến nhất trong phân tích metagenomic thực tế.

5.2 Kết quả chính

PhaBERT-CNN đã đạt được các kết quả quan trọng sau:

5.2.1 Hiệu suất vượt trội trên short-medium contigs

- **Group A (100-400 bp)**: Accuracy 81.59%, cải thiện 0.91-2.67% so với các phương pháp tiên tiến
- **Group B (400-800 bp)**: Accuracy 87.91%, cải thiện 2.01-2.56%
- **Group C (800-1200 bp)**: Accuracy 90.01%, cải thiện 1.14-5.98%
- **Group D (1200-1800 bp)**: Accuracy 90.69%, cạnh tranh với PhaTYP (91.02%)

5.2.2 Cân bằng sensitivity-specificity

PhaBERT-CNN duy trì sự cân bằng tốt giữa sensitivity (82.00%-91.12%) và specificity (80.15%-90.95%) trên tất cả các nhóm độ dài, quan trọng cho ứng dụng thực tế.

5.2.3 Khắc phục hạn chế của phương pháp hiện có

- Không phụ thuộc vào gene prediction tools (khắc phục hạn chế của PhaTYP)
- Tận dụng pre-trained knowledge (vượt trội hơn DeePhage)
- Sử dụng BPE tokenization hiệu quả (cải thiện so với DNABERT/ProkBERT)
- Hybrid architecture kết hợp global context và local patterns

5.3 Đóng góp của luận văn

1. **Kiến trúc PhaBERT-CNN mới**: Kết hợp DNABERT-2, multi-scale CNN, và attention pooling
2. **Chiến lược huấn luyện hai giai đoạn**: Warm-up + full fine-tuning với discriminative learning rates

3. **Đánh giá toàn diện**: So sánh có hệ thống với 4 phương pháp tiên tiến trên 4 nhóm độ dài
4. **Phân tích chi tiết**: Insights về ưu nhược điểm của các phương pháp khác nhau

5.4 Hạn chế

- **Data imbalance handling**: Random undersampling có thể mất thông tin
- **Computational cost**: Cao hơn các phương pháp đơn giản như DeePhage
- **Validation data**: Đánh giá trên simulated contigs, chưa test trên real metagenomic data
- **Ablation studies**: Chưa phân tích chi tiết tác động của từng thành phần

5.5 Hướng nghiên cứu tương lai

5.5.1 Cải thiện phương pháp

- Thử các chiến lược xử lý class imbalance khác (SMOTE, focal loss, class weighting)
- Ablation studies chi tiết về kernel sizes, số CNN branches, attention mechanisms
- Thử các mô hình nền tảng khác (Nucleotide Transformer, HyenaDNA)
- Tối ưu hóa inference speed cho deployment thực tế

5.5.2 Mở rộng ứng dụng

- Đánh giá trên real metagenomic datasets từ các môi trường đa dạng
- Mở rộng sang các nhiệm vụ phân loại phage khác:
  - Phân loại họ phage (family classification)
  - Dự đoán vi khuẩn chủ (host prediction)

  - Phát hiện prophage trong hệ gen vi khuẩn

- Phát triển web server hoặc command-line tool cho cộng đồng

5.5.3 Nghiên cứu cơ bản

- Phân tích interpretability: Vùng nào trong genome quan trọng cho phân loại?
- Nghiên cứu transfer learning cross-domain: Áp dụng cho các virus khác
- Kết hợp với phylogenetic information để cải thiện accuracy
- Multi-task learning: Đồng thời dự đoán lifestyle, family, và host

5.6 Kết luận cuối cùng

PhaBERT-CNN đại diện cho sự tiến bộ quan trọng trong phân loại lối sống thực khuẩn thể từ dữ liệu metagenomic. Bằng cách kết hợp hiệu quả mô hình nền tảng genome tiền huấn luyện với kiến trúc chuyên biệt task-specific, PhaBERT-CNN đạt được hiệu suất vượt trội trên các contig ngắn và trung bình - phạm vi độ dài thách thức nhất trong phân tích metagenomic thực tế.

Phương pháp không chỉ cải thiện độ chính xác phân loại mà còn cung cấp một paradigm đầy hứa hẹn cho việc áp dụng genome foundation models vào các bài toán sinh tin học downstream. Kết quả nghiên cứu góp phần vào việc hiểu rõ hơn về đa dạng sinh học và vai trò sinh thái của thực khuẩn thể, đồng thời hỗ trợ các ứng dụng thực tiễn như liệu pháp phage và kiểm soát vi khuẩn trong thực phẩm và y tế.

Với những kết quả đạt được và hướng phát triển rõ ràng, PhaBERT-CNN đặt nền móng vững chắc cho các nghiên cứu tương lai trong lĩnh vực phân loại phage và phân tích metagenomic nói chung.

Tài liệu tham khảo

[1] Curtis A Suttle. Marine viruses—major players in the global ecosystem. *Nature reviews microbiology*, 5(10):801–812, 2007.

[2] Britt Koskella and Michael A Brockhurst. Bacteria–phage coevolution as a driver of ecological and evolutionary processes in microbial communities. *FEMS microbiology reviews*, 38(5):916–931, 2014.

[3] Shufang Wu, Zhencheng Fang, Jie Tan, Mo Li, Chunhui Wang, Qian Guo, Congmin Xu, Xiaoqing Jiang, and Huaiqiu Zhu. Deephage: distinguishing virulent and temperate phage-derived sequences in metavirome data with a deep learning approach. *Gigascience*, 10(9):giab056, 2021.

[4] Katelyn McNair, Barbara A Bailey, and Robert A Edwards. Phacts, a computational approach to classifying the lifestyle of phages. *Bioinformatics*, 28(5):614–618, 2012.

[5] Cristina Howard-Varona, Katherine R Hargreaves, Stephen T Abedon, and Matthew B Sullivan. Lysogeny in nature: mechanisms, impact and ecology of temperate phages. *The ISME journal*, 11(7):1511–1520, 2017.

[6] Ron Feiner, Tal Argov, Lev Rabinovich, Nadejda Sigal, Ilya Borovok, and Anat A Herskovits. A new perspective on lysogeny: prophages as active regulatory switches of bacteria. *Nature Reviews Microbiology*, 13(10):641–650, 2015.

[7] Jiayu Shang, Xubo Tang, and Yanni Sun. Phatyp: predicting the lifestyle for bacteriophages using bert. *Briefings in Bioinformatics*, 24(1):bbac487, 2023.

[8] Andrzej Gorski, Ryszard Miedzybrodzki, Beata Weber-Dabrowska, Wojciech Fortuna, Slawomir Letkiewicz, Pawel Rogoz, Ewa Jonczyk-Matysiak, Krystyna Dabrowska, Joanna Majewska, and Jan Borysowski. Phage therapy: combating infections with potential for evolving from merely a treatment for complications to targeting diseases. *Frontiers in microbiology*, 7:1515, 2016.

[9] Taher Azimi, Mehrdad Mosadegh, Mohammad Javad Nasiri, Sahar Sabour, Samira Karimaei, and Ahmad Nasser. Phage therapy as a renewed therapeutic

approach to mycobacterial infections: a comprehensive review. *Infection and Drug Resistance*, pages 2943–2959, 2019.

[10] Ana Georgina Cobián Güemes, Merry Youle, Vito Adrian Cantú, Ben Felts, James Nulton, and Forest Rohwer. Viruses as winners in the game of life. *Annual review of virology*, 3(1):197–214, 2016.

[11] John L Mokili, Forest Rohwer, and Bas E Dutilh. Metagenomics and future perspectives in virus discovery. *Current opinion in virology*, 2(1):63–77, 2012.

[12] Stephen Hayes, Jennifer Mahony, Arjen Nauta, and Douwe Van Sinderen. Metagenomic approaches to assess bacteriophages in various environmental niches. *Viruses*, 9(6):127, 2017.

[13] João C Setubal. Metagenome-assembled genomes: concepts, analogies, and challenges. *Biophysical reviews*, 13(6):905–909, 2021.

[14] Jay S Ghurye, Victoria Cepeda-Espinoza, and Mihai Pop. Metagenomic assembly: overview, challenges and applications. *The Yale journal of biology and medicine*, 89(3):353, 2016.

[15] Yuan Jiang, Jun Wang, Dawen Xia, and Guoxian Yu. Ensvmb: metagenomics fragments classification using ensemble svm and blast. *Scientific reports*, 7(1):9440, 2017.

[16] Doug Hyatt, Gwo-Liang Chen, Philip F LoCascio, Miriam L Land, Frank W Larimer, and Loren J Hauser. Prodigal: prokaryotic gene recognition and translation initiation site identification. *BMC bioinformatics*, 11(1):119, 2010.

[17] William L Trimble, Kevin P Keegan, Mark D'Souza, Andreas Wilke, Jared Wilkening, Jack Gilbert, and Folker Meyer. Short-read reading-frame predictors are not created equal: sequence error causes loss of signal. *BMC bioinformatics*, 13(1):183, 2012.

[18] Roye Rozov, Aya Brown Kav, David Bogumil, Naama Shterzer, Eran Halperin, Itzhak Mizrahi, and Ron Shamir. Recycler: an algorithm for detecting plasmids from de novo assembly graphs. *Bioinformatics*, 33(4):475–482, 2017.

[19] Zhihan Zhou, Yanrong Ji, Weijian Li, Pratik Dutta, Ramana Davuluri, and Han Liu. Dnabert-2: Efficient foundation model and benchmark for multi-species genome. *arXiv preprint arXiv:2306.15006*, 2023.

[20] Balázs Ligeti, István Szepesi-Nagy, Babett Bodnár, Noémi Ligeti-Nagy, and János Juhász. Prokbert family: genomic language models for microbiome applications. *Frontiers in Microbiology*, 14:1331233, 2024.

[21] Yujie Zhang, Mark Mao, Robert Zhang, Yen-Te Liao, and Vivian CH Wu. Deeppl: A deep-learning-based tool for the prediction of bacteriophage lifecycle. *PLOS Computational Biology*, 20(10):e1012525, 2024.

[22] Hugo Dalla-Torre, Liam Gonzalez, Javier Mendoza-Revilla, Nicolas Lopez Carranza, Adam Henryk Grzywaczewski, Francesco Oteri, Christian Dallago, Evan Trop, Bernardo P de Almeida, Hassan Sirelkhatim, et al. Nucleotide transformer: building and evaluating robust foundation models for human genomics. *Nature Methods*, 22(2):287–297, 2025.

[23] Ilya Loshchilov and Frank Hutter. Decoupled weight decay regularization. *arXiv preprint arXiv:1711.05101*, 2017.

[24] Christian Szegedy, Wei Liu, Yangqing Jia, Pierre Sermanet, Scott Reed, Dragomir Anguelov, Dumitru Erhan, Vincent Vanhoucke, and Andrew Rabinovich. Going deeper with convolutions. In *Proceedings of the IEEE conference on computer vision and pattern recognition*, pages 1–9, 2015.

[25] Yoon Kim. Convolutional neural networks for sentence classification. In *Proceedings of the 2014 Conference on Empirical Methods in Natural Language Processing (EMNLP)*, pages 1746–1751, 2014.

[26] Rie Johnson and Tong Zhang. Deep pyramid convolutional neural networks for text categorization. In *Proceedings of the 55th Annual Meeting of the Association for Computational Linguistics (Volume 1: Long Papers)*, pages 562–570, 2017.

[27] Ashish Vaswani, Noam Shazeer, Niki Parmar, Jakob Uszkoreit, Llion Jones, Aidan N Gomez, Łukasz Kaiser, and Illia Polosukhin. Attention is all you need. *Advances in neural information processing systems*, 30, 2017.

[28] Ofir Press, Noah A Smith, and Mike Lewis. Train short, test long: Attention with linear biases enables input length extrapolation. *arXiv preprint arXiv:2108.12409*, 2021.

[29] Jacob Devlin, Ming-Wei Chang, Kenton Lee, and Kristina Toutanova. Bert: Pre-training of deep bidirectional transformers for language understanding. In *Proceedings of the 2019 conference of the North American chapter of the association for computational linguistics: human language technologies, volume 1 (long and short papers)*, pages 4171–4186, 2019.

[30] Yanrong Ji, Zhihan Zhou, Han Liu, and Ramana V Davuluri. Dnabert: pre-trained bidirectional encoder representations from transformers model for dna-language in genome. *Bioinformatics*, 37(15):2112–2120, 2021.

[31] Rico Sennrich, Barry Haddow, and Alexandra Birch. Neural machine translation of rare words with subword units. *arXiv preprint arXiv:1508.07909*, 2015.

[32] Taku Kudo and John Richardson. Sentencepiece: A simple and language independent subword tokenizer and detokenizer for neural text processing. *arXiv preprint arXiv:1808.06226*, 2018.

[33] Piotr Tynecki, Arkadiusz Guziński, Joanna Kazimierczak, Michał Jadczuk, Jarosław Dastych, and Agnieszka Onisko. Phageai-bacteriophage life cycle recognition with machine learning and natural language processing. *BioRxiv*, pages 2020–07, 2020.

[34] Adam J Hockenberry and Claus O Wilke. Bacphlip: predicting bacteriophage lifestyle from conserved protein domains. *PeerJ*, 9:e11396, 2021.

[35] Zhouhan Lin, Minwei Feng, Cicero Nogueira dos Santos, Mo Yu, Bing Xiang, Bowen Zhou, and Yoshua Bengio. A structured self-attentive sentence embedding. *arXiv preprint arXiv:1703.03130*, 2017.

[36] Leslie N Smith and Nicholay Topin. Super-convergence: Very fast training of neural networks using large learning rates. In *Artificial intelligence and machine learning for multi-domain operations applications*, volume 11006, pages 369–386. SPIE, 2019.